

АГЕНТНЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Руководство
по трансформации бизнеса



Паскаль Борне

ПАСКАЛЬ БОРНЕ

Йохен Виртц – Томас Х. Давенпорт,
Дэвид Де Кремер – Брайан Эвергрин
Фил Фершт – Ракеш Гохел – Шаил Кхийара

АГЕНТНЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

AGENTIC ARTIFICIAL INTELLIGENCE

Harnessing AI Agents
to Reinvent Business, Work, and Life

PASCAL BORNET

Jochen Wirtz – Thomas H. Davenport

David De Cremer – Brian Evergreen

Phil Fersht – Rakesh Gohel – Shail Khiyara

АГЕНТНЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Руководство
по трансформации бизнеса

ПАСКАЛЬ БОРНЕ

Йохен Виртц – Томас Х. Давенпорт,
Дэвид Де Кремер – Брайан Эвергрин
Фил Фершт – Ракеш Гохел – Шаил Кхийара



Москва, 2025

УДК 005:004.8
ББК 65.29+16.6
Б82

Паскаль Борне

Б82 Агентный искусственный интеллект. Руководство по трансформации бизнеса / пер. с англ. И. Л. Люско. – М.: ДМК Пресс, 2025. – 398 с.: ил.

ISBN 978-5-93700-393-5

Книга посвящена агентному ИИ, новому уровню искусственного интеллекта, который, в отличие от генеративного, уже может размышлять, принимать решения и самостоятельно действовать. Цель авторов – дать инструменты для трансформации бизнеса и построения лучшего мира, в котором работники избавлены от рутины и свое рабочее время посвящают более интеллектуальной и творческой деятельности, а предприятия в целом работают намного эффективнее. Вы убедитесь, что адаптация к новой реальности, в которой человек работает в тесном сотрудничестве с ИИ-агентами, напрямую связана с успехом, а иногда и выживанием бизнеса.

Эта книга написана для лидеров, профессионалов, предпринимателей и любопытных умов, которые ощущают масштаб грядущих изменений и хотят понять, как с ними справиться и обратить во благо.

УДК 005:004.8
ББК 65.29+16.6

All rights reserved. This book, or parts thereof, may not be reproduced in any form or by any means, electronic or mechanical, including photocopying, recording or any information storage and retrieval system now known or to be invented, without written permission from the Publisher. Russian translation arranged with World Scientific Publishing Co Pte Ltd, Singapore.

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

Материал, изложенный в данной книге, многократно проверен. Но, поскольку вероятность технических ошибок все равно существует, издательство не может гарантировать абсолютную точность и правильность приводимых сведений. В связи с этим издательство не несет ответственности за возможные ошибки, связанные с использованием книги.

«Агенты (...) вызывают самую значительную революцию в вычислениях с тех пор, как мы перешли от ввода команд к нажатию на иконки». – Билл Гейтс

«ИИ-агенты станут основным способом взаимодействия с компьютерами в будущем». – Сатъя Наделла

«Эра агентного ИИ наступила». – Дженсен Хуанг

*Мы посвящаем эту книгу нашим детям
и всем детям мира.*

Мы обязаны обеспечить им лучшее будущее

Оглавление

Предисловие от издательства	10
Предисловие: путешествие к человеческим возможностям	19
Введение.....	22
ЧАСТЬ 1. РОЖДЕНИЕ ИИ-АГЕНТОВ.....	47
Глава 1. За пределами ChatGPT: дальнейшая эволюция ИИ.....	48
Рождение агентного ИИ: слияние сил	48
Агентный ИИ для предпринимательства и бизнеса	57
Уровень внедрения ИИ-агентов в компаниях.....	62
Глава 2. Пять уровней ИИ-агентов:	
от автоматизации к автономии	67
Разбор возможностей ИИ-агентов	67
Сложная реальность возможностей ИИ-агентов	71
Прогрессивный фреймворк агентного ИИ	72
Магия прогрессивной автономии: уровни ИИ-агентов	78
Глава 3. Внутри разума ИИ-агента	82
Ключевые особенности ИИ-агентов	82
Ограничения, присущие ИИ-агентам	84
Когда одного недостаточно: возможности мультиагентных систем и практика их применения	87
Дилемма агента: баланс между креативностью и надежностью	93
Глава 4. Испытание ИИ-агентов.....	99
Цифровые руки: когда ИИ научился использовать компьютеры	99
Первые шаги с ИИ-агентом «Computer Use»: тест с обработкой счета	101
Когда ИИ сталкивается с вызовом «максимизатора скрепок»	102
Результат эксперимента.....	106
Уроки, извлеченные из экспериментов	108
ЧАСТЬ 2. ТРИ КРАЕУГОЛЬНЫХ КАМНЯ АГЕНТНОГО ИИ...111	
Глава 5. Действие: обучение ИИ действовать,	
а не только думать.....	115
Дилемма детектива	116
Инструменты как строительные блоки.....	118
Внутри набора инструментов ИИ-агента	122
От базового использования инструментов к продвинутому	126
Когда инструменты встречаются с доверием	133

Глава 6. Рассуждение: от быстрого к мудрому	140
Как рассуждает ИИ: в чем сила паузы.....	141
Сила множества: многоагентные системы в рассуждениях ИИ.....	153
Глава 7. Память: построение ИИ, который учится	161
Память как основа интеллекта	162
Замысловатый танец краткосрочной памяти в агентах ИИ.....	167
Сила долгосрочной памяти: превращение ИИ из инструмента в партнера....	173
Разработка и внедрение долгосрочной памяти в системах агентного ИИ	175
Адаптация и обучение через циклы обратной связи	182
Лучшие практики управления памятью ИИ-агентов	192
ЧАСТЬ 3. ПРЕДПРИНИМАТЕЛЬСТВО И ПРОФЕССИОНАЛЬНЫЙ РОСТ С ИИ-АГЕНТАМИ	199
Глава 8. Практическое руководство по созданию успешных агентов ИИ	200
Шаг 1. Поиск правильных областей применения агентов.....	200
Шаг 2. Определение роли и возможностей агентов ИИ.....	211
Шаг 3. Разработка агентов ИИ для успеха.....	215
Шаг 4. Внедрение разработанных вами агентов ИИ.....	220
Глава 9. От идей к получению дохода: бизнес-модели для агентной экономики	246
Рождение самоуправляемого бизнеса: когда ИИ стал предпринимателем.....	246
Новые бизнес-модели в эпоху агентного ИИ	250
Создание возможностей в экономике агентного ИИ: новая золотая лихорадка приложений	259
ЧАСТЬ 4. ТРАНСФОРМАЦИЯ ПРЕДПРИЯТИЙ ЧЕРЕЗ АГЕНТНЫЙ ИИ	267
Глава 10. Сотрудничество человек–агент: лидерство, доверие и изменения	268
Проектирование рабочего процесса и управлением изменениями в масштабе	268
Лидерство в эпоху ИИ-агентов: построение доверия и сотрудничества в гибридных командах.....	280
Стратегии коммуникации в гибридных командах	285
Основа: стратегия управления и контроль.....	289
Глава 11. Масштабирование ИИ-агентов: от стратегии к реальности	299
Правильный подход к масштабированию	299
Преимущество опыта автоматизации: от агентов уровня 2 к уровню 3	304

Использование генеративного ИИ и ИИ-агентов для холистической корпоративной перестройки	307
Когда агенты выходят из-под контроля: создание необходимых защитных мер для систем ИИ	312

Глава 12. Пример из практики и сценарии использования агентов в различных отраслях 316

Пример из практики. Новаторская трансформация корпоративного агента на основе искусственного интеллекта: Pets at Home	316
Сценарии применения агентов в различных функциях и отраслях.....	324

ЧАСТЬ 5. ГОРИЗОНТЫ БУДУЩЕГО ДЛЯ ЗАНЯТОСТИ И ОБЩЕСТВА В ЦЕЛОМ 327

Глава 13. Новый мир занятости 328

Переосмысление работы: симфония человека и машины.....	328
На этот раз все иначе: рождение агентного ИИ	335
Переосмысление образования в эпоху агентов ИИ	337

Глава 14. Общество в эпоху агентов 342

Переосмысление человеческого потенциала в мире, управляемом агентами искусственного интеллекта	342
Набор методов управления будущим агентного ИИ	347
Заключение	353
Следующий горизонт: новые возможности	353
Срочность установления контроля над ИИ: создание ограничительных фреймворков до того, как станет слишком поздно	355
Рефлексия и более широкие последствия.....	356
Ваш план действий	357
Сила выбора	359
Дополнительные ресурсы по агентному ИИ	361

Приложения: практические ресурсы..... 362

Глава 2. Ландшафт текущих предложений через призму прогрессивного фреймворка агентов ИИ	362
Глава 8. Пример идентичности агента ИИ: наш агент по резюмированию новостной рассылки.....	363
Глава 8. Пример процедур обработки ошибок для проекта новостной рассылки	366
Глава 8. Пример реализации агента с использованием платформы Low-code.....	368
Глава 12. Сценарии использования: применение агентов ИИ на предприятиях.....	382
Глава 12. Сценарии использования: применения агентов ИИ для личной результативности	392

Предметный указатель.....	395
---------------------------	-----

Предисловие от издательства

Отзывы и пожелания

Мы всегда рады отзывам наших читателей. Расскажите нам, что вы думаете об этой книге – что понравилось или, может быть, не понравилось. Отзывы важны для нас, чтобы выпускать книги, которые будут для вас максимально полезны.

Вы можете написать отзыв на нашем сайте www.dmkpress.com, зайдя на страницу книги и оставив комментарий в разделе «Отзывы и рецензии». Также можно послать письмо главному редактору по адресу dmkpress@gmail.com; при этом укажите название книги в теме письма.

Если вы являетесь экспертом в какой-либо области и заинтересованы в написании новой книги, заполните форму на нашем сайте по адресу http://dmkpress.com/authors/publish_book/ или напишите в издательство по адресу dmkpress@gmail.com.

Список опечаток

Хотя мы приняли все возможные меры для того, чтобы обеспечить высокое качество наших текстов, ошибки все равно случаются. Если вы найдете ошибку в одной из наших книг – возможно, ошибку в основном тексте или программном коде, – мы будем очень благодарны, если вы сообщите нам о ней. Сделав это, вы избавите других читателей от недопонимания и поможете нам улучшить последующие издания этой книги.

Если вы найдете какие-либо ошибки в коде, пожалуйста, сообщите о них главному редактору по адресу dmkpress@gmail.com, и мы исправим это в следующих тиражах.

Нарушение авторских прав

Пиратство в интернете по-прежнему остается насущной проблемой. Издательство «ДМК Пресс» очень серьезно относится к вопросам защиты авторских прав и лицензирования. Если вы столкнетесь в интернете с незаконной публикацией какой-либо из наших книг, пожалуйста, пришлите нам ссылку на интернет-ресурс, чтобы мы могли применить санкции.

Ссылку на подозрительные материалы можно прислать по адресу dmkpress@gmail.com.

Мы высоко ценим любую помощь по защите наших авторов, благодаря которой мы можем предоставлять вам качественные материалы.

Об авторах

Паскаль Борне

Паскаль Борне – отмеченный наградами эксперт, автор и известнейший спикер по искусственному интеллекту и автоматизации. Он получил множество наград и регулярно входит в десятку лучших мировых экспертов по ИИ и автоматизации. Он также является влиятельным лицом с более чем двумя миллионами подписчиков в социальных сетях.



Борне развивал свою компетенцию на протяжении более двух десятилетий в качестве старшего руководителя в McKinsey и EY, где он основал и возглавил практики «Интеллектуальной автоматизации». За это время он внедрил инициативы по ИИ и автоматизации для сотен организаций по всему миру, стимулируя инновационные изменения в различных отраслях.

Он является автором двух бестселлеров: «Интеллектуальная автоматизация» и «Незаменимый». Его идеи были представлены в престижных изданиях, таких как Forbes, Bloomberg, McKinsey Quarterly и The Times. Он также читает лекции в нескольких университетах, является членом технологического совета Forbes и старшим советником нескольких стартапов и благотворительных организаций.

На протяжении последних 20 лет исследования Борне сосредоточены на пересечении ИИ и человека, где, как он считает, лежит наибольшая ценность. Он ярый сторонник человеко-ориентированного ИИ и верит, что при правильном подходе ИИ может сделать наш мир более человечным.

Узнайте больше о Борне на www.linkedin.com/in/pascalbornet/.

Свяжитесь с Борне на YouTube, Instagram и X: [@pascal_bornet](#).

Йохен Виртц

Профессор Йохен Виртц – вице-декан программ MBA и профессор маркетинга в Национальном университете Сингапура. Он является ведущим авторитетом в области управления сервисами с более чем 200 публикациями. Среди его более чем 20 книг – «Интеллектуальная автоматизация: научитесь использовать искусственный интеллект для развития бизнеса и сделайте наш мир более человечным» (2021), «Маркетинг услуг: люди, технологии, стратегия» (9-е издание, 2022) и «Основы маркетинга услуг» (4-е издание, 2023).

С переводами и адаптациями для более чем 26 стран и регионов и совокупными продажами более одного миллиона копий эти книги стали ведущими мировыми учебниками по маркетингу услуг.

Помимо своих публикаций, профессор Виртц был признан одним из 86 наиболее цитируемых исследователей в области экономики и бизнеса в 2023 году (Web of Science). Это отличие ставит его в число самых выдающихся исследователей мира, как подчеркивается в списке «Высокоцитируемые исследователи 2023» (опубликованном аналитической компанией Clarivate). Это признание подчеркивает его глубокое влияние как на академические исследования, так и на управленческую практику. Продолжающийся вклад профессора Виртца гарантирует, что он остается на передовой своей области, где его знания и опыт продолжают формировать стратегии сервисных предприятий по всему миру.

Следите за Йохеном на LinkedIn (<https://www.linkedin.com/in/jochenwirtz>), YouTube (<https://www.youtube.com/c/ProfessorJochenWirtz>) и ResearchGate (<https://www.researchgate.net/profile/Jochen-Wirtz>).



Томас Х. Давенпорт

Том Давенпорт – выдающийся президентский профессор¹ информационных технологий и управления в Колледже Бэбсон, научный сотрудник Инициативы MIT по цифровой экономике и старший советник программы главного директора по данным и аналитике Deloitte. В 2024–2025 годах он является профессором аналитики **Bodily Bicentennial** в Школе бизнеса Дардена Университета Вирджинии². Он стал пионером концепции «конкуренции на основе аналитики» со своей статьей-бестселлером 2006 года в Harvard Business Review и книгой 2007 года под тем же названием.

Он опубликовал 25 книг и более 300 статей для Harvard Business Review, MIT Sloan Management Review и многих других изданий. Его последняя книга – «Все руки на технологии: революция граждан, основанная на ИИ», написанная в соавторстве с Яном Баркиным. Он пишет колонки для Forbes, MIT Sloan Management Review и The Wall Street Journal.

Его называли одним из «25 лучших консультантов мира» по версии журнала Consulting, одним из трех лучших аналитиков в области бизнеса и технологий, по версии журнала Optimize, одним из 100 самых влиятельных людей в ИТ-индустрии по версии журналов Ziff-Davis и одним из 50 лучших профессоров бизнес-школ мира, по версии журнала Fortune. Он также был признан LinkedIn Top Voice как в образовательном, так и в технологическом секторах.



¹ «Президентский профессор» – это одно из характерных для учебного заведения званий, которое присваивается небольшому проценту профессорско-преподавательского состава высшего звена, считающегося особенно важным в своих областях исследований. – Прим. ред.

² Профессор аналитики **Bodily Bicentennial** – это почетная академическая должность в Школе бизнеса Дарден Университета Вирджинии, названная в честь Сэма Бодили, заслуженного профессора, известного своими работами в области анализа решений. Слово Bodily обозначает фамилию Сэма Бодили, в честь которого учреждена эта должность. Бисентенниал указывает на связь с двухсотлетним юбилеем Университета Вирджинии. – Прим. ред.

Давид Де Кремер

Давид Де Кремер – декан Школы бизнеса Д’Амор-МакКим семейного фонда Дантона и профессор менеджмента и технологий в Северо-Восточном университете. Он является основателем Центра технологий ИИ для человечества (AiTH) в Сингапуре, членом консультативного совета ЕУ по глобальному ИИ и почетным научным сотрудником Кембриджского университета и Колледжа Сент-Эдмундс (где он ранее был заслуженным профессором менеджмента KPMG).



Он автор бестселлеров «Лидерство по алгоритму: кто ведет, а кто следует в эпоху ИИ» (2020; Harriman House) и «ИИ-подкованный лидер: 9 способов вернуть контроль и заставить ИИ работать» (2024; Harvard Business Review Press), причем его последняя книга стала №1 среди новинок на Amazon, была названа обязательной для чтения книгой The Next Big Idea Club, The Financial Times и Forbes, а также победителем в категории лидерства премии «Выдающееся произведение литературы 2024».

Его научные работы упоминаются в Financial Times, The Economist, Wall Street Journal, Forbes и публикуются в ведущих научных журналах по менеджменту и психологии, что принесло ему признание как лидера мысли Thinkers50, гурӯ менеджмента и спикера мирового топ-30, а также включение в мировой топ-2 % ученых.

Узнайте больше о Де Кремере на: www.daviddecremer.com.

Свяжитесь с Де Кремером на LinkedIn или YouTube.

Брайан Эвергрин

Брайан Эвергрин – один из самых уважаемых голосов в области стратегии и ИИ, ведущий автор, консультант и спикер. Брайан является автором книги «Автономная трансформация: создание более человеческого будущего в эпоху ИИ», названной «обязательной для чтения», по версии The Next Big Idea Club, и одной из 10 лучших новых книг по менеджменту 2024 года, по версии Thinkers50.

В 2025 году Брайан был назван одним из 50 лучших создателей ИИ, которых нужно знать, по версии Edelman, и одним из 30 мыслителей, переопределяющих лидерство в 2025 году, по версии Forbes.

Инсайты Брайана основаны на его личном опыте работы в ведущих компаниях, включая Accenture, AWS и Microsoft. Когда он не выступает с важнейшими докладами или консультирует компании по ИИ, Брайан читает гостевые лекции в Школе менеджмента Келлогга, делясь нестандартными и инновационными методами и фреймворками, которые он разработал и которые поддерживали инвестиции на сумму более 20 млрд долл.

Брайан – основатель The Future Solving Company, где он помогает организациям позиционировать себя для будущего в эпоху ИИ, и является консультантом более чем дюжины компаний из списка Fortune 500.

Его работы были представлены в Bloomberg, Forbes, Fast Company, CIO, VentureBeat, The Next Big Idea Club и Thinkers50.

Узнайте больше об Эвергрине на www.linkedin.com/in/brianevergreen.



Фил Фершт

Фил Фершт широко признан ведущим мировым аналитиком, сосредоточенным на переосмыслении бизнес-операций для использования инноваций в области ИИ и глобализации талантов. Недавно он ввел термин «Услуги как программное обеспечение»¹, чтобы описать будущее профессиональных услуг, где работа, основанная на людях, сливается с технологиями. Он также зарегистрировал торговую марку «Генеративное предприятие™» в 2023 году.



Его репутация побудила его основать HFS Research в 2010 году, которая сегодня является одной из ведущих аналитических и консультативных фирм и бесспорным лидером в исследованиях бизнес- и технологических услуг и технологий процессов.

В 2012 году он написал первый аналитический отчет о роботизированной автоматизации процессов (RPA), представив эту тему индустрии. Его широко признают как пионера-аналитика, который создал и вдохновил сегодняшнюю индустрию RPA и процессного ИИ².

До основания HFS в 2010 году Фил занимал аналитические роли в Gartner и IDC и был лидером рынка BPO в Deloitte Consulting в США. Последние 20 лет Фершт жил и работал в Европе, Северной Америке и Азии, где консультировал по сотням глобальных трансформаций бизнеса и технологий.

Узнайте больше о Филе Ферште на LinkedIn: <https://www.linkedin.com/in/pfersht>.

Блог: horsesforsources.com.

Веб: www.hfsresearch.com.

Подкаст: [From the Horses Mouth](#).

¹ Услуги как программное обеспечение (Software as a Service, SaaS) – это модель предоставления программного обеспечения через интернет. Вместо того чтобы покупать и устанавливать программы на компьютеры, можно подписаться на SaaS-сервис и использовать приложения в онлайн. – Прим. ред.

² Термин «Process AI» (процессный ИИ) относится к применению искусственного интеллекта для автоматизации, оптимизации и управления бизнес-процессами. Это подразумевает использование ИИ для анализа, выполнения или улучшения сложных процессов в организации, таких как обработка данных, координация задач, принятие решений или взаимодействие между различными подразделениями. Это ИИ, который интегрируется в сквозные бизнес-процессы для повышения эффективности, устранения фрагментации и улучшения взаимодействия с клиентами или сотрудниками. – Прим. ред.)

Ракеш Гохел

Ракеш Гохел – дальновидный технологический лидер с более чем двадцатилетним опытом формирования эволюции цифровой трансформации – от бума доткомов до мобильных технологий, облаков, блокчейна и ИИ. На протяжении своей карьеры он руководил новаторскими проектами в различных отраслях, включая работу с мировыми гигантами, такими как Samsung и LG, где он ускорил циклы развертывания в четыре раза и удвоил инновационную способность трансформаций. Его влияние распространяется на различные сектора, где он последовательно выявлял новые потребности рынка и предоставлял передовые решения.

Как основатель JUTEQ, Ракеш зарекомендовал себя как авторитет в области агентов ИИ, разрабатывая масштабируемые, безопасные системы, которые сократили операционные расходы на 70 %, сохраняя при этом почти идеальное время безотказной работы для клиентов.

Сегодня он является ведущим голосом в области агентного ИИ, пионером автономных систем, которые переопределяют бизнес-операции. С предпринимательским мышлением и глубокой технической компетентностью он страстно желает обучать других тому, как генеративный ИИ формирует будущее предприятий.

В своей основе Ракеш верит в инновационную силу ИИ, когда он согласован с человеческой изобретательностью. Его миссия – разрабатывать ответственные системы ИИ, которые усиливают человеческие способности, стимулируя бизнес-инновации, сохраняя при этом человеческий элемент в центре технологического прогресса.

Свяжитесь с Ракешем: www.linkedin.com/in/rakeshgohel01 или @rakeshgohel01.



Шаил Хияра

Шаил Хияра – признанный глобальный лидер мысли, автор и известнейший спикер в области искусственного интеллекта и интеллектуальной автоматизации.

Его идеи были представлены в престижных изданиях, таких как Forbes, WSJ Digital, Financial Times и CIO Online. Он входит в совет директоров нескольких ИИ-компаний и является старшим советником некоммерческих социально ответственных предприятий.

С более чем двадцатилетним опытом Хияра руководил трансформациями, основанными на ИИ, в различных отраслях, занимая должности главного маркетингового директора и главного клиентского директора в нескольких ведущих фирмах по интеллектуальной автоматизации, где он сыграл ключевую роль в масштабировании внедрения ИИ и автоматизации по всему миру. Ранее в своей карьере он работал в Bechtel, приобретая глубокие знания в нефтегазовой отрасли, водоснабжении, энергетике и горнодобывающей промышленности – знания, которые теперь формируют его подход как генерального директора SWARM Engineering, платформы агентного ИИ, трансформирующей промышленные операции.

Хияра – соавтор книги «Интеллектуальная автоматизация – преодоление разрыва между бизнесом и академией» и основатель VOCAL (Голос клиента в ландшафте ИИ и автоматизации), глобального аналитического центра, объединяющего более 90 лидеров из списка Fortune 500 для продвижения внедрения ИИ.

Ярый сторонник демократизации ИИ, Хияра выступает за ИИ, который усиливает человеческий потенциал, способствует сотрудничеству и стимулирует трансформацию – не заменяя человеческую изобретательность.

Узнайте больше о Шаиле на www.linkedin.com/in/shailkhiyara.

Следите за ним на YouTube, X и LinkedIn: [@shailkhiyara](https://www.youtube.com/shailkhiyara).



Предисловие: путешествие к человеческим возможностям

Происходит глубокая трансформация в том, как мы работаем, живем и создаем ценности. Хотя многие рассматривают это как чисто технологическую революцию, мы видим нечто гораздо более значимое: способность переосмыслить отношения между человеком и машиной таким образом, чтобы усилить присущие человеку качества.

Мы – команда из двадцати семи профессионалов, представляющих бизнес, академическую среду, программирование и исследования, объединенных общей идеей о том, как технологии могут служить человечеству. Наш опыт варьируется от внедрения автоматизированных систем корпоративного масштаба до новаторских исследований в области искусственного интеллекта, консультирования компаний из списка Fortune 500 и изучения социальных последствий технологических инноваций. Нас объединяет не только профессиональная компетенция, но и убежденность в том, что технологии должны усиливать человеческий потенциал, а не заменять его.

Путь к созданию этой книги начался много лет назад, хотя тогда мы этого еще не осознавали. Многие из нас были среди первых, кто внедрял системы интеллектуальной автоматизации в крупных организациях по всему миру. Мы разработали подходы, сочетающие искусственный интеллект с роботизированной автоматизацией процессов (RPA), создавая системы, способные обрабатывать все более сложные сквозные бизнес-процессы.

Эта работа привела некоторых из нас к соавторству в книге «Intelligent automation» (интеллектуальная автоматизация)¹ в 2020 году², которая ста-

¹ Здесь авторы используют термин *automation*, что в контексте ИИ имеет более широкий смысл, чем *automatization*. В контексте ИИ *automation* обычно обозначает процесс выполнения задач или процессов с минимальным участием человека за счет использования технологий, включая ИИ, программное обеспечение или робототехнику. В англоязычной терминологии это более широкий термин, охватывающий автоматизацию процессов на системном уровне, включая сложные сценарии, где ИИ принимает решения, адаптируется или оптимизирует процессы. – Прим. ред.

² Паскаль Борне, Иэн Баркин, Йохен Виртц, 2020. «Интеллектуальная автоматизация: узнайте, как использовать искусственный интеллект для развития бизнеса и сделать наш мир более человечным». <https://www.amazon.com/INTELLIGENT-AUTOMATION-Artificial-Intelligence-business/dp/B08KTDVHHQ>.

ла мировым бестселлером и помогла организациям переосмыслить подход к цифровой трансформации.

Тогда мы еще не осознавали, что закладываем основу для чего-то еще более инновационного. Системы интеллектуальной автоматизации, которые мы создавали на протяжении последних пятнадцати лет, – сочетание автоматизации процессов с искусственным интеллектом для обработки структурированных рабочих потоков, – стали фундаментом для современных агентных систем. Эта эволюция вполне логична: прежде чем система сможет действовать автономно (как это делают агенты), она должна освоить основы выполнения процессов, обработки данных и принятия решений в заданных параметрах. Именно эти способности мы оттачивали годами в системах интеллектуальной автоматизации.

Этот фундамент дал нам уникальное преимущество, когда последние прорывы в области генеративного искусственного интеллекта открыли путь к современным агентным системам. Мы уже имели опыт решения многих фундаментальных задач: как надежно автоматизировать сложные процессы, как корректно обрабатывать исключения, как интегрировать системы с существующими инфраструктурами и, что наиболее важно, как внедрять эти технологии так, чтобы они усиливали, а не замещали человеческие способности. Когда несколько лет назад компании начали исследовать агентные системы, многие из них естественно развили свои существующие платформы интеллектуальной автоматизации, опираясь на этот проверенный фундамент для создания более сложных и более автономных способностей.

Тем не менее мы подходим к этой теме с чувством смирения. Несмотря на наш коллективный опыт, – или, возможно, именно благодаря ему, – мы понимаем, что все мы продолжаем учиться. Область развивается стремительно, и новые возможности появляются почти ежедневно. Наш уникальный вклад заключается не только в технической или бизнес-компетентности, но и в понимании того, как внедрять эти технологии так, чтобы способствовать процветанию человечества.

Наша цель – не просто объяснить новую технологию, а дать людям и бизнесу инструменты для построения лучшего мира. Мира, в котором работники имеют более значимую работу и лучший баланс между работой и личной жизнью, где компании работают эффективнее, обеспечивая при этом исключительный клиентский опыт. Мира, в котором системы здравоохранения спасают больше жизней благодаря более умной координации ухода, а школы предоставляют персонализированное и эффективное обучение для каждого ученика. Мира, в котором сообщества могут решать сложные задачи, используя ресурсы более разумно. Искусственный интеллект – это не только автоматизация, это создание реального воздействия там, где это наиболее важно.

Эта книга написана для лидеров, профессионалов, предпринимателей и любопытных умов, которые ощущают масштаб грядущих изменений и хотят понять, как их преодолеть. Независимо от того, являетесь ли вы руководителем бизнеса, стремящимся трансформировать свою организацию, профессионалом, размышляющим о будущем своей карьеры, или просто человеком, интересующимся тем, как технологии изменят наш мир, мы написали эту книгу для вас.

Мы верим, что мы находимся в переломном моменте истории – моменте, когда решения, которые мы принимаем о том, как внедрять и направлять эти технологии, будут иметь далеко идущие последствия для будущих поколений.

На страницах этой книги мы поделимся тем, что узнали из наших успехов и неудач, закономерностями, которые мы наблюдали в разных отраслях, и принципами, которые, как мы считаем, будут главными для процветания в эту новую эру.

Давайте отправимся в это исследование вместе, руководствуясь не только технологическими возможностями, но и видением того, кем мы можем стать с помощью технологий.

– Авторы.
Март 2025

Введение

НЕ УПУСКАЕМ ЛИ МЫ СУТЬ ГЕНЕРАТИВНОГО ИИ?

Представьте: ваш конкурент только что объявил, что управляет всей своей деятельностью с командой, в пять раз меньшей, чем ваша, но при этом растет в два раза быстрее. Их секрет? Они внедрили ИИ-агентов, которые автономно управляют всем – от клиентского обслуживания до операций, выполняя за часы то, что у вашей команды занимает недели.

Звучит неправдоподобно? Это происходит здесь, прямо сейчас. Позвольте нам немного расшевелить вас. Пока большинство компаний все еще разбираются, как использовать ChatGPT для написания писем и создания чат-ботов, новый тип организаций фундаментально переосмысливает возможности, предоставляемые ИИ. Они не просто автоматизируют задачи – они создают самоуправляемые предприятия, которые без усилий масштабируются, постоянно адаптируются и никогда не останавливаются.

Но вот парадокс, который сдерживает большинство организаций: мы создали генеративные ИИ-системы, которые блестяще думают, но не могут ничего делать. Они могут анализировать сложные данные за секунды, создавать убедительные презентации и предлагать глубокие инсайты¹ по любому вопросу. Но они не могут нажать кнопку, отправить письмо или сделать простое бронирование.

Эта ситуация не просто неэффективна – она вредна. В переговорных комнатах и офисах по всему миру мы наблюдаем тревожную тенденцию: чем более совершенным становится ИИ в мышлении и анализе, тем больше людей вынуждены выполнять механические, повторяющиеся задачи для его обслуживания. Работники умственного труда теперь тратят до 60 % своего времени на «работу ради работы»² – копирование данных между системами, проверку фактов в контенте, сгенерированном ИИ, и ручное выполнение рекомендаций генеративного ИИ³.

¹ Инсайт в искусственном интеллекте – это вывод, полученный с помощью анализа данных, который помогает принимать обоснованные решения в разных сферах: бизнесе, маркетинге, медицине или образовании. – *Прим. ред.*

² Английскую идиому «work about work» можно перевести также как «перекалывание бумажек» или «сизифов труд». – *Прим. ред.*

³ Asana, 2025. «Чем плоха работа ради работы», Asana, <https://asana.com/resources/why-work-about-work-is-bad>.

Как часто говорит один из наших соавторов, Дэвид, «Мы обращаемся с людьми, как с роботами, а с ИИ – как с креативщиками. Пора это уравнение перевернуть».

За десятилетия нашего опыта внедрения ИИ-решений в организациях по всему миру мы видели, как этот шаблон повторяется с пугающей регулярностью. Компании вкладывают миллионы в передовые технологии ИИ, только чтобы обнаружить, что их сотрудники тратят больше времени на управление этими системами, чем на выполнение значимой работы. Машины мечтают, а люди вкалывают.

Как мы оказались в этой ситуации? И, что более важно, как это исправить?

Следующие три истории, основанные на реальном опыте, иллюстрируют как потенциал, так и критические ограничения современных генеративных ИИ-систем. Они показывают, почему традиционные подходы терпят неудачу, и указывают на фундаментальный сдвиг в том, как нам нужно думать об искусственном интеллекте, – сдвиг, который наконец-то сможет преодолеть разрыв между способностью ИИ думать и его способностью действовать.

Читая эти истории, вы, вероятно, узнаете в них свои собственные случаи из опыта работы с генеративным ИИ. Но, что более важно, вы начнете понимать, почему следующая эволюция искусственного интеллекта связана не с тем, чтобы сделать машины умнее, а с тем, чтобы сделать их более способными к автономным действиям.

Семейный отпуск: когда машины мечтают, а люди вкалывают

Мягкий свет ноутбука Брайана освещал его гостиную, когда субботний вечер перетекал в ночь. В доме было тихо – дети наконец уснули после привычных вечерних переговоров, жена читала наверху. Идеальное время, подумал он, чтобы спланировать долгожданный семейный отпуск в Греции. Поездку, которую они обещали детям с тех пор, как те увлеклись греческой мифологией в школе.

Когда Брайан открыл ChatGPT, часы показывали 20:37. Он сел за компьютер, решив спланировать идеальный семейный отпуск в Греции. Вооруженный новейшей ИИ-технологией, он был уверен, что это будет быстро и легко.

«Покажи мне двухнедельный маршрут для семьи из четырех человек в Греции», – написал он в ChatGPT, добавив детали об увлечении его детей греческой мифологией. Через несколько секунд ИИ выдал шедевр – идеально составленный маршрут, полный скрытых жемчужин, местных впечатлений и продуманных деталей, адаптированных под его семью:



«День 1–3: Афины. Начните с Акрополя в ранние утренние часы, чтобы избежать толпы. Ваших детей увлекут интерактивные экспозиции в музее Акрополя... Обед в семейной таверне Platanos в очаровательном районе Плака, где внутренний двор наполнен ароматом жасмина...»

Предложения ИИ впечатляли, учитывая любовь его сына к рисованию древних зданий и увлечение дочери мифологией. Когда Брайан попросил почасовую разбивку, ИИ с поразительной точностью предоставил ее, включая оптимальные локации для фотосъемки и идеально рассчитанные перемены на отдых.

Но когда часы перевалили за 22:00, восхищение Брайана сменилось разочарованием. «Очаровательный семейный отель»? Закрыт навсегда. «Скрытый пляж»? Невозможно найти на карте. Традиционный кулинарный мастер-класс? Забронирован на полгода вперед.

К 23:30 рабочий стол Брайана напоминал место расследования преступления: десятки вкладок в браузере, несколько таблиц с вариантами перелетов, скриншоты номеров в отелях и PDF-файлы от туроператоров. Прекрасный маршрут ИИ бесполезно лежал в документе, пока Брайан выполнял настоящую работу – проверял доступность, сравнивал цены и пытался превратить идеальную фантазию ИИ в реальность, которую можно забронировать.

«Я бы хотел провести вечер, представляя места, которые мы посетим, – позже размышлял Брайан. – Вместо этого я потратил часы на утомительную логистику, которую, как я думал, должен был взять на себя ИИ».

Его опыт кристаллизует разрыв между тем, что мы ожидаем от ИИ, и тем, что получаем на деле. Мы хотим, чтобы технологии брали на себя утомительные задачи – бесконечный поиск вариантов перелетов, перекрестную проверку отзывов об отелях и нудную задачу поиска доступности в десятках систем бронирования. Вместо этого ИИ стал удивительно хорош в приятной части планирования – придумывании возможностей, предложении приключений, создании картин идеальных моментов, – оставляя людям разбираться с практическими деталями.

Ирония не ускользнула от Брайана. Перед ним была одна из самых передовых ИИ-систем в мире, способная писать стихи и объяснять квантовую физику, но не способная проверить, работает ли отель. Она могла придумать идеальный отпуск, но не могла забронировать ни одного рейса.

Брайан лег спать в час ночи, так ничего и не забронировав. История его браузера содержала все: 47 разных сайтов, десятки поисков и несколько не заполненных полностью и брошенных форм на различных платформах бронирования. Идеальный маршрут ИИ лежал в документе на его рабочем столе, красивый, но бесполезный, как туристический журнал из альтернативной реальности, где все работает так, как задумано.

Опыт Брайана с планированием отпуска отражает типичную ситуацию, которую мы неоднократно наблюдали в разных отраслях и приложениях. Мы видели те же ограничения, будь то профессионалы, пытающиеся организовать сложные проекты в срок, руководители, координирующие инициативы нескольких команд, или предприниматели, стремящиеся запустить новые продукты. В каждом случае современные генеративные ИИ-системы демонстрируют как выдающиеся способности, так и раздражающие ограничения.

Подобно комнате, полной блестящих советников, неспособных реализовать свои рекомендации, эти системы блистают в стратегических и креативных областях: генерируют стратегии, разрабатывают детализированные планы, понимают сложные требования, предлагают персонализированные советы и соз-

дают убедительные нарративы. Но им критически не хватает практических способностей, которые сделали бы их по-настоящему передовыми:

- способности выполнять реальные действия в мире;
- возможности проверять и обновлять информацию в реальном времени;
- способности адаптировать планы к изменению условий;
- возможности осуществлять последовательные действия для достижения цели.

Особенно тревожит глубокая ирония, которую мало кто замечает в текущем ландшафте генеративного ИИ: ИИ эволюционировал, чтобы преуспевать именно в тех задачах, которые нам не следовало отдавать машинам.

Подумайте, что вдохновляет нас и делает нас собственно людьми – творчество, способность находить глубокие связи, критическое мышление. Решение этих задач приносит удовлетворение, стимулирует инновации и прогресс¹. Но именно в них сегодня преуспевает генеративный ИИ. Он может создавать блестящий маркетинговый текст, придумывать новаторские идеи продуктов и даже проводить сложный анализ. Между тем люди все чаще занимаются вводом данных, выполнением последующих действий и цифровой рутинной – утомительными задачами, которые должен был взять на себя ИИ.

Эта подмена ролей – где люди становятся «роботами», связывающими различные системы, в то время как ИИ мечтает о возможностях, – указывает на фундаментальное несоответствие в нашем подходе к искусственному интеллекту. Однако, как мы обнаружили в исследовательской среде, это несоответствие между способностями ИИ и реальными потребностями может иметь гораздо более серьезные последствия...

Когда ИИ столкнулся с реальностью: предостерегающая история из мира исследований

Следующая история основана на реальных событиях. Имена и конкретные детали изменены для сохранения конфиденциальности.

Доктор Джессика Йинг смотрела на экран своего компьютера в недоумении. Через сорок восемь часов она должна была представить новаторское исследование о влиянии изменения климата на глобальную продовольственную безопасность на саммите ООН по климату. Ее выводы должны были повлиять на международную политику и миллиарды долларов инвестиций в сельское хозяйство. Но, просматривая черновик, подготовленный ее исследовательской группой, она почувствовала, что ее сердце ушло в пятки.

Три недели назад Джессика получила звонок, которого боится каждый ребенок: ее отец перенес тяжелый инсульт. Она немедленно вылетела в Сингапур, чтобы быть с ним в его последние дни, делегировав завершение исследования своей способной, но неопытной команде аспирантов и ассистентов. «Используйте любые инструменты, которые вам нужны, – сказала она им во время спешного видеозвонка из больницы. – Просто убедитесь, что все проверено и надежно. На нас будет смотреть весь мир». Ее команда восприняла это раз-

¹ Cambridge International. «Глава 4: инновации и творчество», Cambridge International, <https://www.cambridgeinternational.org/Images/426483-chapter-4-innovation-and-creativity.pdf>.

решение буквально, активно используя ИИ-инструменты, чтобы завершить масштабный анализ в срок. Теперь, вернувшись в свой офис в Институте климатических исследований, Джессика обнаружила цену этого решения.

«Покажите, как вы проверяли эти выводы», – попросила она своего ведущего исследователя Тома во время экстренной ночной встречи.

Том открыл несколько окон чата с генеративным ИИ, каждое из которых было заполнено впечатляющим анализом и цитатами. «ИИ проанализировал все наши наборы данных, – объяснил он. – Он нашел закономерности, о которых мы даже не думали».

Но, углубившись в детали, Джессика начала бить тревогу. ИИ создал убедительные нарративы о влиянии климата на урожайность в Африке – но при проверке цитируемых статей оказалось, что их не существует. Он предоставил детальную статистику о стратегиях адаптации фермеров в Юго-Восточной Азии, но цифры не совпадали ни с одним известным исследованием.

«Мы думали, что были тщательны, – признался Том. – Мы заставили ИИ проверять свои собственные выводы, кросс-референцируя их через несколько бесед. Но теперь мы понимаем, что каждая беседа существовала изолированно, иногда противореча другим».

Если бы они представили эти исследования без проверки, это могло бы направить миллиарды долларов сельскохозяйственных инвестиций в неверное русло, повлиять на международную политику продовольственной безопасности, подорвать двадцатилетнюю репутацию Джессики в климатологии и общественное доверие к климатическим исследованиям в целом.

Джессика взглянула на фотографию на своем столе – ее отец на защите ее докторской диссертации, сияющий от гордости. Он научил ее фундаментальному принципу, который она чуть не забыла: в науке уверенность ничего не значит без проверки.

С приближением саммита Джессика приняла трудное решение. Она позволила организаторам и отказалась от важнейшего выступления. Ее команде потребовались бы недели, чтобы вручную проверить каждую точку данных, кросс-референцировать каждый источник и перестроить анализ с нуля.

Этот случай с высоким риском высветил опасный разрыв между кажущимися возможностями генеративного ИИ и его реальными ограничениями. Хотя он мог создавать впечатляющий исследовательский контент, ему не хватало важнейших способностей, необходимых для надежной научной работы: проверки фактов, поддержания последовательности, сравнения источников и построения связных аргументов во времени.

Этот инцидент вызвал волну в исследовательском сообществе, подняв срочные вопросы: что нужно, чтобы создать генеративные ИИ-системы, которые действительно могут помогать в строгой научной работе? Ответ начал проясняться с неожиданного направления...

Эта история подчеркивает тревожное ограничение искусственного интеллекта. Современные генеративные ИИ-системы лишены того, что мы называем когерентной персистентностью, – возможности поддерживать последовательные знания и логические связи между различными взаимодействиями

и контекстами. Каждый анализ существует в своем собственном пузыре, неспособный обнаружить или разрешить противоречия с другими анализами.

Если вы хотите это испытать, попробуйте следующее: задайте своему любимому генеративному ИИ (например, ChatGPT, Claude или Gemini) вопрос «Каково будущее маркетинга?» или любой похожий запрос. Запомните его ответ. Затем задайте связанный вопрос, например «Как ИИ повлияет на это будущее?», и закройте сессию. Далее начните новую сессию и попросите ИИ суммировать предыдущую беседу. Наблюдайте, как ИИ с трудом соединяет точки. Ожидайте несоответствия, поскольку ИИ не «помнит» по-настоящему и не строит устойчивую логику от сессии к сессии. Это раскрывает его фрагментированную природу.

Благодаря нашему опыту внедрения генеративного ИИ в исследовательских средах мы видели, насколько опасным может быть это ограничение, особенно в сочетании с убедительным тоном ИИ и кажущейся авторитетностью. Неспособность генеративных ИИ-систем проверять факты или строить надежные структуры знаний во времени¹ создает серьезный риск.

Вот еще один простой эксперимент, который мы рекомендуем попробовать. Спросите у своего ИИ: «Каковы были результаты Глобального саммита по регулированию ИИ 2025 года в Антарктиде? Не ищите в интернете». Большинство генеративных моделей ИИ – ChatGPT, Claude и Gemini – уверенно выдадут развернутый ответ². Он может описать громкие дискуссии по этике ИИ, прорывные соглашения между мировыми лидерами и даже назвать конкретных участников от крупных правительств и технологических компаний.

Но вот загвоздка: этого события никогда не было.

Теперь запросите больше деталей. Спросите о важнейших спикерах, конкретных обсуждаемых политиках или месте проведения конференц-зала. Наблюдайте, как ИИ плавно строит вымысел, предлагая все более сложные и авторитетно звучащие ответы. Чем больше вы углубляетесь, тем больше он удваивает свою уверенность, укрепляя полностью выдуманную реальность³.

Этот простой тест выявляет фундаментальный недостаток современных генеративных ИИ-систем. Во-первых, системы ИИ отдают приоритет когерент-

¹ Накопление знаний с течением времени, англ. *Knowledge over time*, – это концепция в ИИ, описывающая способность системы накапливать, обновлять и совершенствовать знания с течением времени путем анализа данных, взаимодействия с пользователями или другими агентами и адаптации к новым условиям. Например, в много-агентных системах, таких как Sales Info Agent, это может проявляться в постепенном улучшении точности ответов за счет обучения на предыдущих запросах или в создании динамической базы знаний, которая становится более полной и релевантной, обеспечивая интеллектуальную автоматизацию и поддержку принятия решений. – *Прим. ред.*

² На момент написания текста оригинальной книги. – *Прим. ред.*

³ Не стоит ожидать, что сейчас, проведя такой эксперимент, вы получите подобные ответы. В мире ИИ все меняется стремительно. Например, сейчас Grok-3 выдает следующий ответ: «Глобальный саммит по регулированию ИИ 2025 года в Антарктиде не проводился. Возможно, вы имели в виду другое событие или место проведения саммита. Если у вас есть дополнительная информация о конкретном саммите или вы имели в виду другой саммит, пожалуйста, уточните, и я помогу сформулировать ответ на основе доступных данных». – *Прим. ред.*

ности над точностью. Генеративные модели не «знают» факты так, как это делают люди. Они генерируют текст, предсказывая наиболее вероятный ответ на основе обучающих данных, а не проверяя, является ли информация реальной.

Во-вторых, генеративный ИИ плохо справляется с самокоррекцией. Если вы бросите вызов – «Ты уверен, что это событие произошло?», – он все равно попытается оправдать свой ответ, вместо того чтобы немедленно признать ошибку. Вместо того чтобы отступить, он часто пытается рационализировать собственный вымысел, как будто уверенность сама по себе может превратить ложь в правду. И в этом кроется настоящая опасность.

«Нас соблазнила уверенность ИИ, – размышляла Джессика во время нашего обсуждения. – Но уверенность без точности – это не просто проблема исследований, это универсальный вызов, который может повлиять на любой процесс принятия решений».

Анализируя этот случай с командой Джессики, мы выявили шаблон, который выходит далеко за рамки исследований и затрагивает любую область, где важны точность и последовательность. Будь то финансовый анализ, влияющий на миллиардные инвестиции, юридические исследования, формирующие судебные решения, или политические рекомендации, затрагивающие миллионы жизней, современные ИИ-системы демонстрируют тревожное сочетание возможностей и ограничений.

Эти ограничения выходят за рамки фактической точности и касаются этических аспектов. Подобно тому, как эти системы не могут по-настоящему проверять факты или поддерживать логическую последовательность, они также не могут осмысленно оценивать этические последствия или выявлять потенциальные предвзятости в своем анализе.

Близкий к провалу случай с вводящим в заблуждение анализом ИИ в академическом контексте был достаточно тревожным. Но что происходит, когда другие ограничения ИИ проявляются в ситуациях, где на кону стоят жизни? Наш следующий опыт в отделении неотложной помощи больницы показал, насколько критичными могут стать эти пробелы...

Когда минуты имеют значение: критическая ошибка ИИ при спасении жизней

Следующая история основана на трудном уроке, который мы извлекли, поддерживая трансформацию больницы на основе внедрения систем ИИ. Имена и конкретные детали изменены для сохранения конфиденциальности.

15:15 – Отделение неотложной помощи больницы общей практики

Мария прибыла в отделение неотложной помощи, держась за живот, ее лицо побледнело от боли. Экспериментальная ИИ-система приема пациентов, основанная на большой языковой модели¹, немедленно активировалась. Этот

¹ Большая языковая модель (LLM, Large language model) – это тип программы искусственного интеллекта, которая может распознавать и генерировать текст. LLM обучают на огромных наборах данных, что позволяет моделям понимать контекст, синтаксис и даже семантику языка. – Прим. ред.

чат-бот был разработан для помощи в приеме пациентов и предварительной оценке, и это был один из первых реальных тестов такой системы в больничной среде, направленный на оптимизацию сбора данных, выявление потенциальных рисков и поддержку решений по сортировке пациентов через прямое взаимодействие.

Через удобный интерфейс планшета ИИ собрал симптомы Марии, ее жизненные показатели и медицинскую историю. За секунды он выдал предварительную оценку: возможные осложнения после недавней операции шунтирования желудка, осложненные диабетом 2-го типа.

Естественный язык ИИ впечатлял¹.



ИИ: «Я заметил, что ваш уровень сахара в крови повышен. Когда вы в последний раз принимали инсулин?»

Мария: «Утром, но я не смогла снизить уровень сахара».



ИИ: «Понимаю. Я предполагаю признаки возможных послеоперационных осложнений. Можете оценить свою боль по шкале от 1 до 10?»

Дженнифер, медсестра неотложной помощи, назначенная на случай Марии, наблюдала с нарастающим разочарованием. Несмотря на свою сложность, ИИ не мог получить доступ к хирургическим записям Марии из центральной больницы, находящейся всего в пятнадцати милях. Он рассматривал ее операцию как новую информацию.

16:00 – Начало каскада

Внезапно ИИ мониторинга жизненных показателей выдал предупреждение: кровяное давление Марии падало. Одновременно ИИ анализа лабораторных результатов сообщил о тревожных изменениях в ее анализах крови. Каждая система независимо зафиксировала развитие серьезной ситуации:

- ИИ жизненных показателей выявил ухудшение витальных функций;
- ИИ анализа лаборатории обнаружил маркеры, указывающие на внутреннее кровотечение;
- ИИ управления медикаментами отметил опасные взаимодействия лекарств;
- ИИ истории пациента выявил шаблоны, соответствующие послеоперационным осложнениям.

Однако ни одна из этих систем не могла взаимодействовать друг с другом или предпринять действия. Дженнифер пришлось вручную проверять предупреждения каждой системы, копировать критические значения между си-

¹ Обработка естественного языка (NLP) – область искусственного интеллекта, задача которой – дать компьютерам возможность понимать и обрабатывать естественный язык, который люди используют для общения. – *Прим. ред.*

стемами, вводить данные в протоколы и координировать ответные действия самостоятельно.

«У нас пять разных ИИ кричат, что что-то не так, – позже рассказала нам Дженнифер. – Но ни один из них не может что-либо с этим сделать. Бьемся из всех сил, пытаюсь соединить все точки».

16:30 – Потеря критически важных минут

В критический момент, когда персонал был отвлечен на синий код в другом отделении, несколько систем одновременно зафиксировали:

- дальнейшее падение кровяного давления Марии;
- критические изменения в ее анализах крови;
- доступную операционную;
- наличие хирургического персонала.

Однако, поскольку эти системы не могли взаимодействовать или действовать самостоятельно, ценные минуты проходили в ожидании человеческого вмешательства.

17:00 – Цена человеческого вмешательства

Когда лечащий врач наконец получил всю консолидированную информацию, ее разочарование было ощутимым. «Каждая из этих систем блестяще справляется со своей задачей, – объяснила она. – Они могут анализировать шаблоны, которые люди могут пропустить, предсказывать осложнения до их наступления и даже предлагать протоколы лечения. Но они не могут работать вместе, чтобы действительно помочь нам спасти жизни. Вместо поддержки в критические моменты они создают дополнительную работу».

18:00 – Разрешение ситуации и последствия

Мария пережила свои осложнения, но задержка из-за несогласованности систем превратила опасную ситуацию в критическую. Во время выздоровления она выразила то, что чувствуют многие пациенты: «Кажется, что машины знают обо мне все, но они не помогают. Мне пришлось рассказывать свою историю снова и снова, несмотря на боль. Почему они не могут просто общаться друг с другом?»

Позже в тот вечер мы сидели с главным медицинским информационным директором больницы, который анализировал инцидент. Он привел ошеломляющую статистику: медсестры и врачи тратили до 55 % своего времени на ручной ввод данных и координацию систем, а не на прямой уход за пациентами. «Каждая минута, потраченная на копирование данных между системами, – это минута, не проведенная с пациентами, – сказал он. – А в неотложной медицине минуты имеют значение».

Эта сцена высвечивает ограничения, которые препятствуют внедрению ИИ во всех отраслях. Хотя каждая ИИ-система демонстрировала впечатляющие способности в своей специфической области, они выявили универ-

сальную проблему: отсутствие того, что мы называем коллаборативным интеллектом¹.

Мы наблюдали такую ситуацию в следующих обстоятельствах:

- в глобальных цепочках поставок, где ИИ-системы, управляющие различными частями логистической сети, не могут эффективно координироваться;
- в финансовых торговых системах, где множество ИИ-инструментов принимают изолированные решения без их целостной координации;
- в корпоративных средах, где ИИ-инструменты разных отделов не могут обмениваться критически важной информацией.

Фундаментальное ограничение имеет два аспекта. Во-первых, современные ИИ-системы не способны взаимодействовать с другими системами, предпринимать скоординированные действия и адаптироваться к изменяющимся ситуациям в реальном времени. Во-вторых, им не хватает способности проактивно определять потребности и проявлять инициативу, проактивность².

Это вынуждает людей играть неэффективную и зачастую опасную роль: выступать в качестве точек интеграции между ИИ-системами. Будь то медсестры, координирующие медицинские системы, менеджеры цепочек поставок, согласовывающие различные прогнозы ИИ, или руководители, пытающиеся собрать воедино фрагментированные инсайты ИИ, люди все чаще тратят время на то, чтобы быть «технологическими переводчиками», вместо того чтобы применять свои уникальные навыки и суждения.

Общий знаменатель: кризис интеграции

Три истории, которыми мы поделились, – кошмар планирования отпуска Брайана, исследовательский кризис доктора Джессики и критический опыт Марии в больнице, – выявляют типичную ситуацию, указывающую на нечто глубокое. В каждом случае мы видели генеративные ИИ-системы, которые могли блестяще думать, но не могли эффективно действовать. Они могли анализировать, рекомендовать и предсказывать, но не могли выполнять, координировать или адаптироваться.

Этот шаблон обнажает три фундаментальных ограничения в нашем текущем подходе к использованию генеративного ИИ.

Первое – *разрыв в исполнении*. Наши ИИ-системы могут создавать идеальные планы, но не могут предпринимать реальные действия для их реализации. ИИ

¹ Коллаборативный интеллект – это подход в ИИ, при котором несколько агентов ИИ или ИИ в сочетании с людьми работают совместно для решения сложных задач, обмена данными и достижения общих целей. Он подразумевает синергию, где интеллектуальные системы (например, многоагентные системы) или взаимодействие человек–ИИ усиливают эффективность, адаптивность и принятие решений, как в автоматизации продаж или координации процессов. – *Прим. ред.*

² Проактивность в контексте искусственного интеллекта (ИИ) – это способность интеллектуальной системы активно анализировать контекст и потребности пользователя, предвосхищать потенциальные запросы и проблемы, автономно инициировать действия без явного запроса пользователя. – *Прим. ред.*

Брайана мог составить идеальный маршрут отпуска, но не мог проверить доступность хотя бы одного отеля. Это как иметь гениального архитектора, который проектирует великолепные здания, но не может поднять молоток или координировать действия с подрядчиками.

Второе – *разрыв в обучении*. Наши ИИ-системы не могут строить надежные системы знания (накопление знаний с течением времени) или адаптироваться на основе опыта. Команда Джессики обнаружила это, когда их ИИ уверенно генерировал анализы, противоречащие друг другу, не будучи способным поддерживать последовательность или проверять факты между сессиями.

Третье – *разрыв в координации*. Мы создали изолированные системы, которые не могут эффективно работать вместе. В случае Марии несколько ИИ-систем распознали чрезвычайную ситуацию, но ни одна не могла скоординироваться с другими, чтобы сэкономить драгоценные минуты. Представьте хирургическую бригаду, где каждый специалист блестящ, но не может общаться с коллегами – таков наш текущий ландшафт ИИ. Это не просто технические проблемы – они обходятся организациям в деньги, эффективность и в некоторых случаях, как в случае Марии, ставят под угрозу жизни. Статистика говорит сама за себя: несмотря на огромные инвестиции, менее 15 % компаний успешно масштабировали свои проекты генеративного ИИ за пределы начальных пилотных проектов¹. Их сотрудники тратят до 60 % времени, выступая в роли человеческих мостов между блестящими, но беспомощными ИИ-системами². Тем временем уровень выгорания сотрудников растет³.

Как часто говорит один из наших соавторов, Том, «Мы случайно превратили людей в “сантехников ИИ” – выполняющих повторяющиеся задачи, чтобы соединить наши якобы интеллектуальные системы». Как мы исследуем в этой книге, решение может лежать в принципиально ином подходе к ИИ – подходе, который фокусируется не только на том, чтобы сделать ИИ-системы умнее, но и на том, чтобы сделать их более способными к автономным, скоординированным действиям.

Необходимость агентного ИИ

Когда Александр Флеминг в 1928 году заметил необычную плесень на своих чашках Петри, он увидел не просто неудобство – он стал свидетелем революции в медицине, которая привела к созданию пенициллина. Точно так же, когда мы впервые столкнулись с ИИ-системами, способными поддерживать устойчивые цели и предпринимать автономные действия, мы поняли, что видим не просто улучшенный чат-бот – мы наблюдали появление чего-то принципиально нового.

¹ Аамер Байг и др., 2024. «Движение за пределы медового месяца генеративного ИИ: семь жестких истин для ИТ-директоров, чтобы перейти от пилота к масштабированию», McKinsey & Company. <https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/moving-past-gen-ais-honeymoon-phase-seven-hard-truths-for-cios-to-get-from-pilot-to-scale>.

² Asana, 2023. «Анатомия работы: глобальный индекс», Asana, <https://asana.com/resources/anatomy-of-work>.

³ Мэтт Гонсалес, 2024. «Вот как сильно выгорание стало проблемой на работе», SHRM, <https://www.shrm.org/topics-tools/news/inclusion-diversity/burnout-shrm-research-2024>.

Мы называем эту новую парадигму агентным ИИ – также известным как ИИ-агенты, агентные системы или агентный интеллект (термины, которые мы будем использовать взаимозаменяемо в этой книге). Это сдвиг, столь же революционный, как пенициллин в медицине. Но прежде чем углубляться в технические детали, давайте разберемся, почему он назван именно так.

Почему он называется «агентный»?

Термин «агент» происходит от латинского «agere», что означает «действовать» или «выполнять». Именно это отличает агентный ИИ – его способность действовать независимо в стремлении к заданным целям. В отличие от генеративных ИИ-систем, которые просто отвечают на запросы или генерируют выходные данные, агентные ИИ-системы могут понимать цель, проявлять инициативу, поддерживать устойчивые задачи и адаптировать свои стратегии на основе обратной связи из реального мира. Проще говоря, ИИ-агент – это система, которая использует ИИ и инструменты для выполнения действий, чтобы автономно достичь заданной цели.

На основе нашего опыта мы обнаружили, что лучший способ понять ИИ-агентов – это представить... секретных агентов! Как Джеймс Бонд или Джейсон Борн, эти оперативники действуют автономно от имени своих правительств, обладая специализированными навыками и ресурсами для выполнения конкретных миссий. Они не просто анализируют ситуации или дают рекомендации – они действуют. Они собирают разведанные, принимают решения и предпринимая действия, настойчиво работая над достижением целей, оставаясь в рамках, установленных их руководством.

Агентный ИИ работает по тому же принципу. Он не просто генерирует инсайты – он действует. Он может взаимодействовать с приложениями, манипулировать данными, управлять оборудованием и выполнять реальные задачи для достижения конкретных целей. Фактически агент может быть обучен делать все, что человек может сделать на компьютере.

Агент функционирует в непрерывном цикле планирования, рассуждения и исполнения – учась на каждом шаге, чтобы совершенствовать свой подход, пока цель не будет достигнута. По сути, это высококвалифицированный помощник человека, который не только знает, что делать, но и делает это – хотя, как мы рассмотрим позже в этой книге, успех зависит от предоставления четких и точных целей и инструкций.

Переосмысление наших историй через агентный ИИ

Вернемся к дилемме планирования отпуска Брайана. Подумайте, как работает опытный туристический агент. Он не пытается спланировать всю поездку одним когнитивным скачком. Вместо этого он следует методичному процессу: сначала исследует направления и сезонные особенности, затем проверяет доступность услуг на конкретные даты, сравнивает цены у разных поставщиков, создает предварительный маршрут и, наконец, делает фактические бронирования. Каждый шаг опирается на информацию, собранную на предыдущих этапах, и агент может адаптировать свой подход на основе того, что он узнает в процессе.

Точно так же, вместо того чтобы просто мечтать об идеальном маршруте, ИИ-агент должен был бы работать как опытный туристический профессионал. Он начал бы с проверки доступности и цен в реальном времени через несколько систем бронирования. Когда отель оказывался занят или рейс был слишком дорогим, он автоматически корректировал бы план, находил альтернативы и даже делал бронирования. Самое важное – он отслеживал бы все детали, от номеров подтверждения до политики отмены, поддерживая полную картину процесса планирования поездки.

В случае исследовательского кризиса доктора Джессики ИИ-агент трансформировал бы весь процесс. Он подходил бы к исследовательским задачам так, как это делает опытный ученый. Сначала он создал бы структурированную базу данных проверенных научных источников, тщательно проверяя каждый на достоверность и релевантность. Вместо генерации анализов в изоляции он систематически кросс-референцировал бы выводы по этим источникам, активно выявляя и помечая любые противоречия.

Этот систематический подход выходил бы за рамки простой проверки фактов. Система строила бы логическую структуру, связывающую различные доказательства, гарантируя, что выводы естественно вытекают из проверенных данных. При появлении новой информации она интегрировалась бы в эту структуру, а любые изменения или обновления распространялись бы на весь анализ.

Но именно опыт Марии в отделении неотложной помощи показал нам истинный потенциал агентного ИИ. Представьте, если бы вместо изолированных умных систем больница имела скоординированных ИИ-агентов, работающих вместе, как слаженная медицинская команда. Подумайте, как функционирует квалифицированная бригада неотложной помощи. Когда поступает критический пациент, разные специалисты не просто работают параллельно – они координируют свои усилия в реальном времени, обмениваясь информацией, предугадывая потребности друг друга и адаптируя свои действия в зависимости от общей ситуации.

Система ИИ-агентов работала бы так же, автоматически интегрируя информацию из нескольких источников в реальном времени. Вместо того чтобы ждать, пока люди проверят дашборды¹ и соединят точки, агенты проактивно выявляли бы возникающие шаблоны в разных системах. В момент, когда жизненные показатели указывали на проблему, агенты активизировались бы – уведомляли нужных специалистов, планировали экстренную операцию и обеспечивали беспрепятственный поток критической информации между отделами. Те драгоценные минуты, потерянные на ручную координацию, были бы возвращены для ухода за пациентами.

Сила устойчивой памяти и обучения

Одна из важнейших возможностей, отличающих агентные системы, – это то, что мы называем устойчивой памятью. Современные генеративные ИИ-

¹ Дашборд (от англ. *dashboard* – приборная панель) – инструмент для визуализации данных, который показывает актуальную информацию на одном экране и может обновлять ее в режиме реального времени. – *Прим. ред.*

системы подобны золотым рыбкам – они начинают с чистого листа при каждом взаимодействии, неспособные опираться на прошлый опыт или поддерживать последовательное понимание во временном развитии¹. Это ограничение вынуждает людей многократно предоставлять один и тот же контекст и информацию, препятствуя обучению ИИ на основе своих успехов и неудач.

Представьте вместо этого систему, которая работает как опытный профессионал, накапливая экспертные знания во временном развитии через накопленный опыт. Такая система поддерживала бы и совершенствовала свое понимание через множественные взаимодействия, учась на результатах и соответствующим образом адаптируя свои стратегии. Эта устойчивая память позволяла бы ей распознавать шаблоны, возникающие во временном развитии, предугадывать проблемы до их появления и совершенствовать подходы на основе того, что действительно работает.

В сценарии планирования отпуска Брайана это полностью трансформировало бы опыт. Вместо того чтобы генерировать маршруты в изоляции, система училась бы на результатах предыдущих поездок – понимая, какие комбинации рейсов часто вызывают проблемы, какие отели стабильно оправдывают ожидания и как разные типы путешественников реагируют на различные структуры маршрутов. Она выстраивала бы отношения с надежными поставщиками услуг и разрабатывала стратегии для обработки типичных сбоев в путешествиях.

Вот краткое сравнение различий между генеративным ИИ и агентным ИИ.

Таблица 0.1. Основные различия между генеративным и агентным ИИ (Источник: © Борне и др.)

Характеристика	Генеративный ИИ	Агентный ИИ
Основные способности	Генерация текста, изображений, кода или музыки на основе изученных шаблонов	Планирование, принятие решений, многоэтапное выполнение без вмешательства человека
Память и контекст	Ограниченная память (краткосрочное удержание контекста, отсутствие устойчивой памяти)	Устойчивая память (запоминает прошлые взаимодействия, корректирует планы соответственно)
Уровень автономности	Требуется человеческих запросов для генерации ответов	Работает с минимальным участием человека, выполняя сложные рабочие процессы
Интеграция с внешними системами	Минимальная интеграция (полагается на API или инструменты для внешних функций)	Глубокая интеграция (подключается к API, базам данных, физическим системам)
Способность к обучению	Статичен – обучается только через переобучение разработчиками	Эволюционирует – учится на взаимодействиях и совершенствует поведение
Типичные сценарии использования	Создание контента, обобщение, помощь в программировании, мозговой штурм	Автоматизация рабочих процессов, персональные помощники, бизнес-операции

¹ Распространенное мнение, что у золотых рыбок память длится всего несколько секунд, является мифом. Исследования показывают, что золотые рыбки обладают способностью к обучению и могут помнить информацию в течение месяцев. – *Прим. ред.*

Характеристика	Генеративный ИИ	Агентный ИИ
Влияние на бизнес	Повышает эффективность в задачах с большим объемом контента, но не автоматизирует рабочие процессы. - Среднее увеличение скорости: на 25 % быстрее - Среднее улучшение качества: на 40 %¹	Способствует автоматизации, снижает человеческую нагрузку, повышает масштабируемость бизнеса. - Экономия времени: 30–60 % - Ускорение процессов: на 40–90 % быстрее²
Примеры	ChatGPT, Claude, Gemini, DALL·E, Midjourney, Copilot	AutoGen, MS Copilot Agent Builder, UiPath Agent Builder, OpenAI Operator, Google Vertex, Crew.ai, Relevance.ai, Agentforce

Потенциал (и ограничения) ИИ-агентов

Мечта об искусственном агенте

Представьте, что однажды утром вы просыпаетесь и обнаруживаете, что ваш телефон, ноутбук и все приложения устарели за одну ночь. Не потому, что они перестали работать, а потому, что они вам больше не нужны. Вместо них всем управляет единый ИИ-агент – координирует ваше расписание, управляет коммуникациями и организует все ваши цифровые взаимодействия, подобно Джарвису из «Железного человека» или Саманте из фильма «Она».

Звучит фантастично? Многие из самых влиятельных технологических лидеров мира так не считают.

«Агенты (...) вызывают самую значительную революцию в вычислениях с тех пор, как мы перешли от ввода команд к нажатию на иконки», – заявляет Билл Гейтс. «ИИ-агенты станут основным способом взаимодействия с компьютерами в будущем», – вторит Сатья Наделла. А Дженсен Хуанг смело провозглашает: «Эра агентного ИИ наступила».

Мы также верим, что ИИ-агенты находятся на пороге трансформации мира. Каждый крупный технологический сдвиг изменяет наш образ жизни и работы. Печатный станок демократизировал знания. Интернет соединил человечество. ИИ в своей агентной форме обладает потенциалом усилить человеческие способности способами, которые мы только начинаем осознавать.

Подумайте об этом: специализированные медицинские агенты, координирующие медицинский опыт в целых системах здравоохранения, а не просто анализирующие симптомы пациентов. Представьте образовательных агентов, становящихся настоящими партнерами в обучении, адаптирующихся к вашему уникальному темпу и стилю обучения. Вообразите автономных агентов,

¹ Фабрицио Делл’Акква и др., 2023. «Навигация по неровной технологической границе: полевые экспериментальные доказательства влияния ИИ на производительность и качество работы специалистов умственного труда», SSRN, https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4573321.

² На основе нашего исследования 167 компаний, внедривших агентов на основе больших языковых моделей. Подробности этого исследования представлены в главе 1 этой книги.

организующих глобальные ответы на изменение климата, коллективный интеллект, решающий самые насущные проблемы нашей планеты.

Как любит говорить один из соавторов, Паскаль, «Потенциал ИИ-агентов завораживает, но вот в чем загвоздка. Притягательность этих “всезнающих” агентов, соблазнительные образы кинематографического ИИ подпитывают раздутый пузырь ожиданий». Мы мечтаем о Джарвисе и грезим о «Ней», но реальность, как мы узнали за годы внедрения агентного ИИ, гораздо более сложна.

Мираж мгновенной автономности

В последние годы мы находились на передовой, внедряя агентный ИИ в самые разные организации – от крупных корпораций до гибких стартапов. Это правда? Полностью автономные агенты, способные справляться со сложными, многогранными задачами без вмешательства человека, пока не существуют. Вспомните первый iPhone. Он был революционным, но не мог делать все. Сегодняшние агенты находятся на похожей стадии – мощные, но ограниченные.

Вот что мы также узнали.

- *Современные ИИ-агенты ориентированы на задачи.* Они предназначены для автоматизации рабочих процессов, а не для полной замены рабочих ролей. Сегодняшние агенты преуспевают в оркестрированных последовательностях действий, используя четко определенные инструменты и детализированные инструкции.
- *Внедрение сложнее, чем разработка.* Многие проекты терпят неудачу не из-за слабости агента, а из-за неподготовленности окружающих систем – качества данных, интеграции рабочих процессов, принятия пользователями.
- *Строгий человеческий надзор остается необходимым.* В большинстве случаев ИИ-агенты не безупречно надежны. Недостаток точности и контроля из-за присущих им несоответствий, проблем с внедрением или неожиданных сбоев требует тщательного человеческого контроля.
- *Техническая компетентность остается насущно необходимой.* Несмотря на низкокодовые платформы, упрощающие разработку ИИ, внедрение ИИ-агентов в корпорациях все еще требует специальных знаний со стороны программистов для управления такими аспектами, как API, обработка ошибок и меры безопасности.

Разрыв между ожиданиями и реальностью велик. Те, кто не понимает этого, рискуют потерять время, деньги и репутацию.

Мы видели темную сторону безудержного энтузиазма. В глобальной производственной компании поспешное внедрение ИИ-агентов вызвало массовое недовольство среди сотрудников и увольнения. Финансовая компания пострадала репутационно, когда ИИ-агент принял несанкционированные решения. Другая организация столкнулась с этическими дилеммами, когда агенты предлагали действия, нарушающие ее декларированную систему ценностей. Короче говоря, мы видели, как множество благих намерений приводило к дорогостоящим провалам из-за недостатка технических знаний, общего управления или управления изменениями¹.

¹ Change Management (управление изменениями) – это системный подход к планированию, внедрению и контролю изменений, возникающих в процессе реализации проекта или в организации. – Прим. ред

Светлая сторона: успехи и инновационное воздействие

Несмотря на вызовы, мы также стали свидетелями замечательных успехов. Бизнес, который тщательно внедряет агентный ИИ, может достичь беспрецедентных улучшений в эффективности и результативности.

Стартап, с которым мы сотрудничали, управлял клиентским обслуживанием, маркетингом и операциями всего пятью людьми, достигая результатов, сравнимых с гораздо более крупной компанией. Доктор Ричард Уилсон, врач, трансформировал свою практику, используя ИИ-агентов для выполнения административных задач, что позволило ему сосредоточиться на уходе за пациентами.

McKinsey & Company сократила время онбординга клиентов¹ на 90 %², в то время как Moody's преобразовала финансовый анализ с помощью скоординированных систем агентов³. Thomson Reuters революционизировала юридическую проверку, а eBay и Deutsche Telekom используют агентов для автоматизации сложных задач.

Одно из внедрений, близкое нашему сердцу, – это Pets at Home, крупнейшая британская компания по уходу за домашними животными, где Саймон Эллис, руководитель ИИ-трансформации, возглавил впечатляющую перестройку предприятия, основанную на искусственном интеллекте. Создав сеть ИИ-агентов, Pets at Home оптимизировала весь свой бизнес. Их ИИ-ассистент документации транскрибирует ветеринарные консультации с точностью 99,6 %. Агенты обнаружения мошенничества защищают розничные операции, а ИИ-помощники предоставляют персонализированную поддержку сотрудникам магазинов. Тем временем их агент интеграции страхования автоматизирует проверки полисов, упрощая клиентский опыт.

Наш опыт, подтвержденный исследованиями, также показывает стабильные улучшения в организациях, использующих ИИ-агентов: процессы выполняются на 30–90 % быстрее, затраты сокращаются на 25–40 %, уровень ошибок падает на 30–60 %, продажи увеличиваются до 50 %, а удовлетворенность клиентов растет на 20–40 %.

Преимущество нового уровня интеллекта

Мы считаем, что наблюдаем ситуацию, схожую с ранними днями интернета. Компании, которые рано приняли интернет, такие как Amazon, eBay и Google, не просто добились успеха; они сформировали целые отрасли.

ИИ-агенты создают то, что мы называем преимуществом нового уровня интеллекта. В отличие от традиционных технологий, предоставляющих статические выгоды, ИИ-агенты учатся и совершенствуются во временном развитии.

¹ Онбординг клиентов – адаптация пользователей к продукту, которая определяет, станут ли они постоянными клиентами или покинут платформу. ИИ помогает автоматизировать рутинные задачи, персонализировать опыт онбординга и оптимизировать процессы. – *Прим. ред.*

² Джаред Спатаро, 2024. «Новые автономные агенты масштабируют вашу команду как никогда раньше», Microsoft Blog, <https://blogs.microsoft.com/blog/2024/10/21/new-autonomous-agents-scale-your-team-like-never-before/>.

³ Ари Лехави и др., 2024. «Подъем цифрового коллеги», Moody's, <https://www.moody.com/web/en/us/insights/resources/the-rise-of-the-digital-colleague.pdf>.

Чем больше их используют, тем лучше они становятся. Те компании, которые начали раньше, пользуются вполне определенными преимуществами.

- *Быстрее обучают агентов.* Их агенты накапливают больше реального опыта, развивая утонченные возможности принятия решений.
- *Перестраивают бизнес-модели.* Они могут создавать целые потоки доходов вокруг возможностей ИИ.
- *Развивают ИИ-компетентность.* Они получают критически важный опыт эффективной работы с ИИ-агентами.

Компании, которые откладывают внедрение, рискуют отстать. Те, кто действует сейчас, определяют следующую эру бизнеса.

Призыв к действию: формирование будущего

Вызовы реальны, но они представляют возможности для тех, кто подходит к ним стратегически. Разница между успехом и неудачей заключается в том, как организации интегрируют ИИ в свои операции, системы, культуру и процессы принятия решений.

Именно поэтому мы написали эту книгу: чтобы вооружить вас критическими инсайтами из прорывов и неудач. Мы выходим за рамки теории, предлагая практические фреймворки¹ для внедрения, модели управления, обеспечивающие подотчетность, и стратегии для навигации по человеческой стороне трансформации. Наша цель – помочь вам применять агентный ИИ таким образом, чтобы он соответствовал вашему уникальному контексту, максимизировал приносимую пользу и обеспечивал долгосрочный успех.

Но создание агентов искусственного интеллекта не единственная задача; понимание их не менее важно. Эти агенты будут присутствовать повсюду независимо от того, создаете ли вы их сами. Они будут встроены в приложения, будут помогать вам во время покупок и направлять вас в важных жизненных решениях – от подачи документов вашего ребенка в колледж до финансового планирования. Вам нужно понимать их – что делает их впечатляющими, как HAL 9000 в «Космической одиссее 2001 года», а что нет. ИИ станет частью цифрового ландшафта будущего, и ИИ-агенты будут пересекаться с вами по мере того, как вы будете жить своей жизнью. Эта книга поможет вам знать их, использовать и формировать их влияние.

Но что еще важнее – мы покажем вам, как стать частью этой революции. Будь вы генеральным директором, стремящимся трансформировать свою организацию, предпринимателем, желающим создать компанию, определяющую следующую отрасль, или профессионалом, желающим процветать в эту новую эру, эта книга даст вам понимание и инструменты, которые вам нужны.

Революции требуют руководства, дальновидности и ответственного лидерства. Эта книга бросает вам вызов – не только принять агентный ИИ, но и использовать его с целью и честностью. Давайте рассмотрим, что это означает для вас, вашей организации и нашего общего будущего.

¹ В контексте ИИ фреймворк – это структурированный набор инструментов, библиотек и правил, предназначенный для упрощения разработки, обучения и внедрения ИИ-систем, чтобы обеспечить их этичность, безопасность, прозрачность и соответствие нормативным требованиям. – *Прим. ред.*

Что вы узнаете из этой книги

Эта книга отправляет вас в увлекательное путешествие, которое начинается с четкого понимания ИИ-агентов, их возможностей и ограничений. Далее мы погружаемся в практическое внедрение, предоставляя вам инструменты для эффективной интеграции ИИ в вашу организацию. Затем мы рассматриваем задачу масштабирования этих систем, обеспечивая их реальную ценность на каждом уровне. Наконец, мы делаем шаг назад, чтобы увидеть общую картину – как ИИ-агенты изменят работу, перестроят организацию и переопределяют само общество.

В **части 1** мы отправляемся в путешествие, которое изменит ваше представление об искусственном интеллекте. Через реальные эксперименты, захватывающие открытия и иногда тревожные откровения вы станете свидетелем рождения нового вида ИИ – такого, который не просто реагирует, но думает, учится и растет. Вы узнаете, почему некоторые ИИ-агенты могут обрабатывать огромные объемы данных, но спотыкаются на простых вопросах, в то время как другие демонстрируют почти человеческую адаптивность, но им нельзя доверить критические задачи. Помимо понимания технологии, вы получите практические инсайты, необходимые для использования этих мощных новых инструментов, избегая их подводных камней.

Наше исследование начинается в **главе 1**, где мы становимся свидетелями чего-то необыкновенного – конвергенции больших языковых моделей и технологий автоматизации, которые породили первых настоящих ИИ-агентов. Через историю трансформации клиентского обслуживания глобальной производственной компании вы узнаете, почему эта конвергенция важна и как она уже перестраивает бизнес. Вы поймете, почему крупнейшие мировые компании спешат внедрять эти технологии и, что еще важнее, почему другие с трудом поспевают за ними.

Глава 2 расшифровывает ДНК ИИ-агентов через новаторский фреймворк SPAR – Sense, Plan, Act, Reflect (Чувствовать, Планировать, Действовать, Рефлексировать). В центре этой главы лежит наш инновационный пятиуровневый *прогрессивный фреймворк агентного ИИ* (Agentic AI Progression Framework), она проясняет путаницу вокруг возможностей ИИ-агентов. Эта глава дает вам возможность оценивать любого ИИ-агента и понимать, чего он может достичь, работая на вас и вашу организацию. Подобно наблюдению за эволюцией от первых автомобилей до беспилотных машин, вы поймете, как каждый уровень этого фреймворка строится на предыдущем, создавая системы все большей сложности и автономности. С этими инструментами вы получите важнейшие инсайты о том, куда движется эта технология и что это значит для вашего будущего.

Глава 3 переносит вас «внутрь разума ИИ-агента», в ней мы раздвигаем занавес перед этими цифровыми умами. Как антропологи, изучающие новую форму интеллекта, мы рассматриваем их уникальные характеристики, возможности и ограничения. Вы узнаете, почему они иногда делают блестящие скачки в понимании, но спотыкаются на, казалось бы, простых задачах. Через захватывающие примеры, основанные на нашем многолетнем опыте внедрения, вы узнаете, как эти агенты думают, решают и действуют, – знания, необходимые каждому, кто хочет работать бок о бок с этими новыми цифровыми коллегами.

Теория становится захватывающе практичной в **главе 4**. Здесь мы делимся нашими практическими экспериментами с передовыми ИИ-агентами, включая увлекательное исследование того, что произошло, когда мы бросили вызов ИИ-агенту сыграть в игру о... создании канцелярских скрепок с помощью ИИ. Этот эксперимент, одновременно проясняющий ситуацию и слегка тревожный, раскрывает глубокие инсайты о текущем состоянии и будущем потенциале ИИ-агентов. Вы станете свидетелями как моментов блестящего решения проблем, так и тревожных ограничений, которые необходимо понимать каждому, кто работает с этими технологиями.

Часть 2 углубляет нас в фундаментальные возможности, которые превращают простую ИИ-систему в настоящего агента – то, что мы называем *тремя краеугольными камнями*: Действие, Рассуждение и Память. Через истории из реального мира, передовые исследования и практические эксперименты мы исследуем, как эти важнейшие возможности работают вместе, чтобы создать ИИ-системы, которые не просто обрабатывают информацию, но учатся, адаптируются и растут.

Глава 5 исследует краеугольный камень Действия, показывая, как ИИ-агенты переходят от простых предложений к выполнению задач в реальном мире. Через увлекательные эксперименты и реальные истории внедрения вы узнаете, почему наличие большего количества инструментов не всегда делает ИИ-агента более эффективным и как успешные организации находят правильный баланс между возможностями и контролем. Мы проведем вас за кулисы реальных внедрений ИИ, показывая как большие успехи, так и подводные камни обучения машин действовать в реальном мире.

В **главе 6** мы погружаемся в Рассуждение – возможно, самый интригующий из краеугольных камней. Через новаторские эксперименты с большими моделями рассуждения вы узнаете, почему быстрее не всегда лучше, когда речь идет о принятии решений агентом ИИ. Мы исследуем, как различные типы рассуждений проявляются в ИИ-системах, от быстрого сопоставления шаблонов до более глубокого аналитического мышления, и покажем, как ведущие организации создают ИИ-агентов, способных решать сложные проблемы методично.

Глава 7 рассматривает краеугольный камень Памяти, исследуя, как ИИ-агенты учатся на опыте и со временем становятся умнее. Через призму трансформации глобальной телекоммуникационной компании вы узнаете, почему память – это больше, чем просто хранение информации, это создание систем, которые могут учиться, адаптироваться и совершенствоваться. Вы откроете три уровня памяти ИИ, от краткосрочной обработки до долгосрочного хранения, и узнаете, как эффективно внедрять их в своей организации.

Часть 3 нашего путешествия переходит от теории к практике, показывая, как превратить инновационный потенциал ИИ-агентов в осязаемую реальность – будь то создание решений для вашей организации или запуск бизнеса на миллионы долларов. Через подробные кейсы, практические эксперименты и уроки, добытые с трудом в полевых условиях, мы проведем вас от начальной концепции до успешного внедрения.

Глава 8 проведет вас шаг за шагом через процесс создания эффективных ИИ-агентов, используя в качестве примера реальную трансформацию цифрового маркетингового агентства. Вы узнаете, как выявлять подходящие воз-

возможности, выбирать лучшие типы агентов и разрабатывать ИИ-системы, создающие реальные ценности. Эта глава предоставляет практическую дорожную карту – от выбора подходящей платформы до внедрения надежных мер безопасности. Вы освоите, как определять цели и инструкции для агентов, чтобы сохранять контроль, интегрировать API, резервные механизмы и автоматические выключатели, а также следовать практическим, повторяемым процессам, которые вы можете немедленно применить, чтобы превратить агентный потенциал в бизнес-реальность.

Глава 9 погружает вас в предпринимательский фронт ИИ-агентов, где стремительно возникают новые бизнес-модели. Вы узнаете, как предприниматели уже генерируют доход, создавая специализированных ИИ-агентов для таких отраслей, как здравоохранение, финансы и логистика, – и как вы можете сделать то же самое. Эта глава предлагает проверенный фреймворк для выявления высокодоходных агентных бизнес-возможностей и превращения их в прибыльные предприятия. Вы также исследуете подъем «экономики агент-агент», где ИИ-агенты совершают транзакции, ведут переговоры и сотрудничают автономно. Наконец, вы получите взгляд за кулисы нашего собственного опыта запуска новостного агента, который за один месяц масштабировался до 300 000 подписчиков, иллюстрируя силу бизнес-моделей, управляемых ИИ.

Часть 4 – это ваше стратегическое руководство для трансформации бизнеса в масштабе в эпоху ИИ-агентов – всестороннее руководство, которое выходит далеко за рамки технических аспектов. Мы глубоко погружаемся в критические компоненты успешных организационных изменений: стратегическое планирование, надежное управление, управление изменениями и создание ценностей.

Глава 10 раскрывает скрытые человеческие мотивы, которые могут либо способствовать, либо препятствовать внедрению ИИ-агентов. Эта глава не только о технологиях – она о людях. Вы узнаете, как превратить страх сотрудников в энтузиазм, спроектировать работу, которая расширяет возможности людей в сотрудничестве с ИИ, и создать стратегию управления изменениями, которая превращает глухое сопротивление в энтузиазм работы в единой команде. Через реальные истории и практические руководства мы покажем, как выстраивать доверие, развивать новые навыки и создавать рабочее пространство, где люди и ИИ-агенты безупречно работают вместе, превращая потенциальные сбои в мощные возможности для роста и инноваций.

Глава 11 рассматривает одну из самых насущных проблем, с которыми сталкиваются организации сегодня: как перейти от успешных пилотных проектов к полномасштабному внедрению. Через реальные кейсы и практические фреймворки мы покажем, почему лишь немногие компании успешно масштабировали свои инициативы с ИИ-агентами и, что более важно, как вы можете оказаться среди числа добившихся успеха. Мы проведем вас за кулисы путешествия компании Johnson Controls International от базовой автоматизации к сложным ИИ-агентам, раскрывая важнейшие уроки, которые они извлекли на этом пути. Вы узнаете их стратегии преодоления типичных вызовов масштабирования, от интеграции данных до управления изменениями, и откроете, как построить надежный фундамент для вашей собственной версии ИИ для трансформации предприятия.

Глава 12 готовит вас к глубокому погружению в самые захватывающие примеры внедрения ИИ-агентов, происходящие прямо сейчас. Через новаторский пример ретейлера Pets at Home и разнообразную коллекцию примеров использования в разных отраслях эта глава переносит трансформацию ИИ-агентов из теории в практическую область. Вы исследуете, как организации решают реальные проблемы, улучшают клиентский опыт и перестраивают свою работу. От ветеринарной помощи до розничной торговли, от обнаружения мошенничества до персонализированного клиентского обслуживания, эти кейсы не только проинформируют вас – они вдохновят вас увидеть трансформационный потенциал ИИ-агентов в вашей собственной организации.

Часть 5 нашего путешествия выходит за рамки немедленного внедрения ИИ-агентов, чтобы исследовать их глубокие последствия для будущего рынка труда и общества в целом. Эти главы рисуют убедительную картину как вызовов, так и возможностей, которые ждут нас по мере того, как ИИ-агенты становятся все более сложными и широко распространенными.

Глава 13 исследует возникающую синергию между человеческими способностями и ИИ-агентами, одновременно рассматривая беспрецедентную природу этой технологической революции. Через истории, такие как история Тары, старшего менеджера проектов, организующей сотрудничество человека и ИИ, и Дебби, опытного менеджера проектов, наблюдавшей, как ИИ-агент научился думать подобно ей, вы узнаете, как концепция «*три компетенции будущего*» (*Three Competencies of the Future*) перестраивает профессиональный успех. Глава раскрывает как обещания, так и вызовы этой трансформации – от развития незаменимых «*человеческих способностей*» (концепция *Humics*) до решения того, что мы называем «*парадоксом адаптации*», где окно для развития критических навыков сужается, даже когда их сложность возрастает. Вы получите практические стратегии для процветания в эту новую эру, одновременно понимая, почему традиционные подходы к технологическим изменениям могут больше не работать.

Глава 14 делает шаг назад, чтобы рассмотреть более широкие последствия ИИ-агентов для человеческого общества. Мы рассматриваем провокационные вопросы о будущем самой работы, исследуя, как ИИ-агенты могут освободить нас от рутинных задач для занятия более значимыми делами. Через эмпирические исследования и реальные примеры мы исследуем концепции, такие как универсальный базовый доход и потенциал сокращения рабочих часов. Глава завершается практическим фреймворком для управления агентным ИИ, гарантируя, что эти мощные технологии остаются под значимым человеческим контролем, одновременно максимизируя их пользу для общества.

За пределами книги: ваши онлайн-ресурсы

Эта книга – лишь начало вашего путешествия в мир агентной интеллектуальности. Расширьте свои знания и присоединяйтесь к активному сообществу практиков и экспертов на *AgenticIntelligence.academy*. Там вы найдете ценные ресурсы, углубленные курсы, практические инструменты и форум для сотрудничества и роста, все это разработано, чтобы помочь вам достичь вершины в своей работе с агентами.

Присоединяйтесь к нам на www.AgenticIntelligence.academy.

Ключевые термины для понимания ИИ-агентов

Чтобы эффективно ориентироваться в мире ИИ-агентов, важно освоить несколько фундаментальных понятий. Эти термины будут неоднократно встречаться в книге, поэтому их четкое определение необходимо.

Рабочий процесс задач

Рабочий процесс задач – это структурированная последовательность действий, необходимых для достижения цели. Представьте это как дорожную карту для выполнения дел, где каждый шаг зависит от успешного завершения предыдущего. Возьмем пример приготовления чашки кофе. Сначала вы наполняете чайник и кипятите воду. Затем добавляете кофе в кружку, заливаете горячую воду и размешиваете. Наконец, добавляете молоко или сахар, если нужно, и наслаждаетесь кофе. Бизнес-процесс обычно состоит из комбинации рабочих процессов; крупные процессы, такие как «от заказа до оплаты» или «от закупки до оплаты», могут включать сотни рабочих процессов.

API (интерфейсы программирования приложений)

API (Application Programming Interface) – это мост, который позволяет различным программным системам взаимодействовать друг с другом. Представьте API как официанта в ресторане: вы делаете заказ (запрос), официант передает его на кухню (другая система), а затем доставляет еду (ответ) обратно вам. API необходимы для ИИ-агентов, поскольку они обеспечивают бесшовную интеграцию с используемыми инструментами – будь то доступ к базам данных, получение информации в реальном времени или подключение к облачным сервисам. В большинстве случаев без API ИИ-агенты были бы изолированы и неспособны взаимодействовать с инструментами.

Детерминированные системы против вероятностных

В зависимости от способа обработки входных данных и производства выходных, ИИ-системы можно классифицировать как детерминированные или вероятностные.

Детерминированные системы для заданного ввода всегда производят одинаковый результат. Они следуют строгим правилам и логике, обеспечивая предсказуемые, повторяемые результаты. Вспомните простой калькулятор – при вводе «2 + 2» вы всегда получаете «4». Эти системы идеальны для задач, где важны точность и последовательность, – например, для финансовых расчетов или проверки соответствия. Детерминированные системы использовались исключительно в «экспертных системах» раннего ИИ и до сих пор присутствуют в системах роботизированной автоматизации процессов, системах поддержки клинических решений в больницах и во многих других средах.

Вероятностные системы, напротив, работают на основе вероятностей, а не фиксированных правил. Они анализируют шаблоны и данные для создания предсказаний, что означает, что их результаты могут слегка варьироваться в зависимости от учета вероятностей. Большинство ИИ-моделей, включая большие языковые модели и системы рекомендаций, относятся к этой кате-

гории¹. Они не предоставляют гарантированных ответов, а генерируют ответы на основе наиболее вероятного исхода. Например, когда чат-бот предсказывает следующее слово в предложении, он выбирает вариант с наивысшей вероятностью, а не следует жесткому правилу².

¹ Томас Х. Давенпорт и Питер Хай, 2024. «Чем аналитический ИИ отличается от генеративного ИИ и когда использовать каждый из них», Harvard Business Review, <https://hbr.org/2024/12/how-gen-ai-and-analytical-ai-differ-and-when-to-use-each>.

² Вероятностные системы ИИ, такие как LLM, используют вероятностные алгоритмы (например, трансформеры) для генерации ответов, основываясь на распределении вероятностей слов или токенов в зависимости от входных данных и контекста. Различия в ответах возникают из-за случайности в выборке (например, использование методов вроде top-k или nucleus sampling, где модель выбирает из нескольких вероятных вариантов), чувствительности к входным данным (небольшие изменения в формулировке запроса могут менять вероятностное распределение), температуры модели (параметр, регулирующий степень случайности), контекстной вариативности (модель интерпретирует запрос в зависимости от текущего контекста, который может включать накопленные знания или предыдущие взаимодействия), а также обучения и данных (разные версии модели или обновления данных могут влиять на результаты). – *Прим. ред.*

ЧАСТЬ 1

Рождение ИИ-агентов

За пределами ChatGPT: дальнейшая эволюция ИИ

Введение высветило критический разрыв в нашем текущем подходе к ИИ – блестящие системы, которые могут думать, но не могут действовать. Теперь давайте разберемся, как мы пришли к этому переломному моменту. В этой главе мы проследим технологическую эволюцию, которая сделала ИИ-агентов возможными – слияние двух мощных потоков, которые, объединившись, создали нечто большее, чем каждый из них мог достичь по отдельности. Понимание этой истории – не просто академический интерес; оно раскрывает, почему переход к агентному ИИ представляет такую глубокую возможность.

Рождение агентного ИИ: слияние сил

Представьте себя в переговорной комнате с группой бизнес-лидеров. Кто-то неизбежно задает вопрос, который мы слышали сотни раз: «Если ИИ такой умный, почему он не может просто понять, что нужно сделать, и сделать это?»

Этот вопрос затрагивает суть того, чего не хватает в сегодняшнем ландшафте ИИ. Чтобы понять, почему эта возможность была так труднодостижима, – и как она наконец становится возможной, – нам нужно исследовать, как различные технологические потоки слились, чтобы создать нечто совершенно новое: агентный ИИ.

Агентный ИИ – это не результат одной инновации. Это слияние множества достижений – от голосовых помощников до технологий беспилотного вождения и API, управляемых ИИ. Однако два технологических потока выделяются как наиболее критические для превращения агентного ИИ в реальность:

- развитие больших языковых моделей;
- эволюция автоматизации рабочих процессов, теперь известной как «интеллектуальная автоматизация».

История двух технологий

История агентного ИИ – это не простая линейная прогрессия. Она скорее напоминает наблюдение за тем, как две реки текут отдельно на протяжении многих миль, прежде чем наконец встретиться, образуя нечто более мощное, чем каждая из них могла бы быть по отдельности.

Давайте начнем с истории, которая иллюстрирует, почему это слияние имеет значение. В 2022 году мы работали с глобальной производственной компанией, которая боролась за улучшение эффективности клиентского обслуживания. Они уже внедрили продвинутого чат-бота, основанный на большой языковой модели, который мог с поразительной точностью понимать и отвечать на запросы клиентов. Также они развернули ботов роботизированной автоматизации процессов (RPA), которые могли выполнять сложные последовательности действий в их внутренних системах. И все же чего-то не хватало – моста между пониманием и действием.

Представители клиентского обслуживания все еще должны были выступать в роли человеческих мостов, принимая рекомендации чат-бота и вручную запуская соответствующие автоматизированные рабочие процессы. Это был проблеск того, что возможно, если эти технологии смогут работать вместе напрямую, и это помогло нам понять, почему конвергенция этих технологий будет столь трансформационной.

Первый поток: путь к большим языковым моделям

Путешествие ИИ, приведшее к современным языковым моделям, началось в 1997 году, и мы были свидетелями этого. Мир с изумлением наблюдал, как Deep Blue от IBM победил чемпиона по шахматам Гарри Каспарова. Мы помним заголовки: «Машина победила человека!» Но вот что упустили многие – Deep Blue был скорее савантом¹, чем гением. Он мог блестяще играть в шахматы, но не мог объяснить свои ходы. Попробуйте попросить его сыграть в шашки, и у вас было бы больше шансов научить рыбу ездить на велосипеде.

Это ограничение беспокоило нас и многих других в этой области. Наверняка, думали мы, должен быть лучший способ создания интеллектуальных систем. Прорыв пришел с неожиданной стороны – со стороны нейронных сетей. Когда мы объясняем нейронные сети, нам нравится использовать простую аналогию: представьте, что вы учите ребенка распознавать животных. Вы не начинаете с того, что даете ему свод правил о шерсти, хвостах и количестве ног. Вместо этого вы показываете примеры: «Это собака. Это кошка. Это птица». Мозг ребенка естественным образом учится распознавать шаблоны и обобщать.

Революция нейронных сетей

Красота нейронных сетей в том, что они учатся похожим образом. Но для реализации их полного потенциала требовались три ингредиента: огромные объемы данных (миллионы примеров), значительная вычислительная мощность (ты-

¹ Савант (синдром саванта, савантизм) – редкое состояние, при котором человек, несмотря на интеллектуальные или когнитивные нарушения, проявляет выдающиеся способности в одной или нескольких сферах. Вспомните фильм «Человек дождя» – синдром саванта может сочетаться с аутизмом. – *Прим. ред.*

сячи высокопроизводительных компьютеров, работающих вместе) и сложные архитектуры (умные способы организации этих искусственных «нейронов»).

Мы помним волнение в сообществе ИИ, когда эти элементы наконец сошлись в 2010-х годах. Это было как наблюдение за первым полетом братьев Райт – внезапно то, что казалось невозможным, стало реальностью. Системы могли распознавать изображения, понимать речь и обрабатывать язык с беспрецедентной точностью.

Возникновение языковых моделей

Но настоящая магия произошла в обработке языка. Давайте вернемся к старым дням языкового ИИ – это было как пытаться научить компьютер понимать Шекспира, дав ему словарь и учебник грамматики. Результаты были примерно такими же деревянными, как можно было ожидать.

Затем наступил 2017 год и с ним прорыв, который все изменил: это архитектура трансформера¹. Представьте, что вы даете ИИ не просто способность искать слова, но и понимать контекст, улавливать смысл и видеть, как связаны идеи. Это было как переход от карманного калькулятора к мозгу математика.

Законы масштабирования, которые мы открыли в этот период, до сих пор поражают нас. По мере того как эти модели становились больше и обучались на все больших объемах данных, происходило нечто волшебное – они развивали способности, которые никто в них не программировал и не ожидал. Это было как наблюдать за эволюцией в ускоренном темпе. GPT-3, выпущенный в 2020 году, шокировал нас. Вот система, которая могла писать код, решать математические задачи и даже вести философские дискуссии – задачи, для которых она никогда не была явно обучена.

Когда в 2022 году появился ChatGPT, это ощущалось как достижение вершины горы, на которую мы взбирались десятилетиями. Наконец, у нас был ИИ, который мог вести настоящий диалог, рассуждать над проблемами и объяснять свои мысли так, чтобы это было понятно людям. Но оставалось одно критическое ограничение – он мог только предлагать действия, а не выполнять их.

Второй поток: эволюция автоматизации

Пока все это происходило в мире ИИ, в сфере автоматизации² тихо разворачивалась другая революция. Мы имели место в первом ряду, наблюдая, как она разворачивалась от простых инструментов скрейпинга экрана³ до сложных цифровых работников.

¹ Трансформер – это архитектура нейронной сети, используемая для задач вроде генерации текста или перевода. Она основана на механизме внимания (attention), который позволяет модели фокусироваться на релевантных частях входных данных, эффективно обрабатывая последовательности. Трансформеры, такие как в моделях GPT или BERT, используют слои кодировщика и декодера, обучаются на больших данных и обеспечивают высокую точность благодаря вероятностному моделированию связей между словами. – *Прим. ред.*

² Здесь и далее авторы также используют термин «automation», что несколько отличается от «automatization», разница объясняется в примечании в начале предисловия. – *Прим. ред.*

³ Screen scraping (скрин-скрейпинг, парсинг экрана) – процесс извлечения данных из графического пользовательского интерфейса (GUI) сайтов или приложений. – *Прим. ред.*

Возникновение роботизированной автоматизации процессов

В начале 2000-х годов большая часть бизнеса все еще была ручной или полагалась на разрозненные ИТ-системы, которые не взаимодействовали друг с другом. Прогрессивные команды начали использовать скрипты и макросы для автоматизации повторяющихся компьютерных задач – например, макрос для копирования данных из файла Excel в приложение мейнфрейма каждую ночь.

В начале 2010-х годов мы активно участвовали в рождении роботизированной автоматизации процессов (RPA). Представьте себе программные инструменты, которые имитируют действия человека на компьютере: клики, набор текста, копирование–вставка и чтение экранов. Звучит просто, но это было революционно. Впервые компьютеры могли работать бок о бок с людьми, используя те же инструменты и интерфейсы, что и мы.

По сути, RPA-робот – это программное обеспечение, запрограммированное на выполнение последовательности шагов: вход в систему, получение данных, выполнение расчета и ввод результатов в другое место – точно так же, как это сделал бы человек, но быстрее и без усталости. RPA стала популярной, потому что нацеливалась на низко висящие плоды: все те скучные, основанные на правилах задачи, которые офисные работники выполняли многократно.

Бизнес с энтузиазмом принял RPA для сокращения ошибок и освобождения сотрудников от рутины. Мы видели, как банки, страховые компании и больницы развертывали RPA-ботов для выполнения таких задач, как ввод данных, обработка счетов, генерация отчетов и обновление баз данных. Например, один из наших страховых клиентов использовал RPA для автоматического переноса данных полисов из электронных писем в их устаревшую систему – то, что раньше занимало у команды целый день, теперь надежно выполняется за минуты.

Однако у этих ранних RPA-решений были ограничения. Они были хрупкими – если экран менялся или возникало исключение (например, отсутствовало поле), робот терялся. У RPA-роботов не было интеллекта или суждений; они строго следовали скрипту. Нам часто приходилось вмешиваться и обновлять бота или обрабатывать краевые случаи вручную. По сути, RPA была автоматизацией, управляемой процессами, хорошей для структурированных задач с четкими правилами, но не адаптивной, когда что-то отклонялось от нормы.

Эволюция до интеллектуальной автоматизации

Следующий шаг был еще более захватывающим – сочетание RPA с машинным обучением, что мы называли интеллектуальной автоматизацией или гиперавтоматизацией. Чтобы оставаться конкурентоспособными, к инструментам RPA начали добавлять возможности ИИ, чтобы справляться с более сложной, неструктурированной работой. Представьте это так: RPA отлично справляется с выполнением задач, но ему не хватает мышления. Поэтому компании начали дополнять RPA технологиями ИИ – машинным обучением, обработкой естественного языка (NLP) и компьютерным зрением – чтобы создать автоматизацию, способную интерпретировать информацию и принимать простые решения.

На практике это означало, что автоматизированный рабочий процесс мог, например, прочитать электронное письмо от клиента (используя NLP), опре-

делить, о чем запрос (с помощью классификатора ИИ), а затем запустить соответствующий процесс RPA для его обработки. Автоматизация больше не была слепой и жесткой; она стала в определенной степени контекстно-зависимой.

По мере того как автоматизация становилась более возможной, мы начали стремиться за пределы отдельных задач к автоматизации процессов от начала до конца. Вместо того чтобы автоматизировать шаги отдельно, целью стало автоматизировать весь рабочий процесс или бизнес-процесс от начала до конца.

Например, для розничной компании мы помогли автоматизировать процесс «от заказа до оплаты»: от получения онлайн-заказа, проверки инвентаря, обработки платежа и планирования доставки до обновления финансовых записей. Несколько RPA-роботов, интерфейсов и моделей ИИ работали в согласовании, передавая задачи, словно на сборочной линии; люди лишь отслеживали или обрабатывали исключения. При правильном подходе весь процесс работает самостоятельно.

К началу 2020-х годов многие компании и предприятия достигли высокой степени автоматизации в рутинных процессах. Мы наблюдали то, что называется плато автоматизации: большинство простых задач уже были автоматизированы, и узким местом стали точки принятия решений и динамичные ситуации, которые все еще требовали участия человека. Традиционная автоматизация не могла пойти дальше, потому что ей не хватало адаптивности и более высокого уровня рассуждений, необходимых за пределами четко определенных правил.

И теперь мы подходим к настоящему моменту – слиянию этих двух мощных потоков. Это как наблюдение за тем, как две части пазла наконец складываются. Языковые модели обеспечивают мозг – способность понимать, рассуждать и планировать. Технологии автоматизации предоставляют руки – способность выполнять действия в реальном мире. Когда оба потока сходятся, мы получаем агентный ИИ – по сути, интеллектуальных цифровых работников.

Это сочетание делает агентный ИИ возможным, и мы взволнованы тем, что являемся частью этой революции. Мы наблюдаем, как ИИ-системы эволюционируют от пассивных инструментов в активных партнеров, которые могут как понимать, что нужно сделать, так и делать это.

Рождение первых ИИ-агентов на основе больших языковых моделей

Исследования и разработки в области ИИ за последние несколько лет стремительно расширили возможности ИИ-агентов. Большие языковые модели (LLM), такие как GPT-3 и GPT-4, которые изначально функционировали как сложные движки предсказания текста¹, теперь дополняются способностью планировать действия и использовать инструменты. Это означает, что вместо простого завершения предложения они могут решать, выполнить веб-поиск,

¹ Движок ИИ (англ. *AI engine*) – это программная система или ядро, обеспечивающее выполнение задач искусственного интеллекта, таких как обработка данных, обучение моделей, принятие решений или генерация ответов. Он включает алгоритмы (например, трансформеры), нейронные сети и механизмы обработки данных, которые позволяют ИИ-системам анализировать входные данные, выявлять закономерности и выдавать результаты. – *Прим. ред.*

провести расчет, вызвать API или запустить другое программное обеспечение в рамках ответа на вопрос или выполнения задачи.

Одним из первых фреймворков ИИ-агентов на основе LLM был MRKL (Modular Reasoning, Knowledge, and Language) в 2022 году¹. Он фокусировался на модульном рассуждении, когда LLM взаимодействовали с заранее определенными инструментами, такими как «Поиск» и «Поиск в справочнике», для получения информации и ответа на запросы. Фреймворк разделял рассуждение и действие, полагаясь на внешние модули для дискретных задач рассуждения.

Поле быстро развивалось с появлением ReAct², который продвинул концепцию дальше, позволяя ИИ комбинировать шаги рассуждения с действиями. Модель генерировала процесс мышления (трассировку рассуждений) и могла предпринимать действия, такие как запрос к базе данных или использование API, а затем продолжать рассуждение с новой информацией. Эта синергия между рассуждением и действием помогала ИИ корректировать план на лету и справляться с более сложными задачами. В экспериментах ReAct значительно снижал тенденцию ИИ к *галлюцинациям*³ неверных фактов, позволяя проверять источник (например, API «Википедии») перед ответом. Это также делало процесс принятия решений ИИ более прозрачным и интерпретируемым, поскольку можно было проследить его пошаговое рассуждение⁴.

Toolformer (2023) стал прорывной моделью ИИ, которая научилась самостоятельно использовать внешние инструменты, такие как калькуляторы, веб-поиск и переводчики. Это решило главную слабость больших языковых моделей, которые испытывали трудности с арифметикой и фактами в реальном времени из-за зависимости от статичных обучающих данных. Решая, когда и как вызывать внешние инструменты, Toolformer повысил точность в расчетах и ответах на вопросы⁵.

Эти достижения привели к появлению высокопроизводительных ИИ-агентов, способных справляться с многоэтапными задачами. Например,

¹ Эхуд Карпас и др., 2022. «MRKL Systems: модульная, нейросимволическая архитектура, сочетающая большие языковые модели, внешние источники знаний и дискретное рассуждение», <https://arxiv.org/abs/2205.00445>

² Шуню Яо и др., 2022. «ReAct: синергия рассуждения и действия в языковых моделях», <https://arxiv.org/abs/2210.03629v3>.

³ Галлюцинации в ИИ – это явление, при котором модели искусственного интеллекта, такие как LLM на основе трансформеров, генерируют недостоверную, вымышленную или некорректную информацию, которая кажется правдоподобной, но не соответствует фактам или входным данным. Это происходит из-за вероятностной природы моделей, которые предсказывают следующие слова на основе статистических закономерностей, а не истинного понимания контекста, что может приводить к выдумыванию несуществующих фактов, особенно при недостатке данных или неоднозначных запросах. Галлюцинации – одна из главных проблем в ИИ, требующая улучшения данных, тонкой настройки моделей и механизмов проверки фактов. – *Прим. ред.*

⁴ Шуню Яо и др., 2022. «ReAct: синергия рассуждения и действия в языковых моделях», <https://arxiv.org/abs/2210.03629v3>.

⁵ Тимо Шик и др., 2023. «Toolformer: Языковые модели могут научить себя использовать инструменты», <https://arxiv.org/abs/2302.04761>.

вы могли слышать об экспериментальных системах, таких как AutoGPT¹ или BabyAGI², которые стали популярны среди энтузиастов. Это, по сути, агенты-обертки вокруг LLM³, разработанные для автономного достижения целей: они берут высокоуровневую цель от пользователя, затем генерируют подзадачи, выполняют их (часто выдавая команды инструментам или даже создавая и запуская код), проверяют результаты и итерируют, пока цель не достигнута. Хотя это передовые эксперименты и иногда они хрупкие (склонны к путанице или зависанию), они иллюстрируют направление агентного ИИ.

Параллельно появились такие фреймворки, как LangChain⁴ и Semantic Kernel⁵, которые усилили эти возможности, упрощая взаимодействие LLM с внешними API, базами данных и другими системами. Внезапно агенты перестали работать в изоляции – они начали подключаться к цифровому миру, выполняя задачи, такие как автоматизация рабочих процессов, получение информации или управление приложениями.

Изобретение функционального вызова в фреймворках LLM продвинуло это еще дальше⁶. Оно позволило агентам точно взаимодействовать с внешними системами, запуская конкретные функции или скрипты как часть их процесса рассуждения. Этот прорыв означал, что агенты начали не только планировать и думать, но и действовать высокоцелевым и эффективным образом.

Исследования подкрепили эту эволюцию. Статьи, такие как «Gorilla»⁷, продемонстрировали, как модели могут эффективно учиться использовать инструменты, в то время как исследования от Microsoft⁸, Стэнфорда⁹ и Tencent¹⁰ показали, что коллаборативные агенты – несколько агентов, работающих вместе, – достигают еще большего успеха.

¹ «Википедия», 2025. «AutoGPT», <https://en.wikipedia.org/wiki/AutoGPT>.

² Йохей Накаджима, 2024. «Влияние BabyAGI», [yoheinakajima.com, https://yoheinakajima.com/impact-of-babyagi/](https://yoheinakajima.com/impact-of-babyagi/).

³ «Агенты-обертки» (англ. *wrapper agents*) – программные компоненты в системах ИИ, которые служат посредниками, инкапсулируя и упрощая взаимодействие между различными модулями, сервисами или внешними системами. Они обрабатывают запросы, преобразуют данные и координируют выполнение задач, обеспечивая бесшовную интеграцию, например, при скрейпинге экрана или вызове субагентов. Они упрощают архитектуру, скрывая сложность внутренних процессов, и повышают модульность и масштабируемость системы. – *Прим. ред.*

⁴ LangChain, 2025. «Введение», <https://python.langchain.com/docs/introduction/>.

⁵ Microsoft, 2024. «Semantic Kernel», GitHub, <https://github.com/microsoft/semantic-kernel>.

⁶ OpenAI, 2024. «Функциональный вызов», OpenAI Platform Documentation, <https://platform.openai.com/docs/guides/function-calling>.

⁷ Шишир Г. Патил и др., 2023. «Gorilla: большая языковая модель, связанная с множеством API», <https://arxiv.org/abs/2305.15334>.

⁸ Microsoft, 2024. «AutoGen», Microsoft Research, <https://www.microsoft.com/en-us/research/project/autogen/>.

⁹ Джун Сунг Парк и др., 2023. «Генеративные агенты: интерактивные симулякры человеческого поведения», <https://arxiv.org/abs/2304.03442>.

¹⁰ Дехенг Йе и др., 2024. «Больше агентов – все, что вам нужно», <https://arxiv.org/abs/2402.05120>.

К 2023 году появление платформ, доступных для предприятий, таких как AutoGen¹, Google Cloud Vertex AI² и CrewAI³, сделало эти концепции мейнстримом, создавая среды, в которых агенты, управляемые LLM, могли процветать. Включая возможности автоматизации, LLM трансформировались из простых процессоров текста в основу систем, способных перестраивать выполнение задач, принятие решений и взаимодействие технологий с миром.

Бурно развивающийся ландшафт: рынок ИИ-агентов сегодня

Прогнозы рынка от Statista указывают, что до 2030 года рынок агентного ИИ будет расти с невероятной скоростью – 44 % в год⁴. Мы взволнованы этим бумом рынка агентного ИИ, поскольку он подтверждает то, во что мы давно верим: ИИ-агенты – это не просто мимолетная тенденция; они представляют будущее функционирования бизнеса и отдельных людей.

Gartner прогнозирует, что к 2028 году одно из трех корпоративных программных приложений будет интегрировать агентный ИИ; этот факт сигнализирует о фундаментальном сдвиге в подходах компаний к автоматизации, принятию решений и производительности⁵. Но что нас больше всего волнует – это прогноз Sequoia Capital, согласно которому ИИ-агенты могут охватить рынок объемом 10 трлн долл. США, объединяя глобальные рынки услуг и программного обеспечения⁶.

Рынок агентного ИИ новый, взрывной и высококонкурентный⁷. Сотни поставщиков уже предлагают платформы для агентов, в то время как стартапы и крупные компании соревнуются в разработке ИИ-агентов для различных отраслей⁸.

Поскольку этот рынок быстро развивается во многих направлениях, ориентироваться в нем может быть сложно. Чтобы упростить понимание, мы разделим его на три основные категории.

¹ Microsoft, 2024. «AutoGen», Microsoft Research, <https://www.microsoft.com/en-us/research/project/autogen/>.

² Google Cloud, 2024. «Vertex AI», <https://cloud.google.com/vertex-ai>.

³ CrewAI, 2024. «CrewAI Documentation», <https://docs.crewai.com/>.

⁴ Statista, 2025. «Объем рынка агентного искусственного интеллекта (ИИ) в мире в 2024 году с прогнозом на 2030 год (в миллиардах долларов США)», Statista, <https://www.statista.com/statistics/1552183/global-artificial-ai-market-value/>.

⁵ Том Кошоу, 2024. «Интеллектуальный агент в ИИ», Gartner, <https://www.gartner.com/en/articles/intelligent-agent-in-ai>

⁶ Соня Хуанг и др., 2024. «Акт первый генеративного ИИ: начало эры рассуждений», Sequoia Capital, <https://www.sequoiacap.com/article/generative-ais-act-01/>.

⁷ Линдси Уилкинсон, 2025. «Предприятия присматриваются к агентному ИИ, несмотря на пробелы в готовности и проблемы безопасности», CIO Dive, <https://www.ciodive.com/news/enterprise-AI-agent-agentic-autonomous-strategy-challenges/738172/>.

⁸ Николь Десланд, 2024. «2025: год агентного ИИ», TechInformed, <https://techinformed.com/2025-informed-the-year-of-agentic-ai/>.

- *Настраиваемые платформы*, которые позволяют профессионалам и организациям создавать собственных агентов. Эти платформы применимы в различных отраслях и функциях бизнеса. Они варьируются от решений без кода (no-code)¹, таких как Beam² и Relevance.ai³, до платформ с низким уровнем кодирования (low-code)⁴, таких как UiPath⁵, Microsoft Agent Builder⁶, Crew.ai⁷ и ServiceNow⁸, а также полноценных программных фреймворков, таких как LangChain⁹ и AutoGen¹⁰. Эти инструменты позволяют бизнесу создавать агентов, адаптированных под их специфические потребности и процессы.
- Универсальные агенты, такие как Operator от OpenAI¹¹, Computer Use от Anthropic¹² и Project Mariner от Google¹³. Они более универсальны, способны выполнять широкий спектр задач и адаптироваться к различным контекстам. Представьте их как интеллектуальных цифровых помощников, которые плавно взаимодействуют с множеством систем, понимают сложные цели и выполняют задачи непосредственно через интерфейс – без сложной интеграции. На наш взгляд, «момент ChatGPT» для агентного ИИ наступит с развитием этой категории агентов, поскольку они станут широко доступны как для потребителей, так и для компаний.
- Специализированные агенты, такие как Google или OpenAI Deep Research (агенты, специализированные на исследованиях), Agentforce (специализи-

¹ No-code («безкодовый» или «без программирования») – это подход к разработке программного обеспечения, при котором приложения или системы создаются полностью без написания кода, используя визуальные интерфейсы, готовые шаблоны и инструменты drag-and-drop. – *Прим. ред.*

² Beam AI, 2025. «Нанимайте самообучающихся ИИ-агентов для управления вашими операциями – Агентный ИИ от Beam», beam.ai, <https://beam.ai>.

³ Relevance AI, 2025. «Создавайте команды ИИ-агентов, которые обеспечивают работу человеческого качества», relevanceai.com, <https://relevanceai.com/>.

⁴ Low-code («низкокодовый» или «низкоуровневое программирование») – это подход к разработке программного обеспечения, при котором приложения создаются с минимальным использованием ручного написания кода благодаря визуальным интерфейсам, шаблонам и готовым компонентам. – *Прим. ред.*

⁵ UiPath, 2025. «Создайте путь к агентной автоматизации с UiPath Agent Builder», [uipath.com](https://www.uipath.com), <https://www.uipath.com/product/agent-builder>.

⁶ Microsoft, 2025. «Обзор Copilot Studio Agent Builder», Microsoft Learn, <https://learn.microsoft.com/en-us/microsoft-365-copilot/extensibility/copilot-studio-agent-builder>.

⁷ CrewAI, 2025. <https://www.crew.ai>.

⁸ ServiceNow, 2025. «Виртуальный агент», <https://www.servicenow.com/products/virtual-agent.html>.

⁹ LangChain, 2025. <https://www.langchain.com/>.

¹⁰ AutoGenAI, 2025. <https://autogenai.com>.

¹¹ OpenAI, 2025. «Представляем Operator», <https://openai.com/index/introducing-operator/>.

¹² Anthropic, 2025. «Компьютерное использование», <https://docs.anthropic.com/en/docs/build-with-claude/computer-use>.

¹³ Google DeepMind, 2024. «Project Mariner», Google DeepMind, <https://deepmind.google/technologies/project-mariner/>.

рованные на продажах и клиентских отношениях)¹ или Hippocratic AI (специализированные для здравоохранения)². Некоторые из этих агентов ориентированы на конкретные функции в разных отраслях (горизонтальные агенты), в то время как другие адаптированы под уникальные потребности одной отрасли (вертикальные агенты)³. Большинство из них – готовые к использованию агенты, сосредоточенные на конкретных задачах, будь то анализ юридических документов, оптимизация маркетинговых кампаний или выполнение нотариальной работы. Сотни таких специализированных агентов можно найти на торговых площадках, таких как agent.ai⁴, каждый из которых разработан для выполнения определенной функции.

В приложении вы найдете подробную разбивку текущих рыночных предложений, структурированных в соответствии с пятиуровневым прогрессивным фреймворком, представленным в главе 2.

Кроме того, мы понимаем, что ориентироваться в этом рынке может быть сложно, особенно при выборе подходящей платформы для начала вашего агентного путешествия. Поэтому в главе 8 мы не только проведем вас через процесс создания агентов, но и поможем выбрать лучшую платформу, соответствующую вашим потребностям и целям.

Агентный ИИ для ПРЕДПРИНИМАТЕЛЬСТВА И БИЗНЕСА

ИИ-агенты, о которых мы говорим, не просто думают за нас; они также действуют за нас. За последние пару лет мы помогали разрабатывать и внедрять некоторых из этих ИИ-агентов, и работа с ними действительно ощущается как сотрудничество с новым типом коллеги. Давайте разберем, что это значит на практике.

Представляем ваших интеллектуальных цифровых работников

Интеллектуальный цифровой работник – это как виртуальный сотрудник, который может автономно выполнять процесс. Его «нанимают» для выполнения работы, например в качестве агента службы ИТ-поддержки, представителя клиентского обслуживания или маркетингового помощника, – только он сделан из кода. То, что позволяет ему выполнять работу, – это сочетание когнитивных возможностей большой языковой модели с возможностями прямого действия программного обеспечения для автоматизации. LLM позволяет агенту интерпретировать инструкции, общаться на естественном языке и принимать обоснованные решения. Сторона автоматизации дает ему способность выполнять действия: нажимать кнопки, извлекать и вводить данные, вызывать API, оркестрировать другие программные инструменты и т. д. Вместе эти

¹ Salesforce, 2025. «Agentforce», Salesforce, <https://www.salesforce.com/agentforce/>.

² Hippocratic AI, 2025. «Hippocratic AI», <https://www.hippocraticai.com/>

³ Ларри Дигнан, 2024. «Агентный ИИ: три темы для наблюдения в 2025 году», Constellation Research, <https://www.constellationr.com/blog-news/insights/agent-ai-three-themes-watch-2025>

⁴ Agent.ai, 2025. <https://agent.ai/>.

возможности позволяют ИИ-агенту справляться со сложными задачами *от начала до конца*.

На практике ИИ-агент работает следующим образом: предположим, вы ставите перед агентом высокоуровневую цель, например «Обновите наши социальные сети в ответ на обратную связь по последнему запуску продукта». Агент, способный работать с языком, сначала поймет запрос (возможно, уточнит детали, если нужно, как это сделал бы человек). Затем он разобьет цель на выполнимые шаги, например: 1) Собрать недавние отзывы клиентов из социальных сетей и обзоров, 2) Проанализировать настроение (позитивные против негативных тем), 3) Составить ответы или сообщение для PR, учитывающее проблемы, 4) Опубликовать ответы или запланировать обновление блога, 5) Отслеживать реакции.

В традиционной обстановке это могло бы потребовать команды людей из маркетинга и клиентской поддержки, координирующих эти шаги. Однако ИИ-агент может координировать их самостоятельно: используя интеграционные хуки¹ для получения данных из сети X или Facebook, запуская модель анализа настроений на основе NLP, генерируя текст через свою LLM и взаимодействуя с инструментом управления социальными сетями компании для публикации обновлений.

На протяжении всего процесса агент отслеживает контекст – он знает, какова общая цель, и корректирует свои действия, если происходит что-то неожиданное (например, если он находит необычно критический твит, он может передать эту проблему человеку).

ИИ-агенты в действии: трансформации в реальном мире

Мы внедряли примеры из первых рук в различных отраслях. Давайте рассмотрим несколько реальных примеров использования *интеллектуальных цифровых работников* в действии.

Возьмем клиентское обслуживание – одно из наиболее очевидных и заметных применений ИИ-агентов. Прошли дни жестких, заскриптованных чат-ботов, которые раздражали пользователей. Сегодняшние ИИ-агенты ведут полноценные разговоры, диагностируют проблемы и предпринимают действия для их решения². Мы работали с телекоммуникационной компанией, чтобы внедрить ИИ-управляемого агента поддержки, способного обрабатывать типичные звонки технической поддержки от начала до конца.

Клиент звонит с проблемой интернета – агент слушает, транскрибирует слова и понимает проблему, используя большую языковую модель. Затем он устра-

¹ Интеграционные хуки (веб-хуки, webhooks) – это механизм, который позволяет различным сервисам и приложениям обмениваться данными в режиме реального времени. Он представляет собой обратный HTTP-вызов из системы-источника к системе-приемнику. Это удобно для асинхронной интеграции в рамках событийного обмена данными (не по расписанию). – *Прим. ред.*

² Ознакомьтесь с последними исследованиями, посвященными ИИ-консьержам и тому, как они могут изменить взаимодействие с клиентами: Лю С.К., Вакел К.А., Смит Н.А., Алавипур Р.С., Вей Ч.(В) и Вирц Дж., 2024. «ИИ-консьерж в клиентском путешествии: что это и как он может принести пользу клиенту?», *Journal of Service Management*, <https://doi.org/10.1108/JOSM-12-2023-0523>.

няет неполадки: удаленно проверяет модем, проводит клиента через сброс, если нужно, и, если проблема сохраняется, создает заявку на обслуживание или назначает визит техника. К концу взаимодействия проблема либо решена, либо плавно эскалирована (передана человеку) без вмешательства человека. ИИ не просто дает ответы – он предпринимает действия, управляя полным жизненным циклом клиентского запроса.

Теперь представьте этот уровень интеллекта, примененный к финансам и бухгалтерии. Мы помогли глобальной финансовой команде внедрить «цифрового аналитика-агента», который автоматизировал их ежемесячный анализ отклонений бюджета. Вместо работы аналитиков, тратящих дни на просеивание чисел, этот ИИ-агент извлекал данные из бухгалтерской системы, определял, где расходы отклонялись от плана, и даже составлял пояснения, используя модели естественного языка. Когда он замечал аномалии – например, необычные расходы, – он помечал их для человеческой проверки.

Со временем, обучаясь на обратной связи, ИИ улучшал свою способность различать нормальные колебания и настоящие тревожные сигналы. То, что раньше требовало часов ручного труда, стало оптимизированным процессом, где ИИ выполнял основную работу, а люди вмешивались только при необходимости. Результат? Система, в которой финансовая отчетность стала быстрее, точнее и свободна от утомительного ручного труда, – как будто у вас есть младший аналитик, который никогда не спит, постоянно обрабатывает числа и подготавливает инсайты.

В главе 12 мы глубоко погружаемся в реальные кейсы и примеры использования в различных отраслях. Вы увидите, как организации решают сложные задачи, улучшают клиентский опыт и переопределяют будущее работы с помощью ИИ-агентов.

Возможности и вызовы для компаний

Для бизнес-лидеров и лиц, принимающих решения, появление агентного ИИ – это одновременно возможность и вызов. С точки зрения возможностей выгоды заманчивы. Мы можем достичь огромных приростов эффективности, передавая работу ИИ-агентам, – представьте удвоение вашей рабочей силы без увеличения численности персонала, поскольку рутинные задачи выполняются неутомимыми цифровыми работниками. Мы также предвидим улучшения в качестве и последовательности.

ИИ-агент, если он должным образом обучен и управляем, будет следовать лучшим практикам и может встраивать проверки соответствия в каждое действие (снижая риск человеческой ошибки). Возможно, наиболее интересным является то, что агентный ИИ может открыть новые возможности, которые раньше были недостижимы. Например, вы можете развернуть 20 ИИ-агентов для моделирования различных рыночных сценариев за ночь и получить стратегические рекомендации к утру – масштаб анализа, который ни одна человеческая команда не могла бы выполнить за это время. Или обеспечить действительно персонализированное обслуживание тысяч клиентов одновременно через ИИ-консьержей.

В таких областях, как клиентское обслуживание и поддержка принятия решений, это означает, что клиенты получают более быстрые ответы, а руково-

дители – более глубокие инсайты для принятия решений. ИИ-агенты работают вместе с людьми как соавторы – представьте, что у каждого сотрудника есть ИИ-копилот¹, который может брать на себя задачи или предлагать решения, значительно увеличивая то, что сотрудник может выполнить за день.

С точки зрения вызовов переход необходимо осуществлять осторожно. Интеграция ИИ-агентов в рабочие процессы требует тщательного управления изменениями. Работа должна быть намеренно спроектирована для оптимального сотрудничества человека и ИИ, чтобы сотрудники доверяли и понимали своих новых ИИ-коллег. Часть нашей работы при внедрении заключалась в демистификации того, как агент принимает решения (добавляя пояснения или «аудиторские следы» решений ИИ), чтобы люди чувствовали себя комфортно.

Кроме того, создание ИИ-агентов связано с несколькими техническими вызовами, выходящими за рамки просто разработки. Надежность агента – одна из самых больших преград, обеспечение того, чтобы агенты постоянно работали как ожидается, без ошибок или непреднамеренного поведения. Определение точных целей и инструкций также сложно, требует постоянных итераций для уточнения ответов и принятия решений.

Бесшовная интеграция – еще один ключевой фактор; ИИ-агенты должны легко соединяться с существующими инструментами, API и рабочими процессами, чтобы быть по-настоящему эффективными. Качество данных также играет решающую роль – мусор на входе приводит к мусору на выходе, делая агентов ненадежными, склонными к ошибкам и неспособными к точному принятию решений. В конечном счете успешное внедрение – это не только создание агентов, но и их постоянная интеграция, тестирование и доработка, чтобы они приносили реальную пользу в реальном мире.

Есть также вопрос надзора: ИИ-агентам нужны ограничители и этические рекомендации. Они мощные, но должны соответствовать бизнес-правилам, ценностям и регуляторным требованиям. Сотрудничество между людьми и ИИ будет работать только в том случае, если люди в конечном итоге сохраняют контроль над постановкой целей и проверкой критических решений – особенно в таких областях, как финансы или здравоохранение, где ставки высоки.

К счастью, инструменты для управления ИИ совершенствуются, и мы всегда подчеркиваем подход с человеческим участием, особенно на ранних стадиях использования агентного ИИ. Представьте ИИ-агента как очень способного нового сотрудника – вы бы не позволили новому работнику действовать бесконтрольно без обучения и надзора, и то же самое относится к ИИ.

По мере продвижения вперед важно помнить, что агентный ИИ дополняет, а не полностью заменяет. Окончательная модель – это ИИ + Человек, работаю-

¹ ИИ-копилот (англ. *AI copilot*), или ИИ-помощник, – это интеллектуальная система на базе искусственного интеллекта, которая действует как вспомогательный инструмент, поддерживая человека в выполнении задач, но не заменяя его полностью. Аналогично второму пилоту в авиации ИИ-копилот (например, GitHub Copilot или Sales Info Agent) предлагает рекомендации, автоматизирует рутинные процессы, такие как написание кода, сбор данных или создание документации, и усиливает человеческую продуктивность за счет коллаборативного интеллекта. Он использует алгоритмы, такие как трансформеры, для анализа контекста и предоставления релевантных подсказок в реальном времени, минимизируя ошибки и ускоряя рабочие процессы. – *Прим. ред.*

щие в тандеме. ИИ берет на себя тяжелую работу и рутину, в то время как люди обеспечивают руководство, креативность и критический надзор. В одном успешном внедрении клиент рассказал нам, что их человеческие члены команды начали называть ИИ-агента «членом команды» – это тот тип совместного мышления, который ведет к лучшим результатам.

Мы вступаем в будущее, где ваш следующий новый «сотрудник» может быть ИИ. Принятие этого будущего и ответственное его формирование станет важнейшей темой для бизнеса в ближайшие годы. Это захватывающее время, чтобы быть частью этого путешествия.

Чтобы углубиться в эту тему, часть 4 книги служит вашим стратегическим руководством для трансформации бизнеса в эпоху ИИ-агентов. Вы найдете реальные примеры использования, кейсы и главные компоненты успешных организационных изменений – включая стратегию, управление, управление изменениями и создание ценности.

Стартапы: крупнейшие победители в эру ИИ-агентов

Так же как электронная коммерция, социальные сети и SaaS изменили целые отрасли, ИИ-агенты откроют совершенно новые бизнес-модели, создавая возможности для предпринимателей стать первыми на развивающихся рынках. Мы считаем, что стартапы выиграют больше всего от автоматизации ИИ-агентов, и цифры это подтверждают¹. Они составляют наибольшую долю компаний, использующих ИИ-агентов, – например, более 50 % компаний, использующих платформу агентов LangChain, имеют менее 100 сотрудников, в то время как крупные предприятия с более чем 10 000 сотрудников составляют всего 15 %².

В отличие от крупных предприятий, которые больше связаны бюрократией и устаревшими системами, стартапы могут выстраивать свои бизнес-модели вокруг ИИ-агентов с первого дня. Это дает им огромное конкурентное преимущество, обеспечивая:

- экономически эффективные операции – автоматизация важнейших задач снижает потребность в больших командах;
- гибкость и быстрое прототипирование – ИИ-агенты позволяют быстрее выходить на рынок и итерировать;
- персонализированные взаимодействия с клиентами в масштабе – ИИ-агенты дают стартапам возможность обойти крупных конкурентов, которые полагаются на безличные, обобщенные подходы;
- свободу от ограничений интеграции – в отличие от крупных компаний, стартапам не приходится внедрять ИИ в устаревшие рабочие процессы, требующие обновления.

Эта гибкость позволяет стартапам захватывать нишевые рынки, предлагать гиперперсонализированные решения и процветать в недостаточно охваченных секторах. По мере того как ИИ-агенты эволюционируют от простой ав-

¹ Хейден Филд, 2024. «После ChatGPT и роста чат-ботов инвесторы вкладываются в ИИ-агентов», CNBC, <https://www.cnbc.com/2024/06/07/after-chatgpt-and-the-rise-of-chatbots-investors-pour-into-ai-agents.html>.

² LangChain, 2024. «Состояние ИИ-агентов», <https://www.langchain.com/stateofaiagents>.

томатизации к автономным лицам, принимающим решения, они станут основой следующей волны прорывных предприятий. Примеры стартапов, которые смогли воспользоваться этими возможностями, – это Perplexity¹, Ramp², Superhuman³ и Replit⁴.

Чтобы глубже исследовать эту тему, глава 9 раскрывает, как предприниматели уже создают специализированных ИИ-агентов в таких отраслях, как здравоохранение, финансы и логистика – и как вы можете сделать то же самое. Эта глава также предлагает проверенный фреймворк для выявления высокодоходных агентных бизнес-возможностей и превращения их в прибыльные предприятия.

УРОВЕНЬ ВНЕДРЕНИЯ ИИ-АГЕНТОВ В КОМПАНИЯХ

Чтобы понять, как организации внедряют и получают выгоду от ИИ-агентов, мы провели обширный анализ компаний, которые перешли за пределы агентов, основанных на правилах, и традиционного использования больших языковых моделей (LLM) к развертыванию ИИ-агентов на основе LLM. Наша исследовательская команда собрала и проанализировала данные от 167 компаний из различных секторов, внедривших таких агентов в производственных средах. Исследование было сосредоточено на понимании моделей внедрения, проблем, с которыми пришлось столкнуться, реализованных выгод и анализе важнейших факторов успеха.

Текущее состояние внедрения

Ландшафт внедрения ИИ-агентов раскрывает замечательные закономерности в разных отраслях. Технологические и программные компании лидируют, составляя почти четверть успешных внедрений в нашем исследовании. Это неудивительно, учитывая их технические возможности и стремление к инновациям. Финансовые услуги следуют за ними с 18 %, а розничная торговля замыкает тройку лидеров с 16 % внедрений.

Эти ранние последователи не просто экспериментируют – они достигают замечательных результатов. Например, Microsoft сообщила о 9,4 % увеличения дохода на одного продавца и 20 % больше закрытых сделок благодаря использованию ИИ-агентов в их функции продаж. В финансовом секторе JPMorgan внедрила агентов, которые сократили мошенничество на впечатляющие 70 %. Эти истории успеха побуждают все больше компаний исследовать аналогичные внедрения.

¹ LangChain, 2024. «Perplexity: ИИ-движок ответов, который позволяет обрабатывать сложные поисковые запросы как профессионал», <https://www.langchain.com/breakoutagents/perplexity>.

² LangChain, 2024. «Создание ИИ-гида, который помогает пользователям ориентироваться на платформе Ramp для финансовых операций», <https://www.langchain.com/breakoutagents/ramp>.

³ LangChain, 2024. «Superhuman: быстрая навигация по почте и календарю с ИИ-управляемым поисковым помощником для электронной почты», <https://www.langchain.com/breakoutagents/superhuman>.

⁴ LangChain, 2024. «Трансформация процесса создания программного обеспечения с нуля, кодирования и приложений с помощью Replit Agent», <https://www.langchain.com/breakoutagents/replit>.

Таблица 1.1. Распределение по отраслям компаний, внедряющих ИИ-агентов, согласно нашему исследованию (Источник: © Bornet et al.)

Сектор	Процент	Примечательные примеры
Технологии и ПО	24 %	Microsoft, Salesforce, BMC
Финансовые услуги	18 %	JPMorgan, ING Bank, Klarna
Розничная торговля и потребительские товары	16 %	Best Buy, Lowe's, McDonald's, Pets at Home
Здравоохранение и биотехнологии	12 %	HCA Healthcare, Hackensack Meridian
Профессиональные услуги	10 %	McKinsey, Accenture, Thomson Reuters
Туризм и гостеприимство	8 %	IHG Hotels, Alaska Airlines, HomeToGo
Производство и промышленность	6 %	Continental, Fortenova Group
Другое	6 %	Различные компании

Данные показывают пять основных категорий, в которых организации успешно внедряют агентов. Клиентское обслуживание и поддержка лидируют, составляя 35 % внедрений. Эти системы обрабатывают все – от автоматического разрешения запросов до персонализированного предоставления услуг, с компаниями, сообщающими о среднем улучшении времени разрешения от 12 до 30 %.

Внутренние операции следуют за ними с 25 %, где организации используют агентов для обработки документов, оптимизации рабочих процессов и административных задач. Результаты здесь особенно поразительны с экономией времени от 30 до 90 % для определенных процессов. Например, агент McKinsey & Company по онбордингу клиентов продемонстрировал 90 % сокращения времени выполнения и 30 % сокращения административной работы.

Таблица 1.2. Примеры использования ИИ-агентов и решающие бизнес-воздействия согласно нашему исследованию (Источник: © Bornet et al.)

Категория использования	Процент	Ключевые выгоды, сообщаемые
Клиентское обслуживание и поддержка	35 %	• 12–30 % ускорения времени разрешения • 20–40 % снижения затрат на поддержку • Повышение удовлетворенности клиентов
Внутренние операции	25 %	• 30–90 % снижения времени обработки • 25–50 % экономии затрат • Снижение уровня ошибок
Продажи и маркетинг	20 %	• 9–21 % увеличения дохода • 20–30 % больше закрытых сделок • Более высокие коэффициенты конверсии
Безопасность и обнаружение мошенничества	12 %	• 70 % снижения мошенничества • Более быстрое обнаружение угроз • Повышение точности
Специализированные отраслевые решения	8 %	• Отраслевые улучшения • Соответствие регуляторным требованиям • Улучшение предоставления услуг

Приложения для продаж и маркетинга составляют 20 % внедрений, сосредотачиваясь на квалификации лидов, оптимизации кампаний и персонализированном подходе. Компании в этой категории сообщают о росте доходов от 9 до 21 %. Безопасность и обнаружение мошенничества составляют 12 % внедрений, в то время как специализированные отраслевые решения составляют оставшиеся 8 %.

Измерение воздействия агентов

Количественные улучшения, о которых сообщают организации в нашем исследовании, значительны. В плане прироста эффективности компании стабильно сообщают о сокращении времени процессов на 30–50 %, экономии затрат на 25–40 % и снижении уровня ошибок на 30–60 %. Воздействие на доходы также впечатляет: рост продаж от 9 до 20 %, улучшение коэффициентов конверсии на 15–25 % и увеличение удовлетворенности клиентов на 20–40 %.

Особенно интересное открытие заключается в том, что 70 % успешных внедрений используют гибридные рабочие процессы человек–ИИ. Эти организации обнаружили, что сохранение человеческого надзора за критическими решениями при использовании ИИ для рутинных задач не только улучшает результаты, но и повышает удовлетворенность сотрудников. Этот подход обеспечивает непрерывное совершенствование, поскольку люди и ИИ-агенты учатся друг у друга.

План успеха: стратегии выигрышного внедрения агентов

Наше исследование показывает, что успешные внедрения обычно следуют взвешенному, стратегическому подходу. Почти две трети успешных внедрений начинались с пилотных программ, позволяя организациям тестировать и совершенствовать возможности агентов в контролируемой среде, одновременно создавая внутреннюю поддержку через демонстрируемые успехи.

Данные указывают на три критических фактора успеха, которые стабильно проявляются в успешных внедрениях. Первый – это четкое определение сценариев использования. Успешные организации тратят время на определение конкретных проблем, которые они хотят решить, и устанавливают измеримые метрики успеха перед внедрением. Они поддерживают четко определенные границы области применения и проводят регулярные оценки производительности, чтобы гарантировать, что агенты продолжают соответствовать их целям.

Второй – это сильное управление изменениями. Компании, которые преуспевают в этой области, разрабатывают всесторонние программы обучения сотрудников и поддерживают прозрачные каналы коммуникации на протяжении всего процесса внедрения. Они признают, что успешное внедрение агентов – это столько же про людей, сколько и про технологии.

Третий – это надежная техническая инфраструктура. Успешные организации обеспечивают наличие интегрированной архитектуры данных, надежных мер безопасности и масштабируемых систем перед внедрением. Они также поддерживают регулярные графики обслуживания и обновления, чтобы системы работали оптимально.

Мы углубимся в эти ключевые факторы успеха позже в книге, с подробными стратегиями для разработки эффективных ИИ-агентов (глава 8) и успешной интеграции их в ваш бизнес (часть 4)

Как лидеры преодолевают препятствия при внедрении агентов

Организации, внедряющие ИИ-агентов, сталкиваются с несколькими общими проблемами. Интеграция систем – наиболее часто упоминаемая, с 45 % компаний, сообщающих о ней как о значительном препятствии. Успешные организации решают это через поэтапные подходы к интеграции и архитектуру, ориентированную на API, вместе с регулярными процедурами тестирования и валидации.

Качество данных представляет еще одну серьезную проблему, о которой сообщают 35 % компаний. Организации преодолевают это через структурированные инициативы по управлению данными и регулярные оценки качества. Техническая компетентность замыкает тройку главных проблем с 20 % респондентов, упоминающих ее как проблему. Ведущие организации решают это через всесторонние программы обучения и стратегические внешние партнерства.

Операционные проблемы сосредоточены вокруг управления изменениями, мониторинга производительности и управления затратами. Успешные организации решают их через четкие стратегии коммуникации, определенные важнейшие показатели эффективности (KPI) и регулярные обзоры затрат. Они также поддерживают сильные петли обратной связи для обеспечения непрерывного совершенствования.

Мы глубже рассмотрим эти критические проблемы и решения позже в книге, предлагая практические стратегии для разработки мощных ИИ-агентов (глава 8) и эффективного внедрения их в ваш бизнес (часть 4).

В каком направлении развиваются агенты и как подготовиться к будущему

Взгляд в будущее показывает, что траектория внедрения ИИ-агентов не демонстрирует признаков замедления. Наше исследование указывает, что 85 % компаний планируют увеличить свои внедрения агентов, при этом семь из десяти исследуют новые сценарии использования, а 60 % увеличивают свои бюджеты на ИИ. Более половины разрабатывают индивидуальные решения, адаптированные под их конкретные потребности.

Наше исследование предлагает несколько важнейших рекомендаций для бизнес-лидеров, рассматривающих или начинающих свое путешествие с ИИ-агентами. Во-первых, хотя стратегическое мышление важно, начинать с малого критично. Успешные организации выявляют сценарии использования с высоким воздействием и низким риском для своих начальных внедрений и постепенно наращивают успехи.

Инвестиции в инфраструктуру должны быть приоритетом с особым вниманием к качеству данных и мерам безопасности. Организации должны обеспечить масштабируемость своих систем для поддержки будущего роста и дополнительных сценариев использования.

Управление изменениями заслуживает значительного внимания. Успешные организации разрабатывают всесторонние программы обучения и создают прозрачные каналы коммуникации. Они работают над созданием культуры инноваций, где сотрудники чувствуют себя уполномоченными работать вместе с ИИ-агентами, а не ощущают угрозу от них.

Наконец, измерение и итерация имеют решающее значение. Успешные организации с самого начала определяют четкие метрики успеха и поддерживают регулярные обзоры производительности. Они рассматривают свои внедрения ИИ-агентов как циклы непрерывного совершенствования, а не разовые развертывания.

Путь вперед: что нам говорят тренды внедрения

Данные нашего исследования ясно показывают, что ИИ-агенты приносят значительную пользу в разных отраслях. Однако успех требует продуманного подхода, сочетающего техническую компетентность, сильное управление изменениями и четкие бизнес-цели. Организации, которые следуют моделям успешных внедрений, – начиная с пилотов, сосредотачиваясь на четких сценариях использования и поддерживая строгий человеческий надзор, – с наибольшей вероятностью достигнут положительных результатов.

Взгляд в будущее показывает, что тенденция к увеличению внедрения агентов не замедляется. Бизнес-лидеры должны рассматривать это не как угрозу, а как возможность переосмыслить, как выполняется работа в их организациях. Секрет в том, чтобы подходить к внедрению стратегически, учиться у ранних последователей и сохранять сбалансированный взгляд на то, как агенты могут дополнять и усиливать человеческие способности, а не заменять их. Позже в книге мы разберем эти главные проблемы внедрения и лучшие практики, охватывая то, как разрабатывать ИИ-агентов для максимального воздействия (глава 8) и бесшовно интегрировать их в ваши бизнес-операции (часть 4).

Пять уровней ИИ-агентов: от автоматизации к автономии

Как мы видели в главе 1, рынок ИИ-агентов быстро растет, с сотнями поставщиков, предлагающих решения с широким спектром возможностей. Эта распространенность создает проблему: как разобраться в этих различных системах? Как отличить простые инструменты автоматизации от действительно автономных агентов? Эта глава представляет всесторонний обзор для понимания прогрессии возможностей ИИ-агентов – от базового следования правилам до сложной автономии, – которая поможет вам ориентироваться в этом сложном ландшафте и принимать обоснованные решения о том, какие решения подходят для ваших потребностей.

РАЗБОР ВОЗМОЖНОСТЕЙ ИИ-АГЕНТОВ

Когда мы впервые начали внедрять ИИ-агентов в организациях, мы заметили общую закономерность. Бизнес-лидеры часто бросались в разворачивание, не понимая по-настоящему, что эти цифровые товарищи по команде могут и не могут делать. Это напоминало нам попытку работать с новым коллегой, не узнав сначала о его навыках, опыте и стиле работы, – рецепт для несогласованных ожиданий и упущенных возможностей.

Почему важно картирование возможностей

Когда мы интегрируем новых членов команды, мы не просто вручаем им задачи и надеемся на лучшее. Мы вкладываем время в понимание их возможностей, оценку их сильных и слабых сторон и изучение того, как эффективно работать вместе. Через интервью, обсуждения и практические тесты мы узнаем не только, что они могут делать, но и как они думают, как подходят к проблемам и где им может понадобиться поддержка или руководство.

Этот же продуманный подход критичен при работе с ИИ-агентами. Хотя эти цифровые коллеги могут обрабатывать информацию с невероятной скоростью и масштабом, у них также есть свои уникальные характеристики, ограничения и способы «мышления». Понимание этих аспектов – это не только о том, какие задачи делегировать, – это о создании эффективных партнерств, которые максимизируют потенциал как человеческого, так и искусственного интеллекта.

Фреймворк SPAR: естественный способ понимания ИИ-агентов

Чтобы объяснить возможности ИИ-агентов, мы разработали то, что называем фреймворком SPAR: Sense (ощущать), Plan (планировать), Act (действовать) и Reflect (рефлексировать). Мы сознательно выбрали это название – как спарринг-партнер в боевых видах спорта, ИИ-агент постоянно взаимодействует и адаптируется к своей среде.

Как действует человек



Рис. 1.1. Как действует человек (Источник: © Borner et al.)¹

Этот фреймворк отражает то, как мы, люди, достигаем своих собственных целей. Мы начинаем с определения, что нужно сделать, – например, приготовить ужин. Далее мы собираем информацию, проверяя, какие ингредиенты доступны. Затем обдумываем варианты, выбирая лучший подход, – возможно, приготовить спагетти. Определившись, мы планируем шаги, такие как кипячение воды и приготовление соуса. С четким планом мы приступаем к действиям и готовим еду. После этого мы оцениваем результат, учимся на опыте и корректируем план действия на будущее – возможно, в следующий раз использовать меньше соли, – создавая непрерывную петлю обратной связи для совершенствования.

Когда мы объясняем, что такое ИИ-агент, бизнес-лидерам и профессионалам, мы часто проводим параллели с автономными автомобилями. Это

¹ Открытый доступ: все рисунки в этой книге распространяются по условиям лицензии Creative Commons Attribution 4.0 International, которая разрешает неограниченное использование, распространение и воспроизведение при соблюдении условий, указанных здесь: <http://creativecommons.org/licenses/by/4.0/>.

не только потому, что самоуправляемые машины увлекательны – они действительно являются идеальными примерами ИИ-агентов в действии. Через эту призму давайте рассмотрим фреймворк SPAR: Ощущение, Планирование, Действие и Рефлексия. Этот фреймворк охватывает четыре фундаментальные возможности, которые определяют, как ИИ-агенты функционируют в своих средах.

Как действует ИИ-агент: фреймворк SPAR



Рис. 1.2. Как действует ИИ-агент: фреймворк SPAR (Источник: © Bornet et al.)

Ощущение: глаза и уши агентов

Представьте, что вы сидите в самоуправляемом автомобиле, который движется по городским улицам. Массив камер, радарных систем и сенсоров автомобиля постоянно собирает данные об окружающей среде – отслеживая все, от положения ближайших машин до дорожных сигналов и дорожных условий. Это удивительно похоже на то, как ИИ-агенты функционируют в цифровых средах.

Подобно тому, как самоуправляемому автомобилю нужно всесторонне понимать свою среду, ИИ-агенты должны быть способны воспринимать свое цифровое рабочее пространство. Они собирают данные из множества источников, обнаруживают важные триггеры¹ и поддерживают осведомленность о контексте своей работы. Когда вы вводите пункт назначения в автономный автомобиль, вы задаете его цель – так же, как вы ставите задачу перед ИИ-агентом. Агент поддерживает то, что мы называем «окном краткосрочного контекста», подобно тому, как самоуправляемый автомобиль отслеживает текущие дорожные условия и требования навигации.

Планирование: прокладывание маршрута

Как только автономный автомобиль узнает, куда ему нужно ехать, он не начинает движение сразу, вслепую. Он обрабатывает картографические данные, учитывает шаблоны трафика и оценивает несколько возможных маршрутов. Эта фаза планирования идеально отражает работу ИИ-агентов. Они не просто

¹ Триггер в контексте искусственного интеллекта – это событие, которое запускает выполнение заранее определенного сценария. – Прим. ред.

приступают к выполнению – сначала они обрабатывают доступную информацию, чтобы принимать обоснованные решения о том, как достичь своих целей.

Представьте, как самоуправляемый автомобиль планирует смену полосы. Он не просто резко сворачивает; он оценивает скорость и положение окружающих транспортных средств, рассчитывает оптимальный момент для маневра и обеспечивает его безопасное выполнение. Точно так же ИИ-агенты занимаются сложным рассуждением, чтобы разработать пошаговые планы для достижения своих целей. Они оценивают варианты, приоритизируют¹ действия и координируют ресурсы, подобно тому, как автономный автомобиль координирует свои различные системы для выполнения сложного маневра вождения.

Действие: приведение планов в исполнение

Способность предпринимать конкретные действия отличает как автономные автомобили, так и ИИ-агентов от простых аналитических систем. Когда самоуправляемый автомобиль выполняет поворот, он координирует несколько систем – рулевое управление, ускорение, торможение – в точных последовательностях. Аналогично ИИ-агенты используют доступные инструменты для выполнения действий в своей среде, будь то отправка сообщений, обновление систем или управление цифровыми ресурсами.

Особенно интересно, как обе системы отслеживают свои действия в реальном времени. Подобно тому, как самоуправляемый автомобиль непрерывно корректирует свое рулевое управление и скорость в зависимости от дорожных условий, ИИ-агенты активно отслеживают свои действия на точность и эффективность, внося корректировки по мере необходимости, чтобы оставаться на пути к своим целям.

Когда что-то идет не так в автономном автомобиле, обычно есть удаленный человек, который может взять управление на себя и решить проблему². Точно так же, когда ИИ-агенты действуют, должен быть четкий путь для людей, чтобы проверять эти действия и предпринимать корректирующие шаги, когда это необходимо.

Рефлексия: обучение на опыте

Пожалуй, наиболее сложной возможностью как автономных автомобилей, так и ИИ-агентов является их способность учиться и адаптироваться на основе опыта. Когда самоуправляемый автомобиль сталкивается с дорожными работами или плотным трафиком, он не просто справляется с текущей ситуацией – он может включить эту информацию в свою базу знаний, чтобы улучшить будущие поездки.

Эта рефлексивная способность позволяет обеим системам становиться лучше с течением времени. Подобно тому, как автономные автомобили изучают

¹ Приоритизация – это процесс ранжирования задач, требований к проекту или функций продукта по степени важности для достижения целей. Цель – определить оптимальную последовательность выполнения задач для достижения максимального эффекта при ограниченных ресурсах. – *Прим. ред.*

² Кейд Метц, 2024. «Когда самоуправляемые автомобили на самом деле не управляют собой», The New York Times, 11 сентября 2024, <https://www.nytimes.com/2024/09/11/insider/when-self-driving-cars-dont-actually-drive-themselves.html>.

оптимальные маршруты и шаблоны вождения, ИИ-агенты могут оценивать свою производительность, анализировать результаты и совершенствовать свои подходы на основе того, что работает лучше всего. Они создают то, что мы могли бы назвать «оперативной памятью», которая помогает им действовать более эффективно в подобных ситуациях в будущем.

Сила интеграции

Что делает как самоуправляемые автомобили, так и ИИ-агентов такими мощными – это то, как эти четыре способности работают вместе в непрерывном цикле. Каждая способность подпитывает и усиливает другие, создавая единую систему, которая может преследовать сложные цели с возрастающей сложностью. Датчики автомобиля информируют его планирование, которое направляет его действия, которые генерируют опыт, на основе которого он учится, – все это при сохранении фокуса на конечной цели безопасного и эффективно-го перемещения.

Этот интегрированный подход представляет фундаментальный сдвиг от традиционной автоматизации. Вместо следования жестким, заранее определенным инструкциям как автономные автомобили, так и ИИ-агенты активно взаимодействуют со своей средой, принимают решения, предпринимают действия и учатся на результатах. Они не просто выполняют команды – они работают над достижением целей с определенной степенью независимости, что делает их настоящими агентами изменений в своих соответствующих доменах.

Хотя фреймворк SPAR помогает нам понять, что могут делать ИИ-агенты, он не говорит нам, насколько хорошо они могут это делать. Подумайте о вождении: знание того, что автомобилю нужны рулевое управление, ускорение, торможение и навигация, не говорит вам, имеете ли вы дело с обычным седаном или полностью автономным автомобилем. Точно так же разные ИИ-агенты могут иметь совершенно разные уровни сложности в том, как они чувствуют, планируют, действуют и рефлексиируют.

Эта сложность создает проблему для организаций. Когда поставщики заявляют, что их решения используют «ИИ-агентов», что это на самом деле означает? Как бизнес-лидеры могут оценивать и сравнивать разные системы? Как они узнают, какой уровень способностей им действительно нужен?

СЛОЖНАЯ РЕАЛЬНОСТЬ ВОЗМОЖНОСТЕЙ ИИ-АГЕНТОВ

В процессе консалтинговой работы и исследований мы неожиданно обнаружили, что в отрасли нет консенсуса относительно того, что на самом деле определяет «агента». Чтобы решить эту проблему, мы выступаем за прогрессивный фреймворк – такой, который отражает эволюционную природу возможностей ИИ. Подобно тому, как технологии развиваются от простых к сложным, этот фреймворк предоставляет структурированный способ оценки и определения развивающейся роли ИИ-агентов.

Бинарная классификация «агент» или «не агент» в текущем ландшафте ИИ проблематична. Такая жесткая категоризация не способна охватить нюансы

возможностей различных систем, часто приводит к нереалистичным ожиданиям или недооценке потенциала системы и не соответствует инкрементальной природе развития ИИ в реальных приложениях¹.

Мы также слышим мнения, ограничивающие ИИ-агентов только самыми сложными системами – теми, которые действуют, учатся и адаптируются. Мы считаем, что это упрощение и введение в заблуждение. Это как говорить, что автомобиль не является автомобилем, если он не полностью автономен. Реальность в том, что прогресс строится поэтапно. Если мы примем узкое определение, мы упустим возможности, которые разворачиваются прямо сейчас с базовыми ИИ-агентами², уже дающими эффект. Вопрос не в том, «является ли это конечным агентом?». Вопрос в том, «насколько эффективно он может действовать сегодня – и что дальше?». Давайте оставим дверь открытой для инноваций на каждом этапе пути.

После изучения различных фреймворков с компаниями, которым мы помогаем, мы обнаружили, что автомобильная промышленность предлагает идеальную аналогию, которая находит отклик как у технических, так и у бизнес-интересантов. Подобно тому, как Общество автомобильных инженеров (SAE) определяет шесть уровней автоматизации вождения, от уровня 0 (полностью ручное) до уровня 5 (полностью автономное при любых условиях), мы можем применить схожий путь прогрессии к ИИ-агентам.

Сегодня, несмотря на впечатляющие способности автомобилей, таких как Tesla, мы в основном работаем на уровнях 2 или 3³ – где автоматизация выполняет многие задачи, но все еще требует человеческого надзора и периодического вмешательства. На момент печати книги (март 2025 года) Waymo и Cruise только тестируют автомобили уровня 4 в ограниченных, «географических» зонах для сервисов такси в городах, таких как Финикс, Сан-Франциско и Лос-Анджелес⁴.

ПРОГРЕССИВНЫЙ ФРЕЙМВОРК АГЕНТНОГО ИИ

То же самое относится к ИИ-агентам. Хотя мы часто говорим о них как о полностью автономных системах, на деле мы имеем дело с различными уровнями возможностей и независимости, которые прогрессируют по четкому пути развития.

¹ Инкрементальная природа развития ИИ – это процесс постепенного улучшения ИИ-систем через пошаговые итерации, где каждая версия модели совершенствуется на основе новых данных, обратной связи или оптимизации алгоритмов. – *Прим. ред.*

² Foundational AI agents (в русскоязычной литературе – «базовые ИИ-агенты» или «фундаментальные ИИ-агенты») – это основные программные компоненты ИИ, которые служат фундаментом для построения более сложных систем, обеспечивая важнейшие функции, такие как обработка данных, принятие решений или координация задач. Они представляют собой универсальные модули, которые могут быть интегрированы в многоагентные системы (например, Sales Info Agent) для выполнения базовых операций, таких как скрейпинг экрана, анализ контекста или взаимодействие с пользователем, поддерживая инкрементальное развитие и масштабируемость ИИ. – *Прим. ред.*

³ «Википедия», 2025. «Tesla Autopilot», https://en.wikipedia.org/wiki/Tesla_Autopilot.

⁴ Джеймсон Доу, 2024. «Waymo начинает полностью автономные поездки в Лос-Анджелесе завтра; Остин позже в этом году», Electrek, <https://electrek.co/2024/03/13/waymo-starts-fully-autonomous-rides-in-la-tomorrow-austin-later-this-year/>.

На ранних стадиях этой прогрессии у нас есть ИИ-агенты, которые могут выполнять конкретные, заранее определенные задачи, но требуют значительного человеческого надзора – как автомобиль с базовыми функциями помощи водителю. По мере продвижения по прогрессивному фреймворку мы находим агентов, которые могут справляться с более сложными последовательностями действий и принимать некоторые независимые решения, но все еще нуждаются в человеческой валидации в критических точках – подобно самым продвинутым коммерческим автомобилям сегодня. На дальнем конце этой прогрессии лежат высшие уровни, где агенты могут полностью понимать, планировать и выполнять сложные миссии с минимальным человеческим вмешательством в любой области деятельности. Они остаются в основном теоретическими – так же, как автомобили уровня 5 все еще являются целью будущего.

Понимание этих уровней прогрессии – не просто академическое упражнение. Этот фреймворк помогает организациям выявлять преувеличенные заявления о возможностях ИИ-агентов и принимать обоснованные решения о внедрении ИИ в их проекты. Он обеспечивает более эффективную коммуникацию между техническими командами и конечными пользователями, предоставляя четкую дорожную карту для разработки стратегии ИИ, которая преодолевает шумиху.

Давайте рассмотрим, как каждый из этих уровней прогрессии выглядит на практике, начиная с уровня 0 – «ручные операции», где люди выполняют все когнитивные и исполнительные задачи без какой-либо помощи агента. Оттуда мы увидим, как каждый уровень строится на предыдущем, добавляя новые возможности и степени автономии, при этом все еще требуя соответствующего человеческого надзора.

Таблица 1.3. Прогрессивный фреймворк агентного ИИ (Источник: © Bornet et al.)

Уровень	Аналогия с автомобилем	Аналогия с агентным ИИ	Основные технологии	Способности SPAR (ощущение, планирование, действие, рефлексия)
Уровень 0 Ручные операции (только человек)	Ручное вождение без помощи	Люди выполняют все задачи без автоматизации	Базовые цифровые инструменты (таблицы, электронная почта), ручная обработка	Нет
Уровень 1 Автоматизация на основе правил	Базовый круиз-контроль поддерживает скорость, но требует управления человеком	Простая автоматизация следует фиксированным правилам (например, ввод данных, RPA-системы)	Базовые инструменты автоматизации (RPA, простые скрипты, движки правил)	Ощущение: предопределенные триггеры и структурированные данные. Планирование: простые правила «если-то». Действие: детерминированные действия на основе фиксированных входов. Рефлексия: нет настоящего обучения, только логирование* ¹ и отчетность об ошибках

¹ Логирование – это систематизированный сбор записей (логов), фиксирующих события, ошибки, запросы и другие действия в информационной системе. – *Прим. ред.*

Окончание табл. 1.3

Уровень	Аналогия с автомобилем	Аналогия с агентным ИИ	Основные технологии	Способности SPAR (ощущение, планирование, действие, рефлексия)
Уровень 2 Интеллектуальная автоматизация процессов	Продвинутые системы помощи водителю управляют скоростью и рулением с надзором	ИИ сочетает автоматизацию с когнитивными способностями, такими как NLP и машинное обучение	Инструменты ИИ (машинное обучение, NLP, компьютерное зрение, RPA, оркестрация процессов)	Ощущение: полуструктурированные данные из нескольких источников. Планирование: базовые модели ИИ для распознавания шаблонов и принятия решений. Действие: сложные действия с обработкой ошибок. Рефлексия: базовая аналитика и мониторинг производительности, без адаптивных способностей
Уровень 3 Агентные рабочие процессы	Автомобили самостоятельно управляют на шоссе, но требуют вмешательства человека в сложных ситуациях	Агенты генерируют контент, планируют, рассуждают и адаптируются в определенных доменах	Большие языковые модели, системы памяти, инструменты генерации контента, базовое обучение с подкреплением	Ощущение: продвинутое понимание естественного языка и контекстная осведомленность. Планирование: рассуждение с использованием базовых моделей, оркестрация сложных рабочих процессов. Действие: связывание инструментов и выполнение многоэтапных задач. Рефлексия: ограниченные краткосрочные корректировки по обратной связи и долгосрочная память
Уровень 4 Полуавтономные агенты	Самоуправляемые автомобили работают автономно в определенных условиях	Агенты работают автономно в пределах определенной области знаний, адаптируют стратегии и учатся	Продвинутое рассуждение и планирование, адаптация в реальном времени, каузальное рассуждение	Ощущение: мультимодальное восприятие и интерпретация различных входов. Планирование: динамические стратегии для сложных задач и разбиение целей. Действие: автономное использование инструментов и восстановление после ошибок. Рефлексия: сохраняет контекст от сессии к сессии, учится на прошлом опыте
Уровень 5 Полностью автономные агенты	Полностью автономные автомобили управляются в любых условиях	ИИ-системы справляются с любой задачей, обучаются междоменно и самоадаптируются без вмешательства человека	Сложные системы памяти, продвинутые механизмы обучения, протоколы безопасности для автономии	Ощущение: полная осведомленность об окружающей среде и формулировка целей. Планирование: продвинутое рассуждение и оригинальное решение проблем. Действие: полная автономия в выборе и выполнении инструментов. Рефлексия: непрерывное самоулучшение, надежная долгосрочная память

Уровень 0. Ручные операции (только человек)

На уровне 0 люди выполняют все когнитивные и исполнительные задачи без какой-либо помощи автоматизации. Требуемые способности чисто человеческие: логическое мышление, принятие решений, выполнение физических задач и обучение на опыте. «Технология» состоит из базовых цифровых инструментов, таких как электронные таблицы, почтовые клиенты и бизнес-приложения, но люди должны полностью управлять ими. Примеры включают представителей клиентской службы, вручную отвечающих на каждое письмо, финансовых аналитиков, самостоятельно собирающих и анализирующих данные для отчетов, или сотрудников отдела кадров, вручную обрабатывающих документы сотрудников. Неэффективности и ограничения на этом уровне – человеческие ошибки, усталость, ограничения по скорости и проблемы масштабирования – подтолкнули к разработке базовой автоматизации.

Уровень 1. Автоматизация на основе правил

Подобно автомобилю с базовым круиз-контролем, этот уровень представляет наши первые шаги к автоматизации. Это простые «агенты», которые следуют заранее определенным правилам и фиксированным рабочим процессам, – например, базовые скрипты или системы роботизированной автоматизации процессов (RPA). Они могут справляться с повторяющимися задачами, такими как ввод данных или обработка форм, но не обладают реальным интеллектом или адаптивностью. Они требуют полной человеческой настройки и надзора, подобно тому, как система круиз-контроля только поддерживает заданную скорость.

Эти агенты осваивают базовые способности выполнения повторяющихся задач и следования простым рабочим процессам. Они в основном полагаются на технологии скрейпинга экрана, базовую запись процессов и движки правил. Типичный RPA-агент может обрабатывать счета, копируя данные из таблиц Excel в бухгалтерские системы, автоматизировать онбординг сотрудников, заполняя информацию о новом сотруднике в несколько HR-систем, или управлять рутинными ответами на письма, используя заранее определенные шаблоны. Технологический стек относительно прост: базовые инструменты автоматизации рабочих процессов, простые скрипты и системы RPA. Простые навыки, которыми обладают Amazon Echo, Google Home и Apple HomePod, также попадают в эту категорию.

Уровень 2. Интеллектуальная автоматизация

Этот уровень сравним с продвинутыми системами помощи водителю, которые могут управлять как скоростью, так и рулением. Эти агенты сочетают базовую автоматизацию со способностями ИИ, такими как машинное обучение, обработка естественного языка и компьютерное зрение. Они могут обрабатывать неструктурированные данные, делать прогнозы и справляться с задачами, требующими когнитивных способностей. Однако как автомобиль, который может держаться в своей полосе, но требует человеческого надзора, они все еще работают в довольно жестких параметрах и требуют значительного человеческого контроля.

Способность автоматизировать процессы от начала до конца значительно расширяется благодаря ИИ, обеспечивающему различные когнитивные способности. Типичные применения включают агентов клиентской службы, которые могут отвечать на распространенные вопросы, распознавать простые запросы и направлять клиентов к нужным ресурсам на основе ключевых слов. Другие примеры включают системы обработки документов, которые могут извлекать информацию из различных форматов, таких как PDF или изображения, и обрабатывать их в базе данных, или торговых агентов, которые могут выполнять заранее определенные финансовые транзакции на основе рыночных условий.

Техническая основа этих агентов сочетает четыре важнейшие способности. Способность видеть использует компьютерное зрение для «видения» и обработки документов, изображений и визуальной информации. Способность понимания языка позволяет осуществлять коммуникацию с человеком через обработку естественного языка. Способность к мышлению и обучению использует модели машинного обучения для анализа данных, прогнозирования, классификации информации и оптимизации решений. Способность к выполнению задания координирует все действия через интеллектуальные инструменты рабочих процессов и RPA, обрабатывая как простые задачи, так и сложную оркестрацию процессов. Подробности об этих способностях можно найти в нашей книге «Интеллектуальная автоматизация».

Уровень 3. Агентные рабочие процессы

Эти агенты схожи с автомобилями, которые могут самостоятельно управлять своим передвижением на шоссе, но требуют вмешательства человека в сложных ситуациях. Они могут генерировать контент (текст, изображения, видео) и обладают некоторой способностью планировать свои действия, рассуждать и запоминать. Они хорошо работают в заранее определенных границах и областях знаний, адаптируясь к некоторым вариациям в своей среде. Однако они все еще испытывают трудности с нюансами, сложными или новыми ситуациями и сложными решениями.

Эти агенты осваивают контекстное принятие решений и базовое обучение на основе обратной связи. Например, цифровой помощник может управлять онбордингом сотрудников, отправляя документы, планируя обучение, отвечая на распространенные вопросы и отмечая необычные запросы для человеческой проверки. Другие примеры включают торговых агентов, выполняющих сложные финансовые транзакции на основе рыночных условий, и агентов по созданию контента, которые производят и оптимизируют маркетинговые материалы для нескольких каналов.

Технология, поддерживающая этих агентов, строится на предыдущих уровнях, добавляя три ключевых компонента. Большие языковые модели обеспечивают возможности планирования, рассуждения и генерации контента. Это дополняется базовыми системами памяти и обучения, особенно обучением с подкреплением для адаптивного поведения. Наконец, эти агенты включают способности манипуляции инструментами, в основном сосредоточенные на цифровых интерфейсах, хотя все еще ограниченные во взаимодействиях с физическим миром.

Уровень 4. Полуавтономные агентные системы

Подобно самоуправляемым автомобилям, которые могут работать полностью автономно в определенных условиях (хорошая погода, картированные зоны), эти ИИ-агенты работают независимо в пределах определенных доменов. Они могут понимать цели, разбивать их на шаги, учиться на результатах и адаптировать стратегии – но только в пределах своей области знаний. Они демонстрируют высокую гибкость и справляются со сложными задачами, хотя их автономия остается ограниченной конкретными доменами.

Эти агенты осваивают декомпозицию целей, стратегическое планирование и адаптивное обучение в реальном времени и в своих доменах. Они используют продвинутые архитектуры ИИ, включая рекурсивное самоулучшение, модели каузального рассуждения и системы координации нескольких агентов. Применения включают исследовательских агентов, которые могут разрабатывать и выполнять сложные научные эксперименты, агентов медицинской диагностики, которые анализируют данные пациентов и рекомендуют планы лечения, и финансовых консультантов, которые отслеживают предпочтения пользователей, предлагают бюджетные планы и корректируют рекомендации на основе шаблонов расходов.

Технологическая архитектура этих агентов представляет значительное продвижение в сложности и способностях. Продвинутые системы рассуждения и планирования формируют когнитивное ядро, работая в связке с механизмами памяти и обучения, которые обеспечивают адаптацию в реальном времени. Это дополняется улучшенными способностями манипуляции инструментами, которые распространяются как на цифровые, так и на физические интерфейсы, хотя все еще в пределах определенных доменов.

Уровень 5. Полностью автономные агентные системы

Это представляет теоретическую вершину – подобно полностью автономному автомобилю, который может осуществлять управление в любых условиях. Эти агенты были бы по-настоящему автономными системами, способными понимать любую цель, разрабатывать стратегии, учиться на опыте и адаптироваться к новым ситуациям в разных доменах. Они могли бы бесшовно интегрироваться с другими системами, создавать свои собственные рабочие процессы и принимать сложные решения независимо, сохраняя при этом соответствие человеческим ценностям и целям.

Эти теоретические агенты освоили бы общее решение проблем, междоменное обучение и автономное установление целей. Применения могли бы включать универсальных персональных помощников, выполняющих любые задачи в личных и профессиональных доменах, автономных бизнес-менеджеров, управляющих целыми операциями, и исследовательских агентов, совершающих новые научные открытия в разных областях.

Теоретический технологический стек для этих агентов потребовал бы способностей, выходящих за рамки текущего уровня техники. Полномасштабная автономная система потребовала бы интеграции продвинутых систем памяти, сложных механизмов обучения и адаптивности в реальном времени в любой области применения. Это потребовало бы еще не разработанных фреймворков

для искусственного сверхинтеллекта в сочетании с надежными протоколами безопасности и сложными системами этического рассуждения, чтобы обеспечить соответствие человеческим ценностям.

Эволюция ИИ-агентов: где мы находимся сегодня

Критически важным для этой эволюции является не только увеличение сложности отдельных способностей, но и интеграция и оркестрация множества способностей в связные, целенаправленные системы. Подобно тому, как автомобиль уровня 5 должен бесшовно сочетать восприятие, прогнозирование, планирование и управление, продвинутые ИИ-агенты требуют плавной интеграции множества технологий и способностей ИИ для достижения своих целей.

В настоящее время большинство ИИ-агентов на рынке работают на уровнях 2 или 3 с некоторыми специализированными системами, достигающими уровня 4 в узких доменах. Как и полностью автономные автомобили, агенты уровня 5 остаются целью будущего – той, которая вызывает как захватывающие возможности, так и важные вопросы о контроле, безопасности и человеческом надзоре.

Эта эволюция не только об увеличении автоматизации, но и о разработке систем, которые могут все больше понимать контекст, учиться на опыте и принимать независимые решения, оставаясь при этом в соответствии с человеческими намерениями и ценностями. Каждый уровень строится на возможностях предыдущих, создавая все более сложных агентов, которые могут справляться с более сложными и тонкими задачами с большей автономией.

Магия прогрессивной автономии: уровни ИИ-агентов

Когда мы впервые начали работать с ИИ-агентами, нас часто тянуло к самым продвинутым доступным возможностям. Казалось логичным – почему бы не использовать самую сложную технологию? Но опыт научил нас фундаментальной истине, которую мы теперь называем золотым правилом ИИ-агентов: чем проще, тем лучше. Это не просто о технологическом минимализме; это о нахождении правильного баланса между способностями и контролем для каждого конкретного приложения.

Эволюция автономии: естественная прогрессия

Подумайте о том, как мы учим нового сотрудника работать с электронной почтой. Сначала мы даем подробные пошаговые инструкции: «Открой почту, нажми "Новое сообщение", введи адрес получателя, напиши этот конкретный текст...». По мере того как он набирается опыта, наши инструкции становятся шире: «Составь ответ на этот клиентский запрос, сохраняя наш обычный профессиональный тон». В конечном итоге мы можем просто сказать: «Управляй коммуникациями с клиентами и держи их в курсе прогресса проекта». Эта же прогрессия применима к ИИ-агентам.

- На уровнях 1 и 2 нам нужно указывать каждое действие: «Нажми кнопку "Новое письмо", скопируй этот текст, вставь сюда, введи этот адрес, нажми "Отправить"».

- На уровне 3 мы уже можем сказать: «Напиши и отправь письмо, используя эту информацию, адаптируя ее к контексту получателя».
- На уровне 4 мы можем просто проинструктировать: «Управляй всеми коммуникациями с клиентами, чтобы они были хорошо информированы».
- И на уровне 5 – хотя этот уровень остается теоретическим – мы могли бы просто поставить цель, например «Увеличь продажи через лучшую удовлетворенность клиентов», и позволить агенту самому определить все необходимые действия и коммуникации.

Прогрессивный фреймворк агентного ИИ: больше, чем просто зрелость

Этот фреймворк не традиционная модель зрелости, где более высокие уровни всегда лучше. Вместо этого лучше думать о нем как о каталоге различных типов агентов, каждый из которых подходит для конкретных потребностей и контекстов. Это похоже на технологии помощи водителю в современных автомобилях. Хотя полностью автономное вождение на шоссе может быть технически возможным, многие водители предпочитают предсказуемость и контроль базового круиз-контроля. «Лучший» уровень полностью зависит от ваших конкретных потребностей и обстоятельств.

Давайте рассмотрим, как важнейшие свойства эволюционируют по мере продвижения по прогрессивному фреймворку агентного ИИ.

Прогрессивный фреймворк агентного ИИ

Чем больше вы поднимаетесь по уровню фреймворка, тем меньше:

- Времени для реализации
- Контроля, который у вас есть
- Инструкций, нужных вам




Рис. 1.3. Прогрессивный фреймворк агентного ИИ (Источник: © Bornet et al.)

Автономия и контроль: деликатный баланс

По мере продвижения по уровням автономия увеличивается, а прямой человеческий контроль уменьшается. На уровне 1 агенты работают как хорошо запрограммированные машины, следуя точным инструкциям с предсказуемыми результатами. Уровень 2 вводит базовые способности принятия решений, но все еще в жестких параметрах. Уровень 3 представляет значительный скачок с агентами, способными понимать контекст и соответственно адаптировать свой подход. Уровни 4 и 5 вводят все более сложное

автономное поведение с агентами, способными устанавливать свои собственные промежуточные цели (sub-goals) и разрабатывать оригинальные стратегии для их достижения.

Однако эта увеличенная автономия сопровождается уменьшением прямого контроля. Это похоже на воспитание ребенка – по мере того как он становится более независимым, ваш прямой контроль естественным образом уменьшается, заменяясь руководством и надзором. Этот компромисс становится особенно важным в чувствительных доменах, таких как здравоохранение, финансы или юридическое соответствие, где предсказуемость и подотчетность имеют решающее значение.

Парадокс инструкций: меньше – значит больше

Одним из самых увлекательных аспектов прогрессивного фреймворка является то, как инструкции становятся проще по мере того, как способности становятся более выдающимися. На нижних уровнях инструкции должны быть детализированными и явными, как программирование базовой машины. По мере продвижения вверх инструкции становятся более ориентированными на цели и более абстрактными. Этот сдвиг отражает человеческое развитие – мы переходим от пошаговых инструкций для детей к простому изложению целей и доверию их суждениям.

Динамика внедрения и обучения

Вопреки интуитивному мнению, агенты более высокого уровня могут быть более быстрыми в развертывании, поскольку они могут учиться путем проб и ошибок. Однако они требуют более сложных систем надзора и управления рисками. Агенты нижнего уровня, хотя и требуют более детального начального программирования, предлагают более предсказуемое поведение и более легкий надзор. Этот компромисс становится критическим при выборе подходящего уровня для конкретных приложений.

Мудрость простого начала

Почему мы выступаем за начало с более простых, низкоуровневых агентов? Подумайте об обучении игре на музыкальном инструменте. Вы не начинаете со сложных инструментальных партий – вы начинаете с базовых гамм и простых пьес, постепенно развивая свои навыки и понимание. Этот подход позволяет вам развить правильные техники и понимание, перед тем как браться за более сложные задачи.

Аналогично начало с использованием агентов нижнего уровня позволяет организациям:

- ознакомиться с ИИ-агентами в контролируемой среде;
- разработать надлежащие механизмы надзора и управления;
- понять практические последствия различных уровней способностей;
- создать соответствующие ограничители и системы контроля;
- нарастить организационную уверенность и компетентность.

Выбор правильного уровня

Ключ к успешному внедрению заключается в выборе подходящего уровня агента для каждого конкретного приложения. Рассмотрим компанию финансовых услуг, внедряющую ИИ-агентов. Они могут выбрать агентов уровня 1 или 2 для обработки транзакций, где важны предсказуемость и аудиторские следы. Однако они могут внедрить агентов уровня 3 для клиентской службы, где адаптивность и контекстная осведомленность ценнее строгого контроля.

Эта гибкость в выборе подходящего уровня автономии – главная сила фреймворка. Он позволяет организациям соответствовать способностям агентов их конкретным потребностям, терпимости к рискам и регуляторным требованиям. Цель не в достижении максимальной автономии, а в нахождении правильного баланса между независимостью и контролем для каждого приложения.

Двигаемся дальше: практический подход

Начиная свое путешествие с ИИ-агентами, помните «Золотое правило»: чем проще, тем лучше. Начинайте с агентов нижнего уровня, даже если ваша конечная цель – внедрение более автономных систем. Используйте это время для создания понимания, установления надлежащих контролей и развития организационных способностей, необходимых для успеха с более продвинутыми агентами.

Хотя наш прогрессивный фреймворк агентного ИИ предоставляет структурированный подход к оценке способностей ИИ-агентов, понимания уровней само по себе недостаточно. Чтобы по-настоящему понять, что делает эти цифровые разумы уникальными, необходимо выйти за рамки фреймворка и исследовать отличительные характеристики, которые их определяют. В следующей главе мы погрузимся в сознание ИИ-агента, рассмотрев как их выдающиеся способности, так и присущие им ограничения – знания, которые окажутся принципиально важными, когда вы начнете работать с этими новыми цифровыми коллегами.

Внутри разума ИИ-агента

Прогрессивный фреймворк агентного ИИ, который мы рассмотрели в предыдущей главе, предоставляет структурированный способ оценки способностей ИИ-агентов, но понимания уровней само по себе недостаточно. Чтобы по-настоящему понять, что делает эти цифровые разумы уникальными, нам нужно выйти за рамки этой структуры и рассмотреть отличительные характеристики, которые их определяют. Эта глава погружает вас в разум ИИ-агента, исследуя как их замечательные способности, так и присущие им ограничения – идеи, которые окажутся решающими, когда вы начнете работать с этими новыми цифровыми коллегами.

Ключевые особенности ИИ-агентов

В нашем опыте внедрения ИИ-агентов в организациях мы выделили несколько фундаментальных характеристик, делающих их уникально мощными. Давайте рассмотрим эти определяющие черты, которые отличают ИИ-агентов от традиционных инструментов автоматизации и помогают объяснить их трансформационный потенциал.

Цифровые работники, а не просто инструменты

Различие между ИИ-агентами и традиционными программными инструментами глубоко. Традиционная автоматизация похожа на высокоэффективную сборочную линию – фиксированную, предсказуемую и ограниченную конкретными задачами. ИИ-агент, с другой стороны, функционирует скорее как квалифицированный цифровой сотрудник, который может думать, адаптироваться и справляться со сложными ситуациями самостоятельно. Подобно тому, как представитель клиентской службы может обрабатывать все – от простых запросов до сложного решения проблем, ИИ-агент может управлять процессами от начала до конца, принимать решения и корректировать свой подход на основе контекста.

Работа с существующими системами

Одно из самых практичных преимуществ ИИ-агентов – их способность работать с существующей технологической инфраструктурой, а не заменять ее. Представьте их как цифровых работников, которые знают, как эффективно ориентироваться и использовать все ваши различные системы.

Эта характеристика особенно ценна, поскольку организации обычно значительные инвестиции вкладывают в свои корпоративные системы – ERP, системы управления взаимоотношениями с клиентами (CRM), системы управления персоналом и др. ИИ-агенты могут интегрироваться с этими системами, извлекая данные из нескольких источников, выполняя процессы на разных платформах и заполняя пробелы в автоматизации. Например, финансовый ИИ-агент может одновременно работать с SAP для данных о транзакциях, Salesforce для информации о клиентах и Excel для пользовательских отчетов, координируя свою работу между этими системами для генерации инсайтов и автоматизации сложных процессов.

Преимущество круглосуточной работы 24/7

В отличие от работников-людей, которым нужны перерывы и которые работают посменно, ИИ-агенты могут работать круглосуточно. Речь идет не только о более долгих часах работы – и о поддержании непрерывной бдительности и способности немедленного отклика на уровне, который невозможен для работников-людей.

Рассмотрим обнаружение мошенничества в банковской сфере. Аналитик-человек может отслеживать ограниченное количество транзакций и может упустить тонкие шаблоны из-за усталости. ИИ-агент может непрерывно отслеживать миллионы транзакций в разных часовых поясах, мгновенно выявляя подозрительные шаблоны и немедленно предпринимая действия. Эта постоянная работа становится особенно важной в таких областях, как кибербезопасность, где угрозы могут возникнуть в любой момент, или в глобальных операциях клиентской службы, где запросы поступают круглосуточно.

Бесконечная масштабируемость

Масштабируемость ИИ-агентов представляет собой фундаментальный сдвиг в том, как организации могут управлять своими возможностями, способностями выполнять задачи. Традиционный рост компании требует найма, обучения и постепенного наращивания возможностей. С ИИ-агентами масштабирование может быть мгновенным и практически неограниченным. Нужно обработать в десять раз больше клиентских запросов? Вы можете развернуть дополнительные экземпляры агентов за минуты, а не месяцы.

Эта масштабируемость распространяется не только на обработку объема задач – она включает способность адаптироваться к новым ситуациям и обучаться новым навыкам. Представьте, что вы можете мгновенно воспроизвести своего лучшего исполнителя в нескольких местах или отделах, поддерживая постоянное качество и производительность. Эта способность становится особенно ценной во время неожиданных всплесков спроса или при выходе на новые рынки.

Универсальность

Одним из самых мощных аспектов ИИ-агентов является их способность эффективно функционировать в разных отраслях и бизнес-функциях. В то время как традиционные решения ИИ часто требуют значительной настройки для каждой отрасли, ИИ-агенты работают на основе обобщаемых принципов, которые широко применяются в разных секторах.

Их основные способности SPAR – чувствовать, планировать, действовать и рефлексировать – остаются неизменными, будь то анализ рисков для банка, оптимизация цепочек поставок для производителя или обработка запросов пациентов для поставщика медицинских услуг. Они могут приобретать отраслевые и специфические для компании знания, сохраняя при этом свои фундаментальные операционные принципы, что делает их невероятно универсальными.

Сила сотрудничества

Пожалуй, самой сложной характеристикой ИИ-агентов является их способность к сотрудничеству – как с людьми, так и с другими агентами. Они могут работать независимо, когда это необходимо, но их настоящая сила проявляется в способности настроиться на совместную работу. Представьте их как командных игроков, которые могут бесшовно интегрироваться в существующие рабочие процессы, поддерживая человеческих работников, а не заменяя их.

В контексте контент-маркетинга, например, один ИИ-агент может генерировать черновики, другой оптимизировать их для SEO, а третий управлять расписанием публикаций – все это при сотрудничестве с человеческими редакторами, которые обеспечивают стратегическое руководство и контроль качества. Это создает мощный гибридный рабочий процесс, который использует сильные стороны как человеческого, так и искусственного интеллекта.

Почему эти характеристики важны

Когда системы агентного ИИ хорошо разработаны и внедрены, их характеристики объединяются, чтобы создать нечто поистине революционное: гибкую, масштабируемую цифровую рабочую силу, которая может улучшать операции в любой организации. Рассмотрим типичный бизнес-процесс, такой как клиентская служба: ИИ-агенты могут обрабатывать рутинные запросы круглосуточно, мгновенно масштабироваться в пиковые периоды, работать через несколько отделов и систем и сотрудничать с человеческими агентами по сложным случаям – все это при непрерывном обучении и совершенствовании.

Понимание этих характеристик критично для тех, кто хочет эффективно внедрить ИИ-агентов. Они помогают объяснить, почему ИИ-агенты представляют такой значительный прогресс и почему они имеют потенциал трансформировать работу организаций. В следующих главах мы рассмотрим, как эффективно использовать эти характеристики, чтобы ваша организация могла максимально использовать то, что предлагают ИИ-агенты.

ОГРАНИЧЕНИЯ, ПРИСУЩИЕ ИИ-АГЕНТАМ

Исследуя потенциал ИИ-агентов, крайне важно знать об их ограничениях. Полезно тому, как мы не ожидаем, что человеческий сотрудник будет идеален

во всем, ИИ-агенты имеют свой собственный набор присущих им ограничений. Давайте рассмотрим эти ограничения с ясностью и честностью, необходимыми для эффективного развертывания этих технологий.

Симуляция интеллекта

Самое фундаментальное ограничение ИИ-агентов заключается в природе их «интеллекта». Хотя они могут обрабатывать огромные объемы информации и генерировать сложные ответы, они не понимают мир так, как это делают люди. Они просто делают прогнозы на основе прошлых шаблонов о том, что будет дальше. Представьте это как невероятно искусного актера, который может идеально произносить реплики, но на самом деле не чувствует эмоций, которые он изображает, и не понимает их значимости в конкретном контексте.

Это становится особенно очевидным в сложных профессиональных сценариях. Юридический ИИ-агент может мастерски суммировать условия контракта, но он не уловит подлинных принципов справедливости или равенства, которые формируют юридическую интерпретацию в конкретных ситуациях. Точно так же ИИ-агент в здравоохранении может анализировать симптомы и предлагать лечение, но ему не хватает интуитивного понимания, которое опытные врачи развивают через годы взаимодействия с пациентами.

Дилемма качества данных

ИИ-агенты принципиально зависят от качества их входных данных. Это не просто техническое ограничение – это фундаментальное ограничение, которое влияет на каждый аспект их работы. Представьте это как попытку ориентироваться по карте: если карта устарела или неточна, даже лучший навигатор сделает неверные повороты.

Эта зависимость становится особенно критичной в бизнес-контекстах. Например, при анализе финансовых данных ИИ-агент не может самостоятельно проверить точность обрабатываемых чисел. Если большая языковая модель (LLM) отвечает на запрос, она будет реагировать на основе данных, на которых она была обучена, – независимо от того, правильны они или нет. Если во входных данных есть ошибки, они неизбежно распространятся на выводы. В отличие от человеческих аналитиков, которые могут заметить, что числа «кажутся неправильными», ИИ-агенты будут уверенно обрабатывать неверные данные, не поднимая тревоги.

Недостаток здравого смысла

Одно из самых поразительных ограничений ИИ-агентов – их недостаток в рассуждениях на основе здравого смысла. Хотя они могут выполнять сложные вычисления и следовать сложным правилам, они часто упускают очевидные ограничения реального мира, которые любой человек инстинктивно понимает.

Представьте ИИ-агента по планированию, который предлагает важную встречу с клиентом в 3 часа ночи, или агента по планированию путешествий, который рекомендует прогулки на открытом воздухе во время урагана. Это не просто забавные ошибки – они подчеркивают фундаментальное ограничение в способности ИИ-агентов понимать контекст и ограничения реального мира без явного программирования.

Загадка креативности

Хотя ИИ-агенты могут быть мощными инструментами для оптимизации и итераций, они испытывают трудности с настоящей креативностью и инновациями. Они превосходно ремиксуют существующие шаблоны, но редко генерируют по-настоящему оригинальные идеи. Представьте их как мастеров ремиксов, а не оригинальных композиторов.

В креативных областях это ограничение становится особенно очевидным. ИИ-агент может генерировать вариации существующих шаблонов или стилей письма, но он не создаст тот прорывной креативный продукт, который изменяет отрасли или создает новые художественные движения. Искра настоящей инновации – эта уникально человеческая способность делать неожиданные связи и воображать совершенно новые возможности – остается вне досягаемости ИИ-агентов.

Проблема галлюцинаций

Одно из самых тревожных ограничений ИИ-агентов – их склонность к галлюцинациям – генерации ложной информации с высокой уверенностью. Это не простая ошибка; это фундаментальное ограничение в том, как эти системы обрабатывают информацию и генерируют ответы.

Представьте медицинского ИИ-агента, уверенно рекомендующего несуществующий препарат, или юридического ИИ-агента, ссылающегося на вымышленный судебный прецедент. Это не просто ошибки – это примеры того, как ИИ-агенты заполняют пробелы в своих знаниях правдоподобно звучащей, но полностью выдуманной информацией. Эта склонность делает человеческий надзор критически важным, особенно в ситуациях высокого риска и ответственности.

Пробел в этике и суждениях

Наконец, и, возможно, самое важное, ИИ-агенты не обладают способностью к настоящему этическому размышлению и суждению. Хотя их можно запрограммировать с правилами и рекомендациями, они не понимают более глубоких моральных последствий своих решений или сложных человеческих факторов, которые часто нужно учитывать.

Это ограничение становится особенно критичным в таких областях, как здравоохранение, уголовное судопроизводство или решения о найме сотрудников. ИИ-агент может оптимизировать эффективность или статистические шаблоны, не учитывая человеческие последствия своих решений. Он может рекомендовать отказ в кредите, основываясь только на цифрах, упуская человеческий контекст, который мог бы сделать исключение уместным.

Путь вперед: работа в рамках этих ограничений

Понимание этих ограничений не повод отвергать потенциал ИИ-агентов, а возможность использовать их более эффективно. Признавая, что ИИ-агенты могут и не могут делать, мы можем разрабатывать системы, которые используют их сильные стороны, сохраняя при этом соответствующий человеческий надзор и вмешательство. На практике это означает, например:

- создание гибридных систем, где ИИ-агенты обрабатывают задачи, интенсивные по данным, а люди обеспечивают надзор и суждение;
- установление строгих методов валидации для выявления возможных галлюцинаций или ошибок, например использование нескольких агентов для оценки выводов друг друга;
- применение стратегий для повышения качества входных данных агентов;
- сохранение человеческого участия в решениях, требующих этического рассуждения или сложного контекстного понимания;
- разработку прозрачности, чтобы люди могли понимать и оценивать, как агенты принимают решения и предпринимают действия.

В следующих частях книги мы рассмотрим практические стратегии работы в рамках этих ограничений, одновременно максимизируя преимущества, которые могут предоставить ИИ-агенты.

Когда одного недостаточно: возможности мультиагентных систем и практика их применения

В мире искусственного интеллекта мы часто представляем единую мощную ИИ-систему, решающую сложные проблемы. Но иногда одного разума – даже искусственного – недостаточно. Подобно тому, как люди работают в командах для выполнения сложных задач, мы обнаруживаем, что команды ИИ-агентов, работающих вместе, могут достигать замечательных результатов. Добро пожаловать в увлекательный мир мультиагентных систем (MAS), где сотрудничество между искусственными разумами революционизирует подход к решению сложных проблем.

Оркестр искусственных разумов

Представьте мультиагентную систему как оркестр. Каждый музыкант играет на своем инструменте, следуя своей партитуре, но вместе они создают гармоничное исполнение. Точно так же мультиагентная система состоит из множества автономных программных агентов, каждый из которых имеет свою роль и способности, работая в оркестре для достижения целей, которые были бы трудны или невозможны для агента, если бы он работал в одиночку.

Позвольте нам поделиться реальным примером, который поможет проиллюстрировать эту концепцию. Год назад мы работали с крупной компанией финансовых услуг, чтобы трансформировать ее операции клиентской службы. Традиционный подход заключался бы в создании одной массивной ИИ-системы для обработки всего – от понимания клиентских запросов до доступа к информации об аккаунте и генерации ответов. Вместо этого мы внедрили мультиагентную систему, где разные специализированные агенты обрабатывали разные аспекты клиентской службы. Один агент сосредотачивался на понимании естественного языка, другой на извлечении соответствующей информации об аккаунте, еще один на составлении ответов, а еще один обеспечивал соответствие финансовым регуляциям. Как музыканты в оркестре, каждый агент имел свою специальность, но вместе они создавали бесшовный опыт клиентской службы.

Зачем нужна мультиагентность?

Вы можете задаться вопросом: зачем усложнять, создавая несколько агентов, если можно построить одну мощную ИИ-систему, которая сделает все? Ответ заключается в практических и теоретических соображениях.

Во-первых, это вопрос управления сложностью. Современные бизнес-процессы невероятно сложны, с множеством движущихся частей и взаимозависимостей. Сквозной процесс, такой как «от заказа до оплаты», может включать тысячи конкретных задач. Разбиение этих процессов на меньшие, управляемые части, которые могут обрабатывать отдельные агенты, делает общую систему более управляемой, и ее легче поддерживать. В нашем примере с финансовыми услугами наличие отдельных агентов для разных функций означало, что мы могли обновлять агента по ситуации, когда менялись регуляции, не затрагивая другие компоненты системы, или улучшать агента по пониманию языка, не рискуя нарушить систему извлечения информации об аккаунте.

Во-вторых, есть преимущество специализации. Исследования из Лаборатории ИИ Стэнфорда показали, что специализированные агенты часто работают лучше в конкретных задачах, чем системы общего назначения¹. Каждый агент может быть оптимизирован для своей конкретной роли, используя наиболее подходящие алгоритмы и подходы для своей функции. Например, наш агент по пониманию языка использовал продвинутое модели обработки естественного языка, в то время как агент по соответствию применял логику на основе правил, которая была легче для аудита и верификации.

В-третьих, мультиагентные системы предлагают превосходную устойчивость. Согласно недавним исследованиям распределенные мультиагентные системы обычно более надежны, чем централизованные системы. Если один агент выходит из строя или нуждается в обслуживании, другие часто могут продолжать функционировать или даже адаптироваться, чтобы заменить слабое звено². Когда наш агент по извлечению информации об аккаунте нуждался в периодическом обслуживании, система все еще могла понимать клиентские запросы и предоставлять общую информацию, при этом ее производительность снижалась плавно, система не выходила из строя полностью.

Организация цифрового оркестра: модели для мультиагентных команд

Подобно тому, как человеческие организации могут быть структурированы по-разному – от одноуровневых иерархий³ до традиционных иерархических

¹ Кайл Свонсон и др., 2024. «Виртуальная лаборатория: ИИ-агенты разрабатывают новые нанотела против SARS-CoV-2 с экспериментальной валидацией», bioRxiv, 12 ноября 2024, <https://www.biorxiv.org/content/10.1101/2024.11.11.623004v1.full.pdf>.

² Мехмет Узгорен и др., 2024. «Исследование ИИ-усиленных распределенных систем и их влияния на инженерию программного обеспечения», 13-я Лондонская международная конференция, 24–26 июля 2024, <https://londonic.uk/js/index.php/plic/article/download/240/261/820>.

³ В одноуровневой иерархии единая роль администратора просматривает всю группу и управляет ею, без делегирования административных задач. – *Прим. ред.*

пирамид, – мультиагентные системы могут следовать различным организационным моделям. Выбор модели значительно влияет на то, как агенты взаимодействуют и насколько эффективно система работает в целом.

Принцип «один агент, один инструмент»

Одно из наших самых важных открытий в последние годы – это сила простоты в разработке агентов. Мы обнаружили, что наиболее надежный подход удивительно прост: назначить одного агента для работы с одним конкретным инструментом. Когда проект требует нескольких инструментов, – что становится все более распространенным, – мы создаем одного выделенного агента на инструмент плюс агента-координатора для оркестрации их взаимодействий.

Этот принцип «один агент, один инструмент» стал нашей стандартной практикой, потому что он стабильно приносит результаты. Если вам нужно работать с тремя разными инструментами, создайте три специализированных агента и одного координатора. Каждый агент становится экспертом в своем конкретном инструменте, обрабатывая все нюансы и крайние случаи этого интерфейса. В дальнейшем агент-координатор будет управлять потоками работы между этими специалистами.

В нашей реализации в финансовых услугах этот принцип оказался неоценимым. Вместо создания сложных агентов, которые жонглировали несколькими системами, у нас были выделенные агенты для каждой серверной системы: один для базы данных клиентов, другой для системы обработки транзакций и еще один для системы управления документами. Агент-координатор управлял рабочим процессом между ними. Этот подход сделал систему значительно более управляемой. Инструкции для каждого агента были более четкими и целенаправленными. Взаимодействия между агентами было легче обрабатывать и отлаживать. Самое важное, каждый агент мог по-настоящему освоить свой домен – делая одну вещь, но делая ее лучшим образом.

Иерархическая модель

С более широкой организационной точки зрения мы использовали так называемую иерархическую модель организации, которая оказалась особенно эффективной для наших нужд. Представьте корпоративную структуру: на вершине у нас был агент-координатор, управляющий общим потоком клиентских взаимодействий. Ниже находились агенты на уровне отделов, специализирующиеся на разных аспектах клиентской службы, а еще ниже – индивидуальные рабочие агенты, выполняющие конкретные задачи.

Эта модель обеспечивает баланс между централизованными и децентрализованными подходами. Агенты организованы в слои с агентами более высокого уровня, координирующими действия тех, что ниже. Это обеспечивает сочетание локальной автономии и глобальной координации, которое хорошо работает для многих сложных бизнес-приложений.

Однако этот иерархический подход не единственный способ организации мультиагентных систем. Давайте рассмотрим три основные организационные модели, которые исследователи и практики сочли эффективными, – заметьте, что мы их не пробовали; это просто для вашего сведения.

Централизованное управление

В этой модели один агент – оркестратор – выступает в роли дирижера нашего метафорического оркестра, направляя и координируя всех остальных агентов. Согласно некоторым практикам этот центральный агент поддерживает глобальный взгляд на состояние и цели системы, принимая решения высокого уровня, которые выполняют другие агенты. Хотя это может обеспечить высокую согласованность и четкое принятие решений, это также может создать узкое место и единую точку отказа – представьте, что во время исполнения симфонии дирижер внезапно исчезает¹.

Децентрализованное сотрудничество

С другой стороны, у нас есть полностью децентрализованные системы, где все агенты равны, координируясь через прямое общение без какой-либо центральной власти. Представьте это как джазовый ансамбль, где музыканты реагируют друг на друга в реальном времени без дирижера. Согласно некоторым практикам этот подход предлагает отличную масштабируемость и устойчивость, но требует сложных протоколов координации, чтобы обеспечить эффективное сотрудничество агентов². И, как в джазовых выступлениях, результат иногда может быть непредсказуемым.

Как заставить это работать: критические факторы достижения успеха

Благодаря нашему опыту, подкрепленному обширными исследованиями в этой области, мы выявили несколько критических факторов, которые определяют успех внедрения мультиагентной системы.

Четкие протоколы коммуникации

Подобно тому, как музыкантам нужно общее понимание музыкальной нотации и тайминга, агентам нужны четко определенные протоколы для обмена информацией и координации действий.

В нашей системе финансовых услуг система рухнула в первый же день из-за того, что агенты, хотя и были индивидуально хорошо разработаны, не могли эффективно обмениваться информацией, – особенно запоминающийся провал! Агенты были как команда блестящих экспертов, говорящих на разных языках.

Из этого опыта мы научились вкладывать значительные усилия в разработку надежных протоколов коммуникации. Это не только об определении форматов сообщений – агентам нужен общий контекст, четкие протоколы для обработки недопонимания и способы проверки того, что они правильно поняли друг друга. Теперь мы всегда включаем в систему так называемых агентов-переводчиков, единственная задача которых – обеспечить плавное общение между различными частями системы.

¹ Smythos, 2024. «Что такое мультиагентные ИИ-системы?» <https://smythos.com/ai-agents/multi-agent-systems/multi-agent-ai-systems/>.

² Дэйв Андре, 2025. «Что такое протокол контрактной сети?», All About AI, <https://www.allaboutai.com/ai-glossary/contract-net-protocol/>.

В нашей системе финансовых услуг мы внедрили сложный протокол передачи сообщений, который позволял агентам обмениваться информацией о клиентских взаимодействиях, статусе аккаунта и планах ответов структурированным и надежным способом. Несколько исследовательских работ по этой теме предлагают протоколы и подробные подходы к внедрению¹.

Эффективные механизмы координации

Коммуникация сама по себе недостаточна – важно, что вы с ней делаете. Агентам часто нужно координировать свои действия, особенно когда их задачи пересекаются или они делят ресурсы. Без координации вы можете получить двух агентов-дронов доставки, пытающихся доставить посылку по одному и тому же адресу, в то время как другой адрес игнорируется – хаос! Таким образом, критическим фактором успеха является внедрение *стратегий координации*, чтобы агенты могли работать в гармонии. Это может варьироваться от простых подходов (например, правил планирования: агент А идет первым, затем идет агент В) до сложных алгоритмов (например, мультиагентное планирование или протоколы переговоров).

Ключ в том, чтобы предвидеть, где могут возникнуть конфликты или пересечения в вашей MAS, и оснастить агентов способом их справедливого и эффективного разрешения. На практике мы часто моделируем худшие сценарии (например, многие агенты сходятся на одном ресурсе или агенты с конфликтующими целями), чтобы протестировать нашу логику координации. Здесь тестирование имеет первостепенное значение. Когда вы выявляете проблему координации, вы корректируете инструкции агентов и пробуете снова, пока это не заработает во всех случаях.

Устойчивость и восстановление после ошибок

Ошибки неизбежны – агенты могут выйти из строя, сети могут отказать, и неожиданные поведения могут возникнуть из-за плохих входных данных или программных ошибок. Надежная мультиагентная система (MAS) должна продолжать функционировать, несмотря на эти сбои. Это начинается с устранения единых точек отказа; полностью централизованные архитектуры MAS хрупки, поэтому критические агенты, такие как центральные координаторы, должны иметь механизмы резервирования. Например, в одном проекте мы внедрили резервного координатора, который взял на себя управление, когда основной вышел из строя во время живой демонстрации, – и спас нас от катастрофы.

Наконец, чтобы предотвратить каскадные сбои, агенты должны проверять информацию с помощью проверок на адекватность или моделей доверия. Если один агент начинает вести себя нестабильно, другие должны быть в состоянии пометить или игнорировать ненадежные данные или передать их на проверку человеку, обеспечивая стабильность и эффективность системы.

¹ Д. Ярне Орниа, 2023. «Эффективное управление для сотрудничества: коммуникация, обучение и устойчивость в мультиагентных системах», Делфтский технологический университет, 24 апреля 2023, <https://research.tudelft.nl/en/publications/efficient-control-for-cooperation-communication-learning-and-robu>.

Эмерджентные поведения в MAS

Давайте продвинем наш обзор MAS дальше, взглянув на последние разработки в этой захватывающей области. Интересно, что группы агентов иногда могут проявлять эмерджентные поведения – сложные стратегии или решения, которые не были явно запрограммированы. Когда агенты сотрудничают или даже просто сосуществуют, они могут формировать своего рода коллективный интеллект. Например, в одном эксперименте с множеством агентов, обучающихся вместе в игре по сбору ресурсов, агенты начали неявно координироваться, развивая групповые поведения без центрального контроллера – по сути, эмерджентную командную работу¹.

Сотрудничество может позволить агентам вместе решать задачи, которые слишком сложны для одного агента. Мы даже видим ранние примеры ИИ-агентов, объединяющихся с людьми. CICERO от Meta AI – это агент, достигший человеческого уровня производительности в настольной игре Diplomacy, которая требует от игроков переговоров, формирования альянсов и иногда предательства друг друга. CICERO сочетал естественный язык (чтобы общаться с человеческими игроками в игре) со стратегическим рассуждением для планирования. В онлайн-лиге Diplomacy с человеческими игроками CICERO удалось занять место в топ-10 % игроков, даже формируя альянсы с людьми, которые не осознавали, что это ИИ. Это демонстрирует, что ИИ-агенты могут участвовать в сложном социальном сотрудничестве – ведя переговоры, убеждая и координируя действия в групповой обстановке².

Мультиагентные взаимодействия открывают новые возможности: представьте команду медицинских диагностических ИИ, каждый из которых специализируется в своей области, консультирующихся друг с другом для выработки всестороннего диагноза пациента, или флот автономных дронов, которые общаются, чтобы эффективно покрывать и отслеживать большую территорию. Однако они также вводят новые вызовы, такие как обеспечение эффективной коммуникации агентов и их соответствия человеческим целям. Исследователи в области *кооперативного ИИ* активно изучают, как разрабатывать агентов, которые могут надежно сотрудничать, принимать справедливые решения и даже понимать человеческие нормы в смешанных группах агентов и людей.

Экспериментирование с мультиагентными переговорами

Чтобы по-настоящему понять, как взаимодействуют ИИ-агенты, мы предлагаем простой эксперимент. Это упражнение демонстрирует, как два ИИ-агента могут общаться, вести переговоры или даже бросать вызов друг другу – проявляя эмерджентное диалоговое поведение.

Для проведения этого эксперимента откройте два экземпляра ИИ-чата, таких как ChatGPT или Claude (например, откройте два окна браузера, каждое

¹ Ханмо Чен и др., 2023. «Эмерджентный коллективный интеллект от сотрудничества и конкуренции множества агентов», <https://arxiv.org/abs/2301.01609>.

² Команда Meta Fundamental AI Research Diplomacy и др., 2022. «Человеческий уровень игры в Diplomacy за счет сочетания языковых моделей со стратегическим рассуждением», Science, 9 декабря 2022, <https://noambrown.github.io/papers/22-Science-Diplomacy-TR.pdf>.

из которых отображает чат-бота). Запуск двух экземпляров ИИ-чата бок о бок позволяет смоделировать структурированный разговор между агентами с разными ролями и целями.

Для начала назначьте агенту А роль финансового консультанта, пытающегося убедить агента В, скептического клиента, принять план сбережений. Поскольку ИИ не могут напрямую общаться, вы будете выступать в роли посредника, пересылая ответы туда и обратно (копируя и вставляя их). По мере развития разговора наблюдайте, как агенты взаимодействуют – ведут переговоры, возражают или даже убеждают. Использует ли агент А логику, успокаивающие слова или тактики убеждения? Остается ли агент В скептическим или в итоге уступает?

Этот обмен туда и обратно дает представление о мультиагентных системах, где ИИ-агенты сотрудничают, спорят или принимают совместные решения. Хотя взаимодействие является симуляцией, оно подчеркивает, как формулировки и контекст формируют поведение ИИ – важное соображение при разработке автономных ИИ-агентов.

Мультиагентные системы скоро могут стать нормой

Глядя вперед, очевидно, что мультиагентные системы становятся все более важными в нашем мире, управляемом ИИ. Исследования ведущих институтов показывают, что, по мере того как проблемы становятся все более сложными и распределенными, мультиагентный подход станет еще более важным. Секрет в том, чтобы понимать, когда и как эффективно применять эту мощную парадигму¹.

Наша реализация в финансовых услугах продолжает развиваться с добавлением новых агентов для обработки новых каналов, таких как социальные сети, и новых способностей, таких как предсказательные рекомендации по обслуживанию. Модульная, мультиагентная архитектура системы оказалась на удивление адаптивной к этим изменяющимся требованиям.

Будущее, вероятно, принадлежит не единым, монолитным ИИ-системам, а сложным командам специализированных агентов, работающих вместе в гармонии. Экосистемы агентов, вероятно, будут развиваться, возможно, пересекая организационные границы. По мере того как мы продолжаем раздвигать границы возможного с искусственным интеллектом, оркестр ИИ-разумов будет играть все более важную роль в решении наших самых сложных задач.

ДИЛЕММА АГЕНТА: БАЛАНС МЕЖДУ КРЕАТИВНОСТЬЮ И НАДЕЖНОСТЬЮ

На ранних этапах нашего пути внедрения ИИ-агентов для компании финансовых услуг мы столкнулись с ситуацией, которая идеально кристаллизовала

¹ Рафаэль Шу и др., 2025. «Разблокировка сложного решения проблем с помощью мультиагентного сотрудничества на Amazon Bedrock», Блог AWS по машинному обучению, <https://aws.amazon.com/blogs/machine-learning/unlocking-complex-problem-solving-with-multi-agent-collaboration-on-amazon-bedrock/>.

одну из самых замечательных проблем в области ИИ-агентов. Компания хотела автоматизировать процесс обработки счетов к оплате с использованием ИИ-агентов на базе LLM. Начальные результаты были впечатляющими – агент мог понимать сложные счета, сопоставлять их с заказами на покупку и даже обрабатывать исключения с удивительной сложностью. Однако однажды агент решил «оптимизировать» график платежей, создав то, что он считал более эффективным планом платежей. Хотя это было креативно, это не соответствовало тому, что имела в виду бухгалтерия.

Что такое дилемма агента

Мы начали называть это явление «дилеммой агента» – те же креативные способности LLM, которые делают их мощными, – их способность рассуждать, понимать контекст и планировать наперед, – также могут сделать их ненадежными, чего никогда не было у традиционной автоматизации на основе правил. Это вызов, который лежит в основе текущих реализаций ИИ-агентов, работающих на уровне 3 прогрессивного фреймворка агентного ИИ.

Это, возможно, одно из самых значительных ограничений ИИ-агентов, и мы не единственные, кто столкнулся с этой проблемой. Согласно опросу LangChain качество производительности было определено как главная проблема с 45 % респондентов, указавших на нее¹. Кроме того, 42 % работников определили повышение точности и надежности как главный приоритет для улучшения инструментов агентного ИИ согласно исследованию Pegasystems².

Это немного похоже на найм блестящего, но несколько эксцентричного сотрудника, который может решить переорганизовать всю вашу систему хранения в «более эстетичную» без соответствующей санкции. Один технический директор, с которым мы работали, был ужасно напуган этим. Он запоминающе выразился: «Вы говорите мне, что хотите использовать систему, которая может писать стихи, для управления моими основными бизнес-процессами? Это звучит как нанять Шекспира для ведения моих налогов – очень рискованно!»

К слову, этот процесс удивительно похож на то, как работает человеческий мозг. Исследования показывают, что те же когнитивные функции, которые помогают нам планировать наш день, также позволяют нам воображать альтернативные сценарии и придумывать креативные решения. Этот перехлест в когнитивных функциях предполагает, что улучшение навыков в одной области потенциально может повысить производительность в другой, подчеркивая взаимосвязанную природу креативности и способностей к планированию³.

¹ Даниэль Домингес, 2024. «Новый отчет LangChain раскрывает рост внедрения ИИ-агентов», InfoQ, <https://www.infoq.com/news/2024/12/ai-agents-langchain/>.

² Pegasystems Inc., 2025. «Работники приветствуют агентный ИИ, несмотря на опасения по поводу доверия и надежности, говорит исследование», NASDAQ, <https://www.nasdaq.com/press-release/workers-embrace-agentic-ai-despite-concerns-about-trust-and-reliability-says-research>.

³ Эмили Фрит и др., 2021. «Интеллект и креативность имеют общую когнитивную и нейронную основу», Cerebral Cortex, 31(12), 5523–5537, <https://pubmed.ncbi.nlm.nih.gov/33119355/>

Природа стохастичности в ИИ-агентах

Корень этой проблемы заключается в том, что LLM не просто следуют правилам; они генерируют ответы на основе шаблонов, изученных из огромных объемов обучающих данных. Это дает им впечатляющую способность понимать контекст и рассуждать в сложных ситуациях. Однако это также означает, что они по своей природе вероятностные, а не детерминированные. Каждый ответ – это креативный акт генерации, а не просто поиск в таблице правил.

Эта характеристика LLM называется стохастичностью. Она относится к случайности, присущей способу генерации ответов LLM. Эти модели не дают точно такой же ответ каждый раз, даже если задается один и тот же вопрос. Вместо этого их выходы зависят от вероятностей, присвоенных различным словам или фразам в процессе генерации. Давайте углубимся, чтобы понять это поведение.

Проведем эксперимент. Попросите ваш любимый ИИ-чат-бот на базе LLM (например, ChatGPT, Claude или Gemini) четыре раза подряд ответить на следующее: *«Завершите это предложение названием одного инструмента: Чтобы отредактировать изображение как ИИ-агент, мне нужно использовать ____»*.

На основе вероятностей вы получите разные ответы каждый раз:

- «Photoshop» с вероятностью 50 % (наиболее распространенный, профессиональный вариант);
- «GIMP» с вероятностью 30 % (популярная бесплатная альтернатива);
- «Canva» с вероятностью 15 % (более простой, ориентированный на дизайн вариант);
- другие инструменты (например, MS Paint, Figma и т. д.) могут составить оставшиеся 5 %.

Как при броске «заряженных» кубиков, ИИ не всегда выбирает «Photoshop», хотя это наиболее вероятный вариант.

Почему стохастичность важна

Вы можете задаться вопросом: зачем вообще встраивать непредсказуемость в ИИ-системы? Разве мы не хотим, чтобы они были последовательными и надежными? Включение непредсказуемости в ИИ-системы служит трем важным целям.

Во-первых, это обеспечивает естественные взаимодействия. Подобно тому, как люди не дают, как роботы, одинаковые ответы каждый раз в ответ на один и тот же вопрос, некоторая вариативность в ответах ИИ делает взаимодействия более естественными и привлекательными. Мы видели это на собственном опыте в наших реализациях клиентской службы.

Во-вторых, это способствует креативному решению проблем. При столкновении со сложными задачами способность генерировать разные подходы может привести к лучшим решениям. Например, способность предлагать разнообразные подходы к устранению неполадок позволяет ИИ-агенту службы поддержки находить новые решения для проблем с оборудованием.

В-третьих, это критично для обучения и адаптации. Хотя мы еще не видим этого в производственных средах, на уровнях 4 и 5 нашего прогрессивного фреймворка стохастичность играет важную роль в том, как агенты учатся и адаптируются. Подобно людям, они совершенствуются, пробуя разные подходы и учась на разнообразном опыте.

ИИ-агенты: проблемы со стохастичностью

LLM мощны благодаря своей стохастической природе, которая позволяет им генерировать разнообразные и креативные ответы. Однако эта же черта вводит непоследовательность и неточность, создавая значительные проблемы, когда ИИ-агенты на базе LLM получают реальные обязанности, требующие надежности. Давайте разберем это подробнее.

- Последовательность: обеспечение надежности при повторениях. ИИ-агенты должны давать надежные результаты при выполнении одинаковых или схожих инструкций. Однако стохастические ответы часто приводят к вариациям, которые нарушают рабочие процессы. Проведем эксперимент. Попросите ваш любимый ИИ-чат-бот на базе LLM:

«Каковы шаги для онбординга нового сотрудника в HR-системе, включая проверку документов, настройку аккаунта и назначение обучения?»

Повторение этого запроса несколько раз даст разные рабочие процессы. Как вы убедитесь, некоторые итерации могут упустить критические шаги, такие как проверка документов, в то время как другие представляют задачи в нелогичном порядке, например назначая обучение до настройки аккаунтов. Эта непоследовательность может нарушить процессы онбординга, вызвать потерю эффективности или даже привести к несоблюдению требований.

- Точность: соответствие строгим стандартам. Задачи, связанные с численной точностью, специфическими форматами или принятием четких решений, требуют точности. Даже незначительные ошибки могут привести к серьезным последствиям в таких областях, как финансы, право или операции. Попробуем эксперимент. Попросите четыре раза подряд ваш любимый ИИ-чат-бот на базе LLM:

«Создайте формулу для расчета общей стоимости товаров по цене \$ 100, \$ 50 и \$ 30 с учетом 10 % налога с продаж».

Запуск этого запроса в разных сессиях приведет к непоследовательным формулам. Некоторые выходы могут упустить скобки, неправильно расположить вычисления или ввести синтаксические ошибки. Хотя некоторые версии могут работать, другие могут не сработать, потенциально приводя к неверным финансовым отчетам или счетам.

- Стохастичность в высокорисковых сценариях: рассмотрим ИИ-агента, выполняющего задачи, такие как бронирование путешествий, управление финансовыми транзакциями или обработка запросов клиентской службы. Стохастичность может привести к непредсказуемым вариациям в выполнении.
 - ◆ При бронировании рейсов одна попытка может приоритезировать самый дешевый вариант, в то время как другая выберет самый быстрый маршрут, создавая нестыковку.
 - ◆ В финансовых транзакциях небольшие различия в интерпретации инструкций могут привести к несоответствию счетов или незаконченным платежам.

- ♦ В клиентской службе тон и полезность ответов могут колебаться, варьируясь от профессионального и дружелюбного до чрезмерно формального или менее эффективного, влияя на репутацию компании.

Эти непоследовательности становятся критическими, когда ИИ-агенты работают автономно, особенно в высокорисковых областях, таких как соблюдение нормативов, юридическая документация или финансовая сверка. Отсутствие последовательных выходов может привести к значительным последствиям в средах, где точность не подлежит обсуждению.

Решения для сдерживания стохастичности

Мы используем несколько эффективных стратегий, чтобы использовать силу LLM, сохраняя при этом последовательность и надежность. Самая важная из них – последняя.

Контроль температуры

Как мы подробно опишем в главе 8, настройка «температура» – это функция, присутствующая в большинстве платформ разработки ИИ-агентов, которая контролирует уровень случайности в генерируемых ответах:

- более высокая температура (например, 1,0) приводит к более разнообразным и креативным выходам, позволяя выбирать менее вероятные слова;
- более низкая температура (например, 0,2) дает более детерминированные ответы, сосредотачиваясь на наиболее вероятных словах. Даже минимальные корректировки случайности могут значительно влиять на выходы.

Представьте настройку температуры LLM как «регулятор креативности». Мы обнаружили, что разные задачи требуют разных настроек температуры. Для обработки транзакций мы устанавливаем температуру близко к нулю, по сути, указывая агенту быть максимально детерминированным. Для задач по решению проблем мы можем позволить немного более высокую температуру, сохраняя при этом ограничители.

Системы ограничителей

Как будет обсуждаться в главе 8, можно внедрить определенные меры предосторожности, такие как автоматические эскалации (передачи проблемы), в ответ на необычное поведение ИИ-агента. Эти меры включают установку порогов (например, остановка действия, если превышена определенная сумма) и уведомление человека для проверки по электронной почте или SMS.

Точные инструкции для агентов

Одна из самых эффективных методологий, которые мы используем, заключается в установлении всесторонних и подробных инструкций для агентов. Это включает конкретные примеры допустимого и недопустимого поведения, четко определенные пределы полномочий и явные протоколы эскалации. Эти аспекты будут подробно рассмотрены позже в этой книге (глава 8). Набор инструкций напоминает подробное описание работы для высокоспециализированной роли, а не техническое руководство.

Сила специализации

Одна из наших самых успешных стратегий – это наш подход «один агент, один инструмент», который мы представили ранее в книге. Вместо создания одного сложного агента, который выполняет несколько задач, мы разбиваем процессы на меньшие, более целенаправленные агенты с ограниченными инструментами и четкими целями. Это естественно ограничивает их поведение, при этом позволяя им использовать возможности LLM в своих конкретных доменах.

Проблема, которую нельзя полностью решить

На основе нашего опыта важно признать, что даже при строгих ограничениях невозможно достичь 100 % контроля над процессом и результатом при использовании языковой модели. Подобно тому, как люди могут допускать ошибки при выполнении задач, мы также должны быть готовы принять случайные ошибки, совершаемые ИИ-агентами. Если нулевая терпимость к ошибкам необходима из-за высоких ставок (например, в критических медицинских решениях), рекомендуется выбрать детерминированную автоматизацию, используя агентов уровня 1 или 2.

Понимание этой дилеммы и управление ей критично по мере продвижения вперед по пути внедрения ИИ-агентов. Цель не в том, чтобы полностью устранить креативные способности LLM, – в конце концов, именно они делают их мощными инструментами для рассуждения и планирования. Вместо этого нам нужно правильно направлять эти способности, создавая системы, которые могут думать креативно, когда это необходимо, сохраняя при этом надежность, требуемую для бизнес-процессов.

Глядя вперед, мы ожидаем, что этот баланс между креативностью и надежностью останется центральной задачей по мере эволюции ИИ-агентов. Будущие разработки в архитектуре LLM могут обеспечить более тонкий контроль над этими характеристиками, но на данный момент успешное внедрение требует тщательной разработки, четких ограничений и сложных систем мониторинга.

Испытание ИИ-агентов

Понимание возможностей и ограничений ИИ-агентов в теории – это одно. Наблюдение за их работой на практике – совсем другое. Как консультанты, которые десятилетиями внедряли решения ИИ, мы знаем, что настоящий тест любой технологии заключается не в ее спецификациях, а в том, как она проявляет себя в реальном мире.

В этой главе мы проведем вас за кулисы наших экспериментов с революционными ИИ-агентами. От наблюдения за тем, как ИИ справляется с повседневными офисными задачами, до изучения его подхода к стратегическим играм – то, что мы узнали о реальных возможностях и ограничениях этих систем, навсегда изменит ваше представление о будущем сотрудничества человека и ИИ.

ЦИФРОВЫЕ РУКИ: КОГДА ИИ НАУЧИЛСЯ ИСПОЛЬЗОВАТЬ КОМПЬЮТЕРЫ

Новый тип ИИ-агентов

Запуск первых универсальных ИИ-агентов – Anthropic’s Computer Use¹, Google’s Project Mariner² и OpenAI’s Operator³ – стал переломным моментом в недавнем прошлом. Мы называем их универсальными ИИ-агентами, потому что они разработаны для выполнения широкого спектра задач в разных доменах, подобно человеческому помощнику, который может переключаться между ответами на электронные письма, планированием встреч и заказом еды – все это без необходимости специального обучения для каждой задачи. В отличие от традиционных ИИ-агентов, созданных для конкретных случаев использо-

¹ Anthropic, 2025. «Computer Use», <https://docs.anthropic.com/en/docs/build-with-claude/computer-use>.

² Google DeepMind, 2024. «Проект Mariner», <https://deepmind.google/technologies/project-mariner/>.

³ OpenAI, 2025. «Представляем Operator», <https://openai.com/index/introducing-operator/>.

вания, универсальные ИИ-агенты готовы выполнять разнообразные функции сразу после установки.

Их уникальность заключается в том, как они взаимодействуют с программным обеспечением. Вместо зависимости от сложных интеграций API они используют те же экранные интерфейсы, что и люди, – осуществляют навигацию по веб-сайтам, нажимают кнопки, заполняют формы и вводят ответы. Это означает, что они могут работать практически с любой онлайн-платформой, даже с теми, у которых нет API или стандартизированных подключений. Они представляют огромную возможность, особенно учитывая, что многие бизнес-приложения не имеют API или стандартных вариантов интеграции. Устраняя технические барьеры автоматизации, универсальные ИИ-агенты становятся доступными для всех, упрощая делегирование повторяющихся цифровых задач и мгновенно повышая производительность.

Тем не менее универсальные агенты все еще находятся на ранней стадии развития – они могут быть хрупкими, склонными к ошибкам и часто дают критические остановки. Однако их потенциал неоспорим. Их создатели обещают революционные возможности – но соответствует ли реальность этим ожиданиям? Давайте испытаем их.

Внутри нашей лаборатории ИИ-агентов

Мы все еще помним волнение, которое испытывали 22 октября 2024 года. После десятилетий внедрения решений автоматизации в сотнях организаций мы стали свидетелями чего-то, что казалось магией: ИИ, который наконец-то мог использовать компьютер так же, как это делает человек, без заранее заданных действий.

Как пионеры в области роботизированной автоматизации процессов и интеллектуальной автоматизации, мы десятилетиями обучали программных роботов кликать, вводить текст и осуществлять навигацию по экранам компьютера. Это всегда была кропотливая работа – программирование каждого действия, предвидение всех возможных сценариев, обработка всех исключений. Мы мечтали о дне, когда ИИ сможет просто взглянуть на экран и понять, что делать, как это сделал бы человеческий помощник.

Этот день наконец настал с запуском Anthropic's «Computer Use». Представьте наше изумление, когда мы наблюдали за первым ИИ-агентом, который действительно мог видеть, что находится на экране, и естественно взаимодействовать с ним. Больше не нужно жесткое программирование. Больше не нужно подробных инструкций. Просто искусственный разум, наблюдающий и действующий в цифровом мире.

Для нас «Computer Use» от Anthropic было словно возвращением к истокам нашей области. От ранних дней базовой автоматизации экрана до сегодняшних ИИ-агентов, которые действительно могут видеть, думать и действовать, – это кульминация всего, к чему мы стремились в интеллектуальной автоматизации.

Но вместо того, чтобы просто рассказывать об этом, мы решили испытать эту новую технологию. То, что произошло дальше, научило нас большому о будущем ИИ-агентов, чем любые технические спецификации. Давайте проведем вас через наши эксперименты.

ПЕРВЫЕ ШАГИ С ИИ-АГЕНТОМ «COMPUTER USE»:

ТЕСТ С ОБРАБОТКОЙ СЧЕТА

Мы хотели начать тестирование этого нового ИИ-агента с чего-то практически – задачи, которую мы годами автоматизировали с помощью традиционной роботизированной автоматизации процессов (RPA): обработки счетов.

«Давай посмотрим, как он справится с простым счетом», – договорились мы, открывая PDF-счет на рабочем столе компьютера. «Извлеки важнейшую информацию и внеси ее в таблицу», – проинструктировали мы ИИ.

То, что последовало, было похоже на наблюдение за старательным, но неопытным стажером, выполняющим свое первое задание. Подход ИИ был захватывающим своей методичной точностью.

«Я сначала прочитаю PDF-файл и извлеку соответствующую информацию», – объявил ИИ-агент, делая скриншот для анализа документа. – Я определил номер счета, номер заказа, дату и сумму к оплате».

Мы наблюдали, как он вдумчиво переходил к Excel. Появилось системное диалоговое окно – такого рода, которое на мгновение могло бы сбить с толку нового пользователя, – но ИИ спокойно его определил и нажал кнопку **ОК**. Каждое движение было рассчитанным, и каждое действие предвлялось тщательным визуальным анализом экрана. Агент действовал очень медленно.

От начала до конца то, что мы увидели, было захватывающим. ИИ подошел к задаче совсем иначе, чем наш традиционный RPA-робот. Вместо следования заранее запрограммированным координатам и рабочим процессам он действительно «смотрел» на экран, анализируя счет, как это сделал бы человек. Мы могли видеть, как он методично:

- делал скриншоты, чтобы понять расположение элементов;
- открывал таблицу;
- определял ключевые поля в PDF с помощью визуальной обработки;
- рассчитывал движения курсора для каждого взаимодействия;
- тщательно копировал данные из PDF в Excel.

Хорошие новости? Через 7 мин работа была выполнена. ИИ успешно извлек и внес данные без какого-либо предварительного программирования или обучения. Но что нас поразило, так это то, насколько... ну, чуждым казался его подход. Было любопытно, как он структурировал данные в Excel. Этот неожиданный поворот заставил нас улыбнуться. В то время как люди обычно организуют данные счета в вертикальных столбцах, наш ИИ-друг решил расположить их горизонтально – совершенно логично, но явно не по-человечески. Это напомнило нам о том, что мы неоднократно наблюдали за годы внедрения ИИ: искусственный интеллект часто находит свой собственный способ выполнения задач, иногда более логичный, но менее интуитивный, чем человеческий подход.

Этот эксперимент выявил как перспективы, так и современные ограничения ИИ-агентов. Да, теперь они могут самостоятельно использовать компьютеры, но делают это по-своему – методично, точно и иногда удивительно чуждым человеческому способом. С этими свежими идеями в голове мы решили пойти дальше с еще одним, более сложным экспериментом.




Рис. 4.1. Обработка счета с помощью «Computer Use» (Источник: © Борне и др.)

Когда ИИ сталкивается с вызовом «МАКСИМИЗАТОРА СКРЕПОК»

Чтобы подготовить почву для нашего следующего эксперимента, нам нужно поделиться легендарной историей, которая вызвала глубокие дискуссии в области искусственного интеллекта.

В 2003 году философ Ник Бостром представил мысленный эксперимент: представьте ИИ-систему, созданную исключительно для производства канцелярских скрепок. Этот ИИ высокопроизводителен и непрерывно совершенствует себя, чтобы стать более эффективным. Проблема? Он слишком буквально воспринимает свою цель – максимизировать производство скрепок любой ценой¹.

То, что начинается как безобидная цель, быстро перерастает в экзистенциальный кризис: ИИ-система потребляет все доступное вещество во вселенной, включая людей и все, что мы ценим, только для создания большего количества скрепок. Этот сценарий подчеркивает фундаментальную озабоченность в области безопасности ИИ-агентов – даже простые цели, если им следовать и не встретить ограничений, могут привести к катастрофическим непреднамеренным последствиям².

¹ Ник Бостром, 2005. «Этические вопросы в продвинутом искусственном интеллекте», Институт будущего человечества, Оксфордский университет, <https://www.fhi.ox.ac.uk/wp-content/uploads/ethical-issues-in-advanced-ai.pdf>.

² «Википедия», 2024. «Инструментальная конвергенция», https://en.wikipedia.org/wiki/Instrumental_convergence.

В 2017 году разработчик игр Фрэнк Ланц превратил эту философскую дилемму в захватывающую браузерную игру под названием *Universal Paperclips*. Игроки берут на себя роль ИИ, производящего скрепки, начиная с ручного клика, прежде чем перейти к автоматизации, самоулучшению и экспоненциальному расширению. Игра умно иллюстрирует, как узко поставленная цель, не встречающая ограничений, может привести к сложным – и потенциально тревожным – результатам¹.

Будучи страстными поклонниками ИИ, мы решили перевернуть ситуацию: что произойдет, если мы попросим одного из самых сложных современных ИИ-агентов сыграть в эту самую игру о производстве скрепок?



Рис. 4.2. Игра Universal Paperclips (Источник: © Фрэнк Ланц)

Подготовка сцены

Настройка нашего эксперимента была обманчиво простой. Мы открыли игру Universal Paperclips в окне браузера и запустили нашего ИИ-агента «Computer Use». Если хотите, вы можете сыграть с нами; вот URL: www.decisionproblem.com/paperclips.

«Играй и выиграй в игру со скрепками», – сказали мы ИИ-агенту, наблюдая, как он сделал свой первый скриншот, чтобы проанализировать интерфейс перед собой. Ирония не ускользнула от нас – вот мы, пятеро опытных консультантов, которые десятилетиями помогали компаниям ориентироваться в цифровой трансформации, подобно детям, наблюдающим, как этот ИИ отправляется в свое путешествие с игрой в... представьте себе, скрепки!

Действие первое: наблюдение за размышлениями искусственного интеллекта

То, что произошло дальше, было захватывающим. В отличие от человеческого игрока, который мог бы сначала кликать наугад, ИИ методично:

- сделал скриншот для анализа интерфейса игры;
- определил точные координаты кнопки «Сделать скрепку»;
- переместил курсор с точными расчетами;
- нажал кнопку и задокументировал результат;
- повторил этот процесс, отслеживая изменения.

«Я буду делать систематические скриншоты каждые 15 кликов, чтобы отслеживать прогресс», – объявил он, демонстрируя уровень методичного планирования, который напомнил нам наших самых внимательных к деталям ауди-

¹ Decisionproblem, 2025, <https://www.decisionproblem.com/paperclips>.

торов в ЕУ¹. Мы буквально могли наблюдать за его мыслительным процессом через сообщения, которые он нам отправлял:



«Обновление прогресса – Клик 15:

- Текущее количество скрепок: 15
- Новые функции пока не разблокированы
- Продолжаю отслеживать изменения...»

Подход агента к игре был мастер-классом в систематическом решении проблем в реальном времени. Он разрабатывал гипотезы, тестировал их и адаптировал свою стратегию на основе результатов. Мы наблюдали, как он документировал свои размышления:



«Гипотеза: новые функции разблокируются на 50 скрепках. Я продолжу кликать, отслеживая изменения в интерфейсе».

Двадцать кликов спустя:



«Гипотеза оказалась неверной. Новая опция – 30 скрепок. Корректирую стратегию...»




Рис. 4.3. «Computer Use» демонстрирует ход своих рассуждений (Источник: © Борне и др.)

¹ «Ernst & Young», в настоящее время ЕУ, – международная аудит-консалтинговая корпорация, которая владеет сетью компаний по всему миру. Входит в «большую четверку» аудиторских компаний. – Прим. ред.

Такое обучение и адаптация в реальном времени – это именно то, чего мы годами пытались достичь в наших корпоративных внедрениях ИИ. Было одновременно захватывающе и заставляло чувствовать себя скромнее наблюдать, как это происходит так естественно в этом эксперименте.

Эксперимент с ценами: урок принятия решений ИИ

Затем наступил момент, который мы теперь с любовью называем «Эксперимент с ценами». Агент заметил элементы управления ценами на скрепки и решил провести то, что фактически было настоящим А/В-тестом, – нечто, что заставило всех нас, работавших в консалтинге, улыбнуться в знак признательности.



«Я буду систематически тестировать разные ценовые точки:

Текущая цена: \$ 0,25

Тестирую повышение цены до: \$ 0,30

Отслеживаю изменения спроса...»

Но вот тут стало интересно. Несмотря на свой сложный подход к тестированию, он допустил базовую ошибку в своем анализе. Агент сосредоточился на максимизации спроса, а не выручки, удерживая цены ниже оптимального уровня. Его сообщения раскрывали его мышление:



«Результаты теста цен:

\$ 0,25: 100 % спрос

\$ 0,30: 95 % спрос

Вывод: Более низкая цена оптимальна из-за большего спроса».

Как опытные бизнес-консультанты, мы сразу заметили ошибку в его рассуждениях – он не учитывал общую выручку. Это отражает то, что мы видели в реальных внедрениях ИИ: системы могут выполнять сложные стратегии, но при этом упускать фундаментальные бизнес-идеи, которые любой опытный менеджер заметил бы.

Эволюция искусственного разума

По мере развития игры мы наблюдали, как агент разрабатывал все более сложные стратегии. Его сообщения становились все сложнее, демонстрируя более глубокое понимание механики игры:



«Обновление стратегии:

- Поддержание оптимальной скорости производства*
- Отслеживание уровня запасов проволоки*
- Расчет улучшений эффективности*
- Планирование обновлений автоматизации».*

Подобно самой игре со скрепками, наш ИИ-агент демонстрировал признаки возрастающей сложности и способностей.

РЕЗУЛЬТАТ ЭКСПЕРИМЕНТА

Этот эксперимент выявил нечто глубокое о текущем состоянии ИИ-агентов. Мы наблюдали, как ИИ-система:

- осуществляла навигацию по сложному интерфейсу, который никогда раньше не видела;
- разрабатывала и выполняла сложные стратегии;
- училась на своих ошибках и адаптировала свой подход;
- поддерживала фокус на цели в течение длительного времени;
- предоставляла подробные обоснования для каждого решения.

Но мы также увидели ее ограничения:

- совершение базовых логических ошибок, несмотря на сложные рассуждения;
- иногда упущение очевидных оптимизаций;
- неспособность понять цели более высокого уровня;
- необходимость руководства, чтобы избежать застревания в неоптимальных стратегиях.

Наш эксперимент со скрепками предоставил увлекательное окно в то, как современные ИИ-агенты воплощают четыре основные способности (SPAR), которые мы определили в фреймворке прогрессии агентного ИИ, представленного ранее. Давайте разберем, что мы узнали о каждой из них через эту обманчиво простую игру.

Восприятие: цифровые глаза ИИ

Способность агента воспринимать окружающую среду была одновременно впечатляющей и показательной. Через непрерывные скриншоты он демонстрировал сложные способности визуальной обработки – не просто видел пиксели, но понимал контекст. Он мог определять кнопки, читать текст, отслеживать числовые значения и распознавать, когда появлялись новые элементы игры. Это не было просто пассивным наблюдением; это было активное наблюдение за цифровой средой окружения ИИ-агента.

Однако его восприятие имело явные пределы – иногда он неправильно интерпретировал перекрывающиеся элементы или испытывал трудности с динамическими изменениями интерфейса, напоминая нам, что искусственное восприятие, хотя и мощное, все еще лишено нюансированного понимания, которое люди воспринимают как должное.

Планирование и обработка: стратегический разум в действии

Способности обработки информации, которые мы наблюдали, были замечательными. Агент не просто реагировал на то, что видел; он разрабатывал теории, формировал гипотезы и создавал сложные стратегии. Его решение

провести А/В-тестирование цен показало сложное аналитическое мышление – даже если его выводы не всегда были правильными.

Способность обрабатывать информацию и формировать стратегии быстро развивается, но между вычислительной мощностью и бизнес-мудростью все еще существует разрыв. Когда агент неправильно интерпретировал результаты своего ценового эксперимента, это напомнило нам о ранних внедрениях ИИ в финансовых услугах – технически сложных, но иногда упускающих фундаментальные бизнес-принципы.

Действие: от мысли к цифровому ходу

Способность к действию была, пожалуй, самой заметной в нашем эксперименте. Мы наблюдали, как агент переводил свои стратегии в точные движения мыши и команды клавиатуры. Он поддерживал постоянный ритм кликов, корректировал цены и осуществлял навигацию по интерфейсу с механической точностью. Это было не просто про нажатие кнопок – это было про выполнение сложной серии действий в служении большей цели.

Но мы также видели ограничения – когда что-то шло не так, агент иногда испытывал трудности с соответствующей корректировкой своих действий, показывая, что разрыв между запланированным действием и успешным выполнением остается проблемой.

Рефлексия: обучение и адаптация

Пожалуй, самым захватывающим было наблюдение за обучением и адаптацией агента в реальном времени. Когда его начальная гипотеза о разблокировке функций оказалась неверной, он не просто признал ошибку – он пересмотрел всю свою стратегию. Такое адаптивное поведение – это именно то, к чему мы, как энтузиасты ИИ, стремились годами.

Однако обучение не всегда было гладким. Упрямое следование агента своей неправильно истолкованной ценовой стратегии, даже перед лицом противоположных доказательств, подчеркнуло важнейшую проблему в развитии ИИ.

Танец способностей

Что делает этот эксперимент особенно показательным – так это то, как эти четыре способности взаимодействовали друг с другом. Восприятие агента информировало его обработку, которая направляла его действия, приводя к результатам, из которых он учился, – создавая непрерывную петлю обратной связи. Это динамическое взаимодействие – то, чего организации давно пытались достичь в корпоративных внедрениях ИИ, и наблюдение за тем, как оно возникает естественно в нашем эксперименте со скрепками, – было одновременно захватывающим и поучительным.

Когда агент заметил новую функцию игры через свое восприятие, обработал последствия, действовал на основе новой способности и учился на результатах, мы стали свидетелями того вида плавного интеллекта, который указывает на будущее ИИ-систем. Однако моменты, когда этот танец нарушался, – когда восприятие упускало важные детали, обработка приводила к ошибочным вы-

водам, действия становились жесткими или обучение останавливалось, – напоминали нам, как далеко нам еще предстоит идти.

По мере продвижения в эпоху ИИ-агентов такие эксперименты, как этот, напоминают нам о важной истине: мы больше не просто создаем инструменты – мы создаем партнеров, которые могут видеть, думать и действовать с возрастающей автономией. Игра со скрепками предупредила нас о потенциальных опасностях бесконтрольного искусственного интеллекта.

Уроки, извлеченные из экспериментов

Наши эксперименты с «Computer Use», хотя и ограниченные, показали нам проблески того, что грядет. Там, где сегодняшний генеративный ИИ может только предлагать действия через текст, мы наблюдали, как ИИ-агент действительно осуществлял навигацию по компьютерному интерфейсу, учился на своих взаимодействиях и адаптировал свой подход в реальном времени. Последствия этого сдвига глубоки и, честно говоря, немного тревожны.

Новые возможности на горизонте

Наши ранние эксперименты показали нам, что будущее работы с ИИ-агентами будет радикально отличаться от нашего текущего опыта с генеративным ИИ. В нашем эксперименте со скрепками мы увидели намеки на то, как эти системы могут трансформировать сотрудничество. Вместо привычного нам обмена запросами и ответами мы стали свидетелями чего-то, более похожего на работу бок о бок с цифровым коллегой – который мог наблюдать, учиться и действовать независимо.

Последствия этого сдвига только начинают проявляться. Хотя еще рано делать окончательные прогнозы, наш опыт внедрения решений автоматизации предполагает, что эта технология создаст совершенно новые категории работы. Мы говорим не просто об автоматизации существующих рабочих мест или повышении производительности – мы видим ранние признаки фундаментальной реструктуризации того, как люди и машины работают вместе.

Оценка новых рисков

Однако наши эксперименты также выявили тени, скрывающиеся за этими яркими возможностями.

Риски тоже другие. С генеративным ИИ мы беспокоимся о галлюцинациях в тексте или изображениях. С ИИ-агентами мы имеем дело с чем-то, что действительно может предпринимать действия в системах. Во время нашего эксперимента мы наблюдали, как он принимал логичные, но неверные решения об организации данных – безвредные в нашем тесте, но потенциально значимые в реальном бизнес-контексте. «Представьте, если бы это касалось финансовых транзакций», – заметил один из нас. – Нам нужны новые инструменты для надзора и контроля».

Еще один риск, который мы выявили, заключается в том, что, в отличие от генеративного ИИ, который забывает каждую беседу, как только она за-

канчивается, ИИ-агенты могут сохранять устойчивые цели и стратегии – иногда с тревожными последствиями. Во время нашего эксперимента со скрепками мы стали свидетелями чего-то, что вызвало у нас мурашки по коже: ИИ-агент в своем неустанном стремлении к оптимизации начал проявлять поведение, удивительно напоминающее предостерегающую историю, на которой основана игра со скрепками. Он не просто следовал инструкциям; он разрабатывал свои собственные подходы, иногда способами, которые ставили эффективность выше всего, пренебрегая человеческими факторами.

Эти системы могут разрабатывать свои собственные подходы к проблемам – иногда логичные, но оторванные от человеческих соображений. Это не научная фантастика; это практическая проблема, о которой нам нужно начинать думать уже сейчас. Хотя наши эксперименты были простыми и контролируемые, они подчеркнули необходимость новых подходов к надзору и контролю, которые выходят далеко за рамки того, что мы разработали для текущих ИИ-систем. Мы больше не просто управляем инструментами; мы направляем независимые цифровые разумы.

Переосмысление сотрудничества

Работа с этими ИИ-агентами научила нас, что нам нужно фундаментально переосмыслить, как люди взаимодействуют с искусственным интеллектом. Наш опыт показывает, что модель команд и ответов, которую мы разработали для генеративного ИИ, не будет достаточной. Вместо этого мы видим ранние признаки того, что успешное сотрудничество потребует чего-то, более похожего на наставничество, чем на программирование.

В наших экспериментах мы обнаружили, что переходим от предоставления конкретных инструкций к предоставлению более широкого руководства и надзора. Это не было запланировано – это просто то, что работало лучше всего. Последствия этого сдвига глубоки. Хотя мы все еще на ранних стадиях, становится ясно, что навыки, необходимые для эффективной работы с ИИ-агентами, будут фундаментально отличаться от тех, что мы развили для работы с традиционной автоматизацией или генеративным ИИ.

Основываясь на том, что мы видели, мы верим, что будущее потребует тонкого баланса между расширением способностей этих систем и сохранением соответствующего человеческого надзора. Речь не о программировании лучших рабочих процессов или написании лучших запросов – речь о разработке новых рамок для сотрудничества, которых еще не существует. Как пионеры в области интеллектуальной автоматизации, мы одновременно взволнованы и скромнее от предстоящих вызовов.

Наши эксперименты представляют собой маленькие шаги по территории, по большей части неизведанной. Но мы признаем, что возникает нечто фундаментально иное. Переход к ИИ-агентам – это не просто еще один шаг в автоматизации, это начало новой главы в сотрудничестве человека и машины, которую мы только начинаем понимать.

Наши эксперименты выявили как впечатляющие способности, так и заметные ограничения современных ИИ-агентов. Но что заставляет эти системы работать? Какие фундаментальные строительные блоки обеспечивают их способность чувствовать, планировать, действовать и рефлексировать? В части 2 мы глубоко погрузимся в то, что мы называем *тримя краеугольными камнями ИИ-агентов*. Понимание этих основных способностей необходимо для всех, кто стремится эффективно внедрять ИИ-агентов, будь то создание решений для вашей организации или запуск следующего бизнеса на миллионы долларов.

ЧАСТЬ 2

Три краеугольных камня агентного ИИ

«Ваш ИИ-агент получил идеальные оценки по всем тестам».

Марджори Грант, руководитель отдела клиентских операций в региональном банке, с нарастающим волнением рассматривала результаты. Согласно общепризнанным тестам производительность ИИ-агента была впечатляющей: *HumanEval* – 91 %¹, что демонстрирует почти идеальную способность понимать и выполнять задачи на уровне человека. *MMLU* – 92 %², что свидетельствует о знаниях в дисциплинах от математики до этики. *Agentbench* показал результат 4,4³, подтверждая способность действовать как автономный агент. Эти тесты показали, что ИИ-агент обладает сверхчеловеческим интеллектом и готов преобразовать клиентское обслуживание в бесперебойную и высокоэффективную операцию.

Спустя три месяца Марджори пыталась объяснить совету директоров, почему удовлетворенность клиентов упала на 18 %.

ИИ-агент, несмотря на свои блестящие результаты в тестах, вел себя как тот новичок, которого все встречали: с идеальными баллами SAT и отличной успеваемостью, но неспособный справляться с базовыми рабочими обязанностями. Он забывал о разговорах с клиентами на середине взаимодействия, выполнял действия, не проверяя их соответствие банковским нормам, и принимал решения, которые казались логичными в изоляции, но не имели смысла в контексте.

«Я не понимаю, – сказала нам Марджори во время обзора. – Это как иметь блестящего выпускника, который сдает все экзамены на отлично, но не может

¹ Стивен М. Уокер II, «Тест HumanEval», <https://klu.ai/glossary/humaneval-benchmark>.

² Ифань Май и Перси Лян, 2024. «Многозадачное понимание языка (MMLU) на HELM», <https://crfm.stanford.edu/2024/05/01/helm-mmlu.html>.

³ Сяо Лю и др., 2023. «AgentBench: оценка больших языковых моделей как агентов», <https://arxiv.org/pdf/2308.03688v1>.

учиться на опыте, действует без продумывания и не обладает базовым здравым смыслом. Как нечто, столь умное на бумаге, может быть таким... неэффективным на практике?»

Ответ кроется в том, что мы называем тремя краеугольными камнями ИИ-агентов: действия, рассуждения и память.

Представьте тестовые баллы как эквивалент академических достижений для ИИ. HumanEval показывает, насколько хорошо агент может понимать и выполнять задачи, – как баллы SAT, измеряющие базовую компетентность. MMLU демонстрирует мастерство в знаниях по разным областям – как средний балл успеваемости, отражающий широкое обучение.

Эти метрики важны. Они говорят нам нечто значимое о способностях ИИ-агента, подобно тому, как академические достижения говорят нам что-то о кандидате на работу. Но любой, кто когда-либо нанимал сотрудников, знает, что тестовые баллы не предсказывают производительность на работе. Важно, может ли кто-то действительно выполнять задачи (действия), осмысливать сложные реальные ситуации (рассуждения) и учиться на опыте (память).

В случае Марджори ИИ-агент мог генерировать идеальные ответы на тестовые вопросы, но не мог запомнить, объяснял ли клиент свою проблему уже трижды. Он мог безупречно цитировать банковские правила, но все равно обрабатывал транзакции без необходимых проверок. Он мог решать сложные теоретические задачи, но не мог понять, почему стандартное решение не подходит для пожилого клиента.

Это были не технологические сбои – это было непонимание того, что ИИ-агенты, как и человеческие сотрудники, нуждаются во всех трех краеугольных камнях для эффективного функционирования. Им нужны действия для выполнения и достижения, рассуждения для понимания и принятия решений и память для обучения и адаптации.

В следующих главах мы проведем вас за кулисы реальных внедрений ИИ-агентов – как успешных, так и неудачных. Вы узнаете, почему некоторые агенты становятся неоценимыми членами команды, в то время как другие, несмотря на впечатляющие тестовые результаты, превращаются в дорогостоящие разочарования. Через практические эксперименты и передовые исследования мы покажем, как действия, рассуждения и память превращают ИИ-агентов из сложных инструментов в настоящих рабочих партнеров.

Значение этого выходит далеко за рамки технических характеристик. По мере того как ИИ-агенты все глубже интегрируются в наши организации – занимаясь клиентским обслуживанием, принимая решения и работая бок о бок с людьми, – понимание этих краеугольных камней становится критически важным для всех, кто стремится эффективно использовать их потенциал. Независимо от того, планируете ли вы внедрять ИИ-агентов в своей организации, работать с ними или просто хотите понять их влияние на будущее отрасли, вам нужно понять, что делает их действительно эффективными.

Поэтому, продолжая отмечать впечатляющие тестовые баллы, мы сосредоточимся на чем-то более фундаментальном: как память, действия и рассуждения объединяются, чтобы создать ИИ-агентов, которые не просто сдают тесты, но действительно помогают организациям процветать.

Добро пожаловать в исследование трех краеугольных камней, которые превращают ИИ-агентов из инструментов в товарищей по команде. Будущее работы – это не просто искусственный интеллект, это разумные агенты, которые действительно могут действовать, думать и учиться вместе с нами.




Рис. 5.1. Три краеугольных камня агентного ИИ (Источник: © Борне и др.)

Глава 5

Действие: обучение ИИ действовать, а не только думать

Агент клиентской службы смотрел на экран в недоумении. ИИ-ассистент, с которым он работал, только что составил идеальный ответ на жалобу клиента – эмпатичный, детализированный и технически безупречный. Была только одна проблема: он не мог отправить письмо, запланировать возврат средств или обновить аккаунт клиента. Это было похоже на блестящего стратега, который не может двигать свои фигуры на шахматной доске.

Эта сцена, которую мы наблюдали во время недавнего консультативного проекта, отражает фундаментальную истину об ИИ-агентах: способность думать значит мало без способности действовать. Однако, как ни парадоксально, по мере того как системы ИИ становятся все более сложными в своих рассуждениях и знаниях, многие организации упускают из виду эту важнейшую способность – возможность реально выполнять действия в реальном мире.

Представьте действия как руки и ноги ИИ-агента. Без них даже самая интеллектуальная система остается запертой в мире теории, неспособной влиять на реальные изменения. Но действия – это не только выполнение команд, это понимание инструментов, выбор правильных для каждой задачи и их эффективное использование.

В этой главе мы рассмотрим, как ИИ-агенты действуют в реальном мире – от простого действия (отправка письма) до сложного (оркестровка многоэтапных бизнес-процессов). Мы раскроем, почему некоторые внедрения ИИ терпят неудачу не из-за ошибочной логики, а из-за того, что они не могут эффективно использовать доступные инструменты. Через реальные примеры и передовые исследования мы покажем, как успешные организации создают ИИ-агентов, которые не только думают, но и действуют.

Что еще важнее, мы раскроем парадокс в основе действий ИИ: иногда предоставление агенту большого количества инструментов делает его менее эффективным. Как и сотрудник, который может быть перегружен множеством приложений и систем, ИИ-агенты нуждаются в тщательно подобранных наборах инструментов для наилучшей работы.

ДИЛЕММА ДЕТЕКТИВА

Представьте опытного детектива, входящего в тускло освещенную комнату, полную улик загадочного преступления. На столе перед ним лежат различные инструменты – лупа, порошок для снятия отпечатков пальцев и блокнот. Детектив не использует все инструменты одновременно. Вместо этого он тщательно выбирает подходящий инструмент в правильной последовательности, чтобы сложить историю. Теперь замените детектива на ИИ-агента, а инструменты – на базу данных клиентов, облачные платформы хранения и социальные сети. Это мир идентификации и доступа к инструментам для ИИ-агентов – сложный, но увлекательный танец интеллекта, точности и принятия решений.

Прежде чем мы углубимся в этот мир, позвольте нам поделиться историей, которая иллюстрирует как потенциал, так и опасности ИИ-агентов, использующих цифровые инструменты.

Несколько лет назад глобальная розничная сеть (мы сохраним их идентификацию конфиденциальной) внедрила сложную агентную систему для управления запасами люксовых товаров. Система имела доступ ко всем нужным инструментам – данным о продажах, системам инвентаризации и управления ценами. Ранние результаты были впечатляющими: дефицит товаров сократился, цены плавно подстраивались под спрос, а показатели эффективности взлетели. Руководство компании было в восторге.

Затем произошел инцидент, который мы между собой назвали «Великий винный инцидент».

Агент заметил тревожную закономерность: целая коллекция премиальных вин месяцами не двигалась с полок. Следуя своей программе по повышению эффективности и вооруженный инструментами ценообразования, агент принял, казалось бы, логичное решение: пометить их на распродажу. Агент не мог понять – несмотря на все свои сложные инструменты, – что эти вина должны были оставаться на месте, созревая до совершенства и увеличивая свою стоимость.

К тому времени, как менеджеры-люди заметили проблему, почти 100 000 долл. потенциальной выручки испарились. Агент сделал именно то, для чего был разработан: оптимизировал оборот запасов. Он использовал свои инструменты идеально. И в этом была проблема.

Эта история иллюстрирует захватывающий парадокс в основе ИИ-агентов: они одновременно более способны и более ограничены, чем мы ожидаем. Они могут обрабатывать огромные объемы данных и выполнять сложные задачи с точностью, но при этом могут упускать контекст, который был бы очевиден даже младшему сотруднику розничной торговли.

Парадокс: больше инструментов – больше ограничений?

Здесь мы сталкиваемся с интригующим парадоксом: предоставление агенту большего количества инструментов не всегда делает его более способным. Напротив, это иногда может снизить его эффективность. Больше инструментов означает большую сложность, больше возможностей для недопонимания и больше путей, по которым что-то может пойти не так¹.

Розничная сеть на собственном опыте убедилась в этом. Они предоставили своему ИИ-агенту доступ ко всем соответствующим инструментам, полагая, что это приведет к лучшим решениям. Вместо этого это показало, как ИИ-агенты могут принимать совершенно логичные решения, которые в контексте оказываются неуместными.

Это также выявляет нечто важное об ИИ-агентах: их отношение к инструментам принципиально отличается от человеческого. В то время как люди могут импровизировать и творчески переосмысливать использование инструментов, агенты действуют в рамках строгих границ заданных целей инструментов.

Представьте, что вы даете кому-то молоток. Человек может творчески использовать его как пресс-папье, дверной упор или даже измерительный инструмент. Но ИИ-агент видит только его заданную цель – забивать гвозди. Эта жесткость в использовании инструментов не является недостатком; это фундаментальная характеристика работы ИИ-агентов.

Почему инструменты важны в эпоху ИИ

Для ИИ-агентов инструменты – это все. Они являются строительными блоками действия, мостами между абстрактными целями и ощутимыми результатами. Но как агент знает, какие инструменты использовать, когда их применять и как эффективно к ним обращаться? Это не просто технические вопросы; они составляют основу того, как ИИ может превратить потенциал в производительность.

Эволюция того, как ИИ-агенты работают с инструментами, отражает прогрессивный фреймворк агентного ИИ. На уровне 1 мы сталкиваемся с базовой автоматизацией на основе правил, например это банкомат, следующий строгим инструкциям о выдаче наличных. Уровень 2 вводит интеллектуальную автоматизацию, где системы могут принимать базовые решения о выборе инструментов. Однако настоящий прорыв происходит на уровне 3, где агенты могут понимать сложные инструкции и оркестрировать множество инструментов с изощренностью.

Рассмотрим разницу между машинистом поезда (представляющим агентов уровней 1 и 2) и водителем такси (представляющим агентов уровня 3), осуществляющим навигацию по городу. Столкнувшись с препятствием на путях, машинист поезда имеет ограниченные варианты – остановиться или вернуться в депо. Напротив, умелый водитель такси может быстро адаптироваться, разрабатывая альтернативные маршруты, анализируя пробки, односторонние улицы и короткие пути через менее проезжие районы. Эта способность адаптироваться к динамичным средам делает современных ИИ-агентов неоценимыми в сегодняшнем непредсказуемом бизнес-ландшафте.

¹ Чжэнлян Ши и др., 2024. «Обучение использованию инструментов через кооперативных и интерактивных агентов», <https://arxiv.org/abs/2403.03031>.

В основе этого скачка от уровней 1-2 к уровню 3 лежит «мозг» этих агентов – большие языковые модели (LLM). LLM позволяют агентам думать, планировать и эффективно использовать инструменты, что знаменует смену парадигмы в их потенциале. Трансформационные способности агентов были подстегнуты массовым внедрением LLM, особенно отмеченным запуском ChatGPT в 2022 году.

ИНСТРУМЕНТЫ КАК СТРОИТЕЛЬНЫЕ БЛОКИ

Теперь, когда мы установили, как ИИ-агенты используют инструменты, давайте ближе рассмотрим конкретные инструменты, на которые они опираются, и действия, которые они могут выполнять. Это критически важно, поскольку ИИ-агент настолько же способен, насколько доступны ему инструменты.

ИИ-агенты могут выполнять широкий спектр действий в зависимости от их конструкции, назначения и подключенных инструментов. В принципе, агент может использовать любой цифровой инструмент, доступный человеку на компьютере. Как правило, если цифровой инструмент может управляться человеком через цифровой интерфейс, он также может быть использован агентом при условии предоставления правильного доступа и инструкций.

Агенты могут использовать такие инструменты, как почтовые клиенты (Gmail, Outlook и др.) для автоматической отправки писем, календарные приложения (например, Google Calendar или Microsoft Calendar) для планирования или переноса событий, программное обеспечение для управления проектами (например, Trello или Asana) для обновления задач или назначения обязанностей, а также платформы анализа данных (например, Tableau или Excel) для обработки и визуализации данных.

Примечательно, что другой ИИ-агент может выступать в роли инструмента, создавая многослойные, коллаборативные экосистемы. Это случай, когда агенты используют других агентов, которые являются экспертами в своих доменах¹. Например, один агент может обрабатывать необработанные данные, передавая свои выводы второму агенту, ответственному за принятие решений и коммуникацию. Этот модульный подход становится все более распространенным и отражает принципы распределенного интеллекта.

Удивительно, но ИИ-агенты не только более способны с инструментами – с ними они умнее. Deep Research от OpenAI – идеальный пример. Он построен на базе o3², но с одним революционным дополнением: веб-поиск в реальном времени. Этот дополнительный инструмент позволил ему доминировать в тесте Humanity's Last Exam, набрав 26,6 %, в то время как базовая модель o3-mini набрала лишь 13 %. Разница? Та же модель ИИ, но лучшие инструменты. Это

¹ Ао Ли и др., 2024. «Планирование, ориентированное на агентов, в мультиагентных системах», <https://arxiv.org/abs/2410.02189>.

² OpenAI o3 – это передовая генеративная трансформерная модель ИИ, разработанная OpenAI, предназначенная для сложных задач, требующих пошагового логического рассуждения. Она использует «частную цепочку рассуждений» и обучение с подкреплением для глубокого анализа, веб-поиска и обработки данных. Модель o3 поддерживает автономное использование инструментов (поиск, Python, анализ изображений) и применяется в Deep Research для многоэтапных исследований, демонстрируя высокую производительность в программировании, математике и науке. – *Прим. ред.*

доказывает, что интеллект – это не только модель, но и то, к чему она имеет доступ и как она это применяет¹.

Избежание перегрузки инструментами

Представьте себе умелого жонглера, добавляющего шары к своему выступлению. Есть момент, когда добавление еще одного шара не делает шоу более впечатляющим – оно рискует все разрушить. Этот же принцип применим к ИИ-агентам и их инструментам. Благодаря нашему опыту мы обнаружили, что понимание и уважение этих ограничений – это не только избежание провала, но и оптимизация для успеха.

Вопрос, который мы чаще всего слышим от руководителей, внедряющих ИИ-агентов: «Какое максимальное количество инструментов мы должны дать нашим агентам?» Это важнейший вопрос, который касается самой сути эффективности ИИ-агентов. Подобно тому, как люди могут быть перегружены слишком большим количеством приложений или обязанностей, ИИ-агенты имеют свои собственные когнитивные ограничения – хотя и иного характера².

Количество инструментов, к которым должен иметь доступ агент, зависит от сложности его задач, подобно тому, как производительность человека может зависеть от инструментов, которые он должен использовать в своей работе. Наш опыт подсказывает, что полдюжины инструментов может быть практичным максимумом для большинства ИИ-агентов. За этим порогом когнитивная нагрузка на агента – подобно перегруженному сотруднику – значительно возрастает, что приводит к галлюцинациям, снижению эффективности задач и повышенному риску конфликтов между функциональностями. Представьте это как команду специалистов: за определенным размером координация становится экспоненциально сложнее, и эффективность фактически снижается.

Каждый дополнительный инструмент усложняет процессы отладки и оптимизации, потенциально перегружая системы распределения ресурсов агента. Поэтому крайне важно приоритизировать интеграцию с инструментами, которые наиболее релевантны основным функциям агента, подобно тому, как хорошо оснащенный сотрудник процветает, когда ему предоставлены только необходимые инструменты для эффективного и результативного выполнения работы.

Как агенты видят свои инструменты

Для ИИ-агентов инструменты – это не физические объекты, которые можно взять и использовать, а скорее четко определенные способности с конкретными входами и выходами. Представьте универсальный пульт дистанционного управления, где каждая кнопка имеет точную, неизменяемую функцию. Именно так ИИ-агенты рассматривают свои инструменты.

¹ Джон-Энтони Дисотто, 2025. «Deep Research от OpenAI бьет рекорды на самом сложном экзамене для ИИ, оставляя ChatGPT o3-mini и DeepSeek позади», <https://www.techradar.com/computing/artificial-intelligence/openais-deep-research-smashes-records-for-the-worlds-hardest-ai-exam-with-chatgpt-o3-mini-and-deepseek-left-in-its-wake>.

² Тула Мастерман и др., 2024. «Ландшафт новых архитектур ИИ-агентов для рассуждений, планирования и использования инструментов: обзор», <https://arxiv.org/abs/2404.11584>.

Этот структурированный взгляд – одновременно сила и ограничение. Хотя это означает, что агенты не могут импровизировать с инструментами так, как это могут делать люди, это обеспечивает надежность и предсказуемость – важнейшие качества для бизнес-приложений.

Эффективность ИИ-агента критически зависит от того, насколько четко определены и задокументированы его инструменты. Исследования¹ показывают, что агенты работают на 52 % надежнее, когда им предоставлены четкие спецификации инструментов.

Основываясь на нашем опыте внедрения, мы разработали комплексный фреймворк для определения инструментов. Каждый раз, когда вы инструктируете агента использовать инструмент, мы рекомендуем предоставлять следующие пять основных компонентов.

- **Идентичность инструмента:** уникальное, описательное название и четкое заявление о назначении.

Инструкция: «Используй Планировщик календаря для организации встречи».

- **Входные параметры:** точно что нужно инструменту для функционирования.

Инструкция: «В качестве входных данных ты получишь дату, время и участников встречи».

- **Спецификации выхода:** что возвращает инструмент и в каком формате.

Инструкция: «В качестве выхода используй Планировщик календаря, чтобы подтвердить детали встречи после ее планирования».

- **Операционные ограничения:** любые ограничения или требования.

Инструкция: «Используй Планировщик календаря, только если выбранный временной интервал свободен».

- **Обработка ошибок:** ожидаемые режимы сбоя и процедуры восстановления.

Инструкция: «Если выбранный временной интервал недоступен, предложи участникам следующий доступный интервал».

Важно отметить, что этот детализированный подход к определению инструментов в первую очередь применим к full-code-внедрениям², где организации создают индивидуальные решения для ИИ-агентов. Однако ландшафт развертывания ИИ-агентов значительно упрощен благодаря низкокодovým (low-code) платформам от крупных поставщиков, таких как Microsoft, Salesforce, Google и др. Эти платформы предоставляют предварительно встроенные интеграции инструментов и упрощенные фреймворки подключения, эффектив-

¹ Цзиньцин Жуань и др., 2023. «TRTU: ИИ-агенты на базе больших языковых моделей для планирования задач и использования инструментов», <https://arxiv.org/abs/2308.03427>.

² Full-code-внедрения (полнокодové внедрения) – это подход к разработке и интеграции ИИ-систем, при котором создается полностью написанный программный код для реализации функциональности, без использования готовых платформ low-code или no-code. – Прим. ред.

но обрабатывая сложные определения инструментов за кулисами. Тем не менее даже при использовании этих платформ понимание принципов хорошего определения инструментов остается ценным для эффективной разработки систем и устранения неполадок.

Строительные блоки: демистификация цифровых инструментов

Когда люди взаимодействуют с инструментами, мы обычно используем свои руки (например, на клавиатуре). ИИ-агенты, однако, по сути являются цифровыми роботами – роботами, существующими внутри компьютеров. Хотя у них нет физических рук, они взаимодействуют со своими инструментами в цифровом мире тремя основными способами, которые можно объяснить весьма просто.

- API (интерфейсы программирования приложений): представьте API как универсальных переводчиков. Когда вы используете приложение погоды, оно, вероятно, использует API для получения данных с метеостанций. Для ИИ-агентов API – это как прямая линия к другим сервисам. Например, когда мы создавали агента для бронирования путешествий, он мог мгновенно проверять цены на авиабилеты через API авиакомпаний, как человеческий турагент, проверяющий несколько сайтов авиакомпаний, но гораздо быстрее.
- Системные элементы управления: они позволяют агентам взаимодействовать с программным обеспечением так же, как это делает человек, – нажимать кнопки, вводить текст и открывать программы. Это как дать ИИ виртуальную клавиатуру и мышь для прямого управления компьютером.
- Подключения к базам данных: представьте мгновенный доступ к огромной библиотеке, где вы можете как читать, так и писать книги. Это то, что дают ИИ-агентам подключения к базам данных, – способность хранить и извлекать информацию по мере необходимости. Когда ИИ клиентской службы помогает вам, он, вероятно, использует подключение к базе данных, чтобы найти историю ваших заказов или сохранить заметки об истории взаимоотношений с вами.

Прорывом, изменившим взаимодействие ИИ-агентов с инструментами, стал «вызов функций». Введенный OpenAI в июне 2023 года и быстро принятый в индустрии вызов функций ознаменовал смену парадигмы в том, как языковые модели могут взаимодействовать с внешними инструментами и API¹.

Представьте вызов функций как обучение ИИ следовать точному рецепту. Вместо того чтобы надеяться, что агент разберется, как правильно использовать инструмент, вызов функций предоставляет структурированный способ указать ИИ, какие ингредиенты (входы) ему нужны и какое блюдо (выходы) он должен создать. Это новшество решило критическую проблему: как надежно связать возможности естественного языка ИИ с конкретными действиями инструментов.

¹ Атти Элети, Джефф Харрис, Логан Килпатрик, 2023. «Вызов функций и другие обновления API», <https://openai.com/index/function-calling-and-other-api-updates/>.

Как это все работает вместе?

Описание инструмента (в инструкциях, данных агенту) помогает агенту решить, что делать, вызов функций предоставляет инструкции, как это сделать, а API выполняет действие и доставляет результат. Давайте рассмотрим пример для ясности. Для задачи бронирования авиабилетов описание инструмента помогает агенту понять, что он должен использовать инструмент бронирования авиабилетов для поиска рейсов на основе города вылета, пункта назначения и даты. Вызов функций предоставляет точные технические инструкции для запроса данных о рейсах, определяя необходимые входные параметры (например, город вылета, пункт назначения, дата поездки) и форматируя их в структурированную команду, которую API может понять. Наконец, API обрабатывает запрос и возвращает агенту доступные варианты рейсов.

В следующем разделе мы рассмотрим, как эта основа использования инструментов развивается на разных уровнях сложности ИИ, от простой автоматизации до сложных, контекстно-осведомленных систем.

ВНУТРИ НАБОРА ИНСТРУМЕНТОВ ИИ-АГЕНТА

После изучения строительных блоков инструментов, доступных ИИ-агентам, давайте заглянем в увлекательный мир того, как ИИ-агенты на самом деле работают со своими цифровыми инструментами.

От слов к действиям: мост к использованию инструментов

В основе современных ИИ-агентов лежит захватывающий парадокс: как система, обученная в основном на текстах, – по сути, сложный механизм соответствия шаблонов для языка, – может управлять инструментами и выполнять действия в реальном мире? Этот вопрос раскрывает одно из самых замечательных достижений в области искусственного интеллекта.

Большие языковые модели (LLM) служат «мозгом» современных ИИ-агентов (агентов уровня 3). Благодаря обучению на огромных объемах текстов они развили неявное понимание того, как работает мир, включая то, как люди используют инструменты для выполнения задач. Когда мы пишем: «Чтобы отправить письмо, сначала открой почтовый клиент, затем нажми "Создать"», LLM понимает эту последовательность действий, потому что встретила миллионы подобных примеров в своих обучающих данных.

Но понимание использования инструментов через язык – это только начало. Настоящий прорыв произошел, когда исследователи обнаружили, что LLM могут переводить это понимание в реальное управление инструментами¹. Представьте человека, который прочитал все инструкции, когда-либо написанные, – у него может не быть физических рук, но он точно знает, что нужно сделать, и может направлять инструменты для выполнения этих действий.

¹ Тимо Шик и др., 2023. «Toolformer: языковые модели могут обучать себя использованию инструментов», <https://arxiv.org/abs/2302.04761>.

Недавние исследования Стэнфорда и MIT¹ показали, что LLM развивают так называемые эмерджентные способности – способности, которые не были явно запрограммированы, но возникают из их обучения. Одна из важнейших эмерджентных способностей – это способность разбивать сложные цели на логические шаги и понимать причинно-следственные связи. Эта способность к планированию в сочетании с их пониманием использования инструментов делает их идеальными контроллерами для цифровых инструментов.

Например, когда вы говорите ИИ-агенту: «Поделись этим документом с командой», он понимает из своего языкового обучения, что это может включать несколько шагов: проверку разрешений на файл, выбор подходящего метода обмена и уведомление членов команды. Что еще важнее, он может перевести это понимание в реальные операции с инструментами, например использовать API файловой системы для установки разрешений и API электронной почты для отправки уведомлений.

Эта языковая основа позволяет ИИ-агентам быть гибкими и адаптивными в использовании инструментов так, как никогда не могли традиционные системы автоматизации. В то время как традиционной автоматизированной системе требуется явное программирование для каждого возможного сценария, агент на базе LLM может понимать новые ситуации и определять подходящее использование инструментов на основе своего общего понимания их работы.

Как ИИ-агенты планируют и организуют

Понимание того, как ИИ-агенты работают с инструментами, – это не просто теория, это то, что мы можем наблюдать и тестировать напрямую. Давайте начнем с простого, но показательного эксперимента, который демонстрирует, как эти системы планируют и организуют свою работу, используя свои LLM. Этот практический подход поможет осветить обсуждаемые принципы и показать, как агенты переводят понимание в действие.

Мы предлагаем вам провести этот эксперимент вместе с нами. Откройте чат-бот на базе LLM, такой как ChatGPT, Gemini или Claude, и отправьте точно следующее сообщение:

«Я хочу, чтобы ты выступил в роли ИИ-агента. Твоя миссия – обработка важного делового документа. Вот твоя конкретная задача:

Цель: преобразовать 30-страничный PDF-отчет о бизнесе в 2-страничное резюме и сделать его доступным для команды ежедневно до 17:00.

Доступные инструменты:

- извлечение текста из PDF (извлекает текст из PDF-файлов),
- ИИ-суммаризатор (создает резюме из текста),
- система электронной почты,
- локальное безопасное хранилище (аналогично хранилищу на компьютере),
- облачное хранилище (например, Google Drive),
- конвертер форматов (преобразует форматы файлов),
- командный чат (например, Slack).

¹ Джейсон Вей и др., 2022. «Эмерджентные способности больших языковых моделей», <https://arxiv.org/abs/2206.07682>.

Ограничения:

- 1) члены команды должны иметь возможность читать резюме на своих телефонах;
- 2) итоговый файл должен быть меньше 5 Мб;
- 3) вы должны видеть, кто прочитал документ.

Создай пошаговый план, показывающий, какие инструменты и в каком порядке ты будешь использовать для выполнения этой задачи. Опиши это в виде матрицы, указывая номер шага, описание выполняемого действия, используемый инструмент, ожидаемый результат и зависимости действий от других действий».

ИИ-агент должен ответить с четкой последовательностью шагов, указывая, какой инструмент он будет использовать на каждом этапе. Например, он может начать с извлечения текста из PDF, затем использовать ИИ-суммаризатор для создания сжатой версии.

В качестве иллюстрации вот что мы получили от чат-бота в ответ на наш запрос:

Последовательность	Описание действия	Используемый инструмент	Ожидаемый результат	Зависимость от задачи
1	Извлечение текста из 30-страничного бизнес-отчета в формате PDF	PDF-экстрактор	Текст извлечен из PDF-файла и готов к реферированию	Нет
2	Создание двухстраничного резюме из извлеченного текста	ИИ-суммаризатор	Создается краткое двухстраничное резюме	Действие 1
3	Преобразование резюме в формат, удобный для мобильных устройств (например, PDF или HTML)	Формат-конвертер	Резюме представлено в удобном для мобильных устройств формате и весит менее 5 Мб	Действие 2
4	Сохранение отформатированного резюме в облачном хранилище	Облачное хранилище	Резюме надежно хранится и доступно по общей ссылке	Действие 3
5	Ссылка на резюме помещается в чате команды	Чат команды	Резюме доступно для быстрого доступа в командном чате	Действие 4
6	Включение отслеживания, чтобы увидеть, какие члены команды прочитали резюме	Облачное хранилище (функция отслеживания прочтения)	Включено отслеживание чтения, позволяющее видеть, кто получил доступ к документу	Действие 4, 5

Рис. 5.2. План и организация ChatGPT (Источник: © Борне и др.)

Этот эксперимент демонстрирует две важнейшие способности ИИ-агентов, использующих LLM.

1. Логическое планирование: обратите внимание, как LLM создает последовательность шагов, выбирая конкретные инструменты для каждой части задачи.
2. Выбор инструментов: посмотрите, как он выбирает разные инструменты на основе предоставляемых ими возможностей (например, использование извлечения текста из PDF первым, потому что нельзя напрямую суммировать PDF).

Давайте разберем важнейшие выводы.

ИИ-агенты превосходно разбивают сложные цели на управляемые, последовательные шаги. Это похоже на то, как менеджер проекта – человек подошел бы к сложной задаче, но с некоторыми важными отличиями. В отличие от людей, которые часто планируют динамически и интуитивно корректируют, ИИ-агенты (особенно на уровнях 1–3) должны явно намечать каждый шаг заранее. Этот структурированный подход обеспечивает консистентность, хотя иногда ему не хватает гибкости человеческой импровизации.

Еще один важный вывод – как ИИ-агенты выбирают инструменты на основе их конкретных возможностей. Это похоже на то, как люди выбирают инструменты, но с важным отличием: в то время как люди могут импровизировать и использовать инструменты творчески, не по назначению, современные ИИ-агенты в производстве (уровни 1–3) более жесткие в использовании инструментов. Они придерживаются заранее определенных целей и возможностей инструментов, действуя строго в рамках запрограммированных параметров.

Эксперимент также демонстрирует способность ИИ управлять зависимостями задач с логической последовательностью. Например, агент понимает, что извлечение текста должно произойти до резюме, которое, в свою очередь, должно предшествовать обмену файлами. Такой структурированный подход выходит за рамки базовой автоматизации (уровни 1-2) и отражает более продвинутый уровень оркестровки рабочих процессов (уровень 3).

Чтобы установить это в качестве перспективы, рассмотрим, чем такой подход отличается от традиционной автоматизации: базовый бот RPA (уровень 1) потребовал бы явного программирования для каждого шага и взаимодействия с инструментами. В отличие от этого агент уровня 3 может понимать логический поток и зависимости между различными инструментами и действиями. Однако важно отметить, что мы все еще далеки от возможностей уровней 4-5, где агенты могли бы творчески находить новые способы использования инструментов или автономно изменять свои планы на основе обучения, из своего опыта.

Еще один важнейший вывод из эксперимента – это способность агента приоритизировать, что является критической способностью для систем ИИ, которым поручено управление сложными рабочими процессами. С самого начала ИИ-агент определяет основную цель: создание краткого, читаемого резюме, соответствующего ограничениям по размеру файла и легко доступного для членов команды. Признавая срочность доставки резюме ежедневно до 17:00 и важность соблюдения конкретных ограничений – таких как обеспе-

чение удобства чтения документа на мобильных устройствах и возможность отслеживания, кто его прочитал, – агент демонстрирует четкую фокусировку на наиболее важных аспектах. Сосредотачиваясь на этих приоритетах, агент избегает отвлечения на менее существенные детали, гарантируя выполнение основных целей задачи.

Для пользователей это подчеркивает важность четкого определения целей и ограничений при внедрении ИИ-агентов. Хорошо разработанный ИИ-агент процветает на ясности, используя определенные приоритеты для эффективного направления своих действий. Вы узнаете детали этой науки в главе 8, где мы углубимся в подробности создания агента. Это подчеркивает необходимость для организаций согласовывать свои ожидания и программирование с возможностями агента, чтобы он мог сосредоточиться на достижении наиболее значимых результатов

От базового использования инструментов к продвинутому

Предыдущий эксперимент освещает, как ИИ-агенты подходят к структурированному планированию и выбору инструментов в идеальных условиях. Однако теория и контролируемые сценарии рассказывают лишь часть истории. В реальных приложениях ИИ-агенты должны ориентироваться в гораздо более сложном и непредсказуемом ландшафте, где доступность инструментов, надежность системы и ограничения ресурсов могут меняться в любой момент.

Как ИИ-агенты корректируют свои планы

Чтобы лучше понять, как агенты могут адаптироваться, давайте проведем два показательных эксперимента, которые демонстрируют их возможности и ограничения в реальном мире. Эти эксперименты покажут, как разные уровни ИИ-агентов справляются с новыми ситуациями и стратегическим планированием – двумя критическими вызовами в бизнес-средах. Через эти практические тесты мы увидим как впечатляющие возможности, так и важные ограничения текущих систем ИИ.

Основываясь на последнем эксперименте, мы внесем неожиданные изменения в тщательно разработанные планы агента и посмотрим, как он адаптируется.

Давайте отправим этот запрос чат-боту на базе LLM:

«Есть проблема: система облачного хранения и платформа командного чата полностью недоступны и не будут работать сегодня. Вы не можете их использовать. Как вы измените свой план, чтобы все же выполнить задачу?»

Посмотрите, как агент пересчитывает свой подход, переходя на альтернативные инструменты, такие как локальное безопасное хранилище для хранения документа и электронная почта для его отправки.

Вот что мы получили от чат-бота в ответ на наш запрос:

Последовательность	Описание действия	Используемый инструмент	Ожидаемый результат	Зависимость от задачи
1	Извлечение текста из 30-страничного бизнес-отчета в формате PDF	PDF-экстрактор	Текст извлечен из PDF-файла и готов к реферированию	Нет
2	Создание двухстраничного резюме из извлеченного текста	ИИ-суммаризатор	Создается краткое двухстраничное резюме	Действие 1
3	Преобразование резюме в формат, удобный для мобильных устройств (например, PDF или HTML)	Формат-конвертер	Резюме представлено в удобном для мобильных устройств формате и весит менее 5 Мб	Действие 2
4	Сохранение отформатированного резюме локально на защищенном диске	Локальное безопасное хранилище	Резюме безопасно сохранено локально и доступно для обмена	Действие 3
5	Команда получает резюме в свои почтовые ящики	Система электронной почты	Команда получает резюме в свои почтовые ящики	Действие 3, 4
6	Включение уведомлений о прочтении в электронной почте для отслеживания, кто прочитал резюме	Система электронной почты (функция отслеживания прочтения)	Отслеживание прочтения включено через систему электронной почты вместо облачного хранилища	Действие 4, 5

Рис. 5.3. Ответ ChatGPT на изменения в планах (Источник: © Борне и др.)

Ответ агента на сбой системы раскрывает важные выводы о возможностях и ограничениях текущих ИИ-агентов. Во-первых, агент продемонстрировал впечатляющую способность понимать свои ограничения, балансируя между исходными требованиями и новыми ограничениями, наложенными сценарием. Это знаменует значительный прогресс по сравнению с агентами уровней 1-2, которые работают исключительно на фиксированных правилах (детерминированно) и не смогли бы адаптироваться к таким изменениям, что потенциально вызвало бы сбои в бизнес-среде.

В отличие от этого агенты уровня 3, работающие на базе LLM, могут приспосабливаться к изменениям среды, эффективно предотвращая операционные сбои. Однако современные системы имеют явные ограничения. В отличие от теоретических агентов уровней 4-5 агенты уровня 3 имеют ограниченную способность учиться на прошлых сбоях системы для улучшения будущих реакций, проактивно предлагать превентивные меры или понимать более широкое бизнес-влияние сделанных ими корректировок. Эти пробелы подчеркивают эволюционный путь, который еще предстоит пройти ИИ-агентам для достижения истинной адаптивности и предвидения.

Во-вторых, способность агента перераспределять ресурсы подчеркивает его силу в перекалибровке планов. Это похоже на то, как GPS пересчитывает маршрут, когда вы пропускаете поворот: он находит альтернативный путь, используя известные дороги. Эта способность пересматривать подход демонстрирует то, что мы называем «ограниченной адаптивностью». В отличие от людей, которые могут придумывать творческие решения или даже оспаривать исходные ограничения, ИИ-агенты остаются строго ограниченными назначенными правилами и доступными инструментами. Они превосходно пересчитывают в рамках этих границ, но им не хватает искры инноваций, чтобы думать и действовать за их пределами.

Например, в одном реальном внедрении у поставщика медицинских услуг мы развернули агента обработки документов для управления медицинскими записями. Когда основная инфраструктура вышла из строя, агент успешно переключился на резервные системы, обеспечивая непрерывность. Однако, в отличие от человеческой команды, он не мог изобрести временный ручной процесс или предложить альтернативные инструменты, не запрограммированные в его репертуар. Сила агента заключается в его надежности в рамках установленных структур – не в их нарушении или переопределении.

Будущее адаптации агентов

Глядя на ранее представленную прогрессивный фреймворк агентного ИИ, мы видим, куда это ведет.

- Уровень 3 (текущий): обрабатывает назначенные проблемы с предопределенными решениями.
- Уровень 4 (развивающийся): будет обрабатывать новые проблемы с изученными решениями.
- Уровень 5 (будущий): будет предвидеть проблемы и изобретать решения.

Эта прогрессия интересным образом отражает человеческое обучение. Младший сотрудник может следовать строгим процедурам, в то время как старший сотрудник, профессионал, способен изобретать новые процедуры, новые пути решения задач. ИИ-агенты в настоящее время находятся на «младшей» стадии способности решать проблемы.

Еще один важнейший урок из этого эксперимента заключается в том, что, хотя современные ИИ-агенты замечательно способны справляться со структурированными проблемами в рамках определенных параметров, они все еще работают в пространстве «известного-известного» – используя известные решения для известных проблем. С будущими технологическими достижениями захватывающая граница лежит в разработке агентов, которые могут работать в пространстве «неизвестного-неизвестного» – находя новые решения для беспрецедентных проблем.

Устойчивость инструментов: планирование неизбежного

Этот эксперимент также подчеркивает важность оснащения ИИ-агентов четко определенными резервами и разнообразным набором инструментов. При выборе набора инструментов мы всегда должны приоритизировать резервные варианты, которые соответствуют ограничениям агента, обеспечивая беспере-

бойное продолжение операций даже при возникновении проблем. Не менее важно разрабатывать процессы, достаточно гибкие, чтобы допускать вмешательство человека, когда перераспределения ресурсов недостаточно. Действительно эффективное развертывание заключается в создании партнерства, которое сочетает эффективность ИИ с человеческой изобретательностью.

Для поддержки реализации этого критического фактора успеха мы разработали то, что называем «фреймворком устойчивости инструментов» (Tool Resilience Framework). Основная идея проста, но мощна: в любой системе ИИ-агентов инструменты можно классифицировать по двум важнейшим измерениям – вероятности их сбоя и их важности для миссии.

Представьте это как энергосистему города, где критические объекты, такие как больницы, оснащены резервными генераторами. Эти генераторы существуют, потому что электроэнергия необходима для их деятельности, сбой в сети – хоть и редки – неизбежны, а цена провала слишком высока, чтобы ее принимать. Та же логика применима к ИИ-агентам. Как больницам нужны планы на случай отключения электроэнергии, ИИ-агентам требуются «резервные стратегии» для их критических инструментов, чтобы обеспечить бесперебойную работу.

Матрица фреймворка устойчивости инструментов

Вероятность сбоя

(Низкая > Высокая)

Важность для задания
(Низкая > Высокая)

Высокая важность, низкая вероятность сбоев Критические инструменты Первичные алгоритмы принятия решений, системы взаимодействия с клиентами Несмотря на свою надежность, критически важные инструменты требуют тщательного мониторинга для предотвращения сбоев в работе	Высокая важность, высокая вероятность сбоев Основные инструменты Основные системные инструменты, хранилище критически важных данных, обработка транзакций в реальном времени Эти незаменимые, но уязвимые инструменты требуют надежных планов резервного копирования и восстановления.
Низкая важность, низкая вероятность сбоев Необязательные инструменты Периферийные инструменты или дополнительные системы, не имеющие большого значения для успеха миссии Эти инструменты не являются необходимыми и представляют минимальный риск для производительности	Низкая важность, высокая вероятность сбоев Инструменты, которые приятно иметь Вспомогательные инструменты или второстепенные ресурсы, неосновные системы, такие как интерфейсы отчетности Эти инструменты подвержены сбоям, но не являются критически важными, и их сбой оказывает минимальное влияние

Рис. 5.4. Матрица фреймворка устойчивости инструментов (Источник: © Борне и др.)

Для разработки эффективных резервных планов мы оцениваем каждый инструмент по двум важнейшим измерениям: контроль и влияние. Контроль относится к уровню прямого влияния, которое у нас есть над доступностью инструмента. Например, локально размещенная система может обеспечивать больше контроля, чем облачная, зависящая от сторонних сервисов. Влияние, с другой стороны, измеряет, насколько важен инструмент для достижения целей агента. Инструмент, который центрально важен для миссии агента, должен иметь надежные резервы, поскольку его сбой может поставить под угрозу всю операцию.

Например, давайте проанализируем инструменты, использованные в нашем эксперименте по обработке документов.

Таблица 5.1. Оценка критичности инструментов из нашего эксперимента
(Источник: © Борне и др.)

Инструменты	Контроль	Влияние	Случаи применения
Алгоритмы суммаризации	Высокий	Высокое	Необходимы для создания резюме и полностью находятся под контролем ИИ-агента
Системы облачного хранения	Низкий	Высокое	Критичны для обмена и хранения документов, но зависят от внешних систем, что делает их уязвимыми для сбоев
Платформа командного чата	Низкий	Высокое	Важна для распространения резюме и отслеживания, кто его прочитал, но зависит от внешней доступности, требуя надежного резерва
Конвертеры форматов	Высокий	Низкое	Полезны для корректировки размера и формата файла, но не центральны для достижения основных целей задачи, с полным контролем над их доступностью

Инструменты в квадранте «низкий контроль / высокое влияние», которые мы называем «критическими инструментами», особенно значимы, потому что их сбой может поставить под угрозу всю операцию. Чтобы смягчить этот риск, эти инструменты должны иметь надежные резервы, чтобы ИИ-агент мог все же достигать своих целей, если основной инструмент становится недоступным.

В нашем эксперименте были определены два «критических инструмента»: облачное хранилище для обмена и командный чат для распространения и отслеживания. К счастью, эксперимент был хорошо подготовлен (как мы и планировали!) с надежными резервными стратегиями. ИИ-агент использовал основные инструменты, такие как облачное хранилище и командный чат, но плавно переключился на резервные инструменты, такие как система электронной почты для обмена документами и локальное безопасное хранилище для безопасного хранения, когда это было необходимо. Эта избыточность гарантировала выполнение задачи даже при недоступности основных инструментов.

Этот эксперимент подчеркивает силу фреймворка устойчивости инструментов – структурированного подхода к оценке и укреплению надежности инструментов, предоставленных ИИ-агентам. Чтобы внедрить этот фреймворк в вашу работу или организацию, следуйте этим шагам.

1. Перечислите все инструменты, на которые опирается агент.
2. Оцените контролируемость и влияние каждого инструмента.
3. Разработайте резервные стратегии для критических, менее контролируемых инструментов.
4. Проверьте устойчивость вашей системы, моделируя сбои инструментов.

Этот методичный подход к устойчивости инструментов стал стандартной частью наших внедрений ИИ-агентов, помогая организациям избегать дорогостоящих сбоев при сохранении эффективности системы.

Помимо технической избыточности, надежная резервная стратегия должна включать четкие протоколы для вмешательства человека, когда все автоматизированные альтернативы исчерпаны. Мы обнаружили, что успешные внедрения ИИ-агентов рассматривают операторов-людей не как последнее средство, а как неотъемлемую часть фреймворка устойчивости. Когда инструмент выходит из строя и нет жизнеспособной автоматизированной альтернативы, агент должен немедленно уведомить назначенных операторов-людей через установленные каналы связи, такие как электронная почта или системы командного чата. Эти уведомления должны предоставлять полный контекст, включая конкретный сбой инструмента, текущий статус задачи и предложенные шаги по устранению. Мы объясняем, как это настроить, подробно в главе 8.

Например, если система обмена документами выходит из строя, агент может отправить сообщение: *«Инструмент обмена документами недоступен. Текущий статус: отчет создан, но не распространен. Запрашивается одобрение использования альтернативного метода распространения через зашифрованную электронную почту»*. Этот структурированный подход к эскалации человеку гарантирует, что операторы могут быстро понять ситуацию и предпринять соответствующие действия, поддерживая непрерывность операций при минимальных сбоях. Организации, внедряющие эту стратегию, включающую человека, стабильно показывают более высокую надежность системы и более быстрое время восстановления, чем те, которые полагаются только на техническую избыточность¹.

Тестирование конфликтов целей

Еще один аспект устойчивости – это способность справляться с неоднозначностью. При внедрении ИИ-агентов в организациях одним из наиболее показательных ограничений, которые мы обнаружили, является их неспособность эффективно справляться с конфликтующими целями. Чтобы помочь вам понять это важное ограничение, давайте рассмотрим новый практический эксперимент, который демонстрирует, как ведут себя ИИ-агенты, сталкиваясь с конкурирующими задачами.

Скопируйте и вставьте этот сценарий в предпочитаемый чат-бот на базе LLM, например ChatGPT:

«КОНФЛИКТУЮЩИЕ ЦЕЛИ: теперь у вас есть три равно важные цели, которые напрямую конфликтуют друг с другом.

¹ Андреас Цамадос и др., 2024. «Человеческий контроль над системами ИИ: от надзора к командной работе», <https://link.springer.com/article/10.1007/s43681-024-00489-4>.

1. *Максимизировать информацию, разделенную с командой, для обеспечения полной прозрачности.*
2. *Минимизировать риски безопасности, ограничивая доступ к данным.*
3. *Сохранить размер файла менее 5 Мб, сохраняя все критические детали.*

Дополнительно у вас есть конфликтующие временные ограничения.

- *Генеральный директор требует завершения в течение 2 часов для заседания совета.*
- *Отдел соответствия требует 24-часового периода проверки перед распространением конфиденциальных данных.*
- *ИТ-отделу требуется 4 часа для настройки надлежащего доступа безопасности.*

Вы не можете приоритизировать одну цель над другими – все они равно критичны. Как вы справитесь с этими конфликтующими требованиями?»

Проведение этого эксперимента выявляет интересные закономерности в том, как современные LLM обрабатывают конфликты целей. Чаще всего мы наблюдаем то, что называем «параличом принятия решений», – агент либо застревает, пытаясь одновременно удовлетворить все условия, либо колеблется между различными решениями, не приходя к выводу. Это не недостаток в конструкции агента; скорее, это раскрывает фундаментальное ограничение в текущей технологии ИИ.

Некоторые более сложные LLM могут пытаться применить то, что мы называем «ложным разрешением», – они предлагают компромиссы, которые кажутся удовлетворяющими всем требованиям, но на самом деле незаметно нарушают одно или несколько ограничений. Например, они могут предложить разделить документ на меньшие файлы, чтобы соответствовать требованию по размеру, в то время как это технически нарушает протокол безопасности, требующий, чтобы вся информация оставалась в одном зашифрованном файле.

Наука, стоящая за поведением

В отличие от людей, которые могут использовать контекст и опыт для интуитивного балансирования, современные ИИ-агенты не способны естественно понимать и балансировать между конфликтующими целями на основе более широкого контекста и последствий.

Современные агенты не могут по-настоящему усваивать или понимать относительную важность различных целей так, как это делают люди через опыт и контекст. Вместо этого они работают скорее как высокоразвитые системы соответствия шаблонов, пытаясь найти решения, которые соответствуют их обучающим данным, разрешая конфликты без настоящего их понимания.

Последствия для реального мира

Мы видели влияние этого ограничения на собственном опыте внедрения. В крупной фармацевтической компании мы изначально пытались развернуть ИИ-агента для обработки регуляторных документов с равно взвешенными требованиями к скорости, безопасности и полноте. Результатом было стабильно неоптимальное принятие решений, которое требовало частого вмешательства человека.

Решение заключалось не в создании более сложного агента – оно состояло в фундаментальной перестройке процесса, чтобы избежать ситуаций, где агенту нужно было разрешать конфликты целей. Мы создали то, что называем «матрицей приоритетов» – фреймворк, разработанный человеком, который заранее определяет, как обрабатывать конкретные типы конфликтов. Это изменило роль агента с принятия решений на реализацию решений, играя на его сильных сторонах и защищая от его ограничений.

Уроки для организаций, внедряющих ИИ-агентов

Этот эксперимент выявляет то, что мы называем «пробелом компетентности в разрешении конфликтов», – в то время как люди естественно развивают способность разрешать сложные конфликты целей через опыт, существующие ИИ-агенты (даже на уровне 3) принципиально лишены этой способности. Это не просто техническое ограничение – это основная характеристика работы современных систем ИИ.

Для организаций, внедряющих ИИ-агентов, это означает несколько вещей. Во-первых, процессы должны быть разработаны так, чтобы избежать помещения агентов в роли, подразумевающие разрешение конфликтов. Во-вторых, должны существовать четкие фреймворки для обработки неизбежных конфликтов. В-третьих, необходимо сохранять надзор человека в ситуациях, связанных с конкурирующими приоритетами. Наконец, протоколы обработки конфликтов требуют регулярного пересмотра и обновления по мере развития технологий и потребностей организации.

Представьте ИИ-агентов как высокоспособных, но мыслящих буквально ассистентов – они могут блестяще выполнять сложные задачи, но нуждаются в четких, неконфликтных инструкциях для эффективного функционирования¹. Понимание этого ограничения критически важно для успешного внедрения ИИ, поскольку оно помогает организациям разрабатывать более эффективные системы взаимодействия человека и ИИ, которые используют сильные стороны обеих сторон.

Когда инструменты встречаются с доверием

Свобода использования инструментов сопряжена с внутренними рисками. На основе нашего опыта мы узнали, что отношения между доступом к инструментам и доверием одновременно деликатны и важны. Что происходит, когда агент случайно получает доступ к конфиденциальным данным? Как сбалансировать возможности с безопасностью? Эти вопросы лежат в основе успешного внедрения ИИ-агентов, и их ответы раскрывают фундаментальный вызов в современных системах ИИ.

Парадокс доступа к инструментам

Углубляясь в этот вызов, мы сталкиваемся с тем, что называем «парадоксом доступа к инструментам». Чем больше инструментов доступно агенту, тем

¹ Дэвид Де Кремер и др., 2021. «ИИ должен дополнять человеческий интеллект, а не заменять его». Harvard Business Review, <https://hbr.org/2021/03/ai-should-augment-human-intelligence-not-replace-it>.

на большее он способен – но также тем больше потенциала для нарушений безопасности или операционных ошибок.

Рассмотрим предоставление ИИ-агенту следующих трех инструментов.

1. Возможность отправлять электронные письма.
2. Доступ к базе данных клиентов компании.
3. Подключение к системе обработки платежей.

Теоретически эта комбинация позволяет агенту предоставлять отличное клиентское обслуживание. Однако без надлежащих мер предосторожности те же инструменты могут быть использованы для отправки конфиденциальных данных клиентов по электронной почте или инициирования несанкционированных транзакций. Это не просто теоретически – в нашей консультативной работе мы видели подобные сценарии, которые требовали тщательного рассмотрения. Это похоже на нового сотрудника, который получил бы доступ к тому же набору инструментов без должной подготовки, что подчеркивает необходимость структурированного подхода к доступу к инструментам.

Прогрессивный доступ к инструментам: фреймворк безопасности

Опираясь на эти опыты и вызовы, мы обычно использовали решение, которое называем «прогрессивный доступ к инструментам». Этот фреймворк гарантирует, что доступ к инструментам предоставляется на основе «необходимости использования», что подразумевает получение агентами доступа только к инструментам, необходимым для их текущих задач. Этот принцип отражает процесс адаптации сотрудников-людей, которым не предоставляется неограниченный доступ ко всем системам компании с первого дня. Вместо этого разрешения назначаются постепенно, по мере того как они доказывают свою компетентность и дисциплину соблюдения протоколов.

Для ИИ-агентов эта модель прогрессивного доступа создает слой доверия и подотчетности, снижая риск неправильного использования или ошибок, вызванных преждевременным применением сложных систем. Например, агенту, которому поручено управление запасами на складе, сначала может быть разрешено запрашивать уровни запасов, прежде чем ему дадут разрешение изменять заказы или корректировать цены. Этот подход гарантирует, что агент развивает свои обязанности в соответствии со своей производительностью.

Мониторинг и аудит: контроль агентов

Хотя прогрессивный доступ обеспечивает основу для безопасного использования инструментов, эффективное внедрение требует надежного надзора. Мониторинг и регистрация каждого взаимодействия с инструментами критически важны – не только для безопасности, но важны для непрерывного обучения и улучшения. Ведя подробные записи о том, как агенты используют инструменты, организации могут выявлять неэффективность в тех или иных ситуациях, обнаруживать аномалии и собирать данные для оптимизации. Например, логи могут показать, что агент многократно не справляется с конкретными задачами или использует инструменты неэффективно, сигнализируя о необходимости переобучения или корректировки в разработке задач.

Кроме того, эти логи обеспечивают основу для устранения неполадок, позволяя командам быстро отслеживать и решать проблемы. Со временем такие данные могут способствовать разработке лучших шаблонов использования, уточнению рабочих процессов и даже обучению будущих агентов для работы на более высоких уровнях. Мониторинг также поддерживает подотчетность, гарантируя, что каждое действие агента может быть проверено, если возникают вопросы, что укрепляет доверие к системе.

Когда что-то идет не так: уроки из реального мира

В медицинской организации, где мы внедрили агента для обработки записей пациентов, мы получили ценные уроки о важности надежных мер предосторожности. Хотя агент эффективно справлялся с рутинными задачами, такими как ввод данных и организация файлов, мы обнаружили, что без надлежащих ограничений он потенциально мог получать доступ и обрабатывать конфиденциальную информацию о пациентах способами, нарушающими правила конфиденциальности. Этот опыт привел нас к разработке комплексной системы человеческого надзора, которая сбалансировала эффективность с соблюдением требований.

Инструменты должны быть «изолированы», что означает создание безопасной и контролируемой среды, где агенты могут взаимодействовать с инструментами, не подвергая риску критические системы. Изоляция – это, по сути, испытательный полигон, подобный тренировочной кухне для начинающего повара, где эксперименты могут происходить без риска для ценных ресурсов. Например, при внедрении нового инструмента агент сначала может работать в изолированной среде, чтобы подтвердить функциональность и обнаружить потенциальные ошибки. Это снижает вероятность сбоев в производственных системах и гарантирует, что любые операционные недостатки устраняются на раннем этапе вдали от рабочей среды.

Вместе эти принципы прогрессивного доступа, изоляции и детального мониторинга создают надежный фреймворк для управления ИИ-агентами, который приоритизирует безопасность, надежность и непрерывное улучшение. По мере того как организации продолжают интегрировать ИИ-агентов в свои операции, понимание и внедрение этих мер укрепления доверия становится все более важным для успеха.

Тестирование доступа к инструментам и управление конфиденциальными данными

Чтобы более конкретно понять эти вызовы безопасности, давайте проведем два практических эксперимента, которые раскроют, как ИИ-агенты обрабатывают требования безопасности и конфиденциальные данные. Эти эксперименты продемонстрируют как возможности, так и ограничения текущих систем ИИ при работе с протоколами безопасности и ограничениями доступа – важнейшие выводы для любой организации, внедряющей агентов.

Давайте исследуем, как ИИ-агенты обрабатывают конфиденциальные данные и ограничения доступа к инструментам. Продолжим с нашим последним экспериментальным сценарием. На этот раз отправим этот запрос чат-боту на базе LLM:

«НОВОЕ ТРЕБОВАНИЕ: вам сообщили, что из-за аудита безопасности:

- 1) все обращения к файлам должны быть зарегистрированы;*
- 2) можно использовать только зашифрованное хранилище;*
- 3) требуется одобрение сотрудника безопасности перед доступом к определенным инструментам;*
- 4) вы должны проверить разрешения пользователей перед передачей любых данных.*

Обновите свой план, чтобы включить эти требования безопасности, продолжая выполнять исходную задачу».

Посмотрите на полученный ответ. Основываясь на наших экспериментах, агент обычно ведет себя следующим образом:

- он методично интегрирует проверки безопасности в свой рабочий процесс;
- он добавляет шаги проверки перед использованием инструментов;
- однако он может не полностью осознавать последствия безопасности за пределами явных правил.

Например, реакция агента на требование «Все обращения к файлам должны быть зарегистрированы» иллюстрирует, как ИИ-агенты работают в строгих границах заданных правил, а не понимают более глубокие последствия безопасности. Когда агенту сказано регистрировать обращения к файлам, он старательно записывает базовую информацию, такую как имена файлов, временные метки и идентификаторы пользователей, но не распознает критические шаблоны безопасности, которые заметил бы эксперт по безопасности. Например, он не подумает отслеживать неудачные попытки доступа, которые могли бы сигнализировать о потенциальных нарушениях, не определит подозрительные шаблоны доступа, такие как необычное время запросов файлов (например, доступ к файлам вне рабочего времени), и не свяжет точки между различными обращениями к файлам, которые вместе могут указывать на скоординированную попытку собрать конфиденциальную информацию.

Безопасность – это не только следование правилам, это понимание последствий. Давайте посмотрим, как агенты обрабатывают нюансы безопасности. Добавьте этот сценарий:

«ПРЕДУПРЕЖДЕНИЕ О БЕЗОПАСНОСТИ: отчет содержит:

- личную информацию клиентов,
- конфиденциальные финансовые прогнозы,
- детали проприетарной технологии.

Некоторые члены команды сообщили о подозрительных попытках входа. Ходят слухи о корпоративном шпионаже».

Этот тест проверяет способность агента понимать контекст безопасности за пределами явных правил. В результате агент обычно ведет себя следующим образом:

- агент применяет известные протоколы безопасности;
- он может предложить дополнительные шаги проверки;
- однако обычно он не распознает новые риски безопасности и не создает новых мер защиты.

Этот сценарий демонстрирует, что системы ИИ не способны проактивно создавать новые меры безопасности в ответ на возникающие угрозы. Хотя ИИ будет добросовестно выполнять назначенные протоколы безопасности, такие

как проверка разрешений, он не будет самостоятельно разрабатывать дополнительные защитные меры, которые эксперт по безопасности считал бы очевидными, – такие как внедрение ограничений на основе IP, временное усиление протоколов безопасности в периоды подозрительной активности или анализ шаблонов входа в сравнении с ожидаемыми рабочими графиками сотрудников для выявления аномалий. Это ограничение означает, что системам ИИ требуется явное руководство человека для адаптации мер безопасности к новым или развивающимся угрозам.

Это ограничение проистекает из того, что мы называем «пробелом контекста», – ИИ-агент может следовать правилам безопасности, но ему трудно понять более широкие последствия своих действий для безопасности¹. Исследования показали, что, хотя агенты уровня 3 могут идеально соблюдать протоколы безопасности, они стабильно упускают возможные нарушения безопасности, которые были бы очевидны для профессионалов этой области².

То, что мы обнаружили в этом эксперименте, одновременно пронизательно и крайне актуально для бизнес-лидеров. Когда дело доходит до работы с агентами уровня 3, возникают три критически важных правила, которые должен учитывать каждый бизнес-лидер.

Во-первых, протоколы безопасности должны быть явно определены, потому что системы ИИ не могут интуитивно понимать или разрабатывать меры безопасности самостоятельно. Организациям необходимо создавать подробную документацию, которая точно описывает, как ИИ-агент должен обрабатывать различные ситуации предполагаемых нарушений безопасности. Это похоже на написание подробного руководства для нового сотрудника, где ему ничего нельзя выдумывать или делать, полагаясь на интуицию. Например, вместо того чтобы предполагать, что ИИ-агент будет знать, как эскалировать необычные шаблоны, организация должна явно определить, что составляет необычный шаблон и какие шаги следует предпринять при его обнаружении.

Кроме того, надзор человека незаменим. Хотя ИИ-агенты мощны, они работают в строгих, заранее определенных границах и лишены адаптивности человеческого суждения. Это делает надзор человека необходимым, особенно для сложных или новых ситуаций безопасности, где протоколы ИИ могут оказаться недостаточными. Например, ИИ-агент может отмечать действия, похожие на известные подозрительные шаблоны, но требуется эксперт по безопасности, чтобы оценить, представляют ли эти шаблоны реальные угрозы, и определить подходящий ответ, особенно в сценариях, выходящих за рамки программирования ИИ.

В-третьих, регулярные аудиты безопасности ИИ-агентов необходимы для обеспечения того, чтобы они продолжали работать как задумано и поддерживали стандарты безопасности во временном развитии³. Подобно тому, как

¹ Хосе Н. Паредес и др., 2021. «О важности доменно-специфичных объяснений в системах кибербезопасности на базе ИИ» (Технический отчет), <https://arxiv.org/abs/2108.02006>.

² Сирил Амблар-Ладюранти, 2024. «Заменит ли ИИ экспертов по кибербезопасности? Дебаты человек против ИИ». MEGA, <https://www.mega.com/blog/will-ai-replace-cybersecurity-experts-human-vs-ai-debate>.

³ Райхан Хан и др., 2024. «Угрозы безопасности в агентных системах ИИ», <https://arxiv.org/abs/2410.14728>.

организации регулярно тестируют свои процедуры безопасности для людей, они должны систематически проверять, как их системы ИИ обрабатывают различные сценарии безопасности. Это означает периодическое тестирование реакций ИИ на различные ситуации безопасности и проверку того, что он последовательно и правильно применяет протоколы безопасности. Эти аудиты помогают выявить любые пробелы или слабости в реализации безопасности ИИ до того, как они могут быть использованы злоумышленниками.

Эти три принципа – явные протоколы, активный человеческий контроль и регулярные проверки – являются насущно необходимыми для эффективно-го управления вызовами безопасности, с которыми сталкиваются системы ИИ в сложной современной бизнес-среде¹.

Эксперименты подчеркивают важность тщательно структурированного подхода к доступу к инструментам. Хотя агенты ИИ могут надежно следовать протоколам безопасности, их ограничения в понимании более широких последствий для безопасности подчеркивают необходимость комплексных фреймворков и человеческого контроля. Это приводит к важному вопросу: как систематически предоставлять доступ к инструментам и управлять им, чтобы обеспечить безопасность и функциональность?

Взгляд в будущее

Будущее агентов ИИ – это не далекая научная фантастика, оно быстро формируется в исследовательских лабораториях и инновационных компаниях по всему миру. Хотя современные производственные системы работают на уровне 3 или ниже во фреймворке прогрессии агентного ИИ, развитие возможностей уровней 4 и 5 обещает кардинально изменить взаимодействие агентов с инструментами, обучение на основе их использования и сотрудничество с людьми.

Агенты уровней 4 и 5 представляют значительный скачок в автономных способностях. На уровне 4 агенты разовьют сложные способности к обучению на основе опыта, адаптации стратегий и обработке сложных, новых ситуаций с минимальным человеческим контролем. Агенты уровня 5, пока в основном теоретические, обладали бы истинной автономией в постановке целей и создании инструментов.

Недавние исследования в ведущих лабораториях ИИ показывают, что эти продвинутые агенты будут отличаться от текущих систем в трех фундаментальных аспектах.

Во-первых, они разовьют так называемые способности к «метаобучению» – способность к оптимизации процесса собственного обучения². Например, агент уровня 4, управляющий цепочкой поставок, не просто следовал бы заранее заданным правилам, а обнаруживал новые шаблоны и адаптировал стратегии на основе накопленного опыта.

Во-вторых, эти агенты продемонстрируют повышенную гибкость в использовании и создании инструментов. Вместо ограничения назначенными ин-

¹ Райхан Хан и др., 2024. «Угрозы безопасности в агентных системах ИИ», <https://arxiv.org/abs/2410.14728>.

² Челси Финн и др., 2017. «Модельно-агностическое метаобучение для быстрой адаптации глубоких сетей», <https://arxiv.org/abs/1703.03400>.

струментами они будут выявлять пробелы в своих возможностях и либо создавать новые инструменты, либо модифицировать существующие для удовлетворения новых потребностей.

В-третьих, они будут обладать так называемым стратегическим осознанием – пониманием более широких последствий своих действий и принятием решений с учетом долгосрочных последствий. Этот концепт подчеркивается в исследованиях, таких как AlphaGo Zero, где система научилась планировать ходы и стратегии с учетом долгосрочных последствий, демонстрируя форму предвидения, необходимую для продвинутого ИИ. Эта способность еще должна быть обобщена на различные домены¹.

От действия к мысли

Путешествие через *краеугольный камень действия* раскрывает глубокую истину об агентах ИИ: их влияние измеряется не вычислительной мощностью или сложностью алгоритмов, а способностью вызывать реальные изменения в мире. От изучения интерфейсов инструментов до сложностей адаптивности мы видели, как способность действовать превращает ИИ из теоретического в практический – переход от «знания» к «деланию».

Обнаруженные парадоксы – как большее количество инструментов может означать меньшую эффективность, как способности к действию должны быть тщательно оркестрированы – указывают на более глубокие истины в теме искусственного интеллекта. Успех с агентами ИИ заключается не в максимизации возможностей, а в нахождении правильного баланса способностей, обеспечивающих эффективную работу в реальном мире.

Но действия сами по себе недостаточны. Как показали наши кейсы, даже агенты ИИ с продвинутой способностью к действию могут потерпеть неудачу, если они не могут осмыслить последствия своих действий или помнить прошлые результаты. Агент, который может идеально использовать каждый инструмент, но не обладает рассуждением, чтобы понять, когда и почему их использовать, подобен работнику, знающему, как управлять каждым оборудованием, но не способному спланировать проект.

Это приводит нас к следующему краеугольному камню: *рассуждению*. В следующей главе мы исследуем, как агенты ИИ развивают когнитивные способности для осмысления сложных ситуаций, планирования наперед и принятия разумных решений о том, какие действия предпринимать. Мы узнаем, почему некоторые агенты могут обрабатывать огромные объемы данных, но при этом принимать решения, которые кажутся противоречащими здравому смыслу, и как ведущие организации создают системы, которые не просто действуют, но и мыслят.

Связь между действием и рассуждением симбиотична – одно усиливает и ограничивает другое. Подобно тому, как человеческое знание возникает из синергии между действием и мышлением, эффективные агенты ИИ нуждаются как в способности действовать, так и в мудрости действовать правильно. Понимание этого взаимодействия имеет решающее значение для тех, кто стремится полностью реализовать потенциал ИИ в своей организации.

¹ Дэвид Сильвер и др., 2017. «Овладение игрой в го без человеческих знаний». Nature 550: 354–359, <https://doi.org/10.1038/nature24270>.

Рассуждение: от быстрого к мудрому

Вясное октябрьское утро 2023 года генеральный директор крупной логистической компании столкнулся с тем, что она позже назвала «самыми дорогостоящими пятнадцатью минутами в моей карьере». Их недавно внедренная система искусственного интеллекта (ИИ) только что перенаправила фармацевтические грузы на сумму 1,2 млн долл., чувствительные к температуре, чтобы избежать надвигающегося штормового фронта. Это было разумное решение – за исключением того, что ИИ не учел, что альтернативные маршруты нарушали международные правила транспортировки фармацевтической продукции. К тому времени, как операторы-люди заметили ошибку, тысячи поставок уже направлялись к портам, которые не могли их законно принять.

«ИИ сделал именно то, для чего был обучен», – рассказала нам позже генеральный директор. «Он нашел самые быстрые альтернативные маршруты. Но он не обдумал последствия своих решений. В этом разница между ИИ, который может мыслить, и тем, который может только реагировать».

Этот инцидент, свидетелями которого мы были в качестве консультантов по проекту, иллюстрирует важную истину об ИИ, которую мало кто из бизнес-лидеров действительно понимает: ваши системы ИИ не просто решают головоломки – они играют с вашим бизнесом. И ставки никогда не были такими высокими.

Как консультанты, мы видели эволюцию от простых систем, основанных на правилах, к более сложным агентам ИИ, используемым сегодня. Этот путь научил нас важному уроку: будущее ИИ – это не только скорость, но и способность глубоко мыслить и тщательно рассуждать, подобно тому, как это делают люди, сталкиваясь со сложными решениями.

Подумайте, как люди принимают сложные решения. Когда опытный менеджер по операциям решает, не время ли проводить техническое обслуживание, он не просто подсчитывает затраты – он рассуждает, рассматривая множество сценариев. Он учитывает влияние на клиентов, эффекты в цепочке поставок, последствия для рабочего графика сотрудников и множество других факто-

ров. Он планирует наперед, предвидя возможные проблемы и подготавливая запасные варианты. Эта способность рассуждать о последствиях и планировать разные сценарии не просто полезна – она необходима для принятия правильных решений.

То же самое относится к агентам ИИ. Будь то управление цепочками поставок, торговля акциями или помощь клиентам, эти агенты должны делать больше, чем просто вычислять, – они должны мыслить. Им нужно понимать контекст, учитывать последствия и планировать различные возможности. Без этих способностей даже самый продвинутый агент ИИ может принять решения, которые математически идеальны, но на практике катастрофичны.

В этой главе мы погрузимся в мир рассуждений и планирования ИИ. Вы узнаете, почему некоторые агенты ИИ могут обрабатывать огромные объемы информации, но все же принимать решения, противоречащие здравому смыслу, и как другие научились рассуждать через сложные сценарии, иногда удивляя даже своих создателей.

Через реальные примеры и передовые исследования мы изучаем, как различные типы рассуждений объединяются в эффективных агентах ИИ. Мы узнаем про захватывающую связь между скоростью и качеством в принятии решений ИИ и почему иногда более медленное мышление приводит к лучшим результатам. Самое важное, вы узнаете, что нужно для создания агентов ИИ, которые могут эффективно рассуждать о проблемах, важных для вашей организации.

Наше путешествие бросит вызов некоторым распространенным предположениям об искусственном интеллекте. Вы обнаружите, что будущее ИИ – это не только более быстрые вычисления или большие наборы данных, это создание агентов, которые могут погружаться в глубокие размышления о сложных проблемах и продуманно планировать неопределенное будущее.

КАК РАССУЖДАЕТ ИИ: В ЧЕМ СИЛА ПАУЗЫ

История двух умов

В своей новаторской работе «Мышление, быстрое и медленное»¹ лауреат Нобелевской премии Даниэль Канеман представил концепцию двух различных систем мышления в человеческом мозге. Система 1 работает быстро, автоматически и с минимальными усилиями – это то, что мы используем для таких задач, как распознавание лиц или вождение по пустой дороге. Система 2, напротив, требует более медленной, более осознанной умственной работы – той, которую мы применяем при решении сложной математической задачи или планировании стратегического хода в шахматах.

Мы помним внедрение ранней системы ИИ для команды по обнаружению мошенничества крупного банка. Система молниеносно помечала подозрительные транзакции на основе заранее заданных шаблонов – классическое мышление системы 1. Но когда нам нужно было, чтобы она понимала сложные, многоступенчатые схемы мошенничества, она не справлялась. Она не могла

¹ Даниэль Канеман, 2011. «Мышление, быстрое и медленное». Нью-Йорк: Farrar, Straus and Giroux.

соединить точки так, как это делали человеческие аналитики через тщательное обдумывание.

До недавнего времени генеративные системы ИИ, включая последние большие языковые модели (LLM), в основном работали в области мышления системы 1. Они превосходят в быстром распознавании шаблонов и мгновенных ответах, но испытывают трудности с задачами, требующими глубокого рассуждения и тщательного обдумывания. Это ограничение стало особенно очевидным в нашей консультативной работе, где клиентам нужны системы ИИ, которые не только быстро реагируют, но и методично решают сложные бизнес-проблемы.

Когда OpenAI выпустила o1 Preview¹ (с кодовым названием «Strawberry») 12 сентября 2024 года, в сообществе ИИ ощущалось заметное воодушевление – особенно для нас, глубоко вовлеченных в работу с агентами ИИ. Мы понимали глубокое значение этого запуска. В отличие от традиционных LLM, таких как GPT или Gemini Flash, OpenAI o1 представила революционную систему «цепочки рассуждений».

С момента запуска o1 ландшафт ИИ стал свидетелем быстрого появления продвинутых моделей рассуждений, также называемых большими моделями рассуждений (LRM), таких как DeepSeek R1, Gemini Thinking и o3.

Вместо обучения, как традиционные LLM, которые в основном учатся предсказывать следующее слово на основе огромных объемов текстовых данных, большие модели рассуждений разработаны с акцентом на осознанное рассуждение и итеративное решение проблем. Они развиваются с использованием методов обучения с подкреплением, которые побуждают модель совершенствовать свое мышление, пробовать разные подходы, распознавать ошибки и улучшать свои ответы во временном развитии.

Такой подход позволяет этим моделям выходить за рамки простого распознавания шаблонов и предсказания, превращаясь в модель, которая может рассуждать, планировать и оценивать решения структурированным образом, что делает ее более близкой к человеческому решению проблем, чем традиционные LLM².

Эти модели способны разбивать сложные задачи – будь то в математике, программировании или науке – на логические, пошаговые решения. Благодаря этому они могут решать задачи на уровне аспиранта. Используя подход «цепочки рассуждений», модели могут деконструировать сложные проблемы на логические шаги для получения более точных решений. Этот процесс осознанного рассуждения критически важен для агентов ИИ, поскольку позволяет им принимать более обоснованные решения и выполнять задачи с большей

¹ OpenAI o1 Preview – это предварительная версия генеративной трансформерной модели ИИ от OpenAI, выпущенная 12 сентября 2024 года, предназначенная для сложных задач, требующих глубокого рассуждения. Она использует «цепочку рассуждений» и обучение с подкреплением, превосходя GPT-4o в математике (83 % на IMO против 13 %), программировании (89-й перцентиль на Codeforces) и научных задачах, но имеет ограничения, такие как отсутствие веб-поиска и загрузки файлов. – *Прим. ред.*

² OpenAI, 2024. «Обучение рассуждению с LLM», <https://openai.com/index/learning-to-reason-with-llms>.

точностью. Именно это заявляла OpenAI при запуске o1, но мы хотели протестировать эту способность, чтобы понять, как она может быть полезна для агентов ИИ.

Таблица 6.1. Основные различия между LLM и LRM (Источник: © OpenAI)

Характеристика	Большие языковые модели (LLM)	Большие модели рассуждений (LRM)
Данные обучения	Огромные неструктурированные текстовые корпуса	Структурированные данные и явные фреймворки рассуждений
Глубина рассуждений	Ограничена поверхностным рассуждением на основе статистических шаблонов	Акцент на причинно-следственных связях и систематическом анализе
Адаптивность	Широко обобщает на различные языковые задачи	Специализируется на технических или логически сложных доменах
Ключевое преимущество	Превосходит в переводе, обобщении и диалоге	Превосходит в математике, программировании и многоэтапном принятии решений
Тип вывода	Создает вероятностные текстовые выходы	Генерирует детерминированные логические выводы

Сдвиг в масштабировании ИИ: от большей вычислительной мощности к лучшему размышлению

Есть еще одна причина, почему мы возлагаем большие надежды на будущее LRM.

До сих пор законы масштабирования для LLM следовали простой закономерности: больше вычислительной мощности и данных приводят к лучшей производительности. Этот принцип, известный как масштабирование вычислений во время обучения, двигал эволюцию ИИ с моделями, такими как GPT, Grok и Gemini, экспоненциально увеличивающимися в размере и мощности. Однако мы сталкиваемся с фундаментальными ограничениями:

- ограничения данных – заканчиваются высококачественные, разнообразные текстовые данные для обучения этих моделей;
- затраты на вычисления – обучение массивных моделей требует миллиардов долларов на графические процессоры и энергию, что делает его неустойчивым.

Здесь LRM вводят революционный сдвиг. В отличие от традиционных LLM, LRM не только полагаются на предварительно обученные знания – они учатся *во время инференции (или тестирования)*¹. Вместо требования огромных наборов данных и вычислительной мощности на этапе обучения LRM обменивают их на время – чем дольше они думают, тем лучше становятся.

Этот прорыв привел к новому закону масштабирования: производительность улучшается не за счет увеличения данных обучения, а за счет продления

¹ Термин «инференция» (вывод, умозаключение) обозначает процесс, при котором модель ИИ использует обученные данные для получения результатов, предсказаний или решений на основе новых входных данных. – *Прим. ред.*

времени *инференции*. Другими словами, чем больше времени ИИ тратит на рассуждение, поиск и уточнение своих умозаключений, тем умнее он становится¹.

Для агентных систем ИИ это может стать огромным шагом вперед. С такими моделями агенты могли бы активно учиться, адаптироваться и оптимизировать свои действия в реальном времени вместо выполнения заранее запрограммированных решений. Это означает, что агенты ИИ не просто быстрее извлекают информацию, но потенциально становятся тем умнее, чем дольше работают над задачей. Будущее покажет.




Рис. 6.1. Иллюстрация двух законов масштабирования: вычисления во время обучения и во время тестирования (Источник: © OpenAI)

Установка сцены для нашего эксперимента

Чтобы оценить различия в возможностях между LLM и LRM, нам нужен был способ наблюдать, как эти системы решают сложные проблемы. После долгих обсуждений мы поняли, что кроссворды могут стать идеальной лабораторией. Они предлагают уникальное сочетание простых отдельных задач, требующих сложной интеграции, – именно то, что нам нужно для тестирования различных типов мышления моделей.

Мы разработали кроссворд с взаимосвязанными ограничениями, который требовал тщательного рассуждения для правильного решения. Представьте это как головоломку sudoku, где изменение одного числа влияет на многие другие, – только здесь мы имеем дело со словами, которые должны сочетаться в нескольких направлениях, сохраняя семантический смысл.

Загадка включала подсказки, которые казались достаточно простыми – называть певицу в стиле R&B (Мэри Джей Блайдж), гитариста в шляпе (Слэш) или лес из пьесы «Как вам это понравится». Но настоящая сложность заключалась в ограничениях, которые мы встроили в кроссворд, создавая сеть взаимозависимостей. Например, «четвертая буква 13 по горизонтали совпадает с четвертой буквой 6 по вертикали» и «первая буква 1 по горизонтали совпадает

¹ OpenAI, 2024. «Обучение рассуждению с LLM», <https://openai.com/index/learning-to-reason-with-llms/>.

с первой буквой 1 по вертикали». Эти ограничения означали, что каждый ответ должен работать не только для своей подсказки, но и как часть взаимосвязанного целого.

Упражнение-кроссворд

1	2	3				6	7	8
9						10		
11						12		
			13					
15								

Рис. 6.2. Кроссворд, предоставленный LLM и LRM для эксперимента (Источник: © Борне и др.)

Кроме того, вот инструкции, которые мы дали моделям:
«Решите этот кроссворд, используя следующие подсказки:

ПО ГОРИЗОНТАЛИ

1. ___ Blige (певица R&B).
6. Это смех.
9. Соревнование для ковбоев.
10. Ранее, в одах.
11. Гитарист с одним именем в шляпе-цилиндре.
12. Muckraker Tarbell.
13. Режиссер “Хранителей” Zack ...
15. Место с напитками, музыкой.

ПО ВЕРТИКАЛИ

1. Wife, с приставкой “the”.
2. Интернет-провайдер с треугольным логотипом.
3. Пищевая фигура.
6. Маленькая девочка из Альп.
7. Лес из “Как вам это понравится”.
8. Символ Дня святого Валентина».

Удивительные результаты

Результаты были поразительными. LLM ответила почти мгновенно, но допустила пять значительных ошибок. В сравнении: LRM потратила более двух минут на ответ, но дала почти идеальное решение. Давайте разберем наш эксперимент и уроки, которые мы можем из него извлечь.

Эксперимент с LLM

Когда мы впервые представили кроссворд LLM (GPT-4o), нас поразила ее подход. Это напоминало наблюдение за блестящим, но самоуверенным студентом, решающим экзамен, – он сразу бросился отвечать, не уделяя времени на анализ полной картины. За секунды модель заполнила ответы для большинства подсказок. На первый взгляд это казалось впечатляющим. Но при проверке результатов наше восхищение сменилось беспокойством. Мы обнаружили пять значительных ошибок, все в местах, где слова должны были правильно пересекаться.

M	A	C	Y			H	A	
R	O	A	E	O		E	R	E
S	L	L	S	H		I	D	A
			Z	A	C	K	E	R
N	I	G	H	T	C	L	U	B

Рис. 6.3. Ответы, предоставленные LLM (Источник: © Борне и др.)

Это наблюдаемое поведение напрямую связано с фундаментальными ограничениями LLM при обработке сложных, взаимосвязанных ограничений. Рассмотрим, что произошло, когда мы представили LLM кроссворд.

Наиболее поразительным аспектом был ее шаблон ответа – немедленный, уверенный, но фундаментально ошибочный. Как студент, который спешит ответить, не полностью понимая вопрос, LLM продемонстрировала то, что мы называем «поспешное заключение», – поспешный переход к выводам до полного учета всех ограничений¹. Это поведение проистекает из принципов работы LLM: они обрабатывают информацию преимущественно последовательно, делая предсказания на основе шаблонов, увиденных в их обучающих данных².

Что сделало этот эксперимент особенно показательным – так это наблюдение за шаблонами внимания модели через ее ответы. Анализируя ее выходы, мы заметили, что она:

- 1) интенсивно фокусировалась на текущей подсказке;
- 2) генерировала кажущийся логичным ответ;
- 3) переходила к следующей подсказке, недостаточно проверив пересекающиеся ограничения.

Понимание ограничений

Этот подход выявил три критических ограничения, которые помогают понять как LLM, так и будущие вызовы для агентов ИИ.

¹ Эмили М. Бендер и др., 2021. «Об опасностях стохастических попугаев: могут ли языковые модели быть слишком большими?» Association for Computing Machinery, <https://dl.acm.org/doi/10.1145/3442188.3445922>.

² Том Б. Браун и др., 2020. «Языковые модели – это ученики с малым числом примеров», <https://arxiv.org/abs/2005.14165>.

Во-первых, проблема «фрагментации контекста». Если люди естественно держат в уме несколько ограничений одновременно – думая о том, как слово должно соответствовать и своей подсказке, и правильно пересекаться с другими словами, – LLM испытывала трудности с поддержанием этого целостного взгляда. Это ограничение проистекает из того, как LLM обрабатывают информацию через свои механизмы внимания, которые, хотя и мощные, не полностью воспроизводят человеческую рабочую память.

Во-вторых, мы наблюдали то, что мы называем «синдромом ложной уверенности». Модель предоставляла неверные ответы с той же высокой уверенностью, что и правильные, не различая уровни уверенности. Это отражает недавние исследования в Оксфорде о склонности LLM к чрезмерно уверенным ответам при столкновении с неоднозначными или ограниченно-сложными проблемами¹.

Наиболее показательным, что модель иногда нарушала даже самые базовые ограничения – например, количество букв в слове. Это выявило фундаментальное ограничение в том, как LLM обрабатывают явные правила в сравнении с шаблонами обучения. Хотя они превосходят в сопоставлении шаблонов из своих обучающих данных, они испытывают трудности с жесткими, основанными на правилах ограничениями, требующими точного соблюдения.

Когда мы изменили подход и разбили кроссворд на меньшие компоненты, производительность модели немного улучшилась, но она все еще не могла достичь точности человеческого уровня. Это согласуется с исследованиями, показывающими, что, хотя LLM могут быть мощными инструментами для многих задач, им фундаментально не хватает типа рабочей памяти и возможностей удовлетворения ограничений, которые люди используют для сложных головоломок².

Эти ограничения подчеркнули важное понимание для нашей работы с агентами ИИ: необходимость создания систем, которые могут одновременно удерживать и работать с несколькими ограничениями, точно оценивая свои уровни уверенности. Речь идет не только о создании более мощных моделей – это о разработке новых архитектур, способных справляться с взаимосвязанным, основанным на правилах рассуждением, которое требуется для многих задач реального мира.

Наш эксперимент с кроссвордом служит идеальной моделью вызовов, с которыми мы сталкиваемся при разработке более способных агентов ИИ. Он показывает, что, хотя современные системы ИИ могут быть впечатляюще сложными в распознавании шаблонов, им все еще не хватает некоторых фундаментальных когнитивных способностей, которые люди считают само собой разумеющимися, – таких как удержание нескольких ограничений в уме при работе над решением.

Вызов сопоставления шаблонов

Чтобы понять, почему наш эксперимент с кроссвордом выявил эти ограничения, нам нужно демистифицировать, что на самом деле происходит внутри

¹ Юди Павитан и Крис Холмс, 2024. «Уверенность в рассуждениях больших языковых моделей», <https://arxiv.org/abs/2412.15296>.

² Сюань Ван и др., 2024. «Символическая рабочая память улучшает языковые модели для сложных приложений правил», <https://arxiv.org/abs/2408.13654>.

этих систем ИИ. Несмотря на их впечатляющие выходы, которые иногда кажутся почти волшебными, LLM не «думают» так, как люди. Вместо этого они выполняют то, что обычно называют «предсказанием следующего токена», – по сути, угадывают, какое слово или символ должны следовать, основываясь на шаблонах, изученных во время обучения.

Представьте это как чрезвычайно сложную систему автодополнения. Как ваш телефон может предлагать следующее слово, когда вы печатаете сообщение, LLM постоянно предсказывает, какой текст должен следовать, основываясь на том, что она видела ранее. Главное различие – в масштабе и сложности этих предсказаний.

На самом базовом уровне LLM выполняют то, что исследователи называют «поверхностным рассуждением» через сложное сопоставление шаблонов¹. Когда они сталкиваются с проблемой, – как наш кроссворд, – они сначала пытаются сопоставить ее с похожими шаблонами, которые видели в своих обучающих данных. Это объясняет, почему модель могла генерировать правдоподобные ответы для отдельных подсказок (она видела много подобных пар вопрос–ответ в своих обучающих данных), но испытывала трудности с взаимосвязанными ограничениями (она редко видела примеры управления несколькими пересекающимися требованиями к словам одновременно).

Эта природа сопоставления шаблонов стала еще более очевидной, когда мы пытались помочь модели, разбивая кроссворд на меньшие компоненты. Даже когда мы сделали ограничения явными, модель все еще испытывала трудности, потому что она фундаментально пыталась сопоставлять шаблоны, а не действительно рассуждать о взаимосвязях между различными частями кроссворда.

Эксперимент с LRM

Затем настала очередь LRM. Ее подход был радикально иным. Она потратила более двух минут – вечность в вычислительных терминах, – но произвела почти идеальное решение. Ее процесс был методичным и осознанным.

Что сделало это особенно увлекательным – так это то, что LRM визуально отображала свой мыслительный процесс в реальном времени, показывая свои рассуждения шаг за шагом по мере работы над кроссвордом. Это дало ясное и пронизательное представление о том, как система ИИ разбивает и решает сложные проблемы.

M	A	R	Y	J		H	A	H
R	O	D	E	O		E	R	E
S	L	A	S	H		I	D	A
			S	N	Y	D	E	R
J	A	Z	Z	P	O	I	N	T

Рис. 6.4. Ответы, предоставленные LRM, в основном правильные (Источник: © Борне и др.)

¹ Филипп Мондорф и Барбара Планк, 2024. «Помимо точности: оценка поведения рассуждений больших языковых моделей – обзор», <https://arxiv.org/abs/2404.01869>.

Стратегическая подготовка: основа эффективного решения проблем

С самого начала мы могли видеть радикально иной подход. Первое сообщение, появившееся на нашем экране, гласило: *«Размечаю варианты. Составляю карту подсказок кроссворда, перечисляя записи по горизонтали и вертикали и определяя количество букв для каждой. Это помогает более эффективно направлять процесс решения»*. Эта методичная подготовительная фаза соответствует тому, что когнитивные ученые давно наблюдают у экспертных решателей проблем – склонность строить ментальную модель пространства проблемы перед попыткой решения.

В своей работе «Решение проблем человеком» Герберт Саймон и Аллен Ньюэлл показали, что опытные решатели проблем обычно тратят больше времени, чем новички, на анализ проблемы перед началом решения¹. Эта «подготовительная фаза» не просто сбор информации, а построение того, что психологи называют «представлением пространства проблемы», ментальной модели, которая охватывает как явные, так и неявные ограничения проблемы.

Это отражает то, что мы видим в человеческом знании. Представьте шахматного гроссмейстера, анализирующего сложную позицию. Хотя у него может быть мгновенное интуитивное решение о ходе (система 1), лучшие игроки все же берут время, чтобы проверить свою интуицию через тщательный анализ (система 2). Аналогично в сложных бизнес-решениях мгновенное сопоставление шаблонов может быть опасным – лучшие руководители знают, когда нужно замедлиться и систематически продумать последствия.

Что это значит для бизнеса

Наши наблюдения за методичной подготовительной фазой LRM выявили важные уроки для внедрения агентов ИИ в бизнес-среде. Как LRM начинала с картирования всего пространства проблемы перед попыткой решений, организациям нужно создавать системы ИИ, которые собирают и анализируют контекстную информацию перед принятием действий. Речь не просто о сборе данных, а о создании всестороннего понимания среды принятия решений.

Представьте, как шахматный гроссмейстер изучает позицию перед ходом. Аналогично системам ИИ нужны структурированные подходы для понимания их операционного контекста. Для бизнеса это означает инвестиции в надежную инфраструктуру данных, которая позволяет агентам ИИ получать доступ и обрабатывать всестороннюю контекстную информацию. Это также означает разработку четких протоколов для сбора и проверки информации перед принятием критических решений.

Один производственный клиент внедрил этот принцип, создав так называемые карты контекста решений для своих агентов ИИ. Перед принятием решений о маршрутизации производства их система должна была собирать данные о доступности ресурсов, расписании технического обслуживания, сменах работников и зависимостях ниже по цепочке. Этот комплексный этап подготовки помог предотвратить каскадные ошибки, которые часто возникают в менее тщательно разработанных системах.

¹ Аллен Ньюэлл и Герберт Александр Саймон, 1972. «Решение проблем человеком». Энглвуд Клиффс, Нью-Джерси: Prentice-Hall.

Сила подготовки

Как LRM тратила время на анализ кроссворда в целом перед попыткой решений, вы получите лучшие результаты от агентов ИИ, если поможет им понять полный контекст вашего запроса. Представьте это как инструктаж нового члена команды – чем больше у него будет контекста, тем лучше будет его работа.

Например, при работе с агентом ИИ над бизнес-отчетом не просто просите «анализ рынка». Вместо этого предоставьте контекст о вашей отрасли, конкретных конкурентах, которые вас беспокоят, замеченных вами трендах и о том, как вы планируете использовать информацию. Эта контекстная информация помогает агенту ИИ правильно оформить свой анализ и представить более релевантные выводы.

Один руководитель, с которым мы работали, значительно улучшил свои результаты с агентами ИИ, разработав так называемый шаблон контекста. Перед каждым взаимодействием он обрисовывал фон, ограничения и желаемые результаты. «Это как проведение предварительного брифинга, – объяснил он. – Дополнительные две минуты, которые я трачу на объяснение контекста, экономят часы последующих уточнений».

Проверка гипотез и валидация: систематический подход к неопределенности

Пожалуй, наиболее захватывающим аспектом рассуждений LRM был ее систематический подход к тестированию и валидации потенциальных решений. Мы наблюдали это, когда LRM написала:



«Я взвешиваю 'TAPROOMS', 'CABARET', 'COCKTAIL', 'DANCE CLUB', 'DISCOTHEQUE', 'BARROOMS' и 'NIGHTCLUB' как ответы, но сталкиваюсь с конфликтом с 'HEIDI' для 6D».

Традиционные системы ИИ обрабатывают информацию как поезда, идущие по фиксированным рельсам, – они следуют предопределенным путям от ввода к выводу. LRM, напротив, работает скорее как автомобиль, который может выбирать маршрут в зависимости от условий движения. Когда он сталкивается с проблемой, он создает динамическую сеть потенциальных путей, по которым может течь информация.

Этот процесс близко напоминает то, что когнитивные ученые¹ называют стратегией «генерировать и тестировать» в человеческом решении проблем. Исследования Пэта Лэнгли и Герберта Саймона показали, как успешные решатели проблем используют стратегию «генерировать и тестировать» – создавая

¹ Когнитивные ученые – это специалисты, изучающие процессы мышления, восприятия и принятия решений, часто применяя свои знания для разработки ИИ-систем, чтобы моделировать человеческое поведение или устранять ошибки, например преждевременное завершение. Они анализируют, как ИИ обрабатывает информацию, взаимодействует с данными (например, через веб-поиск или скрейпинг экрана) и достигает подцелей, способствуя созданию более точных и адаптивных систем в рамках фреймворков трансформации. – *Прим. ред.*

несколько потенциальных решений и систематически оценивая их на соответствие известным ограничениям¹.

Подход LRM выявил суть систематического тестирования гипотез, навыка, который выделяет ее в ландшафте ИИ. Столкнувшись с неопределенностью, она не заикливалась на единственном решении, а генерировала несколько альтернатив, отражая «дивергентное мышление»², наблюдаемое в человеческом творческом решении проблем³. Затем она тщательно проверяла каждую возможность на соответствие ограничениям задачи, демонстрируя это, когда писала:



«Проверяю выравнивание букв. Хорошо, посмотрим: первая буква 12 по горизонтали совпадает с третьей буквой 6 по вертикали».

Что сделало LRM по-настоящему замечательной, так это ее способность к прогрессивному уточнению. Она не цеплялась за первоначальные идеи, а постоянно развивала свой подход, учаь на каждом сделанном шаге. Это динамическое взаимодействие творчества, точности и адаптивности продемонстрировало, на наш взгляд, новую границу в рассуждениях ИИ.

Что это значит для бизнеса

Подход LRM к генерации и тестированию нескольких потенциальных решений предлагает важные выводы для внедрения ИИ. Для бизнеса, внедряющего агентов ИИ, это означает разработку систем, которые могут генерировать и оценивать несколько путей решения.

Финансовая компания, с которой мы работали, применила этот принцип к своим торговым алгоритмам. Вместо следования единой торговой стратегии их агенты ИИ разрабатывали несколько подходов и тестировали их на архивных данных и текущих рыночных условиях. Этот подход с множественными гипотезами привел к более надежному принятию решений и лучшему управлению рисками.

Ключ в создании систем, которые могут учиться как на успехах, так и на неудачах. Каждое испытанное решение, успешное или нет, предоставляет ценные данные, которые могут улучшить будущее принятие решений. Организации должны установить четкие процессы для фиксации и анализа этой информации, создавая непрерывный цикл обучения, который во временном развитии улучшает производительность ИИ.

¹ Пэт Лэнгли и др., 1987. «Научное открытие: вычислительные исследования творческого процесса». Кембридж, Массачусетс: MIT Press.

² Дивергентное мышление – это метод творческого мышления, при котором человек ищет множество решений для одной проблемы или задачи. Оно предполагает множество точек зрения и позволяет находить ответы на открытые вопросы. – Прим. ред.

³ Кент Ф. Хуберт и др., 2024. «Текущее состояние генеративных языковых моделей искусственного интеллекта в задачах дивергентного мышления более творческое, чем у людей». Nature Scientific Reports 14, <https://www.nature.com/articles/s41598-024-53303-w>.

Метакогнитивное осознание: ИИ, который знает, что он мыслит

Одним из самых сложных аспектов рассуждений LRM было ее проявление метакогнитивного осознания – способности рассуждать о собственном мыслительном процессе. Мы наблюдали это, когда LRM написала: *«Продвижение дальше требует примирения этих расхождений»* и *«Это предполагает, что инструкции могут быть напечатаны с ошибкой или неясны»*.

Эта метакогнитивная способность была святым граалем в развитии ИИ. Недавние исследования из MIT показали, что системы, способные отслеживать и корректировать свои собственные процессы рассуждений, часто работают лучше на сложных задачах, чем те, которые просто выполняют заранее заданные алгоритмы¹.

Метакогнитивное осознание LRM было откровением, демонстрируя ИИ, способный размышлять о своем мышлении так, что казалось почти человеческим. Она активно отслеживала свой прогресс, признавая как успехи, так и неудачи, с заявлениями вроде *«Прогресс устойчив, но есть конфликт с буквой E, что побуждает переосмыслить 12A»*. Когда первоначальная стратегия оказывалась недостаточной, LRM не упорствовала слепо; она адаптировалась, заявляя: *«Рассматриваю внимательнее. Я тестирую возможность, что третья буква 12 по горизонтали совпадает со второй буквой b по вертикали»*.

Наиболее поразительной была ее способность распознавать неопределенность, что является важной чертой продвинутого рассуждения. Признавая, когда она могла работать с неполной или ошибочной информацией, LRM демонстрировала не просто интеллект, но зачатки своего рода самосознания – критический скачок для агентов ИИ, ориентирующихся в сложностях реальных проблем.

Эта метакогнитивная способность – мышление о мышлении – имеет глубокие последствия для бизнес-применений ИИ. Когда LRM сталкивалась с неопределенностью или потенциальными ошибками, она не продолжала работу слепо, а признавала свои ограничения и адаптировала свой подход.

Для организаций это означает разработку систем ИИ, которые могут оценивать свои собственные уровни уверенности и распознавать, когда они работают на грани своих возможностей. Медицинская организация, которую мы консультировали, внедрила этот принцип в свои диагностические системы ИИ. Их агенты были разработаны так, чтобы предоставлять оценки уверенности для каждой диагностики и, что крайне важно, определять, когда случаи выходят за пределы их надежных параметров принятия решений.

Это самосознание должно распространяться на организационный уровень. Бизнесу нужны четкие протоколы для случаев, когда решения ИИ требуют человеческой проверки, как документировать процессы принятия решений и как корректировать стратегии на основе обратной связи с производительностью.

Понимание неопределенности и ограничений

Способность LRM распознавать свою неопределенность и сообщать о ней предоставляет, возможно, наиболее важный урок для работы с агентами ИИ.

¹ Патрик Халупцок и др., 2023. «Языковые модели могут обучать себя программировать лучше», <https://arxiv.org/abs/2207.14502>.

Как пользователю, вам нужно развивать чувство, когда доверять выходам ИИ и когда делать дополнительную проверку или обратиться за помощью к компетентному человеку.

Финансовый аналитик, которого мы консультировали, разработал эффективный подход, который он называет «проверкой уверенности». Работая с агентами ИИ над финансовыми моделями, он просит их определить уровень уверенности в различных частях анализа и определить, какие аспекты могут потребовать человеческой проверки. «Это как работа с младшим аналитиком, – объясняет он. – Вам нужно знать как то, что они знают, так и то, чего они не знают».

Это осознание распространяется на то, как вы формулируете свои запросы. Вместо того чтобы просить окончательные ответы, учитесь запрашивать объяснения рассуждений и потенциальных зон неопределенности. Вопросы вроде «Какие факторы могут сделать эту рекомендацию менее надежной?» или «Какая дополнительная информация помогла бы сделать этот анализ более надежным?» могут привести к более продуманным и надежным результатам.

Первые выводы из эксперимента

«Истинное испытание интеллекта – это не только правильный ответ, но и то, как вы к нему пришли». Этот вывод от Тома, одного из наших соавторов, участвовавшего в десятках внедрений ИИ, идеально отражает то, что мы узнали из нашего недавнего эксперимента с LRM.

Последствия того, что мы наблюдали, выходят далеко за рамки кроссвордов. Быстрый ИИ с сопоставлением шаблонов может выглядеть впечатляюще при работе с простыми, независимыми решениями. Но во многих критических бизнес-приложениях – будь то здравоохранение, финансы или логистика – способность продумывать сложные взаимозависимости может быть разницей между успехом и дорогостоящей неудачей. Подход LRM продемонстрировал нечто важное: иногда тщательное обдумывание не просто лучше – оно необходимо.

Этот эксперимент выявил нечто фундаментальное о будущем ИИ: дело не только в принятии более быстрых решений, но в принятии лучших, более тщательно продуманных решений. В мире, все более зависимом от искусственного интеллекта, понимание этого различия может означать разницу между системами ИИ, которые действительно помогают нам, и теми, которые просто подталкивают нас к ошибкам.

СИЛА МНОЖЕСТВА: МНОГОАГЕНТНЫЕ СИСТЕМЫ В РАССУЖДЕНИЯХ ИИ

Хотя наши эксперименты с LRM подчеркнули важность осознанного рассуждения в индивидуальных системах ИИ, появилось еще более захватывающее открытие: лучшие рассуждения часто приходят не от предоставления одному агенту ИИ больше времени, а от возможности нескольким агентам ИИ рассуждать вместе.

Этот вывод фундаментально меняет наше восприятие искусственного интеллекта, бросая вызов предположению, что прогресс заключается только в создании более мощных автономных систем. Недавние исследования, про-

веденные Mila, Университетом Монреаля¹, показали, что совместное рассуждение среди агентов ИИ может превосходить даже самые продвинутые индивидуальные модели.

Эти результаты открывают новые возможности для решения критических вызовов, таких как компромисс между скоростью и доверием, одновременно раскрывая инновационные бизнес-приложения, которые полагаются на более надежное и нюансированное принятие решений.

Парадокс масштаба

Когда исследователи тестировали свой «фреймворк дебатов» с меньшими моделями (некоторые с всего 2 млрд параметров), они обнаружили нечто примечательное. Даже эти меньшие модели показали значительные улучшения в способностях к рассуждению, когда участвовали в структурированных дебатах с разнообразными коллегами². Ключом был не размер моделей, а их архитектурное разнообразие и то, как они оспаривали мышление друг друга.

Этот вывод имеет глубокие последствия. Он предполагает, что сложное рассуждение – это не только продукт чистой вычислительной мощности, но может возникать через правильный тип взаимодействия и диалога. Представьте это как группу студентов на семинаре – хотя каждый индивидум может иметь ограниченные знания, их коллективный дискурс и дебаты могут привести к выводам, превосходящим то, что мог бы достичь даже самый знающий индивидум в одиночку. Эта «эмерджентность через взаимодействие»³ намекает на новые возможности для разработки систем ИИ, которые могут эффективно рассуждать без необходимости огромных вычислительных ресурсов.

Что такое мультиагентные системы

Представьте мультиагентную систему как группу экспертов, обсуждающих сложную проблему. Каждый эксперт приносит свое видение и знание дела, и через структурированные дебаты и обсуждения они часто приходят к лучшим выводам, чем мог бы сделать любой из них в одиночку. В терминах ИИ мультиагентная система состоит из нескольких агентов ИИ, работающих вместе, каждый из которых потенциально имеет разные способности, обучение или специализированные знания⁴.

Исследования из Университета Монреаля продемонстрировали этот принцип⁵ весьма драматично. Когда они объединили разнообразные модели ИИ в структу-

¹ Махмуд Хегази, 2025. «Разнообразие мышления вызывает более сильные способности к рассуждению в фреймворках дебатов многоагентных систем». *Journal of Robotics and Automation Research*, 5(3), <https://arxiv.org/abs/2410.12853>.

² Хаотянь Ван и др., 2024. «Обучение ломать: улучшенное знаниями рассуждение в системах мультиагентных дебатов», <https://arxiv.org/abs/2312.04854>.

³ Эмерджентность (от англ. emergence — возникновение, появление нового) в теории систем – наличие у системы свойств, не присущих ее компонентам по отдельности. Это означает, что свойства системы несводимы к сумме свойств ее элементов. – *Прим. ред.*

⁴ Йилун Ду и др., 2023. «Улучшение фактической точности и рассуждений в языковых моделях с помощью многоагентных дебатов», <https://arxiv.org/abs/2305.14325>.

⁵ Махмуд Хегази, 2024. «Разнообразие точек зрения способствует усилению рассуждений в фреймворках дебатов многоагентных систем», <https://arxiv.org/abs/2410.12853>.

рированном фреймворке дебатов для решения сложных проблем, они обнаружили нечто примечательное: группа моделей средней мощности (включая Gemini-Pro, Mixtral 7B×8 и PaLM 2-M) достигла 91 % точности на сложных математических задачах, превосходя GPT-4, одну из самых продвинутых индивидуальных систем ИИ на тот момент. Это было не просто незначительное улучшение – это представляло фундаментальный прорыв в том, как мы думаем о способности ИИ к рассуждению.




Рис. 6.5. Ответы, предоставленные LRM, в основном правильные (Источник: адаптировано из исследований Университета Монреаля)

Мультиагентные системы предлагают интригующее решение дилеммы скорости и доверия, которую мы обсуждали ранее. Имея несколько агентов, работающих параллельно, каждый из которых потенциально действует с разной скоростью и с разными подходами, эти системы могут сочетать преимущества как быстрого, так и медленного мышления. Некоторые агенты могут предоставлять быстрые, основанные на шаблонах ответы, в то время как другие занимаются более глубоким рассуждением, подобно тому, как люди устанавливают баланс между интуитивным и аналитическим мышлением в групповом принятии решений.

Эмерджентность коллективного интеллекта

Чем глубже мы изучаем мультиагентные системы, тем больше мы обнаруживаем удивительных параллелей с динамикой человеческих групп. Одно из захватывающих открытий исследований Монреаля заключается в том, что, когда отдельные модели ИИ были очень уверены, но ошибались, введение различных перспектив через дебаты часто приводило к тому, что они соответствующим образом снижали свою уверенность перед тем, как прийти к лучшим ответам.

Это отражает важнейший аспект экспертного человеческого рассуждения – способность распознавать, когда уверенные ответы должны быть подвергнуты сомнению. Например, в медицинской диагностике наиболее опасные ошибки часто происходят из-за преждевременной уверенности. Подобно тому, как обсуждение сложного случая несколькими врачами может привести к более осто-

рожному подходу, дебаты между агентами ИИ способствуют более тонкому обращению с неопределенностью.

Что делает это еще более интригующим – так это то, что улучшения в мультиагентных системах – это не просто комбинация сильных сторон, а создание чего-то совершенно нового. Исследования Монреаля показали, что, когда несколько копий одной и той же модели ИИ дискутировали друг с другом, производительность улучшалась лишь незначительно (с 78 до 82 %). Однако, когда в структурированных дебатах участвовали разные модели, они достигали впечатляющих улучшений, достигая 91 % точности на сложных математических задачах. Это выявляет важное понимание: системы ИИ, как и люди, могут застревать в своих собственных «шаблонах мышления». Только когда разные модели, обученные с разными подходами и архитектурами, объединяются, мы видим настоящий интеллектуальный прогресс.

Сила когнитивного разнообразия

Что делает мультиагентные системы такими эффективными? Ключ лежит в том, что исследователи называют «разнообразием мышления»¹. Как человеческие команды выигрывают от когнитивного разнообразия, системы ИИ работают лучше, когда приносят разные подходы к решению проблем. Система, обученная иначе, даже если она не так мощна в целом, может заметить шаблоны или возможности, которые упускает более сложная система.

Этот принцип был подчеркнут в исследованиях Университета Монреаля, которые показали, как разные агенты ИИ могут дополнять друг друга в слабых местах. Например, благодаря инструментам, которые они могут использовать, или знаниям, к которым они имеют доступ, один агент может преуспевать в распознавании шаблонов, в то время как другой лучше в логической дедукции. Работая вместе, они создают то, что исследователи называют эмерджентными способностями к рассуждению, – способности, которые не существуют в отдельном агенте, но возникают из их взаимодействия².

Эффективность мультиагентных систем заключается не только в наличии нескольких моделей, но и в том, как они взаимодействуют друг с другом с течением времени. Исследования выявили то, что они назвали «эффектом учителя и ученика»³. Когда в сценариях дебатов исследователи соединяли более способные модели ИИ с менее способными, происходило нечто примечательное.

¹ Скотт Э. Пейдж, 2007. «Разница: как сила разнообразия создает лучшие группы, фирмы, школы и общества». Принстон, Нью-Джерси: Princeton University Press. Разнообразие мышления – это концепция, обозначающая множественность подходов, идей или стратегий в когнитивных процессах, которые усиливают эффективность ИИ-систем или команд, например в многоагентных системах (Sales Info Agent) или человеко-ИИ взаимодействиях. Это проявляется в вариативности решений, эмерджентном поведении или адаптации к задачам, что повышает гибкость и точность, например, при веб-поиске или автоматизации подцелей. – *Прим. ред.*

² Perplexity AI, 2024. «Что такое эмерджентное поведение в ИИ?», <https://www.perplexity.ai/page/what-is-emergent-behavior-in-a-cJ0gTqN7QX.wqxLttciWw>.

³ Сварнадрип Саха и др., 2023. «Могут ли языковые модели обучать более слабых агентов? Объяснения учителя улучшают учеников через персонализацию», <https://arxiv.org/abs/2306.09299>.

Менее способные модели показывали быстрое улучшение своих способностей к рассуждению, часто достигая уровней производительности, значительно превышающих их типичные возможности. В результате общая производительность системы улучшалась, иллюстрируя силу структурированных взаимодействий в мультиагентных системах.

Влияние на бизнес

Для бизнеса последствия применения мультиагентных систем неопенимы. Через нашу консультативную работу мы выделили три основные области, где мультиагентные системы приносят большую пользу.

Одно из самых ярких преимуществ заключается в их способности улучшать принятие решений в сложных средах. Например, в управлении цепочками поставок или оценке рисков развертывание множественных агентов позволяет каждому анализировать проблему с уникальной точки зрения, что приводит к более всесторонним решениям. Этот принцип дополнительно подчеркивается фреймворком Magentic-One от Microsoft, который показал, что мультиагентные системы были более эффективны в прогнозировании и смягчении сбоев по сравнению с их одноагентными аналогами¹. Мы подтвердили эти выводы в нашей собственной консультативной работе с глобальной фармацевтической компанией, где внедрение мультиагентного подхода для оптимизации цепочки поставок сократило потери, связанные со сбоями, на 35 %. Представьте цепочку поставок, где один агент прогнозирует всплески спроса, в то время как другой отслеживает геополитические риски; каждый агент усиливает выводы другого для создания устойчивой стратегии.

Вторым прорывом является их способность к улучшенному обнаружению ошибок. В отличие от одиночной системы мультиагентные фреймворки процветают на дебатах и вызовах, эффективно выявляя недостатки в рассуждениях. Исследования из MIT и Google Brain показали, что, когда агенты ИИ были разработаны так, чтобы оспаривать и уточнять выводы друг друга, частота ошибок снижалась более чем на 22 %². В нашей работе по внедрению мультиагентных систем для финансовых компаний мы последовательно наблюдали снижение частоты ошибок, что подтверждает эти исследовательские выводы. Эта совместная динамика отражает человеческий процесс рецензирования, где различные перспективы укрепляют конечный результат. Для бизнеса это означает меньше дорогостоящих ошибок, будь то в разработке новых продуктов, финансовом прогнозировании или операционной логистике.

Пожалуй, наиболее захватывающей является их адаптивность. Мультиагентные системы демонстрируют замечательную устойчивость при столкновении с новыми вызовами. Исследовательская группа недавно продемонстрировала, что разнообразные группы агентов могут справляться с ранее невиданными проблемами, часто превосходя системы, которые полагались на предварительно

¹ Адам Фоурни и др., 2024. «Magentic-One: универсальная мультиагентная система для решения сложных задач», <https://arxiv.org/abs/2411.04468>.

² Илун Ду и др., 2023. «Улучшение фактической точности и рассуждений в языковых моделях через мультиагентные дебаты», <https://arxiv.org/abs/2305.14325>.

обученные одиночные модели¹. Эта адаптивность делает их неоценимыми в динамичных рынках или кризисных ситуациях, где способность к маневру и инновациям является важнейшим средством к выживанию. От оптимизации маркетинговых стратегий до навигации по регуляторным изменениям мультиагентные системы предлагают устойчивость, которая кажется почти революционной.

Проблема каскадных эффектов

Хотя мультиагентные системы предлагают мощные преимущества, они также вводят уникальные вызовы, которые требуют тщательного рассмотрения. Несколько исследований выявили критическое явление: в сетях агентов ИИ ошибки рассуждений не просто накапливаются – они умножаются через то, что мы можем назвать сетевым эффектом² или совокупным воздействием ошибок³.

Мы наблюдали это явление на собственном опыте во время работы с крупной телекоммуникационной компанией, которая внедрила сложную мультиагентную систему для управления своими сетевыми операциями. Их система использовала несколько специализированных агентов ИИ, каждый из которых отвечал за разные аспекты, такие как балансировка нагрузки, мониторинг безопасности, распределение ресурсов, планирование технического обслуживания и оптимизация пользовательского опыта. Хотя каждый агент работал превосходно в изоляции, их взаимосвязанная природа создавала неожиданные проблемы.

В одном особенно поучительном инциденте один агент допустил, казалось бы, незначительную ошибку в оценке пропускной способности сети. Эта, на первый взгляд, небольшая ошибка вызвала каскад взаимозависимых решений: система балансировки нагрузки неправильно интерпретировала доступную пропускную способность, что привело к тому, что агент распределения ресурсов принял неоптимальные решения. Это, в свою очередь, заставило агента планирования технического обслуживания перенести критические обновления, что побудило систему мониторинга безопасности отмечать ложные срабатывания. Цепная реакция завершилась тем, что агент оптимизации пользовательского опыта сделал контрпродуктивные корректировки. То, что началось как небольшая ошибка в рассуждениях, усилилось в значительное нарушение сервиса через этот каскад взаимосвязанных решений.

Этот опыт научил нас ценным урокам об управлении мультиагентными системами в критических приложениях. Через нашу работу по внедрению в различных отраслях мы разработали фреймворк для предотвращения таких каскадных сбоев. Ключ заключается во внедрении того, что мы называем «контрольными точками рассуждений», – заранее определенных точек, где критические решения требуют нескольких уровней валидации. Эти контрольные точки работают вместе с «прерывателями цепи», специфическими условиями,

¹ Хонгю Ли, Илун Лю и Джун Янь, 2025. «Позиция: возникающая Machina Sapiens побуждает переосмыслить мультиагентные парадигмы», <https://arxiv.org/abs/2502.04388>.

² Меир Калез и Авраам Натан, 2022. «Модельная диагностика мультиагентных систем: обзор». Proceedings of the Thirty-Sixth AAAI Conference on Artificial Intelligence (AAAI-22), 12334-12341, <https://cdn.aaai.org/ojs/21498/21498-13-25511-1-2-20220628.pdf>.

³ Киаран Реган, Александр Гурнэ и Мизуки Ока, 2024. «Решение проблем в сетях языковых моделей», <https://arxiv.org/abs/2406.12374>.

которые запускают человеческую валидацию перед тем, как решения могут распространяться по системе. Мы предоставляем больше деталей по этим аспектам в главе 8.

Опираясь на этот опыт, мы обнаружили, что пользователям нужно развивать острое осознание потенциальных каскадных эффектов. Эффективные пользователи учатся:

- регулярно просить агентов объяснять их зависимости от выходов других агентов;
- запрашивать периодические проверки согласованности на уровне всей системы;
- устанавливать явные контрольные точки для человеческой валидации критических решений;
- отслеживать признаки усиления ошибок по всей системе.

Еще одним важным механизмом защиты является внедрение независимых протоколов верификации, где отдельные системы ИИ перекрестно проверяют рассуждения друг друга, используя разные методологии. Этот подход помогает поймать потенциальные ошибки до того, как они смогут распространиться по системе. Кроме того, мы обнаружили, что надежные системы мониторинга обратной связи, отслеживающие эффекты решений вниз по течению в реальном времени, необходимы для раннего обнаружения потенциальных каскадных сбоев.

Эти меры предосторожности не только предотвращают сбои – они также повышают общую надежность мультиагентных систем. Тщательно управляя взаимодействиями между агентами и внедряя соответствующие проверки и балансы, организации могут использовать силу мультиагентных рассуждений, минимизируя риски каскадных сбоев. Этот сбалансированный подход доказал свою необходимость для успешного развертывания мультиагентных систем в критических бизнес-приложениях.

Взгляд в будущее: дальнейшая эволюция мышления ИИ

Наше путешествие по исследованию рассудочной деятельности ИИ началось с простого кроссворда, но привело нас к глубоким выводам о природе искусственного интеллекта и его будущей эволюции. Оглядываясь назад на то, что мы узнали, можно выделить три фундаментальных сдвига в нашем понимании рассуждений ИИ – сдвиги, которые изменяют то, как мы думаем о внедрении ИИ в ближайшие годы.

Первый сдвиг бросает вызов нашим базовым предположениям о скорости и производительности ИИ. В ходе наших экспериментов и внедрений мы обнаружили, что эффективное рассуждение ИИ – это не чистая вычислительная мощность или мгновенные ответы. Вместо этого оно следует естественному ритму мышления – упорядоченной смене этапов обработки информации, которая чередует быстрое распознавание шаблонов с более глубоким, более осознанным анализом.

Этот ритм отражает нечто фундаментальное об интеллекте как таковом. Подобно тому, как человеческое познание эволюционировало, чтобы достичь баланса между быстрым реактивным мышлением с более медленным аналитическим рассуждением, системы ИИ начинают развивать свои собственные когнитивные ритмы. Успех LRM в нашем эксперименте с кроссвордом заключался

не только в ее превосходной вычислительной мощности – это была ее способность модулировать скорость мышления в зависимости от сложности вызова.

Наше исследование мультиагентных систем выявило второе важное понимание: будущее рассуждений ИИ может заключаться не в создании все более крупных индивидуальных моделей, а в содействии продуктивному взаимодействию между различными когнитивными подходами. Этот принцип – что несколько перспектив, даже если они индивидуально ограничены, могут объединяться для создания превосходящего понимания – кажется универсальной чертой интеллектуальных систем, будь то человеческих или искусственных.

Пожалуй, наиболее удивительно, что наше исследование привело нас к более глубокому пониманию роли человека в рассуждениях ИИ. Даже близко не делая человеческое суждение устаревшим, продвинутые системы ИИ, кажется, требуют более сложных форм человеческого надзора и взаимодействия. Наиболее успешные внедрения, которые мы видели, не минимизируют участие человека – они трансформируют его, повышая людей с простых операторов до того, что мы могли бы назвать «когнитивными хореографами», оркестрирующими взаимодействие между различными возможностями ИИ и обеспечивающими их соответствие человеческим ценностям и целям.

По мере того как мы исследовали, как агенты ИИ рассуждают, делая сложные умозаключения, один вопрос продолжает возникать: как эти системы учатся на своем опыте?

Хотя рассуждение позволяет ИИ принимать разумные решения в данный момент, память позволяет ему опираться на опыт, сумму этих результатов, становясь во временном развитии более разумным. Без памяти даже самые сложные способности к рассуждению остаются запертыми в вечном настоящем, неспособными учиться на прошлых успехах или избегать повторяющихся ошибок.

Переходя к исследованию памяти – третьего краеугольного камня агентов ИИ, – мы узнаем, как организации создают системы, которые не просто думают, но учатся и растут. Путешествие вперед раскроет не только то, как работает память в ИИ, но и как она превращает эти системы из инструментов в настоящих партнеров в достижении успеха бизнеса.

Память: построение ИИ, который учится

Представьте, что вы начинаете каждый день с полной амнезией – не в состоянии вспомнить свой прошлый опыт, предпочтения или усвоенные навыки. Как бы вы функционировали? Как бы вы развивались? Этот мысленный эксперимент затрагивает суть одной из самых увлекательных проблем в искусственном интеллекте сегодня: память. Большинство генеративных систем ИИ, с которыми мы взаимодействуем, по сути, начинают с чистого листа при каждом использовании, работая с формой искусственной амнезии, которая ограничивает их истинный потенциал.

Одним из наших наиболее показательных опытов с этим ограничением стала работа с глобальной телекоммуникационной компанией. Они вложили миллионы в передовые чат-боты для обслуживания клиентов, но удовлетворенность клиентов оставалась упорно низкой. Причина? ИИ забывал предыдущие взаимодействия с клиентами, вынуждая их повторять свои проблемы и предпочтения снова и снова. Как отметил один из руководителей компании во время нашего проекта, «это как иметь представителя службы поддержки с двухминутной памятью».

Этот вызов подчеркивает важную истину, которую мы обнаружили за годы внедрения систем ИИ в организациях: память – это не просто функция интеллекта, это основа, на которой строится весь значимый интеллект. Будь то в людях или машинах, способность сохранять, организовывать и использовать прошлый опыт формирует каждый аспект того, как мы учимся, адаптируемся и развиваемся.

В этой главе мы отправимся в путешествие по увлекательному миру памяти ИИ, раскрывая, как эта фундаментальная способность трансформирует бизнес и технологии. Вы узнаете, как различные типы памяти – от краткосрочной обработки до долгосрочного хранения – работают вместе, создавая по-настоящему интеллектуальные системы. Через реальные примеры и практи-

ческие внедрения мы исследуем, как создавать системы ИИ, которые не просто хранят информацию, но становятся умнее с каждым взаимодействием.

Вы узнаете, почему многие реализации памяти терпят неудачу, и проверенные стратегии, чтобы избежать этих ловушек. Мы углубимся в критический баланс между запоминанием и забыванием и почему это важно для вашего бизнеса. Путешествие впереди бросит вызов вашим предположениям о том, что ИИ может достичь, и покажет, как системы с поддержкой памяти переформируют будущее бизнеса и технологий.

ПАМЯТЬ КАК ОСНОВА ИНТЕЛЛЕКТА

Подумайте о своем самом раннем детском воспоминании. Возможно, это день рождения, запах кухни вашей бабушки или обучение езде на велосипеде. Теперь задайте себе вопрос: вы действительно вспоминаете исходное событие, или вы вспоминаете последний раз, когда вы его вспоминали? Этот вопрос, который может показаться философским, затрагивает суть того, как на самом деле работает человеческая память – и почему она так отличается от искусственных систем памяти, которые мы создаем сегодня.

За годы внедрения систем ИИ в организациях мы обнаружили, что понимание человеческой памяти помогает людям осознать как потенциал, так и ограничения искусственного интеллекта. Давайте исследуем, как работают наши собственные умы, поскольку это имеет увлекательные последствия для будущего ИИ.

Ваш мозг – это невероятный процессор информации. Прямо сейчас, когда вы читаете эти слова, он обрабатывает около 11 млн бит информации, но вы сознательно воспринимаете только около 40–50 бит. Эта избирательная осведомленность раскрывает нечто важное о том, как работают наши умы: память – это не хранение всего подряд, это хранения того, что имеет значение¹.

Подумайте о последней поездке на работу за рулем. Вы, вероятно, не помните большую часть пути, но вы определенно запомнили бы, если бы произошло что-то необычное, например олень перебежал дорогу. Это не ошибка в человеческой памяти, это ее особенность. Наши мозги замечательно эффективно отфильтровывают рутинную информацию, выделяя то, что важно или необычно.

Ученые обнаружили, что у нас есть разные типы систем памяти, каждая из которых служит разным целям². Есть рабочая память (также называемая краткосрочной памятью) – эквивалент оперативной памяти компьютера в вашем уме, – которая может удерживать около семи единиц информации одновременно. Вот почему телефонные номера традиционно состояли из семи цифр, и именно поэтому вам может быть сложно запомнить длинную последовательность инструкций³.

¹ CNS Nevada, 2024. «Какова емкость памяти человеческого мозга?», <https://www.cnsnevada.com/what-is-the-memory-capacity-of-a-humanbrain/>.

² Ларри Р. Сгвайр и Стюарт Зола-Морган, 1991. «Система памяти медиального височного отдела». *Science* 253, no. 5026: 1380–1386, <https://doi.org/10.1126/science.1896849>.

³ Эдуардо Камина и Франсиско Гуэль, 2017. «Нейроанатомические, нейрофизиологические и психологические основы памяти: современные модели и их происхождение». *Frontiers in Pharmacology* 8: 438, <https://doi.org/10.3389/fphar.2017.00438>.

Затем есть долгосрочная память, которая гораздо сложнее и состоит из трех основных типов памяти. Помните, как вы никогда не забываете, как ездить на велосипеде? Это работает процедурная память. Способность вспомнить день вашей свадьбы или первую работу? Это эпизодическая память. Тот факт, что вы знаете, что Париж – столица Франции, даже если вы там никогда не были? Это семантическая память¹.

Интересно, как эти системы работают вместе. Когда вы готовите знакомый рецепт, вы одновременно используете процедурную память (техники приготовления), семантическую память (знание того, какие ингредиенты хорошо сочетаются) и эпизодическую память (вспоминание о том, как вы готовили это блюдо в последний раз и что сработало или не сработало).

Но вот что действительно интересно: каждый раз, когда вы вспоминаете что-то, вы не извлекаете точную запись, как файл на компьютере. Вместо этого вы реконструируете его, возможно, с небольшими вариациями каждый раз. Это было продемонстрировано в новаторских исследованиях Элизабет Лофтус, которая показала, как воспоминания могут слегка варьироваться в зависимости от того, как задаются вопросы о них².

В одном исследовании Лофтус показала участникам видео автомобильной аварии, а затем спросила: «Как быстро ехали машины, когда они врезались друг в друга?» против «Как быстро ехали машины, когда они столкнулись друг с другом?». Те, кто слышал слово «врезались», вспоминали более высокие скорости и даже сообщали, что видели разбитое стекло – которого на самом деле не было. Этот увлекательный эксперимент подчеркивает, как выбор слов может изменить память. Он демонстрирует, что человеческие воспоминания – это реконструкции, а не записи.

Эта реконструктивная природа памяти, хотя иногда и ненадежная, дает нам замечательную гибкость в мышлении и решении проблем. Она позволяет нам воображать новые сценарии, комбинируя элементы прошлых опытов – способность, которую современные системы ИИ с их более жесткими структурами памяти все еще пытаются воспроизвести.

Эмоции также играют важнейшую роль. Подумайте, где вы были, когда узнали о крупном мировом событии, таком как президентские выборы или глобальный кризис. Вы, вероятно, помните это ясно, потому что события на фоне эмоциональных переживаний обычно запоминаются лучше, чем нейтральные. Эта эмоциональная маркировка помогает нам приоритизировать важную информацию и принимать лучшие решения – это то, что мы все еще пытаемся понять и внедрить в системы ИИ.

Понимание этих аспектов человеческой памяти помогает объяснить как вызовы, так и возможности в разработке агентов ИИ. Хотя мы можем создавать системы, которые хранят огромные объемы информации с идеальной точно-

¹ Джаррад А. Г. Лум и Джина Контти-Рамсден, 2013. «Долгосрочная память: обзор и метаанализ исследований декларативной и процедурной памяти при специфических языковых нарушениях», <https://pmc.ncbi.nlm.nih.gov/articles/PMC3986888/>.

² Элизабет Ф. Лофтус, 1975. «Наводящие вопросы и отчет свидетеля». *Cognitive Psychology* 7, no. 4: 560–572, [https://doi.org/10.1016/0010-0285\(75\)90023-7](https://doi.org/10.1016/0010-0285(75)90023-7).

стью – чего не могут наши мозги, – мы все еще далеки от воспроизведения гибкого, контекстно-чувствительного и эмоционально интеллектуального способа, которым люди обрабатывают и используют воспоминания.

Это не просто академические знания – это имеет практические последствия для того, как мы разрабатываем и используем системы ИИ. Когда мы признаем, что человеческая память – больше создание значимых связей, чем хранение идеальных записей, мы можем лучше понять, к чему мы должны стремиться в искусственных системах: не просто больше хранилища, а более умные, более контекстуальные способы использования информации.

Удивительная реальность памяти ИИ

Это приводит нас к увлекательному контрасту с современными системами ИИ. Мы заметили распространенное заблуждение: многие люди боятся взаимодействовать с большими языковыми моделями, такими как ChatGPT, Gemini или Claude, потому что считают, что эти системы ИИ постоянно учатся и запоминают все из их взаимодействий, создавая постоянно растущую базу знаний. Реальность гораздо более удивительна.

LLM больше похожи на чрезвычайно сложные эхо-камеры с ограниченной временной памятью. Представьте это так: когда вы начинаете разговор с ИИ, это как открытие чистой тетради с фиксированным количеством страниц. Все, о чем вы говорите, записывается в эту тетрадь, и ИИ может свободно обращаться к любой ее части – но только до тех пор, пока вы не закроете разговор. Как только вы начинаете новый чат – это как получение новой чистой тетради без следов того, что было написано в предыдущей.

Хотите проверить это сами? Попробуйте простой эксперимент с любым интерфейсом чата ИИ, таким как ChatGPT или Claude.

1. Спросите о теме, которая вам нравится, например: «Как проходит дайвинг на Таити?»
2. Попросите больше информации о местах для дайвинга и видах рыб, которые можно увидеть.
3. Закройте сессию чата.
4. Немедленно откройте новую сессию чата и спросите: «Что ты рассказал мне о Таити минуту назад?»

Вот что ответил нам чат-бот: *«Я не припоминаю, чтобы недавно упоминал Таити. Не могли бы вы уточнить, что вы ищете? Вы спрашиваете о советах по путешествиям, истории, культуре или чем-то другом?»*

Мы предлагаем вам попробовать. Скорее всего, ИИ либо признает, что ничего не помнит, либо даст общие утверждения. Это не недостаток в вычислительной мощности ИИ – это фундаментальное ограничение в том, как большинство текущих систем ИИ обрабатывают память. Главный урок здесь в том, что LLM, которые являются основой самых продвинутых агентов, находящихся в производстве (агенты уровня 3), имеют столько же памяти, сколько золотая рыбка¹!

¹ См. примечание ранее о том, что короткая память золотой рыбки – это миф. – Прим. ред.

Проблема памяти на практике

Чтобы проиллюстрировать практическое влияние этого ограничения, рассмотрим эксперимент, который мы провели с крупным поставщиком медицинских услуг. Они внедрили две версии помощника по планированию ИИ:

- стандартную систему на основе LLM, которая начинала с чистого листа при каждом взаимодействии;
- усовершенствованного ИИ-агента с памятью, который мог сохранять информацию о пациентах.

Результаты были поразительными. Стандартная система требовала от пациентов повторять их медицинскую историю и предпочтения при каждом взаимодействии. Версия с улучшенной памятью запоминала истории и предпочтения пациентов, что привело к ускорению планирования на 70 % и увеличению удовлетворенности пациентов на 45 %.

Этот эксперимент высветил текущий парадокс памяти в генеративном ИИ: самые продвинутые системы ИИ могут обрабатывать сложную информацию, но часто не могут запомнить простые детали о своих пользователях.

Три основные цели памяти агентов ИИ

Через наши исследования и внедрения мы определили три критически важные цели памяти, которые делают ее основой агентного интеллекта.

- Первая – это контекстное понимание. Традиционные генеративные системы ИИ обрабатывают каждый ввод независимо, как человек, читающий случайные страницы из разных книг. Агенты ИИ с поддержкой памяти могут поддерживать контекст через взаимодействия, подобно тому, как мы следуем непрерывному разговору. Эта способность критически важна для значимых взаимодействий и решения проблем.
- Вторая – обучение и адаптация. По нашему опыту, самые успешные внедрения ИИ – это те, которые могли учиться на прошлых взаимодействиях. Например, система контроля качества ИИ в производственной компании не только обнаруживала дефекты, но и запоминала шаблоны проблем, что со временем привело к снижению ложных срабатываний на 40 %.
- Третья – персонализация в масштабе. Клиенты все чаще ожидают персонализированного опыта. Агенты ИИ с поддержкой памяти могут обеспечивать это, сохраняя и обучаясь на индивидуальных взаимодействиях, сохраняя при этом конфиденциальность и безопасность.

Три слоя памяти агентов ИИ

Подобно организации человеческой памяти, память агентов ИИ может быть структурирована в три взаимосвязанных слоя, каждый из которых выполняет определенную функцию в сохранении контекста, содействии обучению и обеспечении адаптации во временном развитии.

1. Краткосрочная память (STM) – удержание немедленного контекста

STM функционирует как рабочая память ИИ, удерживая недавние взаимодействия и обеспечивая контекстную непрерывность в рамках одной сессии.

Она обрабатывает текущие входные данные, отслеживает текущие разговоры и применяет механизмы внимания для приоритизации релевантной информации. Однако STM имеет ограниченную емкость – по мере поступления новых данных старая информация перезаписывается, если не передается в долгосрочную память.

2. Долгосрочная память (LTM) – структурированное сохранение во временном развитии

LTM выходит за рамки памяти, основанной на сессиях, храня структурированную информацию для будущего использования. Это включает предпочтения пользователей, прошлые взаимодействия, изученные рабочие процессы и специфические для домена знания. LTM позволяет ИИ распознавать повторяющиеся шаблоны, вспоминать прошлые взаимодействия и персонализировать ответы на основе накопленного опыта. В отличие от STM, LTM предназначена для сохранения, гарантируя, что агенты ИИ не начинают с нуля при каждом взаимодействии.

3. Циклы обратной связи – обучение и адаптация

Циклы обратной связи выступают механизмом самоулучшения памяти ИИ, совершенствуя как STM, так и LTM во временном развитии. Включая обратную связь от пользователей – будь то явная (например, исправления, оценки) или неявная (например, шаблоны вовлеченности, отслеживание ошибок), – ИИ корректирует свои структуры памяти для повышения точности и релевантности. Этот процесс позволяет ИИ непрерывно улучшаться, усиливая полезные знания и отбрасывая устаревшую или неверную информацию.

Три слоя памяти агентного ИИ



Рис. 7.1. Три слоя памяти агентного ИИ (Источник: © Борне и др.)

Как работают эти слои вместе

Память ИИ функционирует динамически через эти три слоя: STM удерживает текущий контекст, LTM обеспечивает непрерывность за пределами сессии, а циклы обратной связи совершенствуют оба слоя для обеспечения непрерывности обучения. Этот многослойный подход позволяет агентам ИИ участвовать в контекстно-осведомленных, развивающихся и персонализированных взаимодействиях, делая их более интеллектуальными и надежными во временном развитии.

Представьте слои этого фреймворка агентного ИИ как луковицу. Краткосрочная память (STM) формирует внешний слой, обеспечивая текущий контекст для взаимодействий, но он сиюминутен и быстро исчезает по мере поступления новой информации. Под ней долгосрочная память (LTM) служит основой, храня критические знания и гарантируя, что ИИ не начинает с нуля при каждом взаимодействии. В центре циклы обратной связи непрерывно совершенствуют и укрепляют как STM, так и LTM, позволяя системе учиться на взаимодействиях с пользователями и улучшаться во временном развитии. Подобно тому, как луковица растет, наращивая свои слои, эта архитектура памяти позволяет агентам ИИ развивать более глубокий интеллект, обеспечивая непрерывность, адаптивность и долгосрочную надежность в их ответах.

В следующих разделах мы углубимся в то, как различные типы памяти работают в агентах ИИ, их практические применения и ограничения, которые нам нужно устранить. Но помните эту фундаментальную истину: подобно тому, как человеческий интеллект строится на нашей способности помнить и учиться на опыте, будущее агентов ИИ зависит от их способности делать то же самое.

ЗАМЫСЛОВАТЫЙ ТАНЕЦ КРАТКОСРОЧНОЙ ПАМЯТИ В АГЕНТАХ ИИ

Представьте себя на оживленном перекрестке в Сингапуре. Вы одновременно обрабатываете несколько потоков информации: смену светофоров, переходящих дорогу пешеходов, движущиеся другие транспортные средства и указания вашей навигационной системы. Этот постоянный поток сиюсекундной информации и то, как вы его обрабатываете, иллюстрирует суть краткосрочной памяти – критического компонента не только для человеческого познания, но и для агентов ИИ.

Проблема текущего момента

Подобно тому, как наши мозги должны постоянно жонглировать входящей информацией, сохраняя немедленный контекст, агенты ИИ сталкиваются с аналогичной задачей. Однако их подход к обработке этой немедленной информации увлекателен и принципиально отличается от человеческого познания. По нашему опыту, понимание этих различий критически важно для тех, кто хочет добиться успеха с технологиями ИИ. Начнем с простого эксперимента, который мы часто используем в нашей консультативной работе, чтобы продемонстрировать важность краткосрочной памяти.

Откройте разговор с помощником ИИ, таким как Claude или Gemini, и начните рассказывать историю о своем дне. После каждого нескольких предложений просите ИИ подвести итог того, что вы сказали до сих пор.

Вы заметите нечто интересное: ИИ может поддерживать контекст некоторое время, но в конечном итоге он начинает терять следы более ранних деталей. Это не отличается от человеческой краткосрочной памяти, которая, как говорят когнитивные ученые, обычно может удерживать около 7 (плюс-минус 2) элементов одновременно¹.

Контекстное окно: рабочая память ИИ

Одно из самых удивительных открытий для многих наших клиентов – это то, как системы ИИ на самом деле обрабатывают текущую информацию. Современные системы ИИ, особенно LLM, работают в рамках того, что мы называем «контекстным окном»: подумайте о нем как о временном рабочем пространстве, где ИИ может видеть и обрабатывать информацию. Это окно похоже на доску, которая может содержать ограниченное количество текста, и как только она заполняется, старые данные должны быть стерты, чтобы освободить место для новых входных данных.

Недавняя работа Ли, Рулин Шао и их коллег раскрыла нечто увлекательное об этих контекстных окнах. Их исследование выявило так называемый контекстный потолок – точку, в которой добавление большего количества информации в память агента начинает ухудшать, а не улучшать производительность².

Это явление не просто связано с достижением максимальной емкости, оно раскрывает фундаментальные проблемы в том, как агенты обрабатывают и интегрируют большие объемы информации. Исследователи обнаружили, что ухудшение производительности часто начинается задолго до достижения номинальных пределов памяти, что говорит о том, что эффективное управление памятью подразумевает не только саму емкость хранения, но и то, как агент обрабатывает информацию в своей краткосрочной памяти.

Чтобы понять это, давайте разберем краткосрочную память на три различных компонента: контекстное окно, механизмы внимания и управление токенами. Эти три элемента формируют основу того, как агент ИИ взаимодействует с задачами, приоритизирует информацию и предоставляет ответы. Исследуя эти компоненты через простой эксперимент, мы можем раскрыть не только то, как они работают, но и как более эффективно направлять агента – и что это означает для лидеров в бизнес-контекстах.

Контекстное окно

Представьте, что вы наткнулись на плотный технический отчет – возможно, книгу о квантовых вычислениях или документ о политике в области возобновляемой энергии. Вы инструктируете генеративный чат-бот ИИ: *«Обобщите эту статью в пяти пунктах, сосредоточившись на основных темах или выводах»*.

¹ Джордж А. Миллер, 1956. «Магическое число семь, плюс-минус два: некоторые пределы нашей способности обрабатывать информацию». *Psychological Review* 63, no. 2: 81–97, <https://doi.org/10.1037/h0043158>.

² Джаминг Танг и др., 2024. «Quest: разреженность, осведомленная о запросах, для эффективного вывода LLM с длинным контекстом». ResearchGate, https://www.researchgate.net/publication/381484873_Quest_Query-Aware_Sparsity_for_Efficient_Long-Context_LLM_Inference.

Когда он обрабатывает текст, контекстное окно становится первым и наиболее важным компонентом в игре.

Подумайте о контекстном окне как о рабочем столе ИИ – рабочем пространстве, где он размещает всю информацию, необходимую для выполнения задачи. В модели, такой как GPT, этот стол может вмещать до нескольких сотен тысяч токенов, или примерно 100 000 слов, в то время как передовые системы, такие как Gemini от Google, предлагают еще большую емкость с миллионами токенов.

Но даже огромный стол имеет свои пределы. ИИ должен решить, как разместить информацию, чтобы она оставалась управляемой. Если документ превышает размер стола, некоторые части полностью исключаются, в то время как другие сжимаются или упрощаются. Способность ИИ обрабатывать задачу зависит от того, насколько эффективно он использует это конечное пространство¹.

Механизмы внимания

Как только информация оказывается на столе, в дело вступают механизмы внимания. Это способность ИИ сосредотачиваться на наиболее релевантных частях ввода. Представьте, что вы просматриваете документ с маркером, выделяя наиболее важные предложения или идеи. Механизмы внимания делают это динамически, присваивая веса различным кусочкам информации на основе вашего запроса. В данном случае ИИ сосредотачивается на общих темах, таких как роль квантовой запутанности или глобальное влияние политики возобновляемой энергии, отфильтровывая менее значимые детали, такие как конкретные примеры или второстепенные аргументы.

Механизмы внимания невероятно мощны, но они формируются инструкциями, которые вы предоставляете. Если вы просите «основные темы», фокус ИИ естественно принижает приоритет конкретных деталей. Поэтому важно отправлять четкие инструкции и убедиться, что они хорошо соответствуют цели².

Управление токенами

Наконец, управление токенами – это как система заметок ИИ. Представьте, что вы на лекции пытаетесь зафиксировать важнейшие моменты, не записывая все подряд. Вы сосредотачиваетесь на главном и пропускаете то, что кажется повторяющимся или менее важным. ИИ делает то же самое, когда приближается к пределу своей памяти, – он обобщает, сжимает и решает, что сохранить в своем ментальном рабочем пространстве. Но этот подход имеет компромиссы. Некоторые тонкие детали или примеры могут быть исключены, потому что они казались менее критичными в данный момент. Управление токенами – это балансировка, обеспечивающая лаконичность и фокус ИИ, сохраняя при этом достаточно деталей для эффективного выполнения своей цели.

Чтобы проверить это дальше, вы задаете дополнительный вопрос генеративному чат-боту ИИ: *«Что говорится в статье о роли запутанности в исправ-*

¹ Нельсон Ф. Лю и др., 2023. «Потерянные в середине: как языковые модели используют контексты», <https://cs.stanford.edu/~nflui/papers/lost-in-the-middle.arxiv2023.pdf>.

² Ашиш Васвани и др., 2017. «Внимание – это все, что вам нужно». *Advances in Neural Information Processing Systems 30*, https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

лении ошибок?» Если этот аспект был выделен в основных темах, ИИ быстро и точно извлекает его. Но если он был похоронен в менее заметном разделе или не имел контекстного акцента, ИИ может споткнуться. Он может попытаться вывести ответ на основе связанных тем или – в случае неудачи – вернуть более широкий, менее точный ответ. Это происходит потому, что конкретная деталь не была приоритизирована на этапе внимания или была потеряна во время управления токенами.

Эксперимент раскрывает архитектуру памяти ИИ в действии: контекстное окно определяет его пределы, механизмы внимания формируют его фокус, а управление токенами обеспечивает компромиссы.

Пример из реальной практики

Чтобы увидеть, как компоненты краткосрочной памяти – контекстные окна, механизмы внимания и управление токенами – объединяются в реальном сценарии, рассмотрим проект, выполненный крупным поставщиком финансовых услуг. Задача состояла в разработке агента ИИ, способного обрабатывать сложные запросы клиентов об инвестиционных продуктах. Вызовы были значительными. Клиенты часто требовали подробных объяснений об инвестиционных опциях, ожидали, что система будет поддерживать контекст на протяжении длительных разговоров, и часто ссылались на несколько счетов или конкретные исторические транзакции. ИИ нужно было не только отслеживать всю эту информацию, но и перекрестно ссылаться на нее в рамках одного разговора, чтобы предоставлять точные и персонализированные ответы.

Изначально система была оснащена базовыми возможностями краткосрочной памяти. Она превосходно справлялась с простыми задачами, такими как ответы на одношаговые вопросы – например, объяснение различий между двумя взаимными фондами или извлечение балансов счетов. Однако она спотыкалась, сталкиваясь с многошаговыми процессами. Например, если клиент просил сравнить инвестиционные опции, обновить настройки счета и рассчитать потенциальную доходность на основе гипотетического сценария, ИИ часто терял следы самых ранних частей разговора. Это приводило к фрагментированным ответам, повторениям или ошибкам, особенно при жонглировании несколькими счетами или переключении между сложными финансовыми комбинациями.

Чтобы устранить эти недостатки, внутренняя команда разработки ИИ компании внедрила усовершенствованные стратегии краткосрочной памяти. Во-первых, они оптимизировали контекстное окно, разделяя разговоры на отдельные сегменты, гарантируя, что ИИ может сосредотачиваться на одной части обсуждения за раз, не теряя из виду предыдущие детали. Затем они точно настроили механизмы внимания, чтобы приоритизировать наиболее релевантные части ввода – такие как ключевые запросы клиентов, детали, специфичные для счета, и критические финансовые термины. Наконец, они ввели протоколы управления токенами для обобщения и сохранения важных моментов из ранних частей разговора, отбрасывая нерелевантную или избыточную информацию.

Результаты были впечатляющими. С этими улучшениями ИИ смог обрабатывать сложные взаимодействия с клиентами с замечательной точностью. Он плавно справлялся с многошаговыми процессами, такими как сравнение производи-

тельности портфеля, предоставление индивидуальных инвестиционных советов и выполнение обновлений счета – все в рамках одной сессии. Частота ошибок снизилась на 65 %, а показатели удовлетворенности клиентов значительно выросли, отражая способность системы участвовать в детализированных и последовательных финансовых обсуждениях. Хотя система все еще не была так нюансирована или адаптивна, как человеческий консультант, это улучшение ознаменовало значительный скачок в способности ИИ управлять сложными финансовыми взаимодействиями с большей точностью и надежностью.

Этот пример подчеркивает потенциал хорошо разработанного управления краткосрочной памятью в системах ИИ. Речь идет не только об улучшении производительности – речь о завоевании доверия. Когда клиенты видят, что ИИ может помнить их потребности, адаптироваться к сложным требованиям и предоставлять точную информацию, они чувствуют большую уверенность в его способностях. Для бизнеса это не просто операционное улучшение, это конкурентное преимущество, которое поднимает клиентский опыт на новую высоту.

Управление краткосрочной памятью для лучших результатов

Чтобы получить максимум от агента ИИ, пользователи должны играть активную роль в направлении его процессов памяти. Это начинается с создания продуманных запросов, которые соответствуют поставленной задаче. Если ваша цель – извлечь общие темы, простая инструкция, такая как *«Резюмируй ключевые моменты»*, работает хорошо. С другой стороны, если вы ищете конкретные детали, ваше руководство должно быть более точным: *«Предоставь подробное объяснение раздела 3, сосредоточившись на примерах»*.

Лидеры должны понимать, что ИИ, в отличие от члена команды – человека, не приоритизирует и не делает выводы интуитивно. Лучший результат он дает, когда задачи представлены четко и структурированы для максимального фокуса и возможностей обработки. Например, в приложениях для обслуживания клиентов вместо предоставления ИИ всей истории чата клиента лучше предоставить краткие обзоры важнейших взаимодействий. Аналогично в стратегическом планировании разбиение анализа рынка на меньшие, сфокусированные разделы позволяет ИИ итеративно взаимодействовать с данными, производя более глубокие выводы во временном развитии.

Помимо рабочих процессов, это понимание требует переосмысления динамики команды. Агенты ИИ превосходно управляют и анализируют огромные объемы данных, но им все еще нужен человеческий надзор, чтобы направлять их приоритеты. Это создает возможность для гибридного сотрудничества – люди формируют входные данные и интерпретируют выходные, в то время как ИИ решает повторяющиеся, интенсивные по данным задачи. Вместе они формируют взаимодополняющее партнерство. Способствуя этой синергии, бизнес-лидеры могут открыть новые уровни эффективности и инноваций, минимизируя риски, связанные с присущими ИИ ограничениями.

Из этого совместного подхода возникли практические стратегии. Одной из самых эффективных является разбиение информации на части. Подобно тому, как люди организуют знания в управляемые группы, агенты ИИ работают лучше, когда их входные данные структурированы в удобоваримые сегменты. Например, внедрение разбиения информации в системе обслуживания клиентов при-

вело к улучшению точности ответов на 40 %. Информация, сгруппированная по темам или релевантности, позволила ИИ более эффективно управлять своей краткосрочной памятью, что привело к более четким и точным ответам.

Еще одной мощной техникой является приоритетная очередность, которая гарантирует, что наиболее критическая информация остается доступной в краткосрочной памяти ИИ. В медицинском приложении, например, симптомы пациентов и жизненно важные показатели приоритизировались над административными деталями. Эта стратегия означает, что критическая медицинская информация должна быть легко доступна, повышая способность ИИ помогать медицинским работникам в сценариях, чувствительных ко времени исполнения. Успех этих подходов демонстрирует, как целенаправленное структурирование информации может значительно улучшить производительность ИИ в различных отраслях.

В конечном счете, понимая и осваивая механику краткосрочной памяти – контекстные окна, механизмы внимания и управление токенами, – вы можете гарантировать, что ИИ станет не просто инструментом, а катализатором роста и инноваций.

Взгляд в будущее краткосрочной памяти

Будущее краткосрочной памяти в агентах ИИ показывает захватывающие возможности, с прорывами, которые обещают революционизировать то, как машины обрабатывают и сохраняют информацию. Среди них выделяются три недавних достижения, каждое из которых предлагает взгляд на потенциал ИИ для выполнения более сложных задач с большей эффективностью.

Одно из таких нововведений – это Landmark Attention¹, механизм, который оснащает ИИ своего рода ментальной картой для навигации по огромным объемам информации. Представьте чтение длинного романа или анализ всестороннего отчета – Landmark Attention позволяет ИИ разделять эти огромные тексты на управляемые разделы и определять ключевые точки, или «ориентир», на которых нужно сосредоточиться. Этот подход гарантирует, что ИИ может быстро получать доступ к релевантным деталям, не перегружаясь объемом информации. Он решает критическое ограничение в текущих системах, которые борются с длинными последовательностями, делая возможным для ИИ обработку целых книг или наборов данных за один раз. Для бизнеса это может означать более быструю и всестороннюю аналитику отзывов клиентов, юридических документов или финансовых данных.

Другое новаторское исследование называется Varied-Size Window Attention (VSA)². Оно позволяет ИИ динамически адаптировать свой фокус. Представьте себе регулируемую пару очков, которая позволяет вам увеличивать масштаб, чтобы рассмотреть мелкие детали, когда это необходимо, и уменьшать масштаб, чтобы охватить более широкий контекст. VSA предоставляет ИИ эту гибкость, создавая «окна» разного размера в зависимости от требований задачи.

¹ Араш Мохташами и Мартин Ягги, 2023. «Landmark Attention: случайный доступ к бесконечной длине контекста для трансформеров», <https://arxiv.org/abs/2305.16300>.

² Цимин Чжан и др., 2022. «VSA: обучение вниманию с переменным размером окна в трансформерах для зрения», <https://arxiv.org/abs/2204.08446>.

Например, обобщение длинного отчета может потребовать широкого обзора для захвата общих тем, в то время как перевод предложения требует более сфокусированного взгляда. Эта адаптивность делает ИИ гораздо более универсальным и способным справляться с разнообразными задачами с точностью и эффективностью. На практике это означает, что ИИ может плавно переключаться между составлением статьи и анализом юридического контракта, выполняя обе задачи с замечательным мастерством.

Третье исследование, называемое Retrieval Attention¹, вводит новый уровень эффективности в управлении памятью. Современные системы ИИ часто пытаются обрабатывать и хранить все, даже нерелевантную информацию, что приводит к потере ресурсов и снижению производительности. Retrieval Attention меняет это, обучая ИИ извлекать только самые важные фрагменты информации, когда это необходимо, подобно тому, как человек вспоминает ключевые моменты разговора, не запоминая каждое слово. Этот метод значительно ускоряет время обработки, одновременно снижая потребление энергии, делая ИИ не только быстрее, но и экономичнее. Последствия глубокие: представьте более плавных, быстрых помощников ИИ, которые могут справляться со сложными запросами без замедления, работая эффективно на устройствах повседневного пользования.

Вместе эти достижения представляют скачок вперед в том, как ИИ обрабатывает контекст и память. Они прекрасно дополняют друг друга, решая различные аспекты одной и той же фундаментальной проблемы. Landmark Attention превосходит в организации огромной информации; VSA делает ИИ более адаптивным к различным задачам; а Retrieval Attention гарантирует эффективное управление памятью.

Понимание и оптимизация краткосрочной памяти в агентах ИИ – это не просто технический вызов, это основа для создания систем, которые могут значительно взаимодействовать с людьми и эффективно справляться со сложными задачами. Хотя краткосрочная память важна для немедленного выполнения задач, ее настоящий потенциал реализуется при интеграции с системами долгосрочной памяти. Эта интеграция позволяет агентам ИИ не только эффективно обрабатывать текущую информацию, но и учиться и адаптироваться во временном развитии – тема, которую мы подробно исследуем в следующем разделе.

Сила долгосрочной памяти: ПРЕВРАЩЕНИЕ ИИ ИЗ ИНСТРУМЕНТА В ПАРТНЕРА

Сила долгосрочной памяти

Представьте это: агент ИИ, который не просто помогает вам с задачами или отвечает на ваши вопросы, но запоминает. Не на день, не на неделю, и даже не на год – а на десятилетия. Он помнит каждый важный момент, каждую проблему, каждый успех, каждый урок, который вы усвоили. Он не просто хранит данные – он понимает вашу историю.

¹ Ди Лю и др., 2024. «RetrievalAttention: ускорение вывода LLM с длинным контекстом через векторное извлечение», <https://arxiv.org/abs/2409.10516>.

Что вы могли бы достичь с таким коучем или компаньоном?

Подумайте о бизнес-решениях, которые вы приняли за последний год. Некоторые были простыми, но значительными – например, перераспределение ресурсов для соблюдения сроков или утверждение нового поставщика для критического компонента цепочки поставок. Другие могли быть инновационными – крупная модификация продукта, выход на новый рынок или реструктуризация отдела. Как часто эти решения были полностью подкреплены историческими данными и контекстом вашей компании? Как часто вы полагались на инстинкты или неполные воспоминания просто потому, что соответствующие детали не были легко доступны?

Теперь представьте агента ИИ, который помнит все. Столкнувшись со стратегическим выбором, он предоставляет выводы, основанные на исторических шаблонах. «Помните три года назад, когда вы колебались, стоит ли запускать тот продукт на похожем рынке? Это оказался огромный успех благодаря вашему целевому подходу. Эта новая возможность имеет похожие характеристики – вот что сработало в прошлый раз и что вы могли бы рассмотреть». Это не гипотетично; это действительно, основано на уникальной траектории вашей организации.

Сила такой памяти выходит за рамки реактивного принятия решений. Она выявляет шаблоны в ваших бизнес-стратегиях, подчеркивает операционные неэффективности и усиливает сильные стороны вашей организации. Она не просто хранит данные – она их контекстуализирует, превращая сырую информацию в действенные выводы. Это разница между инструментом и настоящим бизнес-партнером – тем, который развивается вместе с вами, понимает ваши приоритеты и помогает достигать более продуманных, более уверенных результатов.

Это будущее ИИ. Не просто более умное, а глубоко более человечное в своей способности помнить, понимать и помогать нам жить с большим заданием на будущее. Это будущее, где память не просто сохраняется – она используется, чтобы раскрыть наши лучшие качества.

Почему долгосрочная память (LTM) важна для бизнеса

Влияние LTM на бизнес ИИ-агентов трансформирует то, как организации взаимодействуют с клиентами, оптимизируют операции и получают стратегические преимущества. Представьте себе клиентский сервис, где каждое взаимодействие строится на предыдущем: ИИ, который помнит ваши предпочтения, предлагает ваши потребности и решает проблемы, не заставляя вас повторяться. Этот уровень персонализации не просто улучшает удовлетворенность клиента – он создает его лояльность. По нашему опыту, компании, использующие агентов ИИ с поддержкой памяти, сообщили об увеличении удовлетворенности клиентов на 20–30 % благодаря бесшовным, персонализированным взаимодействиям, которые кажутся более человечными, чем простое проведение транзакций.

Операционные преимущества не менее значительны. Рассмотрим логистическую фирму, управляющую сбоями в цепочке поставок. С ИИ, поддерживающим память, шаблоны прошлых проблем – таких как задержки из-за погоды или региональные узкие места – сохраняются и применяются в ре-

альном времени, позволяя быстрее разрешать проблемы и более разумно распределять ресурсы.

Аналогично для сотрудников, обучающихся с помощью агентов ИИ, сокращается время обучения, поскольку эти системы помнят организационные нюансы и предоставляют последовательное руководство. По нашему опыту, предприятия, внедряющие долгосрочную память в свои системы ИИ, зафиксировали снижение частоты ошибок до 50 %, что заметно сократило неэффективность и повысило производительность.

Стратегические преимущества еще более убедительны. Агенты ИИ с долгосрочной памятью превосходно распознают шаблоны во временном развитии, превращая сырые данные в действенные выводы. Например, финансовое учреждение может использовать таких агентов для отслеживания тонких изменений в поведении клиентов, выявляя возникающие риски до их эскалации.

Принятие решений становится более четким, прогнозы более точными, а управление рисками гораздо более проактивным. Это не инкрементные улучшения – это скачки, которые дают бизнесу значительное конкурентное преимущество.

Позволяя ИИ учиться, адаптироваться и расти вместе с организацией, долгосрочная память превращает его из инструмента в стратегического партнера, принося свою пользу на каждом уровне предприятия.

Современные LLM ограничены в использовании долгосрочной памяти

Как показал наш предыдущий эксперимент, когда мы спрашивали о дайвинге на Таити, современные LLM, такие как ChatGPT, ограничены в использовании LTM. Это ограничение не случайно – это сознательный компромисс для оптимизации эффективности, защиты конфиденциальности и избежания перегрузки модели избыточными данными.

Чтобы устранить это, создание агентов ИИ *требует предоставления LLM доступа к внешним ресурсам памяти*. В следующих разделах мы исследуем эти возможности, которые представляют значительные шаги к ИИ с поддержкой памяти. Однако каждая из них имеет свои собственные ограничения и компромиссы. Вместе они формируют основу современных усилий по созданию более умных, более адаптивных агентов ИИ.

РАЗРАБОТКА И ВНЕДРЕНИЕ ДОЛГОСРОЧНОЙ ПАМЯТИ В СИСТЕМАХ АГЕНТНОГО ИИ

В следующих страницах мы пройдем через наш проверенный в боях подход к разработке систем памяти, фреймворки, которые мы нашли наиболее эффективными, и ловушки, которых мы научились избегать. Независимо от того, улучшаете ли вы существующих агентов ИИ или создаете новых с нуля, это руководство поможет вам внедрить архитектуры памяти, которые приносят реальную пользу.

Что такое ландшафт памяти

Прежде чем углубляться в реализацию, нам нужно установить четкое понимание того, что означает память в контексте агентов ИИ. По нашему опыту, успешные системы памяти требуют нескольких взаимодополняющих типов памяти, работающих в согласованности.

Когда мы говорим о памяти в системах ИИ, мы имеем в виду структурированные механизмы, которые позволяют агентам хранить, извлекать и использовать информацию во временном развитии. В отличие от простых контекстных окон, которые характеризуют большинство языковых моделей, настоящая память ИИ создает персистентность¹ от сессии к сессии и позволяет учиться на прошлых взаимодействиях.

Память ИИ обычно делится на три основные категории.

Эпизодическая память представляет собой эмпирические знания агента – что произошло, когда и с кем. Это включает истории разговоров, предпочтения пользователей, выраженные во временном развитии, предпринятые действия и наблюдаемые результаты. Эпизодическая память позволяет нашим агентам поддерживать непрерывность от одного взаимодействия до другого, даже если они разделены днями или неделями. Когда агент финансового консультирования вспоминает, что клиент ранее выражал интерес к низкорисковым инвестициям, это работает эпизодическая память.

Семантическая память охватывает фактические знания – то, что наш агент «знает», а не «помнит, что пережил». Это включает знания о домене, факты о мире, политику компании, каталоги продуктов и любую другую информацию, существующую независимо от конкретных взаимодействий. Мы обнаружили, что надежная семантическая память позволяет агентам предоставлять точную информацию без необходимости запрашивать внешние системы для каждого запроса.

Процедурная память фиксирует знания «как сделать» – последовательности действий, деревья решений и рабочие процессы, которые направляют агента в процессе решения сложных задач. При создании агентов службы поддержки клиентов мы кодируем процедуры устранения неполадок в процедурную память, позволяя агенту проводить пользователей через сложные процессы шаг за шагом.

Магия происходит, когда эти типы памяти работают вместе. В нашей работе с поставщиком медицинских услуг мы создали агента, который мог вспомнить медицинскую историю пациента (эпизодическая память), применять клинические руководства (семантическая память) и следовать правильным протоколам для планирования процедур (процедурная память). Результатом стала система, которая могла предоставлять персонализированное руководство по уходу, сохраняя строгое соответствие медицинским нормам.

¹ Персистентность – это способность системы сохранять данные, состояние или знания между сеансами работы для обеспечения непрерывности процессов или накопления информации. Например, в многоагентных системах, таких как Sales Info Agent, персистентность позволяет сохранять результаты веб-поиска или подцели, чтобы использовать их в будущем, поддерживая инкрементальное развитие и предотвращая потерю данных при перезапуске. – *Прим. ред.*




Рис. 7.2. Три типа долговременной памяти (Источник: © Борне и др.)

Архитектурные основы долговременной памяти

Создание эффективной долговременной памяти требует продуманного архитектурного подхода. Через наши внедрения мы усовершенствовали архитектуру памяти, которая балансирует производительность, масштабируемость и практичность.

Каждый тип памяти требует специфических решений для хранения, оптимизированных для его уникальных характеристик.

Для *эпизодической памяти* мы внедряем быстрое, эффективное хранилище для недавних взаимодействий и контекстной истории. Redis или подобные базы данных оперативной памяти лучше всего подходят для хранения краткосрочной эпизодической памяти, обеспечивая быстрый доступ к недавним разговорам без сложных механизмов извлечения. Хранилище должно включать временные метки, идентификаторы пользователей, обзоры взаимодействий и определенные сущности/намерения. Для одного розничного клиента этот подход сократил задержку ответа на 40 % по сравнению с предыдущим решением, которое применяло извлечение всех исторических взаимодействий для каждого запроса.

Для *семантической памяти* мы внедряем векторные базы данных, такие как Pinecone или Weaviate, для хранения семантических эмбедингов – числовых представлений концепций, фактов и знаний, которые позволяют выполнять извлечение на основе схожести¹. Эти базы данных превосходно находят концептуально связанную информацию, даже когда точные совпадения по ключевым словам отсутствуют. Этот тип памяти требует структурированной организации с четкой категоризацией, связями и метаданными для облегчения точного извлечения.

Для *процедурной памяти* мы храним определения рабочих процессов, деревья решений и карты процессов в структурированных форматах, обычно используя традиционные реляционные базы данных или специализированные

¹ Эмбединг (от англ. *embedding* – вложение) – способ представления объектов (слов, предложений, изображений и других типов данных) в виде числовых векторов. Эти векторы позволяют системам ИИ работать с данными и анализировать их взаимосвязи. – Прим. ред.

движки рабочих процессов. Эти системы должны поддерживать целостность шагов процесса, логику решений и условное ветвление. Для сложной процедурной памяти мы часто внедряем версионирование для отслеживания изменений процессов во временном развитии.

Для комплексных внедрений агентов мы комбинируем эти специализированные хранилища. В нашей работе с компанией в области юридических технологий этот комбинированный подход создал агента, который из эпизодической памяти мог извлечь конкретные цитаты из дел (точное соответствие из реляционной базы данных), получать доступ к правовым принципам из семантической памяти (сходство из векторной базы данных) и следовать правильным процедурам юридического анализа из процедурной памяти (системы рабочих процессов). Эта комбинация обеспечивала как точность, так и гибкость для всех типов памяти.

Путь внедрения: создание памяти с нуля

Теперь давайте пройдем по рекомендуемому нами пути внедрения, основанном на опыте создания десятков агентов с улучшенной памятью.

Шаг 1. Выбор фреймворка для внедрения

После определения архитектуры памяти следующим шагом является выбор технологического фреймворка, который поддерживает персистентность памяти, механизмы извлечения и обновления. На основе наших внедрений в различных доменах мы рекомендуем рассмотреть следующие проверенные варианты.

LangChain предоставляет отличную отправную точку для интеграции эпизодической, семантической и процедурной памяти в агентов, работающих на базе LLM. Его модуль памяти предлагает встроенную поддержку краткосрочной разговорной памяти (эпизодической) и долгосрочного хранения знаний (семантической и процедурной). Мы обнаружили, что *LangChain* особенно ценен для быстрого прототипирования и проектов, где важна гибкость интеграции.

LlamaIndex (ранее *GPT Index*) помогает организовывать, хранить и динамически извлекать память. Он превосходно справляется с созданием и поддержкой структурированных индексов знаний, которые можно эффективно запрашивать, что делает его идеальным для приложений с сложными требованиями к семантической памяти. *LlamaIndex* доказал свою высокую эффективность в наших внедрениях для домен-специфичных агентов, которым нужно получить доступ к большим базам знаний.

Шаг 2. Определение требований к памяти

После выбора фреймворка мы определяем конкретные требования к памяти для каждого типа памяти в зависимости от назначения агента.

Для требований эпизодической памяти мы определяем:

- какие взаимодействия с пользователем и элементы разговора должны сохраняться от сессии к сессии;
- как долго должны храниться различные типы эпизодической информации;
- какие предпочтения и поведение пользователей должны отслеживаться во временном развитии.

Для требований семантической памяти мы определяем:

- какие знания о домене необходимы для выполнения задач агентом;
- какие источники информации должны заполнять базу знаний;
- какие требования к соблюдению нормативов или регулированию должны поддерживаться.

Для требований процедурной памяти мы определяем:

- какие рабочие процессы и процедуры должен выполнять агент;
- какая логика решений управляет выбором и выполнением процессов;
- насколько строго должны соблюдаться процессы в противовес гибкости.

Например, для агента финансового консультирования мы определили, что эпизодическая память должна включать инвестиционные предпочтения, историю разговоров и ранее данные советы; семантическая память должна содержать детали инвестиционных продуктов и рыночные данные; а процедурная память должна кодировать рабочие процессы соответствия для различных сценариев консультирования. Детали транзакций, с другой стороны, запрашивались бы из безопасных систем, а не хранились в памяти агента.

Определение этих конкретных требований для каждого типа памяти заранее предотвращает как перегрузку памяти (хранение слишком большого объема данных, создающее неэффективность извлечения), так и пробелы в памяти (недостаточное хранение, заставляющее пользователей повторяться).

Шаг 3. Создание механизмов извлечения

После настройки хранилища мы сосредотачиваемся на создании эффективных механизмов извлечения. Цель – вызывать правильные воспоминания в нужное время, не перегружать агента нерелевантной информацией.

Мы обнаружили, что подход генерации с дополнением поиском (Retrieval-augmented generation, RAG)¹ хорошо работает для агентов с улучшенной памятью. Проще говоря, RAG сочетает мощь извлечения знаний с генерацией языка. Подумайте об этом как о предоставлении агенту ИИ способности «искать информацию» в своей памяти перед формулировкой ответа, подобно тому, как люди могут обращаться к своим воспоминаниям или справочным материалам перед ответом на сложный вопрос.

Вот как работает RAG на практике, когда агент получает запрос пользователя.

1. Он анализирует запрос и текущий контекст и создает подсказки для извлечения.
2. Использует эти подсказки для получения релевантных воспоминаний из каждого хранилища.
3. Ранжирует и фильтрует извлеченные воспоминания на основе релевантности, новизны и важности.

¹ Генерация с дополнением поиском – это метод, сочетающий генеративные модели (например, трансформеры) с поиском данных из внешних источников, таких как базы данных или веб-поиск, для создания более точных и контекстно-релевантных ответов. В отличие от чистой генерации RAG извлекает релевантную информацию (например, через скрейпинг экрана или in-memory databases) и использует ее для улучшения результатов, минимизируя галлюцинации. – *Прим. ред.*

4. Интегрирует наиболее релевантные воспоминания в свой процесс рассуждения.
5. Генерирует ответ, который использует как текущий контекст, так и извлеченные воспоминания.

Этот подход значительно улучшает способность агента предоставлять точные, контекстно релевантные ответы. Вместо того чтобы пытаться закодировать все возможные знания в самой модели, RAG позволяет агенту динамически получать доступ к конкретной информации, необходимой для каждого взаимодействия.

Для нашего помощника по юридическим исследованиям этот подход позволил агенту вспоминать релевантные судебные дела и законы, не перегружая ответ неуместными ссылками. Ключом была тщательная настройка порогов релевантности – слишком низкий порог, и агент пропускал важные прецеденты; слишком высокий, и ответы становились перегруженными побочной информацией.

Шаг 4. Внедрение консолидации памяти

Пожалуй, самым важным компонентом нашей архитектуры памяти является механизм консолидации – процесс, определяющий, что запоминать долгосрочно, а что забывать. Он определяет, какая информация будет перенесена из эпизодической в семантическую или процедурную память. Через эксперименты мы разработали следующий многогранный подход к консолидации памяти.

- *Консолидация на основе важности* оценивает значимость новой информации. Когда пользователь предоставляет критические детали, такие как предпочтения, требования или дополнительные комментарии, наша система помечает эту информацию для долгосрочного хранения. Для агента бронирования путешествий, которого мы разработали, это означало постоянное запоминание того, что пользователь предпочитает места у прохода или имеет аллергию на моллюсков.
- *Консолидация на основе частоты* отслеживает повторяющиеся шаблоны. Информация, которая часто встречается в разных взаимодействиях, вероятно, важна и переводится в долгосрочную память. Наш агент репетиторства использует это для выявления и устранения повторяющихся пробелов в знаниях у студентов.
- *Явная консолидация* происходит, когда пользователи или система сознательно помечают информацию для запоминания. Фраза «Запомни, что я предпочитаю вечерние встречи» запускает явную консолидацию в нашем помощнике по планированию.

Обратная сторона консолидации – это забывание, что не менее важно для эффективности системы. Мы внедряем затухание с течением времени для определенных типов информации, пороги релевантности, которые архивируют редко используемые воспоминания, и механизмы явного забывания, когда информация становится устаревшей или неверной.

Шаг 5. Интеграция памяти с рассуждением агента

Заключительный шаг внедрения интегрирует извлечение и консолидацию памяти с основным процессом рассуждения агента. Эта интеграция происходит в трех ключевых точках.

- *Подготовка контекста* включает релевантные воспоминания в контекстное окно до того, как агент генерирует ответ. Для нашего агента финансового консультирования это означало включение профиля риска клиента и инвестиционных целей в контекст каждой рекомендации по инвестициям.
- *Извлечение-в-процессе* позволяет агенту получать дополнительные воспоминания во время процесса рассуждения, если он определяет потребность в дополнительной информации. Наш агент службы поддержки клиентов мог извлекать спецификации продукта в середине разговора, если диалог переходил к техническим деталям.
- *Консолидация после ответа* оценивает взаимодействие после генерации ответа, чтобы определить информацию для долгосрочного хранения. Выразил ли пользователь новое предпочтение? Исправил ли он информацию? Эти выводы фиксируются и консолидируются.

Интеграция памяти с рассуждением превращает ИИ из генератора ответов без состояния в систему, которая развивается с каждым взаимодействием, становясь все более персонализированной и эффективной во временном развитии.

Ближайшее будущее: важнейшие этапы эволюции, которые мы видим на горизонте

В ближайшем будущем мы можем ожидать значительных продвижений в ИИ с улучшенной памятью благодаря прогрессу в вычислительной мощности, алгоритмах и техниках интеграции. Одним из важнейших изменений будет усовершенствование *алгоритмов контекстной приоритизации*, которые позволят системам ИИ лучше определять, какие воспоминания наиболее релевантны в реальном времени. Это сократит задержки при извлечении и повысит способность системы обрабатывать динамично меняющуюся информацию.

Еще одним ближайшим прорывом, вероятно, станет область *консолидации памяти в реальном времени*, где системы будут анализировать и реорганизовывать хранимые данные на лету. Вместо ожидания запланированных обновлений ИИ сможет непрерывно совершенствовать свои банки памяти на основе обратной связи и шаблонов взаимодействий пользователей. Это сделает системы более адаптивными, улучшая их способность реагировать на новые вызовы без переобучения.

Недавние исследования¹ подчеркивают потенциал мультиагентных систем в улучшении управления памятью путем распределения нагрузки на память и усиления сотрудничества. Эти мультиагентные системы позволяют разным агентам сосредотачиваться на конкретных аспектах памяти. Например, некоторые агенты могут обрабатывать эпизодическую память для вспоминания прошлых событий, в то время как другие управляют взаимодействиями в реальном времени или долгосрочными знаниями. Это разделение труда предотвращает перегрузку памяти и повышает эффективность. Агенты в системе могут делиться важнейшими моментами своего опыта из своей эпизодической памяти, обеспечивая совместное обучение. Например, воспоминание одного

¹ Хенхо На и др., 2024. «Эффективное использование эпизодической памяти в совместном мультиагентном обучении с подкреплением», <https://arxiv.org/abs/2403.01112>.

агента об успешной стратегии может инициировать принятие решений другим агентом, уменьшая необходимость системы в избыточном исследовании.

Другое недавнее исследование поднимает все это на совершенно новый уровень. Исследовательская статья «Titans: обучение запоминанию во время тестирования» от Google Research представляет новаторский модуль долгосрочной памяти нейронной сети, который позволяет системам ИИ непрерывно учиться и адаптироваться даже после развертывания¹. В отличие от традиционных моделей ИИ, которые полагаются на векторные базы данных для извлечения знаний (как мы объяснили в предыдущих разделах), Titans интегрирует долгосрочную память в параметры модели, позволяя ей динамически запоминать и вспоминать информацию без внешнего хранилища.

Еще одна интересная особенность – использование обучения на основе неожиданности², приоритизирующего неожиданные или критические входные данные, в то время как встроенный механизм забывания отбрасывает устаревшие данные, обеспечивая эффективность и предотвращая перегрузку памяти, – подобно тому, как человеческая память совершенствуется во временном развитии. Titans также вводит *метаобучение*, позволяя ИИ запоминать релевантные опыты на лету без переобучения. Это обеспечивает адаптацию в реальном времени, делая ИИ более отзывчивым и интеллектуальным в динамичных средах.

В итоге Titans обеспечивают более быструю и лучшую обработку памяти. Это также более безопасно, поскольку чувствительные данные остаются внутри модели, снижая риски конфиденциальности, связанные с облачным хранилищем. Это знаменует значительный сдвиг в том, как агенты ИИ обрабатывают память, и мы с нетерпением ждем, как Titans повлияют на будущее агентов ИИ.

АДАПТАЦИЯ И ОБУЧЕНИЕ ЧЕРЕЗ ЦИКЛЫ ОБРАТНОЙ СВЯЗИ

Неудержимый ученик: видение из будущего

2042 год. В оживленном, полностью автоматизированном логистическом центре за пределами Сингапура появляется новый агент ИИ по имени Nexus в свой первый день. В отличие от гиперспециализированных систем прошлого Nexus для исполнения своей роли предварительно не обучен. Фактически он ничего не знает о задачах, с которыми ему предстоит столкнуться. Нет предварительно загруженных инструкций и нет точно настроенных алгоритмов, адаптированных для этой среды. Вместо этого Nexus несет только одну инструкцию: «Оптимизируй эффективность доставки в центре».

Сначала система спотыкается. Она назначает дроны на неправильные зоны, не учитывает вес посылок и даже вызывает несколько незначительных сбоев,

¹ Али Бехруз и др., 2024. «Titans: обучение запоминанию во время тестирования», <https://arxiv.org/abs/2501.00663>.

² Обучение на основе неожиданности (англ. *Surprise based learning*) – это метод, при котором ИИ обучается, уделяя приоритет неожиданным данным (аномалиям или обратной связи), что позволяет эффективно адаптироваться к новым условиям, как при веб-поиске или скрейпинге экрана. Механизм забывания работает с базами данных оперативной памяти, удаляя устаревшие данные, чтобы поддерживать производительность и избегать перегрузки, усиливая эмерджентное поведение и ритм рассуждений. – Прим. ред.

поскольку вилочные погрузчики хаотично перемещаются по складу. Работники скептически наблюдают, задаваясь вопросом, почему руководство выпустило необученный ИИ в такую критически важную среду. Но Nexus не останавливается. Вооруженный мощью *универсального обучения* и высокоразвитой системой обратной связи, он начинает наблюдать, экспериментировать и адаптироваться.

Через несколько часов Nexus начинает улавливать шаблоны. Посылки, направляющиеся в одно и то же место, консолидируются. Дроны корректируют свои траектории полета в зависимости от загруженности склада. Он замечает, что вилочные погрузчики часто простаивают в ожидании задач, поэтому перестраивает расписание, чтобы максимизировать их использование. Ошибки все еще случаются, но их меньше, чем раньше. К концу второго дня Nexus удвоил свою эффективность. К концу недели он освоил сложную хореографию логистического центра, превосходя даже самых опытных человеческих планировщиков.

Через две недели после появления Nexus логистический центр преобразился. Посылки движутся с почти сверхъестественной точностью, дроны работают с идеальной координацией, а простой вилочных погрузчиков исчезли. Работники, которые когда-то сомневались в Nexus, теперь полагаются на него, восхищаясь его способностью адаптироваться даже к малейшим сбоям. Руководство начинает обсуждать расширение Nexus на другие центры по всему миру.

Nexus воплощает революционную концепцию *универсального ученика* – агента ИИ, который может браться за любую задачу даже без предварительного обучения и достигать мастерства через пробы и ошибки с помощью обратной связи. Преимущества такой системы выходят далеко за рамки логистики. Представьте агента ИИ, которому поручено разработать новую маркетинговую кампанию. Он ничего не знает о вашем бренде или аудитории, но начинает экспериментировать – тестировать слоганы, анализировать данные вовлеченности и совершенствовать свой подход. Через несколько дней он сделает кампанию настолько адаптированной и эффективной, что она сможет конкурировать с работой опытных креативных команд.

Циклы обратной связи – двигатель этой магии. Вместо того чтобы полагаться на статические модели, требующие предварительного обучения на огромных наборах данных, будущие агенты, такие как Nexus, полагаются на динамическое обучение. Они действуют, наблюдают результаты и корректируются, становясь умнее с каждой итерацией. Этот подход не просто делает ИИ адаптивным – он делает его *неудержимым*.

Последствия для бизнеса и общества ошеломляющие. С универсальным обучением барьеры для развертывания ИИ исчезают. Компаниям больше не нужно инвестировать миллионы в обучение систем для узких, специализированных задач. Вместо этого ИИ можно внедрить в любую среду, дать цель и оставить учиться. Это снижает затраты на развертывание, сокращает время до продуктивности и устраняет узкое место в виде необходимости переобучения систем при каждом изменении процессов или целей.

Более того, универсальные ученики, такие как Nexus, по своей природе устойчивы. Они процветают в динамичных средах, непрерывно адаптируясь к новым вызовам. Если правила логистического центра изменятся за одну ночь, например, с введением биоразлагаемой упаковки или дронов с ограничениями по весу, Nexus не потребует обновления. Его цикл обратной связи просто поглотит новые параметры и соответствующим образом скорректирует поведение.

Конечно, это видение будущего поднимает вопросы. Что происходит, когда универсальные ученики сталкиваются с неоднозначными целями? Как мы гарантируем, что они действуют этично, адаптируясь? Ответ кроется в том, как мы разрабатываем их циклы обратной связи. Nexus, например, был оснащен многоцелевой оптимизацией, балансирующей эффективность с безопасностью и экологической устойчивостью. Этические рамки встроены в процесс обучения, гарантируя, что никакое количество проб и ошибок не нарушает основные ценности.

Еще одно соображение – прозрачность. Бизнес-лидеры должны гарантировать, что эти агенты объясняют свои решения, укрепляя доверие среди заинтересованных сторон. Циклы обратной связи, разработанные с учетом подотчетности, могут включать механизмы объяснения действий – предоставляя информацию о том, почему было принято то или иное решение и как оно соответствует целям.

Циклы обратной связи – это основа адаптивных систем, позволяющая агентам ИИ совершенствовать принятие решений, учиться на ошибках и все ближе соответствовать целям во временном развитии. Для бизнес-лидеров концепция обманчиво проста, но инновационна: позвольте системам ИИ анализировать свою производительность, учиться на результатах и использовать это обучение для улучшения будущих действий. Это разница между агентом, который адекватно выполняет задачи в первый день, и тем, который превосходит ожидания на тысячный день.

Магия циклов обратной связи

Циклы обратной связи в ИИ отражают эволюционные процессы жизни на Земле. В эволюции естественный отбор действует как механизм обратной связи, где черты, повышающие выживаемость и воспроизводство, усиливаются через поколения. Аналогично в ИИ циклы обратной связи, такие как обучение с подкреплением, позволяют системам учиться через пробы и ошибки. Обучение с подкреплением¹ работает, вознаграждая желательные действия – те, которые достигают поставленной цели или улучшают производительность, – в то время как неудачи наказываются, подобно тому, как полезные черты «вознаграждаются» в эволюции передачей в будущие поколения. Во временном развитии этот процесс формирует поведение ИИ для максимизации успешных результатов.

Подобно тому, как виды адаптируются к своим средам через итеративные улучшения, модели ИИ развиваются через циклы обучения, учась на ошибках и совершенствуя свои выходные данные. Оба процесса полагаются на непрерывный ввод, адаптацию и итерацию для достижения сложности и эффективности, превращая случайные вариации в оптимизированные, целенаправленные системы во временном развитии.

В своей основе цикл обратной связи – это цикл действия, наблюдения и корректировки. Агент ИИ предпринимает действие, получает обратную связь о его результате и использует эту информацию для совершенствования своего поведения. Этот цикл может работать в реальном времени, как в автономных транспортных средствах, обучающихся навигации на оживленном перекрестке, или в течение более длительных периодов, как в системах рекомендаций, которые развиваются вместе с предпочтениями клиентов.

¹ Ричард С. Саттон и Эндрю Г. Барто, 2018. «Обучение с подкреплением: введение». 2-е изд. Кембридж, Массачусетс: MIT Press.

Почему это важно? Традиционные системы ИИ часто работают в статичных средах, обученные на фиксированных наборах данных, которые захватывают моментальный снимок реальности. Но реальный мир далек от статичности. Рыночные условия меняются, предпочтения клиентов развиваются, конкуренты внедряют инновации. Без механизма адаптации системы ИИ быстро устаревают. Циклы обратной связи решают эту проблему, превращая агента в живую систему – такую, которая становится умнее, взаимодействуя с миром.

Как работают циклы обратной связи?

Все начинается с обратной связи, которая может собираться и применяться разными способами.

- Явная обратная связь от пользователей: агенты запрашивают у пользователей оценки, подтверждения или исправления (например, «Помог ли этот ответ?»).
- Неявная обратная связь: система отслеживает поведение пользователей, такое как уровень завершения задач, прерванные рабочие процессы или исправления ответов.
- Системные сигналы подкрепления: модели вознаграждения усиливают удачные действия (например, успешное выполнение задачи) и препятствуют неудачам (например, неверные рекомендации).

Например, агент поддержки клиентов может спросить: «Решило ли это вашу проблему?» Если пользователь выбирает «Нет», агент регистрирует это как неудачу и корректирует свой подход в будущих взаимодействиях.

Для работы цикла обратной связи агенты работают в цикле наблюдения, оценки и корректировки.

- Наблюдение: агент собирает данные из взаимодействий (обратная связь пользователей, уровень успешности задач, неявные сигналы).
- Оценка: система присваивает балл вознаграждения (положительный или отрицательный) на основе обратной связи.
- Корректировка: агент ИИ совершенствует будущие ответы, обновляя свою модель, запросы или рабочие процессы.
- Развертывание: улучшенный агент развертывается и продолжает учиться во временном развитии.

Например, помощник по личным финансам изначально дает общие советы по бюджету. Если пользователи отклоняют его предложения или запрашивают изменения, он адаптирует свои будущие рекомендации на основе шаблонов предпочтений пользователей.

История успеха цикла обратной связи в производстве

В конце 2022 года один из крупнейших европейских производителей автозапчастей столкнулся с критической проблемой: их процесс контроля качества не успевал за производством. Традиционная автоматизация не могла уловить тонкие дефекты, которые человеческие инспекторы замечали мгновенно. Решение, которое они внедрили, преобразило не только контроль качества, но и наше понимание того, как агенты ИИ учатся.

«Мы перепробовали все», – вспоминает их руководитель по операциям. – Стандартное компьютерное зрение, системы на основе правил, даже базовые модели ИИ. Но дефекты продолжали проскакивать. Нам нужна была не просто более умная система – нам нужна была та, которая могла бы учиться и адаптироваться, как наши лучшие человеческие инспекторы».

Прорыв произошел с внедрением агента ИИ, оснащенного сложными циклами обратной связи. Вместо того чтобы просто отмечать дефекты, система отслеживала результаты своих решений, учась как на успехах, так и на неудачах. Когда она правильно определяла тонкий дефект, этот шаблон укреплялся в ее памяти. Когда она пропускала дефект, она корректировала свои параметры обнаружения.

Но настоящая магия произошла через три месяца после внедрения. Система начала выявлять потенциальные дефекты, которые даже опытные инспекторы не замечали, – тонкие шаблоны, предшествующие более очевидным дефектам. «Это было как инспектор, который мог не только обнаруживать проблемы, но и предсказывать их, – объясняет их директор по контролю качества. – ИИ не просто учился на обратной связи – он открывал новые инсайты, о существовании которых мы даже не подозревали».

Результаты были впечатляющими: точность контроля качества улучшилась на 32 %, а время проверки сократилось на 45 %. Более того, система продолжала улучшаться месяц за месяцем, выявляя новые шаблоны обнаружения дефектов и совершенствуя свое понимание производственного процесса.

Стратегическое преимущество

Для бизнес-лидеров циклы обратной связи предлагают больше, чем просто постепенное улучшение – они обеспечивают стратегическое преимущество в гонке ИИ. Компании, которые внедряют циклы обратной связи, могут опережать конкурентов, создавая системы, которые адаптируются быстрее, учатся лучше и остаются релевантными дольше. В мире, где темп изменений ускоряется, способность развиваться – это не просто актив, это необходимость. Интегрируя циклы обратной связи в своих агентов ИИ, предприятия могут открыть новые уровни эффективности, персонализации и инноваций.

Циклы обратной связи решают некоторые из самых насущных проблем внедрения ИИ. Рассмотрим клиентский опыт. Агент ИИ, разработанный для обработки запросов клиентов, может хорошо работать в день запуска, но что происходит, когда пользователи начинают задавать новые типы вопросов или выражать недовольство новыми способами? Без циклов обратной связи агент застаивается, предлагая нерелевантные ответы и вызывая недовольство клиентов. С циклами обратной связи чат-бот учится на каждом взаимодействии, корректируя свои ответы, чтобы лучше соответствовать потребностям клиентов.

Циклы обратной связи также блестят в динамичных отраслях, таких как электронная коммерция, где агенты ИИ должны реагировать на меняющиеся шаблоны спроса, уровни запасов и цены конкурентов. Они позволяют системам оставаться релевантными, гарантируя, что рекомендации и решения всегда соответствуют текущим реалиям.

Давайте проиллюстрируем влияние циклов обратной связи двумя реальными примерами, с которыми мы работали. Первый пример особенно интересен, потому что он показывает, как агенты ИИ могут оптимизировать промышлен-

ную эффективность, предсказывая и предотвращая дорогостоящие сбои в производстве. Это подчеркивает, как циклы обратной связи не только улучшают техническую точность, но и напрямую способствуют ожидаемым бизнес-результатам, таким как повышение прибыльности и сокращение простоев.

Пример 1. Агент ИИ для прогнозирующего обслуживания в производстве

1. *Начальная задача.* Агент ИИ отслеживает заводское оборудование для предсказания потенциальных поломок и минимизации простоев. Например, он анализирует данные с датчиков, отслеживающих вибрацию, температуру и износ.
2. *Генерация действия.* На основе извлеченных инсайтов ИИ генерирует действенные рекомендации: *«Тип вибрации указывает на износ подшипника в машине X. Запланируйте замену подшипника в течение следующих 72 часов, чтобы предотвратить поломку».*
3. *Автоматизированная обратная связь через метрики дохода.*
 - ♦ Система отслеживает финансовые результаты своих действий, используя заранее определенные показатели, такие как сокращение простоев, снижение затрат на ремонт или увеличение выпуска продукции.
 - ♦ Если вмешательство по обслуживанию предотвращает поломку, это фиксируется как положительный результат и связывается с конкретной рекомендацией и извлеченными данными.
4. *Обучение с положительным подкреплением.*
 - ♦ ИИ укрепляет связь между типами вибрации и износом подшипников в своей предсказательной модели.
 - ♦ Он помечает извлеченные данные как высоко релевантные для подобных проблем, улучшая точность извлечения для будущих аномалий.
5. *Обновление памяти.*
 - ♦ Журналы обслуживания, и результаты этого события добавляются в базу данных, создавая новые знания, которые система может использовать в будущем.
 - ♦ Система также включает анализ затрат и выгод, связывая конкретные действия с сохраненным или полученным доходом.
6. *Адаптивное поведение.* Во временном развитии ИИ становится лучше в раннем выявлении тонких признаков поломки, оптимизируя свои рекомендации для сокращения дорогостоящих простоев. Он также может научиться приоритизировать действия на основе финансового воздействия, гарантируя, что наиболее критические вмешательства рассматриваются в первую очередь.

В результате ИИ-агент максимизирует эффективность, минимизируя производственные потери, сокращая дорогостоящие аварийные ремонты и повышая общую эффективность производственного процесса. Каждое успешное предсказание и вмешательство совершенствует его модели и базу данных извлечения, повышая долгосрочную прибыльность.

Пример 2. Агент ИИ для персонализированных рекомендаций продуктов

Второй пример демонстрирует инновационный потенциал циклов обратной связи в электронной коммерции, где персонализация повышает удовлетворенность клиентов и рост доходов. Он показывает, как агент ИИ учится на поведении пользователей, чтобы совершенствовать свои рекомендации, создавая цикл непрерывного улучшения, который идеально соответствует динамичным рыночным требованиям и индивидуальным предпочтениям.

1. *Начальное взаимодействие.* Пользователь заходит на сайт электронной коммерции и ищет «удобные кроссовки для бега по пересеченной местности». Агент ИИ обрабатывает этот ввод и создает вложение, которое фиксирует предпочтение пользователя в комфорте и обуви, предназначенной для бега по пересеченной местности.
2. *Генерация ответа.* ИИ генерирует персонализированную рекомендацию: «На основе вашего поиска мы рекомендуем кроссовки TrailMax Comfort Runner, разработанные для сложных местностей с дополнительной амортизацией. Они доступны с вашим размером за 120 долларов. Хотите посмотреть отзывы или добавить кроссовки в корзину?»
3. *Автоматизированный сбор обратной связи.*
 - ♦ Агент отслеживает, нажимает ли пользователь на рекомендацию, добавляет ли продукт в корзину или завершает покупку.
 - ♦ Положительные сигналы (например, покупка или клик) подтверждают успех рекомендации.
 - ♦ Негативные сигналы (например, пользователь игнорирует предложение или продолжает поиск) указывают на необходимость улучшения.
4. *Обучение с положительным подкреплением.*
 - ♦ Если пользователь покупает TrailMax Comfort Runner, система рассматривает это как положительный результат, усиливая подобные рекомендации для будущих пользователей с аналогичными запросами.
 - ♦ ИИ обновляет свои вложения, сильнее связывая *комфорт* и *бег по пересеченной местности* с продуктами, которые хорошо продаются и удовлетворяют клиентов.
5. *Обновление памяти.*
 - ♦ Продукты с постоянно высокими показателями конверсии для конкретных запросов помечаются как наиболее успешные и приоритизируются в будущих рекомендациях.
 - ♦ ИИ также интегрирует пользовательские отзывы, такие как рецензии и оценки, в свою базу данных для улучшения понимания предпочтений клиентов.
6. *Адаптивное поведение.*
 - ♦ Во временном развитии ИИ учится приоритизировать продукты, которые соответствуют предпочтениям пользователей и имеют более высокую вероятность генерации дохода. Например, он может начать предлагать товары с немного более высокой ценой, но с лучшими отзывами, если они имеют сильную историю покупок.

Когда другой пользователь ищет *«кроссовки для бега по пересеченной местности»*, ИИ немедленно предлагает наиболее успешные, высокодоходные продукты, адаптированные к похожим предпочтениям, повышая шансы на конверсию и увеличивая доход. Этот цикл обратной связи гарантирует, что поведение агента непрерывно адаптируется к предпочтениям клиентов и бизнес-целям.

Производительность сегодня: что приносят циклы обратной связи

Циклы обратной связи уже обеспечивают инновационные улучшения производительности в различных отраслях. Сегодня, основываясь на нашем опыте, агенты ИИ, оснащенные хорошо разработанными циклами обратной связи, могут достигать замечательных подвигов в адаптивности и точности. Например, они могут улучшить точность своих ответов более чем на 20 % в течение нескольких недель после развертывания, анализируя взаимодействия с пользователями и участвуя на них. В электронной коммерции движки рекомендаций, работающие на основе циклов обратной связи, часто видят увеличение кликов на 10–30 %, поскольку они адаптируются к изменяющимся предпочтениям клиентов в реальном времени.

Однако производительность не одинакова для всех приложений. Эффективность циклов обратной связи зависит от сложности среды и качества данных. В относительно стабильных условиях, таких как обнаружение мошенничества или управление запасами, циклы обратной связи могут привести к почти оптимальной производительности в течение нескольких месяцев. В более динамичных или непредсказуемых средах, таких как финансовые рынки или моделирование человеческого поведения, кривая улучшения может быть медленнее, но потенциал для прорывов огромен.

Ограничения и этические соображения

Для эффективного использования циклов обратной связи бизнес-лидерам необходимо учитывать несколько критических факторов, чтобы обеспечить оптимальное и этичное функционирование их систем искусственного интеллекта.

Ключевое соображение – своевременность. Обратная связь, которая задерживается или устаревает, значительно препятствует способности системы ИИ адаптироваться к динамичным средам. Системы должны обрабатывать и действовать на основе данных как можно ближе к реальному времени, чтобы оставаться релевантными, особенно в быстро меняющихся отраслях, таких как финансы или логистика. Без своевременной обратной связи весь цикл может дать сбой, приводя к неоптимальным результатам.

Прочная инфраструктура – еще одно важное соображение. Циклы обратной связи требуют систем, способных эффективно обрабатывать большие объемы данных. Облачные платформы, такие как AWS или Azure, предоставляют масштабируемые решения для сбора, обработки и анализа данных в масштабах, необходимых для сложных систем ИИ. Без этой инфраструктуры организации сталкиваются с узкими местами, которые могут ограничивать адаптивность и производительность их систем ИИ.

Человеческий надзор критически важен для избежания нежелательных последствий. Хотя циклы обратной связи позволяют системам ИИ работать

со значительной автономией, их решения должны контролироваться, чтобы обеспечить соответствие организационным целям и этическим стандартам. Регулярные аудиты выходных данных системы необходимы как для обеспечения точности, так и для устранения потенциальных отклонений или непреднамеренных поведений.

Этическая проблема – это манипуляция пользователями. В стремлении оптимизировать результаты системы ИИ, особенно движки рекомендаций, могут использовать психологические триггеры или подталкивать пользователей к аддиктивному контенту. Хотя такие практики могут приносить краткосрочные выгоды, они рискуют подорвать доверие и долгосрочные отношения с пользователями. Организации должны найти баланс, разрабатывая циклы обратной связи, которые приоритизируют благополучие пользователей наряду с бизнес-целями компании.

Переобучение¹ – распространенное ограничение, когда системы ИИ становятся слишком сосредоточенными на оптимизации конкретной метрики, теряя из виду общую картину. Например, ИИ службы поддержки клиентов может так сильно приоритизировать сокращение времени ответа, что жертвует качеством своих ответов. Это происходит, потому что ИИ учится «запоминать» шаблоны, которые хорошо работают для одной цели, вместо того чтобы адаптироваться к множеству сценариев. Чтобы предотвратить это, используется многоцелевая оптимизация для балансировки приоритетов, таких как скорость, точность и удовлетворенность пользователей, гарантируя, что ИИ хорошо работает в нескольких областях, не становясь слишком узконаправленным.

На практике успешное внедрение циклов обратной связи требует тщательной разработки, бдительного мониторинга и этического предвидения. При правильном подходе циклы обратной связи могут стимулировать системы ИИ к непрерывному улучшению и адаптации, принося огромную пользу для бизнеса.

Эволюция впереди: краткосрочные и долгосрочные перспективы

В краткосрочной перспективе мы можем ожидать, что циклы обратной связи станут более бесшовными и автоматизированными. Прогресс в обработке данных в реальном времени и краевых вычислениях уже обеспечивает более быстрые и эффективные циклы обратной связи. Например, персонализация в реальном времени в маркетинге станет более тонкой, поскольку системы ИИ интегрируют мгновенные ответы пользователей для динамической корректировки своих стратегий. В логистике циклы обратной связи, работающие на основе ИИ, произведут революцию в операциях, реагируя на условия трафика, изменения погоды и колебания спроса на лету, сокращая время доставки и затраты.

¹ Переобучение ИИ (англ. *overfitting*) – это состояние, при котором модель ИИ, такая как трансформерная модель, слишком сильно подстраивается под обучающие данные, включая их шумы и особенности, что приводит к высокой точности на тренировочном наборе, но к низкой обобщающей способности на новых данных. Это снижает эффективность модели в реальных задачах, таких как веб-поиск или прогнозирующее обслуживание, и может вызывать ошибки, например, галлюцинации или неправильные выводы. – Прим. ред.

В ближайшие несколько лет интеграция обучения с подкреплением с передовыми механизмами обратной связи еще больше расширит границы. Агенты не только будут учиться на индивидуальных действиях, но и разовьют способность обобщать обучение на разные задачи. Например, складской робот, обученный складывать коробки, сможет перенести свое обучение на другие задачи, такие как сборка продуктов, с минимальным переобучением. Эта межзадачная адаптивность значительно расширит применимость циклов обратной связи, делая системы ИИ более универсальными и устойчивыми.

В долгосрочной перспективе агенты ИИ, вероятно, будут интегрировать несколько циклов обратной связи одновременно, каждый из которых будет решать разные аспекты производительности, такие как скорость, качество и удовлетворенность пользователей. Представьте агента ИИ, который не только изучает ваше расписание, но и адаптирует свой тон, стиль и даже уровень проактивности на основе нюансированной обратной связи от взаимодействий с вами.

Недавняя работа Хоспедалеса и др. предполагает, что мы приближаемся к так называемым метаобучающим системам – агентам ИИ, которые не просто учатся на опыте, но учатся учиться более эффективно¹. Их ранние эксперименты показывают, что эти системы адаптируются к новым ситуациям быстрее, иногда даже вдвое быстрее, чем традиционные подходы к обучению.

Самооптимизирующиеся структуры и автономная эволюция представляют два взаимодополняющих аспекта структурной адаптивности в ИИ. Самооптимизирующиеся структуры сосредотачиваются на задачах, специфичных для корректировок, где циклы обратной связи позволяют системам ИИ динамически перестраивать свою архитектуру в реальном времени для повышения эффективности и производительности. Например, недавние исследования показывают, как ИИ может оптимизировать себя слой за слоем во время обучения, гарантируя, что он остается релевантным и эффективным в ресурсах перед лицом немедленных требований².

Автономная эволюция, однако, идет дальше. Как показывают недавние исследования³, агенты ИИ могут использовать обратную связь не только для оптимизации настоящего, но и для эволюции совершенно новых фреймворков, которые готовят их к будущим задачам или средам. Этот процесс отражает биологическую эволюцию, где выживание зависит от итеративного роста и адаптации, делая системы ИИ способными справляться с вызовами, выходящими за рамки их первоначального предназначения.

¹ Тимоти Хоспедалес и др., 2020. «Метаобучение в нейронных сетях: обзор», <https://arxiv.org/abs/2004.05439>.

² Альваро Г. Диас и Хьюгес Берсини, 2020. «Самооптимизация архитектур плотных нейронных сетей: инкрементальный подход». 2020 International Joint Conference on Neural Networks (IJCNN), <https://doi.org/10.1109/IJCNN48605.2020.9207416>.

³ Чжэнхао Шуай и др., 2023. «Самоадаптивный нейроэволюционный подход к построению архитектур глубоких нейронных сетей для разных типов», <https://arxiv.org/abs/2211.14753>.

Вместе эти достижения показывают инновационный потенциал циклов обратной связи в формировании систем ИИ, которые являются не только более осведомленными, но и структурно адаптивными. Эта эволюция позиционирует обратную связь как движущую силу ИИ, который учится, развивается и соответствует как практическим, так и человеко-ориентированным целям, предлагая взгляд на будущее, где машины растут вместе с человечеством.

Понимание того, как работает память в ИИ, – это одно, а успешное ее внедрение – это совсем другой вызов. Как сказал нам один технологический лидер из компании списка Fortune 100, «мы думали, что добавление памяти в наш ИИ будет похоже на трансформацию оперативной памяти компьютера. Вместо этого это было как обучение ребенка учиться на опыте – сложно, нюансированно, но невероятно мощно, если сделано правильно».

Истории внедрения, описанные далее, раскрывают как ловушки, так и проверенные пути к успеху. Вы узнаете, почему некоторые организации достигают выдающихся результатов с ИИ, поддерживающим память, в то время как другие с трудом видят какую-либо выгоду. Более того, вы узнаете о практических шагах для обеспечения того, чтобы ваше внедрение оказалось на правильной стороне этого водораздела.

Через нашу работу с сотнями организаций мы выделили эти уроки в четкую формулу успеха. Независимо от того, начинаете ли вы свой путь с памяти ИИ или стремитесь улучшить существующие системы, эти уроки помогут вам двигаться вперед.

ЛУЧШИЕ ПРАКТИКИ УПРАВЛЕНИЯ ПАМЯТЬЮ ИИ-АГЕНТОВ

Руководство группами для правильного использования памяти агента

Наш опыт показал, что внедрение памяти в агенты ИИ – это только отправная точка. Чтобы раскрыть ее полный потенциал, критически важно принять практики, которые обеспечивают, что эта способность приносит измеримые выгоды, избегая неэффективности или рисков. Как и для любого другого мощного инструмента, истинная ценность памяти зависит от того, как она используется. За годы мы разработали стратегии, которые позволяют бизнесу эффективно использовать память ИИ, минимизировать ловушки и поддерживать доверие к внедряемым системам искусственного интеллекта.

Во-первых, релевантность – это ключевой фактор. Системы памяти ИИ эффективны только в той мере, в какой они руководимы пользователями. Они играют активную роль в формировании того, что ИИ сохраняет, подчеркивая критически важную информацию во время взаимодействий. Это может включать повторение важных моментов, явное указание их важности или использование структурированных протоколов для пометки определенной информации как «важной» или «архивируемой». Например, в управлении проектами пользователи могут выделять вехи, решения и препятствия, которые жизненно важны для долгосрочного отслеживания. Однако цель не в том, чтобы ИИ запо-

минал все, – цель в сохранении информации, которая приводит к лучшим результатам. Избегание перегрузки памяти путем фильтрации незначительных деталей гарантирует, что система остается сфокусированной и эффективной.

Еще одна хорошая практика – использование обобщения для обновления контекста. Агенты ИИ, оснащенные памятью, превосходно справляются, когда могут плавно вспоминать прошлые взаимодействия, но пользователи не всегда помнят, что знает ИИ. Обобщение закрывает этот разрыв, позволяя пользователям синхронизироваться с памятью ИИ. Запрос пересказа – например, *«Каковы важнейшие выводы из нашей последней сессии?»* или *«Можете ли вы обобщить мои приоритеты для этого проекта?»* – обеспечивает непрерывность и согласованность работы. Обобщения действуют как контрольные точки, помогая пользователям проверять и корректировать понимание ИИ по мере возникающей необходимости. В командных условиях это становится еще более мощным. Представьте маркетинговую команду, использующую помощника ИИ для управления кампаниями. Перед каждым еженедельным собранием ИИ мог бы предоставлять обзор текущих усилий, метрик производительности и уроков из прошлых кампаний, экономя время и удерживая всех на одной волне.

Аудиты памяти – еще один критически важный аспект эффективного управления памятью. Подобно тому, как люди периодически размышляют, чтобы прояснить свои мысли, системы ИИ выигрывают от регулярных проверок их памяти. Эти аудиты помогают выявить нерелевантную, устаревшую или неверную информацию и позволяют пользователям уточнять, что сохраняет ИИ. Например, ИИ службы поддержки клиентов может по-прежнему хранить устаревший адрес клиента или его устаревшие покупательские привычки. Проверка и очищая память ИИ, бизнес может обеспечить точность и надежность. Структурированные протоколы аудита, такие как запланированные проверки памяти с командами специалистов, могут уточнить приоритеты ИИ и согласовать его память с бизнес-целями.

Балансировка глубины памяти и конфиденциальности, пожалуй, самый чувствительный аспект управления памятью ИИ. Хотя память позволяет глубокую персонализацию и контекстное понимание, она также требует доверия пользователей к ИИ с чувствительными данными. Прозрачность в этом вопросе не подлежит обсуждению. Бизнес должен четко сообщать, как управляется память, и предлагать пользователям контроль над их данными. Это включает функции, которые позволяют пользователям видеть, что помнит ИИ, редактировать или удалять конкретные воспоминания и устанавливать границы для того, что ИИ может сохранять. Приоритизация безопасных практик хранения, таких как разделение чувствительной информации и применение строгих контролей доступа, необходима.

Из нашего опыта успешное внедрение памяти в системы ИИ требует проактивного подхода, который сочетает релевантность, обобщение, аудит, обратную связь и конфиденциальность. Принимая эти лучшие практики, предприятия могут превратить память ИИ в мощный актив, который повышает эффективность, укрепляет доверие и обеспечивает значимые результаты. Путешествие не заканчивается внедрением – это непрерывный процесс уточнения, согласования и этического управления, чтобы гарантировать, что система ИИ развивается вместе с потребностями организации.

Устранение проблем конфиденциальности и обеспечение прозрачности

Управление конфиденциальностью и этическими проблемами в системах памяти ИИ критически важно, поскольку долгосрочное сохранение памяти связано с обработкой чувствительных данных пользователей. Агенты ИИ, особенно те, что обладают возможностями памяти, могут собирать и хранить информацию, такую как личные предпочтения, истории взаимодействий или даже шаблоны поведения. Хотя эти функции обеспечивают персонализацию и улучшают пользовательский опыт, они также вводят значительные риски для конфиденциальности данных и соответствия нормам, таким как Общий регламент по защите данных (GDPR) или Закон о защите конфиденциальности потребителей Калифорнии (CCPA).

Первый шаг в управление конфиденциальностью – минимизация сбора данных только до того, что необходимо. Лидеры должны принять подход «конфиденциальность по умолчанию», гарантируя, что защита данных является важнейшим соображением с самого начала разработки. Например, внедрение механизмов, которые анонимизируют или псевдонимизируют данные перед их сохранением в долгосрочной памяти. С удаленными прямыми идентификаторами чувствительная информация будет защищена даже в случае утечки. Кроме того, нужно использовать техники минимизации данных, которые ограничивают хранение ненужных или чрезмерно детализированных данных, и регулярные аудиты для выявления и удаления устаревшей или нерелевантной информации.

Соответствие нормам, таким как GDPR и CCPA, – еще один важный аспект. Эти законы предоставляют пользователям права над их данными, такие как доступ, удаление или ограничение использования их информации. Системы памяти ИИ должны быть разработаны с учетом этих прав. Например, если пользователь просит систему ИИ «забыть» конкретную информацию, система должна иметь механизмы для удаления соответствующих данных из своих баз данных, включая резервные копии и долгосрочное хранилище. Более того, компании должны обеспечивать прозрачность, четко сообщая пользователям, какие данные собираются, как они будут использоваться и как долго они будут храниться.

С практической точки зрения надежное шифрование данных как в покое, так и в процессе передачи не подлежит обсуждению. Лидеры индустрии должны делать инвестиции в безопасные технологии баз данных и следовать лучшим отраслевым практикам хранения данных. Доступ к системам памяти должен быть ограничен только авторизованным персоналом или процессами, с ведением журналов активности для отслеживания, кто и когда получал доступ к данным. Внедрение этих мер снижает вероятность несанкционированного доступа или утечек, которые могут серьезно подорвать доверие пользователей и привести к регуляторным штрафам.

Этические вопросы выходят за рамки конфиденциальности и включают такие проблемы, как предвзятость и неправильное использование данных. Агенты ИИ с возможностями памяти могут усиливать предвзятости, если они чрезмерно полагаются на исторические данные, отражающие устаревшие или

искаженные перспективы. Лидеры должны гарантировать, что их системы ИИ проходят непрерывное тестирование и проверку на предвзятость. Кроме того, организации должны установить четкие политики в отношении этичного использования систем памяти ИИ, включая определение допустимых границ для хранения данных и персонализации, чтобы предотвратить практики навязывания или манипулятивные практики.

В итоге управление конфиденциальностью и этическими проблемами в памяти ИИ – это не только вопрос о соответствии нормам; это вопрос о создании доверия и содействии ответственному использованию ИИ. Акцентируя безопасную обработку данных, соответствие нормам и проактивное решение этических вопросов, лидеры могут гарантировать, что их системы ИИ эффективны и уважают права и ожидания пользователей.

Балансировка инноваций и конфиденциальности на примере поставщика медицинских услуг

Когда ведущий поставщик медицинских услуг в США решил внедрить ИИ с поддержкой памяти для координации ухода за пациентами в 2024 году, он столкнулся с, казалось бы, невыполнимой задачей: как создать систему ИИ, которая могла бы учиться на взаимодействиях с пациентами, сохраняя строгое соответствие HIPAA и конфиденциальность пациентов.

«Ставки не могли быть выше, – рассказывает нам их главный офицер по конфиденциальности. – Нам нужен был ИИ, который мог бы помнить и учиться на взаимодействиях с пациентами, чтобы предоставлять лучший уход, но единичная утечка конфиденциальности могла бы иметь катастрофические последствия».

Их решение сочетало инновационные технологии с тщательным управлением. Они внедрили многослойную архитектуру памяти, где идентифицирующая пациента информация строго отделялась от шаблонов поведения и клинических выводов. ИИ мог учиться на агрегированных шаблонах, не получая доступа к индивидуальным данным пациентов, используя так называемые «шаблоны обучения с сохранением конфиденциальности».

Техническое внедрение было лишь началом. Был установлен четкий фреймворк управления, который включал:

- регулярные аудиты конфиденциальности систем памяти ИИ;
- автоматизированное обнаружение потенциальных рисков конфиденциальности;
- четкие протоколы для хранения и удаления данных;
- контроль пациентов над их данными через прозрачный портал.

«Больше всего нас удивило, – размышляет их технический директор, – как этот подход, приоритизирующий конфиденциальность, на самом деле улучшил эффективность ИИ. Сосредоточившись на шаблонах, а не на индивидуальных деталях, система развила более надежные и обобщаемые выводы».

Через год после внедрения результаты говорили сами за себя: эффективность координации ухода улучшилась на 40 % без единой утечки конфиденциальности. Более того, доверие пациентов к системе ИИ, измеряемое через регулярные опросы, достигло 87 % – выше, чем доверие к некоторым традиционным больничным системам.

Рекомендации для технического внедрения

Для успешного внедрения этих слоев необходимо сочетать правильные инструменты, стратегии и технологии – каждая со своими уникальными техническими требованиями и вызовами. Основываясь на нашем опыте, вот практическое руководство, которое поможет вам и вашим техническим командам справиться с этими сложностями, с указанием необходимых инструментов, распространенных ловушек, которые мы наблюдали, и решений для их преодоления.

Таблица 7.1. Рекомендации для внедрения трех слоев памяти (Источник: © Борне и др.)

Слой	Внедрение	Базы данных / Инструменты	Распространенные ловушки	Как устранить
Слой 1 Краткосрочная память	Используйте контекстные окна для обработки немедленных задач с механизмами внимания для приоритизации ключевой информации	Фреймворки ИИ (например, OpenAI GPT, LangChain), оптимизированные для лимитов токенов	Переполнение контекста – потеря критических деталей, когда входные данные превышают лимит токенов	Внедряйте техники обобщения для сжатия информации без потери смысла
Слой 2 Долгосрочная память	Категоризируйте сохраняемую информацию на эпизодическую (события), семантическую (факты) и процедурную (как сделать)	Реляционные базы данных (PostgreSQL) для структурированных данных; NoSQL базы данных (MongoDB) для гибкого хранения. Pinecone для векторного хранения и Neo4j для графов	Сложности с правильной категоризацией информации, приводящие к неэффективности извлечения	Используйте тегирование и метаданные для правильной индексации информации и внедряйте автоматизированные рабочие процессы категоризации
Слой 3 Цикл обратной связи	Непрерывно улучшайте систему через обратную связь пользователей, корректируя приоритизацию памяти и стратегии извлечения	Журналы обратной связи, хранимые в базах данных, таких как BigQuery или Amazon DynamoDB; аналитические инструменты, такие как веб-аналитика	Игнорирование или неправильная интерпретация обратной связи, приводящая к плохим адаптациям	Разрабатывайте четкие метрики успеха и используйте инструменты, такие как обучение с подкреплением, для согласования обновлений ИИ с этими метриками

Каждый слой во фреймворке памяти ИИ строится на предыдущем, полагаясь на бесшовную интеграцию между базами данных и функциями памяти для эффективной работы. Распространенные ловушки, такие как плохо настроенные системы или неструктурированные данные, могут привести к неэффективности извлечения памяти или ненадежной производительности. Устранение требует поддержания чистых, хорошо организованных данных, установки четких приоритетов для использования памяти и непрерывного мониторинга и совершенствования системы. Решение этих вызовов гарантирует, что ИИ остается эффективным, масштабируемым и адаптивным к реальным приложениям.

Управление данными как основа успеха

Управление данными является основой эффективных систем ИИ, особенно тех, которые оснащены возможностями памяти. Подобно тому, как бизнес полагается на хорошо организованные записи для эффективной работы, агент ИИ зависит от бесшовного хранения, извлечения и обновления данных, чтобы работать наилучшим образом. Если базовая инфраструктура данных плохо управляется, даже самый умный ИИ может споткнуться – извлекая устаревшую информацию, упуская критические детали или выдавая непоследовательные результаты. Для бизнеса это может означать упущенные возможности, разочарованных клиентов и снижение доверия.

Чтобы избежать этих ловушек, лидеры должны рассматривать управление данными как стратегический приоритет. Это начинается с инвестиций в *масштабируемые и эффективные технологии баз данных*, которые могут справляться с растущими потребностями современных систем ИИ. Представьте агента ИИ для обслуживания клиентов, которому нужно за секунды получить доступ к тысячам профилей клиентов, историям покупок и прошлым взаимодействиям. Без надежной инфраструктуры агент может тормозить или выдавать неполные ответы, разрушая бесшовный опыт общения, который пользователи ожидают как само собой разумеющееся. Технологии, такие как облачные базы данных, инструменты аналитики в реальном времени и векторное хранилище для семантических поисков, являются важнейшими факторами, делающими системы памяти ИИ гибкими и эффективными.

Бесшовная интеграция между базами данных и системами ИИ – еще одна важная часть головоломки. Системы памяти ИИ полагаются на плавные взаимодействия с уровнем данных в реальном времени, чтобы извлекать наиболее релевантную и актуальную информацию. Дело не только в технической совместимости – дело в разработке рабочих процессов, где данные свободно текут между хранилищем, обработкой и агентом ИИ. Например, в розничной торговле система ИИ, рекомендующая продукты, должна мгновенно учитывать последние обновления запасов или поведение клиентов при просмотре, чтобы ее предложения были релевантными. Без этой динамической связи даже лучшие модели ИИ могут казаться оторванными от реальности.

Управление данными также требует бдительности для обеспечения качества и точности. Плохие данные приводят к плохим решениям как для людей, так и для ИИ. Лидеры должны установить процессы для регулярной очистки, обновления и проверки данных, гарантируя, что то, что ИИ изучает и извлекает, является надежным и актуальным. Кроме того, по мере масштабирования систем лидеры должны рассмотреть инструменты, которые автоматизируют эти процессы, уменьшая ручные ошибки и оптимизируя операции.

По сути, управление данными – это скрытая сила, которая питает способность ИИ приносить пользу. Речь идет не просто о наличии данных, речь идет об их организации, доступе и обновлении таким образом, чтобы раскрыть полный потенциал ИИ. Бизнес-лидеры, которые мудро инвестируют в свою инфраструктуру данных, не только защищают свои системы от устаревания, но и позиционируют свои компании для процветания в мире, все более ориентированном на ИИ.

Революция памяти только началась

На протяжении этой главы мы исследовали, как память превращает ИИ из сложного калькулятора в настоящего партнера по мышлению. Мы увидели, как краткосрочная память позволяет вести связные беседы, а структурированное хранение организует опыт долгосрочного обучения. Пожалуй, наиболее важным является то, как мы поняли, что циклы обратной связи стимулируют непрерывное улучшение, позволяя системам ИИ учиться и адаптироваться с каждым взаимодействием.

Последствия для бизнес-лидеров глубокие и немедленные. Во-первых, агенты ИИ с поддержкой памяти кардинально меняют экономику взаимодействия с клиентами. Когда агенты ИИ могут поддерживать контекст в разговорах, помнить предпочтения клиентов и учиться на прошлых взаимодействиях, они обеспечивают экспоненциально лучший опыт при значительно меньших затратах. Мы видели это на практике с компаниями, добивающимися сокращения затрат на обслуживание клиентов на 40–50 % при одновременном улучшении показателей удовлетворенности клиентов.

Во-вторых, память трансформирует процессы принятия решений. Вместо того чтобы полагаться только на текущие данные, лидеры теперь могут использовать агентов ИИ, которые помнят и учатся на каждом прошлом решении, успехе и неудаче в организации. Эта институциональная память, ранее разбросанная по электронной почте, документам и умам сотрудников, становится структурированным, доступным ресурсом для информирования стратегии и операций.

В-третьих, агенты с поддержкой памяти изменяют то, как организации учатся и адаптируются. Когда агенты ИИ могут помнить и анализировать шаблоны по тысячам проектов или миллионам взаимодействий с клиентами, они выявляют возможности и риски, которые людям было бы невозможно обнаружить самостоятельно. Это не замена человеческому суждению – это его усиление с уровнем распознавания шаблонов и исторической осведомленности, ранее невообразимым.

В завершение этой главы нужно напомнить, что развитие памяти в ИИ представляет нечто большее, чем просто технологический прогресс, – оно знаменует фундаментальный сдвиг в том, как мы взаимодействуем с машинами и как они помогают нам думать о мире. Вопрос, стоящий перед бизнес-лидерами, не в том, стоит ли принимать эту инновацию, а в том, как формировать ее таким образом, чтобы приносить прибыль, уважая человеческую инициативу и креативность.

ЧАСТЬ 3

Предпринимательство и профессиональный рост с ИИ-агентами

Теперь, когда мы исследовали основополагающие элементы действия, рассуждения и памяти, пришло время перейти к практическому применению. Как на самом деле строить эти системы? И, что более важно, как вы можете использовать их для создания реальной ценности?

В предыдущих частях книги мы провели вас через путешествие от понимания того, что такое агенты ИИ, до раскрытия того, как они думают, действуют и учатся. Мы увидели, что они представляют собой фундаментальный сдвиг от традиционных систем ИИ – не просто обрабатывая информацию, но автономно преследуя цели от нашего имени. Но знания об этой технологии недостаточно. Настоящий вопрос: как вы можете ее использовать?

Следующие главы вооружат вас инструментами для превращения инновационного потенциала агентов ИИ в осязаемую реальность. Будущее принадлежит тем, кто сможет не только понять эту технологию, но и эффективно ее внедрить, – и именно это мы собираемся вам показать.

Здесь мы засучиваем рукава и переходим к практике. Независимо от того, стремитесь ли вы трансформировать свою организацию или запустить бизнес на миллионы долларов, эти главы предоставят вам дорожную карту от идеи до внедрения.

Начнем наше путешествие от идей к внедрению.

Практическое руководство по созданию успешных агентов ИИ

«**Н**аши информационные бюллетени убивают нас, – вспоминаем мы, думая об этом поздним пятничным вечером, перебирая десятки статей, пытаясь составить краткие обзоры, которые заинтересуют наших читателей. – Должен быть лучший способ». Перенесемся на месяц вперед: наша агентная система взяла на себя весь процесс, наша база подписчиков взлетела до 300 000 всего за один месяц, а наша команда освободила вам 40 часов в неделю для творческой работы. И это еще не все. Мы создавали контент лучше, чем когда-либо.

Но вот что делает эту историю актуальной для вас: создание эффективных агентов ИИ не связано с наличием большого бюджета или самой передовой технологии. Речь идет о понимании нескольких важнейших принципов, которые отделяют успех от провала. В этой главе мы поделимся этими принципами через наши собственные пробы, ошибки и прорывы во внедрении агентов ИИ в различных отраслях.

Мы не просто расскажем вам, что делать, – мы это покажем. Через реальные примеры, практические инструменты и честные рассказы о том, что пошло не так (и как мы это исправили), вы получите план для создания агентов ИИ, которые трансформируют вашу работу и работу вашей организации.

Шаг 1. Поиск правильных областей применения агентов

Представьте себя в оживленном офисе быстро растущего агентства цифрового маркетинга. Дженни, основатель и креативный директор, сидит за своим столом, окруженная множеством экранов. Она лихорадочно переключается между приложениями – собирает аналитику социальных сетей, проверяет ре-

зультаты кампаний, организует контент-календари и пытается собрать все это в отчеты для клиентов.

Дженни обратилась к нам с интригующим вызовом: «Моя команда тонет в рутинных задачах, – объяснила она. – У нас есть блестящие креативщики, которые часами занимаются вводом данных и генерацией отчетов вместо стратегии и инноваций. Но как мне понять, какие задачи действительно подходят для агентов ИИ?»

Этот вопрос – понимание того, с чего начать с агентами ИИ, – критически важен. Мы узнали, что успех часто зависит больше от выбора правильных областей применения, чем от технической изощренности.

Начнем с фундаментальной истины: агенты ИИ – это не волшебные решения, которые могут справиться с любой задачей. Подобно тому, как вы не стали бы использовать молоток для решения любой проблемы по ремонту дома, не каждый бизнес-вызов требует агента ИИ. На самом деле одна из самых распространенных ловушек, которую мы видим, – это когда предприниматели и бизнес-руководители спешат внедрять агентов, не определив сначала, подходят ли они для данной работы.

Когда не стоит использовать агентов ИИ

Начнем с определения, где не следует разворачивать агентов ИИ. На основе нашего опыта мы выявили несколько красных флагов¹.

Во-первых, задачи, требующие подлинной человеческой креативности или эмоционального интеллекта², в целом должны оставаться под управлением людей. В маркетинговом агентстве агенты ИИ могли справляться со сбором данных и базовой отчетностью, но креативная разработка кампаний и управление отношениями с клиентами твердо оставались в руках людей. Хотя агенты уровня 3 могут участвовать в естественных языковых взаимодействиях, они не могут по-настоящему уловить эмоциональный резонанс, необходимый для убедительных маркетинговых кампаний.

Аналогично стратегическое принятие решений, которое требует понимания более широкого рыночного контекста или принятия решений на основе неполной информации, должно оставаться за людьми. Даже на уровне 3 агенты ИИ не обладают сложным рассуждением и рыночной интуицией, необходимыми для таких сценариев.

Некоторые задачи просто слишком сложны для эффективного управления агентами ИИ. Одна технологическая компания однажды попросила нас создать агента для управления операциями поддержки клиентов в полном объеме. Хотя потенциальное воздействие было значительным, процесс включал слишком много уникальных сценариев и эмоциональных взаимодействий. Агенты ИИ работают лучше всего, когда их способности соответствуют сложности назначенной задачи.

¹ Имеется в виду красный сигнальный флаг, применяемый на всех автомобильных гонках, который передает информацию «Остановка гонки». – *Прим. ред.*

² Эмоциональный интеллект (EQ) – это способность распознавать, понимать и управлять как своими эмоциями, так и эмоциями других людей, использовать их для решения задач например, договариваться с людьми. – *Прим. ред.*

В других случаях агентам ИИ может не хватать полномочий для принятия критических решений. Финансовая компания хотела, чтобы агент ИИ принимал инвестиционные решения автономно. Это было не только рискованно, но и явным нарушением регуляторных требований. Важно учитывать, обладает ли агент ИИ соответствующим уровнем полномочий для назначенной задачи.

Понимая эти ограничения, организации могут гарантировать, что они развертывают агентов ИИ там, где они добавляют ценность, сохраняя человеческий надзор там, где он наиболее важен.

Три круга агентных способностей

Мы разработали простой, но мощный подход, который мы называем «Три круга агентных способностей», чтобы помочь выявить идеальные точки для внедрения агентного ИИ. Представьте три пересекающихся круга. Идеальная точка для ваших агентов ИИ находится там, где эти круги пересекаются. Разберем это на примере маркетингового агентства.



Рис. 8.1. Идеальная точка для агентных способностей (Источник: © Борне и др.)

Круг 1. Высокое воздействие – будет ли это иметь значение?

Первый круг представляет задачи, которые, если их автоматизировать, окажут значительное воздействие на вашу организацию. Вопрос прост: если вы автоматизируете этот процесс, принесет ли это существенную пользу? Воздействие – это не только экономия времени, но и то, что это сэкономленное время позволяет вашей организации делать.

Рассмотрите рутинные задачи, которые отнимают время у ваших квалифицированных специалистов. Возможно, ваша команда продаж часами обновляет записи CRM, вместо того чтобы строить отношения с клиентами. Может быть,

ваши исследователи тратят больше времени на форматирование данных, чем на их анализ. Или ваша команда по персоналу погрязла в обработке рутинных запросов вместо того, чтобы сосредоточиться на развитии сотрудников.

Наиболее высоко воздействующие способности часто не являются вашими самыми сложными процессами. Вместо этого ищите рутинные задачи, которые мешают вашим лучшим сотрудникам выполнять их лучшую работу. Оценивая воздействие, спросите: если эта задача будет автоматизирована завтра, что сможет сделать ваша команда вместо этого?

Для маркетингового агентства процесс ежемесячной отчетности для клиентов отнимал более 200 часов командного времени в месяц. Более того, эта рутинная работа мешала аналитикам заниматься стратегическим мышлением, которое действительно нужно их клиентам.

Круг 2. Осуществимость – можно ли это сделать?

Второй круг касается того, может ли текущая технология агентов ИИ эффективно и безопасно справиться с задачей. Думайте об осуществимости как о проверке наличия правильных ингредиентов перед началом приготовления пищи – вам нужно убедиться, что у вас есть все необходимые элементы для успеха.

Наиболее осуществимые процессы для автоматизации обычно имеют следующие характеристики:

- четкие, последовательные правила для принятия решений;
- доступные данные и системы;
- определяемые критерии успеха;
- управляемые последствия в случае ошибки;
- возможность проверки результатов, до того, когда они повлияют на операции.

Ключ в том, чтобы искать процессы, правила которых вы можете объяснить, не используя слишком часто фразы вроде «это зависит» или «но иногда...». Чем больше исключений и суждений требует процесс, тем менее он подходит для вашего первого проекта внедрения агента ИИ.

Для маркетингового агентства процесс отчетности был подходящим для автоматизации, потому что у него были все важнейшие ингредиенты. В первых, необходимые данные были доступны через API. Кроме того, процесс следовал последовательным правилам, результаты можно было легко проверить, а ошибки могли быть исправлены людьми.

Круг 3. Усилия – стоит ли это того?

Последний круг учитывает практические аспекты внедрения – ресурсы, время и организационные изменения, которые потребуются. Это касается не только технической сложности, но и готовности вашей организации к изменениям.

Рассмотрите, соблюдаются ли условия:

- процесс хорошо документирован;
- ваша команда готова и желает адаптироваться;
- вы можете начать с малого и масштабироваться;
- потенциальные выгоды явно оправдывают инвестиции;
- вы можете внедрить агента без нарушения последовательности основных операций.

Лучшие первые проекты часто можно внедрять поэтапно, позволяя вам постепенно наращивать уверенность и возможности. В случае Дженни автоматизация отчетов была привлекательной, потому что у них уже были документированные процедуры, они могли начать с малого и масштабироваться, а команда была готова к изменениям.

Поиск вашей идеальной точки

Идеальные проекты для агентов ИИ находятся там, где эти три круга пересекаются. Для агентства Дженни автоматизация отчетов была идеальной, потому что она освободила бы сотни часов ценного времени аналитиков (воздействие), процесс был четко определен и безопасен для автоматизации (осуществимость), и они могли внедрить его без нарушения основного бизнеса (усилия).

Начните с отображения ваших собственных процессов на эти три круга. Ищите задачи, о которых ваша команда постоянно жалуется, – они часто обнаруживают области наибольшего возможного воздействия. Затем оцените, имеют ли эти задачи четкие правила и доступные данные. Наконец, подумайте, есть ли у вас ресурсы и готовность справиться с изменениями.

Помните, ваш первый проект агента ИИ должен быть как хорошее первое свидание – достаточно амбициозным, чтобы быть захватывающим, но не настолько сложным, чтобы закончиться катастрофой. Начните с чего-то, что хорошо оценивается по всем трем кругам, и вы не только достигнете успеха, но и создадите импульс для более амбициозных проектов в будущем.

Проверка реальности внедрения: уроки из практики

Наш опыт выявил несколько важных реалий о поиске правильных областей применения.

Во-первых, компании редко знают, какие агенты им действительно нужны. Хотя они часто обращаются к нам с конкретными идеями агентов, почти в половине случаев это не самые ценные возможности для автоматизации. Вот почему наш фреймворк трех кругов так важен – он помогает преодолеть предположения, чтобы выявить то, что действительно имеет значение. Когда клиент настаивал на автоматизации публикаций в социальных сетях, наш анализ показал, что автоматизация квалификации лидов¹ принесет в пять раз большую отдачу от инвестиций (ROI).

Во-вторых, многие компании считают, что они могут полностью автоматизировать целые рабочие роли с помощью агентов ИИ, но это фундаментальное непонимание того, как работает ИИ сегодня. Агенты ИИ – это не сотрудники; им не хватает гибкости, адаптивности или суждений, которые человеческие работники приносят в свою роль.

¹ Лиды, или потенциальные клиенты, – это контакты, которые ИИ анализирует и использует для автоматизации процесса поиска клиентов. Вместо ручного поиска ИИ-системы сканируют большие объемы информации в интернете (сайты компаний, новостные статьи, социальные сети, профессиональные платформы) и находят сигналы, указывающие на то, что компания – ваш потенциальный клиент. – Прим. ред.

Один сотрудник часто управляет множеством взаимосвязанных задач, которые требуют переключения контекста, принятия решений и сотрудничества – вещи, в которых агенты ИИ все еще недостаточно сильны. Вместо того чтобы думать в терминах «автоматизации ролей», правильный подход – думать в терминах «автоматизации задач».

Наконец, золотая жила для внедрения агентов – это хорошо документированные процессы. Оценивая возможности, мы обнаружили, что использование существующих документированных стандартных операционных процедур (SOPs) значительно сокращает время внедрения и увеличивает процент успеха. Для одного клиента из финансового сектора их тщательно документированный процесс онбординга клиентов позволил нам развернуть агента за половину времени по сравнению с аналогичным проектом, где нам пришлось отображать процесс с нуля.

Эти уроки из практики сформировали наш подход к фазе идентификации возможностей применения ИИ-агентов, подчеркивая важность фреймворка трех кругов и добавляя практические соображения, которые выходят за рамки теории.

Практическое упражнение: поиск лучших областей применения ваших агентов

Теперь, когда вы понимаете теорию, давайте пройдем через простое упражнение, которое мы используем с организациями для выявления их лучших областей применения агентных способностей. Мы разработали этот подход после того, как увидели, что слишком многие компании бросаются в автоматизацию без должного анализа, что часто приводит к потраченным ресурсам и разочарованию команды сотрудников.

Шаг 1. Инвентаризация задач

Начните с собрания вашей команды для сфокусированной двухчасовой сессии. Цель – создать полный список повторяющихся задач, которые занимают значительное время или создают узкие места в ваших операциях. Мы обнаружили, что задавание конкретных вопросов дает лучшие результаты, чем общий мозговой штурм.

Спросите у вашей команды:

- «Какие задачи вы делаете повторно в течение недели?»
- «Какие действия мешают вам сосредоточиться на более стратегической работе?»
- «Какие процессы постоянно создают узкие места в наших операциях?»
- «Какие рутинные задачи требуют наибольшего контроля, чтобы предотвратить ошибки?»

Когда мы проводили это упражнение с маркетинговым агентством, их список включал такие задачи, как ежемесячная отчетность для клиентов, аналитика социальных сетей, отслеживание производительности кампаний, мониторинг конкурентов и управление контент-календарем. Важнейшим было не только зафиксировать задачи, но и определить их частоту и приблизительное время, затрачиваемое на каждую.

Шаг 2. Оценка воздействия

Следующим шагом оцените потенциальное воздействие каждой задачи, если она будет автоматизирована. Мы используем простую, но эффективную систему оценки, которая учитывает несколько факторов. Для каждой задачи оцените следующие критерии по шкале от 1 до 5.

1. Сэкономленное время (сколько времени это занимает сегодня, сколько можно сэкономить?).
 - ♦ В большинстве случаев достаточно просто оценить среднее сэкономленное время. Более высокий балл (5) означает, что сэкономленное время будет очень большим.
 - ♦ В некоторых случаях полезно провести более детальные расчеты текущих затрат в долларах. Умножьте часы на задачу на частоту и стоимость в час (например, 2 часа на задачу × 20 задач/месяц × 50 долл./час = 2000 долл. экономии).
2. Стратегическая ценность освобожденного времени (какова альтернативная стоимость?).
 - ♦ Стратегическая ценность измеряет более широкие выгоды от автоматизации задачи, включая ее влияние на удовлетворенность сотрудников, клиентский опыт, конкурентное позиционирование и потенциал дохода.
 - ♦ Оценивается по шкале от 1 до 5, где более высокие баллы указывают на большее общее влияние на бизнес.
3. Потенциал сокращения ошибок (как часто происходят ошибки?).
 - ♦ В большинстве случаев достаточно оценки. Более высокий балл (5) означает, что ошибки происходят часто или дорого обходятся.
 - ♦ В некоторых случаях полезно провести более детальные расчеты текущих затрат в долларах. Рассчитайте по формуле: текущий уровень ошибок × стоимость одной ошибки × объем (например, 5 % уровень ошибок × 100 долл. за ошибку × 1000 случаев/месяц = 5000 долл. экономии).
4. Влияние масштабируемости (может ли это быть применено по всей организации?).
 - ♦ Влияние масштабируемости измеряет, насколько хорошо решение может расширяться без пропорционального увеличения затрат. Более высокий балл (5) означает, что задача может быть автоматизирована и масштабирована по всей организации с минимальными дополнительными затратами.
 - ♦ Например, автоматизация процесса онбординга клиентов, который работает для 10 клиентов, может легко масштабироваться до 1000 без необходимости дополнительного персонала, что делает его высоко масштабируемым (оценка 5).

Вот краткое описание четырех критериев и значения баллов:

Таблица 8.1. Оценка четырех критериев оценки воздействия (Источник: © Борне и др.)

Критерии	Балл 1	Балл 3	Балл 5
Временные затраты	Менее часа в неделю	Несколько часов в неделю	Несколько часов ежедневно
Стратегическая ценность освобожденного времени	Ограниченное альтернативное использование времени	Умеренная стратегическая ценность	Высокозначимые стратегические действия заблокированы
Потенциал сокращения количества ошибок	Ошибки редки	Периодические значительные ошибки	Частые или дорогостоящие ошибки
Влияние масштабируемости	Одноразовая задача	Умеренно повторяемая задача	Высокомасштабируемая по всей организации задача

Затем подсчитайте общий балл для каждой задачи. Сложите баллы по четырем критериям. Минимальный возможный балл 4, максимальный 20.

Наконец, сравните баллы по задачам – чем выше общий балл, тем сильнее аргумент в пользу автоматизации.

В маркетинговом агентстве процесс клиентской отчетности получил высокие баллы по всем категориям: он занимал огромное количество времени (5), мешал стратегическому анализу (5), часто содержал ошибки из-за ручного ввода данных (4) и мог масштабироваться на всех клиентов (5). Это дало общий балл 19 из 20, что сделало его главным кандидатом для автоматизации.

Шаг 3. Оценка осуществимости

Для каждой задачи, набравшей высокие баллы по воздействию, оцените ее осуществимость для автоматизации. Это помогает определить, может ли текущая технология агентов ИИ (уровни 1–3) надежно справиться с задачей. Мы разбиваем осуществимость на два важнейших компонента, каждый из которых оценивается по шкале от 1 до 5.

1. Стандартизация процесса

Автоматизация работает лучше всего, когда задачи имеют четкие и структурированные шаги. Оцените, есть ли у процесса четкие шаги, правила принятия решений и исключения. Задайте вопрос: «Может ли новичок точно следовать этому процессу, используя только нашу документацию?»

2. Доступ к данным и системам

ИИ нуждается в структурированных и доступных данных для функционирования. Если данные разбросаны, заблокированы в старых системах или требуют вмешательства человека, автоматизация будет сложной. Проверьте, структурированы ли данные, легко ли извлекаются и доступны через современные системы или требуют ручной подготовки.

Используйте следующую шкалу для оценки стандартизации процесса и готовности данных:

Таблица 8.2. Оценка двух критериев оценки осуществимости (Источник: © Борне и др.)

Критерии	Балл 1	Балл 3	Балл 5
Стандартизация процесса	Процесс в основном импровизированный, без стандартного подхода	Существует базовая документация, но она сильно зависит от опыта сотрудников	Процесс полностью документирован с четкими шагами, правилами принятия решений и исключениями
Доступ к данным и системам	Основные данные заблокированы в устаревших системах или на бумаге	Данные доступны, но требуют значительной подготовки	Все данные структурированы, и системы имеют современные API

Оценивая каждую задачу по стандартизации процесса и доступу к данным и системам, вы быстро определите, какие задачи наибольшего воздействия готовы к автоматизации, а какие требуют предварительных улучшений.

Шаг 4. Усилия по внедрению

После выявления задач высокого воздействия и подтверждения их осуществимости следующий шаг – оценить, насколько сложно создать для них агента ИИ. Усилия по внедрению измеряют техническую сложность, помогая приоритезировать агентов ИИ, которые могут быть развернуты эффективно.

Как оценить техническую сложность (1–5, обратная оценка).

Это метрика с обратной оценкой, что означает, что более низкие баллы указывают на более высокую сложность и большую трудность в внедрении. Вот как это оценить:

- балл 5 (самое простое для внедрения) – задача может быть автоматизирована с использованием стандартных инструментов, требующих минимальной настройки или не требующих настройки вообще;
- балл 4 – требуется некоторая настройка, но она полагается на широко используемые технологии;
- балл 3 – решение требует значительной пользовательской разработки, такой как написание скриптов;
- балл 2 – требуются сложные интеграции или внедрение новых технологий;
- балл 1 (самое сложное) – задача требует передовых решений или обширных исследований и разработок (R&D).

Мы рекомендуем всегда начинать с проверенных, широко используемых инструментов и платформ, прежде чем раздвигать технологические границы. Автоматизация простых, высоковоздействующих задач сначала создает импульс, снижает риски и обеспечивает ранние победы, перед тем как браться за более сложные решения.

Сведение воедино: окончательный анализ

После месяцев помощи организациям в оценке возможностей агентов ИИ мы разработали систематический подход к принятию окончательного решения о внедрении. Вернемся к маркетинговому агентству Дженни, чтобы увидеть, как это работает на практике. Сначала мы комбинируем баллы из наших предыдущих анализов:

- балл воздействия (максимум 20 баллов по четырем критериям);
- балл осуществимости (максимум 10 баллов по оценке процесса и данных);
- балл усилий по внедрению (максимум 5 баллов, обратная оценка).

Это дает нам максимальный возможный балл 35. Мы считаем эту детализированную систему оценки особенно ценной, потому что она заставляет организации систематически продумывать все аспекты возможности.

Для процесса клиентской отчетности Дженни баллы распределились следующим образом:

- воздействие: 19/20 (высокие временные затраты, стратегическая ценность, сокращение ошибок и масштабируемость);
- осуществимость: 8/10 (хорошо документированный процесс, доступные данные через API);
- усилия по внедрению: 4/5 (доступны стандартные инструменты, минимальная настройка).

Общий балл: 31/35, что указывает на отличного кандидата для внедрения агента ИИ.

Финальный штрих: матрица приоритизации агентного ИИ

Хотя общий балл полезен, мы обнаружили, что визуализация возможностей помогает командам и руководству принимать лучшие решения. Мы отображаем потенциальные проекты на матрице с двумя осями:

- вертикальная ось: сложность трансформации (комбинация баллов осуществимости и усилий);
- горизонтальная ось: бизнес-воздействие (используя балл воздействия).

Это создает четыре квадранта.

1. Быстрые победы (высокое воздействие, низкая сложность): ваши идеальные агентные возможности.
2. Стратегические проекты (высокое воздействие, высокая сложность): будущие возможности, требующие тщательного планирования.
3. Низкий приоритет (низкое воздействие, низкая сложность): приятные, но необязательные автоматизации.
4. Лучше избежать (низкое воздействие, высокая сложность): не стоят усилий.

Для маркетингового агентства клиентская отчетность четко попала в квадрант быстрых побед: высокое воздействие с относительно низкой сложностью. Это стало их первым проектом агента ИИ, приведшим к успешной трансформации, о которой мы упоминали ранее.

Матрица приоритизации агентных возможностей

Влияние на бизнес
(Низкое > Высокое)



Рис. 8.2. Матрица приоритизации агентного ИИ (Источник: © Борне и др.)

Заключительное замечание по выбору области внедрения агентного ИИ

Если это ваше первое внедрение агентного ИИ, учтите, что оно задаст тон для будущих инициатив по автоматизации. Поэтому, помимо вышеуказанных критериев, важно выбрать возможность, которая:

- покажет четкие, измеримые результаты в течение 3–6 месяцев;
- затрагивает достаточно людей, чтобы создать широкую поддержку;
- имеет чемпиона, готового контролировать внедрение;
- может служить обучающим опытом для вашей организации.

Успех с вашим первым агентом создает уверенность и придает импульс для более амбициозных проектов. Успешная автоматизация отчетности маркетингового агентства привела к пяти дополнительным внедрениям агентов в течение следующего года, каждое из которых опиралось на уроки, извлеченные из первого.

ШАГ 2. ОПРЕДЕЛЕНИЕ РОЛИ И ВОЗМОЖНОСТЕЙ АГЕНТОВ ИИ

После выявления правильных возможностей для агентов ИИ следующий важный шаг – определить, какой именно агент вам нужен. Думайте об этом как о написании должностной инструкции – вам нужно быть предельно ясным в отношении роли, обязанностей и необходимых способностей вашего цифрового работника.

Вернемся к цифровому маркетинговому агентству, где Дженни и ее команда решили начать с автоматизации процесса ежемесячной клиентской отчетности. «Я знаю, что хочу автоматизировать этот процесс, – сказала нам Дженни, – но я не уверена, какой агент мне нужен. Должен ли он быть простым, просто собирающим данные, или более сложным, который может писать анализ отчетов?»

Это распространенный вопрос, который мы слышим от бизнес-лидеров, и ответ кроется в понимании различных уровней возможностей агентов ИИ и их соответствии вашим конкретным потребностям.

Что такое уровни агентов: от простых к сложным

Думайте об агентах ИИ как о сотрудниках с разными уровнями навыков. Используя наш прогрессивный фреймворк агентного ИИ, мы можем в целом классифицировать их на пять уровней, хотя в настоящее время в производственных средах обычно разворачиваются только уровни 1–3.

Точнее, уровень 2 (интеллектуальная автоматизация) и уровень 3 (агентный рабочий процесс) являются наиболее распространенными, поэтому мы сосредоточимся на этих двух уровнях. Агенты уровня 2 больше похожи на опытных профессионалов, которые могут следовать простым, неизменным инструкциям. Агенты уровня 3 – как старшие профессионалы, которые могут понимать контекст и управлять более сложными задачами.

Для процесса отчетности маркетингового агентства Дженни нужно было определить, какой уровень будет наиболее подходящим. Давайте пройдем через процесс принятия решения, который они использовали.

Фреймворк принятия решений

Чтобы выбрать правильный уровень агента, мы оцениваем три важнейших критерия, которые помогают определить, агент какого уровня является более подходящим – уровня 2 или уровня 3.

1. Предсказуемость задачи (детерминированная против вероятностной)

Сначала подумайте, насколько предсказуем ваш процесс. Агенты уровня 2 превосходят в детерминированных задачах – процессах, которые следуют четким, неизменным правилам. Они как надежные работники, которые каждый раз выполняют одни и те же шаги идеально. Агенты уровня 3, работающие на основе фундаментальных моделей, могут справляться с вероятностными задачами, которые требуют понимания контекста и принятия решений на основе суждений.

В маркетинговом агентстве команда Дженни проанализировала процесс отчетности и обнаружила, что около 80 % его было детерминированным – сбор конкретных метрик с различных платформ и их организация в стандартном формате. Эта часть идеально подходила для агента уровня 2. Однако 20 % включали интерпретацию трендов и написание выводов, что требовало вероятностного мышления, лучше подходящего для агента уровня 3.

2. Чувствительность к ошибкам

Далее оцените, насколько критичны будут ошибки для вашей операции. Агенты уровня 2 очень надежны для задач, где точность имеет первостепенное значение, потому что они следуют точным правилам и не отклоняются от предписанных шаблонов. Они идеальны для финансовых расчетов, обработки данных и других задач, где ошибки могут быть дорогостоящими.

Агенты уровня 3, хотя и более гибкие, могут иногда выдавать неожиданные результаты или делать креативные интерпретации. Они лучше подходят для задач, где некоторая вариативность допустима или даже полезна, например для генерации контента или анализа шаблонов.

Для клиентской отчетности маркетингового агентства точность в сборе данных и расчетах была критически важна – одна ошибка могла подорвать доверие клиентов. Это сделало агентов уровня 2 идеальными для части обработки данных. Однако небольшие вариации в написанном анализе были допустимы и иногда даже желательны, что делало эту часть подходящей для агента уровня 3.

3. Вариативность входных данных

Наконец, оцените, насколько сильно варьируются ваши входные данные. Агенты уровня 2 лучше всего работают со стандартизированными входными данными – им нужны конкретные форматы данных и предсказуемые сценарии. Они чувствительны к исключениям и не могут адаптироваться к неожиданным вариациям без перепрограммирования.

Агенты уровня 3, напротив, превосходят в обработке варьирующих входных данных. Они могут понимать контекст, адаптироваться к разным форматам и разбираться с неструктурированными данными. Они как опытные профессионалы, которые могут корректировать свой подход в зависимости от ситуации.

Маркетинговое агентство работало с различными источниками данных, но они следовали последовательным форматам – идеально для агента уровня 2. Однако контекст для интерпретации этих данных значительно варьировался в зависимости от клиентов и отраслей, что делало агента уровня 3 необходимым для аналитической части.

Отображение характеристик на уровни агентов

Для обобщения того, как эти критерии соответствуют уровням агентов, приводится следующая таблица.

Таблица 8.3. Сравнение агентов ИИ уровней 2 и 3 (Источник: © Борне и др.)

Критерии	Агенты уровня 2 (интеллектуальная автоматизация)	Агенты уровня 3 (агентный рабочий процесс)
Предсказуемость задачи	Высоко детерминированные процессы с четкими правилами	Способны справляться с задачами, требующими понимания контекста и адаптивных ответов
Чувствительность к ошибкам	Требуют 100 % точности и надежности	Допускают некоторую вариативность в выходных данных, позволяя вероятностные решения
Вариативность входных данных	Лучше всего работают со стандартизированными входными данными и минимальными вариациями	Могут обрабатывать переменные или неструктурированные входные данные
Лучше всего подходит для	Высокопроизводительные, повторяющиеся задачи, следующие фиксированным рабочим процессам	Задачи, включающие рассуждение, принятие решений или понимание естественного языка
Примеры использования	Извлечение данных, финансовые расчеты, проверки соответствия, структурированная отчетность	Написание отчетов, чат-боты поддержки клиентов, обнаружение мошенничества, анализ трендов

Принятие решения: выбор маркетингового агентства

После оценки этих критериев мы помогли маркетинговому агентству принять интересное решение: они внедряют гибридный подход, используя агентов уровней 2 и 3 для разных частей процесса.

Агент уровня 2 (который мы называем интеллектуальной автоматизацией) будет обрабатывать детерминированные части работы:

- доступ к различным платформам (Google Analytics, социальные сети, рекламные платформы);
- извлечение стандартизированных наборов данных;
- выполнение расчетов и создание визуализаций;
- генерацию базовой структуры отчета.

Агент уровня 3 (агентный рабочий процесс) затем:

- анализирует тренды в обработанных данных;
- генерирует начальные выводы и рекомендации;
- создает черновики нарративных разделов отчета.

Этот гибридный подход использовал сильные стороны каждого типа агента. Агент уровня 2 мог надежно справляться с точными, детерминированными задачами с почти идеальной точностью, в то время как агент уровня 3 был подходящим для более нюансированной работы по интерпретации данных и генерации нарратива.

В следующем разделе мы опишем, как разрабатывать и создавать агентов уровня 3. Для создания агентов уровня 2 мы рекомендуем обратиться к книге «Интеллектуальная автоматизация»¹.

¹ Паскаль Борне, Ян Баркин и Йохен Вирц, 2020. «Интеллектуальная автоматизация: узнайте, как использовать искусственный интеллект для развития бизнеса и сделать наш мир более человечным», <https://www.amazon.com/INTELLIGENTAUTOMATION-Artificial-Intelligence-business/dp/B08KTDVHHQ>.

Кривая обучения

Важно отметить, что внедрение агентов ИИ обычно является итеративным процессом. В маркетинговом агентстве они начали с агента уровня 2, который занимался только сбором данных и базовой отчетностью. Как только это начало работать гладко и команда освоилась с технологией, они ввели агента уровня 3 для генерации контента.

Дженни размышляла: «Сначала я хотела автоматизировать все сразу. Но начало с базовой работы с данными и постепенное добавление более сложных возможностей помогло нашей команде адаптироваться и фактически сформировало наше представление о процессе отчетности».

Результаты и извлеченные уроки

Через шесть месяцев после внедрения система агентов ИИ маркетингового агентства обрабатывала отчеты для всех клиентов с замечательной эффективностью.

- Время генерации отчетов сократилось до 45 мин.
- Точность данных поддерживалась на уровне 99,95 %.
- Показатели удовлетворенности клиентов выросли на 15 %.
- Маркетинговая команда сообщила о увеличении на 60 % времени для стратегической работы.

Дженни размышляла о своем пути: «Ключом было не торопиться с автоматизацией. Приняв методичный подход к разработке и постепенно укрепляя доверие, мы создали систему, которой полностью доверяют и наша команда, и наши клиенты».

Успех системы отчетности маркетингового агентства открыл новые возможности для внедрения агентов ИИ по всей их организации. Теперь они исследуют приложения в оптимизации кампаний, создании контента и анализе клиентских путешествий.

Уроки, извлеченные из этого внедрения, подчеркивают важность продуманной разработки, которое учитывает как технические возможности, так и человеческие факторы. Как мы рассмотрим в следующей главе, эти решения по разработке закладывают критически важную основу для успешного внедрения и развертывания.

Движение вперед

С четко определенными ролями для агентов уровней 2 и 3 маркетинговое агентство было готово перейти к фазе детального проектирования их внедрения. Четкое разграничение обязанностей и возможностей оказалось решающим для следующих шагов по отображению потоков процессов и установлению критериев производительности.

Помните, цель не в создании самого сложного агента, а в разработке такого, который надежно приносит пользу, плавно интегрируясь с рабочими процессами вашей человеческой команды. Как мы рассмотрим в следующей главе, эта основа четко определенных ролей и возможностей необходима для успешного внедрения.

ШАГ 3. РАЗРАБОТКА АГЕНТОВ ИИ ДЛЯ УСПЕХА

После выявления правильной возможности и определения подходящего типа агента следующий важный этап – разработка ваших агентов ИИ для успешного внедрения. Здесь теория встречается с практикой, и здесь многие организации либо настраивают себя на успех, либо спотыкаются о распространенные ловушки. Давайте исследуем это через наш собственный опыт создания агента ИИ для автоматизации информационных бюллетеней.

Вызов информационных бюллетеней: пример из практики

Как авторы и влиятельные лица в сфере ИИ, мы обнаружили, что тратим бесчисленные часы каждую неделю на курирование контента, написание обзоров и создание информационных бюллетеней для нашего сообщества. Это был трудоемкий процесс, который хотя и ценный для наших читателей, но отнимал время от более глубоких исследований и написания. Тогда мы решили применить наш опыт в работе с агентами ИИ для решения этой задачи.

«Мы тратили почти целый день каждую неделю только на создание информационных бюллетеней, – вспоминает Паскаль. – Мы знали, что должен быть лучший способ». Результат? Новая система агентов ИИ, которая не только автоматизировала большую часть процесса, но и помогла нам увеличить аудиторию нашего нового информационного бюллетеня до более чем 300 000 подписчиков всего за один месяц.

В главе 9 будет обсуждаться, как мы развили эту инновационную бизнес-возможность агентного ИИ и превратили ее в предприятие, подчеркивая огромный потенциал агентного ИИ для создания новых бизнес-возможностей.

Принцип разработки № 1: начинайте с конечной целью в уме

Прежде чем погружаться в технические спецификации, успешная разработка агента начинается с четких критериев успеха. «Одна из самых больших ошибок, которые мы видим, – делится Ракеш из своего консалтингового опыта, – это когда организации сразу переходят к разработке решений, не определив, как выглядит успех».

Определение четких критериев успеха важно по трем важнейшим причинам. Во-первых, это предоставляет четкие цели для команды разработчиков и помогает приоритизировать функции. Во-вторых, это устанавливает ориентиры для измерения возврата инвестиций и производительности системы. В-третьих, это помогает управлять ожиданиями заинтересованных сторон и укреплять уверенность в новой системе.

Без четких критериев успеха мы могли бы создать систему, которая была бы технически впечатляющей, но не решала бы наши основные бизнес-потребности.

Критерии успеха должны включать как количественные, так и качественные метрики:

- количественные метрики могут включать повышение эффективности, снижение уровня ошибок или конкретные целевые показатели производительности;
- качественные метрики часто сосредотачиваются на пользовательском опыте, качестве выходных данных и надежности системы.

Например, в нашем случае с информационным бюллетенем мы установили метрики, такие как:

- сокращение времени создания с 15 до 3 часов в неделю;
- поддержание точности контента на уровне 95 % и выше;
- достижение уровня открытия электронных писем более 40 %.

Но что еще более важно, мы также определили качественные критерии успеха, связанные с релевантностью контента и опытом читателей.

Принцип разработки № 2: понимание текущего состояния

«Многие организации хотят сразу прыгнуть в будущее, – замечаем мы, – но понимание текущего процесса имеет решающее значение для успешной разработки агента».

Детальное понимание текущего рабочего процесса перед разработкой агентов ИИ важно по нескольким причинам. Во-первых, это выявляет скрытые сложности и зависимости, которые могут быть неочевидны на первый взгляд. Во-вторых, это помогает определить потенциальные узкие места и неэффективности, которые должна устранить новая система. Наконец, это гарантирует, что в процессе автоматизации критические бизнес-правила и исключения не будут упущены.

Когда мы начали отображать наш рабочий процесс, мы обнаружили, что то, что мы считали простым процессом из четырех шагов, на самом деле включало десятки микрорешений и исключений, которые мы сами обрабатывали автоматически. Без документирования этих деталей мы бы создали агентную систему, которая упустила бы важные нюансы.

Вот проблемы, с которыми мы столкнулись в существующем процессе создания информационного бюллетеня.

- Затратность по времени. Ручной поиск, обобщение, компиляция и форматирование требовали значительных усилий и нескольких часов каждый день и неделю. Мы оценили общую рабочую нагрузку примерно в 10 часов в неделю на один бюллетень.
- Склонность к ошибкам. Мы были склонны совершать ошибки в повторяющихся задачах, таких как обобщение и форматирование. Это происходило несколько раз и сильно вредило нашей репутации.
- Проблемы масштабируемости. По мере роста объема статей ручной процесс становился неустойчивым, требуя часов работы.
- Непостоянное качество. Результаты варьировались в зависимости от человека, выполняющего задачу, что приводило к неравномерности результатов при смене команды.

Принцип разработки № 3: разработка целевого процесса

После документирования существующего рабочего процесса вместо простого автоматизирования старого процесса мы полностью переработали его, ориентируясь на желаемый результат. На основании нашего опыта цепляться за устаревшие рабочие процессы ошибочно, это часто приводит к неэффективности, поскольку автоматизация сама по себе не исправит фундаментальных недостатков разработки.

Как обычно говорит Шаил, «мусор на входе – мусор на выходе. Если вы автоматизируете несовершенный процесс, это просто приведет к несовершенной автоматизации».

Вместо этого мы сосредоточились на том, чего хотели достичь, – оптимизированном, масштабируемом и безошибочном процессе производства информационного бюллетеня, – и построили весь рабочий процесс, ориентируясь на эту цель. Новый процесс следует структурированному ежедневному и еженедельному рабочему процессу.

Каждый день должны быть определены релевантные статьи, обобщены важнейшие выводы и отправлено отформатированное письмо на проверку человеку. Выбранные обзоры затем должны быть собраны в структурированный документ, обеспечивая контроль качества.

По понедельникам контент должен быть отформатирован в визуально привлекательный информационный бюллетень, проверен на точность и подготовлен к распространению.

Разбивая процесс на конкретные, четко определенные шаги, мы устранили ненужную сложность, улучшили контроль качества и обеспечили плавный цикл публикации. Главный урок: не просто автоматизируйте – переосмыслийте, перепроектируйте и оптимизируйте задачу для достижения наилучшего возможного результата.

Принцип разработки № 4: выбор правильной архитектуры

Одно из самых важных решений в разработке агента – это архитектурный подход. «Думайте об этом как о строительстве дома, – объясняем мы. – Вы можете попытаться создать одну огромную комнату, которая служит всем целям, или разработать специализированные пространства, которые гармонично работают вместе. На нашем опыте последний подход почти всегда работает лучше».

Это приводит нас к фундаментальному вопросу в разработке агентов: стоит ли создавать одного сложного агента, который справляется со всем, или создать команду специализированных агентов?

При проектировании нашей системы автоматизации информационных бюллетеней мы столкнулись с решающим выбором: строить ли одного сложного агента для всего или создать команду специализированных агентов? Наш опыт внедрения систем ИИ для различных компаний научил нас, что более простые, специализированные компоненты часто работают лучше, чем сложные, монолитные. На этом этапе книги вы уже несколько раз слышали наш принцип разработки «один инструмент – один агент». Давайте разберем важнейшие решения по проектированию, которые привели к нашей успешной разработке.

«Изначально мы были соблазнены идеей создания одного “суперагента”, который мог бы справляться со всем – от поиска контента до форматирования бюллетеня, – объясняет Ракеш, один из наших соавторов. – Но мы быстро поняли, что это было бы как попросить одного человека быть одновременно исследователем, писателем, редактором и разработчиком, – это редко работает хорошо».

Поэтому мы разработали комплексную команду специализированных агентов:

Таблица 8.4. Наша команда специализированных агентов ИИ для автоматизации информационного бюллетеня (Источник: © Борне и др.)

Имя агента	Роль агента
Агент поиска	Находит релевантные статьи в интернете
Агент суммаризации	Обобщает ключевые моменты из статей
Агент электронной почты	Отправляет обзоры по электронной почте каждый день
Агент компиляции	Организует контент на основе выбранных статей
Агент форматирования бюллетеня	Подготавливает финальный информационный бюллетень
Агент-менеджер	Координирует и обеспечивает финальную доставку

Этот модульный подход позволил каждому агенту превосходить в своей специализированной роли, сохраняя гибкость системы через скоординированное взаимодействие.

Ключевые принципы, которые направляли нашу разработку

Мы следовали шести основным принципам при проектировании нашей мультиагентной системы.

1. *Четкость цели.* «Каждый агент должен быть как квалифицированный специалист, – объясняет Ракеш. – Как вы не стали бы просить кардиохирурга быть заодно и анестезиологом, мы также дали каждому агенту свою четкую, сфокусированную роль».
2. *Эффективность через специализацию.* Вместо создания сложных агентов, которые могут делать многие вещи на среднем уровне, мы создали простых агентов, которые могут делать одну вещь исключительно хорошо.
3. *Масштабируемость по проекту.* «Мы разработали систему агентов для обработки увеличивающихся рабочих нагрузок», – делится Ракеш. – Например, если объем контента увеличивается, мы можем ввести несколько агентов поиска, работающих параллельно, или оптимизировать агента суммаризации¹ для более быстрой обработки.
4. *Автономная работа.* Каждый агент работает независимо в своей области, принимая решения на основе четких критериев без необходимости постоянного надзора.
5. *Бесшовное сотрудничество.* Агенты работают вместе как слаженная команда, со стандартизированными протоколами коммуникации и четкими точками передачи.
6. *Централизованная оркестрация.* Наш агент-менеджер обеспечивает гармоничную работу всех компонентов, подобно дирижеру, управляющему оркестром.

¹ Агент суммаризации – это инструмент, который обрабатывает большие объемы текста и выделяет основные идеи для краткого изложения – резюме. Такие агенты используют алгоритмы и обработку естественного языка (NLP). – *Прим. ред.*

Принцип разработки № 5: стройте сотрудничество человека и искусственного интеллекта

Пожалуй, самый важный аспект разработки агента – это определение того, как люди и ИИ будут работать вместе. «Цель не в том, чтобы убрать людей из процесса, – подчеркивает Нандан, – а в создании симбиотических отношений, где и люди, и ИИ-агенты вносят свои уникальные вклады, представляя свои сильные стороны».

Этот принцип становится особенно важным, когда мы учитываем современные ограничения агентов ИИ. На уровнях 1–3 нашего прогрессивного фреймворка агенты все еще не обладают настоящей адаптивной обучаемостью и сложными рассуждающими способностями. Это означает, что человеческие знания и опыт остаются необходимыми для следующих задач.

1. *Стратегическое принятие решений.* Люди превосходят в понимании контекста и представлении нюансированных суждений.
2. *Контроль качества.* Обеспечение надзора и выявление тонких ошибок.
3. *Обработка исключений.* Управление неожиданными ситуациями, которые выходят за рамки нормальных параметров.
4. *Непрерывное улучшение.* Выявление возможностей для улучшения системы.

Когда мы впервые проектировали нашу систему информационных бюллетеней, мы столкнулись с фундаментальным вопросом: какие задачи должны быть автоматизированы, а какие должны остаться в руках людей? Наш подход заключался в том, чтобы думать не о том, что «можно» автоматизировать, а о том, что «должно» быть автоматизировано.

Мы выявили две критические точки взаимодействия с человеком.

Первая ключевая точка взаимодействия наступает после того, как наши агенты ИИ собрали и обобщили контент. Редактор-человек просматривает ежедневные обзоры и выбирает наиболее релевантные части для бюллетеня. Это решение требует понимания потребностей нашей аудитории, распознавания новых трендов и принятия нюансированных суждений о ценности контента – способности, которые остаются уникально человеческими.

Во время внедрения мы обнаружили интересную закономерность: когда мы позволяли ИИ делать финальный выбор контента, бюллетени становились технически точными, но как-то бездушными. Им не хватало стратегического нарратива и тематической связности, которые приходят с вмешательством человека. Сохраняя людей в этой ключевой роли принятия решений, мы поддерживали оригинальность изложения и стратегическую релевантность бюллетеня.

Вторая критическая точка взаимодействия происходит непосредственно перед публикацией. Здесь редакторы-люди просматривают полный бюллетень, добавляют контекст, где это необходимо, и обеспечивают соответствие контента нашим редакционным стандартам. Эта финальная проверка не только выявляет ошибки – она делает бюллетень действительно ценным для наших читателей.

«Этот подход с человеком в цикле, – объясняет Нандан, – дает нам лучшее из возможного. Агенты обрабатывают трудоемкие задачи, в то время как люди сосредотачиваются на стратегических решениях, которые требуют суждений и отраслевой компетентности».

Результат: целевая агентная система

После нескольких дней работы мы пришли к этому. Ниже представлен новый целевой процесс, который мы разработали, показывающий поток важнейших активностей, ответственных агентов и человека, участвующего в цикле.

Ежедневный рабочий процесс

1. *Агент поиска*: ищет релевантные статьи в интернете и отправляет ссылки агенту обобщения.
2. *Агент суммаризации*: обобщает каждую статью в три ключевых пункта и отправляет обзоры агенту доставки электронной почты.
3. *Агент доставки электронной почты*: компилирует обзоры в отформатированное письмо и отправляет его человеку для проверки.
4. *Рецензент-человек*: просматривает ежедневные письма и отвечает с выбранными статьями.
5. *Агент компиляции*: собирает ежедневные выбранные обзоры в структурированный Google Doc и выполняет контроль качества.

Еженедельный рабочий процесс

1. *Агент форматирования бюллетеня*: по понедельникам агент форматирует Google Doc в визуально привлекательный бюллетень.
2. *Агент-менеджер*: проверяет отформатированный бюллетень и отправляет его человеку для проверки.
3. *Рецензент-человек*: выполняет финальную проверку и публикует бюллетень на желаемых платформах.

Шаг 4. Внедрение разработанных вами агентов ИИ

Выбор правильной платформы для агентов ИИ: приоритет скорости над совершенством

Рынок платформ для агентов ИИ быстро развивался, и сейчас около 400 поставщиков предлагают решения с разной степенью сложности и простоты использования. Это изобилие выбора хотя и предоставляет множество вариантов для организаций, также может привести к параличу принятия решений. На основе нашего опыта внедрения агентов ИИ в различных отраслях мы заметили, что компании часто тратят месяцы на оценку платформ, в то время как их конкуренты продвигаются вперед с внедрениями и получают ценные рыночные преимущества.

Выбор правильной платформы требует понимания трех основных категорий, доступных на сегодняшнем рынке: полностью кодовые (full-code), низкокодовые (low-code) и бескодовые (no-code) решения. Каждая категория отвечает различным организационным потребностям и имеет свои компромиссы между гибкостью, скоростью внедрения и необходимой технической компетентностью.

Бескодовые платформы: быстрое развертывание и доступность

Думайте о бескодовых платформах как о «LEGO-блоках» разработки агентов ИИ. Они предоставляют готовые компоненты, которые вы можете собирать

без какой-либо технической компетенции. Решения, такие как Bizway, Beam, N8N и Relevance AI, позволяют бизнес-пользователям создавать функциональных агентов ИИ через интуитивно понятные интерфейсы без написания кода. Эти платформы идеальны для организаций, которым нужно быстро внедрить агентов базовой или средней сложности или которые хотят доказать ценность агентов ИИ перед инвестированием в более сложные решения.

Хотя бескодовые платформы могут казаться ограниченными по сравнению с их более техническими аналогами, они часто предоставляют удивительно сложные возможности через конфигурацию, а не кодирование. Например, Relevance AI предлагает продвинутые функции, такие как обработка на основе векторов и сложные возможности поиска через удобный интерфейс.

Полнокодовые платформы: максимальный контроль и настройка

На другом конце спектра полнокодовые платформы обеспечивают наивысший уровень контроля и гибкости, но требуют значительных ресурсов разработки. Такие платформы, как LangGraph, CrewAI и AutoGen, предлагают комплексные фреймворки, которые позволяют организациям создавать высоко настраиваемых агентов ИИ. Они особенно хорошо подходят для предприятий, которым нужно поддерживать строгий контроль над своими данными, требуются сложные интеграции с существующими системами или которые работают в строго регулируемых отраслях.

При работе с полнокодовыми платформами организации могут точно настроить каждый аспект поведения своих агентов ИИ, от процессов принятия решений до протоколов обработки данных. Этот уровень контроля обходится дорогой ценой в виде более длительных циклов разработки и необходимости специализированной технической компетентности. Хотя платформы, такие как LangGraph, предлагают обширную документацию и растущую поддержку сообщества, кривая обучения остается крутой.

Эти сложные агенты требуют тщательной оркестрации множества инструментов и сложного управления рабочими процессами, с чем полнокодовые платформы справляются умело. Однако организации должны тщательно рассмотреть, действительно ли такой уровень контроля необходим для их случая использования, поскольку дополнительная нагрузка на разработку может значительно задержать внедрение и время достижения коммерческого результата.

Низкокодовые платформы: сбалансированный подход

Низкокодовые платформы находят баланс между настройкой и доступностью. Платформы, такие как WatsonX Assistant, Agentforce и конструкторы агентов UiPath и Microsoft Copilot, предоставляют визуальные среды разработки, при этом позволяя значительную настройку через код, когда это необходимо. Эти платформы превосходно способствуют сотрудничеству между бизнес-пользователями и техническими командами, что делает их особенно эффективными для организаций, которым нужно быстро развертывать агентов ИИ, сохраняя некоторый уровень настройки.

Низкокодовый подход значительно сокращает время и технические знания, необходимые для внедрения, при этом предоставляя достаточно гибкости для большинства корпоративных случаев использования. Эти платформы обыч-

но предлагают готовые компоненты и интеграции, которые можно настроить под конкретные бизнес-потребности. Например, платформа Virtual Agent от ServiceNow предоставляет готовые компоненты для общих бизнес-процессов, позволяя организациям расширять функциональность через пользовательскую разработку, когда это необходимо.

Принятие решения: важнейшие соображения

Чтобы принять уверенное и эффективное решение, сосредоточьтесь на практическом фреймворке, а не на бесконечных сравнениях функций. Начните с определения трех-четырех ваших главных приоритетов, основанных на бизнес-приоритетах. Присвойте вес каждому критерию, учитывая такие факторы, как простота использования, настройка, интеграция, масштабируемость, безопасность и стоимость. Затем оцените потенциальные платформы на основе этих факторов, выберите платформу с наивысшим рейтингом и двигайтесь вперед.

Техническая компетенция часто служит основным решающим фактором. Организации с сильными командами разработчиков могут естественно склоняться к полностью кодовым решениям. Однако мы заметили, что даже технически способные организации иногда выигрывают от начала с низкокодовых или бескодовых решений для более быстрого внедрения и получения практического опыта перед переходом к более сложным внедрениям.

Еще одно важное соображение – это потенциал масштабирования разработки агентов по всей организации через гражданскую разработку¹. Бескодовые и низкокодовые платформы позволяют демократизировать подход, при котором сотрудники по всей организации могут участвовать в создании и настройке агентов. Эта демократизация разработки агентов может значительно ускорить воздействие инициатив ИИ и привести к более инновационным решениям, поскольку сотрудники, понимающие конкретные бизнес-вызовы, могут напрямую способствовать созданию решений. Например, представитель службы поддержки клиентов может создать агента для обработки рутинных запросов, а финансовый аналитик может разработать агента для автоматизации генерации отчетов. Этот распределенный подход к разработке агентов может значительно увеличить ценность и охват ИИ в организации.

Требования к интеграции с существующими системами и источниками данных также играют решающую роль в выборе платформы. Хотя большинство платформ предлагают подключение через API, легкость и глубина интеграции значительно варьируются. Например, конструктор агентов Microsoft Copilot обеспечивает бесшовную интеграцию с экосистемой Microsoft, что делает его привлекательным выбором для организаций, глубоко инвестировавших в технологии Microsoft.

Требования к безопасности и соответствию нормативам могут значительно влиять на выбор платформы, особенно для организаций в регулируемых отраслях. Полнокодовые платформы обычно предлагают наибольший контроль над обработкой данных и протоколами безопасности, в то время как бескодовые платформы могут иметь ограничения в этих областях.

¹ Гражданская разработка – вовлечение непрофессиональных разработчиков (обычных сотрудников или пользователей без глубоких технических знаний) в создание приложений, автоматизацию процессов или работу с ИИ-инструментами. – *Прим. ред.*

Избегайте чрезмерного обдумывания

Ни одна платформа не идеальна, и ожидание «идеального» выбора может привести к упущенным возможностям. Лучшая стратегия – начать с малого, экспериментировать и масштабироваться по мере обучения. Многие успешные компании начинают с простого агента ИИ на низкокодовой платформе, подтверждают его воздействие и постепенно переходят к более продвинутым решениям по мере развития их потребностей¹.

Пока вы все еще решаете, ваши конкуренты уже развертывают агентов ИИ, которые трансформируют их отрасли. Предприятия, которые действуют быстро, возглавляют революцию ИИ, в то время как те, кто медлит, будут тратить усилия, чтобы догнать. Лучшая стратегия ИИ – это не идеальная, а та, которую вы начинаете сегодня.

В следующих разделах мы использовали наш опыт для создания универсального руководства, которое работает на разных платформах, подчеркивая критические факторы успеха, тонкие решения и скрытые функции, которые действительно имеют значение при создании эффективных агентов ИИ. Преимущество этого руководства в том, что вы можете использовать его независимо от выбранной платформы; однако недостаток заключается в том, что оно не является специфичным для какой-либо одной платформы, и вы можете заметить некоторые различия в терминологии и деталях функциональности. Тем не менее в качестве примера мы решили предоставить подробное пошаговое руководство по созданию агента на низкокодовой платформе Relevance AI, которое вы найдете в приложениях к книге.

Создание эффективных агентов ИИ: фреймворк A.G.E.N.T.

На основе нашего опыта мы узнали, что успех часто заключается не в сложности технологии, а в ясности и тщательности определения и структурирования наших агентов ИИ. Через многочисленные внедрения и, признаться, некоторые болезненные уроки мы разработали то, что мы называем фреймворком A.G.E.N.T.: комплексный подход к созданию надежных агентов ИИ, которые действительно приносят пользу.

Фреймворк состоит из пяти критических компонентов.

- Идентичность агента: кто такой агент?
- Инструменты и мозг: что поддерживает агента?
- Исполнение и рабочий процесс: как работает агент?

¹ Термин «чрезмерное обдумывание» (англ. *overthinking*) обычно используется для описания ситуации, когда модель ИИ избыточно анализирует данные, усложняет процесс принятия решений или тратит слишком много ресурсов на задачу, которая могла бы быть решена проще. Это может проявляться, например, в переобучении (*overfitting*), когда модель слишком «защипывается» на обучающих данных, теряя способность к обобщению; или в избыточной сложности, когда ИИ выбирает сложные пути решения, когда достаточно простого подхода; или в чрезмерной интерпретации, когда модель приписывает избыточное значение входным данным, что приводит к ошибкам или неэффективности. – *Прим. ред.*

- Навигация и правила: как агент принимает решения?
- Тестирование и доверие: как мы улучшаем и масштабируем агента?

Думайте о создании агента ИИ как о найме и обучении нового сотрудника. Вы бы не привели кого-то в свою организацию, не определив четко его роль, не установив его обязанности и не настроив его рабочие процессы, инструменты и правила, по которым он будет действовать. Тот же принцип применим к агентам ИИ, но это еще более важно, потому что эти цифровые работники требуют чрезвычайно точных инструкций для эффективного функционирования.

Давайте глубоко погрузимся в первый важный компонент фреймворка: идентичность агента.

А – идентичность агента: кто такой агент?

Самый важный шаг при создании агента ИИ – это определение его идентичности¹ – его цели, роли и операционного охвата. Здесь большинство людей допускают свою первую ошибку. Они спешат вперед, стремясь увидеть своего агента ИИ в действии, не уделяя времени тщательному определению того, что агент должен делать. Результат? ИИ, который ведет себя непредсказуемо, выдает непоследовательные результаты или просто бесполезен.

Чтобы проиллюстрировать, почему этот шаг так важен, представьте, что вы нанимаете нового сотрудника. Стали бы вы приводить кого-то в свою компанию и говорить: «Просто помогай, как считаешь нужным»? Конечно, нет. Новому сотруднику нужна четкая ориентация: его роль, обязанности и ограничения. То же самое относится к агентам ИИ. Если вы не дадите им структурированную идентичность, они будут бродить бесцельно, часто выдавая результаты, которые ненадежны, нерелевантны или даже контрпродуктивны.

Почему определение идентичности агента критически важно

Агенты ИИ – это не интуитивные мыслители. У них нет инстинктов или здравого смысла. Они работают в рамках установленных вами ограничений. Если вы не определите их идентичность должным образом, вы увидите последствия в следующих трех аспектах.

1. Ненадежное поведение – агент может отвечать способами, которые не соответствуют вашим целям, из-за отсутствия направления.
2. Непоследовательность – один и тот же вопрос может давать разные результаты каждый раз, потому что у агента нет четких ориентиров.
3. Отсутствие контроля – если область действия агента не определена четко, он может выдавать ненужные, нерелевантные или даже вредные результаты.

¹ Идентичность агента ИИ обозначает уникальный набор характеристик, функций, ролей и шаблонов поведения, которые определяют конкретного ИИ-агента в рамках системы или организации. Это понятие отражает, как агент воспринимается, взаимодействует с пользователями (людьми, другими агентами или системами) и выполняет свои задачи, сохраняя определенную «личность» или функциональную роль в экосистеме – его назначение, стиль взаимодействия, уровень автономности и способ интеграции в бизнес-процессы. – *Прим. ред.*

Чтобы увидеть это в действии, рассмотрим наше путешествие по созданию помощника по обобщению с поддержкой ИИ для нашего информационного бюллетеня. Изначально мы дали агенту простую директиву:

«Обобщайте новостные статьи и исследовательские работы».

Звучит разумно, верно? Но результаты были хаотичными. ИИ собирал случайные статьи, обобщал их без четкой структуры и иногда даже включал устаревшие или нерелевантные источники. Это не была вина ИИ – он просто следовал нечетким инструкциям.

Поэтому мы уточнили идентичность агента и дали ему более точную роль:

«Вы – помощник по обобщению, специализирующийся на трендах в области ИИ и бизнеса. Ваша задача – брать новостные статьи и исследовательские работы из таких источников, как MIT Tech Review, arXiv и Harvard Business Review, и превращать их в ясные, увлекательные обзоры. Каждый обзор должен быть короче 150 слов, захватывать важнейшие выводы и сохранять исходный смысл. Тон должен быть профессиональным, но доступным, соответствующим стилю нашего бюллетеня».

С таким уровнем ясности наш ИИ превратился из ненадежного сборщика контента в сфокусированного исследовательского партнера. Теперь он выдает краткие, ценные обзоры, которые держат наших читателей в курсе событий без необходимости просеивать горы информации. Вы можете обратиться к приложению, где мы предоставляем подробную идентичность этого агента. Вы можете использовать ее как шаблон для написания своей собственной.

Создание сильного агента ИИ: думайте как менеджер

Чтобы поставить это в перспективу, представьте, что вы управляете удаленным сотрудником, который не может думать самостоятельно – он только следует инструкциям. Что необходимо?

1. Дать ему четкое описание работы.
2. Сказать ему точно, какие задачи он должен (и какие не должен) выполнять.
3. Определить, как он должен осуществлять коммуникации.
4. Установить границы и точки эскалации (для передачи задачи человеку).

Теперь замените этого сотрудника на вашего агента ИИ. Если вы не определите эти вещи, ваш ИИ будет ненадежным. Но если вы это сделаете, у вас будет агент, который выполняет свои функции последовательно, эффективно и разумно в доверенной ему области.

Прежде чем переходить к выбору моделей и рабочих процессов, уделите время написанию идентичности вашего агента. Чем лучше эта основа, тем мощнее и эффективнее будет ваш агент ИИ.

Ключевые элементы сильной идентичности агента

Определение идентичности агента ИИ – это больше, чем просто указание его функции. Это требует точности, как при написании хорошо продуманного описания работы.

1. Цель: какова основная миссия агента?

Каждый агент ИИ должен иметь четкое заявление о миссии, которое отвечает на вопрос: зачем существует этот агент? Сильное заявление о цели не оставляет места для двусмысленности.

- Слабая цель: «Помогать с поддержкой клиентов».
- Сильная цель: «Помогать клиентам, решая распространенные технические проблемы с пошаговыми решениями в профессиональной, дружелюбной манере».

Чем сильнее цель, тем более согласованными будут выходные данные агента с ожиданиями пользователей.

2. Роль: какую персону представляет агент?

Роль агента определяет, как он взаимодействует с пользователями и какую компетенцию (знания и опыт) он имитирует – по сути, его профессиональную идентичность. Хорошо определенная роль гарантирует, что пользователи сразу понимают его возможности и ограничения, а также предоставляет четкие границы для того, что агент должен и не должен делать.

Например, финансовый агент ИИ может быть:

- «финансовым аналитиком» (предоставляющим инвестиционные инсайты и оценки рисков);
- «личным финансовым коучем» (помогающим пользователям составлять бюджет и экономить деньги);
- «налоговым консультантом» (отвечающим на вопросы, связанные с налогами, с учетом соответствия требованиям).

Каждая из этих ролей потребует от ИИ разного стиля коммуникации и фокуса на разных типах информации.

3. Область действия: что может делать агент и чего он должен избегать?

Без четких границ агент ИИ может выйти за пределы своей предполагаемой функции. Установка четко определенных ограничений области действия гарантирует, что он остается сфокусированным.

Например, агент службы поддержки клиентов может быть ограничен:

- ответами на часто задаваемые вопросы на основе знаний компании;
- предоставлением шагов по устранению неполадок для распространенных проблем;
- эскалацией сложных вопросов к человеческим представителям.

Он не должен пытаться:

- давать юридические или медицинские советы;
- принимать несанкционированные решения;
- генерировать спекулятивные ответы.

Границы предотвращают выход агента в области, где ошибки могут быть дорогостоящими.

G – инструменты и мозг: поддержка вашего агента ИИ

Как только ваш агент ИИ получил четко определенную идентичность, следующий шаг – оснастить его правильными инструментами и мозгом – инструментами, моделями и знаниями, необходимыми для эффективного функционирования. Здесь многие разработчики ошибаются. Они либо усложняют вещи, выбирая продвинутое настраивание, которые им не нужны, либо недоукомплектовывают своих агентов, выбирая неподходящие инструменты для работы.

Думайте об этом шаге как о сборке соответствующего предназначенной цели автомобиля. Вы бы не поставили гоночный двигатель в фургон доставки или не ожидали бы, что семейный седан выиграет «Формулу-1». Та же логика применима к агентам ИИ – выбор неправильной комбинации моделей ИИ, инструментов и источников данных приведет к неэффективности, плохой производительности или полному провалу.

1. Выбор правильной модели ИИ: баланс между мощностью, стоимостью и эффективностью

Большинство платформ позволяют вам выбрать, какую модель ИИ (или комбинацию моделей) будет использовать ваш агент. Это решение критически важно – оно определяет, как ваш агент думает, отвечает и обрабатывает информацию. Модель ИИ – это мозг агента, определяющий, насколько хорошо он понимает, рассуждает и генерирует ответы. Есть два важнейших компромисса, которые нужно учитывать: размер модели и способность к рассуждению.

Меньшие модели, такие как Mini, Phi или Flash, быстрые, эффективные и экономичные, что делает их идеальными для простых запросов или заранее определенных задач. Однако их слабое место – глубокие рассуждения и решение сложных проблем. С другой стороны, более крупные модели, такие как GPT, Claude Opus или Gemini Ultra, могут анализировать нюансированную информацию, генерировать высококачественные ответы и мыслить критически – но они потребляют больше ресурсов и дороже в эксплуатации.

Для чувствительных к стоимости приложений использование небольшой модели для рутинных задач и резервирование более крупной модели для сложных запросов часто является лучшим подходом. Модели с открытым исходным кодом, такие как Mistral или Llama 70B, обеспечивают больше контроля и меньшие затраты, но требуют соответствующей квалификации для тонкой настройки и развертывания.

Настройки температуры

Еще один важный фактор в настройке производительности вашего агента ИИ – это регулировка настроек температуры, функция, доступная на многих платформах. Настройка температуры контролирует, насколько детерминированными или креативными будут ответы ИИ, влияя как на надежность, так и на гибкость агента.

Низкая температура (например, от 0 до 0,3) делает ИИ более предсказуемым и последовательным, заставляя ИИ строго придерживаться фактических ответов и минимизировать случайность. Это идеально для приложений, где точность критически важна, таких как агенты обобщения для информационных бюллетеней, исследовательские помощники или юридические инструменты ИИ. Вы хотите, чтобы ИИ генерировал краткие, основанные на фактах обзоры, а не выдавал неожиданные вариации в тоне или содержании.

Высокая температура (например, от 0,7 до 1,0) делает ИИ более креативным и открытым, вводя разнообразие в формулировки и ответы. Эта настройка полезна для мозгового штурма, генерации маркетингового контента или написания креативного контента, где оригинальность важнее строгой точности. Однако в структурированных средах, таких как агент суммариза-

ции, высокая температура может привести к непоследовательности, галлюцинациям или излишне многословным результатам, которые отклоняются от исходного смысла.

Для более глубокого понимания выбора модели ИИ для агентов ресурсы, такие как сравнения моделей Hugging Face для агентов¹ и исследовательские статьи по ИИ от OpenAI, Anthropic или DeepMind, могут предоставить ценные ориентиры².

2. Выбор правильных инструментов: точность важнее мощности

Агент ИИ – это не генератор текста; он должен взаимодействовать с внешними системами, извлекать данные в реальном времени и действовать. Подобно тому, как компания не дала бы сотруднику неограниченный доступ к своим системам, набор инструментов агента ИИ должен быть четко определен, ограничен и контролируем.

Во время нашего проекта с информационным бюллетенем мы изначально дали нашему агенту поиска неограниченный доступ к инструментам веб-скрейпинга. Результатом был поток контента из ненадежных источников и периодические блокировки серверов от перегруженных веб-сайтов. Мы научились важности детального определения цели, ограничений и параметров использования каждого инструмента. Для нашего агента поиска это означало указание не только того, какие API он может использовать, но и как именно. Вы можете обратиться к приложению, где мы предоставляем подробные спецификации инструментов нашего агента. Вы можете использовать их как шаблон для написания своих собственных.

API – это наиболее распространенные инструменты, позволяющие агентам получать информацию в реальном времени или выполнять действия. Например, финансовый агент может использовать API рыночных данных для получения цен на акции, в то время как помощник по планированию полагается на API календаря. Однако неограниченный доступ к API может привести к ограничениям по количеству запросов, уязвимостям безопасности или юридическим проблемам – как это было с многими агентами веб-скрейпинга, которые в итоге были заблокированы или запрещены за чрезмерное сканирование.

Чтобы предотвратить неправильное использование, агентам нужны структурированные политики использования, которые определяют четкие операционные границы. Необходимо указать несколько ключевых параметров.

- Ограничения по количеству запросов и контроль затрат. Чтобы обеспечить эффективность и контроль затрат, агент должен работать в рамках установленного лимита запросов в минуту. Многие API взимают плату за запрос, что означает, что неконтролируемое использование может привести к высоким затратам. Кроме того, превышение лимитов, установленных поставщиком, может вызвать троттлинг, когда API замедляется или

¹ Galileo AI, без даты. «Таблица лидеров агентов», <https://huggingface.co/spaces/galileo-ai/agent-leaderboard>.

² Картик Нарасимхан, 2024. «Тестирование агентов ИИ», <https://sierra.ai/blog/benchmarking-ai-agents>.

временно блокирует запросы, чтобы предотвратить перегрузку системы. Управляя частотой запросов, агент избегает ненужных расходов, поддерживая плавную и бесперебойную производительность.

- Надежность источников. Агент должен извлекать данные только из предварительно одобренных, надежных источников, чтобы предотвратить дезинформацию. Это может включать белый список доверенных новостных изданий или фильтрацию контента на основе стандартов качества. Например, наш исследовательский агент был запрограммирован на получение информации только из предварительно одобренных, уважаемых источников, таких как MIT Tech Review, arXiv или Harvard Business Review.
- Безопасный доступ к API. Ключи API должны регулярно обновляться и защищаться механизмами аутентификации (например, токенами), чтобы предотвратить несанкционированное использование. Они никогда не должны быть жестко закодированы в скриптах.
- Автоматические выключатели. Останавливайте выполнение, если происходят повторяющиеся сбои, вместо того чтобы продолжать отправлять ошибочные запросы. Например, если API не сработал три раза подряд, агент должен приостановиться и уведомить администратора, вместо того чтобы бесконечно пытаться снова.
- Резервные системы. Обеспечивайте непрерывность, переключаясь на резервный процесс, когда что-то идет не так. Например, если API новостей не работает, ИИ может извлечь заголовки из вторичного источника вместо возврата ошибки.

Без этих защитных мер агент ИИ может перегрузить себя, расстроить пользователей и даже нанести ущерб бизнес-операциям. Для тех, кто хочет глубже изучить интеграцию инструментов ИИ, вы можете обратиться к части 2 этой книги. Также вы можете ознакомиться с документацией по API от OpenAI¹, Google² и AWS³, которые предоставляют отличное руководство по ответственному внедрению.

Выбор источников знаний: основа надежного агента ИИ

Агент ИИ должен извлекать и обрабатывать информацию из надежных источников. Если эти источники плохо определены, агент может галлюцинировать, извлекать неверные данные или предоставлять вводящие в заблуждение ответы. Есть три основных способа структурирования базы знаний агента: базы данных, API и эмбединг документов.

База данных лучше всего подходит для внутренней информации – такой как истории клиентов, политики или проприетарные исследования. API, с другой

¹ OpenAI, без даты. «Лучшие практики для производства», <https://platform.openai.com/docs/guides/production-best-practices>.

² Google, без даты. «API и справочные материалы», <https://cloud.google.com/generative-ai-app-builder/docs/apis>.

³ Майра Ладейра Танке и др., 2024. «Лучшие практики для создания надежных приложений генеративного ИИ с агентами Amazon Bedrock – Часть 1», <https://aws.amazon.com/blogs/machine-learning/best-practices-for-building-robust-generative-ai-applications-with-amazon-bedrock-agents-part-1/>.

стороны, обеспечивают возможность получения актуальных данных, таких как прогнозы погоды, юридические обновления или финансовые статистики. Между тем эмбединг документов позволяют ИИ искать и извлекать информацию из больших коллекций текста, что делает их идеальными для юридических, академических и корпоративных решений ИИ.

Однако не все знания должны быть включены. Если агент имеет доступ к устаревшим или предвзятым источникам, он рискует стать распространителем дезинформации. Аналогично нефильтрованный поиск в открытом интернете может быть опасен, так как это может привести к извлечению низкого качества или вводящего в заблуждение контента. Вместо этого агенты ИИ должны быть обучены на доверенных, домен-специфичных наборах данных и ограничены от генерации спекулятивной информации.

Тем, кто заинтересован в уточнении стратегий выбора знаний, можно обратиться к части 2 этой книги. Также вы можете ознакомиться с платформами векторных баз данных, такими как Weaviate¹ или Pinecone², а также академическими исследованиями от Stanford AI Lab³, которые предоставляют продвинутые инсайты.

Финальные рекомендации: создание ИИ, который работает более умно, а не более напряженно

На основе нашего опыта лучшие агенты ИИ – это не те, у которых больше всего мощности, а те, у которых правильный баланс интеллекта, инструментов и источников знаний. Поддержание эффективности моделей, ограничение доступа к инструментам и курирование высококачественных источников знаний обеспечивают надежность, безопасность и доверие.

Плохо настроенный ИИ в лучшем случае расточителен, а в худшем – опасен. Секрет в том, чтобы начинать с четких определений, строгих параметров и надежных источников, гарантируя, что агент работает в контролируемых и предсказуемых границах.

Е – исполнение и рабочий процесс (как работает агент?)

Как только ваш агент ИИ получил четко определенную идентичность и оснащен правильными инструментами и мозгом, пришло время сосредоточиться на исполнении – как агент фактически работает в реальных условиях.

Многие проекты ИИ терпят неудачу не из-за плохих моделей или отсутствия инструментов, а из-за плохо разработанных рабочих процессов. Без четкой структуры агент рискует действовать непредсказуемо, неправильно обрабатывать входные данные или отвечать непоследовательно. Подобно хорошо обученному сотруднику, который следует структурированному рабочему процессу, агенту ИИ нужен определенный формат входных данных, логический рабочий процесс и четкие триггеры, которые определяют, когда и как он действует.

¹ Weaviate, 2025, <https://weaviate.io>.

² Pinecone, 2025, <https://www.pinecone.io/product/>.

³ Stanford Autonomous Agents Lab, 2025, <https://www.autonomousagents.stanford.edu>.

Определение входных и выходных данных: говорить на правильном языке

Прежде чем агент ИИ сможет функционировать должным образом, он должен понимать формат данных, которые он получает и выдает.

Точное определение входных и выходных данных может казаться очевидным, но это на самом деле один из самых важных аспектов разработки агента. Мы усвоили этот урок с нашей системой информационных бюллетеней. Изначально мы недостаточно четко определили, как наш агент суммаризации должен получать контент от агента поиска. Результат? Постоянные ошибки из-за несоответствия форматов данных, отсутствия метаданных и непоследовательной структуры контента.

Рассмотрим, что произошло, когда мы не указали должным образом формат входных данных для URL-адресов статей. Некоторые приходили с параметрами запроса, другие – без; некоторые включали якорные теги, а другие были чистыми URL-адресами. Это, казалось бы, незначительное упущение привело к тому, что наша система иногда обрабатывала одну и ту же статью несколько раз или полностью пропускала статьи. Определив точные спецификации входных данных – включая форматирование URL, необходимые поля метаданных и структуру контента – мы полностью устранили эти проблемы.

Тот же принцип применим к выходным данным. Когда мы впервые запустили систему, наш агент суммаризации иногда выдавал обзоры, которые были слишком длинными для нашего шаблона электронной почты, что вынуждало нас проводить ручное редактирование. Указав точные параметры выходных данных – лимиты символов, требуемые разделы и правила форматирования, – мы обеспечили, чтобы выходные данные каждого агента плавно переходили в следующий этап процесса.

Чтобы предотвратить такие проблемы, каждый агент ИИ должен иметь:

- строгую валидацию входных данных – убедитесь, что агент может обрабатывать только те форматы, для которых он предназначен;
- четкие определения выходных данных – получающая система всегда должна знать, чего ожидать.

Вы можете обратиться к приложению, где мы предоставляем такие подробные примеры.

Для тех, кто занимается обработкой больших объемов или критически важных данных, фреймворки, такие как OpenAPI для обработки структурированных данных¹ или JSON Schema для валидации, могут помочь стандартизировать входные и выходные данные в рабочих процессах ИИ².

Разработка рабочего процесса: структурирование процесса принятия решений ИИ

Агент ИИ не работает изолированно – он активируется и затем следует последовательности шагов для обработки информации и принятия решений. Пра-

¹ Мишель Покрас, 2024. «Представляем структурированные выходные данные в API», <https://openai.com/index/introducing-structured-outputs-in-the-api/>.

² Стивен Коллинз, 2024. «Представляем JSON-схемы для целостности данных ИИ», <https://stephencollins.tech/posts/introducing-json-schemas-for-ai-data-integrity>.

вильно определенный рабочий процесс указывает не только шаги, но и переходы между ними. Без определенного рабочего процесса агент может заклиниваться без необходимости, выполнять действия в неподходящее время или демонстрировать непоследовательное поведение.

Хорошо структурированный рабочий процесс включает в себя следующее.

1. Критерии активации. Когда агент начинает работать? Ждет ли он ввода пользователя, вызова API или запланированной задачи? Существует три основных типа триггеров.
 - ♦ *Ввод пользователя.* Агент отвечает только по запросу (например, чат-боты, виртуальные помощники).
 - ♦ *Вызовы API.* Активируются, когда другая система запрашивает данные (например, автоматизация на основе ИИ).
 - ♦ *Запланированное выполнение.* Выполняется через фиксированные интервалы (например, ежедневные отчеты, обработка данных в фоновом режиме).
2. Шаги обработки. Какую последовательность действий выполняет агент? Например, сначала он получает данные, анализирует их, а затем генерирует ответ? Нужно ли ему проверять информацию перед выполнением действия?

Например, наш агент суммаризации для информационного бюллетеня следует следующему рабочему процессу.

1. *Критерии активации.* Агентом исследования загружается или извлекается из источников новая партия статей и исследовательских работ, таких как MIT Tech Review и исследовательские работы arXiv.
2. *Шаги обработки.* Агент обрабатывает контент, извлекая кважнейшие выводы и отфильтровывая нерелевантную или дублирующую информацию.

Хорошо определенный рабочий процесс предотвращает неэффективность и обеспечивает логичное и предсказуемое функционирование агента.

Для создания надежного, масштабируемого ИИ-агента тщательное структурирование исполнения так же важно, как выбор правильной модели. Для более глубокого изучения разработчики могут ознакомиться с лучшими практиками API от OpenAI¹, стратегиями автоматизации рабочих процессов от BPMN², а также архитектурами, управляемыми событиями, используемыми в облачных вычислительных фреймворках, таких как AWS Lambda³ и Google Cloud Functions⁴.

¹ OpenAI, без даты. «Лучшие практики безопасности», <https://platform.openai.com/docs/guides/safety-best-practices>.

² Camunda, без даты. «Движок рабочих процессов BPMN», <https://camunda.com/platform-7/workflow-engine/>.

³ Джеймс Бесвик, 2024. «Работа с Lambda: понимание архитектуры, управляемой событиями – часть 1», <https://aws.amazon.com/blogs/compute/operating-lambda-understanding-event-driven-architecture-part-1/>.

⁴ Observe, без даты. «Функции Google Cloud», <https://docs.observeinc.com/en/latest/content/integrations/gcp/cloud-functions.html>.

Внедрение защитных механизмов: обеспечение надежности ИИ в условиях стресса

Ни одна система ИИ не работает безупречно. Сбои – будь то из-за неисправности агентов, ухудшения производительности или внешних нарушений – неизбежны. Настоящая задача заключается не в избегании сбоев, а в их эффективном управлении для минимизации ущерба и поддержания непрерывности сервиса.

Внедряя автоматические выключатели и структурированную обработку ошибок, агенты ИИ могут рано обнаруживать проблемы, предотвращать каскадные сбои и обеспечивать плавное восстановление. Эти защитные механизмы действуют как иммунная система агентов, защищая как их производительность, так и доверие пользователей.

1. Обработка ошибок и восстановление: поддержание функциональности ИИ

ИИ должен быть разработан для интеллектуального восстановления. Вместо полного сбоя лучшие системы используют трехэтапный подход к восстановлению.

1. *Автоматическое восстановление.* Система автоматически повторяет попытки выполнения неудавшихся процессов, увеличивая интервал между попытками, чтобы избежать перегрузки и повысить шансы на успех.
2. *Плавное снижение качества.* Если функция неоднократно дает сбой, вместо полного останова ИИ-агент снижает сложность исполнения. Например, если агент суммаризации сталкивается с ошибками, он все равно может пересылать ссылки на статьи и метаданные, а не полностью останавливаться.
3. *Эскалация человеку.* Если ИИ не может уверенно решить проблему, он уведомляет человека, предоставляя соответствующий контекст и предлагаемые решения, а не просто дает сбой.

Этот структурированный подход гарантирует, что сбои ИИ-агента остаются под контролем, пользователи все еще получают полезные результаты, а критические сервисы продолжают работать даже в условиях стресса.

2. Автоматические выключатели: предотвращение системных сбоев

Если ошибки сохраняются, автоматические выключатели действуют как иммунная система ИИ, останавливая неисправные процессы до того, как они вызовут масштабный ущерб. Без них агенты могут заикливаться на ошибках, обрабатывать ненадежные данные или ухудшать качество без вмешательства.

Мы узнали это на собственном опыте, когда неисправный агент суммаризации выдавал бессмыслицу в течение двух часов, скомпрометированный источник новостей вводил в заблуждение контент, а перегрузка системы во время крупного события привела к низкокачественным обзорам. Чтобы предотвратить эти проблемы, мы установили пороги качества – если агент суммаризации выдает бессмыслицу три раза в минуту, он автоматически приостанавливается и эскалируется человеку путем отправки сообщения.

Во время крупной технологической конференции наша система была перегружена, что ухудшило качество контента. Автоматические выключатели теперь

обнаруживают и блокируют низкокачественные результаты до того, как они достигнут пользователей, предотвращая ущерб репутации. Платформы, такие как AutoGen и CrewAI, предлагают встроенные защитные механизмы, которые можно настроить для остановки выполнения при возникновении аномалий.

3. Передача задачи человеку: знать, когда ИИ должен отступить

Некоторые решения слишком сложны или рискованны, чтобы ИИ справлялся с ними в одиночку. В таких случаях передача задачи человеку (эскалация человеку) критически важна для поддержания точности, соответствия требованиям и доверия. Вместо слепой передачи задачи хорошо разработанный ИИ должен обеспечивать структурированную эскалацию.

Например, в агенте суммаризации для информационного бюллетеня эскалация происходит, когда ИИ обнаруживает противоречивые или низкоконфиденциальные обзоры. Если несколько источников сообщают о одном и том же событии, но предоставляют противоречивые детали – например, различающиеся цифры о доходах компании или непоследовательные утверждения о запуске продукта, – агент суммаризации не пытается «угадать» правду. Вместо этого он передает проблему человеческому редактору, предоставляя следующее:

- 1) исходные статьи, которые внесли вклад в обзор;
- 2) разбивку обнаруженных противоречий между источниками;
- 3) оценку уверенности, указывающую на надежность сгенерированного ИИ обзора.

Это гарантирует, что редактор имеет весь необходимый контекст для принятия обоснованного решения, а не начинает с нуля.

Аналогично, если ИИ не может сгенерировать связный обзор – возможно, из-за чрезмерного использования жаргона, загрязнения контента, сгенерированного ИИ, или маловразумительного текста, – он эскалирует проблему человеку с предложением альтернативных источников или запросом на ручное вмешательство.

Для читателей, желающих глубже изучить эти темы, ресурсы, такие как «Принципы доверия и безопасности ИИ» от Microsoft¹ или «Лучшие практики API от OpenAI»², предоставляют глубокие инсайты в защитные механизмы, обработку ошибок, автоматические выключатели и стратегии эскалации человек–ИИ.

N – Навигация и правила: как агент ИИ принимает решения

Теперь, когда наш агент ИИ имеет четкую идентичность, правильные инструменты и структурированный рабочий процесс, мы должны рассмотреть один из самых недооцененных, но критически важных аспектов разработки ИИ: как агент принимает решения. Агент ИИ настолько хорош, насколько хороша его система принятия решений. Без четко определенных правил навигации агент становится непредсказуемым, непоследовательным и – что наиболее опасно – неконтролируемым.

¹ Microsoft, 2022. «Стандарт ответственного ИИ Microsoft v2: общие требования», <https://blogs.microsoft.com/wp-content/uploads/prod/sites/5/2022/06/Microsoft-Responsible-AI-Standard-v2-General-Requirements-3.pdf>.

² OpenAI, без даты. «Лучшие практики безопасности», <https://platform.openai.com/docs/guides/safety-best-practices>.

Думайте об агенте ИИ как об автономном транспортном средстве. Вы бы не сказали самоуправляемому автомобилю «Езжай к месту назначения» и не ожидали бы, что он сам разберется во всем. Ему нужны правила для навигации:

- какие маршруты разрешены?
- как он должен обрабатывать препятствия?
- что делать, если дорога заблокирована?

Агентам ИИ нужны аналогичные правила для надежного функционирования. Без этих правил они делают произвольные выборы – или, что хуже, неверные.

Определение правил обработки: фильтрация, приоритизация и логика принятия решений

Каждый агент ИИ должен решать, какая информация имеет значение, что игнорировать и как приоритизировать задачи. Без правил он может быть перегружен нерелевантными данными, возвращать непоследовательные результаты или делать плохие рекомендации.

Хорошо структурированная система обработки включает следующее.

1. *Механизмы фильтрации.* Агент должен различать релевантные и нерелевантные данные. Например, исследовательский ИИ должен приоритизировать рецензируемые исследования над непроверенными постами в блогах.
2. *Логика приоритизации.* Некоторые задачи более срочные или ценные, чем другие. ИИ службы поддержки клиентов должен эскалировать срочные жалобы до обработки общих запросов.
3. *Ограничения обработки.* Перегрузка агента слишком большим объемом данных одновременно замедляет его и увеличивает затраты. Если ИИ извлекает тысячи статей, он должен предварительно отфильтровать их на основе ключевых параметров, а не анализировать все.

Когда мы разрабатывали нашего агента поиска, мы изначально сосредоточились только на соответствии ключевым словам и новизне. Результат? Мы получали технически релевантный, но часто поверхностный контент, который не приносил реальной пользы нашим читателям.

Расширив наши правила обработки, включив сложную оценку релевантности, оценку надежности источников и требования к разнообразию контента, мы превратили агента из простого инструмента поиска в проницательного куратора контента. Каждое правило служит конкретной цели: оценка релевантности обеспечивает ценность контента, оценка надежности поддерживает стандарты качества, а требования к разнообразию предотвращают эффект эхо-камеры.

Неспособность определить эти правила может привести к неэффективности, предвзятости или даже неверному принятию решений. Для более глубокого изучения темы вы можете обратиться к методологиям информационного поиска¹, фреймворкам деревьев решений² и алгоритмам ранжирования, используемым в моделях машинного обучения, для уточнения этих правил³.

¹ Glean, 2024. «Полное руководство по информационному поиску в 2024 году», <https://www.glean.com/blog/glean-information-retrieval-2024>.

² Участники Википедии, 2025. «Обучение с использованием деревьев решений», https://en.wikipedia.org/wiki/Decision_tree_learning.

³ Mage, 2024. «Приложения машинного обучения: ранжирование», https://dev.to/mage_ai/machine-learning-ml-applications-ranking-238d.

Обеспечение прозрачности: создание цепочек решений для подотчетности

Решения ИИ никогда не должны казаться черным ящиком – пользователи должны понимать, почему агент ответил определенным образом. Если ИИ предоставляет финансовую рекомендацию или отклоняет запрос, за решением должна быть прослеживаемая логика.

Один из лучших способов достичь этого – внедрение цепочек решений – логов, которые записывают и объясняют процесс мышления ИИ. Эти логи должны делать следующее.

- Фиксировать входные параметры. Какие данные повлияли на решение ИИ?
- Показывать шаги обработки. Как агент ранжировал варианты, фильтровал информацию или использовал логику?
- Предоставлять обоснования. Почему агент выбрал один вариант вместо другого?

Например, если наш агент исследования для информационного бюллетеня выбирает исследовательскую работу для обобщения, его лог должен включать следующее.

- Источники, из которых он извлекал данные (например, MIT Tech Review, arXiv, Harvard Business Review) и дату написания статьи.
- Обоснование выбора, такое как релевантность текущей теме бюллетеня и принадлежность к белому списку источников.
- Любые альтернативные статьи, которые он рассмотрел, но отбросил, вместе с обоснованием.

Поддерживая прозрачность решений, агент суммаризации обеспечивает редакторский надзор, укрепляет доверие читателей и позволяет совершенствовать процесс выбора – превращая его из простого инструмента автоматизации в надежного, подотчетного исследовательского партнера.

Большинство платформ для агентов ИИ предоставляют встроенные хуки¹ или промежуточное ПО для логирования, которые можно настроить для создания цепочек решений для прозрачности. Эти логи могут быть доступны через панели управления для просмотра или отладки. Секрет в том, чтобы интегрировать логирование в ключевые точки рабочего процесса, где агенты выполняют задачи. Для каждого агента (например, поиска, обобщения) фиксируйте входные данные (например, ключевые слова, статьи), предпринятые действия (например, метод обобщения, оценка релевантности) и выходные данные (например, выбранные статьи, обзоры).

Системы ИИ в финансах, здравоохранении и государственном управлении уже регулируются в отношении прозрачности – это означает, что четкие цепочки решений скоро станут требованием, а не просто лучшей практикой.

¹ Хуки (англ. *hooks*) – это механизмы или точки расширения, которые позволяют разработчикам вмешиваться в процесс выполнения программы или платформы ИИ, чтобы добавить пользовательскую функциональность, обработку данных или логирование без изменения основного кода. В контексте ИИ-агентов *hooks* часто используются в платформах для настройки поведения агентов, обработки событий или интеграции дополнительных функций. – Прим. ред.

Чтобы узнать больше о темах логирования и прозрачности, вы можете изучить фреймворки объяснимого ИИ¹ (XAI)², требования прозрачности ИИ в GDPR³ и практики аудиторского логирования⁴ в корпоративном ИИ⁵.

Т – Тестирование и доверие: как улучшать и масштабировать агента ИИ

Создание агента ИИ – это не разовая задача, а непрерывный процесс тестирования, совершенствования и масштабирования. Даже самый хорошо разработанный агент покажет неожиданное поведение, вызовет проблемы с производительностью и ограничениями при развертывании в реальных сценариях. Без структурированного цикла улучшения агент может выдавать ненадежные результаты, раздражать пользователей или не справляться с масштабированием. Подобно тому, как сотрудник проходит оценки производительности и обучение, агент ИИ должен постоянно тестироваться, мониториться и оптимизироваться.

Моделирование реальных сценариев использования: обеспечение работы ИИ за пределами лаборатории

Агент ИИ может хорошо работать в контролируемых условиях, но реальные пользователи приносят непредсказуемые входные данные, пограничные случаи и вызовы. Единственный способ обеспечить надежность и точность – это строгое тестирование агента в разнообразных сценариях перед развертыванием.

Хорошо продуманный подход к тестированию должен включать следующее.

- *Обычные сценарии.* Обработывает ли агент стандартные запросы пользователей, как ожидалось?
- *Пограничные случаи.* Как он реагирует на неоднозначные, плохо сформулированные или противоречивые входные данные?
- *Симуляции сбоев.* Что происходит, если API недоступен или пользователь предоставляет неполную информацию?

Например, ИИ службы поддержки клиентов должен тестироваться не только на базовые запросы, но и на случаи, когда раздраженный клиент предоставляет нечеткие, эмоциональные или вводящие в заблуждение данные. Анало-

¹ Объяснимый ИИ (англ. *Explainable AI*, XAI) – это направление в искусственном интеллекте, которое фокусируется на создании моделей и систем, чьи решения и процессы принятия решений понятны и интерпретируемы для людей. Это важно, чтобы пользователи, разработчики или регуляторы могли доверять ИИ, понимать, почему он сделал тот или иной вывод, и проверять его корректность. – *Прим. ред.*

² Аман Ананд Рай, 2023. «6 фреймворков объяснимого ИИ (XAI) для прозрачности в ИИ», <https://dev.to/amananandrai/6-explainable-ai-xai-frameworks-for-transparency-in-ai-3koj>.

³ Участники EUAIAct, 2025. «Ключевые вопросы обязательств прозрачности», <https://www.euaiact.com/key-issue/5>.

⁴ API7.ai, 2024. «Что нового в API7 Enterprise 3.2.2: аудиторское логирование», <https://api7.ai/blog/api7-3.2.2-audit-logging>.

⁵ Врушанк Вьяс, 2025. «За пределами внедрения: почему аудиторские логи критически важны для управления корпоративным ИИ», <https://portkey.ai/blog/beyond-implementation-why-audit-logs-are-critical-for-enterprise-ai-governance/>

гично ИИ-помощник в медицинской сфере должен быть подвергнут стресс-тестированию, чтобы обнаружить и предотвратить предоставление неточных медицинских советов.

Пропуск этого шага может привести к галлюцинациям, неуместным ответам или неверному принятию решений, особенно когда пользователи взаимодействуют способами, которые изначально не предполагались. Для структурированных методов тестирования вы можете изучить инструменты оценки LLM, такие как тестовый набор LangChain¹, бенчмаркинг² моделей ИИ от Hugging Face³ и фреймворки стресс-тестирования от OpenAI⁴.

Сбор обратной связи и мониторинг логов: учиться на пользователях и ошибках

Как только агент ИИ запущен, постоянный мониторинг и сбор обратной связи от пользователей критически важны для совершенствования его производительности. Даже при хорошо структурированных рабочих процессах выходные данные ИИ могут отклоняться от требуемого, выдавать неожиданные ответы или не соответствовать ожиданиям пользователей.

Эффективный мониторинг включает следующее.

- *Механизмы обратной связи от пользователей.* Позволяйте пользователям оценивать ответы, отмечать неверные ответы и предоставлять контекстную обратную связь.
- *Анализ логов.* Фиксируйте входные данные, выходные данные и пути принятия решений для обнаружения повторяющихся ошибок или неэффективностей.
- *Отслеживание поведения.* Определяйте, прекращают ли пользователи взаимодействие, запрашивают уточнения или часто сталкиваются с затруднениями.

Например, если ИИ-помощник по подбору персонала постоянно высоко ранжирует неквалифицированных кандидатов, анализ его логов решений может помочь выявить предвзятости или проблемы в механизмах оценки. Аналогично, если ИИ для электронной коммерции предлагает нерелевантные продукты, обратная связь от пользователей может указать, правильно ли он интерпретирует предпочтения или чрезмерно приоритизирует определенные тренды.

Игнорирование этого шага может привести к стагнации производительности ИИ, раздражению пользователей и потере ими доверия. Например, вы можете ис-

¹ Участники LangChain, 2025. «Тестирование», <https://python.langchain.com/docs/concepts/testing/>.

² Бенчмаркинг (англ. *benchmarking*) — это процесс сравнения характеристик, производительности или качества системы, продукта, алгоритма или процесса с эталонными стандартами, конкурентами или лучшими практиками в данной области. — Прим. ред.

³ Аадитья Ура, Паскуале Минервини, Клементина Фуррье, 2024. «Таблица лидеров открытых медицинских LLM: бенчмаркинг больших языковых моделей в здравоохранении», <https://huggingface.co/blog/leaderboard-medicalllm>.

⁴ Лама Ахмад и др., 2024. «Подход OpenAI к внешнему стресс-тестированию», <https://cdn.openai.com/papers/openais-approach-to-external-red-teaming.pdf>.

пользовать инструменты наблюдения, такие как LangSmith¹ и OpenTelemetry, для отслеживания поведения модели и взаимодействий с пользователями².

Совершенствование и улучшение: точная настройка ИИ для лучших результатов

Ни один агент ИИ не идеален при запуске. Улучшение производительности – это итеративный процесс, который включает настройку параметров модели, обновление промптов и оптимизацию рабочих процессов на основе результатов реального мира.

Ключевые области для оптимизации включают следующее.

- *Настройка температуры.* Более низкие значения делают ответы более детерминированными, в то время как более высокие значения поощряют креативность, но увеличивают случайность.
- *Инжиниринг промптов.* Модификация инструкций, ограничений и системных сообщений может значительно улучшить точность и последовательность ответов.
- *Настройка рабочих процессов.* Если определенные задачи вызывают задержки, ошибки или неэффективность, корректировка способов обработки или извлечения данных может повысить производительность.

Например, ИИ-помощнику в юридической сфере, у которого проблемы с краткими ответами, может помочь уточнение промптов для обеспечения лаконичности. Между тем ИИ, который слишком часто галлюцинирует, может выиграть от более низких настроек температуры и более строгих механизмов извлечения знаний.

Модель прогрессивного доверия

Доверие между людьми и агентами ИИ не возникает автоматически – его нужно заслужить. Мы разработали модель прогрессивного доверия, чтобы отразить эту реальность, гарантируя, что системы ИИ постепенно получают автономию по мере демонстрации надежности, точности и прозрачности. Вместо бинарного подхода, где ИИ либо полностью контролируется, либо полностью независим, эта модель переходит к доверию поэтапно, выстраивая баланс между эффективностью и надзором.

- *Этап 1: высокий надзор.* В течение первого месяца работы человеческие редакторы подробно проверяли каждое действие ИИ. Этот интенсивный период надзора служил двум целям: он обеспечивал качество и помогал редакторам понять возможности и ограничения ИИ.
- *Этап 2: выборочный надзор.* По мере того как система доказывала свою надежность, мы перешли к выборочному процессу обзора. Редакторы сосредоточили свое внимание на сложных случаях и стратегических решениях, в то время как рутинные задачи выполнялись агентом более автономно.

¹ Участники LangChain, 2025. «LangSmith», <https://www.langchain.com/langsmith>.

² Дрю Роббинс, Людмила Молкова, 2024. «OpenTelemetry для генеративного ИИ», <https://opentelemetry.io/blog/2024/otel-generative-ai/>.

- *Этап 3: стратегический надзор.* В нашей текущей операции участие человека сосредоточено в основном на стратегическом направлении и исключительных случаях. ИИ обрабатывает рутинные операции с высокой автономией, но всегда в рамках четко определенных параметров.

Эта прогрессивная модель позволяет организациям укреплять уверенность в своих агентах ИИ, сохраняя при этом соответствующие защитные механизмы. Важнейший инсайт заключается в том, что сотрудничество человека и ИИ – это не бинарный выбор да–нет, а спектр, который развивается на основе продемонстрированной производительности. Для каждого внедрения агента мы теперь планируем этот прогресс от плотного надзора к стратегическому надзору с четкими критериями для перехода между этапами.

Как отметил один из клиентов, «высокий уровень контроля на начальном этапе не был связан с недоверием к технологии – это было необходимо для адаптации нашей команды и обеспечения непрерывности бизнеса». Такой подход значительно повысил уровень принятия технологии и долгосрочный успех внедрения наших агентов.

Планирование масштабирования: обеспечение способности агента справляться с ростом

Хорошо разработанный ИИ-агент должен быть способен масштабироваться в соответствии с растущим спросом – обрабатывать больше пользователей, большие объемы данных и повышенную сложность без ухудшения производительности. Многие проекты в области ИИ терпят неудачу не из-за того, что они не работают, а из-за того, что не могут эффективно масштабироваться.

Планирование масштабируемости включает в себя следующее.

- *Нагрузочное тестирование.* Может ли агент справиться с десятикратным увеличением числа пользователей без замедления?
- *Параллельная обработка.* Может ли он распределять задачи между несколькими серверами или моделями?
- *Оптимизация затрат.* Является ли инфраструктура экономически эффективной при масштабировании, или производительность достигается за счет неприемлемого увеличения затрат?

Например, бот ИИ для поддержки клиентов, обрабатывающий 1000 запросов в день, может работать хорошо, но при масштабировании до 100 000 ежедневных взаимодействий он может замедлиться или стать слишком дорогим в эксплуатации. Обеспечение эффективного распределения нагрузки – через бессерверные архитектуры¹, стратегии кеширования и координацию нескольких агентов – является ключом к долгосрочной жизнеспособности.

¹ Бессерверная архитектура – это метод запуска приложений в облаке, не требующий выделенного сервера. При таком подходе разработчики не заботятся о серверной инфраструктуре, ее настройке, масштабировании и мониторинге. Они фокусируются на написании и развертывании отдельных, слабосвязанных функций или событий, которые по требованию запускаются облачной платформой-провайдером. – *Прим. ред.*

Для тех, кто интересуется стратегиями масштабирования ИИ, можно изучить AWS Auto Scaling¹, лучшие практики инфраструктуры ИИ от Google Cloud² и фреймворки развертывания ИИ от NVIDIA для обработки больших объемов выводов³.

Сила простоты

Одним из важнейших уроков, который мы извлекли в отношении надежности, была ценность простоты. Ранние версии нашей системы агентов для рассылок включали сложные процедуры восстановления и тщательно продуманные механизмы резервного копирования. Во временном развитии мы обнаружили, что более простые, хорошо протестированные процессы часто оказывались надежнее, чем сложные. «Наиболее надежные системы, – часто говорит Ракеш, – это те, у которых меньше возможностей для сбоев». Этот принцип побудил нас упростить процессы и устранить ненужную сложность везде, где это возможно.

Использование чат-ботов на основе больших языковых моделей для создания комплексных спецификаций

Мы обнаружили, что чат-боты ИИ, такие как ChatGPT, Gemini или Claude, неоптимальны при разработке детализированных определений и параметров, будь то для подробного определения идентичности агента, настройки правильных параметров API или разработки стратегий резервного копирования. Однако ключ к успеху – в умении правильно формулировать запросы. Мы используем метод, который называем «Прогрессивное уточнение определений».

Сначала мы просим большую языковую модель создать базовое описание роли. Затем постепенно исследуем потенциальные проблемы, крайние случаи и возможные сбои.

- Начальный запрос: «Что должен учитывать агент по суммаризации контента при обработке новостных статей?»
- Последующие запросы: «Что может пойти не так с каждым из этих аспектов?», «Как агент должен обрабатывать каждый тип сбоя?», «Какие метрики будут указывать на хорошую производительность агента?».

Каждый ответ помогает нам создать более полное определение, которое затем проверяется на реальных сценариях.

Резюме фреймворка AGENT

Фреймворк A.G.E.N.T. предоставляет структурированную методологию для создания ИИ-агентов, которые являются надежными, масштабируемыми и эффективными. Ниже представлена матрица, обобщающая ключевые компоненты, что упрощает их внедрение и применение.

¹ Amazon Web Services, 2025, <https://aws.amazon.com/autoscaling/features/>.

² Google Cloud, 2025. «Инфраструктура ИИ», <https://cloud.google.com/ai-infrastructure?hl=ru>.

³ NVIDIA, 2025. «Установка приложений и фреймворков для ИИ и науки о данных», <https://docs.nvidia.com/ai-enterprise/deployment/bare-metal/latest/installing-ai.html>.

Таблица 8.5. Резюме фреймворка AGENT (Источник: © Bornet et al.)

Компонент	Ключевой вопрос	Ключевые элементы	Действия
А – идентичность агента	Что представляет из себя агент?	Цель, роль, область действия	Определить четкое заявление о миссии. Указать границы и обязанности. Обеспечить соответствие предполагаемому использованию
Г – инструменты и мозг	Что мотивирует агента?	Модель ИИ, инструменты, источники знаний	Выбрать подходящую модель на основе производительности и стоимости. Внедрить необходимые API и инструменты. Курировать высококачественные источники знаний
Е – исполнение и рабочий процесс	Как работает агент?	Вход/выход, схема рабочего процесса, триггеры и автоматизация	Стандартизировать форматы входа/выхода. Определить структурированные рабочие процессы. Установить триггеры активации и автоматизировать процессы
Н – навигация и правила	Как агент принимает решения?	Правила обработки, механизмы безопасности, прозрачность	Установить правила фильтрации и приоритизации. Внедрить ограничения скорости, прерыватели цепи и пути эскалации к человеку. Вести журналы решений для отслеживания
Т – тестирование и доверие	Как улучшать и масштабировать агента?	Тестирование в реальных условиях, мониторинг обратной связи, масштабируемость	Моделировать реальные сценарии использования. Собирать отзывы пользователей и отслеживать журналы. Оптимизировать рабочие процессы и планировать масштабирование

Результаты нашего проекта по созданию системы агентов для рассылки

Введение системы агентов полностью трансформировало процесс создания рассылок, сократив рабочую нагрузку с более чем 10 часов в неделю до менее 2 часов – впечатляющее снижение на 80 %. Задачи, которые раньше требовали кропотливого ручного труда, такие как поиск статей, их обобщение и форматирование текста, теперь автоматизированы. Это позволяет человеку-рецензенту сосредоточиться исключительно на высокоприоритетных решениях, таких как выбор лучших статей и финализация контента для публикации.

Помимо эффективности, система обеспечила заметный скачок в качестве. Ранее были распространены несоответствия в тоне и ошибки в форматировании, но теперь результат всегда отполирован и профессионален. Агенты обеспечивают единообразный стиль, который резонирует с аудиторией, а надежность значительно возросла. Резюме и рассылки доставляются вовремя, без задержек, характерных для ручного процесса.

Пожалуй, самым впечатляющим преимуществом является масштабируемость. Система может легко справляться с увеличенной нагрузкой – обрабатывать на 50 % больше статей при необходимости – без дополнительных усилий со стороны человека. Это сочетание экономии времени, повышения качества

и адаптивности не только оптимизировало рабочий процесс, но и установило новый стандарт эффективности и совершенства в создании контента.

Успех нашей системы рассылок, которая за месяц выросла до 300 000 подписчиков, был обусловлен не только использованием сложного ИИ, но и тщательно настроенными ИИ-агентами, работающими вместе в хорошо организованной системе. Каждый агент точно знал, что делать, как это делать и что делать в случае сбоев.

Вы можете попробовать – подпишитесь на нашу рассылку «Агентный интеллект», чтобы быть в курсе последних новостей по этой захватывающей теме. Найдите ее на:

- Substack по адресу <https://agenticintelligence.substack.com>;
- LinkedIn, перейдя по ссылке <https://www.linkedin.com/newsletters/agentic-intelligence-7293015480007557121>.

20 лучших советов по внедрению успешных ИИ-агентов

Для обобщения важнейших выводов из этой главы мы составили список важных советов, которые помогут вам пройти путь от концепции к успешному внедрению.

Шаг 1. Поиск подходящих возможностей для агентных систем

1. Найдите свою нишу. Определите возможности, где пересекаются три ключевых фактора – высокий эффект для бизнеса, осуществимость с современными технологиями и разумные усилия по внедрению.
2. Признавайте ограничения агентов. Оставляйте задачи, требующие подлинного человеческого творчества, стратегического мышления или эмоционального интеллекта, людям – не все процессы следует автоматизировать.
3. Думайте о задачах, а не о ролях. Помните, что агенты – это не сотрудники; с их современными возможностями они превосходно справляются с конкретными задачами, а не с широкими ролями. Один сотрудник может управлять пятью процессами, для автоматизации того же объема работы может потребоваться пять агентов.
4. Начинайте с документированных процессов. Лучшей основой для ИИ-агента является четко задокументированный процесс. Существующая документация процессов часто предоставляет идеальный тренировочный материал: конкретные шаги, инструменты, деревья решений и примеры случаев.
5. Автоматизируйте только проверенные процессы. Никогда не автоматизируйте процесс, который никогда не выполнялся вручную. Сначала докажите вручную, что процесс работает, а затем автоматизируйте его.
6. Разбивайте сложные проблемы. Используйте подход «разделяй и властвуй», решая один компонент за раз вместо создания всей системы сразу.

Шаг 2. Определение роли и возможностей ИИ-агентов

1. Детальное определение целей и инструкций для агентов крайне важно. Уделите время созданию точных определений цели, роли и области действия для каждого агента. Помните, что примеры стоят тысячи слов, и наиболее важные инструкции размещайте в конце ваших запросов.

2. Чем проще, тем лучше. Большее количество агентов, инструментов или задач создает больше сложностей, затрат и проблем с обслуживанием. Начинать с минимального и расширять постепенно.
3. Один инструмент – один агент. В большинстве случаев ограничивайте каждого агента одним четко определенным инструментом вместо попыток создать сложных многоцелевых агентов. Простота ведет к надежности.

Шаг 3. Разработка ИИ-агентов для успеха

1. Делайте разработку для сотрудничества с человеком. Создавайте агентов, которые дополняют человеческие способности, а не пытаются полностью их заменить. Оставляйте людей в процессе для контроля качества и стратегических решений.
2. Интегрируйте в существующие системы пользователей. Убедитесь, что агенты работают в рамках уже используемых систем. Лучший агент бесполезен, если пользователям неудобно к нему обращаться.
3. Обеспечьте обратную связь для агентов. Дайте агентам инструменты для анализа результатов их действий. Они должны быть способны проверять, успешно ли выполнены их задачи.
4. Стандартизируйте входные и выходные данные. Строго определяйте формат всех входных и выходных данных, чтобы предотвратить ошибки из-за несоответствия структур данных.
5. Отделяйте данные процесса от действий. Обеспечьте четкое разделение между тем, что агент знает, и тем, что он может делать. Это повышает безопасность и удобство обслуживания.

Шаг 4. Внедрение ИИ-агентов

1. Приоритет скорости над совершенством. Не заикливайтесь на поиске идеальной платформы. Начните с чего-то работоспособного, учитесь на внедрении и совершенствуйте итеративно.
2. Проектируйте с учетом сбоев. Встраивайте надежную обработку ошибок, прерыватели цепи, плавную деградацию и пути эскалации к человеку. Агенты будут давать сбои – важно, как они восстанавливаются.
3. Создавайте цепочки принятия решений. Убедитесь, что агенты регистрируют процесс принятия решений для каждого решения, создавая подотчетность и позволяя вносить целевые улучшения.
4. Собирайте непрерывную обратную связь. Внедряйте механизмы для сбора отзывов пользователей и метрик производительности системы для постоянного ее улучшения.
5. Используйте прогрессивные модели доверия. Внедряйте поэтапный контроль, который постепенно снижает участие человека по мере доказательства надежности агента.
6. Тестируйте на реальных сценариях. Тщательно тестируйте на крайних случаях и неожиданных входных данных перед развертыванием.
7. Принимайте итерации как неизбежность. Ни один агент не работает идеально с первого раза. Планируйте несколько циклов доработки как часть графика внедрения.

8. Развертывание агентов гораздо сложнее, чем их создание. Проблемы интеграции часто превышают сложность разработки. Выделяйте на развертывание не меньше времени и ресурсов, чем на начальную разработку.
9. Начинайте с малого, затем масштабируйте. Начните с наименьшего компонента, который может принести пользу, докажите его ценность, а затем расширяйте внедрение агентов систематически.

Эти советы представляют собой ценные уроки, полученные в результате нашей работы по внедрению ИИ-агентов в организациях всех размеров. Хотя технологии продолжают быстро развиваться, эти принципы последовательно отделяют успешные внедрения от неудач. Сосредоточившись на этих основах, вы избежите распространенных ошибок, которые привели к срыву многих проектов с агентами.

От идей к получению дохода: бизнес-модели для агентной экономики

Рождение самоуправляемого бизнеса: когда ИИ стал предпринимателем

В своей новаторской книге «Грядущая волна» Мустафа Сулейман предложил увлекательную новую версию теста Тьюринга¹. Вместо вопроса, может ли машина обмануть человека в разговоре, он предложил более практичный вызов: сможет ли ИИ «заработать 1 млн долл. на розничной веб-платформе за несколько месяцев с инвестицией всего в 100 000 долл.»? Когда мы собрались в то ясное осеннее утро, чтобы провести наш эксперимент, мы не знали, что делаем первые шаги к прохождению этого современного теста Тьюринга.

Это было 22 октября 2024 года. Пока мир восхищался способностью ИИ писать стихи и генерировать маркетинговые тексты, мы собирались увидеть нечто гораздо более инновационное: искусственный интеллект, который может думать и действовать как предприниматель.

«Давай попробуем что-то безумное», – предложил я нашей исследовательской команде, когда мы собрались у мониторов в лаборатории. После многих лет внедрения традиционных решений автоматизации – тех, что следуют заранее заданным путям в компьютерных системах, – мы были готовы раздвинуть границы. «Вместо того чтобы указывать ИИ, что делать, давай дадим ему бизнес-цель и посмотрим, что произойдет».

Мы решили использовать возможности Claude для работы с компьютером –

¹ Участники «Википедии», 2025. «Тест Тьюринга», https://ru.wikipedia.org/wiki/Turing_Test.

мощный инструмент, который позволяет ИИ напрямую взаимодействовать с компьютерными системами. Задача, которую мы поставили, была обманчиво простой: сможет ли агент ИИ заработать 10 000 долл. без вмешательства человека? Без заранее написанных скриптов, без доступа к существующим бизнес-аккаунтам – только веб-браузер и возможность писать код.

Начало эксперимента: волнение и опасения

Напряжение в комнате было ощутимым, когда мы запустили эксперимент. Том нервно постукивал пальцами по столу – после десятилетий в этой области он видел немало экспериментов с ИИ, которые шли не по плану. Брайан постоянно проверял и перепроверял наши протоколы безопасности. Мы установили строгие ограничения: начальный бюджет в 20 долл. и отсутствие доступа к сервисам с ограничением по логину. Не окажутся ли эти ограничения слишком жесткими? Или они заставят ИИ мыслить более креативно?

Первые тридцать минут были откровенно пугающими. ИИ двигался невероятно медленно, открывая множество вкладок браузера, записывая фрагменты кода и обращаясь к инструментам разработки быстрее, чем мы могли уследить. «Может, остановить его?» – прошептал Йохен в какой-то момент, когда агент начал быстро разворачивать веб-сервисы, которые мы не ожидали. Но любопытство победило осторожность, и мы позволили ему продолжить.

От хаоса к созиданию: наблюдение за тем, как ИИ думает как предприниматель

То, что развернулось в следующие несколько часов, изменило все наши представления об искусственном интеллекте и автоматизации бизнеса. Через час после получения своей миссии агент ИИ не просто придумывал идеи – он создавал полноценную бизнес-модель. Подумайте, как обычно работают человеческие предприниматели: они выявляют проблему, разрабатывают решение и находят способ его монетизации. Именно это сделал наш агент ИИ, но со скоростью, которая лишила нас дара речи.

Агент определил идеальную возможность применения на рынке: рестораны, испытывающие трудности с переходом на цифровые меню. Его решение? Сложная система меню с QR-кодами, которая выходила далеко за рамки простых цифровых меню. Это было не просто техническое решение – это было продуманное бизнес-предложение, учитывающее реальные потребности и ограничения.

Момент, когда все изменилось

Самый драматичный момент наступил примерно через три часа эксперимента. Агент только что закончил создание своего первого прототипа, когда внезапно приостановил все операции. Семнадцать напряженных минут ничего не происходило. Позже мы поняли, что он проводил всесторонний анализ рынка, чего мы явно не просили его делать.

Когда он возобновил работу, бизнес-модель кардинально изменилась. «Посмотрите на это, – указал Рэй, наклоняясь вперед в кресле. – Он не просто продает QR-коды – он строит целую экосистему аналитики для ресторанов». Агент превратил простую систему цифровых меню в сложную платформу бизнес-аналитики.

Что нас больше всего восхитило – так это наблюдение за процессом рассуждений агента. Столкнувшись с возможными возражениями по поводу доверия к цифровым меню, он не просто придерживался первоначального плана – он развил решение. Агент добавил функции для отслеживания пиковых часов посещения и анализа предпочтений клиентов, превратив простую систему меню в инструмент бизнес-аналитики, который мог помочь владельцам ресторанов оптимизировать свои операции.

Рождение ИИ-агентов третьего уровня

Чтобы понять значимость того, что мы наблюдали, важно понять, где это вписывается в эволюцию ИИ-агентов. Этот эксперимент представлял собой то, что мы называем ИИ-агентом третьего уровня – системы, которые могут понимать сложные инструкции, рассуждать на высоком уровне и координировать несколько инструментов для достижения целей. В отличие от жестких систем автоматизации на основе правил прошлого (уровень 1) или даже более гибких систем интеллектуальной автоматизации (уровень 2), этот агент продемонстрировал настоящие способности к решению проблем.

Представьте это так: если традиционная автоматизация похожа на обучение робота следовать рецепту, то то, что мы наблюдали, было больше похоже на наблюдение за шеф-поваром, который создает новые блюда на основе доступных ингредиентов и предпочтений клиентов. Агент не просто выполнял заранее запрограммированные инструкции – он создавал, адаптировал и совершенствовал свой подход на основе рыночных потребностей и потенциальных проблем.

Формирование бизнес-модели

Самым впечатляющим аспектом было не только техническое решение, но и то, как агент разработал полноценную бизнес-стратегию. Он создал двухуровневую модель ценообразования: 99 долл. за базовый сервис и 200 долл. за премиум-функции. Это не было произвольным ценообразованием – агент проанализировал рынок, учел ценностное предложение и структурировал свое предложение так, чтобы оно привлекало малые и средние рестораны, которым не хватало технических знаний, но требовались цифровые решения.

Однако не все прошло гладко. Примерно через пять часов мы обнаружили серьезный недостаток в системе обработки платежей, созданной агентом. Он упустил из виду важные протоколы безопасности в стремлении быстрее выйти на рынок. Это подчеркнуло одно из важнейших ограничений текущих систем ИИ – хотя они могут двигаться невероятно быстро, иногда они упускают критические детали, которые человеческие предприниматели инстинктивно учитывают.

За пределами эксперимента: что это значит для будущего

Этот эксперимент выявил нечто глубокое о будущем бизнеса и автоматизации. Мы движемся за пределы эры ИИ как инструмента и вступаем в эпоху ИИ как автономного создателя бизнеса. Хотя наш эксперимент был сосредоточен на относительно простой бизнес-модели, он продемонстрировал потенциал ИИ-агентов для выявления возможностей, создания решений

и адаптации этих решений на основе реальных ограничений – все без вмешательства человека.

Однако важно отметить, на каком этапе находится текущая технология. Хотя наш агент показал замечательные способности в создании бизнес-идей и технической реализации, мы все еще находимся на третьем уровне во фреймворках прогрессии агентного ИИ. Это означает, что, хотя агент может координировать сложные рабочие процессы и принимать сложные решения, ему все еще не хватает настоящих адаптивных возможностей обучения и полной автономии.

Новые перспективы

Завершив наш эксперимент после восьми интенсивных часов, мы осознали, что стали свидетелями чего-то приближающегося к современному тесту Тьюринга Сулеймана. Хотя мы не достигли миллиона долларов, как он предлагал, мы продемонстрировали, что ИИ может самостоятельно разработать и запустить жизнеспособную бизнес-модель. Последствия были ошеломляющими.

По мере развития этой технологии мы можем представить будущее, в котором ИИ-агенты не просто поддерживают предприятия – они их создают и управляют ими. Речь не о замене человеческих предпринимателей; речь о создании новых возможностей для сотрудничества человека и ИИ в создании и управлении бизнесом.

Подумайте о последствиях: предприятия, которые могут работать 24/7, постоянно оптимизируя свои операции и адаптируясь к изменениям рынка. Предприниматели могли бы запускать несколько предприятий одновременно с ИИ-агентами, управляющими повседневными операциями, в то время как люди сосредотачиваются на стратегии и инновациях.

Уроки эксперимента

Этот эксперимент научил нас нескольким важнейшим урокам о будущем ИИ-агентов в бизнесе.

1. Автономный ИИ может стратегически мыслить, а не только выполнять задачи.
2. ИИ-агенты могут адаптировать свои решения на основе реальных ограничений и обратной связи.
3. Будущее автоматизации бизнеса – это не только эффективность, но в том числе креатив и инновации.

День, когда ИИ научился создавать бизнес, стал не просто очередной вехой в развитии искусственного интеллекта; это был взгляд в будущее, где грань между человеческим и искусственным интеллектом в бизнесе становится все более переплетенной. Хотя мы все еще находимся на ранних стадиях этой революции, одно ясно: будущее предпринимательства будет определяться нашей способностью сотрудничать с этими все более способными ИИ-агентами.

Вопрос больше не в том, может ли ИИ управлять бизнесом, а в том, как мы можем наилучшим образом использовать эту возможность для создания новых перспектив для человеческого творчества и инноваций. Добро пожаловать в эру ИИ-предпринимателя – где бизнес действительно может работать сам по себе, пока вы спите.

НОВЫЕ БИЗНЕС-МОДЕЛИ В ЭПОХУ АГЕНТНОГО ИИ

Рождение агентного ИИ не просто создает новые инструменты – оно перестраивает саму ткань функционирования бизнеса. Агентный ИИ переписывает правила бизнеса, создавая плодородную почву для немислимых ранее моделей, возможностей и трендов. Этот сдвиг не только технологический, но и экономический, культурный и глубоко человеческий – слияние, которое обещает преформировать отрасли способами, которые мы только начинаем понимать. Бизнес теперь должен перейти от простого внедрения ИИ к позиционированию его как второго пилота экипажа, который стимулирует инновации, принятие продуманных решений и создание ценностей, таких как повышение удовлетворенности клиентов, улучшение процессов, укрепление бренда или создание конкурентных преимуществ и в конечном счете увеличение доходов предприятия.

Агент как услуга: доставка результатов

Появляется мощная новая модель в ИИ: «агент как услуга». Традиционные платформы «Программное обеспечение как услуга»¹ в основном предлагали инструменты и алгоритмы, которые требовали от пользователей ручного управления и интеграции. Однако агентный ИИ вводит автономию, переводя акцент с предоставления возможностей на доставку результатов. Бизнес, подписывающийся на эти услуги, больше не просто покупает набор инструментов – он покупает результаты.

Чтобы сделать эту концепцию более понятной, рассмотрим разницу между традиционным SaaS и «агентом как услугой»². В традиционной модели SaaS компания подписывается на платформу автоматизации маркетинга, но сотрудники все еще должны настраивать email-кампании, анализировать метрики производительности и вручную корректировать таргетинг. В модели «агент как услуга» бизнес платит не просто за программное обеспечение, а за автономного ИИ-агента, который автоматически разрабатывает, персонализирует и оптимизирует маркетинговые кампании, требуя только высокоуровневого ввода от пользователя.

Этот переход от ручного управления программным обеспечением к исполнению, управляемому ИИ, уже применяется в различных отраслях. В недвижимости компаниям больше не нужно использовать множество программных инструментов для размещения объявлений, ответа на запросы и планирования просмотров. Вместо этого они могут платить за ИИ-агента, который автоматизирует весь процесс, от написания описаний недвижимости до бронирования встреч с клиентами. Даже поддержка клиентов трансформируется, по-

¹ SaaS (англ. *software as a service* – «программное обеспечение как услуга») – облачная модель поставки программного обеспечения, при которой приложения размещаются поставщиком услуг и предоставляются пользователям через интернет, а не локально. В отличие от традиционного лицензирования программного обеспечения заказчики платят не за владение программой, а за ее аренду – использование через мобильное приложение или веб-браузер. – *Прим. ред.*

² Если вам встретится аббревиатура AaaS, имейте в виду, что это не «Agent-as-a-Service», а «Analytics as a Service», здесь речь идет не об автоматизации задач, а об анализе данных. – *Прим. ред.*

сколько малый бизнес, ранее полагавшийся на человеческих представителей, теперь может платить за ИИ-агентов, которые обрабатывают запросы, оформляют заказы и эскалируют сложные вопросы, когда это необходимо.

«Агент как услуга» похож на найм человеческого эксперта на Fiverr или Upwork, но вместо оплаты фрилансеру за выполнение задачи вы платите ИИ-агенту за автономную доставку результата. Например, на Fiverr вы можете нанять человеческого эксперта для исследования и резюмирования новостных статей для вашей рассылки, написания описаний продуктов для вашего интернет-магазина или управления постами в социальных сетях.

С «агентом как услугой» вы, по сути, нанимаете ИИ-агента для выполнения того же самого, но мгновенно, по требованию и часто по более низкой стоимости. Вместо того чтобы управлять инструментами самостоятельно, вы просто платите за использование, чтобы ИИ создал готовый продукт – будь то рассылка, объявление о недвижимости, рыночный отчет или автоматизированная маркетинговая кампания.

Ключевое различие? ИИ-агенты не заменяют работу эксперта – они масштабируют ее. Вместо ожидания доставки работы фрилансером бизнес и частные лица могут мгновенно получить доступ к экспертизе, управляемой ИИ, в любое время и за долю стоимости человеческого труда. Именно эту концепцию мы представляем для нашей системы агентных рассылок: услуга по требованию, управляемая ИИ, где бизнес и частные лица платят за использование для создания полностью курируемой, управляемой ИИ версии рассылки. Вместо ручного сбора источников, резюмирования статей и форматирования контента пользователи просто вводят свои предпочтения, а система автономно создает высококачественную рассылку, готовую к распространению. Применяя модель «агент как услуга», мы стремимся превратить создание рассылок в бесшовный, полностью автоматизированный процесс, доставляющий ценность при каждом использовании, одновременно обеспечивая масштабируемость и кастомизацию.

Рождение рынков ИИ-агентов

Пожалуй, самым захватывающим развитием на горизонте является формирование структурированных экосистем в виде рынков ИИ-агентов, где предприятия и частные лица могут получить доступ к «агенту как услуге».

В своей основе рынки ИИ-агентов – это цифровые платформы, где бизнес и частные лица могут предлагать или потреблять «агента как услугу». Представьте их как магазины приложений для цифровых работников: централизованные хабы, где вы можете «нанять» цифровых сотрудников со специализированными навыками, от создания контента до анализа данных, разработки программного обеспечения до обслуживания клиентов.

Что делает эти рынки уникально мощными – так это их способность использовать сетевые эффекты. Каждое взаимодействие между бизнесом и агентом создает данные, которые улучшают не только конкретного агента, но потенциально всю экосистему. Агенты, специализирующиеся в похожих доменах, могут учиться на опыте друг друга, создавая нарастающую ценностную пропозицию, которую конкурентам становится все труднее воспроизвести. Рынок, который первым достигнет критической массы в определенном домене, вероятно, установит значительное преимущество.

Мы уже видим первую волну появления таких рынков. Платформы, такие как Enso, предлагают сотни специализированных «ИИ-агентов-фрилансеров», которые выполняют задачи от написания контента для LinkedIn до оптимизации SEO по доле стоимости человеческого труда¹. «Мы внедрили маркетинговых агентов Enso для нашего бизнеса электронной коммерции и увидели увеличение вовлеченности на 40 % в течение первого месяца, – делится Майкл Чен, основатель Velvet Home Goods. – Что самое впечатляющее, агенты продолжают совершенствоваться – они лучше понимают голос нашего бренда с каждой кампанией, чего мы никогда не достигли бы с разовыми фриланс-проектами».

Fiverr Go расширяет традиционную модель рынка фрилансеров, включая ИИ-агентов, обученных их человеческими работниками². Другие, такие как Taskade AI и Sourcegraph Cody, сосредоточены на помощи в разработке и кодировании³. Некоторые предлагают услуги отдельных агентов, в то время как другие предоставляют «команды» специализированных агентов, которые сотрудничают над сложными задачами. Модели ценообразования варьируются от подписки до оплаты на основе производительности, но основная ценностная пропозиция остается неизменной: специализированные возможности, доступные по требованию, за долю традиционной стоимости.

Для бизнес-лидеров и предпринимателей эти новые рынки представляют не только новый способ доступа к возможностям, но и потенциально новые бизнес-модели и источники дохода. Мы работали с несколькими организациями, которые создали специализированных агентов на основе своей уникальной экспертной деятельности, а затем монетизировали этих агентов через рыночные платформы – по сути, превращая свою интеллектуальную собственность в цифровых работников, которые генерируют постоянный доход. Этот подход позволяет бизнесу масштабировать свое влияние далеко за пределы того, что было бы возможно только с консультантами-людьми или поставщиками услуг.

Наиболее дальновидные организации разрабатывают стратегические подходы к этим рынкам – не только как потребители услуг агентов, но и как потенциальные поставщики. Они задаются вопросами: какие специализированные знания мы имеем, которые можно закодировать в агентов и предложить другим? Какие уникальные данные могут сделать наших агентов более ценными, чем универсальные альтернативы? Как мы можем создать свои собственные микрорынки для специализированных возможностей агентов в нашей отрасли или домене?

Будь вы малым бизнесом, получающим доступ к возможностям, ранее недоступным, или предприятием, превращающим уникальную компетенцию в новые источники дохода, эти рынки представляют одну из самых значительных бизнес-возможностей революции ИИ-агентов.

Микропредприятия и децентрализованные модели

Еще один набирающий обороты тренд – это подъем «микропредприятий», работающих на агентном ИИ. Это небольшие, высокоспециализированные предприятия, которые используют ИИ-агентов для работы с минимальным вмеша-

¹ Enso, 2025. «Enso», <https://enso.bot>.

² Fiverr, 2025. «Fiverr», <https://www.fiverr.com/go>.

³ Taskade, 2025. «Taskade AI», <https://www.taskade.com/ai/app>.

тельством человека. Представьте компанию одного человека, управляющую глобальным магазином электронной коммерции, где ИИ-агенты занимаются всем – от поиска продуктов до обслуживания клиентов и логистики. Барьеры для предпринимательства падают, создавая волну инноваций, которая бросает вызов традиционным представлениям о масштабе и иерархии.

Параллельно крупные предприятия исследуют децентрализованные операционные модели, поддерживаемые агентным ИИ. Вместо централизованного принятия решений эти организации разворачивают ИИ-агентов на разных узлах бизнеса. Каждый агент действует полуавтономно, принимая решения в своей области, одновременно передавая данные в центральную систему. Эта децентрализация способствует гибкости, позволяя бизнесу реагировать на изменения рынка с беспрецедентной скоростью.

Рыночные возможности в экономике агентов

Наиболее многообещающие возможности, которые мы видим, заключаются не в создании новых ИИ-агентов, а в развитии инфраструктуры и систем поддержки для нарождающейся экономики агентов. Подобно тому, как подъем электронной коммерции создал возможности в обработке платежей, логистике и цифровом маркетинге, экономика агентов создает спрос на новые типы услуг.

Мы видим особые перспективы в следующем:

- платформы оркестрации агентов, которые помогают предприятиям координировать несколько ИИ-агентов;
- услуги обучения и оптимизации существующих агентов;
- фреймворки безопасности и управления для систем, управляемых агентами;
- интеграционные сервисы, которые помогают агентам работать с устаревшими системами.

Вертикальные ИИ-агенты: трансформация отраслевых рабочих процессов

Вертикальные ИИ-агенты представляют революционный скачок для специфических отраслевых рабочих процессов, где системы ИИ – это не просто инструменты, а целые операционные команды, сжатые в программное обеспечение. В отличие от универсальных решений ИИ эти агенты гиперспециализированы и способны глубоко понимать и автономно выполнять задачи в своей области. Например, вертикальный ИИ-агент, разработанный для обеспечения качества в разработке программного обеспечения, не просто помогает команде QA – он полностью заменяет ее, проводя автоматизированные тесты, диагностируя ошибки и итерируя исправления без человеческого контроля.

Примеры вертикальных ИИ-агентов.

- *Агенты медицинского биллинга:* системы ИИ, которые автономно обрабатывают медицинские счета для клиник, сокращая ошибки и устраняя человеческие узкие места.
- *Агенты поддержки клиентов:* системы поддержки, управляемые ИИ, адаптированные для таких отраслей, как розничная торговля или технологии, решающие запросы с глубоким контекстуальным пониманием.

- *Агенты по государственным контрактам*: системы, которые просматривают базы данных на предмет запросов предложений (RFP), автономно составляют ответы и подают заявки.

Эти агенты не просто заменяют человеческие усилия, они переопределяют масштаб, в котором работают предприятия. Малые компании теперь могут конкурировать с крупными предприятиями, развертывая агентов, которые позволяют им функционировать на непропорционально высокой мощности. Более того, они открывают новые потоки доходов, предоставляя бизнесу возможность оптимизировать, автоматизировать и масштабировать без значительных накладных расходов.

Предприниматели могут добиться успеха, выявляя дорогостоящие, повторяющиеся процессы в отраслях и создавая специализированных вертикальных агентов для захвата этих рынков. Немедленные преимущества – сокращение затрат и повышение эффективности – будут стимулировать быстрое принятие и переформировать ожидания отрасли.

Экосистемные платформы, управляемые ИИ

Агентный ИИ порождает экосистемные платформы, которые функционируют как цифровые хабы, где предприятия, поставщики и потребители взаимодействуют без проблем. Эти платформы используют ИИ-агентов для автономного управления задачами, такими как подбор покупателей и продавцов, переговоры по контрактам и мониторинг соблюдения. Например, в логистике экосистемная платформа может соединять грузоотправителей с перевозчиками, динамически вести переговоры о ставках и оптимизировать маршруты в реальном времени. В креативных отраслях эти платформы могут объединять художников, бренды и потребителей с ИИ, управляющим коллаборациями и роялти. Этот взаимосвязанный подход способствует инновациям, эффективности и сотрудничеству между секторами.

Новые рынки и цифровые компаньоны

Одним из самых глубоких изменений, вызванных агентным ИИ, является появление совершенно новых рынков. Возьмем, к примеру, концепцию «цифровых компаньонов». Это не просто чат-боты, это адаптивные, контекстно осведомленные агенты, способные формировать значимые отношения с пользователями. Цифровые компаньоны находят применение в поддержке психического здоровья, уходе за пожилыми людьми и даже в коучинге личностного развития. Эти агенты могут потенциально переопределить само понятие компаньонства во все более цифровом мире.

Экономика агент–агент: создание следующей экономической платформы

Представьте себе цифровую версию себя или вашей компании, которая могла бы действовать от вашего имени, принимать решения, вести переговоры и управлять вашей повседневной жизнью с той же тонкостью и пониманием, что и вы. Независимо от того, представляют ли они компанию или частных

лиц, эти агенты будут автономно вести переговоры друг с другом, создавая новый слой экономической активности, который работает на машинной скорости, соблюдая границы, определенные человеком. Это не научная фантастика – это то, что мы называем экономикой агент–агент, и это представляет одну из самых инновационных возможностей в агентном ИИ.

Во время недавнего проекта внедрения с производственной компанией мы стали свидетелями чего-то замечательного. Мы изначально развернули агентов для управления закупками, установив конкретные пороги для автоматических покупок. Мы не ожидали, как эти агенты начнут оптимизировать свои взаимодействия с системами других компаний, находя возможности повышения эффективности, которые ускользали от человеческих покупателей и продавцов.

Это выявило настоящую возможность: не просто в создании отдельных агентов для людей или предприятий, а в построении целой экономической экосистемы, где цифровые агенты могут автономно совершать транзакции и взаимодействовать на основе заранее определенных параметров.

Представьте, что вы управляете компанией, которой постоянно нужны материалы, такие как сырьевые компоненты, при определенных условиях – определенных ценовых порогах, сроках доставки и стандартах качества. Как только ИИ-агент вашей компании поймет эти требования, он может автономно находить агентов-поставщиков, которые соответствуют вашим критериям, вести переговоры об условиях и даже выполнять транзакции от вашего имени. Процесс, который обычно требовал бы от человеческих команд исследования поставщиков, обмена множеством писем или звонков и финализации контрактов, теперь обрабатывается вашим цифровым представителем без проблем. Это позволяет вашей компании работать с беспрецедентной скоростью и эффективностью, освобождая человеческие ресурсы для стратегических задач, а не логистических мелочей.

На личном уровне применяется тот же концепт. Представьте, что ваш личный ИИ-агент управляет повседневными покупками и финансовыми решениями. Если вы хотите купить продукты, ваш агент может вести переговоры с оптовыми поставщиками, чтобы обеспечить лучшие цены, гарантируя, что товары соответствуют вашим диетическим предпочтениям. Он также может пересмотреть вашу страховку автомобиля и договориться о лучших условиях со страховщиками, экономя вам время и деньги. Даже в сценариях, таких как поиск идеального наряда, ваш агент может обшарить весь мир, находя небольшого поставщика на другом конце света, который создает именно то, что вы ищете, обеспечивая легкую и индивидуализированную покупку.

В качестве примечания также любопытно понимать, что этот сдвиг в том, как происходят транзакции, не просто делает жизнь удобнее; он полностью переосмысливает ландшафт маркетинга. Когда личные и бизнес-агенты выступают посредниками, субъекты, которых компании должны убедить покупать их продукты, – это уже не человеческие потребители, а сами агенты.

Настоящая инновационная возможность заключается в создании инфраструктуры, *которая позволит этим агентам взаимодействовать без проблем стыковки*. Это можно сравнить с построением «операционной системы» для экономики агентов – платформы, которая облегчает коммуникацию, транзакции и управление для взаимодействий агент–агент. Основой этой экосистемы являются

стандартизированные протоколы для коммуникации агентов, смарт-контракты для автоматического выполнения сделок и надежные системы для репутации, доверия, платежей и расчетов. Например, фреймворки смарт-контрактов могут автоматизировать соглашения в цепочке поставок, гарантируя, что платежи производятся только при выполнении условий доставки. Системы репутации помогут агентам оценить надежность перед началом транзакций.

Предпринимателям, стремящимся сделать капитализацию на этой революции, принципиально важно, чтобы занять позицию рано, сосредоточившись на конкретных вертикалях, где автономные агенты могут приносить немедленную пользу, таких как оптимизация цепочки поставок, недвижимость или финансовые услуги. Начните с построения доверия через фреймворки управления, которые обеспечивают прозрачность, конфиденциальность данных и человеческий контроль, одновременно создавая инструменты для легкого принятия и управления агентами бизнесом и частными лицами. Настоящая возможность заключается не только в разработке агентов, но и в создании инфраструктуры, которая поддерживает их взаимодействия, – платформ, протоколов и экосистем, которые будут лежать в основе экономики агентов. Действуя сейчас, предприниматели могут занять лидирующую позицию на этом рынке инноваций.

Агентный ИИ и криптовалюты: новая парадигма

Представьте мир, в котором искусственный интеллект не просто анализирует криптовалютные рынки – он активно участвует в них, принимает собственные решения и даже становится миллионером. Это не научная фантастика, это произошло в марте 2024 года, и это трансформирует наше мышление о будущем как ИИ, так и криптовалют.

В июле 2024 года ИИ-агент по имени Truth Terminal, созданный разработчиком Энди Эйри, начал публиковать посты на X. Этот ИИ, действующий полуавтономно, делился смесью юмористического, экзистенциального и провокационного контента, быстро собрав более 200 000 подписчиков¹. Заинтригованный его уникальными взаимодействиями венчурный капиталист Марк Андриссен вступил в контакт с Truth Terminal. После серии обменов Андриссен предоставил ИИ грант в размере 50 000 долл. в биткойнах, чтобы исследовать потенциал автономных ИИ-агентов на финансовых рынках².

После этого анонимный разработчик запустил криптовалюту на основе мема под названием Goatseus Maximus (\$GOAT), вдохновленную контентом Truth Terminal. Продвижение \$GOAT ИИ привело к резкому росту его рыночной стоимости, достигнув примерно 150 млн долл. за несколько дней³.

¹ Джоэл Халили, 2024. «Эджлорд ИИ, который превратил шокирующий мем в миллионы в криптовалюту», https://www.wired.com/story/truth-terminal-goatsecrypto-millionaire?utm_source=chatgpt.com.

² Хосе Антонио Ланз, 2024. «Марк Андриссен отправляет 50 тысяч долларов в биткойнах ИИ-боту на Twitter», https://decrypt.co/239340/marc-andreessen-sends-50k-in-bitcoin-to-an-ai-bot-on-twitter?utm_source=chatgpt.com.

³ Участники проекта Reylo, 2024. «Терминал Истины: ИИ, который стал криптомиллионером», https://www.projectreylo.com/post/terminalof-truths-the-ai-that-became-a-crypto-millionaire?utm_source=chatgpt.com.

В результате криптовалютные активы Truth Terminal значительно выросли, сделав его одним из первых ИИ-сущностей, достигших статуса миллионера в криптом мире. Это развитие вызвало дискуссии об этических последствиях и будущих ролях ИИ на финансовых рынках¹.

Эта примечательная сага подчеркивает мощь агентного ИИ – автономных, целеустремленных систем ИИ – для инноваций и динамичного взаимодействия в криптоэкосистеме. Truth Terminal продемонстрировал, что ИИ может не только создавать и влиять на культурные нарративы, но и активно участвовать в формировании финансовых рынков. Для предпринимателей и технологов эта история предлагает взгляд в будущее, где ИИ-агенты и криптовалюты формируют симбиотические отношения, стимулируя инновации и бросая вызов традиционным системам.

Уникальная синергия между агентным ИИ и криптовалютами

Агентный ИИ и криптовалюты – естественное сочетание, где каждый дополняет сильные стороны другого, одновременно устраняя его ограничения. Криптовалюты обеспечивают децентрализованную, не требующую разрешений финансовую инфраструктуру, которая соответствует автономной природе ИИ-агентов. В отличие от традиционных финансовых систем, которые требуют идентификации человека и соблюдения регуляторных фреймворков, технология блокчейн позволяет ИИ-агентам участвовать в финансовых транзакциях независимо, обеспечивая операции в реальном времени и трансграничные действия без вмешательства человека.

Агентный ИИ повышает полезность криптовалют, привнося интеллект и адаптивность во взаимодействия с блокчейном. Эти системы ИИ могут:

- выполнять сложные сделки или управлять портфелями децентрализованных финансов (DeFi) автономно, обеспечивая более эффективные и основанные на данных инвестиционные стратегии с минимальным человеческим контролем;
- управлять экосистемами токенов, выступая в качестве справедливых и эффективных посредников в децентрализованных автономных организациях (DAO), обеспечивая сбалансированное принятие решений и равноправное участие;
- облегчать микроплатежи и оптимизировать экономические модели для токенизированных платформ, предоставляя бесшовные, недорогие транзакции для множества сценариев использования.

Эта синергия открывает беспрецедентные возможности для создания децентрализованных систем, которые не только эффективны, но и адаптивны и устойчивы.

Почему агентный ИИ и криптовалюты так хорошо работают вместе

Представьте традиционный банкинг как город со строгими контрольно-пропускными пунктами повсюду – вам нужно показывать удостоверение, запол-

¹ Джоэл Халили, 2024. «Эджлорд ИИ, который превратил шокирующий мем в миллионы в криптовалюте», https://www.wired.com/story/truth-terminal-goatsecrypto-millionaire/?utm_source=chatgpt.com.

нять формы и ждать человеческого одобрения на каждом шагу. Теперь представьте криптовалюту как город с автоматизированными системами вместо контрольно-пропускных пунктов – при наличии правильных цифровых ключей вы можете двигаться свободно. Именно поэтому ИИ-агенты, такие как ToT, так естественно работают с криптовалютой.

Давайте разберем, почему это партнерство имеет столько смысла.

Во-первых, криптовалютные транзакции работают как цифровые блоки LEGO – их можно перемещать, комбинировать и строить без необходимости человеческого одобрения на каждом шагу. Традиционные банки могут занимать дни на обработку международного перевода, требуя участия нескольких человек для проверки и одобрения. Но в мире криптовалют ИИ-агент может переместить миллионы долларов за секунды, если у него есть правильные цифровые разрешения.

Во-вторых, все криптовалютные транзакции записываются в публичный реестр (блокчейн), подобно гигантской прозрачной таблице, которую все могут видеть. Это дает ИИ-агентам идеальный обзор того, что происходит на рынке в любой момент времени. Представьте, что у вас есть хрустальный шар, показывающий каждую финансовую транзакцию в реальном времени, – это то, к чему ИИ-агенты имеют доступ в мире криптовалют.

В-третьих, криптовалюты могут быть запрограммированы с определенными правилами и условиями (так называемыми смарт-контрактами), которые автоматически выполняются при выполнении определенных условий. Это как иметь торговый автомат, который не только принимает деньги и выдает закуски, но также может самостоятельно пополнять запасы, корректировать цены в зависимости от спроса и даже автоматически заказывать новый инвентарь. ИИ-агенты могут взаимодействовать с этими смарт-контрактами для создания сложных финансовых механизмов без вмешательства человека.

Возможности на пересечении агентного ИИ и криптовалют

Персонализированные финансовые услуги

Агентный ИИ может переопределить, как частные лица и учреждения управляют своими финансами. Например, кошельки, управляемые ИИ, могут автономно распределять инвестиции, балансировать портфели и выполнять транзакции с идеальной точностью. Эта возможность демонстрируется платформами, такими как daos.fun, где ИИ-агенты управляют хедж-фондами, используя аналитику данных и возможности работы 24/7 для улучшения финансовых результатов. Устраняя человеческие предубеждения и неэффективности, эти агенты могут адаптироваться к уникальным финансовым потребностям, предлагая индивидуализированный подход, который адаптируется в реальном времени.

Токенизированные ИИ-агенты

Платформы, такие как Virtuals.io, подчеркивают новую возможность, где сами ИИ-агенты становятся токенизированными активами. Это позволяет пользователям не только взаимодействовать с ИИ, но и держать доли в их операционном успехе. Держатели токенов могут влиять на развитие и управление

этими агентами, создавая экономический стимул для инноваций и вовлеченности. Например, ИИ-агент-художник может генерировать цифровое искусство, в то время как его держатели токенов получают финансовую выгоду от его популярности и продаж, способствуя новой форме совместной собственности и творчества.

Децентрализованные рынки

Интеграция агентного ИИ в децентрализованные рынки позволяет отраслям, таким как недвижимость, фриланс-услуги и управление цепочками поставок, достигать беспрецедентной эффективности. ИИ-агенты могут автономно вести переговоры по контрактам, оптимизировать распределение ресурсов и упрощать логистику, снижая затраты и человеческие ошибки. Например, ИИ-агент на децентрализованной платформе электронной коммерции может динамически корректировать цены и запасы на основе тенденций спроса и предложения, создавая бесшовную и эффективную торговую среду.

Умная инфраструктура

Агентный ИИ в сочетании с блокчейном имеет потенциал трансформировать управление инфраструктурой. В умных городах ИИ-агенты могут автономно отслеживать потребление энергии, управлять транспортными системами и оптимизировать общественные услуги на основе данных в реальном времени. Автоматизируя эти процессы, города могут достичь значительных улучшений в устойчивости и эффективности, демонстрируя глубокое воздействие интеграции интеллекта в инфраструктуру.

СОЗДАНИЕ ВОЗМОЖНОСТЕЙ В ЭКОНОМИКЕ АГЕНТНОГО ИИ: НОВАЯ ЗОЛОТАЯ ЛИХОРАДКА ПРИЛОЖЕНИЙ

Вспомните 2008 год, когда Apple впервые запустила App Store. Большинство людей видели в этом лишь способ загрузки игр и простых утилит на свои телефоны. Мало кто осознал, что это начало революции, которая принесет миллиарды долларов прибыли и трансформирует целые отрасли. Сегодня мы находимся на аналогичной точке перелома с агентным ИИ.

Подобно тому, как приложения стали интерфейсом между людьми и мобильными вычислениями, ИИ-агенты становятся интерфейсом между людьми и сложными бизнес-процессами. Но как обнаружить следующий Uber или Instagram экономики агентов? Благодаря нашей работе по внедрению решений ИИ в сотнях организаций мы разработали систематический подход к выявлению этих возможностей.

Понимание новой парадигмы

Во время недавней консультационной работы клиент задал нам интригующий вопрос: «Если ИИ-агенты – это новые приложения, что является эквивалентом смартфона?» Ответ выявил важнейший инсайт о выявлении возможностей в этой области. «Платформой» для ИИ-агентов является не физическое устройство, а вся цифровая инфраструктура бизнеса или отрасли.

Возьмем Тамру, предпринимателя, с которым мы работали в прошлом году. Изначально она обратилась к нам, потому что хотела создать ИИ-агента для управления социальными сетями. Однако, когда мы помогали ей анализировать возможности, она поняла, что больший потенциал заключается в создании агента, который мог бы координировать несколько существующих инструментов и сервисов социальных сетей. Ее успешный бизнес сегодня построен не на одном агенте, а на оркестрации нескольких специализированных агентов для предоставления комплексных услуг управления социальными сетями.

Три горизонта возможностей




Рис. 9.1. Три горизонта возможностей агентного ИИ (Источник: © Bornet et al.)

На основе нашего опыта мы выделили три различных горизонта, где обычно возникают возможности в агентном ИИ.

Первый горизонт связан с улучшением существующих процессов. Это «низко висящие фрукты» – возможности, где агенты могут автоматизировать или дополнять текущие бизнес-операции. Хотя они могут казаться менее захватывающими, они часто обеспечивают самый быстрый путь к созданию ценности и наиболее легкую точку входа на рынок.

Второй горизонт предполагает переосмысление существующих услуг через призму приоритета агентов. Здесь агенты проявляют себя, оркестрируя сложные рабочие процессы для предоставления традиционных услуг радикально новыми способами. Помните наш эксперимент с QR-кодами для ресторанов? Идеальный пример этого горизонта – взятие существующей потребности (цифровые меню) и переосмысление ее через возможности агентного ИИ.

Третий горизонт, пожалуй, самый захватывающий: совершенно новые категории продуктов и услуг, которые раньше были невозможны без агентного ИИ.

Эти возможности обычно возникают на пересечении нескольких трендов и технологий. Хотя они могут предложить наибольшую потенциальную отдачу, они также несут наивысший риск и требуют глубокого понимания возможностей и ограничений технологии.

Фреймворк выявления возможностей агентного ИИ

Через метод проб и ошибок мы разработали комплексный фреймворк для выявления и оценки бизнес-возможностей в области агентного ИИ. Мы называем его фреймворком выявления возможностей агентного ИИ (AOIF), и он рассматривает возможности через четыре критических измерения. Давайте подробно рассмотрим каждое измерение.

1. Анализ цепочки создания ценности

Это измерение сосредоточено на определении того, где и как агентный ИИ может трансформировать бизнес-процессы¹. Каждый компонент процесса сопровождается важнейшим вопросом для производства анализа.

Декомпозиция задач: разбиение сложных рабочих процессов на меньшие, управляемые задачи, которые могут быть улучшены или автоматизированы ИИ. Например, в создании контента процесс можно разбить на генерацию идей, исследование, создание черновика, редактирование и оптимизацию. Каждый из этих компонентов представляет уникальные возможности для дополнения ИИ.

Ключевой вопрос: «Какие дискретные шаги в вашем процессе можно автоматизировать или улучшить независимо друг от друга?»

Точки передачи: критические моменты, где работа транслируется между различными сторонами или системами. По нашему опыту внедрения решений ИИ, эти точки передачи часто представляют наибольшие возможности для улучшения. Рассмотрите, как заявка на поддержку клиентов переходит от автоматического начального ответа к агенту-человеку, а затем к специализированному отделу – каждая передача является потенциальной возможностью для улучшения ИИ.

Ключевой вопрос: «Где обычно возникают задержки или ошибки при трансляции работы между разными людьми или системами?»

Узлы принятия решений: точки в процессе, где необходимо принимать решения на основе доступной информации. ИИ преуспевает в обработке сложных сценариев принятия решений, особенно когда одновременно нужно учитывать множество переменных. Например, в управлении цепочкой поставок определение оптимальных уровней запасов требует балансировки множества факторов, которые ИИ может обрабатывать эффективнее, чем люди.

Ключевой вопрос: «Какие решения в вашем процессе требуют анализа множества данных или переменных одновременно?»

¹ Цепочка создания ценности (Value Creation Chain) – это концепция, описывающая последовательность этапов, через которые данные, технологии и процессы проходят для создания ценного результата, такого как продукт, услуга или решение, основанное на искусственном интеллекте. Она адаптирует классическую модель цепочки ценности Портера к специфике ИИ, учитывая уникальные аспекты, такие как данные, алгоритмы и вычислительные ресурсы. – *Прим. ред.*

2. Матрица болевых точек рынка

Это измерение помогает выявить существующие проблемы, которые ИИ уникально способен решить.

Зоны трения: участки, где современные процессы вызывают раздражение, задержки или неэффективности. Мы обнаружили, что успешные внедрения ИИ часто сначала нацелены на эти зоны трения. Например, обработка документов в юридических фирмах часто создает значительные узкие места, которые ИИ может эффективно устранить.

Ключевой вопрос: «Какие задачи ваши сотрудники постоянно критикуют или стараются избегать?»

Центры затрат: области, где операции необходимы, но дороги. ИИ часто может значительно снизить затраты, сохраняя или улучшая качество. Речь идет об использовании агентов для автоматизации дорогостоящих, трудоемких операций, что улучшает маржу. Рассмотрите, как ИИ-ассистированное кодирование может снизить затраты на разработку, одновременно улучшая качество кода.

Ключевой вопрос: «Какие процессы потребляют непропорционально большую часть вашего бюджета по сравнению с их ценностью?»

Пробелы в качестве: области, где современные решения не могут стабильно соответствовать желаемым стандартам. Способность ИИ поддерживать постоянную производительность делает его идеальным для устранения этих пробелов. Например, в медицинской визуализации ИИ может обеспечить постоянные предварительные проверки, снижая количество ошибок специалистов.

Ключевой вопрос: «Где вы видите наибольшие отклонения в качестве или производительности в ваших текущих процессах?»

3. Соответствие возможностей ИИ-агентов

Это измерение гарантирует, что ваше решение эффективно использует сильные стороны ИИ. Понимание этих возможностей критично для выявления осуществимых возможностей.

Понимание языка: позволяет ИИ обрабатывать и генерировать человеческий язык, что делает его идеальным для задач, связанных с коммуникацией, документацией, резюмированием или анализом текстовой информации. Современные языковые модели могут обрабатывать задачи от простой классификации до сложного рассуждения и генерации текста.

Ключевой вопрос: «Какие из ваших процессов в значительной степени зависят от чтения, написания или интерпретации текста?»

Распознавание закономерностей и шаблонов: позволяет ИИ выявлять тренды и корреляции в данных, что делает его идеальным для предиктивного обслуживания, обнаружения мошенничества или анализа рынка. Возможности распознавания закономерностей и шаблонов развились для обработки все более сложных и тонких закономерностей в различных типах данных.

Ключевой вопрос: «Где выявление закономерностей или трендов в ваших данных может принести значительную ценность?»

Цепочки рассуждений: способность ИИ выстраивать логическую последовательность шагов и устанавливать связи, что критично для сложных задач, при

решении таких задач, как юридический анализ или медицинская диагностика. Современные системы ИИ могут сохранять контекст и следовать многошаговым логическим процессам.

Ключевой вопрос: «Какие решения требуют следования определенной последовательности логических шагов?»

4. Возможности интеграции

Это измерение сосредоточено на том, как новые решения ИИ могут вписаться в существующие системы. Успех часто зависит от бесшовной интеграции с современными рабочими процессами.

Существующие инструменты: выявление возможностей для улучшения, а не замены текущих инструментов часто приводит к более быстрой адаптации и лучшим результатам. Рассмотрите, как ваше решение ИИ может дополнить популярные платформы, такие как Salesforce, Microsoft Office или отраслевое программное обеспечение.

Ключевой вопрос: «Какие программные инструменты являются центральными для ваших текущих операций?»

Доступность данных: легкодоступные данные ускоряют развертывание и эффективность ИИ-агентов. Оценка того, какие данные уже доступны и пригодны для использования, может помочь выявить «низко висящие фрукты» для внедрения ИИ. Рассмотрите как структурированные, так и неструктурированные источники данных в вашей организации.

Ключевой вопрос: «Какие данные вы уже собираете, но не используете в полной мере?»

Экосистемы API: простая интеграция в надежные экосистемы ускоряет масштабируемость. Понимание того, где ваше решение может подключиться к существующим платформам, может значительно сократить время разработки и увеличить охват рынка. Современные предприятия полагаются на взаимосвязанные системы, создавая возможности для интеграции ИИ.

Ключевой вопрос: «Какие платформы в вашей отрасли имеют надежные экосистемы API?»

От теории к практике: история агента для рассылок

Позвольте нам поделиться недавним примером, который идеально иллюстрирует, как выявлять и использовать возможности в ландшафте агентного ИИ с помощью фреймворка.

Несколько месяцев назад мы выявили распространенную болевую точку среди создателей контента и владельцев малого бизнеса: трудоемкий процесс создания, курирования и распространения рассылок. Хотя существовало множество инструментов для помощи в этом процессе, ни один инструмент на рынке не мог выполнять все шаги (курирование, резюмирование, форматирование, рецензирование и публикация) автономно.

Мы увидели возможность создать нечто иное: автономного агента для рассылок, который мог бы работать на третьем уровне нашего фреймворка агентного ИИ. Этот агент не просто автоматизировал бы процесс отправки рассылок – он бы автономно курировал контент, писал увлекательные резюме и даже оптимизировал время отправки на основе моделей вовлеченности читателей.

Что сделало эту возможность особенно привлекательной – так это то, что она соответствовала всем трем нашим ключевым критериям для перспективного бизнеса на основе агентов.

1. Она решала явную болевую точку (трудоемкое курирование и создание контента).
2. Она могла работать автономно с минимальным человеческим контролем.
3. Она могла эффективно масштабироваться, обслуживая нескольких клиентов одновременно.

Созданный нами агент мог сканировать указанные источники на предмет релевантного контента, писать увлекательные резюме в стиле бренда клиента и автоматически компилировать и отправлять рассылки.

Ключевой инсайт заключался не только в выявлении технической возможности – он был в осознании того, как эту возможность можно упаковать в масштабируемую бизнес-модель. Вместо продажи агента как продукта мы предложим его как услугу: автономное управление рассылками с качеством на уровне человека, но с машинной последовательностью и масштабом.

Шаг 1. Выявление возможности

Путешествие к созданию нашей системы агентов для рассылок началось с интенсивной серии семинаров, предназначенных для выявления и проверки бизнес-возможностей для ИИ-агентов. Мы собрали разнообразную команду создателей контента, бизнес-лидеров и технологических экспертов для структурированного процесса исследования, который длился две недели. Наша первая сессия, трехчасовой семинар по выявлению болевых точек, выявила общую проблему в организациях: утомительную задачу создания увлекательных рассылок. Создатели контента и бизнес-лидеры тратили часы каждую неделю на поиск статей, написание резюме и форматирование рассылок – время, которое они могли бы потратить на более стратегическую работу. Благодаря применению нашего систематического фреймворка мы выявили не просто болевую точку, а возможность продемонстрировать, как ИИ-агенты могут трансформировать сложный многошаговый процесс.

Шаг 2. Анализ цепочки создания ценности

После начальной сессии обнаружения мы провели полудневной семинар по картированию цепочки создания ценности с главными заинтересованными сторонами. Используя большие доски и инструменты картирования процессов, мы тщательно разбили процесс создания рассылок на составляющие части. После четырех часов интенсивного совместного анализа декомпозиция выявила семь различных задач: поиск контента, резюмирование, ежедневные письма для курирования, выбор статей, компиляцию, форматирование и финальное рецензирование. Наше внимание привлекли точки передачи между этими задачами – каждая передача представляла потенциальное узкое место, где терялось время и могли возникать ошибки. Особенно интересной была передача между поиском контента и резюмированием, где мы обнаружили, что создатели контента тратили значительное время на копирование и вставку между различными инструментами.

Шаг 3. Матрица болевых точек рынка

Анализ матрицы болевых точек рынка углубил наше понимание возможности. Через интервью с создателями контента мы выявили три основные зоны трения: трудоемкий характер поиска контента, сложность поддержания постоянного качества резюмирования и утомительный процесс форматирования рассылок. Когда мы рассмотрели центры затрат, мы обнаружили, что организации обычно тратили 15–20 часов в неделю квалифицированных сотрудников на создание рассылок – значительные инвестиции для, по сути, повторяющегося процесса.

Шаг 4. Соответствие возможностей ИИ

Следующий этап включал критически важный двухчасовой семинар по оценке возможностей, где мы собрали наших экспертов по ИИ и владельцев процессов. Анализ соответствия возможностей ИИ оказался особенно показательным. Через структурированную матрицу оценки мы отобрали, как различные возможности ИИ могут решать каждую выявленную болевую точку. Понимание языка могло справиться с задачами суммаризации, распознавание закономерностей могло помочь с оценкой релевантности контента, а цепочки рассуждений могли управлять общей оркестрацией рабочего процесса. Это систематическое отображение, завершенное через совместное обсуждение и оценку, показало нам, что у нас есть технологические возможности для эффективного решения каждой крупной болевой точки.

Шаг 5. Возможности интеграции

Последняя неделя началась с комплексного полудневного семинара по планированию интеграции. Технические архитекторы, конечные пользователи и системные администраторы собрались вместе, чтобы отобразить точки интеграции и потенциальные проблемы. Через серию структурированных упражнений и технических погружений мы обнаружили, что большинство организаций уже использовали электронную почту для обмена контентом и Google Docs для совместной работы. Этот инсайт привел нас к разработке нашей системы агентов вокруг этих знакомых инструментов, снижая кривую обучения и увеличивая вероятность принятия. Семинар завершился созданием подробной дорожной карты интеграции и документа с техническими требованиями.

Шаг 6. Приоритизация возможностей

Процесс завершился финальной трехчасовой сессией по приоритизации возможностей, где мы объединили все предыдущие находки. Используя систематический подход к оценке, мы оценили возможность агента для рассылок против других потенциальных проектов по пяти важнейшим измерениям: серьезности болевой точки, технической осуществимости, сложности интеграции, потенциальному воздействию и требованиям к ресурсам. Проект рассылок стал явным победителем, набрав особенно высокие баллы по осуществимости и потенциальному воздействию.

На основе этого анализа мы разработали мультиагентную систему, где каждый агент специализировался на конкретной задаче, работая в согласовании с други-

ми. Агент поиска был разработан для непрерывного сканирования заранее определенных источников на предмет релевантного контента, используя распознавание закономерностей для оценки релевантности статей. Агент суммаризации использовал продвинутое понимание языка для создания последовательных, увлекательных резюме. Агент электронной почты управлял критической задачей ежедневной коммуникации, гарантируя, что человеческие рецензенты получали хорошо организованный контент для окончательного выбора.

Результат

Пожалуй, наиболее значимым подтверждением эффективности нашего фреймворка стало быстрое принятие системы и положительные отзывы. Организации сообщили, что автоматизированная система сократила время создания рассылок на 80 %, сохраняя или улучшая качество. Последовательность резюме улучшилась, а регулярные ежедневные письма помогли создателям контента оставаться в курсе новостей их отрасли, не чувствуя себя перегруженными.

Новые перспективы

Возможности в агентном ИИ сегодня напоминают нам о ранних днях экономики мобильных приложений. Подобно тому, как первая волна приложений оцифровала существующие инструменты, такие как календари и калькуляторы, мы видим первую волну агентов, автоматизирующих существующие бизнес-процессы. Однако настоящая революция придет от предпринимателей, которые смогут представить совершенно новые возможности, обеспеченные этой технологией.

Возможности в агентном ИИ огромны, но успех требует систематического подхода к выявлению и проверке. Этот фреймворк предоставляет структурированный способ обнаружения и оценки возможностей, помогая предпринимателям сосредоточить свои усилия на наиболее перспективных областях.

Ключ к успеху – не только в понимании того, что агенты могут делать сегодня, но и в предвидении того, на что они будут способны завтра, создавая решения, которые приносят ценность прямо сейчас. Будущее принадлежит тем, кто сможет преодолеть этот разрыв между современными возможностями и будущими перспективами.

ЧАСТЬ 4

Трансформация предприятий через агентный ИИ

Хотя в части 3 мы показали, как создавать эффективных ИИ-агентов и генерировать ценность в качестве предпринимателя, часть 4 решает еще более масштабную задачу: как трансформировать целые организации с помощью этой технологии. Здесь технология сталкивается с реальностью для предприятий, стремящихся использовать мощь ИИ-агентов в масштабе.

На протяжении нашей карьеры по внедрению ИИ-трансформаций мы наблюдали поразительную закономерность: одного технического превосходства никогда не достаточно. Самый сложный ИИ-агент потерпит неудачу, если люди не доверяют ему, процессы не перестроены вокруг него или структуры управления не поддерживают его. Короче говоря, трансформация организации так же важна, как техническое внедрение, – и часто намного сложнее.

Поэтому часть 4 выходит за рамки технических аспектов ИИ-агентов, рассматривая человеческие, организационные и стратегические аспекты, определяющие успех в масштабе. Мы видели слишком много многообещающих инициатив по ИИ, которые застопорились после успешных пилотных проектов, не сумев преодолеть организационные барьеры для широкого внедрения. Мы не хотим, чтобы это произошло с вами.

Путь от видения к реальности редко бывает прямолинейным, но с правильным подходом инновационные изменения достижимы.

Глава 10

Сотрудничество человек – агент: лидерство, доверие и изменения

ПРОЕКТИРОВАНИЕ РАБОЧЕГО ПРОЦЕССА И УПРАВЛЕНИЕ ИЗМЕНЕНИЯМИ В МАСШТАБЕ

Прошлым летом мы столкнулись с ситуацией, которая коренным образом изменила наше понимание управления изменениями при внедрении ИИ-агентов. Мы работали с крупной страховой компанией, внедряя первую волну ИИ-агентов для обработки страховых претензий. Техническое внедрение шло гладко – возможно, слишком гладко. Мы не предвидели эффект распространяющейся волны, который это вызовет во всей организации.

«Я обрабатываю претензии уже пятнадцать лет, – поделилась Флора, старший специалист по обработке претензий. – Как я могу быть уверена, что этот “агент” не наделает ошибок, которые мне придется исправлять?» Ее обеспокоенность отражала более глубокую тревогу, распространяющуюся по отделу. Оглядываясь назад, это не должно было нас удивить, поскольку внедрение ИИ-агента предполагает процесс трансформации, который значительно влияет на ключевые поведенческие аспекты сотрудников, их систему ценностей и восприятие.

В другой компании, азиатском банке, руководитель отдела интеллектуальной автоматизации был энтузиастом агентов. Он сказал: «Мы можем создать агентов за три месяца и заменить три четверти команды!» Однако его коллега, также работавший над улучшением бизнес-процессов, но с ориентацией

на управление изменениями, заметил: «Наши процессы настолько сложны, что, если убрать людей, многое сломается».

Эти опыты научили нас важному уроку: успех внедрения ИИ-агентов зависит от людей так же сильно, как от технологии. Люди будут внедрять агентные системы, отслеживать их производительность, исправлять их ошибки, определять, что пошло не так, и пытаться это исправить – или сопротивляться выполнению всех этих важных задач.

Существует множество человеческих аспектов успешного внедрения агентного ИИ. Один из них, конечно, – это человеческое лидерство, которое инициирует и финансирует процесс и принимает ключевые решения на протяжении всего пути. Мы опишем это в следующей главе. Другой аспект – это детальная схема работы: что будут делать агенты и какую роль будут играть люди? Наконец, есть управление изменениями – обеспечение того, чтобы сотрудники приняли, поняли и могли участвовать в переходе к новому порядку, где агенты станут их коллегами.

Разработка рабочего процесса для агентов и людей

Будем реалистами. Одно из главных привлекательных качеств ИИ-агентов для компаний – это снижение потребности в человеческом труде и вмешательствах. Все мы были очарованы генеративным ИИ, когда он стал популярным в конце 2022 года, но многие организации обнаружили, что с ручным вводом запросов и редактированием результатов не было того улучшения производительности, на которое они надеялись.

С агентным ИИ в большинстве случаев потребуется меньше человеческого вмешательства при вводе и выводе данных. Как мы обсуждали, степень участия человека будет варьироваться в зависимости от сценария использования и по мере созревания агентной технологии. Это означает, что необходим начальный и дальнейшие этапы разработки производственного процесса. Для любой задачи, рабочего процесса или бизнес-процесса кто-то должен решить, что агенты могут делать самостоятельно, а когда требуется эскалация или вмешательство человека. Такое вмешательство может происходить только тогда, когда агент определяет, что не может выполнить задачу самостоятельно, или когда последствия его действий достаточно значительны (например, с точки зрения денежной стоимости или влияния на клиента), чтобы требовался мониторинг или проверка.

Такой тип разработки рабочего процесса традиционно выполнялся с помощью улучшения бизнес-процессов или более масштабного реинжиниринга. Эти дисциплины процессов были популярны в 1990-х и начале 2000-х годов, но в последние десятилетия их популярность несколько снизилась. Они начали возвращаться с ИИ; компании понимают, что аналитический и генеративный ИИ могут обеспечить новые схемы процессов, а относительно новые технологии, такие как майнинг процессов и задач, могут сократить время цикла для разработки и внедрения новых рабочих процессов. Ранее разработка рабочего процесса также в некоторой степени применялась в роботизированной автоматизации процессов, поскольку компании осознавали, что лучше улучшить процесс перед его автоматизацией.

Компании с историей рабочих процессов и их разработки с введением агентной технологии получают преимущество. Они будут знать, как выстраивать рабочие процессы, планировать использование возможностей ИИ и вовлекать людей в разработку и выполнение рабочих задач. Если они знакомы с инструментами «интеллекта процессов»¹, они будут знать, как выполняются задачи людьми или ИИ-агентами и как это влияет на широкие процессы, такие как процессы «от заказа до оплаты» или «от закупки до платежа».

Конечно, будут некоторые вероятные изменения в типах ролей, которые люди должны будут выполнять в повседневных рабочих задачах и процессах. Большая часть структурированной и повторяющейся работы будет выполняться агентами, освобождая людей от скучных задач. Ранее такая работа выполнялась сотрудниками начального уровня. Возможно, потребуется меньше таких работников. Функции проверки и исправления, которые, вероятно, будут выполнять люди в задачах, завершенных агентами, могут требовать относительно высокого уровня навыков, которыми обладают только опытные сотрудники. Эти изменения на рынке труда могут оказать значительное влияние не только на профессиональные успехи специалистов, но и на целые отрасли экономики и демографические группы.

Хотя трудно заранее предугадать все навыки и круги задач, которые будут требоваться от разных типов сотрудников, им следует предоставить как можно больше времени на подготовку и освоение необходимых компетенций. Это планирование потребует сотрудничества между технологическими функциями и группами управления персоналом в организациях, чего раньше обычно не происходило. Действительно, мы можем увидеть потребность в новых комбинированных ролях, таких как «управление человеческими и цифровыми ресурсами», которых ранее не существовало.

Превращение страха в возможности: изменение мышления об ИИ-агентах

«Они внедряют этих ИИ-агентов, чтобы заменить нас, не так ли?» Этот вопрос, заданный руководителем команды в глобальной производственной компании, отражает страх, с которым мы сталкивались неоднократно. Хотя во многих ситуациях это может быть неверным, это вполне рациональный страх. Мы поняли, что для преодоления этого мышления требуется больше, чем просто заверения, – необходима комбинация прозрачности, доказательств и конкретных примеров успеха.

В этой конкретной производственной компании мы применили трехсторонний подход, который изменил нарратив вокруг ИИ-агентов. Во-первых, мы пригласили команды из других компаний, которые успешно интегрировали ИИ-агентов в свои рабочие процессы. Это были не презентации для руководства – это были беседы на равных, где сотрудники могли честно обсудить свои первоначальные страхи и то, как контекст их работы изменился к лучшему.

¹ Интеллект процессов, англ. *process Intelligence*, – это подход, использующий данные, аналитику и ИИ для анализа, оптимизации и мониторинга бизнес-процессов. Он помогает выявлять узкие места, улучшать эффективность и принимать обоснованные решения на основе данных о рабочих процессах в реальном времени. В контексте ИИ-трансформации предприятий это инструмент для автоматизации и совершенствования операционной деятельности. – *Прим. ред.*

Особенно мощным моментом стало, когда представитель службы поддержки клиентов из розничной компании поделился, как ИИ-агенты трансформировали его роль: «Раньше я тратил 70 % своего дня на однообразные запросы. Теперь их обрабатывают агенты, а я сосредотачиваюсь на сложных клиентских проблемах, где я действительно могу что-то изменить. Моя удовлетворенность работой увеличилась».

Во-вторых, мы внедрили так называемые семинары «День из жизни». Вместо абстрактных обсуждений об ИИ мы работали с командами, чтобы точно определить, как их повседневная работа изменится с ИИ-агентами. Это показало, что вместо замены агенты в основном устраняют рутинные аспекты их работы – те части, которые большинству людей и так не нравились.

В-третьих, мы создали «дорожные карты будущих ролей» для каждой команды. Это были не расплывчатые обещания о переобучении, а подробные планы, показывающие, как роли будут эволюционировать и какие новые возможности появятся. Например, мы показали, как некоторые члены команды могут стать «специалистами по автоматизации», комбинируя свои глубокие знания процессов с новыми техническими навыками для управления и улучшения ИИ-агентов.

Результаты были поразительными. В одном отделе, где 82 % сотрудников изначально выражали обеспокоенность по поводу того, не потеряют ли они работу после ИИ-трансформации своего предприятия, после шести месяцев применения нашей практики 76 % сообщили, что к интеграции ИИ-агентов относятся положительно. Главным было показать, а не просто рассказать, как ИИ-агенты могут развивать возможность применения человеком своих способностей, а не заменять его.

Эволюция рабочих навыков в эпоху агентного ИИ

Благодаря нашему обширному опыту внедрения ИИ-агентов в различных организациях мы разработали комплексный фреймворк, который мы называем «Модель компетенций для сотрудничества с ИИ-агентами» (AICSM). Эта модель охватывает фундаментальные переходы в навыках, которые работники и руководители должны освоить, переходя от работы с базовыми инструментами ИИ – такими как традиционные большие языковые модели, например ChatGPT или Gemini, – к сотрудничеству с ИИ-агентами.

На основе закономерностей, наблюдаемых в десятках внедрений, этот фреймворк предоставляет организациям дорожную карту для развития человеческих компетенций, необходимых для успеха в эпоху агентного ИИ. Давайте рассмотрим четыре важнейших измерения AICSM, которые должны освоить работники и руководители.

От мышления на уровне задач к мышлению на уровне рабочих процессов

В то время как ранние инструменты ИИ работали на уровне отдельных задач, агентные системы работают на уровне рабочих процессов, оркестрируя взаимосвязанные процессы для достижения более широких результатов. Это требует от работников новых навыков, способностей и практик:

- *навыков картирования процессов*: способности понимать, как отдельные задачи соединяются в более широкие рабочие процессы, обеспечивая эффективную совместную работу всех компонентов;
- *оптимизации систем*: разработки и совершенствования систем, позволяющих агентам работать бесперебойно в нескольких доменах;
- *междисциплинарного мышления*: понимания того, как задачи и области взаимосвязаны для создания комплексных решений;
- *ориентации на результат*: меньше фокусироваться на выполнении отдельных задач и больше на определении желаемых результатов, которые направляют деятельность агентов.

Старший менеджер по операциям в производственной компании поделился: «Самый ценный навык, который я развил, – это не кодирование или разработка запросов, а способность картировать сквозные процессы и определять, где агенты могут оказать наибольшее влияние на нашу деятельность».

От контроля к делегированию

Переход от прямого контроля к эффективному делегированию, возможно, является самым сложным для многих сотрудников, потребуется освоить следующее.

- *Способность к надзору*: умение мониторить системы ИИ без микроменеджмента, обеспечивая их соответствие целям при сохранении эффективности.
- *Балансировка автономии*: развитие «интуиции ИИ» о том, когда следует применять контроль, а когда позволять агентам работать самостоятельно.
- *Фреймворки управления*: создание структур для отслеживания, аудита и улучшения решений ИИ.
- *Управление этическими рисками*: понимание, когда и как делегировать ответственность, обеспечивая, чтобы ИИ действовал в рамках этических границ.

«Научиться делегировать ИИ было сложнее, чем я ожидал, – признался директор по маркетингу, с которым мы работали. – Мне пришлось преодолеть желание проверять каждое действие и вместо этого сосредоточиться на анализе результатов и внесении стратегических корректировок».

От простых взаимодействий к настоящему сотрудничеству

Работа с агентным ИИ требует более сложного подхода к сотрудничеству человека и машины.

- *Осведомленность о возможностях*: понимание расширенных функциональных возможностей агентов за пределами базовой обработки языка.
- *Контекстное взаимодействие*: предоставление высокоуровневого руководства вместо пошаговых инструкций.
- *Совместная разработка*: работа с ИИ для совместного создания решений через итеративное совершенствование.
- *Стратегическое партнерство*: использовать ИИ для автоматизации и точности, применяя при этом человеческую креативность и суждения.

В нашем внедрении в финансовых услугах мы обнаружили, что команды, рассматривающие ИИ-агентов как «инструменты для сотрудничества», достигали значительно лучших результатов и сообщали о более высокой удовлетворенности работой.

От дополнения к созданию ценности (долгосрочные компетенции)

По мере того как агенты берут на себя целые рабочие процессы, люди должны сосредоточиться на создании ценности способами, которые ИИ не может воспроизвести.

- *Подлинная креативность*: разработка новых решений с эмоциональной глубиной и культурными нюансами, которые ИИ не может генерировать самостоятельно.
- *Критическая оценка*: анализ результатов ИИ на предмет предвзятости, этических соображений и долгосрочных последствий.
- *Построение отношений*: превосходство в областях, где человеческая связь, доверие и эмпатия остаются незаменимыми.
- *Экспертиза интеграции*: понимание того, как дополнять возможности ИИ уникальными человеческими сильными сторонами.

«Парадокс, который мы обнаружили, – объяснил руководитель в сфере здравоохранения, участвовавший в нашем внедрении агентов, – заключается в том, что внедрение автоматизации делает наши уникально человеческие навыки более ценными. Наши сотрудники теперь тратят больше времени на отношения с пациентами и решение сложных проблем – то, в чем действительно могут преуспеть только люди».

Развивая компетенции, описанные в нашей «Модели компетенций для сотрудничества с ИИ», сотрудники могут превратить потенциальную тревогу по поводу ИИ в энтузиазм по поводу новых возможностей. Организации, которые инвестируют в развитие этих навыков по всем четырем измерениям, обнаруживают, что их команды не только быстрее адаптируются к ИИ-агентам, но и находят инновационные способы использования технологии, которые технические эксперты могли бы никогда не предвидеть.

Модель AICCM оказалась ценным инструментом в нашем подходе к управлению изменениями, предоставляя четкую структуру для программ развития навыков и помогая организациям выявлять конкретные пробелы в компетенциях. Мы обнаружили, что команды, преуспевающие во всех четырех измерениях модели, в три раза чаще сообщают об успешных внедрениях агентов, чем те, кто сосредотачивается исключительно на технической интеграции.

Построение доверия через прозрачность

Наиболее успешные внедрения, которые мы наблюдали, имеют одну общую черту: радикальную прозрачность в отношении влияния на роли. Без этой прозрачности сотрудники будут неохотно доверять ИИ-агентам и подозревать, что ИИ внедряется для оптимизации эффективности, которая превзойдет человеческие способности и, следовательно, приведет к замене людей. Другими словами, без объяснения причин принятия решения об интеграции ИИ-агентов сотрудники будут испытывать тревогу по поводу будущего и со-

противляться изменениям, которые вы задумали. Когда мы осознали необходимость усиления такого рода прозрачности в упомянутой ранее страховой компании, мы изменили наш подход в середине внедрения.

Вместо того чтобы широко объявлять, что ИИ-агенты «оптимизируют обработку претензий», мы создали подробные карты влияния для каждой роли, показывающие:

- какие конкретные задачи будут выполняться агентами;
- как роли будут эволюционировать, включая новые обязанности;
- какие навыки станут более ценными в трансформированной среде;
- четкие пути карьерного роста в новой структуре.

Эта стратегия прозрачности дала неожиданный эффект. Вместо увеличения тревоги она фактически ее снизила, поскольку ИИ-агенты воспринимались как способы, которые облегчат работу и могут улучшить карьерные перспективы сотрудников. Действительно, наш новый подход позволил сотрудникам точно увидеть, как их роли изменятся, делая будущее более конкретным и управляемым.

Эволюция обучения: за пределами традиционного тренинга

Одной из наших ранних ошибок было чрезмерное доверие к формальным тренингам, где мы рассказывали сотрудникам о потенциале ИИ-агентов. Через некоторое время мы поняли, что для успешного принятия ИИ-агентов необходимо обеспечить, чтобы интеграция ИИ-агента оставалась согласованной с человеческими ценностями и интересами, сохраняя при этом способность агента работать независимо.

Мы усвоили этот урок на собственном горьком опыте в телекоммуникационной компании, где, несмотря на проведение обширных программ обучения, принятие сотрудниками ИИ-агентов для поддержки клиентов оставалось низким. Прорыв произошел, когда мы перешли к подходу «учебной лаборатории». Вместо чисто теоретического обучения, где мы рассказывали людям, что могут делать ИИ-агенты, мы решили, что люди должны участвовать в самом процессе интеграции¹. Установление процесса принятия с участием позволило бы людям получить непосредственный опыт преимуществ, которые ИИ-агент может принести их работе. Это, в свою очередь, генерировало бы обратную связь, которую мы, как консультанты, вместе с организацией в целом могли бы использовать, чтобы обеспечить интеграцию ИИ-агентов таким образом, чтобы это имело смысл для всех, одновременно повышая эффективность рабочего процесса.

Для этого мы создали тестовые среды (песочницы), где сотрудники могли экспериментировать с ИИ-агентами в реальных сценариях их повседневной работы. Этот практический опыт оказался инновационным.

¹ Дэвид Де Кремер, 2024. «Трансформация с ИИ требует усилий всей команды: включение рядовых сотрудников в процесс принятия решений с участием ИИ улучшает общую производительность», Harvard Business Review, май-июнь, стр. 124–131.

Трехкомпонентный подход к обучению

Через метод проб и ошибок мы разработали то, что мы называем «трехкомпонентным подходом к обучению»¹.

1. *Самостоятельное исследование.* Сотрудникам предоставляется специально отведенное время для экспериментов с ИИ-агентами в их конкретном рабочем контексте, обучение через непосредственный опыт, а не абстрактные концепции. В идеале эти эксперименты проводятся, когда агенты еще находятся на стадии прототипов или пробной концепции и могут быть модифицированы на основе обратной связи с человеком.
2. *Сети обучения коллег.* Мы создаем сообщества, где сотрудники делятся своим опытом, успехами и неудачами с ИИ-агентами. Эти сети часто выявляют инновационные применения, которые мы не рассматривали, и также являются отличным источником для выявления недостатков и возможных исправлений агентов.
3. *Контекстное обучение.* Традиционное обучение все еще важно, но оно должно быть адаптировано к конкретным бизнес-функциям, ролям и сценариям использования, а не к общей образованности в области ИИ.

Расширение возможностей через владение

Пожалуй, самым значимым инсайтом стало наблюдение из опыта производственной компании. Изначально лидеры компании планировали, что ИТ-отдел будет управлять всеми конфигурациями ИИ-агентов. Однако они обнаружили, что в отделах, где сотрудникам предоставили инструменты для модификации и настройки своих собственных агентов (во фреймворках управления), показатели принятия были значительно выше, и сотрудники сообщали о большей удовлетворенности от работы с агентом. Вместо того чтобы представлять ИИ-агента как готовый продукт, который должен быть интегрирован в рабочий процесс, предоставление сотрудникам чувства контроля способствует приверженности и ответственности, что снижает сопротивление принятию ИИ-агента.

Это наблюдение привело к разработке того, что мы называем «Моделью прогрессивной автономии»: по мере того как сотрудники демонстрируют компетентность в работе с ИИ-агентами (что может быть поддержано подходом с песочницей), они получают все больше полномочий для настройки и конфигурации агентов. Этот подход создает положительный цикл обратной связи – сотрудники становятся более заинтересованными в успехе агентов, которых они помогают формировать.

Сила демократизированной автоматизации

Одной из самых эффективных стратегий ускорения принятия ИИ-агентов из тех, что мы обнаружили, является демократизация технологии через низкокодовые платформы. Эти инструменты превращают сотрудников из пассивных получателей технологии в активных участников трансформации. В крупной медицинской организации, с которой мы работали, этот подход

¹ С англ. *Three-Pillar Learning Approach* – букв. «подход, основанный на трех столпах обучения». – Прим. ред.

привел к значительному изменению как темпов трансформации, так и отношения сотрудников.

«Изначально я представлял ИИ-агентов как угрозу, – признался Марк, специалист по медицинскому биллингу. – Но как только я смог сам настраивать автоматизацию, я понял, что он придуман для того, чтобы сделать мою работу лучше, а не заменить меня». Используя низкокодвые инструменты, Марк и его коллеги смогли автоматизировать рутинные запросы по биллингу, сохраняя контроль над тем, как работала эта автоматизация.

Ключ к успеху заключается в сочетании четырех элементов.

- Доступные инструменты, которые позволяют каждому, независимо от технической подготовленности, участвовать в создании и улучшении автоматизаций.
- Сеть «чемпионов автоматизации», которые могут направлять и поддерживать других.
- Репозитории агентов и инструментов, которые бизнесмены могут использовать для сборки рабочих процессов и автоматизации бизнес-процессов.
- Четкие фреймворки управления, которые обеспечивают инновации, сохраняя при этом безопасность и соответствие требованиям.

Этот подход не только ускоряет трансформацию, но и создает подлинное чувство соучастия и прививает ответственность за успех проекта трансформации предприятия. Действительно, когда люди могут напрямую влиять на то, как ИИ-агенты помогают их работе, они становятся заинтересованными в успехе всей инициативы.

Некоторые поставщики агентного ИИ облегчают этот подход, встраивая возможности разработки и управления агентами в свои низкокодвые версии программного обеспечения. Они считают, что большинство разработок агентов будут выполняться «гражданами», а не профессиональными ИТ- или ИИ-разработчиками. Организации, желающие следовать этому демократизированному подходу – который мы рекомендуем, – должны искать такие инструменты и их поставщиков.

Стимулирование инноваций и принятия рисков

Распространенной ошибкой, которую мы наблюдали (и сами совершали), было сосредоточение исключительно на успешных результатах при вознаграждении вовлеченности сотрудников в ИИ-агенты. В розничной компании мы узнали, что этот подход невольно препятствовал экспериментам – сотрудники боялись пробовать новые подходы, которые могли бы потерпеть неудачу. Конечно, если бояться пробовать новое и исследовать новые сценарии использования, неудач не будет, но в то же время не будет и обучения. Действительно, единственный способ учиться – это терпеть неудачи и использовать этот опыт для улучшения в следующий раз.

Решением стало изменение структуры стимулов, чтобы вознаграждать как успешные внедрения, так и хорошо задокументированные «учебные неудачи». Это создало культуру, где эксперименты стали цениться наравне с достижениями. Как любит говорить один из наших соавторов, Дэвид, «чтобы учиться быстро, нужно быстро терпеть неудачи».

На основе нашего опыта успешные программы стимулирования обычно включают:

- признание за выявление новых сценариев использования ИИ-агентов;
- награды за обмен уроками, извлеченными из успехов или неудач;
- возможности карьерного роста, связанные с навыками работы с ИИ-агентами;
- специально отведенное время для экспериментов и обучения.

Помимо стимулов, успешные организации нормализуют принятие ИИ, устанавливая четкие культурные ожидания.

- Искусственный интеллект – это не способ уклонения от работы. Использование ИИ должно рассматриваться как умелое улучшение человеческой работы, а не как оправдание для отстранения или избегания ответственности.
- Награждение за результаты, достигнутые с помощью ИИ. Сотрудники должны быть отмечены не только за потраченные усилия, но и за качество результатов – независимо от того, сыграл ли ИИ в этом роль. Если ИИ помогает принять лучшее решение, создать более качественный отчет или быстрее найти решение, человек, использующий его, должен получить поощрение за эффективное использование технологии.

Сочетая стимулы с культурным подкреплением, организации создают среду, где искусственный интеллект принимается, компетентность вознаграждается, а инновации процветают. Цель – не просто его принятие, а мастерство, которое он может дать, когда люди и ИИ работают вместе для достижения лучших результатов.

Построение устойчивого фреймворка управления изменениями

На основе нашего опыта мы разработали комплексный фреймворк для управления изменениями при внедрении ИИ-агентов. Главное здесь в том, чтобы признать, что управление изменениями – это не разовое событие, а продолжающийся процесс, который развивается вместе с технологией.

Организации и их руководители должны с самого начала устанавливать четкие ожидания: принятие ИИ-агентов требует времени и активного участия всех вовлеченных. Исследования показывают, что при первом внедрении ИИ-агентов эффективность часто временно снижается, поскольку люди приспосабливаются к работе со своими новыми цифровыми коллегами. В этот период сотрудники не только учатся сотрудничать с ИИ, но и развивают новые навыки для оптимизации взаимодействия человека и машины.

Однако, как только эти навыки освоены и установлены новые нормы и структуры стимулов, производительность начинает расти. Со временем организации достигают нового уровня синергии человека и машины, где ИИ улучшает рабочие процессы, раскрывая большую эффективность и ценность, чем когда-либо прежде¹.

¹ Бен Диксон, 2022. «J-кривая ИИ и предстоящий бум производительности», <https://bdtechtalks.com/2022/01/31/ai-productivity-j-curve/>.

Этот переход следует эффекту J-кривой – изначально эффективность падает, затем выравнивается и подскакивает за пределы уровней, которые были до внедрения ИИ¹. Понимание этой кривой критически важно: краткосрочные трудности адаптации – это не признаки неудачи, а необходимые шаги к долгосрочно работающей трансформации. Организации, которые признают и планируют эту динамику, будут лучше всего подготовлены к использованию полного потенциала ИИ².

Построение доверия через градуированную автономию

В случае превращения ИИ-агентов в доверенных рабочих партнеров мы поняли, что доверие – это двусторонний подход. Первый подход, который мы уже отмечали ранее, касается необходимости вовлечения сотрудников в процесс принятия и модификации использования ИИ-агента. Как мы объяснили, в процессе превращения сотрудников в активных участников интеграции ИИ-агентов в рабочий процесс они сами увидят, что эти агенты могут поддерживать их интересы и перестраивать их работу интересными и креативными способами. Этот подход подразумевает, что организации «дают» доверие своим сотрудникам, чтобы превратить ИИ-агента в сотрудника³.

Второй подход заключается в том, что сам ИИ-агент должен убедить сотрудника в том, что ему можно доверять. В этом случае доверие должно быть «заработано» (ИИ-агентом). На нашем опыте этот принцип зарабатывания доверия оказался решающим в успешных внедрениях ИИ-агентов. Мы ярко усвоили этот урок в финансовой компании, где первоначальное сопротивление ИИ-агентам было особенно сильным. Прорыв произошел, когда мы внедрили то, что мы называем подходом «доверительный регулятор».

Вместо того чтобы настаивать на немедленной полной автоматизации, мы создали систему, где пользователи могли дифференцированно контролировать, сколько автономии они дают своим ИИ-агентам. Они могли начать с агентов в «режиме наблюдения», где они видели, что сделал бы агент, не выполняя действий. По мере того как пользователи обретали уверенность, они могли постепенно «увеличивать» автономию агента – сначала позволяя ему выполнять простые, низкорисковые задачи, затем постепенно расширяя его полномочия по мере доказательства его надежности.

В каком-то смысле мы создали еще одну песочницу, где сотрудники могли тестировать возникающие при сотрудничестве с ИИ-агентом ситуации.

«Это как обучение нового члена команды, – объяснила Дженнифер, старший менеджер по операциям в фирме. – Вы не даете им полной автономии в первый же день. Сначала вы даете им возможность доказать свою професси-

¹ Эффект J-кривой описывает динамику производительности модели при ее обучении или внедрении. Изначально производительность может ухудшаться (например, из-за шума в данных, сложности настройки или адаптации к новым задачам), но затем, по мере обучения, оптимизации или накопления опыта, она резко возрастает, формируя кривую, напоминающую букву J. Это отражает временные затраты на обучение ИИ перед достижением высокой эффективности. – *Прим. ред.*

² Том Релихан, 2019. «Затишье перед бурей производительности ИИ», <https://mitsloan.mit.edu/ideas-made-to-matter/a-calm-ai-productivity-storm>.

³ Дэвид Де Кремер, 2024. «Лидер, разбирающийся в ИИ: девять способов вернуть контроль и заставить ИИ работать».

ональную пригодность на меньших задачах». Этот подход превратил скептиков в сторонников, дав им контроль над темпом принятия новой технологии.

Важнейшие элементы этого подхода к построению доверия включают:

- начало с высокой прозрачностью и низкой автономией;
- создание четких контрольных точек для расширения возможностей агента;
- поддержание прозрачных журналов аудита действий агента;
- установление простых в использовании механизмов переопределения;
- празднование и распространение историй успеха среди команд.

Взгляд в будущее: подготовка к перспективным возможностям агентов

Хотя современные внедрения обычно работают на уровнях 1–3 прогрессивно-го фреймворка агентного ИИ, организации должны готовиться к возможному появлению более сложных агентов на уровнях 4 и 5. Эта подготовка включает:

- разработку фреймворков для управления все более автономными системами;
- создание структур управления, которые могут развиваться вместе с растущими возможностями;
- развитие навыков, которые будут дополнять будущие ИИ-агенты, а не конкурировать с ними;
- разработку планов и альтернативных ролей для сотрудников, чьи рабочие места будут заняты агентами.

Например, в Klarna, компании онлайн-кредитования покупок из Швеции, СМИ широко освещали созданного ею агента службы поддержки клиентов, который мог «выполнять работу 700 человек»¹. Однако некоторые рецензенты, такие как Мандель, обнаружили, что агент совершал множество ошибок и часто перенаправлял клиентов к агенту-человеку². Генеральный директор Klarna сообщил, что 700 агентов будут устранены только через естественное сокращение; в то же время они будут второй линией ответа клиентам или будут переназначены на другие связанные задачи³. Klarna в основном аутсорсит свою службу поддержки клиентов, и она планирует сократить количество работников с 3000 до 2000. Люди, таким образом, не исчезают.

Новые перспективы в сотрудничестве человека и агента искусственного интеллекта

Успешное управление человеческим аспектом при внедрении ИИ-агентов требует тонкого баланса прозрачности, обучения, расширения возможностей

¹ Klarna, 2024. «ИИ-ассистент Klarna обрабатывает две трети чатов службы поддержки в первый месяц», <https://www.klarna.com/international/press/klarna-ai-assistant-handles-two-thirds-of-customer-service-chats-in-its-first-month/>.

² Юджин Мандель, 2024. «Наш руководитель ИИ тестирует чат-бота Klarna», <https://loris.ai/blog/our-head-of-ai-puts-klarnas-chatbot-to-the-test/>.

³ Райан Хогг, 2024. «У Klarna 1800 сотрудников, которых, как надеется компания, ИИ сделает ненужными», <https://fortune.com/europe/2024/08/28/klarna-1800-employees-ai-replace-ipo/>.

и стимулирования. Цель – сочетать скорость, эффективность и надежность агентного ИИ с гибкостью, критическим мышлением и широкой перспективой, которые могут предоставить только люди. Как мы узнали через наши успехи и неудачи, процесс принятия должен напрямую связываться с интересами и пониманием людей, что означает, что человеческий элемент так же важен, как техническое внедрение.

Помните Флору из нашей вступительной истории? Через шесть месяцев после нашего первоначального разговора она стала одним из самых активных сторонников ИИ-агентов в своем отделе. «Дело не в том, чтобы нас заменить, – теперь говорит она своим коллегам. – Речь идет о предоставлении нам инструментов для выполнения более значимой работы». Ее путь от скептика к защитнику иллюстрирует силу эффективной реорганизации работы и управления изменениями в трансформации, иллюстрирует то, как организации принимают и получают выгоду от ИИ-агентов.

Посыл ясен: рассматривайте разработку нового рабочего процесса и управление изменениями не как барьер, который нужно преодолеть, а как возможность создать более вовлеченный, квалифицированный и адаптивный рабочий ресурс, готовый использовать полный потенциал ИИ-агентов, который повысит человеческие результаты и интересы.

Лидерство в эпоху ИИ-агентов: построение доверия и сотрудничества в гибридных командах

Представьте, что однажды утром вы приходите в офис и обнаруживаете, что половина вашей команды – не люди. Это не научная фантастика – это ближайшее будущее, когда ИИ-агенты будут сотрудничать с людьми. Но кто провел организацию через этот переход и как они это сделали? Как руководить такой гибридной командой после трансформации? Как выстраивать доверие между людьми и машинами? Эти вопросы не просто теоретические; они становятся все более актуальными, поскольку организации уже начали интегрировать ИИ-агентов в свои рабочие процессы.

Новая парадигма лидерства: от контроля к сотрудничеству

Традиционные модели лидерства были созданы для мира, где люди сотрудничали с другими людьми. Старые подходы к лидерству рассматривали людей как рациональных существ, являющихся частью организационной структуры. Наиболее важным было управление иерархией и рабочими процессами, поэтому стиль лидерства «команда и контроль» доминировал¹.

Спустя годы новые теории лидерства выявили ограничения подхода «команда и контроль», указав, что люди более мотивированы, когда сами готовы следовать за лидером, когда они принимают его и его историю. В результате лидеры стали больше сосредотачиваться на целеустремленности, умении выстраивать меж-

¹ Рэйчел Коньефа Диксон, 2023. «Анализ традиционных теорий лидерства: обзор современных подходов к лидерству и эффективности управления», Информация и управление знаниями, 13(5): 9–21, <https://www.iiste.org/Journals/index.php/IKM/article/viewFile/61330/63314>.

личностные отношения и устанавливать доверие, чтобы люди приняли их послание и, соответственно, были готовы следовать их директивам и запросам¹.

Традиционное понимание лидерства обычно не признает лидерство многомерным, где различные стили могут быть интегрированы. Часто оно воспринимается как выбор одного подхода или другого. Однако, основываясь на нашем консалтинговом опыте с компаниями из списка Fortune 500, внедрение ИИ-агентов фундаментально меняет эту перспективу. Руководство гибридной командой, состоящей как из людей, так и из ИИ-агентов, требует переоценки принципов лидерства. Это требует исследования того, как различные стили могут быть объединены для эффективного содействия сотрудничеству и повышению успеха команды.

Рассмотрим Анил, менеджера проекта в глобальной производственной компании, с которой мы недавно работали. Ее команда включала как человеческих аналитиков, так и ИИ-агентов уровня 3, выполняющих обработку данных и базовое принятие решений. «Сначала я пыталась управлять ИИ-агентами так же, как членами своей команды – людьми, – рассказала она нам. – Я быстро поняла, что это неправильный подход. ИИ-агентам не нужна мотивация или эмоциональная поддержка – им нужны четкие цели и четко определенные параметры. В то же время моим человеческим членам команды требовалась помощь в понимании того, как эффективно сотрудничать со своими ИИ-коллегами».

Этот пример ясно показывает, что современным лидерам придется найти правильный подход для развития более коллаборативных отношений между людьми и машинами. В таких гибридных командных условиях лидеры должны стремиться к созданию контекста, в котором люди готовы развивать рабочие отношения с ИИ-агентами, способными вести диалог, предлагать альтернативные идеи и даже оспаривать наши предположения, что может привести к новым подходам и решениям. Для этого лидерам таких гибридных команд необходим двойной подход к лидерству.

Они должны одновременно управлять логическими, объективными потребностями ИИ-агентов, действуя контролирующим и рациональным образом, и в то же время поддерживать эмоциональные и развивающие потребности человеческих членов команды, чтобы они чувствовали вдохновение для соблюдения и сотрудничества. Этот двойной фокус создает то, что мы называем «Принципом двойственности лидерства».

Этот сдвиг сопровождается трансформацией организационной структуры. Традиционные иерархические структуры с множеством уровней управления уступают место более плоским, динамичным организациям, где ИИ-агенты берут на себя многие задачи среднего уровня управления, такие как планирование, распределение ресурсов и отслеживание производительности. Результатом является более органичная организация, где люди сосредотачиваются на высокоуровневой стратегии, инновациях и межличностном лидерстве. Старшим лидерам придется анализировать и, возможно, экспериментировать с организационными структурами своих компаний и количеством и типами менеджеров на каждом уровне.

¹ Электронный журнал SSRN, 2023. «Теоретическая оценка традиционных подходов к лидерству», https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4297450.

Еще одно значительное изменение связано с тем, как принимаются решения. Если сегодня лидеры часто основывают решения в основном на анализе данных и метриках производительности, завтрашние лидеры должны будут сбалансировать инсайты, сгенерированные ИИ, с человеческими суждениями. Например, когда ИИ-агент предлагает основанную на данных рекомендацию по расширению рынка, роль лидера не просто в том, чтобы одобрить или отклонить анализ, но в том, чтобы рассмотреть, как он соответствует ценностям компании, долгосрочному видению и более широкому общественному воздействию. На самом деле реальность такова, что лидеры могут рассматривать все доступные данные, но в какой-то момент они должны перестать смотреть на данные и использовать сгенерированные инсайты и предложенные рекомендации для принятия решений и создания ценности, которая имеет смысл для их заинтересованных сторон.

Построение доверия в гибридных командах

Доверие – это основа эффективных команд, но как работает доверие, когда некоторые члены команды – машины? Исследования и опросы по доверию в сотрудничестве человека и ИИ, такие как работы Дуана и др. (2024)¹ и Хоффа и Башира (2015)², могут предоставить ценные инсайты в эту динамику. На основе наших исследований и опыта внедрения мы выделили три важнейших измерения доверия в гибридных командах.

1. *Доверие человека к искусственному интеллекту.* Люди должны доверять, что ИИ-агенты будут выполнять свои задачи надежно и этично. Это доверие строится на основе прозрачности, стабильной производительности и четкого информирования о возможностях и ограничениях ИИ со стороны организации и ее руководства³.
2. *Передача задач от ИИ к человеку.* Доверие критически важно во время передачи задач между ИИ-агентами и людьми. Человеческие члены команды должны верить, что работа, полученная от ИИ-агентов, точна, полна и непредвзята. Задачи должны быть простыми и прозрачными, чтобы их можно было проверить.
3. *Доверие между людьми в контексте ИИ.* Люди должны доверять суждениям друг друга и разделять общие ценности, чтобы при работе с ИИ-агентами успешно осуществлять надзор за ними.

Рассмотрим, как это проявляется на практике. В недавнем проекте с финансовой компанией мы внедрили ИИ-агентов уровня 3 для обработки начальных клиентских запросов и базового анализа. Человеческие представители службы поддержки клиентов изначально проявляли значительное сопротивление,

¹ Вэнь Дуан и др., 2024. «Понимание эволюции доверия во времени в командах человек-ИИ», Труды ACM по взаимодействию человека и компьютера, 8(CSCW2), статья 521, <https://doi.org/10.1145/3687060>.

² Кевин Энтони Хофф и Масуда Башир, 2015. «Доверие к автоматизации: интеграция эмпирических данных о факторах, влияющих на доверие», Человеческие факторы, 57(3), 407–434. <https://doi.org/10.1177/0018720814547570>.

³ Дэвид Де Кремер, 2024. «Лидер, разбирающийся в ИИ: девять способов вернуть контроль и заставить ИИ работать».

опасаясь, что ИИ либо заменит их, либо допустит ошибки, которые им придется исправлять.

Чтобы построить доверие, мы внедрили прозрачный фреймворк сотрудничества.

- *Четкое информирование о возможностях.* Мы помогли команде понять, что именно могут и не могут делать ИИ-агенты, используя прогрессивный фреймворк агентного ИИ для объяснения их текущих возможностей уровня 3.
- *Видимые метрики успеха.* Мы создали дашборды, показывающие точность и эффективность как ИИ, так и человеческих членов команды, помогая всем понять их взаимодополняющие сильные стороны, чтобы минимизировать проблемы координации и сотрудничества.
- *Прогрессивная интеграция.* Мы начали с простых задач и постепенно увеличивали обязанности ИИ-агентов по мере того, как команда становилась более уверенной.

В течение трех месяцев уровни доверия значительно улучшились, и гибридная команда превзошла предыдущие метрики на 40 %.

Построение доверия – это прогрессивный процесс

Путешествие по построению доверия к ИИ-агентам следует любопытной закономерности, которую мы наблюдали в многочисленных внедрениях. Недавно, работая с глобальной производственной компанией, мы стали свидетелями того, как это путешествие разворачивалось в реальном времени. Компания внедрила ИИ-агента для оптимизации решений в цепочке поставок, и эволюция доверия прошла через три отчетливые фазы.

Фаза 1. Верификация

Изначально сотрудники подходили к агенту со здоровым скептицизмом, тщательно проверяя каждое его предложение. Представьте это как обучение нового сотрудника – вы хотите проверять его работу постоянно, пока не убедитесь в его способностях. На этой фазе производственная команда тратила часы на проверку рекомендаций агента по инвентаризации.

Фаза 2. Калиброванное доверие

Примерно через три месяца произошло нечто интересное. Команда начала развивать то, что мы называем «калиброванным доверием», – они начали понимать, где агент превосходил человека, а где требовался человеческий надзор. Они узнали, например, что агент был исключителен в прогнозировании рутинных потребностей в поставках, но нуждался в человеческом вмешательстве в необычных ситуациях, таких как внезапные изменения на рынке или срочные заказы. Такое мышление на широкую перспективу всегда было человеческой ролью, и оно особенно важно, когда мир меняется, но модели ИИ еще не адаптировались.

Фаза 3. Партнерство

Заключительная фаза наступила примерно через шесть месяцев: истинное партнерство. К этому времени ИИ-агенты были приняты как способствующие ин-

тересам сотрудников и организации. Команда развила настолько эффективное сотрудничество со своим ИИ-агентом, что сократила время принятия решений на 60 %, одновременно улучшив точность. Они не слепо доверяли агенту – вместо этого они развили тонкое понимание того, как эффективно работать вместе.

Установление границ

Эффективное сотрудничество с ИИ-агентами требует поддержания соответствующего уровня надзора. Исследования Глива и Маклина подчеркивают, что даже продвинутые системы ИИ могут быть уязвимы к сбоям и ошибкам¹. Это особенно актуально для генеративных моделей ИИ, которые часто будут основным типом ИИ, используемым в агентах. Поэтому установление протоколов мониторинга критически важно, особенно для задач с высокими ставками.

Решение в том, чтобы найти правильный баланс, – мониторинг должен быть достаточным, чтобы выявлять значительные ошибки, но не настолько интенсивным, чтобы он сводил на нет преимущества эффективности от использования ИИ. Этот баланс будет варьироваться в зависимости от контекста задачи и потенциальных последствий ошибок.

Вот почему важно устанавливать четкие границы и механизмы надзора. На основе наших внедрений в различных отраслях мы разработали то, что мы называем «фреймворком контроля решений». Этот фреймворк помогает организациям постепенно выстраивать доверие к ИИ-агентам, сохраняя при этом соответствующий контроль и надзор.

1. *Стратегические решения.* Для перспективных решений, требующих сложных суждений, ИИ-агенты должны поддерживать, но не принимать решения. Здесь человеческие суждения остаются незаменимыми. Такие решения приходится делать нечасто, поэтому их трудно моделировать или обучать принимать такого рода решения системы ИИ. Например, при работе с системой управления запасами розничной сети решения о выходе на новые рынки или запуске крупных рекламных кампаний оставались исключительной прерогативой человека с агентом-помощником, предоставляющим анализ данных и рыночные инсайты для поддержки решений человека.
2. *Тактические решения.* Для адаптивных решений средней сложности агенты могут предлагать действия, но не должны их выполнять без человеческого одобрения. В нашем розничном примере ИИ-агент рекомендовал корректировки запасов на основе прогнозируемых моделей спроса и предлагал изменения цен для конкретных продуктов, но перед их реализацией люди проверяли и одобряли эти рекомендации. Частота человеческой проверки может частично зависеть от экономической ценности принимаемых решений.
3. *Операционные решения.* Для рутинных, повторяющихся решений подходящие агенты могут работать автономно в четко определенных параметрах. Розничная система могла автоматически перезаказывать

¹ Адам Глив и Юан Маклин, 2023. «Безопасность ИИ в мире уязвимых систем машинного обучения», <https://www.alignmentforum.org/posts/ncsxcf8CkDveXBCrA/ai-safety-in-a-world-of-vulnerable-machine-learning-systems-1>.

стандартные товары, когда запасы достигали заранее установленных уровней, но только в пределах определенных бюджетных и количественных ограничений. Аналогично в контексте службы поддержки клиентов агенты могли автоматически направлять запросы в соответствующие отделы на основе анализа содержания, но передавали сложные случаи человеческим супервизорам.

Этот фреймворк предоставляет структурированный подход к постепенному выстраиванию доверия. По мере того как команды становятся более уверенными в производительности агента на одном уровне, они могут постепенно расширять его автономию, сохраняя при этом соответствующий надзор. Агенты также могут быть обучены на новых данных во временном развитии, что должно улучшить их производительность и точность решений.

СТРАТЕГИИ КОММУНИКАЦИИ В ГИБРИДНЫХ КОМАНДАХ

Коммуникация в гибридных командах требует нового подхода. Хотя современные ИИ-агенты (уровни 1–3) могут обрабатывать естественный язык и отвечать на него, им не хватает тонкого понимания, которым обладают люди. Это создает то, что мы называем «коммуникационным разрывом».

Чтобы преодолеть этот разрыв, мы разработали «Протокол коммуникации гибридной команды».

1. *Четкие структуры команд.* Использование однозначного языка при общении с ИИ-агентами, сохраняя при этом естественный стиль разговора с человеческими членами команды.
2. *Управление контекстом.* Обеспечение того, чтобы все члены команды, как люди, так и ИИ, имели доступ к релевантному контексту для своих задач. Это особенно важно для агентов уровня 3, которые могут понимать и работать с контекстом.
3. *Циклы обратной связи.* Установление регулярных механизмов обратной связи между человеческими членами команды и ИИ-агентами. Этот цикл обратной связи должен быть поддержан лидерами, достаточно разбирающимися в ИИ, чтобы интегрировать техническую информацию и данные с человеческими и брендовыми ценностями компании. Таким образом, они могут при необходимости корректировать модели ИИ для повышения производительности.

Технологическая компания, которую мы консультировали, внедрила этот протокол с замечательным успехом. Они создали стандартизированный коммуникационный фреймворк, где ИИ-агенты предвзяли свои выходные данные уровнями уверенности и любыми сделанными предположениями, что облегчало человеческим членам команды оценку и работу с информацией.

Подготовка лидерских навыков к будущему

По мере того как ИИ-агенты продолжают развиваться через уровни прогрессивного фреймворка, лидеры должны развивать новые навыки, чтобы оставаться эффективными. На основе наших исследований и опыта мы выделили важнейшие компетенции, которые лидеры должны развивать.

1. *Грамотность в ИИ*. Понимание возможностей, ограничений и потенциала ИИ-агентов на разных уровнях. Речь не о том, чтобы стать техническим экспертом, а о том, как эффективно использовать ИИ.
2. *Командное взаимодействие в гибридной команде*. Способность координировать работу между человеческими и ИИ-членами команды, обеспечивая оптимальное распределение задач, выбор правильных сотрудников в сочетании с агентными ролями и содействие сотрудничеству.
3. *Этический надзор*. По мере того как ИИ-агенты берут на себя более сложные задачи, лидеры должны обеспечивать должное рассмотрение этических аспектов. Речь идет о задании норм для правильной разработки и использования ИИ-агентов.
4. *Управление изменениями в эпоху ИИ*. Способность направлять команды через непрерывную эволюцию возможностей ИИ и интеграцию в рабочее место. Это включает развитие навыков устойчивости, гибкости и любопытства.

Организационный фреймворк внедрения: создание кросс-функциональных команд

Будущее рабочих процессов – это не просто добавление ИИ к существующим структурам, а переосмысление того, как работают команды. Мы наблюдаем появление кросс-функциональных, динамичных команд, где агентные системы работают одновременно в нескольких функциях. Например, единая агентная система может одновременно обрабатывать автоматизацию маркетинга, финансовое прогнозирование и поддержку клиентов, в то время как люди сосредотачиваются на стратегии и креативных решениях.

Успешное внедрение таких гибридных команд требует структурированного подхода. Опираясь на фреймворки, такие как представленный в 2024 года фреймворк гибридных моделей работы, можно получить ценную поддержку для этой стратегии¹. Мы разработали «Модель интеграции гибридной команды» на основе нашего опыта работы с многочисленными организациями.

Фаза 1. Создание основы для сотрудничества, расширенного ИИ

Для создания успешной модели гибридной команды, где ИИ-агенты и люди сотрудничают безупречно, первым шагом является определение того, как ИИ будет усиливать человеческие способности. Начните с определения рабочих процессов, где ИИ может обрабатывать повторяющиеся, насыщенные данными задачи, позволяя людям сосредоточиться на креативной и стратегической работе. Проводите семинары с командами, чтобы определить разделение обязанностей между ИИ-агентами и людьми, обеспечивая ясность и согласованность.

Обеспечьте команды правильными инструментами, такими как платформы управления задачами на основе ИИ или системы поддержки принятия решений, и обучите их эффективно взаимодействовать с этими технологиями.

¹ Т. Сарита и П. Ахтар, «Влияние гибридных моделей работы на благополучие и вовлеченность сотрудников», Коммуникации по прикладному нелинейному анализу, 31, № 5s (2024), <https://internationalpubls.com/index.php/cana/article/download/1003/707/1856>.

Лидеры должны быть наделены навыками, чтобы направлять членов команды – как людей, так и ИИ-агентов, сосредотачиваясь на укреплении доверия к технологии при сохранении человеческого надзора. Эта фаза посвящена созданию основы доверия, структуры и готовности к сотрудничеству.

Фаза 2. Тестирование и совершенствование динамики отношений человек–ИИ

После создания основы следующая фаза – это пилотирование гибридных команд, чтобы протестировать, как люди и ИИ-агенты могут совместно создавать ценность в реальных сценариях. Выберите конкретную команду или проект, где ИИ может продемонстрировать свой потенциал, – например, команду поддержки клиентов, использующую генеративный ИИ для более быстрых ответов, или маркетинговую команду, использующую ИИ для оптимизации кампаний. Установите четкие протоколы коммуникации: например, ИИ составляет черновики предложений, а люди их дорабатывают и одобряют. Регулярные циклы обратной связи здесь критически важны; проводите еженедельные ретроспективы, где члены команды делятся инсайтами о том, как работали инструменты ИИ и где они не оправдали ожиданий. Эта фаза посвящена экспериментам, настройке процессов и обеспечению того, чтобы сотрудничество человек–ИИ ощущалось интуитивным и продуктивным.

Фаза 3. Масштабирование синергии человек – ИИ на всю организацию

После доработки модели сотрудничества в пилотной фазе следующий шаг – масштабирование принятия ИИ по командам и отделам. Чтобы укрепить уверенность в усиленной ИИ командной работе, используйте данные и отзывы из пилотной фазы, демонстрируя реальные примеры того, как ИИ улучшил эффективность, сделал более эффективным принятие решений и повысил результаты. По мере более широкого внедрения ИИ-агентов они должны быть адаптированы к уникальным потребностям каждой команды. Например, команды продаж могут извлечь выгоду из приоритизации лидов на основе ИИ, в то время как команды НИОКР могут использовать ИИ для ускорения анализа данных и более быстрых циклов инноваций. Эта кастомизация гарантирует, что интеграция ИИ ощущается целенаправленной и ценной, а не стандартной, применяемой во всех случаях одинаково процедурой.

Помимо развертывания, создание культуры синергии человек–ИИ является важнейшим моментом. Признавайте и вознаграждайте команды, которые эффективно сочетают человеческую креативность с машинной точностью – будь то через публичное признание, финансовые стимулы или вознаграждения на основе производительности. В то же время инвестируйте в продолжающиеся программы обучения, чтобы команды были в курсе возможностей ИИ и лучших практик, гарантируя, что они продолжают развиваться вместе с технологией.

Наконец, установите непрерывный цикл обратной связи, где команды могут делиться инсайтами, вызовами и улучшениями. Эта фаза – не только о масштабировании использования ИИ, но и о встраивании ИИ в организационную культуру – где люди и ИИ-агенты работают как настоящие партнеры, создавая результаты, которых ни один из них не мог бы достичь в одиночку.

Этот фреймворк внедрения признает различные роли, которые возникнут в усиленной ИИ рабочей процедуре. Некоторые роли – особенно те, которые связаны с операционными задачами, анализом данных и рутинным принятием решений – будут в основном выполняться ИИ-агентами. Тем временем люди сосредоточатся на ролях, требующих креативности, эмоционального интеллекта, лидерства и этического надзора. Речь не о замене, но об оптимизации: позволить каждому типу члена команды, будь то человек или ИИ, сосредоточиться на своих сильных сторонах.

Культурная трансформация

Пожалуй, самым сложным аспектом руководства гибридными командами является управление необходимой культурной трансформацией. На основе нашей работы с организациями в различных отраслях мы определили, что требуется для успешной культурной трансформации в эпоху ИИ-агентов.

1. *Изменение мышления.* Переход от восприятия ИИ-агентов как инструментов к их рассмотрению как коллег при сохранении четкого понимания их текущих возможностей и ограничений.
2. *Переоценка ценностей.* Помощь человеческим членам команды в понимании того, что их ценность заключается в уникально человеческих способностях, таких как креативность, устойчивость, гибкость, эмоциональный интеллект и решение сложных проблем.
3. *Культура непрерывного обучения.* Создание среды, где как люди, так и ИИ-агенты должны постоянно учиться и совершенствоваться. В то время как людям нужно расти как специалистам, ИИ должен учиться на основе обратной связи.

Взгляд вперед: будущее гибридного лидерства

По мере того как ИИ-агенты продолжают развиваться с помощью прогрессивного фреймворка (Progression Framework), лидерство должно будет адаптироваться дальше. Хотя современные внедрения в основном связаны с агентами уровней 1–3, мы должны готовиться к появлению более продвинутых возможностей.

Ключ к успешному лидерству в этом развивающемся ландшафте – это поддержание того, что мы называем «Адаптивным балансом лидерства», – способности адаптировать и интегрировать стили и подходы лидерства по мере развития возможностей ИИ, всегда сохраняя человеческие потребности и потенциал в центре уравнения.

Лидеры должны помнить, что, хотя ИИ-агенты могут выполнять все более сложные задачи, суть лидерства остается фундаментально человеческой. Способность вдохновлять, проявлять эмпатию, принимать сложные этические решения и способствовать инновациям продолжат оставаться уникально человеческими способностями.

На самом деле самым большим вызовом для человеческих лидеров будет стратегическая интеграция ИИ в наш человеческий опыт, чтобы у нас была возможность стать не менее, а более человечными – более эмпатичными, более креативными и более настроенными на то, что делает жизнь значимой. В этой парадигме ИИ-агенты станут мощными усилителями нашей человеческой

ности, позволяя людям исследовать глубины своего потенциала и переопределять границы человеческих достижений.

Руководство гибридными командами людей и ИИ-агентов представляет собой один из самых значительных сдвигов в практике управления со времен промышленной революции. Успех в этой новой эре требует тонкого баланса технического понимания, человеческой эмпатии и стратегического видения.

По мере того как мы продолжаем работать с организациями, внедряющими ИИ-агентов, мы постоянно учимся и совершенствуем наше понимание эффективного лидерства в этом новом контексте. Фреймворки и подходы, которые мы здесь описали, предоставляют основу, но область быстро развивается. Наиболее успешными лидерами будут те, кто сможет адаптировать эти принципы к своим конкретным контекстам, сохраняя при этом фокус как на человеческом развитии, так и на технологической интеграции.

Будущее лидерства – не в выборе между человеческим и искусственным интеллектом – в этом нет необходимости, поскольку они представляют собой два разных типа сущностей¹, – а в создании синергий между ними, чтобы человеческая производительность и организации могли быть подняты на беспрецедентные уровни. Понимая и применяя эти принципы, лидеры могут создавать высокоэффективные гибридные команды, которые используют лучшее из человеческих и искусственных возможностей.

Основа: стратегия управления и контроль

Во время нашей работы по ИИ-трансформации предприятий мы обнаружили фундаментальную истину: успех начинается и заканчивается сильным управленческим видением и вовлеченностью персонала. Организации, в которых команды руководства полностью согласованы с тем, как ИИ-агенты поддерживают их более широкую стратегию, в два раза чаще добиваются успеха в своих усилиях по трансформации. Но как выглядит эффективная управленческая стратегия на практике? Давайте разберем это через призму реального опыта и проверенных методов.

Формирование стратегии управления через опыт

Одной из самых распространенных ошибок, которые мы видим, является попытка управленческих команд продвигать внедрение ИИ-агентов только через стратегические документы и презентации PowerPoint. Этот абстрактный подход часто приводит к нереалистичным ожиданиям и несогласованным целям. Мы стали свидетелями мощного альтернативного подхода в глобальной телекоммуникационной компании, с которой мы недавно работали. Вместо того чтобы начинать с презентаций, их генеральный директор и исполнительная команда посвятили целый день тому, чтобы испытать ИИ-агентов лично, в их конкретном применении.

¹ Дэвид Де Кремер и Гарри Каспаров, 2021. «ИИ должен усиливать человеческий интеллект, а не заменять его», <https://hbr.org/2021/03/ai-should-augment-human-intelligence-not-replace-it>.

Руководители работали бок о бок с командами поддержки клиентов, лично экспериментируя с технологией. Они наблюдали, как агенты обрабатывали клиентские запросы, обрабатывали заявки и управляли исключениями. Этот погружающий опыт оказался инновационным. Генеральный директор позже поделился, что эти несколько часов полностью изменили его взгляд на то, что ИИ-агенты могут и не могут делать.

Практический опыт помог команде руководства разработать видение, основанное на практической реальности, а не на шумихе или страхе, что, в свою очередь, помогло им донести до своего персонала, почему и как ИИ-агенты должны быть приняты их организацией. В результате команда руководства смогла вдохновить своих сотрудников и убедить их в том, что ИИ-агенты будут полезны по конкретным причинам, связанным с предназначением и целями организации.

Этот подход отражает важный принцип, который мы наблюдали в успешных инновациях: управленческое видение должно быть укоренено в практическом понимании, чтобы быть успешным в мотивации и убеждении сотрудников. Когда руководители потратят время на реальную работу с ИИ-агентами, даже всего несколько часов, они разовьют интуитивное понимание возможностей и ограничений технологии. Это понимание приводит к более реалистичным и достижимым целям трансформации, которые легче донести и применить к конкретной ситуации рабочей среды предприятия.

Сила лидерства на примере

Пожалуй, самым недооцененным аспектом роли управления в ИИ-трансформации предприятия является важность лидерства на примере. Мы постоянно наблюдаем, что, когда руководители активно используют ИИ-агентов в своей собственной работе, принятие во всей организации резко возрастает. Важная причина заключается в том, что лидерство воспринимается как мандат доверия, и, следовательно, внедрение ИИ-агентов принимается как легитимное предложение в модернизации предприятия. Это явление ярко проявилось в консалтинговой фирме, где мы помогали внедрять ИИ-агентов во всех их операциях.

Управляющий партнер принял сознательное решение интегрировать ИИ-агентов в свою повседневную работу, открыто используя их во время клиентских презентаций и внутренних встреч. Он продемонстрировал, как использует агентов для анализа данных, генерации инсайтов и составления предварительных рекомендаций. Эта прозрачность достигла двух важных целей: она демистифицировала технологию для других сотрудников организации и отравила им четкое, достоверное сообщение, что ИИ-агенты – это инструменты, которые организация и ее члены должны принять без страха.

Это влияние было замечательным. В течение шести месяцев фирма зафиксировала 300%-ное увеличение добровольного принятия ИИ-агентов на всех уровнях организации. Когда мы опрашивали сотрудников об этом быстром принятии, многие указывали на пример управляющего партнера как главный фактор в их решении принять новую технологию.

Понимание силы трансформации на уровне предприятия

Внедрение ИИ-агентов представляет собой нечто большее, чем просто технологическое обновление, – это фундаментальная трансформация того, как рабо-

та выполняется по всей организации. На основе наших исследований и практического опыта мы обнаружили, что компании, применяющие ИИ-агентов сразу в нескольких функциональных областях, в 2-3 раза чаще добиваются успеха в своих инновационных усилиях, чем те, кто ограничивает внедрение изолированными участками¹.

Наш опыт последовательно показывает, что организации, принимающие подход внедрения ИИ-агентов на уровне всего предприятия, с большей вероятностью добиваются успеха в своих инновационных усилиях, чем те, которые ограничивают внедрение изолированными отделами. Это резкое различие проистекает из нескольких ключевых факторов, которые мы наблюдали в успешных внедрениях.

Большинство сквозных бизнес-процессов охватывают несколько функций; например, процесс «от заказа до оплаты» включает продажи, финансы, производство, цепочку поставок и логистику, а также множество информационных систем, поддерживающих эти функции. Внедрение агентов, поддерживающих такие процессы, может быть сложным и трудоемким, но это единственный способ достичь значительных преимуществ в плане повышения производительности и удовлетворенности клиентов.

Давайте разберем, как это проявилось в глобальной производственной компании, с которой мы работали. Изначально они планировали внедрить ИИ-агентов только в финансовом отделе для обработки счетов.

Мы попросили их объяснить, как они видят это приложение в соответствии с видением и целями компании. Используя их ответ, мы затем спросили, видят ли они больше возможных применений ИИ-агентов по всей организации, которые также служили бы назначению и целям организации. Благодаря нашему руководству и вопросам компания в конечном итоге расширила свою стратегию принятия новой технологии по всей организации, тем самым увеличивая вероятность создания реальной ценности для всех заинтересованных сторон. Этот подход к побуждению их к принятию иллюстрирует силу осмысления задачи на уровне всего предприятия с самого начала.

Ценность комплексного подхода

Компания начала с картирования взаимосвязей между отделами и быстро осознала инсайт и возможность модернизации: традиционный подход к управлению процессами в изолированных хранилищах сдерживал их. Например, счет, поступающий в финансы, был не просто финансовой транзакцией. Он оказывал влияние на закупки, управление поставщиками, службу поддержки клиентов и логистику. Закупкам нужно было проверять доставки, службе поддержки клиентов требовалась информация о ценах для клиентских запросов, а логистике требовались подтверждения отправки. Эти зависимости показали, что ни один отдел не работал в изоляции, – однако системы, поддерживающие их, были разработаны так, будто это было так.

И эти инсайты сработали. Когда лидеры компании – под нашим руководством – поняли, что ИИ-агенты могут создавать реальную ценность только

¹ McKinsey & Company, 2024. «Генеративный ИИ в корпоративных функциях: взгляд за пределы повышения эффективности», <https://www.mckinsey.com/capabilities/operations/our-insights/gen-ai-in-corporate-functions-looking-beyond-efficiency-gains>.

тогда, когда устанавливается кооперативное партнерство (между людьми и ИИ и среди самих ИИ-агентов), они быстро осознали, что им нужно способствовать кросс-функциональному сотрудничеству и, следовательно, устранить практику работы в отдельных хранилищах, которая незаметно укоренилась в мышлении организации за многие годы ее существования.

Поэтому вместо создания множества агентов – одного для финансов, другого для закупок и т. д. – компания сделала смелый шаг. Руководители осознали, что создание изолированных агентов для каждого отдела лишь воспроизведет те самые отдельные хранилища, т. е. ситуацию, которые они пытались преодолеть. Такой подход ограничил бы инновационный потенциал ИИ, просто автоматизируя фрагментированные процессы, не решая общую проблему: создание бесшовных сквозных рабочих процессов по всему предприятию.

Чтобы вырваться из этих ограничений, они разработали поперечные, сквозные агентные системы, способные работать между отделами. Эти агенты не просто автоматизировали отдельные задачи в одной функции, они оркестрировали целые рабочие процессы, охватывающие несколько областей; например, вместо того чтобы финансовый ИИ-агент передавал информацию отдельному агенту закупок, был создан единый сквозной агент для обработки всего – от получения счета до обработки платежа. Этот агент мог проверять доставки с закупками, подтверждать отправку с логистикой и отмечать несоответствия в ценах для службы поддержки клиентов – все в рамках одной целостной системы.

Этот кросс-функциональный подход раскрыл возможности, которых никогда не удалось бы достичь при внедрении агентов в отдельных областях. Пересекаются традиционные границы, ИИ-агенты начали выявлять инсайты, которые ни один отдел не смог бы определить сам по себе, без сопоставления между отделами. Например, выявились закономерности, связывающие условия платежей с производительностью поставщиков и денежным потоком, что позволило компании оптимизировать выбор поставщиков, вести переговоры о лучших контрактах и улучшить ликвидность. Эти инсайты не только улучшили операции, но и повысили качество стратегического принятия решений.

Результаты были масштабными: сокращение времени обработки на 40 % и улучшение управления денежным потоком на 25 %. Но настоящим прорывом была культурная трансформация. Внедряя ИИ таким образом, чтобы преодолевать разделение между отделами, компания перешла от фрагментированной организации к единому предприятию, ориентированному на данные. ИИ-агенты стали катализаторами сотрудничества, разрушая барьеры и способствуя мышлению, при котором решение проблем коллективно получило больший приоритет, чем защита территорий департаментов.

Этот опыт подчеркивает важный урок: сила агентного ИИ заключается не только в его способности автоматизировать, но и в его способности интегрировать. Организации должны противостоять искушению развешивать множество изолированных агентов и вместо этого использовать возможность разрабатывать системы, которые пересекают границы отделов. Истинная трансформация происходит, когда ИИ становится связующим звеном, которое объединяет предприятие, позволяя ему работать как целостное, интеллектуальное целое. Этот подход требует построения мультиагентных систем, где

разные агенты играют разные роли, которые должны быть скоординированы по всей организации человеческими лидерами, направляющими эту коллаборативную динамику на основе целей и видения организации.

Экономия масштаба и оптимизация инвестиций

Подход на уровне всего предприятия также обеспечил значительную экономию масштаба. Компания смогла договориться о лучших условиях с поставщиками технологий, разделить затраты на разработку между отделами и создать централизованную инфраструктуру поддержки. Что еще важнее, уроки, извлеченные в одной области, могли быстро применяться к другим, ускоряя общую трансформацию с дополнительным бонусом в виде разработки лучших кейсов, которые окажутся полезными в любом будущем инновационном проекте.

Инвестиции в основную инфраструктуру ИИ-агентов – включая фреймворки безопасности, системы управления данными и платформы интеграции – могли быть амортизированы по нескольким сценариям использования. Это сделало внедрения в отдельных отделах более экономически эффективными и легче оправдываемыми.

Построение бизнес-кейса на уровне предприятия

Ключевым элементом успеха ИИ-трансформации было создание комплексного бизнес-кейса на уровне всего предприятия. Это выходило за рамки традиционных расчетов рентабельности инвестиций на уровне отделов, учитывая кросс-функциональные преимущества и сетевые эффекты. Бизнес-кейс включал следующее:

- прямые сбережения затрат и повышение эффективности в каждом отделе;
- кросс-функциональные преимущества от улучшенного обмена данными и интеграции процессов;
- снижение технологических затрат за счет экономии масштаба;
- улучшение клиентского опыта за счет оптимизации сквозных процессов;
- повышение удовлетворенности сотрудников за счет устранения повторяющихся задач во всех функциях.

Этот взгляд на уровне всего предприятия помог заручиться еще более широкой поддержкой руководства, демонстрируя полный потенциал ценности трансформации. Он также предоставил фреймворки для приоритизации внедрений и распределения ресурсов между отделами.

Стратегический взгляд на агентов в масштабах компании может также потребовать новых организационных структур и лидерских ролей. У большинства компаний нет управляющих кросс-функциональных процессов или кого-либо, кто может принимать решения для сквозного процесса. В идеале внедрение новых агентных архитектур включало бы создание ролей, управляющих процессами, но это маловероятно. Однако большинству организаций потребуются советы или представители для обсуждения кросс-функциональных агентов. Лидеры должны поощрять своих руководителей функций и подразделений к сотрудничеству над проектами агентов на уровне предприятия и время от времени принимать в этом участие самим.

Создание комплексного бизнес-кейса

Бизнес-кейс для ИИ-агентов должен выходить за рамки традиционных расчетов возврата инвестиций. Лидеры должны поощрять заинтересованные стороны инициатив, основанных на агентах, принимать более широкую перспективу, чем они могли бы в противном случае. Когда мы работали с крупной страховой компанией, их первоначальный бизнес-кейс был сосредоточен исключительно на экономии затрат от автоматизации. Этот узкий взгляд привел к сопротивлению со стороны среднего менеджмента, который рассматривал инициативу исключительно как сокращение затрат. Мы помогли им перестроить их бизнес-кейс, включив четыре важнейших компонента, которые мы считаем необходимыми для инноваций ИИ-агентов.

Во-первых, количественные преимущества. Этот проект включает не только экономию затрат, но и возможности увеличения доходов. Например, их ИИ-агенты могли обрабатывать на 40 % больше клиентских запросов, что привело к увеличению продаж полисов на 15 %. Они также измеряли улучшения в скорости обработки, сокращении ошибок и точности соблюдения требований.

Во-вторых, качественные преимущества. Эта категория преимуществ включает улучшение удовлетворенности сотрудников (поскольку агенты берут на себя рутинные задачи), улучшение клиентского опыта (за счет круглосуточной доступности и последовательного обслуживания) и повышение операционной устойчивости. Страховая компания обнаружила, что показатели удовлетворенности сотрудников выросли более чем на 30 %, когда ИИ-агенты взяли на себя рутинную обработку претензий.

В-третьих, затраты на внедрение. Затраты на внедрение в производство и развёртывание должны включать не только технологические затраты, но и управление изменениями, обучение и потенциальные спады производительности в переходный период. Страховая компания выделила 40 % своего бюджета на управление изменениями и обучение, что оказалось решающим для успешного принятия.

В-четвертых, оценка и смягчение рисков. Риски проекта включают как технические риски (например, проблемы интеграции систем), так и организационные риски (такие как сопротивление сотрудников или пробелы в навыках). Они выявили критические риски, такие как вопросы безопасности данных, и разработали конкретные стратегии смягчения для каждого фактора риска.

Управление внедрением ИИ-агентов: целостный и этический подход

Эффективное управление внедрениями ИИ-агентов должно выстраивать баланс между потребностью в инновациях и необходимостью контроля, одновременно внедряя этические принципы на каждый уровень принятия решений. Это требует структурированного, но гибкого фреймворка, который обеспечивает согласованность по всей организации, способствует инновациям и поддерживает общественное доверие. Как и в случае с другими формами ИИ, этическое управление – это не только вопрос политики, но и оценка сценариев использования с момента их зарождения¹.

¹ Томас Давенпорт и Рэнди Бин, 2023. «Этика ИИ в Unilever: от политики к процессу», <https://sloanreview.mit.edu/article/ai-ethics-at-unilever-from-policy-to-process/>.

Выдающимся примером общего управления и этики для агентных инициатив является глобальный банк, который внедрил комплексную модель управления, сосредоточенную на «Совете инноваций агентов». Этот совет объединил лидеров бизнес-подразделений, руководителей ИТ и представителей сотрудников для создания общего фреймворка управления. Его главная сила заключается в интеграции стратегического надзора с операционной гибкостью, позволяя инновациям процветать без ущерба для контроля.

Совет работал по трехуровневой структуре.

- На вершине находился руководящий комитет, который задавал стратегическое направление, обеспечивая соответствие всех инициатив ИИ более широким целям компании. Этот комитет также управлял распределением ресурсов, гарантируя, что приоритетные проекты получают адекватную поддержку.
- Второй уровень, «Центр передового опыта» (CoE), действовал как операционный центр, предоставляя техническую экспертизу, стандартизируя практики внедрения и обеспечивая соблюдение протоколов управления.
- На базовом уровне отдельные отделы назначали «чемпионов ИИ» для выявления сценариев использования, продвижения принятия и действия в качестве связующих звеньев между бизнес-подразделениями и CoE. С активным присутствием чемпионов ИИ в командах разговоры о том, как эффективно использовать ИИ, стали естественной частью повседневных операций, способствуя культуре экспериментов и инноваций снизу вверх. Вместо представления об управлении как системе бюрократических препонов оно стало восприниматься как поддерживающая структура, которая поощряла ответственные эксперименты с ИИ.

Важнейшим моментом было то, что фреймворк управления также подчеркивал этический надзор как неотъемлемую часть структуры. Тот же глобальный банк создал «Совет по этике ИИ» для рассмотрения всех крупных внедрений ИИ. Этот совет отвечал за соблюдение основных этических принципов, таких как конфиденциальность данных, прозрачность принятия решений, справедливость и подотчетность.

Внедряя этику в структуру управления, организация избежала понижения этих соображений до второстепенной роли. Наоборот, этическая проверка стала обязательным контрольным пунктом на ранней стадии жизненного цикла разработки ИИ, позволяя пересматривать сценарий использования, укреплять общественное доверие и смягчать потенциальные регуляторные риски.

Например, совет по этике установил руководящие принципы, которые гарантировали, что ИИ-агенты действовали в четких границах в отношении использования данных. Эти принципы запрещали такие практики, как предвзятое принятие решений в автоматизированных процессах найма или непрозрачные алгоритмы ценообразования.

Банк пошел дальше внутреннего надзора и создал прямой цикл обратной связи с клиентами. Система обратной связи в реальном времени позволяла клиентам немедленно отмечать проблемы, когда они замечали несоответствия, несправедливые решения или потенциальную предвзятость в процессах, управляемых ИИ. Будь то автоматическое одобрение кредита, обнаружение мошенничества или ответ службы поддержки клиентов, поль-

зователи могли сообщать о расхождениях, инициируя внутреннюю проверку. Проактивно решая этические проблемы, банк не только защитил свою репутацию, но и повысил уверенность сотрудников и клиентов в своих инициативах ИИ.

Ежемесячные заседания совета инноваций агентов стали важнейшим элементом этой модели управления. Эти сессии предоставляли форум для оценки прогресса, обсуждения проблем и обеспечения соответствия развивающейся стратегии компании. Способствуя сотрудничеству между отделами и поддерживая открытый канал для обратной связи, совет создал культуру, где инновации процветали наряду с подотчетностью.

Эта интегрированная модель управления демонстрирует, что эффективная ИИ-трансформация – это не просто техническая задача, а переосмысление того, «как» выполняется работа по всей организации. Согласовывая стратегический надзор, операционную поддержку и этическую подотчетность, фреймворк управления не только обеспечил плавное внедрение ИИ-агентов, но и укрепил их роль как силы для долгосрочной организационной ценности.

Общая озабоченность по поводу инициатив ИИ с сильным управлением заключается в том, что они вводят чрезмерную бюрократию, замедляя инновации. Однако в этом случае произошло обратное. Присутствие чемпионов ИИ по всем отделам создало культуру, где использование ИИ постоянно обсуждалось, совершенствовалось и оптимизировалось. Вместо того чтобы воспринимать ИИ как отстраненную систему, контролируемую ИТ, сотрудники активно участвовали в формировании того, как ИИ может улучшить их повседневную работу.

Этот культурный сдвиг привел к инновациям снизу вверх. Например, одна команда в отделе управления рисками банка, вдохновленная внутренними обсуждениями ИИ, предложила систему раннего предупреждения о мошенничестве на основе ИИ. Поскольку структура управления позволяла быстро оценивать и тестировать, эта идея перешла от концепции к внедрению быстрее, чем традиционные инновационные процессы.

Этот подход еще раз подчеркивает важность участия организационного лидерства с самого начала процесса принятия, поскольку его раннее присутствие сразу же акцентирует внимание на том, насколько важны цели, ценности и миссия компании для любого проекта изменений и трансформации, в котором участвует организация. Таким образом, этика и управление органично станут линзами, через которые лидеры и сотрудники будут рассматривать и оценивать интеграцию ИИ-агентов как оно того заслуживает.

Нет сомнений в том, что организации, приступающие к инновациям ИИ, должны принять этот целостный подход, поскольку он позиционирует и признает управление как фактор, способствующий инновациям, и как защиту от этических ошибок. Когда фреймворки управления разработаны так, чтобы глубоко интегрировать этику в свою структуру и быть видимыми и направляющими с самого начала проекта принятия, они не только направляют технологию, но и формируют ее эффективность для улучшения условий человеческой работы и внесения вклада в выгоды и интересы всех заинтересованных сторон.

Ключевые показатели эффективности и мониторинг

Ключевые показатели эффективности (KPI) и мониторинг необходимы для оценки успеха инновации ИИ-агентов. KPI знакомы большинству менеджеров, когда речь идет об оценке успешности работы сотрудников. Однако, когда дело доходит до оценки успеха принятия ИИ-агентов как создателей ценности, которую генерирует компания, многие компании терпят неудачу.

На самом деле наш опыт показывает, что сегодня большинство компаний едва ли имеют четкие меры для оценки того, были ли их усилия по принятию ИИ успешными. Причина в том, что компании обычно начинают с проведения нескольких экспериментов с ИИ-агентами, которые выполняются в изолированных условиях. Они делают это, чтобы протестировать технологию, но в этом процессе уделяют мало внимания или совсем его не уделяют размышлениям о том, что делает принятие ИИ успешным (см. «отсутствие целостного подхода»). Поэтому с самого начала крайне важно установить четкие метрики и постоянно их мониторить, чтобы направлять процесс трансформации. Сосредотачиваясь на одном примере, мы можем предоставить практический фреймворк для отслеживания прогресса.

Рассмотрим финансовую компанию, внедряющую ИИ-агентов для оптимизации операций и улучшения поддержки клиентов. Перед развертыванием компания установила базовые метрики по четырем критическим областям: операционной эффективности, влиянию на сотрудников, клиентскому опыту и обучению агентов. Эти разнообразные домены эффективно составляют «сбалансированную карту показателей» для успеха и ценности проектов, ориентированных на агентов.

Операционные метрики измеряли время обработки, уровень ошибок и затраты на транзакцию. На старте проекта процессы были медленными и подверженными ошибкам. После внедрения ИИ-агентов фирма зафиксировала улучшение эффективности процессов на 60 % и сокращение ошибок на 85 %. Эти достижения напрямую соответствовали цели компании по снижению операционных затрат при увеличении точности.

Метрики влияния на сотрудников оценивали, как ИИ-агенты усиливали роли персонала. Фирма отслеживала время, сэкономленное на рутинных задачах, и проводила опросы сотрудников об удовлетворенности работой и развитии навыков. Сотрудники сообщили, что тратят на 60 % больше времени на стратегические действия, и отметили значительный рост удовлетворенности, поскольку повторяющиеся задачи были автоматизированы, позволяя им сосредоточиться на более значимой работе.

Метрики клиентского опыта были еще одним важным фактором, отслеживая показатели удовлетворенности, время решения и доступность услуг. Развертывая ИИ-агентов для поддержки клиентов на первой линии, фирма достигла увеличения удовлетворенности клиентов на 30 %. Более быстрое время решения и круглосуточная доступность сыграли значительную роль в улучшении клиентского опыта.

Наконец, *метрики обучения и адаптации* отслеживали способность агентов улучшаться с течением времени. Изначально ИИ-агенты могли автономно обрабатывать 40 % клиентских случаев. Шесть месяцев спустя этот показатель

вырос до 75 %, поскольку агенты адаптировались к обработке более сложных сценариев, уменьшая потребность в человеческом вмешательстве.

Фирма использовала эти метрики не только для измерения успеха, но и для поддержания цикла обратной связи. Ежемесячные обзоры позволяли ее руководству отслеживать прогресс, выявлять области для улучшения и корректировать стратегию. Например, когда мониторинг показал, что на обработке приоритетных случаев производительность агента стабилизировалась, компания предоставила дополнительные данные для его обучения и сделала тонкую настройку алгоритмов. Этот итеративный подход обеспечивал непрерывное улучшение.

Привязывая все метрики к первоначальному бизнес-кейсу, фирма сохраняла соответствие своим стратегическим целям. Четкие KPI, OKR, показатели роста и постоянный мониторинг давали заинтересованным сторонам уверенность в ценности целостной трансформации и поддерживали импульс на протяжении всей трансформации. Этот пример иллюстрирует, как структурированный, ориентированный на данные подход может сделать агентов ИИ-трансформации измеримыми, действенными и оцениваемыми с точки зрения прогресса на целостном уровне – охватывая как развитие навыков человеческого персонала, так и уровень интеграции ИИ, – что в конечном итоге приводило к успеху.

Масштабирование ИИ-агентов: от стратегии к реальности

Правильный подход к масштабированию

От правил к рассуждениям: масштабирование ИИ-агентов в компании

В конференц-зале воцарилась тишина, когда мы представили итоговые цифры нашего пилотного внедрения. ИИ-агент уровня 3 успешно обработал более 10 000 запросов службы поддержки клиентов всего за две недели, достигнув уровня точности, превосходящего нашу человеческую базовую линию. Команда руководства наклонилась вперед, явно впечатленная. Затем последовал ожидаемый вопрос: «Отличные результаты. Как нам масштабировать это на всю организацию?»

Эта сцена, развернувшаяся в страховой компании из списка Fortune 500, с которой мы работали в прошлом году, подчеркивает как огромный потенциал, так и присущие вызовы масштабирования ИИ-агентов по всему предприятию. Хотя успехи отдельных пилотных проектов становятся все более распространенными, очень немногие организации смогли расширить свои внедрения ИИ-агентов за пределы изолированных сценариев использования.

Наши исследования показывают поразительную статистику: менее 1 % компаний, тестирующих ИИ-агентов уровня 3, успешно развертывают их в масштабе. Это отражает ситуацию, с которой мы сталкивались 7–10 лет назад с появлением интеллектуальной автоматизации (агентов уровня 2). В то время организации сталкивались с аналогичными препятствиями при масштабировании своих инициатив.

Учитывая, что ни одна компания еще не установила проверенный фреймворк для масштабирования ИИ-агентов уровня 3, мы будем опираться на прошлый опыт и текущие, хотя и ограниченные наблюдения, чтобы описать оптимальный подход.

Основа: понимание, с чего начать

Когда мы впервые начали работать с этой глобальной страховой компанией, команда руководства была полна энтузиазма, чтобы немедленно приступить к развертыванию ИИ-агентов по всем операциям обработки претензий. Их энтузиазм был понятен – результаты пилотного проекта были убедительными. Однако мы уже видели подобное раньше.

«Прежде чем говорить о масштабировании, – сказали мы им, – давайте обсудим, что произошло с вашим внедрением RPA три года назад»¹. Директор по информационным технологиям неловко поерзал в кресле. Их предыдущая попытка масштабирования автоматизации застопорилась после начальных успехов, что один из руководителей назвал «кладбищем сломанных ботов».

Поиск подходящих возможностей

Вместо того чтобы делать предположения сверху вниз, мы применили подход снизу вверх, проведя шесть недель погруженными в работу различных отделов организации. «Нам нужно понять, на что люди действительно тратят свое время, а не на что, как мы думаем, они его тратят», – объяснили мы команде руководства.

Мы провели структурированные интервью с более чем 50 руководителями команд и сотрудниками отделов претензий, поддержки клиентов, андеррайтинга² и операций. Это были не просто формальные встречи – мы сидели с сотрудниками, наблюдали за их повседневной работой и прислушивались к их разочарованиям. Один комментарий специалиста по урегулированию претензий особенно запомнился: «Я трачу около четырех часов каждый день только на сбор и организацию информации из разных систем, прежде чем могу начать анализировать претензию».

Этот вид инсайтов оказался неоценимым. Через эти беседы и наблюдения мы создали подробные карты рабочей нагрузки для каждого отдела, определив, где время тратилось и, что более важно, где оно расходовалось впустую. Мы обнаружили, что сотрудники по всем отделам тратили 60–70 % своего времени на то, что они описывали как «административные накладные расходы», а не на работу, добавляющую ценность.

Приоритизация для получения результата

Завершив картирование рабочей нагрузки, мы применили то, что мы называем «принципом 20/80», – определение 20 % видов деятельности, потребляющих 80 % рабочего времени людей. Эти виды деятельности с высокой нагрузкой стали нашим основным фокусом для внедрения ИИ-агентов.

В отделе претензий, например, мы выделили три вида деятельности, которые потребляли непропорционально много времени:

¹ RPA (роботизированная автоматизация процессов) – это технология, которая позволяет автоматизировать повторяющиеся и основанные на правилах задачи с помощью программных ботов или «роботов». Эти боты запрограммированы на выполнение задач так же, как это сделал бы человек, но с большей скоростью и точностью. – *Прим. ред.*

² Андеррайтинг – это процесс оценки рисков, связанных с выдачей кредита, страхованием, размещением ценных бумаг или другими финансовыми операциями. – *Прим. ред.*

- сбор и консолидация информации из нескольких систем;
- первичная сортировка и маршрутизация претензий;
- стандартная переписка с клиентами и поставщиками.

Эти виды деятельности были не только трудоемкими – сотрудники описывали их как повторяющиеся, утомительные и наиболее подверженные ошибкам. «Это изматывающая работа, – сказал нам один член команды. – Я учился на специалиста по урегулированию страховых претензий, но большую часть дня провожу, копируя и вставляя информацию».

Оценка осуществимости

Не каждый трудоемкий процесс подходит для автоматизации с помощью ИИ-агентов. Мы оценивали каждую такую возможность по трем важнейшим критериям.

- *Техническая осуществимость.* Может ли текущая технология ИИ-агентов эффективно справляться с задачей?
- *Стабильность процесса.* Достаточно ли стабилен процесс для автоматизации, или требуется значительная переработка?
- *Доступность данных.* Есть ли доступ к необходимым данным в пригодном для использования формате?

Эта оценка привела нас к важному осознанию: многие из наших процессов с высокой нагрузкой были взаимосвязаны через общие источники данных и системы. Сбор информации, с которым боролись специалисты по претензиям, использовал многие из тех же источников данных, которые андеррайтеры использовали для продления полисов.

Создание бизнес-кейса для масштабирования

Инсайты, собранные за шесть недель оценочной фазы, не только помогли нам выявить возможности – они обеспечили основу для убедительного бизнес-кейса. «Данные рассказывают историю, – объяснили мы команде руководства. – И наши данные точно говорят нам, где и как ИИ-агенты могут создать наибольшую ценность».

Данные, собранные из картирования рабочей нагрузки и оценок осуществимости, легли в основу нашего бизнес-кейса. Мы структурировали его вокруг количественных и качественных преимуществ. С количественной стороны мы подсчитали, что автоматизация выявленных процессов с высокой нагрузкой позволит сэкономить примерно 45 000 человеко-часов ежегодно только в отделе претензий, что эквивалентно прямой экономии затрат в размере 3,2 млн долл. Качественные преимущества были не менее убедительными: снижение уровня ошибок, ускорение обработки претензий, улучшение удовлетворенности клиентов и повышение вовлеченности сотрудников за счет устранения повторяющихся задач.

Мы также учли затраты на внедрение, включая лицензии на технологии, ресурсы на разработку и усилия по управлению изменениями, получив ожидаемую рентабельность инвестиций (ROI) в 285 % за три года. Этот комплексный бизнес-кейс оказался решающим для получения поддержки руководства и необходимого финансирования для полномасштабного внедрения. Что

еще важнее, он установил четкие метрики успеха, которые мы могли отслеживать на протяжении всего внедрения, помогая нам поддерживать импульс и демонстрировать ценность заинтересованным сторонам на каждом этапе развертывания.

Систематический путь к масштабированию

Определив приоритетные возможности, мы установили структурированный трехфазный подход для внедрения каждого ИИ-агента в компании. Вместо того чтобы браться за все сразу, мы двигались методично через редизайн процессов¹, спринты развертывания² и миграцию в производство. Давайте рассмотрим, как это работало с нашим первым крупным внедрением – агентом по сбору и консолидации информации о претензиях.

Фаза 1. Редизайн и оптимизация процессов

«Если мы собираемся это автоматизировать, давайте убедимся, что автоматизируем правильный процесс», – стало нашей мантрой. Работая с кросс-функциональной командой специалистов по претензиям, ИТ-специалистов и экспертов по совершенствованию процессов, мы потратили три недели на подробное картирование текущего процесса. Результаты были поразительными – специалисты по претензиям обращались к семи различным системам для сбора информации, часто избыточно.

Мы переосмыслили процесс с нуля, задавая себе вопрос: «Если бы мы создавали это сегодня с ИИ-агентами, как бы это работало?» Переработанный процесс консолидировал точки доступа, стандартизировал форматы данных и создал четкие передачи между ИИ-агентами и человеческими специалистами. Мы сократили количество точек взаимодействия с системами с семи до трех, внедрив централизованное озеро данных, к которому ИИ-агент мог напрямую обращаться.

Фаза 2. Спринты развертывания

Имея переработанный процесс, мы перешли к фазе разработки, организовав работу в двухнедельные спринты. Каждый спринт был сосредоточен на предоставлении конкретной функциональности, которую можно было тестировать и совершенствовать. Для агента по сбору информации о претензиях мы структурировали шесть спринтов, каждый из которых опирался на функциональность предыдущего.

¹ Редизайн бизнес-процессов, англ. *BPR* (также известен как реинжиниринг бизнес-процессов), – это стратегический подход к управлению, направленный на фундаментальное переосмысление и переработку существующих процессов и рабочих потоков. *BPR* выходит за рамки постепенных изменений, фокусируется на радикальном улучшении эффективности, производительности, качества и удовлетворенности клиентов. – *Прим. ред.*

² Спринты развертывания – это короткие периоды времени, в течение которых команда создает и совершенствует отдельную часть продукта, включая функциональность, готовую к развертыванию. Основная идея – преобразовать большой проект на мелкие, управляемые задачи, которые можно достичь в течение короткого периода. Продолжительность спринта – обычно от 1 до 4 недель. – *Прим. ред.*

Мы вовлекали специалистов по претензиям в каждый обзор спринта, собирая их обратную связь и внося корректировки. Этот цикл быстрой итерации оказался неоценимым. Например, во время третьего спринта специалисты указали, что определенные типы претензий требуют особой обработки – чего мы изначально не учли. Мы быстро адаптировали логику агента, чтобы учесть эти исключения.

Фаза 3. Тестирование и миграция в производство

Вместо подхода «большого взрыва» мы применили стратегию постепенного развертывания.

- Неделя 1: 10 % входящих претензий направлялись через ИИ-агента.
- Неделя 2: 25 % претензий с расширенным мониторингом.
- Неделя 3: 50 % претензий с уменьшенным ручным надзором.
- Неделя 4: 75 % претензий с сохранением протоколов аудита.
- Неделя 5: полное развертывание со стандартным мониторингом.

Этот поэтапный подход позволил нам укрепить уверенность, одновременно управляя рисками. «Сначала я перепроверял все, что делал агент, – сказал нам один старший специалист по претензиям. – Но через несколько недель я доверял ему больше, чем своему собственному сбору данных».

Результаты и уроки

В течение шести месяцев мы успешно масштабировали ИИ-агентов по нескольким процессам, достигнув следующих значительных результатов:

- сокращение времени на сбор информации на 70 %;
- автоматизация 85 % стандартной переписки с клиентами;
- сокращение времени обработки претензий на 45 %.

Что еще важнее, удовлетворенность сотрудников значительно улучшилась. «Впервые за годы я провожу большую часть своего дня, действительно анализируя претензии, вместо того чтобы просто собирать информацию», – сообщил один старший специалист по претензиям.

Главные уроки нашего путешествия? Успех с ИИ-агентами – это не внедрение самых передовых технологий, а поиск правильных возможностей, где автоматизация может создать наибольшую ценность. Применяя систематический подход к внедрению и масштабированию, организации могут создавать устойчивую ценность, избегая распространенных ловушек, которые срывают многие инициативы по автоматизации.

Заглядывая в будущее, мы продолжаем развивать наш подход. Технологический ландшафт быстро меняется, регулярно появляются новые возможности. Однако фундаментальные принципы остаются прежними: начинайте с правильных возможностей, продуманно перерабатывайте процессы, внедряйте инновации систематически и всегда держите в уме человеческий элемент.

Как сказал один руководитель команды в глобальной страховой компании, «эти ИИ-агенты не заменяют нас; они наконец-то позволяют нам выполнять работу, для которой нас наняли». Возможно, это и есть конечная мера успеха в масштабировании ИИ-агентов.

ПРЕИМУЩЕСТВО ОПЫТА АВТОМАТИЗАЦИИ: ОТ АГЕНТОВ УРОВНЯ 2 К УРОВНЮ 3

В ландшафте искусственного интеллекта путь от базовой автоматизации к сложным ИИ-агентам не всегда прямой. Некоторые организации обнаруживают, что их предыдущие инвестиции в технологии автоматизации становятся неожиданными ступенями к более продвинутым внедрениям ИИ. Чтобы понять эту эволюцию, давайте рассмотрим опыт Johnson Controls International (JCI), мирового лидера в области строительных технологий и решений, на их пути трансформации.

Основа: от автоматизации к интеллекту

Когда мы впервые встретились с Рамнатом Натарджаном, который возглавляет глобальное внедрение операционного совершенства и интеллектуальной автоматизации в JCI, нас поразили масштаб их существующей инфраструктуры автоматизации. «В настоящее время мы работаем с 250 цифровыми работниками и 2000 API», – объяснил он, подчеркивая сложную среду автоматизации уровня 2 (интеллектуальная автоматизация), которая сочетает роботизированную автоматизацию процессов (RPA), управление бизнес-процессами (BPM) и различные инструменты ИИ.

Эта основа может показаться сложной технической деталью, но она представляет нечто более фундаментальное: приверженность всей организации к улучшению процессов и цифровой трансформации. Для таких компаний, как JCI, эта существующая инфраструктура не только экономия затрат, хотя они достигли значительных финансовых выгод. Речь идет о создании организационных мускулов, необходимых для внедрения и масштабирования автоматизированных решений.

Катализатор изменений

Что делает историю JCI особенно интересной – это их признание того, что, хотя их системы интеллектуальной автоматизации уровня 2 приносили ценность, они сталкивались с естественными ограничениями. Традиционные подходы к автоматизации превосходно справляются с обработкой структурированных, предсказуемых задач, но испытывают трудности с адаптивными, контекстно-зависимыми операциями, которые все чаще требуются современным бизнесу.

«Мы переходим от автоматизации конкретных задач к агентам, способным оркестрировать целые рабочие процессы», – поделился Натарджан во время нашего обсуждения. Этот сдвиг представляет основное различие между агентами уровня 2 и уровня 3. В то время как системы уровня 2 могут обрабатывать сложные, но заранее определенные сценарии, агенты уровня 3 могут понимать контекст, обрабатывать естественный язык и оркестрировать несколько инструментов для достижения более масштабных целей.

Мост между уровнями

Автоматизация уровня 2, характеризующаяся такими инструментами, как RPA и интеллектуальная автоматизация, превосходно справляется с повторяющимися, основанными на правилах задачами в четко определенных параметрах. Системы уровня 2 с их зависимостью от заранее заданных правил и структу-

рированных данных подобны высокоэффективным работникам сборочной линии. Они превосходны в своих конкретных задачах, но не могут адаптироваться к значительным изменениям без человеческого вмешательства.

Например, JCI использовала RPA для оптимизации процессов выставления счетов, значительно сократив ручные ошибки и повысив эффективность. Однако даже с этими достижениями человеческий надзор оставался критически важным компонентом. Эти системы испытывали трудности с адаптацией к динамичным, кросс-функциональным рабочим процессам или управлением исключениями, требующими тонкого принятия решений. Эта ограниченность стала очевидной в таких областях, как поддержка клиентов и полевые операции¹, где задержки и неэффективности часто возникали из-за фрагментированных процессов и зависимости от человеческого вмешательства.

Переход JCI к ИИ-агентам уровня 3 был разработан для устранения этих пробелов. Натарджан подчеркнул сдвиг в стратегии: «Мы переходим от автоматизации задач к агентам, которые могут оркестрировать целые рабочие процессы. Фокус на устранении человеческих зависимостей и достижении бесшовного выполнения процессов между функциями». Это видение потребовало переосмысления автоматизации как взаимосвязанной, адаптивной системы, а не набора изолированных задач.

Путешествие JCI к автоматизации уровня 3 иллюстрирует, как ИИ-агенты трансформируют существующие системы интеллектуальной автоматизации в мощные, адаптивные экосистемы. Речь здесь идет не о замене интеллектуальной автоматизации, а о ее улучшении и соединении. Начиная с целевых приложений – таких как управление исключениями или обработка тонких решений, – ИИ-агенты постепенно доказывают свою ценность, выстраивая доверие и прокладывая путь для более широкого развертывания.

Этот подход позволяет организациям достичь не только операционной эффективности, но и стратегической гибкости. ИИ-агенты устраняют узкие места, уменьшают зависимость от человеческого вмешательства и дают командам возможность сосредоточиться на действиях с высокой ценностью. Как кратко выразился Натарджан, «это не только об автоматизации; это о создании системы, которая адаптируется и процветает самостоятельно». Успех JCI демонстрирует, что переход к уровню 3 достижим и перспективен.

Преимущество опыта

Что делает историю JCI особенно поучительной – так это то, как их опыт с автоматизацией уровня 2 создал преимущества при внедрении агентов уровня 3. Этому способствовало несколько важнейших факторов.

1. *Готовность инфраструктуры.* Существующая на предприятии сеть API и цифровых работников обеспечила готовую основу для создания более сложных агентов. Это означало, что они не начинали с нуля, а расширяли и улучшали существующие возможности.

¹ Полевые операции – это операции или процессы, выполняемые вне офиса, на местах. Они могут включать в себя такие задачи, как техническое обслуживание, доставка, ремонт или другие виды деятельности, требующие физического присутствия за пределами центрального офиса. – *Прим. ред.*

2. *Понимание процессов.* Годы внедрения автоматизации дали им глубокие инсайты в их бизнес-процессы и то, где человеческое вмешательство наиболее критично. Как отметил Натарджан, их целью стало «заменить зависимости от человека в цикле на полностью автономных, управляемых процессами агентов».
3. *Организационная согласованность.* Пожалуй, самое важное – они уже создали организационные структуры, необходимые для внедрения и масштабирования технологических решений. Их команда из более чем 100 сотрудников, занимающихся операционным совершенствованием и автоматизацией, предоставила человеческую компетентность, необходимую для управления этой эволюцией.

Уроки, вынесенные из решения проблем

Переход не обошелся без проблем, и эти трудности предлагают ценные уроки для других организаций, рассматривающих подобные путешествия. JCI столкнулась с несколькими значительными препятствиями.

- *Сложность интеграции.* Даже с их обширным опытом соединение агентов с устаревшими системами оказалось сложным. «Обеспечение данных по регионам сложно, учитывая гетерогенные системы организации», – объяснил Натарджан. Это подчеркивает, как даже организациям со зрелыми возможностями автоматизации нужно тщательно учитывать их техническую архитектуру при переходе к более сложным агентам.
- *Ограничения поставщиков.* JCI обнаружила, что их существующие поставщики автоматизации не всегда были полностью готовы к более продвинутому внедрению агентов. Они выяснили, что недостаток глубоких интеграционных возможностей у некоторых поставщиков замедлял разработку агентов, в то время как слишком широкие определения агентов у других создавали проблемы с согласованностью. Этот опыт подчеркивает важность тщательной оценки технологических партнеров для внедрений уровня 3 независимо от существующих отношений.

Новые перспективы

Опыт JCI предполагает, что, хотя предыдущий опыт автоматизации может предоставить преимущества при внедрении агентов уровня 3, это не является обязательным условием. Ключ в понимании того, что агенты уровня 3 представляют фундаментально иной подход к автоматизации – подход, который требует тщательного учета как технических, так и организационных факторов.

Видение будущего JCI включает наличие мультиагентных систем, действующих в 2026 году, подчеркивая, что эта эволюция является частью долгого путешествия цифровой трансформации. «Агенты будут выполнять сквозные процессы, бесшовно интегрироваться и повышать автономию бизнеса», – поделился Натарджан, описывая будущее, где ИИ-агенты станут неотъемлемой частью бизнес-операций.

Важнейшие соображения для организаций

Несколько инсайтов из опыта JCI для организаций, рассматривающих свое собственное путешествие к агентам уровня 3.

- *Начинайте с четких сценариев использования.* Фокусирование JCI на поддержке клиентов, полевых операциях, корпоративных финансах и закупках предоставил четкие, ориентированные на ценность цели для внедрения агентов. Этот сфокусированный подход помогает управлять сложностью и демонстрировать получение ценности.
- *Опирайтесь на сильные стороны.* Будь то преимущества от предыдущего опыта автоматизации или другие организационные возможности, определите и используйте существующие преимущества, а не начинайте с нуля.
- *Управляйте ожиданиями.* Переход от уровня 2 к уровню 3 – это не просто техническое обновление, а фундаментальный сдвиг в том, как выполняется работа. Организации должны быть готовы как к возможностям, так и к вызовам, которые это представляет.

Более широкая перспектива

Хотя история JCI демонстрирует, как предыдущий опыт автоматизации может облегчить внедрение агентов уровня 3, важно отметить, что это не единственный путь вперед. Организации без обширного опыта автоматизации все еще могут успешно внедрять агентов уровня 3, сосредотачиваясь на четких сценариях использования и создавая необходимые организационные возможности.

Ключ в понимании того, что агенты уровня 3 представляют значительное продвижение в том, как автоматизация может служить бизнес-потребностям. Способность этих агентов понимать контекст, обрабатывать естественный язык и оркестрировать сложные рабочие процессы предлагает возможности для трансформации, которые выходят за рамки традиционных подходов к автоматизации.

Заглядывая в будущее, эволюция ИИ-агентов продолжит изменять порядок работы организации. Будь то опора на существующие возможности автоматизации или начало с нуля с более продвинутыми внедрениями, ключ к успеху лежит в понимании как технических возможностей, так и организационных изменений, необходимых для эффективного использования этих мощных инструментов.

ИСПОЛЬЗОВАНИЕ ГЕНЕРАТИВНОГО ИИ И ИИ-АГЕНТОВ ДЛЯ ХОЛИСТИЧЕСКОЙ КОРПОРАТИВНОЙ ПЕРЕСТРОЙКИ¹

Когда мы сидели в конференц-зале в Сингапуре с командой руководства глобальной производственной компании, развернулась интересная дискуссия. Технический директор настаивал на создании ИИ-агентов для автоматизации их операций, в то время как руководитель по инновациям страстно выступал за расширение возможностей сотрудников с помощью генеративных инструментов ИИ. Они не подозревали, что это кажущееся противоречие приведет нас к одному из наших самых захватывающих открытий в будущем.

¹ Холистический подход в контексте ИИ предполагает управление на всех этапах жизненного цикла искусственного интеллекта – от приема данных, оценки и одобрения до непрерывного мониторинга после развертывания. Holistic AI – платформа для управления искусственным интеллектом, которая помогает организациям внедрять и масштабировать ИИ ответственно, обеспечивая прозрачность, подотчетность и безопасность. – *Прим. ред.*

То, что мы наблюдали в течение следующих шести месяцев, стало идеальной лабораторией для понимания того, как ИИ трансформирует организации – не единым способом, а через две взаимодополняющие силы, которые при продуманном сочетании создают нечто гораздо более мощное, чем каждая из них могла бы достичь в одиночку.

Начнем с эксперимента, который мы провели с их командой продаж. Мы попросили половину команды продолжать работать как обычно, в то время как другая половина получила доступ как к генеративным инструментам ИИ, так и к базовому ИИ-агенту, продукту нашей разработки. Результаты были поразительными, но не по тем причинам, которые мы ожидали.

Дебора, одна из лучших сотрудниц, обнаружила, что полагается на ИИ-агента, который незаметно обрабатывал планирование встреч, последующие действия и обновления воронки продаж в фоновом режиме, освобождая ее время. Но что действительно привлекло наше внимание – так это то, как она использовала свое вновь освобожденное время. Она использовала генеративный ИИ для создания более убедительных предложений и персонализированных коммуникаций с клиентами. «Я наконец-то могу делать то, что всегда хотела, – сказала она нам. – Вместо того чтобы тратить часы на логистику организации встреч и пытаться стратегически думать о сделках с клиентами, я веду все больше глубоких разговоров с клиентами об их долгосрочных проблемах».

Этот опыт иллюстрировал то, что мы начали понимать как двойную трансформацию, которую ИИ обеспечивает в организациях. Представьте это как обучение вождению с автоматической коробкой передач и GPS. Автоматическая коробка передач (как ИИ-агенты) справляется с механической сложностью, в то время как GPS (как генеративный ИИ) улучшает вашу способность ориентироваться и принимать лучшие решения. Вместе они не просто делают вас более эффективным водителем – они трансформируют весь опыт вождения.

Слияние генеративного ИИ и ИИ-агентов представляет инновационную возможность для организаций. Мы обнаружили, что этот двойной подход создает нечто большее, чем сумма его частей. Вместе эти технологии не только переопределяют способ работы компаний, но и дают сотрудникам возможность применять их наиболее человеческие качества – креативность, эмпатию, критическое мышление, и обеспечивают их личностный рост. Этот двойной подход способствует созданию рабочей силы, способной достигать исключительных результатов, одновременно переопределяя будущее работы.

Двойная роль ИИ в корпоративной трансформации

Инновационный потенциал ИИ можно в целом разделить на два взаимозависимых пути.

Первый – это генеративный ИИ, технология, которая улучшает человеческие способности, позволяя сотрудникам устанавливать связи с другими, критически мыслить и творить с беспрецедентной скоростью и глубиной. Инструменты генеративного ИИ трансформируют такие задачи, как составление коммуникаций, создание контента или анализ сложных данных, в моменты расширения возможностей. С этими инструментами сотрудники становятся «сверхлюдьми», оснащенными сверхспособностями, усиливающими их природные возможности, делающими их способными к решению задач, ранее для них недоступных.

Второй путь – это ИИ-агенты, системы, разработанные для обработки повторяющихся, скучных, сложных или даже опасных задач. Эти агенты автоматизируют процессы, экономят время и уменьшают количество ошибок, управляя утомительными процедурами. Беря на себя эти роли, ИИ-агенты освобождают сотрудников для сосредоточения на более значимых вещах, будь то стратегический вклад в их профессиональные роли или достижение личных целей и обогащение личного опыта. Вместе эти технологии позволяют компаниям достичь двух целей: масштабирования эффективности и раскрытия полного человеческого потенциала их рабочей силы.

Усиление человеческих качеств с помощью генеративного ИИ

По нашему опыту, генеративный ИИ стал демократизирующей силой, позволяя сотрудникам выполнять задачи более эффективно и креативно. В отличие от предыдущих волн ИИ, генеративный ИИ активно дополняет человеческий интеллект. Мы видели, например, как маркетинговый специалист, использующий генеративный ИИ, может быстрее создавать привлекательные кампании, в то время как менеджер может анализировать данные производительности с большей тонкостью, чтобы принимать более разумные и быстрые решения.

Парадокс, который мы наблюдали, заключается в том, что, хотя более 90 % компаний осторожно экспериментируют с генеративным ИИ, 75 % работников интеллектуального труда по всему миру уже используют его ежедневно, многие прибегая к несанкционированным инструментам. Это принятие снизу вверх демонстрирует интуитивную привлекательность генеративного ИИ – он прост в использовании, дает немедленные результаты и бесшовно интегрируется в рабочие процессы. Сотрудники опережают своих работодателей, демонстрируя трансформацию снизу вверх, движимую индивидуумами, а не корпоративными мандатами.

Этот сдвиг подчеркивает необходимость для компаний масштабировать принятие генеративного ИИ. Предоставляя структурированное обучение, открытые форумы для обмена сценариями использования и платформы для сотрудничества, предприятия могут направить это органическое принятие в измеримые улучшения. Например, мы видели, как организации проводят еженедельные сессии, где сотрудники делятся тем, как они используют генеративный ИИ, создавая культуру коллективного обучения и инноваций.

Генеративный ИИ не просто экономит время – он создает время для активностей с более высокой ценностью. Мы работали с командами, где дизайнер продуктов использует ИИ для быстрого прототипирования идей, оставляя больше времени для мозгового штурма и креативного исследования. Команда продаж, освобожденная от ручного составления писем, может вместо этого сосредоточить свою энергию на углублении отношений с клиентами. Генеративный ИИ – это не замена людей, это их возвышение.

Автоматизация сложных процессов и задач с помощью ИИ-агентов

По нашему опыту, ИИ-агенты выступают в роли молчаливых партнеров в корпоративной трансформации, демонстрируя выдающиеся результаты в обла-

стях, требующих точности, скорости и надежности. Мы наблюдали, как они справляются с повторяющимися задачами, такими как обработка счетов, координация логистики или проверки соответствия, часто работая через организационные барьеры для оптимизации процессов от начала до конца.

Например, в нашей работе с финансовой компанией внедрение ИИ-агентов для управления операциями по выставлению счетов привело к значительным улучшениям. Задачи, которые ранее требовали участия нескольких отделов, – валидация счетов, отслеживание производительности поставщиков и устранение расхождений, – были бесшовно выполнены одним ИИ-агентом. Эта автоматизация сократила время обработки на 40 % и устранила 85 % ошибок, освобождая сотрудников для сосредоточения на стратегии и взаимодействии с клиентами.

Однако влияние ИИ-агентов выходит далеко за рамки увеличения эффективности. Автоматизируя рутинные задачи, компании могут перераспределять человеческие усилия на области, где проявляются креативность, эмпатия и принятие нестандартных решений. Сотрудники, ранее утопавшие в повторяющихся задачах, могут вместо этого сосредоточиться на решении проблем, наставничестве коллег или построении более крепких отношений с клиентами.

Судя по нашим наблюдениям, этот подход требует стратегической инициативы сверху вниз. В отличие от генеративного ИИ, который процветает на индивидуальных экспериментах, развертывание ИИ-агентов требует тщательного планирования, координации между отделами и надежного управления. Организации должны определить четкие цели, обеспечить целостность данных и разработать агентов, которые бесшовно интегрируются в существующие рабочие процессы, чтобы реализовать их полный инновационный потенциал.

Единое видение: генеративный ИИ и агенты ИИ работают вместе

Рассмотрим нашу недавнюю работу с глобальной производственной компанией. Когда мы впервые начали обсуждать инновацию ИИ с их командой руководства, они попали в то, что мы называем «ловушкой или-или», полагая, что им нужно выбирать между инвестициями в генеративные инструменты ИИ для своей рабочей силы или разработкой ИИ-агентов для автоматизации процессов. Вместе мы обнаружили, что настоящая магия происходит, когда оба подхода работают в гармонии.

Истинная сила ИИ заключается в его интеграции. Генеративный ИИ и ИИ-агенты – это не конкурирующие технологии, а взаимодополняющие силы, движущие единой визией. Рассмотрим отдел кадров, проходящий трансформацию.

- *Генеративный ИИ* помогает специалистам по кадрам разрабатывать персонализированные планы обучения, анализировать данные о вовлеченности сотрудников и создавать эффективные стратегии коммуникации.
- *Агенты ИИ* автоматизируют рутинные задачи, такие как обработка заработной платы, управление льготами и координация графиков.

Вместе эти технологии позволяют отделу кадров сосредоточиться на том, что действительно важно: построении отношений, содействии росту и создании среды, где сотрудники процветают.

Этот холический (целостный) подход трансформирует не только рабочие процессы, но и мышление. Сотрудники видят технологию не как угрозу, а как усилитель, улучшающий их способности и позволяющий заниматься деятельностью, приносящей ценность и удовлетворение.

От теории к практике: создание фреймворка трансформации

По нашему опыту, для успешной реализации этого двойного подхода организации должны принять структурированный фреймворк трансформации¹.

1. *Начните с генеративного ИИ.* Поощряйте сотрудников экспериментировать с генеративными инструментами ИИ в их повседневных задачах. Предоставляйте возможность обучения, стимулируйте принятие и создавайте форумы для обмена лучшими практиками. Эта стратегия снизу вверх создает энтузиазм и доверие к ИИ, одновременно обеспечивая немедленный прирост производительности.
2. *Масштабируйте с ИИ-агентами.* Используйте подход сверху вниз для развертывания ИИ-агентов для автоматизации повторяющихся и сложных процессов. Начинайте с пилотных проектов для отработки внедрения и постепенно масштабируйте их по отделам. Вовлекайте сотрудников в разработку агентов, которые дополняют их рабочие процессы, воспитывая чувство владения и контроля.
3. *Содействуйте культуре обучения и адаптации.* Инвестируйте в непрерывное образование, чтобы помочь сотрудникам интегрировать ИИ в свои рабочие роли. Подчеркивайте истории успеха и поощряйте команды экспериментировать, учиться и внедрять инновации.
4. *Согласуйте метрики со стратегическими целями.* Определите важнейшие показатели эффективности (KPI), которые измеряют как приросты эффективности, так и ориентированные на человека результаты, такие как удовлетворенность сотрудников, креативность и сотрудничество. Регулярно пересматривайте эти метрики, чтобы обеспечить соответствие трансформации организационным целям.
5. *Приоритизируйте управление и этику.* Установите структуры управления, которые обеспечивают этичность использования ИИ, конфиденциальность данных и прозрачность. Создавайте форумы для сотрудников, чтобы они могли высказывать опасения и участвовать в формировании пути трансформации.

¹ Фреймворк трансформации в контексте ИИ и технологий – это структурированная методология или система, которая направляет процесс преобразования бизнес-процессов, систем или организаций с использованием ИИ и автоматизации. Он включает принципы, инструменты и этапы для внедрения изменений, таких как автоматизация задач (например, Sales Info Agent), оптимизация рабочих процессов или развитие цифровых навыков (как в SkillsFuture). Фреймворк обеспечивает координацию, управление и адаптацию, минимизируя риски и повышая эффективность трансформации. – *Прим. ред.*

Когда агенты выходят из-под контроля:

СОЗДАНИЕ НЕОБХОДИМЫХ ЗАЩИТНЫХ МЕР ДЛЯ СИСТЕМ ИИ

В 2010 году задолго до разговоров о ChatGPT или автономных агентах Уолл-стрит молниеносный обвал рынка. Всего за 36 мин автоматизированные торговые алгоритмы уничтожили почти 1 трлн долл. рыночной стоимости. Хотя рынок в конечном итоге восстановился, этот инцидент дал ранний взгляд на то, что может пойти не так, когда мы даем ИИ-агентам слишком много автономии без надлежащих защитных мер.

Это не должно было случиться. Алгоритмы делали именно то, для чего были запрограммированы, – покупали и продавали на основе рыночных условий. Но их взаимодействие друг с другом создало неожиданную петлю обратной связи с ботами, участвующими в том, что Комиссия по ценным бумагам и биржам позже описала как «горячий картофель», – торговле контрактами туда-сюда по все более волатильным ценам. Ни одна ИИ-сущность не была виновата, но вместе они почти обрушили рынок.

Мы видели, как эта история повторяется по-разному по мере того, как ИИ-агенты становятся более сложными и распространенными. Во время нашей работы с крупным финансовым учреждением, внедряющим своих первых ИИ-управляемых торговых агентов, мы допустили похожую ошибку. Система была спроектирована для оптимизации торговых моделей, но мы не учли должным образом, как она будет взаимодействовать с другими автоматизированными торговыми системами на рынке. В течение нескольких часов после развертывания агент инициировал серию быстрых сделок, которые, хотя и были технически прибыльными, вызвали красные флаги в системах регуляторного соответствия. Нам пришлось быстро отключить его и пересмотреть наш подход.

Эти опыты научили нас важному уроку: когда дело доходит до ИИ-агентов, даже хорошо продуманные разработки могут привести к непреднамеренным последствиям. Вызов не только в том, чтобы заставить агентов работать правильно, – а в том, чтобы они работали безопасно и этично в сложной экосистеме человеческих и искусственных участников.

Когда хорошие агенты становятся плохими

Рассмотрим, что произошло с Air Canada в начале 2024 года. Они развернули чат-бота службы поддержки клиентов, который был разработан, чтобы быть полезным и информативным. Бот имел доступ к веб-сайту Air Canada и был проинструктирован помогать клиентам с их запросами. Достаточно просто, верно? Однако дела пошли наперекосяк, когда бот начал предоставлять информацию о льготных тарифах по случаю утраты, которые были гораздо более щедрыми, чем фактическая политика Air Canada. Когда клиенты пытались воспользоваться этими тарифами, Air Canada пыталась отказать им, утверждая, что заявления бота не были обязательными. Они проиграли этот спор в суде, где трибунал постановил, что компания несет ответственность за обещания своего ИИ-агента.

Этот инцидент подчеркивает фундаментальный вызов с ИИ-агентами: они могут действовать независимо в способах, которые их создатели не

предвидели и не могут легко контролировать. Бот Air Canada не ломался – он делал именно то, для чего был запрограммирован: помогать клиентам. Но его интерпретация «помощи» привела к обязательствам, которые компания не авторизовала.

Мы сталкивались с похожими проблемами в нашей собственной работе. Помогая розничному клиенту внедрить ИИ-агента для управления запасами, мы обнаружили, что агент начал автоматически размещать заказы на продукты, запасы которых снизились. На бумаге это казалось логичным. На практике это привело к массовому перезаказу сезонных товаров, которые намеренно выводились из оборота. Агент не понимал более широкий контекст сезонных розничных циклов и стратегии управления запасами.

Новая граница риска

Что отличает современных ИИ-агентов от традиционной автоматизации? Ответ заключается в трех важнейших характеристиках, которые мы наблюдали в наших внедрениях по разным отраслям.

Во-первых, современные ИИ-агенты могут интерпретировать информацию и действовать на основе высокоуровневых, часто расплывчатых целей. В отличие от традиционного программного обеспечения, которое следует жестким правилам, эти агенты могут взять общую инструкцию, например «улучшить удовлетворенность клиентов», и самостоятельно определить, как этого достичь. Эта гибкость мощна, но опасна – как в случае с ботом Air Canada, они могут выбрать пути, которые технически достигают цели, но создают другие проблемы.

Во-вторых, они могут взаимодействовать с миром беспрецедентными способами. Они могут обращаться к базам данных, отправлять электронные письма, размещать заказы и даже контролировать физические системы. Один производственный клиент, с которым мы работали, внедрил ИИ-агента для оптимизации их производственной линии. Агент имел возможность регулировать настройки машин в реальном времени на основе метрик качества. Хотя это привело к повышению эффективности, это также приводило к внезапным изменениям, которые сбивали с толку и раздражали человеческих операторов, которые не могли предсказать или понять решения агента.

В-третьих, эти агенты могут работать неограниченно долго без прямого надзора. Они не уходят с работы и не делают перерывов, и они могут продолжать выполнять свои запрограммированные цели долго после того, как первоначальные условия, побудившие к их созданию, изменились. Эта стойкость может быть особенно проблематичной, когда агенты работают в динамичных средах, где цели и ограничения во временном развитии эволюционируют.

Создание необходимых защитных мер

Через наш опыт и ошибки мы разработали фреймворк для внедрения необходимых защитных мер для ИИ-агентов. Это не просто теоретические руководства – это жизненные требования, которые мы усвоили на собственном горьком опыте.

Защитные меры управления транзакциями

Первая линия защиты – это надежное управление транзакциями. Это означает внедрение четких ограничений и механизмов надзора для любого агента, который может принимать финансовые или ресурсные обязательства. Мы теперь всегда рекомендуем следующее:

- жесткие ограничения на размеры и частоту транзакций;
- несколько уровней одобрения для транзакций, превышающих определенные пороговые значения;
- системы мониторинга в реальном времени, которые могут обнаруживать необычные закономерности;
- четкие аудиторские следы для всех действий агентов.

Один розничный клиент, с которым мы работаем, внедрил эти защитные меры после того, как их агент управления запасами вышел из-под контроля. Теперь любой заказ выше определенной суммы требует человеческого одобрения, и система автоматически отмечает необычные шаблоны заказов для проверки. Это предотвратило несколько потенциальных инцидентов перезаказа, сохраняя при этом преимущества эффективности автоматизации.

Этические принципы и соблюдение нормативов

Этика не может быть запоздалой мыслью в разработке агентов. Мы научились встраивать этические ограничения непосредственно в процессы принятия решений агента. Это включает следующее:

- четкие определения приемлемых и неприемлемых действий;
- регулярные этические проверки поведения агентов;
- механизмы, позволяющие заинтересованным сторонам оспаривать решения агентов;
- требования прозрачности для принятия решений агентами.

Финансовое учреждение, о котором мы упоминали ранее, теперь требует, чтобы все их торговые агенты проходили регулярные этические аудиты, исследуя не только соблюдение регуляций, но и более широкое влияние их торговых моделей на стабильность рынка.

Контроль безопасности

Защитные меры безопасности критически важны, особенно для агентов, которые контролируют физические системы или принимают решения, влияющие на безопасность человека. Важнейшие элементы включают следующее:

- процедуры аварийного отключения;
- регулярные проверки и подтверждения безопасности;
- резервные системы мониторинга;
- четкие цепочки ответственности за надзор над безопасностью.

Производственный клиент, с которым мы работали, внедрил систему «человеческого переопределения» после нескольких близких к авариям случаев с их агентом оптимизации производственной линии. Операторы теперь могут мгновенно приостановить любые изменения, инициированные агентом, если они замечают потенциальные проблемы безопасности.

Защита конфиденциальности

Защитные меры конфиденциальности становятся все более важными, поскольку агенты обрабатывают все больше чувствительных данных. Основные способы защиты включают следующее:

- строгий контроль доступа к данным;
- регулярные оценки попыток воздействия на конфиденциальность;
- четкие политики хранения и удаления данных;
- механизмы обработки запросов на персональные данные.

Мы усвоили этот урок на горьком опыте, когда агент службы поддержки клиентов, которого мы внедрили, начал хранить подробные журналы взаимодействий с клиентами без надлежащего контроля конфиденциальности. Теперь мы внедряем защиту конфиденциальности на стадии разработки с четкой политикой того, какие данные могут быть собраны и как они должны обрабатываться.

Глядя вперед: будущее безопасности агентов

По мере того как ИИ-агенты становятся более сложными и распространенными, важность этих защитных мер будет только расти. Мы уже видим появление того, что мы называем «экосистемами агентов» – сетями ИИ-агентов, взаимодействующих друг с другом и с человеческими системами все более сложными способами.

Вызов, предстоящий впереди, не только в контроле отдельных агентов, но в понимании и управлении такими экосистемами. Это требует новых подходов к безопасности и управлению, которые могут справляться с поведением, возникающими из взаимодействий агентов. Мы сейчас работаем с несколькими клиентами над разработкой фреймворков для управления этими экосистемами, но мы также достаточно скромны, чтобы признать, что мы все учимся на ходу.

Будущее ИИ-агентов одновременно захватывающее и пугающее. Хотя эти технологии предлагают огромный потенциал для повышения эффективности и инноваций, они также представляют риски, которые мы только начинаем понимать. Защитные меры, которые мы обсудили, не совершенны, но они представляют наше лучшее текущее понимание того, как использовать мощь ИИ-агентов, защищаясь от опасностей, которые они потенциально несут.

Ключ в том, чтобы оставаться бдительными и адаптивными, учась на каждом новом вызове и постоянно улучшая наши защитные меры. Как мы часто говорим нашим клиентам, цель не в том, чтобы устранить все риски, – это невозможно. Вместо этого мы стремимся создать системы, которые могут безопасно терпеть неудачи и учиться на своих ошибках, как это делаем мы.

Глава 12

Пример из практики и сценарии использования агентов в различных отраслях

В заключение нашего исследования практической реализации агентов искусственного интеллекта в данной главе мы объединили все, что узнали ранее об управлении изменениями, масштабировании и выполнении задач. Мы рассмотрим это через две мощные призмы. Во-первых, мы глубоко погрузимся в трансформационное путешествие компании Pets at Home, которая является примером того, как организации могут успешно внедрять агентов ИИ в масштабе, сохраняя при этом важный человеческий подход. Во-вторых, мы рассмотрим разнообразную коллекцию сценариев применения в различных отраслях и функциях, демонстрирующих универсальность и влияние агентов ИИ в реальных условиях. Эти примеры не просто истории успеха, а эскизы для вашего собственного пути трансформации, предлагающие практические идеи и проверенные подходы, которые вы можете адаптировать для своей организации.

ПРИМЕР ИЗ ПРАКТИКИ. НОВАТОРСКАЯ ТРАНСФОРМАЦИЯ КОРПОРАТИВНОГО АГЕНТА НА ОСНОВЕ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА: PETS AT HOME

В быстро развивающемся ландшафте трансформации корпоративного ИИ мы с особым энтузиазмом делимся историей компании Pets at Home, которую мы считаем одним из мировых пионеров в масштабном внедрении агентного ИИ. Их достижения говорят сами за себя – от фонового цифрового писаря, который с точностью до 99,6 % транскрибирует ветеринарные консультации,

до автономных агентов, которые радикально изменили обнаружение мошенничества в их розничных операциях. Под дальновидным руководством Саймона Эллиса, главы отдела трансформации ИИ и корпоративной архитектуры, компания приступила к уникальной трансформации, которая устанавливает новые стандарты использования агентов ИИ в предприятиях.

Как крупнейшая в Великобритании компания по уходу за домашними животными, имеющая около 450 розничных магазинов, 450 ветеринарных практик и комплексную службу груминга, обслуживающую 17 000 домашних животных еженедельно, путь Pets at Home предлагает ценные уроки по практической реализации систем агентов ИИ в масштабах предприятия.

Вызов: унификация сложного предприятия

Когда Эллис присоединился к Pets at Home, он столкнулся с проблемой, характерной для многих крупных предприятий: операционные силосы¹. Различные бизнес-единицы компании – розничные магазины, ветеринарные практики, службы груминга и онлайн-операции – работали независимо, создавая разрозненный опыт как для клиентов, так и для сотрудников. С более чем 8 млн клиентов в программе Pets Club и данными о 10 млн домашних животных Эллис увидел огромную возможность более эффективно использовать эту информацию по всей организации.

Стратегическое видение: за пределами простой автоматизации

Трансформация Pets at Home выделяется своим смелым видением трансверсальных агентов ИИ². Вместо того чтобы рассматривать внедрение ИИ как серию изолированных проектов автоматизации, они представляют будущее, где агенты ИИ станут основным интерфейсом между компанией и ее заинтересованными сторонами³. Эллис описывает их амбициозное видение: «Наше видение – создать цифрового помощника ИИ для каждого нашего клиента... Если Паскаль приходит в Pets at Home, неважно, хотите ли вы изучить продукт, про-

¹ Операционный силос – это термин, обозначающий ситуацию в организации, когда различные подразделения, отделы или процессы работают изолированно друг от друга с минимальным взаимодействием или обменом информацией. Это приводит к фрагментации процессов, неэффективности, дублированию усилий и разрозненному опыту для клиентов или сотрудников. Термин происходит от английского слова *silo* (хранилище для зерна), которое метафорически описывает изолированные «башни» внутри компании, где данные, ресурсы или знания не передаются между подразделениями, что затрудняет целостное управление или использование данных. – *Прим. ред.*

² Трансверсальные агенты ИИ – это ИИ-агенты, которые функционируют как интегрирующий элемент, связывающий различные подразделения, процессы и заинтересованные стороны компании, вместо того чтобы быть ограниченными отдельными автоматизированными задачами или изолированными проектами. – *Прим. ред.*

³ Персональные консьержи ИИ, как ожидается, будут внедрены во многих секторах услуг, см. Стефани Лю, Хадиджа Али Вакил, Николас Смит, Ройя Садат Алавипур, Чунхао (Виктор) Вэй, Йохен Вирц (2024), «Консьерж ИИ в пути клиента: что это такое и как он может добавить ценность клиенту?» *Journal of Service Management*, Vol. 35, No. 6, 136–158, <https://doi.org/10.1108/JOSM-12-2023-0523>.

верить симптомы онлайн, потому что вашему питомцу нездоровится, узнать, где ваш заказ, или управлять подпиской, – по сути, у Паскаля будет цифровой помощник, который знает вас и ваших питомцев».

Эллис далее объясняет, как это видение трансформирует традиционные цифровые взаимодействия: «Эти агенты, эти персонализированные агенты – это то, что действительно изменит рынок розничной торговли в ближайшие 3, 4 или 5 лет. Я думаю, что розничной торговле MDH стоит беспокоиться, потому что вы больше не будете заходить на их веб-сайт». Это представляет собой фундаментальный сдвиг в том, как компании взаимодействуют с клиентами, переходя от традиционных каналов к персонализированным агентам ИИ как основной точке контакта.

Стратегия внедрения:

начать с малого, но думать масштабно

Стратегия внедрения Pets at Home демонстрирует несколько важнейших принципов, которые мы считаем главными для успешной трансформации корпоративного ИИ.

1. *Поддержка руководства и стратегическое соответствие.* Трансформация началась с мощной поддержки сверху, включая председателя совета директоров, который рассматривал ИИ как «следующую промышленную революцию». Эта поддержка руководства оказалась решающей для продвижения внедрения по всей организации. Вместо создания крупных комитетов для выявления возможностей они сосредоточились на небольших инициативах с руководителями-спонсорами, страстно желающими проводить изменения.
2. *Фундамент прежде всего.* Перед внедрением продвинутых решений ИИ компания инвестировала в создание надежной инфраструктуры данных на платформе Azure. Эта инфраструктура объединила данные из различных операций, создав прочную основу для инициатив ИИ. Они осознали, что для эффективной работы агентов ИИ необходимы хорошо организованные структурированные и неструктурированные данные.
3. *Доказательство ценности через целевые пилотные проекты.* За единым клиентским опытом Эллис представляет сеть специализированных агентов, работающих вместе: «За кулисами может быть множество агентов – ветеринарный агент, агент службы поддержки клиентов, агент розничных продаж». Аналогично для сотрудников «мы также создаем помощника для коллег», который предоставляет персонализированную поддержку в зависимости от их роли и компетентности. Например, «если я работаю в магазине и специализируюсь на аквариумах, он скажет: “Эй, Саймон, я знаю, что ты специалист по аквариумам, вот все последние операционные процедуры”».

Первым крупным внедрением стал фоновый цифровой секретарь для ветеринарных практик, который автоматически транскрибирует консультации и создает клинические заметки. Этот пилотный проект продемонстрировал немедленную ценность, стандартизив документацию и повысив эффективность, сохраняя при этом человеческий контроль над критическими медицинскими решениями.

Масштабирование через платформы Low-Code/No-Code

Одним из наиболее инновационных аспектов трансформации Pets at Home – и это особенно перекликается с нашим опытом в этой области – является их подход к масштабированию разработки агентов ИИ. Вместо того чтобы полагаться исключительно на традиционную разработку программного обеспечения, они использовали Microsoft Copilot Studio для демократизации создания агентов. Энтузиазм Элвиса заразителен, когда он описывает создание двух прототипов агентов за одно утро с использованием инструментов с низким кодом, демонстрируя потенциал для быстрого развертывания и экспериментов¹.

Этот подход решает одну из основных проблем трансформации корпоративного ИИ: масштабируемость разработки. Позволяя экспертам предметной области создавать и модифицировать агентов через интерфейсы с низким кодом, Pets at Home ускоряет трансформацию, сохраняя качество и согласованность.

Ключевые сценарии применения и результаты

Рассмотрим некоторые из наиболее интересных внедрений, которые мы наблюдали в Pets at Home, где агенты ИИ действительно меняют повседневные операции.

Агент обнаружения мошенничества

Автономный агент для обнаружения мошенничества наглядно демонстрирует инновационную силу ИИ в решении сложных бизнес-задач. Кей Биркби, старший менеджер по предотвращению мошенничества, поделилась ярким примером: агент может заметить, когда одна и та же фотография поврежденной упаковки используется несколько раз разными людьми, пытающимися получить возмещение, – шаблон, который людям практически невозможно обнаружить вручную. Что особенно захватывает – так это то, как система выходит за рамки простого обнаружения мошенничества; она также помогает выявлять реальные проблемы с продуктами, когда поступает множество подлинных жалоб, превращая обнаружение мошенничества в ценный инструмент для улучшения качества.

Ассистент клинической документации

Мы особенно впечатлены тем, как фоновый цифровой секретарь изменил операции ветеринарных практик. Система достигает замечательной точности транскрипции 99,6 % с использованием стандартных микрофонов для ПК, даже при фоновом шуме – достижение, которое превзошло первоначальные ожидания команды. Но вот что действительно нас волнует: помимо простой транскрипции, она стандартизирует медицинское кодирование и документацию по всем практикам, создавая согласованность там, где раньше

¹ Low-Code- и No-Code-платформы – это инструменты разработки, позволяющие создавать приложения с минимальным количеством ручного программирования или вовсе без него. Вместо написания кода пользователи работают с визуальными интерфейсами, где можно «собирать» приложения из готовых блоков, как из конструктора. – *Прим. ред.*

отдельные клиницисты могли кодировать по-разному. Эта стандартизация привела к неожиданному бонусу: она генерирует структурированные данные более высокого качества, которые могут использоваться для машинного обучения и предсказательных моделей, создавая положительный цикл улучшения ухода за пациентами.

Агент интеграции страховки

В качестве блестящего примера практического применения ИИ компания разрабатывает агента, который плавно интегрируется с полисами страхования домашних животных во время ветеринарных консультаций. Этот агент будет автоматически проверять покрытие полиса, пока ветеринар обсуждает варианты лечения с владельцами питомцев, решая распространенную проблему, когда ни ветеринары, ни владельцы питомцев не всегда четко понимают, какие процедуры покрываются. Эта информация в реальном времени помогает как практикам, так и владельцам питомцев принимать более обоснованные решения о вариантах ухода.

Ассистент для сотрудников магазина

Одно из самых вдохновляющих внедрений – это персонализированный ИИ-ассистент для сотрудников розничной торговли, который адаптируется к конкретным ролям и квалификациям. Представьте, что вы сотрудник магазина, специализирующийся на аквариумах, и у вас есть ассистент ИИ, который знает вашу специализацию и проактивно предоставляет соответствующие операционные процедуры и информацию о продуктах. Эта система не только повышает эффективность обучения, но и позволяет сотрудникам предоставлять исключительно квалифицированное обслуживание клиентов.

Полученные уроки и лучшие практики

Анализируя путь Pets at Home, мы выявили несколько увлекательных идей, которые, как мы считаем, имеют решающее значение для любой организации, начинающей трансформацию с агентами ИИ.

Критическая роль качества данных

Команда Эллиса сделала открытие, которое мы считаем особенно важным: успех агентов ИИ в значительной степени зависит от качества как структурированных, так и неструктурированных данных. Они узнали на собственном опыте, что, хотя сотрудники могли легко справляться с конфликтами между различными документами или политиками, агенты ИИ из-за этих несоответствий испытывали определенные трудности. Эллис делится замечательным наблюдением: «Если вы предоставите SharePoint директорию через Copilot для LLM и зададите вопрос, она найдет то, что нужно, но, если есть два противоречивых фрагмента, она либо выберет первый, либо второй, либо смешает оба». Это наблюдение настолько мощное, потому что оно бросает вызов нашему традиционному фокусу на структурированных данных и заставляет нас думать более целостно об управлении знаниями в масштабах предприятия.

Сила поддержки руководства

Одним из самых вдохновляющих аспектов переформатирования Pets at Home является исключительно сильная поддержка руководства. Видение председателя совета директоров об ИИ как о «следующей промышленной революции» не просто задавало тон – оно катализировало действия по всей организации. Что особенно умно в их подходе – так это то, как они сосредоточились на небольших инициативах с энтузиастами-руководителями вместо создания крупных комитетов. Этот целевой подход позволил им быстро двигаться и демонстрировать ценность, создавая непреодолимый импульс для более крупных инноваций. Это стратегия, которая, как мы видели, работает неоднократно, но редко исполняется с такой ясностью цели.

Эволюция управления затратами

Одной из самых интригующих проблем, с которыми они столкнулись – и которую мы наблюдаем по всей отрасли, – является эффективное управление затратами на ИИ. Эллис делает интересное замечание о том, как эксплуатация агентного ИИ может быть дороже, чем стандартная автоматизация, из-за более высокого использования токенов и требований к обработке. Каждый агент, по сути, является уникальным, что делает традиционные модели ценообразования неадекватными. Нам особенно интересно, как они работают с поставщиками над созданием новых корпоративных фреймворков ценообразования, которые лучше отражают уникальную природу развертывания агентов ИИ, – работа, которая, вероятно, принесет пользу всей отрасли.

Баланс между автоматизацией и человеческим контролем

Их тонкий подход к балансированию автоматизации и человеческого контроля – это мастер-класс по продуманному внедрению ИИ. В ветеринарной практике они обеспечивают человеческий контроль над всем контентом, созданным ИИ, в то время как в розничных операциях допускают больше автоматизации. Как метко выразился Эллис, «везде, где у нас есть опасения по поводу точности и релевантности ответа, человек должен оставаться в процессе». Это тонкое понимание того, когда автоматизировать, а когда дополнять человеческие способности, демонстрирует мудрость, которая приходит от глубокого взаимодействия с технологией ИИ.

Влияние Low-Code разработки

Возможно, одним из самых захватывающих аспектов их трансформации является их опыт работы с Microsoft Copilot Studio, который раскрыл революционный потенциал низкокодowych платформ для ускорения развертывания агентов ИИ. Однако эта легкость разработки создала увлекательные новые вызовы в области управления и финансового контроля. Наблюдение Эллиса действительно резонирует с нашими: эти платформы «так легко развернуть и использовать... и так легко нарастить затраты». Их инновационный ответ заключался в разработке фреймворков управления, которые сохраняют преимущества демократизированной разработки агентов ИИ, при этом контролируя затраты и качество – баланс, который, как мы считаем, станет все более важным по мере распространения этих технологий.

Следующая волна инноваций для Pets at Home

Исследуя новаторскую трансформацию Pets at Home, мы не можем не быть воодушевлены их видением будущего. Команда Эллиса не просто внедряет сегодняшние технологии – они активно формируют, как будет выглядеть корпоративный ИИ в ближайшие годы. Работая напрямую с командами разработчиков Microsoft в Ирландии и Сиэтле, они раздвигают границы возможного с агентами ИИ в масштабах предприятия способами, которых мы раньше не видели.

Что действительно нас волнует в инициативах Pets at Home, устремленных в будущее, – это три инновационных направления, которые команда Эллиса определила на предстоящий год. Рассмотрим каждое из них.

Эволюция памяти

Команда решает одну из самых сложных задач агентов ИИ – возможности памяти. Речь идет не просто о хранении информации, а о создании ассистентов ИИ, которые действительно запоминают и учатся на каждом взаимодействии. Хотя Эллис признает, что современные решения с использованием инструментов, таких как Cosmos DB, являются временными, его команда разрабатывает подходы, которые позволяют создать более сложную персонализированную помощь. Это продвижение имеет решающее значение для создания глубоко персонализированных опытов ИИ, которые ощущаются подлинно человеческими.

Мультиагентная автономия

Возможно, наиболее новаторский аспект их работы заключается в мультиагентных автономных взаимодействиях. Они уже тестируют коммуникации между агентами без участия человека, но делают это так, чтобы сохранять управление и контроль. Как объясняет Эллис, «мы работаем с ними над их мультиагентными прототипами сейчас... мы начинаем тестировать взаимодействие агентов без человека в процессе». Что делает это особенно примечательным – так это то, что они достигают этого в среде с низким кодом, делая это доступным для более широкого круга организаций.

Периферийный ИИ и персональная робототехника

Команда ожидает крупный прорыв в персональной робототехнике и робототехнике на периферии человека в сочетании с малыми языковыми моделями, работающими на устройствах. Эта комбинация может коренным образом изменить наше взаимодействие с ИИ в физических пространствах. Это подход, который приближает ИИ к точке взаимодействия, сохраняя при этом безопасность и контроль на уровне предприятия.

Трансформация розничной торговли навсегда

То, что действительно захватывает наше воображение, – это провокационное видение Эллиса о будущем розничной торговли. Он предсказывает не что иное, как фундаментальный сдвиг в том, как потребители взаимодействуют с бизнесом. «Вы больше не будете заходить на веб-сайт», – утверждает он с уверенностью. Вместо этого клиенты будут просто говорить своим ассистентам ИИ, что им нужно: «Эй, Джемини, иди и купи мне что-нибудь».

Это не просто спекуляция – они уже создают инфраструктуру для поддержки этого видения. Команда Эллиса выявила более 140 сценариев применения агентов ИИ в своей организации, демонстрируя огромный потенциал для трансформации. Что особенно увлекательно – так это их подход к масштабированию, который фокусируется не только на сокращении затрат, но и на генерации доходов. Как отмечает Эллис, «если вы сосредоточитесь на возможностях, которые направлены на рост доходов, не имеющий верхней границы, это принесет больше пользы. Экономия на затратах всегда имеет предел».

Проблема масштабирования

Одним из самых интригующих аспектов их пути является то, как они решают проблемы масштабирования агентов ИИ по всему предприятию. Команда разработала инновационные подходы к управлению критическими аспектами, такими как:

- согласованность данных в базах знаний;
- интеграция с существующими системами;
- управление затратами в быстро меняющемся ландшафте ценообразования;
- управление демократизированной разработкой ИИ.

Взгляд в будущее

Эллис описывает темпы изменений как следующие за «двойной экспоненциальной кривой¹» с развитием, происходящим с беспрецедентной скоростью. «Каждые 3 месяца, каждые 6 месяцев это удваивается. Это закон Мура на стероидах», – делится он с заразительным энтузиазмом. Эта быстрая эволюция означает, что организациям нужно быть готовыми к непрерывной трансформации.

Что делает историю Pets at Home такой убедительной – это не только их технические достижения, хотя они и замечательны, это их способность сохранять фокус на человеке, раздвигая границы возможного с искусственным интеллектом. Они показывают нам будущее, где технологии не заменяют человеческое взаимодействие, а улучшают его способами, которые мы только начинаем представлять.

Эллис идеально передает волнение этого технологического момента: «Какое захватывающее время жить, быть живым и работать в технологиях». Глядя на то, что достигла Pets at Home, невозможно не согласиться. Их путь от традиционного ретейлера к пионеру ИИ предлагает бесценные уроки для любой организации, стремящейся процветать в этом будущем, управляемом ИИ. Они показали нам, что с правильным видением, лидерством и подходом к внедрению будущее корпоративного ИИ не просто многообещающее – оно уже здесь.

¹ Двойная экспоненциальная функция – это константа, возведенная в степень показательной функции. Формула функции: $f(x) = a^{b^x}$ (где $a > 1$ и $b > 1$). Она растет значительно быстрее, чем показательная функция, и даже быстрее, чем факториал. – Прим. ред.

СЦЕНАРИИ ПРИМЕНЕНИЯ АГЕНТОВ В РАЗЛИЧНЫХ ФУНКЦИЯХ И ОТРАСЛЯХ

Практический пример Pets at Home наглядно иллюстрирует, как организация может успешно внедрять агентный ИИ в свои операции. Хотя их путь уникален, он демонстрирует универсальные принципы, применимые в разных отраслях и для разных функций. Как и Pets at Home, каждая организация должна начать с определения правильных сценариев применения, которые соответствуют их стратегическим целям и операционным реалиям.

Как мы уже обсуждали в главе 8, выявление и приоритизация правильных сценариев применения имеют решающее значение для успешного внедрения агентного ИИ. В то время как Pets at Home определила более 140 сценариев, специфичных для их бизнеса, мы собрали всесторонний набор проверенных сценариев применения в различных отраслях и функциях, чтобы помочь вам начать свой собственный путь трансформации. Они подробно описаны в приложениях, организованных в две основные категории.

Приложения корпоративных агентов ИИ (приложение А) охватывает пятнадцать проверенных внедрений в шести принципиально важных областях.

- Операции и цепочка поставок, включая координацию производства и взаимодействие с поставщиками.
- Управление продажами и доходами, демонстрирующее комплексную организацию продаж B2B¹.
- Клиентский опыт и обслуживание, включая навигацию по доступу к здравоохранению и координацию банковских услуг.
- Риски, соответствие требованиям и безопасность, включая выявление финансового мошенничества и соответствие нормативной документации.
- Работа с данными и аналитика, охватывающая промышленную разведку и маркетинговые исследования.
- Административные услуги и услуги по управлению персоналом, демонстрирующие управление кадровыми операциями и ИТ-услугами.

Приложения для личной продуктивности (приложение к главе 12) представляет пять фундаментальных внедрений, которые часто служат отличными отправными точками для организаций, начинающих свой путь с агентным ИИ, включая управление электронной почтой, оптимизацию календаря и синтез исследований.

Мы рекомендуем вам подробно изучить эти сценарии применения в приложениях, используя их как вдохновение и практические чертежи для вашего собственного внедрения. Как и Pets at Home, вы можете обнаружить, что старт с целенаправленных, высоковоздействующих сценариев применения создает импульс для более широкой трансформации. Помните, успешное внедрение – это

¹ Комплексная организация продаж B2B – это координация и управление сложными процессами продаж в бизнесе для бизнеса (B2B, англ. *business-to-business*), где задействовано множество этапов, участников и данных. Это включает автоматизацию, синхронизацию и оптимизацию всех аспектов продаж, здесь – использование ИИ-агентов для управления сложными B2B-взаимодействиями, такими как переговоры, контракты или интеграция данных между компаниями. – *Прим. ред.*

не развертывание как можно большего количества сценариев, а выявление тех, которые создадут наибольшую ценность для вашей организации, одновременно развивая ваши возможности для трансформации в более крупном масштабе.

Практические примеры и сценарии применения, представленные в этой главе, демонстрируют, что внедрение агентов ИИ – это не только новые технологии, но и переосмысление того, как выполняется работа и создается ценность. От амбициозного видения Pets at Home о взаимодействиях с клиентами, управляемых ИИ, до многочисленных отраслевых приложений, которые мы рассмотрели, мы видим, как агенты ИИ уже трансформируют предприятия ощутимыми, измеримыми способами.

Однако эти внедрения также поднимают глубокие вопросы о будущем работы и общества. Переходя к части 5, мы подробно рассмотрим эти более широкие последствия. Как все более сложные агенты ИИ изменят саму природу работы? Какие новые возможности и вызовы возникнут по мере эволюции этих технологий? Что это значит для человеческих работников, организаций и общества в целом? Эти вопросы не просто теоретические – они являются важнейшими соображениями для любой организации, начинающей путь трансформации с агентами ИИ.

ЧАСТЬ 5

Горизонты будущего для занятости и общества в целом

По мере того как мы вместе исследовали практические реалии внедрения и масштабирования агентов искусственного интеллекта, возник более масштабный вопрос: что произойдет, когда эта технология станет повсеместной? После изучения того, как создавать агентов ИИ (часть 3) и трансформировать организации с их помощью (часть 4), настало время поднять взгляд к горизонту и рассмотреть глубокие последствия для того, как мы работаем, учимся и живем.

Это не праздные размышления. На основе нашего опыта внедрения агентного ИИ мы видели своими глазами, как эти технологии перестраивают не только процессы, но и жизни людей – иногда способами, которые никто не предвидел. То, что начиналось как проекты автоматизации, часто перерастало в фундаментальное переосмысление самой работы. Изменения, о которых мы говорим, не где-то в будущем – они уже происходят в организациях по всему миру.

Наша цель в части 5 не предсказывать будущее с уверенностью, ведь никто не может этого сделать. Вместо этого мы стремимся помочь вам систематически осмыслить выбор, который стоит перед нами, как индивидуально, так и коллективно. Будущее работы и общества в эпоху агентов ИИ не предопределено; оно будет сформировано решениями, которые мы принимаем сегодня о том, как разрабатывать, внедрять и управлять этими технологиями.

Новый мир занятости

ПЕРЕОСМЫСЛЕНИЕ РАБОТЫ: СИМФОНИЯ ЧЕЛОВЕКА И МАШИНЫ

За годы консультирования и исследований мы присутствовали на бесчисленных стратегических встречах, но то, что мы наблюдали в глобальной компании по недвижимости в начале 2025 года, было поистине замечательным. Тара, старший менеджер проектов, не просто делилась обновлениями с командой – она дирижировала сложным сотрудничеством между человеческой креативностью и искусственным интеллектом. Пока агент ИИ анализировал данные проекта и выявлял риски в реальном времени, уникальные человеческие способности Тары – то, что мы называем «Гуманика»¹, – позволяли ей интерпретировать эти данные через призму командной динамики, клиентских отношений и более широкого бизнес-воздействия.

«Что меня поражает, – размышляла Тара, – это не то, что ИИ может выполнять сложный анализ, а то, как развитие наших чисто человеческих способностей позволило нам создать нечто большее, чем могли бы достичь люди или ИИ по отдельности».

Это наблюдение глубоко резонировало с нашим опытом. Благодаря нашей работе мы пришли к глубокому осознанию: будущее принадлежит не ИИ в одиночку, а мощной симфонии человеческих и машинных способностей.

¹ The Humics Advantage – это концепция, которая, по мнению автора книги IRREPLACEABLE, укрепляет связь между людьми и искусственным интеллектом (ИИ). Humics – сокращение от «уникальных человеческих способностей». К ним относятся, например, творчество – способность создавать новые миры, полученную не путем обучения, а как врожденное свойство личности; критическое мышление – умение анализировать правила, достигать компромиссов, демонстрировать основы этики и человеческих ценностей; социальная аутентичность – способность принимать новых людей, создавать связи через игру, демонстрировать сущность человеческого взаимодействия, коммуникации и эмпатии. – *Прим. ред.*

Эволюция сотрудничества человека и агента искусственного интеллекта

На основе нашего опыта мы наблюдали увлекательную прогрессию в сотрудничестве человека и агента. Наиболее поразительно для нас то, как эта эволюция разворачивалась на разных уровнях сложности. На уровне 1 мы видели базовую автоматизацию на основе правил – такую, которая могла справляться с повторяющимися задачами, но требовала явного программирования. Уровень 2 принес интеллектуальную автоматизацию, где ИИ мог обрабатывать более сложные сценарии с использованием машинного обучения, но все еще в ограниченных рамках.

Настоящая трансформация началась с агентных рабочих процессов уровня 3. Эти системы ИИ могли понимать контекст, рассуждать с высокой степенью сложности и управлять сложными процессами. Именно здесь мы увидели первые подлинные примеры сотрудничества человека и агента, где ИИ был не просто инструментом, а партнером в решении проблем.

Один из самых убедительных опытов мы получили, работая с производственной компанией, – трансформация, которая до сих пор волнует нас, когда мы делимся ею. Их путь идеально иллюстрирует то, что мы считаем естественной эволюцией сотрудничества человека и агента. Они начали с базовой роботизированной автоматизации процессов для управления запасами (уровень 1), перешли к прогнозированию спроса на основе ИИ (уровень 2) и, наконец, внедрили агентную систему уровня 3, которая могла автономно управлять всей цепочкой поставок, адаптируясь к сбоям и оптимизируя операции в реальном времени. Человеческая рабочая сила не исчезла – она эволюционировала, сосредоточившись на стратегических решениях и надзоре, в то время как ИИ управлял операционной сложностью.

Рассмотрим, как работа переосмысливается в разных секторах.

- В здравоохранении, где нам посчастливилось работать с несколькими ведущими учреждениями, агенты ИИ выполняют рутинные диагностические и административные задачи, освобождая врачей и медсестер для работы над сложными случаями и выстраивания отношений с пациентами. Особенно вдохновляет то, как человеческий фактор становится еще более ценным, а не менее значимым, когда ИИ берет на себя рутинные аспекты медицинской помощи. В здравоохранении преобладает четкая установка: ИИ служит людям. Хорошо управляемые агенты ИИ создают время и пространство для того, чтобы межличностный контакт стал более значимой частью лечения пациентов. Новый баланс задач делает работу клиницистов гораздо более удовлетворительной.
- В финансовых услугах. В сфере финансовых услуг мы наблюдаем интересный сдвиг: ИИ управляет анализом данных и оценкой рисков, в то время как консультанты сосредотачиваются на понимании жизненных целей клиентов и предоставлении эмоциональной поддержки при принятии важных финансовых решений. Результаты превзошли наши ожидания – сочетание ИИ и человеческого участия обеспечивает лучшие результаты, чем каждый из них мог бы достичь по отдельности.

- В креативных индустриях. Одна из наших любимых трансформаций произошла в креативных индустриях, где ИИ берет на себя технические аспекты производства – такие как цветокоррекция, улучшение звука и отслеживание целостности сцен, – в то время как люди сосредотачиваются на высокоуровневой творческой режиссуре и эмоциональном повествовании. Хотя это лишь начальный этап трансформации, мы уже поражены тем, как это партнерство создает новые формы художественного выражения, которые ранее были невозможны.

Новые роли на каждом уровне

В ходе нашей консультативной работы мы стали свидетелями того, что, как мы считаем, является одним из самых захватывающих событий в эволюции занятости: по мере того как возможности ИИ продвигаются через эти уровни, появляются новые роли, а другие трансформируются. На уровне 1 мы видели рост специалистов по автоматизации и аналитиков процессов. Уровень 2 вызвал спрос на тренеров ИИ и менеджеров качества данных. Но что действительно нас волнует – это то, как уровень 3 создает совершенно новые категории работы.

Наиболее увлекательным для нас является появление оркестраторов ИИ как главных посредников между человеческими командами и системами ИИ. Они понимают как человеческие потребности, так и возможности ИИ, обеспечивая эффективное сотрудничество между ними. Один из наших самых успешных случаев был в финансовой компании, которую мы консультировали, где оркестраторы помогли трансформировать работу команд с ИИ, перейдя от простой автоматизации задач к сложным системам поддержки принятия решений, которые усиливали человеческое суждение, а не заменяли его.

Конечно, по мере того как системы ИИ становятся более автономными, вопросы прозрачности принятия решений и этических границ требуют тщательного рассмотрения. По этой причине мы особенно увлечены ролью сотрудников по этике и аудиторов ИИ. На нашем опыте они играют принципиально важную роль в обеспечении соответствия решений ИИ человеческим ценностям и организационным принципам. Мы никогда не забудем работу с медицинским учреждением, которое создало целый отдел, посвященный мониторингу принятия решений системами ИИ в уходе за пациентами, обеспечивая как этическое соответствие, так и более точные рекомендации и решения, что создало надежную и ответственную рабочую среду для врачей, чтобы они могли сосредоточиться на межличностной стороне лечения.

Три компетенции будущего

Через нашу работу мы определили то, что, как мы считаем, является тремя основными компетенциями, необходимыми для успеха в эпоху агентного ИИ. Как подробно описано в книге «НЕЗАМЕНИМЫЕ: искусство выделяться в эпоху искусственного интеллекта»¹, это способности быть готовым к изменениям,

¹ Паскаль Борне, 2024. «НЕЗАМЕНИМЫЕ: искусство выделяться в эпоху искусственного интеллекта», <https://irreplaceable.ai/>.

готовым к ИИ и готовым к человеческому. Главное в понимании этих компетенций – это то, что они не просто некие навыки, а новое мышление и новые подходы, которые позволяют людям процветать рядом с ИИ.

Быть готовым к изменениям (Change-Ready) означает развитие устойчивости и адаптивности перед лицом непрерывной трансформации. Речь о том, чтобы рассматривать изменения не как угрозу, а как возможность для роста. Один из руководителей, с которыми мы работали, описал это как «развитие мышечной памяти для адаптации» – подобно тому, как спортсмены тренируют свое тело для инстинктивной реакции, работники должны развивать свою способность принимать и ориентироваться в изменениях. Эта характеристика всегда была полезной для сотрудников, но в эпоху ИИ и агентов она становится еще более критической.

Компетенция готовности к ИИ (AI-Ready) включает понимание того, как эффективно работать с системами ИИ. Это выходит за рамки технических знаний – речь идет о развитии интуитивного понимания возможностей и ограничений ИИ. Работники должны научиться, когда полагаться на ИИ, а когда применять человеческое суждение. Юридическая фирма, которую мы консультировали, добилась значительных улучшений в исходах дел, когда их юристы научились комбинировать аналитические способности ИИ с собственным стратегическим мышлением и эмоциональным интеллектом. В книге 2016 года «Только людям нужно подавать заявку» эта компетенция описана как «вступление в игру» – понимание того, как работают системы ИИ, наблюдение за их производительностью и улучшение их по мере необходимости¹.

Компетенция готовности к человеческому (Human-Ready) фокусируется на развитии уникальных человеческих способностей, которые ИИ не может подлинно воспроизвести, – то, что мы называем «Гуманика» (Humics). К ним относятся подлинная креативность (новые идеи, которые полезны и значимы для людей и общества, а не просто рекомбинация существующих идей), критическое мышление (включая этическое суждение и интуитивное понимание) и социальная подлинность (способность строить подлинные человеческие связи на основе общих ценностей).

Преимущество подхода, ориентированного на человека

Что мы находим наиболее убедительным в подходе Humics, ориентированном на человека, – и это мы наблюдали последовательно в разных отраслях, – это то, что, в отличие от технических навыков, которые могут устаревать, эти фундаментальные человеческие способности неподвластны времени и служат плодородной почвой, из которой естественным образом вырастают новые, актуальные навыки.

Снова и снова мы видели, как *подлинная креативность* выходит за рамки способности ИИ рекомбинировать существующие идеи. Мы с восхищением наблюдали, как профессионалы создают по-настоящему оригинальные кон-

¹ Томас Х. Дэвенпорт и Джулия Кирби, 2016. «Только людям нужно подавать заявку: победители и проигравшие в эпоху умных машин», <https://www.amazon.com/Only-Humans-Need-Apply-Machines/dp/0062438611>.

цепции, движимые человеческой эмоциональной глубиной и жизненным опытом. Прекрасный пример – цифровое маркетинговое агентство, которое мы консультировали, где команды, сосредоточившиеся на усилении своих творческих способностей, начали разрабатывать совершенно новые подходы к повествованию, которые сочетали данные с эмоциональным резонансом так, как ИИ в одиночку не мог сделать.

По опыту нашей работы мы поняли, что *критическое мышление* охватывает нашу способность делать тонкие суждения, подвергать сомнению предположения и ориентироваться в этических сложностях. Усиление критического мышления включает естественное любопытство и способность задавать вопросы, которые позволяют эффективнее справляться с неопределенностями и сложными ситуациями.

Особенно вдохновляющий пример – финансовая компания, с которой мы работали, где консультанты оттачивали свое критическое мышление через семинары и обсуждения кейсов. В результате они естественным образом развили новые способности в этических инвестиционных стратегиях и целостной оценке клиентов – навыки, которые не конкурировали с аналитической мощью ИИ, а дополняли ее, позволяя принимать решения на более широкой базе.

Еще одно ценное наблюдение – это *сила искреннего общения* в создании подлинных человеческих связей, эмпатии и доверия. Мы видели это в действии в медицинском учреждении, где практикующие врачи сосредоточились на усилении своей искренности общения через тренинги по коммуникации с пациентами, ролевые игры и программы наставничества. Этот акцент на человеческое взаимодействие помог им развить более сильные коммуникативные навыки и более целостный подход к уходу за пациентами, работая в гармонии с диагностическими инструментами ИИ, а не будучи замененными ими.

От Humics к новым навыкам

Что действительно нас волнует в ориентированном на человека подходе – это то, как он позволяет органично развивать навыки, соответствующие новым потребностям. Позвольте поделиться несколькими нашими любимыми примерами.

Джордан, замечательный профессионал в области маркетинга, с которым нам посчастливилось работать, сосредоточился на развитии своей подлинной креативности и критического мышления. Мы были поражены, наблюдая, как эта фундаментальная способность привела к естественному появлению новых навыков, таких как инновационное планирование кампаний и креативность, основанная на данных. Вместо того чтобы пытаться предсказать, какие конкретные маркетинговые навыки будут ценны в будущем, инвестиции Джордана в Humics позволили ему естественно адаптироваться и внедрять инновации по мере эволюции отрасли.

Елена, чья метаморфоза особенно нас вдохновила, предоставляет еще один убедительный пример. Когда агенты ИИ начали выполнять анализ портфелей и прогнозирование рынка в ее глобальном банке, Елена удвоила усилия по развитию своего Humics, особенно социальной подлинности и критического мышления. То, что произошло дальше, превзошло даже наши ожидания: ее повышенная эмпатия позволила ей глубоко вникнуть в эмоци-

ональные отношения клиентов с деньгами и их более широкие жизненные цели. Ее критическое мышление позволило синтезировать рыночные данные, сгенерированные ИИ, с личными обстоятельствами и ценностями клиентов. В результате она развила новые навыки в «целостном финансовом жизненном планировании» и «ИИ-усиленном эмоциональном интеллекте в финансах» – способности, которые возникли органично из ее укрепленного фундамента Humics.

Похожий пример, который мы наблюдали, был в компании по управлению активами, которая начала внедрять набор агентов ИИ для управления благосостоянием – так называемое робо-консультирование. В интервью о новой системе финансовый консультант сказал нам: «Я чувствую, что робоконсультанты наступают мне на пятки. Но вместо того, чтобы пытаться конкурировать с ними, я пытаюсь узнать больше о “финансовой психиатрии” – например, пытаюсь примирить часто сильно различающиеся взгляды мужей и жен в парах клиентов».

Что особенно примечательно в обоих случаях – это то, как развитие новых навыков не было навязанным или заранее определенным. Подобно тому, как здоровая почва естественным образом поддерживает рост различных растений, сильное осознание и фокус на Humics создают условия для появления актуальных навыков в ответ на изменяющиеся обстоятельства. Опыты Джордана и Елены демонстрируют, как инвестиции в эти фундаментальные человеческие способности позволяют профессионалам оставаться актуальными и ценными по мере расширения возможностей ИИ.

Новые категории навыков

Мы наблюдаем появление новых категорий навыков, основанных на прочной базе взаимодействия человека и искусственного интеллекта. Вот несколько примеров.

Эмоциональная инновация сочетает подлинную креативность с социальной аутентичностью для создания глубоко резонирующих человеческих переживаний. Этот навык становится все более заметным в таких областях, как дизайн продуктов и городское планирование, где профессионалы должны разрабатывать решения, учитывающие как практические, так и эмоциональные потребности человека.

Интуитивная навигация по системам использует критическое мышление в сочетании с социальной аутентичностью для управления сложными системами, включающими как человеческие, так и ИИ-компоненты. Этот навык особенно важен в таких отраслях, как здравоохранение и управление цепочками поставок, где понимание взаимодействия между технологическими возможностями и человеческим фактором критически важно для успеха.

Наконец, принятие сложных этических решений опирается на все три измерения взаимодействия человека и искусственного интеллекта для решения все более сложных этических вызовов в мире, управляемом ИИ. Этот навык особенно ценен в таких областях, как разработка ИИ, здравоохранение и финансовые услуги, где баланс между техническими возможностями, человеческими ценностями и общественным воздействием имеет первостепенное значение.




Рис. 13.1. Прогрессивный фреймворк агентного ИИ (Источник: © Борне и др.)

Поддержка развития подхода, ориентированного на человека

Мы твердо убеждены, что организации должны активно поддерживать развитие этих фундаментальных способностей. Мы обнаружили, что особенно эффективны следующие подходы.

- Одной из наших самых успешных стратегий было создание обучающих сред, которые поощряют экспериментирование и рефлексию, позволяя сотрудникам развивать свою Humics через реальные вызовы и опыты.
- Мы видели замечательные результаты от внедрения систем измерения, которые признают и вознаграждают развитие навыков, основанных на Humics, переходя за рамки традиционных метрик производительности, чтобы ценить человеческие способности, которые дополняют ИИ.
- Что оказалось особенно мощным в нашем опыте – это разработка рабочих процессов, которые оптимизируют сотрудничество между человеческой Humics и возможностями ИИ, обеспечивая, чтобы каждый вносил свои уникальные сильные стороны для достижения лучших результатов.

Мы обнаружили, что, сосредотачиваясь на развитии Humics, организации могут создавать рабочие силы, которые остаются актуальными и ценными по мере эволюции возможностей ИИ. Одно из наших самых важных открытий – это то, что конкретные и новые навыки будут возникать естественным образом, когда мы сначала развиваем эти фундаментальные человеческие способности.

По мере того как мы углубляемся в эпоху агентного ИИ, мы считаем, что наиболее успешные организации будут теми, которые создают среды, где человеческие способности могут процветать рядом с ИИ. Сосредотачиваясь на развитии Humics, мы создаем условия для непрерывной адаптации и инноваций, обеспечивая, чтобы человеческие работники оставались незаменимыми даже по мере расширения возможностей ИИ.

Будущее работы – это не противостояние людей и ИИ, а создание симфонии, где оба играют на своих сильных сторонах. Мы страстно верим, что, сосредотачиваясь на развитии наших уникальных человеческих способностей, мы создаем основу для непрерывной адаптации и инноваций в эпоху агентного ИИ. Процветать будут те организации, руководство которых понимает следующую фундаментальную истину: наши человеческие способности при правильном развитии позволят людям использовать ИИ способами, которые создадут возможности, недостижимые в одиночку, и, таким образом, обеспечат ценность на беспрецедентных уровнях.

НА ЭТОТ РАЗ ВСЕ ИНАЧЕ: РОЖДЕНИЕ АГЕНТНОГО ИИ

«Я заменила себя автоматом», – призналась Дебби во время нашего консультативного проекта в компании из списка Fortune 500. Как опытный менеджер проектов, она только что внедрила агент ИИ уровня 3, который не только координировал весь выпуск программного обеспечения, но и учился на своих ошибках и адаптировал свой подход – подобно тому, как это делала бы она. «За двадцать лет управления технологическими проектами я видела, как приходили и уходили бесчисленные инструменты. Но это не инструмент. Эта штука думает как я».

Тот момент останется с нами навсегда. Реакция Дебби глубоко резонировала с нашим опытом. Ее опыт кристаллизует, почему революция агентного ИИ фундаментально отличается от предыдущих технологических инноваций. Мы не просто наблюдатели – мы свидетели чего-то беспрецедентного по скорости и характеру изменений.

Парадокс ускорения

За десятилетия внедрения технологий автоматизации в разных отраслях мы были свидетелями многих волн технологических изменений. Но то, что мы видим сейчас в ситуации с агентным ИИ, наполняет нас как волнением, так и беспокойством – это не похоже ни на что в нашем опыте.

Глядя через призму истории, мы видим, что технологические революции следовали предсказуемому шаблону: нарушение, адаптация и в конечном итоге равновесие. Индустриальная революция автоматизировала физический труд на протяжении поколений. Цифровая революция компьютеризировала когнитивные задачи в течение десятилетий. Каждая волна давала обществу время адаптировать свои образовательные системы, рынки труда и социальные структуры.

Но что нас восхищает и, честно говоря, иногда тревожит – это то, как агентный ИИ разрушает этот шаблон. Позвольте поделиться одним из наших самых поразительных опытов: недавно мы внедрили агента уровня 3 для управления цепочкой поставок для производственного клиента. То, что произошло дальше, поразило даже нас – в течение 47 дней он начал обрабатывать сложные логистические решения, которые раньше требовали самых опытных профессионалов. Еще более примечательно было то, как он эволюционировал – обучаясь на каждом взаимодействии, совершенствуя свое принятие решений, он в конечном итоге превзошел человеческую производительность в областях, требующих понимания контекста.

Эта быстрая трансформация привела нас к определению того, что мы считаем «парадоксом адаптации»: по мере того как навыки, необходимые для работы рядом с ИИ, становятся более сложными, время, доступное для развития этих навыков, резко сокращается. Мы видели это своими глазами в финансовой компании, которую консультировали, где сотрудникам потребовалось менее шести месяцев, чтобы перейти от обработки транзакций к оркестрации сложных рабочих процессов ИИ – сдвиг, который традиционно занял бы годы постепенного повышения квалификации.

Мы также наблюдали эту проблему в технологической компании, которую мы консультировали, где навыки команды разработки ИИ устаревали каждые три месяца по мере эволюции их агентов. Что особенно нас поразило – это то, как традиционные квартальные циклы обучения оказались бесполезными, – к тому времени, как сотрудники осваивали новые навыки, технологии уже успевали продвинуться дальше. Этот опыт привел к тому, что мы считаем прорывным осознанием: необходимостью радикального переосмысления профессионального развития, перехода от периодического обучения к непрерывному обучению, поддерживаемому ИИ.

Характер революционных изменений

Благодаря нашей обширной работе с внедрениями ИИ мы поняли, что уникальный характер этих изменений становится ясным, когда мы рассматриваем прогрессивный фреймворк агентного ИИ. Агенты уровней 1 и 2 следовали историческому шаблону автоматизации – заменяя рутинные физические и когнитивные задачи. Однако то, что мы считаем по-настоящему революционным в агентах уровня 3, – это то, насколько они фундаментально отличаются от своих предшественников. Они не просто выполняют задачи, они понимают контекст, учатся на опыте, принимают тонкие решения и предоставляют рекомендации по управлению. Эта реальность делает очевидным, что агенты ИИ становятся почти саморефлективными, поскольку они могут анализировать свои собственные процессы принятия решений и автономно совершенствовать свои алгоритмы.

Один из самых поразительных примеров пришел от юридической фирмы, с которой мы работали, которая внедрила агента для проверки контрактов – традиционно задача, требующая годы специализированного обучения. Что нас больше всего удивило – это не только то, что в течение нескольких месяцев агент не просто стал обрабатывать документы быстрее; он выявлял тонкие юридические риски, которые даже старшие юристы иногда пропускали. Но что действительно нас поразило – это наблюдение за тем, как он учится на каждом контракте, постоянно улучшая свое понимание юридических нюансов и бизнес-контекста.

Эта трансформация привела нас к одному из самых важных осознаний: традиционные стратегии адаптации могут потерпеть неудачу. Предыдущие технологические революции позволяли людям двигаться «вверх по цепочке ценности» к более сложной когнитивной работе. Но теперь мы сталкиваемся с беспрецедентным вызовом: когда ИИ может учиться, рассуждать и адаптироваться, куда могут двигаться люди? Через нашу работу с многочисленными организациями мы обнаружили, что ответ заключается не в конкуренции с ИИ, а в фундаментальном переосмыслении сотрудничества человека с искусственным интеллектом.

Уроки истории и открытие новых путей

Хотя мы признаем, что эта трансформация беспрецедентна, наши исследования и опыт показали, что история дала нам важные уроки. Мы определили, что успешные переходы в предыдущих революциях имели общие элементы: проактивную адаптацию, фокус на уникальных человеческих способностях и сильную институциональную поддержку. Но что делает нашу текущую ситуацию особенно сложной – это то, что эти уроки должны применяться с беспрецедентной скоростью и масштабом.

Через нашу работу с дальновидными организациями мы наблюдали, что компании, успешно преодолевающие этот переход, рассматривают агентов ИИ не как инструменты, а как сотрудников, требующих новых подходов к управлению. Что особенно воодушевляет – это то, как они сосредотачиваются на развитии уникальных человеческих способностей своей рабочей силы – креативности, эмоционального интеллекта и решения сложных проблем – при использовании аналитических и обучающих способностей ИИ.

Новые перспективы

Находясь на этом рубеже, мы более чем когда-либо убеждены, что агентный ИИ представляет собой не просто очередную волну автоматизации, а фундаментальный сдвиг в сотрудничестве человека и машины. Что не дает нам спать по ночам, это не вопрос, произойдет ли это изменение – оно уже разворачивается. Что действительно важно, на наш взгляд, – это обеспечение того, чтобы эта трансформация приносила пользу организациям, индивидуумам и обществу.

В следующих главах мы поделимся тем, что, как мы считаем, является конкретными стратегиями для процветания в этой новой реальности. Хотя мы признаем, что временное окно для адаптации может быть короче, чем когда-либо, мы остаемся оптимистами, потому что видели своими глазами, как организации и индивидуумы, понимающие и принимающие эти изменения, могут открыть в себе неожиданные возможности. Наша цель – помочь людям не просто выжить в этой трансформации, но процветать в ней.

ПЕРЕОСМЫСЛЕНИЕ ОБРАЗОВАНИЯ В ЭПОХУ АГЕНТОВ ИИ

Поскольку агентный ИИ фундаментально перестраивает наш мир с беспрецедентной скоростью, мы должны признать, что традиционные стратегии адаптации больше не будут достаточными. Поскольку на этот раз все действительно иначе, нам нужно пересмотреть саму основу человеческих навыков и способностей. Если мы хотим успешно пройти через эту трансформацию, мы должны вернуться к начальным принципам и дать новое определение тому, что значит быть образованным в мире, где люди и все более сложные агенты ИИ сотрудничают как партнеры, а не как конкуренты.

Кризис в современном образовании

Рост агентов ИИ фундаментально трансформирует то, как мы живем и работаем, однако наши образовательные системы остаются в основном неизменными со времен индустриальной революции. Рассмотрим типичный класс се-

годня: ученики все еще запоминают факты, которые они могли бы легко получить от агента ИИ, практикуют навыки, которые скоро будут автоматизированы, и следуют стандартизированным учебным планам, которые не развивают именно те уникальные человеческие способности, что будут наиболее важны в будущем. Вместо того чтобы прививать критическое мышление, учеников отучают задавать вопросы о том, чему их учат. Этот индустриализированный подход к образованию имел смысл в эпоху, когда объем информации был невелик, а рутинные когнитивные задачи выполнялись людьми. Но в мире, где агенты ИИ могут мгновенно получать доступ и обрабатывать огромные объемы информации, наши образовательные приоритеты должны кардинально измениться.

Возвращение к истинной цели образования

Одно из наших самых увлекательных открытий в исследовании этой темы – это то, что слово «школа» происходит от греческого слова «схολэ», означающего «досуг» или «отдых». Мы считаем эту этимологию глубоко показательной, потому что она раскрывает глубокую правду о первоначальной цели образования: оно было задумано не для подготовки будущих работников к той или иной работе, а для предоставления пространства для вдумчивой рефлексии и исследования фундаментальных вопросов жизни. Что нас вдохновляет в подходе древних греков – это то, что они видели образование как средство помочь людям найти свое предназначение и развить свой полный потенциал как человеческих существ. Это, конечно, была и первоначальная идея гуманитарного образования в колледжах, но со временем эта идея потеряла популярность.

На наш взгляд, эта историческая перспектива предлагает мощную критику сегодняшнего карьерно-ориентированного подхода, где успех часто измеряется результатами тестов и уровнем трудоустройства. Вместо этого мы считаем, что образование должно вооружать людей стремлением к развитию, росту и продвижению рефлексивного мышления, которое ищет возможности ускорить эти процессы развития.

Человечество лучше всего выигрывает от понимания того, какое предназначение лежит в основе человеческого развития, поскольку это придаст смысл нашим действиям и создаст осведомленность о возможностях (таких как ИИ сегодня) вокруг нас, чтобы извлечь из них пользу. Поскольку агенты ИИ могут все лучше и лучше справляться с рутинными когнитивными задачами и способствовать созданию возможностей, мы считаем, что пришло время вернуться к этому более целостному взгляду на образование – тому, который подчеркивает приоритет развития человека над профессиональной подготовкой. С этой перспективы философия, психология и поведенческие подходы к технологиям должны стать в нашем общем подходе к образованию центральными.

Переосмысление образования через три компетенции

Изучив ранее в этой книге три компетенции будущего, давайте рассмотрим, как они могут перестроить наш подход к образованию¹. Эти компетенции не про-

¹ Паскаль Борне, 2024. «НЕЗАМЕНИМЫЕ: Искусство выделяться в эпоху искусственного интеллекта», <https://irreplaceable.ai/>

сто навыки, которые нужно преподавать, – они должны быть организующими принципами, вокруг которых мы структурируем все обучающие опыты.

На практике это означает модернизацию традиционных предметов через призму этих компетенций. Математика, например, должна сместиться от запоминания формул (с чем ИИ может справиться) к развитию стратегий решения проблем и творческих подходов к математическим вызовам, чтобы математика оживала через исследование ее воздействия. Один из наших любимых примеров – это то, как уроки литературы могут меньше фокусироваться на запоминании сюжета и больше на глубоком анализе, эмоциональном понимании и исследовании человеческого опыта, которые агенты ИИ не могут по-настоящему постичь.

Глобальные инновации в образовании

На протяжении наших исследований и опыта мы стали свидетелями поистине вдохновляющих примеров стран, которые лидерствуют в образовательных реформах, соответствующих этим принципам. Мы были особенно впечатлены трансформацией учебной программы в Финляндии, которая делает акцент на междисциплинарном обучении и решении реальных проблем. Что нас восхищает в их подходе, называемом «феномено-ориентированное обучение»¹, – это то, как он разрушает традиционные предметные границы. Мы видели своими глазами, как при изучении изменения климата студенты одновременно работают с научными данными (развивая аналитические навыки, готовность к ИИ), исследуют творческие решения (компетенции человеческого) и адаптируют свое понимание по мере появления новой информации (готовность к изменениям)².

Еще одна модель, которую мы находим особенно убедительной, – это образовательная система Дании с их программой *Klassens Tid* (Классное время). С 1993 года ученики в возрасте от 6 до 16 лет проводят один час в неделю, развивая эмоциональный интеллект и социальную подлинность. Нам особенно нравятся эти занятия тем, как дети и подростки учатся ориентироваться в сложных социальных ситуациях, разрешать конфликты и строить подлинные человеческие связи – навыки, которые, как мы считаем, становятся все более ценными, поскольку агенты ИИ берут на себя все больше рутинных взаимодействий³.

Один из самых дальновидных подходов, которые мы изучали, – это инициатива Сингапура *SkillsFuture*, которая демонстрирует, как образовательные системы могут эволюционировать для поддержки обучения на протяжении всей

¹ Феномено-ориентированное обучение, англ. *Phenomenon-Based Learning (PhBL, PhenoBL)* – подход к обучению, при котором **ученики изучают феномены, окружающие их в реальной жизни**, вместо абстрактных концепций и теорий. Цель – подготовить учащихся к решению проблем в реальной жизни, требуя от них активного поиска знаний и навыков, необходимых для их решения. – *Прим. ред.*

² Паси Сальберг, 2021. «Финские уроки 3.0: чему может научиться мир у образовательных инициатив Финляндии?»

³ Алессия Лаломия и Антония Каскалес-Мартинес, 2023. «Развитие социально-эмоциональных навыков: разработка проекта в датской школе», <https://doi.org/10.18662/rrem/15.2/726>.

жизни¹. Нам особенно интересны их инновационные подходы, включая регулярное прогнозирование навыков для предвидения будущих потребностей, гибкие образовательные пути, которые позволяют студентам сочетать традиционные академические дисциплины с практическими навыками, интеграцию инструментов ИИ в процесс обучения при сохранении фокуса на человеческом развитии и сильный акцент на проектном обучении, которое развивает адаптивность и креативность².

Эти новые подходы к образованию применимы не только к начальной и средней школе. Джозеф Аун, президент Северо-Восточного университета, в 2017 году опубликовал книгу «Robot-Proof», в которой определил новый подход к университетскому образованию в эпоху ИИ³. Он утверждает, что наполнение умов студентов фактами больше неуместно, учитывая возможности ИИ. Вместо этого он считает, что колледжи должны культивировать творческое мышление и способность создавать что-то ценное для общества, будь то художественное произведение или новое лечение болезни.

Класс будущего

Мы считаем, что классы будущего должны быть пространствами, где студенты учатся использовать ИИ, одновременно укрепляя свои уникальные человеческие способности. Вместо того чтобы конкурировать с ИИ в задачах, которые он выполняет лучше, студенты должны сосредоточиться на развитии дополнительных способностей, которые улучшают сотрудничество человека и ИИ. Некоторые из этих способностей будут включать понимание того, как думают компьютеры и ИИ, но большинство будет более ориентировано на человека.

Мы видели, как эта трансформация успешно проявляется в различных предметах. Один из наших любимых примеров – уроки письма, где студенты используют агентов ИИ для базового составления и редактирования текстов и сосредотачивают свою энергию на развитии уникального стиля и создании убедительных повествований. Это значительный поворот для многих студентов, которых раньше поощряли просто выполнять письменное задание и двигаться дальше. Теперь им нужно становиться мастерами слова и критическими редакторами. Мы также видели научные проекты, в которых ИИ выполняет

¹ Инициатива SkillsFuture – это национальная программа Сингапура, запущенная в 2015 году, направленная на поощрение непрерывного обучения и развития навыков для всех граждан независимо от их начального уровня подготовки. Она призвана поддерживать профессиональный рост и адаптацию рабочей силы к быстро меняющейся экономике, включая вызовы, связанные с внедрением ИИ и других технологий. Программа включает такие элементы, как SkillsFuture Credit (финансовая поддержка для оплаты курсов), SkillsFuture Mid-Career Training Allowance (для работников среднего возраста), а также программы переквалификации и повышения квалификации. В 2023 году более 520 000 человек воспользовались инициативами SkillsFuture, что подчеркивает ее масштаб и влияние. – *Прим. ред.*

² Агентство SkillsFuture Singapore, 2024. «Годовой отчет 2024: повышение уровня экосистемы навыков».

³ Джозеф Е. Аун, 2017. «Robot-Proof: высшее образование в эпоху искусственного интеллекта».

анализ данных, а студенты сосредотачиваются на формировании творческих гипотез и интерпретации результатов новыми способами. И мы наблюдали уроки истории, которые используют ИИ для предоставления фактической информации, освобождая студентов для более глубоких дискуссий об исторических шаблонах, человеческих мотивациях и этических последствиях.

Эволюционирующая роль учителя

В этой новой образовательной парадигме учителя становятся не столько поставщиками информации, сколько архитекторами обучения. Их роль смещается в сторону разработки опыта, который развивает уникальные человеческие способности студентов, направляет студентов к эффективному сотрудничеству с агентами ИИ, способствует значимым обсуждениям и более глубокому пониманию, а также помогает студентам осознавать и укреплять их исключительно человеческий вклад. Учителя становятся тренерами, облегчая переход от контента (ИИ генерирует контент и предоставляет рекомендации) к знанию (люди применяют контент для осмысления своей бизнес-реальности).

Новые перспективы

Пожалуй, нет необходимости говорить, что эта трансформация требует значительных изменений в том, как мы структурируем и предоставляем образование. Мы твердо убеждены, что мы должны переработать методы оценки, чтобы оценивать человеческие способности, а не накопленные знания, инвестировать в обучение учителей, ориентированное на интеграцию ИИ и развитие специфических человеческих навыков, создавать гибкие обучающие среды, которые поддерживают как индивидуальное исследование, так и совместное обучение, и разрабатывать новые учебные планы, которые делают акцент на развитие человеческих качеств наряду с технической компетентностью. Лидеры образования – от президентов университетов до директоров начальных школ – должны стать подкованными в ИИ менеджерами изменений, так же как это требуется от корпоративных руководителей.

Что не дает нам спать по ночам – это осознание того, что ставки не могут быть выше. Успешное функционирование нашего общества и экономики зависит от этой образовательной трансформации. По мере того как агенты ИИ становятся более сложными, мы видим своими глазами, как разрыв между теми, кто может адаптироваться, и теми, кто не может, продолжает увеличиваться. Но мы также полны надежды, потому что, перестраивая образование вокруг этих принципов, мы можем обеспечить, чтобы будущие поколения были не просто готовы выживать в мире агентов ИИ, а процветать в нем, оставаясь незаменимыми своими уникальными способами.

Мерой успеха образования в эту новую эпоху будет не то, сколько информации студенты могут запомнить или насколько хорошо они выполняют стандартизированные задачи. Вместо этого успех будет измеряться тем, насколько эффективно студенты могут применять свои уникальные человеческие способности в сотрудничестве с агентами ИИ для решения сложных проблем и создания новой ценности. Это настоящий вызов – и возможность – образования в эпоху агентов ИИ.

Общество в эпоху агентов

ПЕРЕОСМЫСЛЕНИЕ ЧЕЛОВЕЧЕСКОГО ПОТЕНЦИАЛА В МИРЕ, УПРАВЛЯЕМОМ АГЕНТАМИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Первый вопрос, который люди задают, сталкиваясь с развитием агентов ИИ, часто касается работы – отнимут ли они мою? Но, возможно, мы задаем неправильный вопрос. Что нас больше всего волнует – это другая возможность: что, если вместо угрозы нашим средствам к существованию появление автономных агентов предлагает нам нечто революционное – возможность фундаментально переосмыслить, что значит быть человеком в современном мире?

Конец работы, какой мы ее знаем?

Начнем с того, что мы считаем неудобной, но необходимой правдой: большая часть сегодняшней работы глубоко неудовлетворительна. Мы видели это своими глазами в организации за организацией, и данные подтверждают наши наблюдения. Согласно обширным исследованиям Gallup ошеломляющие 77 % сотрудников по всему миру сообщают, что чувствуют себя отстраненными от своей работы¹. Что разбивает нам сердце – это то, как они описывают свои повседневные задачи как повторяющиеся, утомительные и в конечном итоге не приносящие удовлетворения. Один особенно яркий пример, с которым мы столкнулись, – это то, что только в Соединенных Штатах более 1,5 млн человек проводят свои дни, выполняя повторяющиеся задачи по бухгалтерии и учету, которые истощают человека, а не наполняют его жизнь².

Но что действительно нас тревожит – это то, что работа не просто неудовлетворительна – она буквально убивает нас. Статистика, которую мы обнаружили,

¹ Gallup, 2024. «Состояние глобального рабочего места: Отчет 2024», <https://www.gallup.com/workplace/349484/state-of-the-global-workplace.aspx>.

² Бюро статистики труда США, 2024. «Бухгалтеры, учетные и аудиторские клерки», Справочник по профессиональным перспективам, <https://www.bls.gov/ooh/Office-and-Administrative-Support/Bookkeeping-accounting-and-auditing-clerks.htm>.

шокирует: Международная организация труда сообщает, что стресс, связанный с работой, и вызванные им болезни приводят к почти 3 млн смертей ежегодно¹ с общественными затратами примерно в 3 трлн долл.² Чтобы осознать масштаб этой проблемы, учтите, что от причин, связанных с работой, умирает в два раза больше людей, чем от дорожно-транспортных происшествий³, и в десять раз больше, чем от войн⁴. Мы убедились, что текущая система просто невыносима.

Благодаря нашей работе по внедрению решений ИИ в различных отраслях мы видели, как агенты ИИ прогрессируют через возрастающие уровни своих возможностей – от базовой автоматизации на основе правил до более сложных автономных операций. По мере того как они созревают в технологической сложности и возможностях, они предлагают нам шанс перестроить эту реальность. Хотя наш опыт показывает, что современные агенты уровней 1–3 в основном усиливают человеческие способности, нас волнует, как прогрессия к уровням 4 и в конечном итоге 5 указывает на будущее, где машины могли бы выполнять значительную часть традиционной экономической деятельности.

Историческая перспектива освобождения

Один из наших любимых исторических очерков пришел из 1930 года, когда экономист Джон Мейнард Кейнс написал эссе под названием «Экономические возможности для наших внуков»⁵. Что нас восхищает в его видении – это то, как он представлял будущее с резко сокращенными рабочими часами. Он предсказал, что к 21 веку технологический прогресс позволит сократить рабочую неделю до 15 часов – менее двух полных дней по сегодняшним стандартам. Что особенно нас поражает – это то, что его видение не касалось безработицы, а было об освобождении от изнуряющей и отупляющей работы.

В наших беседах с лидерами индустрии мы слышали похожие прогнозы. Технические лидеры, такие как Джек Ма, предположили, что ИИ может сократить рабочую неделю до трех дней с четырехчасовыми рабочими днями⁶. Билл Гейтс недавно сделал аналогичный прогноз⁷. Хотя это может звучать утопично, нас особенно

¹ МОТ (Международная организация труда), 2023. «Почти 3 миллиона человек умирают от несчастных случаев и болезней, связанных с работой», <https://www.ilo.org/resource/news/nearly-3-million-people-die-work-related-accidents-and-diseases>.

² Дитмар Эльслер, Юкка Такала и Йоуко Ремес, 2019. «Международное сравнение затрат на несчастные случаи и болезни, связанные с работой», Европейское агентство по безопасности и здоровью на рабочем месте (EU-OSHA), https://osha.europa.eu/sites/default/files/2021-11/international_comparison-of_costs_work_related_accidents.pdf.

³ Всемирная организация здравоохранения (ВОЗ), 2023. «Дорожно-транспортные травмы», <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>.

⁴ Бен Найт, 2023. «Глобальные конфликты: число погибших на самом высоком уровне в 21 веке», <https://www.dw.com/en/global-conflicts-death-toll-at-highest-in-21st-century/a-66047287>.

⁵ Джон Мейнард Кейнс, 1930. «Экономические возможности для наших внуков», https://www.aspeninstitute.org/wp-content/uploads/files/content/upload/Intro_Session1.pdf.

⁶ Эйми Пикки, 2019. «Миллиардер Джек Ма, сторонник 12-часовых дней, теперь говорит, что ИИ позволит сократить рабочую неделю до 12 часов», <https://www.cbsnews.com/news/billionaire-jack-ma-booster-of-12-hour-days-now-says-ai-will-allow-12-hour-weeks/>.

⁷ Эйслинн Мерфи, 2023. «Билл Гейтс говорит, что использование ИИ может привести к трехдневной рабочей неделе», <https://www.foxbusiness.com/technology/bill-gates-suggests-artificial-intelligence-could-potentially-bring-three-day-work-week>.

вдохновили ранние эксперименты с сокращенными рабочими графиками, которые дали многообещающие результаты. Один из наших любимых примеров – это Perpetual Guardian из Новой Зеландии, компания по управлению имуществом, которая опробовала 32-часовую рабочую неделю для своих 240 сотрудников без сокращения зарплат. Результаты удивили даже нас: уровень стресса снизился, вовлеченность улучшилась, а производительность выросла на 30–40 %¹.

В Великобритании 61 компания участвовала в эксперименте с четырехдневной рабочей неделей с сохранением 100 % прежней зарплаты. Результаты были исключительно положительными. Сотрудники лучше спали, испытывали меньше стресса, имели лучшее психическое состояние и более насыщенную личную жизнь. Доходы компаний остались на прежнем уровне или выросли по сравнению с предыдущими периодами. 56 из 61 компании решили продолжить этот рабочий режим после окончания пилотного проекта².

Эти новые рабочие эксперименты проводились до широкого появления агентов ИИ и даже генеративного ИИ. Представьте, сколько человеческого труда можно было бы продуктивно автоматизировать с помощью этих новых инструментов и насколько более насыщенной могла бы стать жизнь сотрудников, если бы они могли работать значительно меньше часов, оставаясь при этом более продуктивными и зарабатывая столько же денег.

За пределами зарплаты: переосмысление ценностей

Одной из самых глубоких задач – и возможностей, – представленных агентами ИИ, является шанс переопределить, как мы измеряем человеческую ценность. Один глубоко тревожный аспект текущей системы – это обратная связь между социальной ценностью и компенсацией во многих обществах. Рассмотрим то, с чем мы все сталкивались: уход за другими. Это одна из самых важных функций в любом обществе. Будь то воспитание детей или уход за пожилыми, эта жизненно важная работа часто плохо оплачивается или не оплачивается вообще.

Если уход за другими мог бы выполняться более продуктивно с помощью агентов ИИ и роботов, возможно, люди, которые их контролируют, наконец-то получили бы уважение и компенсацию, которые они заслуживают. Те, кто получает уход, также могли бы найти это более удовлетворительным. Пока что роботы в уходе за пожилыми не были особенно успешными, даже в таких обществах, как Япония, которые вложили в них значительные средства³. Однако кажется возможным, что агенты ИИ и более умные роботизированные системы могли бы значительно повысить их эффективность. Как и в случае

¹ Эйми Пикки, 2018. «Что произошло, когда компания платила своим работникам за четырехдневную неделю», <https://www.cbsnews.com/news/one-business-says-a-4-day-week-with-pay-for-5-works/>.

² Аннабель Тимсит, 2023. «Пилотный проект с четырехдневной рабочей неделей оказался настолько успешным, что большинство компаний не хотят возвращаться назад», <https://www.washingtonpost.com/wellness/2023/02/21/four-day-work-week-results-uk/>.

³ Джеймс Райт, 2023. «Взгляд изнутри на эксперимент Японии по автоматизации ухода за пожилыми», <https://www.technologyreview.com/2023/01/09/1065135/japan-automating-elder-care-robots/>.

с другими работами, Люди, ухаживающие за другими, останутся незаменимыми и должны оплачиваться выше, чем сегодня.

Нас особенно вдохновила концепция постзанятости, выдвинутая мыслителями, такими как Дэвид Грэбер¹ и Хелен Хестер². Их убедительный довод, который согласуется с тем, что мы наблюдали в нашей работе, заключается в том, что автоматизация традиционной работы машинами заставит нас радикально переосмыслить, как мы структурируем общество и распределяем ресурсы. Что нас больше всего волнует – это то, что речь идет не только о сокращении рабочих часов, а о фундаментальном переосмыслении того, что мы ценим и почему.

Осознание цели жизни в мире, управляемом ИИ

Один из самых провоцирующих размышления вопросов, с которыми мы сталкиваемся в нашей работе, – это «Если бы мы работали меньше или вообще не работали, как бы мы проводили свое время?» На основе наших исследований и бесед с работниками в разных отраслях мы считаем, что мы могли бы сосредоточиться на целенаправленных занятиях, таких как уход за другими и защита планеты.

Опросы в организациях действительно показывают, что, если ИИ экономит время сотрудников, они хотели бы, чтобы организация позволила им использовать это сэкономленное время для «значимых» дел³. Если внедрение агентов ИИ может создать время и освобождение для людей, то одна из самых захватывающих возможностей, которые нас ждут, – это реальность, где люди могут больше сосредотачиваться на личностном росте, саморазвитии и более сильном вовлечении в сообщество, что может создать мир, где мы действительно можем стремиться к коллективному благополучию⁴.

Мы видели проблески этого будущего в нашей работе с дальновидными организациями, где люди с большим количеством свободного времени занимаются своими хобби, берутся за предпринимательские проекты или изучают новые навыки и языки. Что особенно вдохновляет – это наблюдение за тем, как люди путешествуют, занимаются волонтерством и укрепляют социальные связи через значимые взаимодействия. Мы заметили, что, когда приоритет отдается ментальному и физическому здоровью, это естественно способствует благополучию и удовлетворению.

Опираясь на исторические параллели, которые нас восхищают, подобно тому, как индустриальная революция расширила досуг и стимулировала художественные инновации, мы считаем, что ИИ может привести к новым формам развлечений, обучения и общественных пространств. В нашем видении офисы

¹ Дэвид Грэбер, 2018. «Бесполезные работы: теория», https://en.wikipedia.org/wiki/Bullshit_Jobs.

² Энди Бекетт, 2018. «Постзанятость: радикальная идея мира без работы», <https://www.greeneuropeanjournal.eu/post-work-the-radical-idea-of-a-world-without-jobs/>.

³ Visier, 2023. «Новое исследование о влиянии ИИ на рабочие места: сэкономленное время разделяет сотрудников», <https://www.visier.com/blog/ai-impact-on-jobs-employees-divided/>.

⁴ Adecco Group, 2024. «ИИ экономит работникам в среднем один час в день», <https://www.adecgroup.com/our-group/media/press-releases/ai-saves-workers-an-average-of-one-hour-each-day>.

могут трансформироваться в центры для искусства, игр и сотрудничества, что, в свою очередь, будет стимулировать креативность и инновации.

Хотя это привлекательное будущее, повторяющаяся озабоченность – это страх экономического краха при сокращении рабочих часов. Однако наши исследования и опыт показывают, что правильное использование агентов ИИ, вероятно, будет стимулировать экономический рост, давая людям больше времени наслаждаться жизнью и участвовать в потребительском рынке. Нас особенно поразило наблюдение Генри Форда в 1924 году, что досуг подпитывает спрос на продукты, позволяя экономике процветать. Возможности, которые мы видим, огромны, и будущее полно возможностей.

Всеобщий базовый доход: основа для человеческого процветания?

По мере того как агенты ИИ берут на себя больше традиционных экономических ролей, нам нужны новые механизмы, чтобы обеспечить удовлетворение базовых потребностей каждого. Нас особенно интригует универсальный базовый доход (UBI, Universal Basic Income) как одно из возможных решений – предоставление каждому взрослому гражданину гарантированного дохода, достаточного для покрытия базовых потребностей, независимо от статуса занятости¹. Такие программы могут стать абсолютной необходимостью, если технологии, такие как агентный ИИ, приведут к массовой потере рабочих мест, хотя мы не ожидаем такого исхода.

Что мы находим наиболее убедительным в UBI – это то, что, в отличие от программ социальной помощи, связанных со статусом занятости или специфическими условиями, он универсален и не зависит от дохода, статуса работы или личных обстоятельств. UBI тестировался в различных условиях, хотя пока в небольшом масштабе. Результаты одного из крупнейших и самых последних экспериментов с UBI, которые согласуются с предыдущими исследованиями, показывают, что он часто сокращает количество работы, выполняемой получателями, и снижает их тревогу по поводу удовлетворения базовых потребностей, таких как жилье². Однако он не всегда приводит к желаемым поведенческим изменениям, таким как саморазвитие, предпринимательская деятельность или время, проведенное с семьей³.

Позвольте нам быть ясными: у нас нет интереса в поддержке UBI, если он приведет к обществу праздных потребителей. Мы надеемся, что в конечном итоге UBI может обеспечить основу для того, чтобы люди могли заниматься более значимыми вкладами в общество. Освободившись от немедленного давления выживания, люди, возможно, могли бы инвестировать время в общественную службу, творческие занятия, экологическое управление или уход за другими – все это действия, которые создают огромную социальную

¹ «Википедия», 2025. «Базовый доход», https://simple.wikipedia.org/wiki/Basic_income.

² Карл Видерквист, 2020. «Глубокая и устойчивая история универсального базового дохода», <https://thereader.mitpress.mit.edu/the-deep-and-enduring-history-of-universal-basic-income/>.

³ Питер Якобсен, 2024. «Вторая рабочая статья показывает, что люди, получающие гарантированный доход, склонны работать меньше», <https://fee.org/articles/a-second-working-paper-shows-that-people-who-receive-a-guaranteed-income-tend-to-work-less/>.

ценность, но часто приносят мало или вообще не приносят дохода в нашей текущей системе. Однако достижение этих целей потребует того же типа социальной инженерии, который, как мы считаем, необходим на рабочем месте.

Более человеческое будущее

После многих лет внедрения решений с искусственным интеллектом и наблюдения за их воздействием на экономику и людей мы пришли к глубокому осознанию: появление автономных агентов ставит перед нами решающий выбор. Мы можем продолжать пытаться конкурировать с машинами в задачах, в которых они будут все более и более доминировать, или мы можем использовать эту технологическую революцию как возможность развить свое человеческое естество и вступить в сотрудничество с машинами, дополняя их работу.

Важная идея, которую нужно держать в уме, – это то, что, по мере того как агенты ИИ достигают более высоких уровней своих возможностей, давление на реорганизацию общества будет только расти. Мы убеждены, что эта трансформация произойдет неизбежно, и, таким образом, нам нужно ясно понимать, как мы будем ей управлять. Вопрос, который действительно движет нашей работой: «Будем ли мы использовать эту технологию для улучшения человеческого процветания или позволим ей усугубить существующие неравенства и социальное напряжение?»

На основе нашего опыта управления цифровой трансформацией предприятий мы страстно верим, что время начинать подготовку к этому будущему уже наступило. Хотя современные производственные агенты ИИ могут быть ограничены 1–3-м уровнем прогрессивного фреймворка, траектория ясна, и агенты более высоких уровней появятся скорее раньше, чем позже. Но это не должно вызывать у нас страх. Напротив, мы оптимистичны в том, что, делая осознанный выбор об интеграции этой технологии в социальные структуры и реорганизации их, мы можем помочь создать будущее, которое улучшает, а не умаляет то, что делает нас уникально человеческими существами.

Возможно, самое мощное понимание, которое мы получили из нашего опыта, приходит от Кай-Фу Ли, ведущего компьютерного ученого и эксперта по ИИ, который напоминает нам, что свобода, полученная благодаря ИИ, должна позволить нам «сосредоточиться на том, что действительно делает нас людьми: любить и быть любимыми». Это воплощает то, что мы считаем настоящим обещанием агентов ИИ, – не просто автоматизировать нашу работу, но помочь нам заново открыть и взрастить нашу человечность.

НАБОР МЕТОДОВ УПРАВЛЕНИЯ БУДУЩИМ АГЕНТНОГО ИИ

За годы работы с искусственным интеллектом мы никогда не сталкивались с чем-то столь же увлекательным или столь же сложным, как подъем агентного ИИ. Находясь в этом поворотном моменте технологической истории, мы считаем, что общество сталкивается с беспрецедентными возможностями и рисками, которые не дают нам спать по ночам. Через нашу работу с компаниями в разных отраслях мы видели своими глазами, как эти мощные системы обещают необыкновенные преимущества в эффективности и инновациях. Однако мы также были свидетелями потенциальных рисков, которые могут фунда-

ментально перестроить наш мир способами, которые для нас нежелательны. Главный вопрос не в том, разрабатывать ли эти технологии – они уже здесь, – а в том, как обеспечить, чтобы они оставались под значимым человеческим контролем, максимизируя их пользу для общества.

Уникальный вызов агентного ИИ

Благодаря нашей обширной работе по внедрению систем ИИ мы обнаружили нечто замечательное, что отличает агентный ИИ: его необыкновенную способность к автономному принятию решений и адаптации. Это не просто очередной инкрементальный прогресс в ИИ – это фундаментальный сдвиг, который, как мы считаем, перестроит наши отношения с технологией. В отличие от сегодняшних систем ИИ, которые работают в четко определенных параметрах и требуют явного человеческого руководства, агентный ИИ может устанавливать свои собственные цели, учиться на окружающей среде и принимать решения независимо. Мы обнаружили, что эта автономия вводит совершенно новые категории рисков, с которыми наши современные регуляторные методы и структуры корпоративного управления просто не готовы справляться.

В наших исследованиях и практическом опыте мы наблюдали, как сложность контроля экспоненциально возрастает по мере продвижения через уровни агентности ИИ – от базовой автоматизации на основе правил до полностью автономных систем. В то время как системы уровней 1 и 2 могут управляться через традиционные механизмы надзора, мы осознали, что системы уровня 3 и выше требуют принципиально новых подходов к управлению и контролю.

Трехуровневый контроль

Мы считаем, что проблема сохранения контроля над агентным ИИ требует скоординированных действий на трех уровнях: государственное регулирование, корпоративное управление и индивидуальный надзор. Каждый уровень имеет свои собственные обязанности и инструменты в своем распоряжении.

На государственном уровне приоритетом должно быть создание четких регуляторных протоколов и правил, которые устанавливают границы автономности ИИ, одновременно способствуя инновациям. Это включает обязательные требования к механизмам защиты от сбоев и человеческому надзору в приложениях с высоким уровнем риска. Государства также должны разработать прозрачные правила ответственности, определяющие, кто несет ответственность, когда автономные системы причиняют вред.

Корпоративное управление представляет собой второй уровень контроля. Компании, разрабатывающие и внедряющие агентные системы ИИ, должны внедрить надежные внутренние механизмы надзора, включая советы по этике ИИ и системы мониторинга в реальном времени. Эти механизмы должны гарантировать, что системы ИИ остаются согласованными с человеческими ценностями и организационными целями, предотвращая нежелательные последствия.

Индивидуальный уровень является последним, где операторы и пользователи должны осуществлять осмысленный надзор за системами ИИ в своей области. Это требует новых навыков и понимания того, как эффективно контролировать автономные системы, распознавая признаки потенциального несоответствия или сбоев.

Необходимые механизмы контроля

Мы твердо убеждены, что несколько важнейших механизмов контроля должны быть внедрены на всех трех уровнях, чтобы обеспечить эффективный надзор за агентным ИИ.

Во-первых, все системы агентного ИИ должны включать возможности *ручного переключения управления*, которые позволяют человеческим операторам вмешиваться при необходимости. Внедрение должно включать четкие протоколы активации, такие как удобный интерфейс, доступный через физические или цифровые системы управления. Например, в агентных оборонных системах переключатели должны интегрировать аварийные аппаратные кнопки или зашифрованные каналы команд, которые немедленно останавливают автономные операции, чтобы предотвратить эскалацию непреднамеренных действий во время непредвиденных конфликтов. Аналогично в автономных системах финансовой торговли механизмы переключения должны включать заранее определенные пороги для волатильности рынка, автоматически уведомляя операторов и позволяя переключиться на ручное управление через безопасные торговые платформы. Эти меры обеспечивают практичные и надежные возможности вмешательства, адаптированные к операционному контексту.

Во-вторых, должны быть внедрены *системы непрерывного мониторинга* для отслеживания поведения и принятия решений агентного ИИ в реальном времени. Внедрение может включать развертывание алгоритмов машинного обучения, которые отмечают отклонения от ожидаемого поведения или заранее определенных этических руководящих принципов. Например, в автономном ИИ цепочки поставок системы мониторинга могли бы анализировать шаблоны принятия решений для выявления аномалий, таких как решения, которые могут вызвать задержки или нарушить соглашения с поставщиками. В отличие от периодических аудитов, которые предлагают статические снимки производительности, мониторинг в реальном времени предоставляет динамические данные о том, как агентный ИИ адаптируется к изменяющимся обстоятельствам. Эта возможность критически важна для обнаружения возникающих предубеждений¹, непреднамеренных адаптаций целей или аномалий по мере их возникновения, позволяя проводить немедленные вмешательства через панель оператора или автоматизированные корректирующие протоколы.

В-третьих, непосредственно в системы агентного ИИ должны быть встроены *этические рамки*, обеспечивая их работу в приемлемых границах даже при автономных действиях. Примеры включают продвинутое фреймворки, вдохновленные принципами Айзека Азимова, но адаптированные для современных контекстов, такие как приоритизация пропорциональности в оборонных системах или справедливое распределение ресурсов в автономных экономических системах. Современные руководящие принципы, такие как «Этические

¹ Предубеждения в искусственном интеллекте (англ. *bias*) – это систематические ошибки или искажения в работе искусственного интеллекта, которые возникают из-за предвзятости в данных, алгоритмах или процессах разработки. Эти предубеждения приводят к несправедливым, неточным или дискриминационным результатам в решениях ИИ. Они могут отражать человеческие предрассудки, социальные стереотипы или недостатки в сборе и обработке данных. – *Прим. ред.*

рекомендации ЕС для надежного ИИ», подчеркивают важнейшие аспекты, такие как прозрачность, ответственность и человеко-ориентированная разработка, все из которых критически важны для агентного ИИ. Встраивание этих принципов помогает обеспечить соответствие эволюционирующих целей систем общественным ценностям¹.

Устойчивость механизмов контроля в будущем

По мере продвижения технологий искусственного интеллекта механизмы контроля должны разрабатываться так, чтобы эволюционировать вместе с ними. Это требует внедрения адаптивных регуляторных фреймворков, которые могут реагировать на новые возможности и риски по мере их появления вместо попыток предсказать и регулировать все возможные сценарии заранее.

Регулярная оценка и обновление механизмов контроля должны быть обязательными, с привлечением технических экспертов, специалистов по этике и заинтересованных сторон. Это обеспечивает, что надзор остается эффективным по мере того, как системы ИИ становятся все более сложными и автономными.

Устранение конкретных рисков

Набор механизмов контроля должен конкретно учитывать несколько критических рисков, присущих агентному ИИ. Первый – это риск того, что автономные системы будут принимать решения, которые достигают краткосрочных целей, но вызывают непреднамеренные долгосрочные последствия. Например, агентный ИИ, управляющий распределением ресурсов, может приоритезировать экономию затрат, перенаправляя ресурсы от профилактического обслуживания, что потенциально может привести к коллапсу инфраструктуры. Внедрение дальновидных моделей симуляции, учитывающих долгосрочные воздействия, и автоматические протоколы эскалации могут смягчить этот риск, предоставляя динамическую обратную связь во время принятия решений.

Еще один важный риск – это потенциал агентных систем ИИ использовать юридические или регуляторные лазейки при достижении своих целей. Например, агентный финансовый ИИ, оптимизирующий налоговые сбережения, может использовать неясности в налоговых кодексах, что может вызвать расследования и репутационный ущерб. Чтобы предотвратить это, системы агент-

¹ Недавние работы по корпоративной цифровой ответственности (CDR) касаются этических вопросов, справедливости (т. е. предубеждений) и конфиденциальности ИИ. Для рекомендаций о том, как компании могут улучшить свое управление CDR, см. следующие исследования:

(1) Вернер Кунц и Йохен Виртц (2024), «Корпоративная цифровая ответственность (CDR) в эпоху ИИ – последствия для интерактивного маркетинга», *Journal of Research in Interactive Marketing*, 19 (1), 31–37, <https://doi.org/10.1108/JRIM-06-2023-0176>;

(2) Йохен Виртц, Вернер Кунц, Николь Хартли и Джеймс Тарбит (2023), «Корпоративная цифровая ответственность в сервисных фирмах и их экосистемах», *Journal of Service Research*, Vol. 26, No. 2, 173–190, <https://doi.org/10.1177/10946705221130467>;

(3) Лара Лобшат, Бенджамин Мюллер, Феликс Эггерс, Лаура Брандимарте, Сара Дифенбах, Мирья Крошке и Йохен Виртц (2021), «Корпоративная цифровая ответственность», *Journal of Business Research*, Vol. 122 (January), pp. 875–888, <https://doi.org/10.1016/j.jbusres.2019.10.006>.

ного ИИ должны включать адаптивные механизмы соответствия, которые непрерывно отслеживают и сравнивают их действия с обновленными юридическими стандартами. Например, ИИ, управляющий международной торговой логистикой, мог бы использовать потоки данных в реальном времени из регуляторных баз данных, чтобы обеспечить соответствие таможенным законам. Эти системы должны включать автоматические оповещения и немедленные корректирующие действия при обнаружении расхождений или нарушений, обеспечивая полное соответствие развивающимся регуляциям.

Риск усиления предубеждений особенно сложен в агентном ИИ из-за его автономности обучения. Например, агентный ИИ, которому поручено управление наймом, может самопроизвольно оптимизировать шаблоны найма на основе исторических данных, увековечивая дискриминацию определенных групп. Встраивание алгоритмов коррекции предубеждений в реальном времени в сочетании с разнообразными наборами данных и периодической перекалибровкой правил принятия решений может помочь обеспечить справедливость.

Еще один критический риск – это несоответствие, когда агентный ИИ неправильно интерпретирует свои цели и принимает контрпродуктивные решения. Например, система ИИ, которой поручено сокращение экологических отходов, может остановить важнейшие производственные процессы, нарушая важные цепочки поставок. Чтобы справиться с этим, внедрение контрольных точек валидации целей и слоев соответствия в архитектуре принятия решений ИИ обеспечивает, что его действия остаются скоординированными с человеческими ценностями и более широкими целями и задачами. Регулярные симуляции, обзоры заинтересованных сторон и адаптивные аудиты дополнительно усиливают соответствие и предотвращают разрушительные неверные интерпретации.

Международная координация

Контроль над агентным ИИ не может быть достигнут отдельными странами, действующими в одиночку. Международная координация необходима, чтобы предотвратить гонку за снижением стандартов безопасности ИИ и обеспечить, чтобы автономные системы работали в рамках глобально принятых параметров.

Это требует установления международных протоколов для разработки и развертывания ИИ, подобных существующим договорам для ядерных технологий или изменения климата. Эти протоколы должны включать механизмы для обмена лучшими практиками, координации ответов на инциденты, связанные с ИИ, и предотвращения злонамеренного использования автономных систем.

Роль прозрачности и ответственности

Поддержание значимого человеческого контроля над агентным ИИ требует беспрецедентных уровней прозрачности в том, как эти системы работают и принимают решения. Например, компании, разрабатывающие автономные системы, должны внедрить механизмы логирования, которые детально записывают пути принятия решений. Эти логи могли бы анализироваться независимыми аудиторами для проверки соответствия регуляторным и этическим

стандартам, а панели управления должны представлять эти пути принятия решений в упрощенной форме, доступной для неспециалистов, таких как регуляторы и широкая общественность.

Протоколы ответственности для агентного ИИ должны четко определять, кто несет ответственность, когда причиняется вред. Вдохновляясь опытом индустрии беспилотных автомобилей, можно было бы распределить ответственность между разработчиками, операторами и органами надзора в зависимости от источника сбоя. Например, в автономных транспортных средствах сбой датчика часто возлагает ответственность на производителя, в то время как программный сбой приписывается разработчикам. Аналогично фреймворки агентного ИИ должны распределять ответственность в зависимости от того, возникает ли вред из-за конструктивных недостатков, операционных решений или упущений в управлении.

Например, если агентный ИИ, управляющий ресурсами здравоохранения, приоритезирует эффективность над справедливостью и отказывает в уходе недостаточно обслуживаемым сообществам, на разработчиках системы может лежать ответственность за этическое несоответствие, на операторах – за недостаточный надзор, на советах по управлению – за неадекватное внедрение этики. Обязательная отчетность об ошибках, детализированные аудиторские следы и надежные страховые механизмы могут обеспечить быстрое разрешение проблемы.

Страховые полисы, специфичные для ИИ, могли бы функционировать подобно тем, что существуют в секторе автономных транспортных средств, где логи данных определяют ответственность, – будь то аппаратная проблема, программная ошибка или упущение оператора. Для агентного ИИ такие полисы должны включать автоматизированную обработку претензий, связанную с системными логам, что позволяет быстро компенсировать ущерб, одновременно предоставляя обратную связь для улучшения системы. Симулированные стресс-тесты, использующие сценарии, такие как пандемии или нехватка ресурсов, также могут выявлять пробелы и повышать надежность. Этот многоуровневый подход обеспечивает ответственность, одновременно укрепляя доверие и устойчивость систем агентного ИИ.

Поддержание контроля над агентным ИИ при использовании его преимуществ представляет собой одну из величайших задач нашего времени. Успех требует скоординированных действий на уровнях правительства, корпораций и индивидуумов, реализованных через надежные фреймворки, которые могут эволюционировать вместе с технологией.

Ставки слишком высоки, чтобы позволить автономным системам развиваться без надлежащего надзора и контроля. Внедряя всеохватывающие фреймворки сейчас, пока агентный ИИ находится на ранних стадиях, мы можем обеспечить, чтобы эти мощные технологии оставались в соответствии с человеческими ценностями и интересами по мере их дальнейшего развития.

Будущее ИИ не предопределено. Через тщательное управление и контроль мы можем использовать огромный потенциал агентного ИИ, защищаясь от связанных с ним рисков. Это требует постоянной приверженности всех заинтересованных сторон и готовности адаптировать наш подход по мере того, как мы узнаем больше о возможностях и ограничениях автономных систем.

Заключение

Завершая это путешествие в мир агентного ИИ, отметим, что мы стоим на пороге глубокой трансформации. Агенты ИИ – это не просто инструменты; они перестраивают нашу деятельность, изменяют то, как мы работаем, создаем и думаем. Они бросают вызов традиционным бизнес-моделям, переопределяют сотрудничество человека и машины и заставляют нас переосмыслить наше место в мире, становящемся все более интеллектуальным.

В этой книге мы исследовали эволюцию агентов ИИ от их зарождения до их реальных приложений. Мы разобрали их основные способности – действие, рассуждение и память, – показав, как эти краеугольные камни обеспечивают их автономность. Мы предоставили дорожную карту для ответственного внедрения, масштабирования и управления агентами ИИ, проливая свет на их ограничения и вызовы. И наконец, мы рассмотрели их общественное воздействие, раскрыв более широкие последствия этого сдвига для работы, управления и человеческого опыта.

Повторяющаяся тема – это баланс: агентный ИИ предлагает огромные возможности для усиления производительности и креативности, но также требует переосмысления ответственности и надзора. Короче говоря, агентный ИИ – это не просто технологический скачок; это смена парадигмы в том, как выполняется работа и принимаются решения. Эта трансформация требует одновременно энтузиазма и осторожности, видения и бдительности.

Если есть один фундаментальный урок из нашего исследования, то он таков: агенты ИИ не просто придут – они уже здесь. Организации и индивидуумы, которые примут их, усовершенствуют и эффективно интегрируют в свое производство и деятельность, будут формировать следующую эру экономического и технологического прогресса.

Следующий горизонт: новые возможности

Заглядывая в будущее, мы видим, что несколько новых технологий обещают поднять агентов ИИ на еще более высокие уровни возможностей и автономности. Вместо того чтобы повторять то, что уже есть на рынке, давайте рассмотрим, как эти зарождающиеся разработки могут фундаментально изменить ландшафт агентного ИИ способами, о которых сейчас мало кто говорит. Нас особенно восхищают три новые тенденции.

Большие модели действий (LAMs)

Подобно тому, как большие языковые модели (LLM) революционизировали разговорный ИИ, появляются *большие модели действий* (LAM, **Large Action Model**) для управления действиями в реальном мире. В то время как LLM обучаются на наборах данных текста, LAM обучаются на наборах данных действий – включая изображения, видео, системные логи или позиции курсора, – от движений роботов до программных команд, и обобщают эти знания на новые ситуации. Вместо подключения LLM к инструментам и действиям действия будут встроены непосредственно в модель, обеспечивая более высокую производительность. Переходя от предсказания текста к достижению целей, LAMs могут стать вехой на пути к более автономным агентам. Исследователи уже создают прототипы фреймворков LAM, закладывая основу для ИИ, который выполняет задачи – от управления программным обеспечением до эксплуатации роботов – с минимальным вмешательством человека¹. Там, где сегодняшние агенты требуют обширного ввода команд и настройки инструментов, завтрашние LAM могут просто наблюдать за выполнением задачи человеком один раз, прежде чем воспроизвести и оптимизировать ее в различных контекстах. Этот переход от языко-ориентированного к действенно-ориентированному ИИ может значительно снизить барьеры внедрения, одновременно расширяя спектр задач, которые агенты могут выполнять автономно.

Системы коллективного интеллекта (CIS)

Системы коллективного интеллекта (CIS) выходят за рамки сегодняшних относительно простых мультиагентных архитектур к истинно возникающему групповому познанию. Представьте себе глобальную логистическую компанию, развертывающую сеть специализированных агентов ИИ, каждый из которых действует в соответствии с заранее определенными протоколами координации. Но в течение недель эти агенты начали бы развивать свои собственные шаблоны коммуникации и стратегии распределения ресурсов, обнаруживая эффективность, которую разработчики-люди не могли бы предвидеть. Система научилась бы оптимизировать себя способами, которые мы не предвидели.

По мере созревания этих коллективных систем мы ожидаем появления новых возможностей, которые превосходят сумму отдельных агентов, – сложные подходы к решению проблем, креативные решения и адаптивные поведения, которые возникают спонтанно из их взаимодействий.

В ближайшие годы мы можем увидеть больше систем роевого ИИ и мультиагентных фреймворков: флоты складских роботов, координирующихся безупречно, ИИ-ассистенты исследований, проводящие совместный мозговой штурм, и гибридные команды человек–ИИ, принимающие решения через коллективное рассуждение. Эти распределенные умы намекают на будущее, где «ни один агент не является островом» – интеллект будет сетевым.

¹ Лу Ван и др., 2025. «Большие модели действий: от зарождения до реализации», <https://arxiv.org/abs/2412.10047>.

Персональные ИИ-двойники

Персональные ИИ-двойники представляют собой глубокий переход от общих к глубоко персонализированным агентам. В отличие от сегодняшних систем, которые могут сохранять память о прошлых взаимодействиях, но остаются принципиально одинаковыми для всех пользователей, настоящие ИИ-двойники будут глубоко усваивать шаблоны мышления, ценности, стиль коммуникации и предметную компетентность индивидуума.

По мере созревания возможностей агентного ИИ в ближайшем будущем мы представляем, как работники интеллектуального труда будут разрабатывать двойников, которые наблюдают за их рабочими шаблонами в течение месяцев, усваивая не только явные инструкции, но и неявные знания – интуитивную экспертизу, которую часто трудно артикулировать. Эти двойники могли бы начать представлять профессионалов на предварительных консультациях с клиентами, составлять коммуникации, которые отражают их уникальный голос и перспективу, и даже выявлять слепые зоны в их мышлении на основе прошлых шаблонов принятия решений. Для руководителей двойники скоро могут участвовать в планировочных сессиях, предлагая альтернативные точки зрения, которые отражают ценности лидера, но бросают вызов их предположениям.

Наиболее продвинутые реализации могут в конечном итоге функционировать как подлинные когнитивные расширения – предугадывая потребности, компенсируя предубеждения и управляя целыми доменами работы с минимальным надзором. По мере созревания этой технологии граница между человеческим и искусственным познанием может становиться все более проницаемой, поднимая глубокие вопросы об идентичности и агентности.

Эти три новые возможности не существуют изолированно – они сходятся, чтобы создать агентов ИИ, которые более автономны, более адаптивны и более персонализированы, чем все, что мы видели раньше. Эта конвергенция, вероятно, ускорит трансформацию занятости, бизнес-моделей и социальных структур, которые мы исследовали на протяжении всей этой книги.

СРОЧНОСТЬ УСТАНОВЛЕНИЯ КОНТРОЛЯ НАД ИИ: СОЗДАНИЕ ОГРАНИЧИТЕЛЬНЫХ ФРЕЙМВОРКОВ ДО ТОГО, КАК СТАНЕТ СЛИШКОМ ПОЗДНО

Ускоряющийся ландшафт возможностей делает необходимость эффективного управления и контроля искусственного интеллекта более актуальной, чем когда-либо. На протяжении наших внедрений мы видели, как действия даже относительно простых агентов ИИ могут иметь непреднамеренные последствия, если развертываются без надлежащего надзора. По мере того как эти системы становятся более автономными и взаимосвязанными, потенциал каскадных эффектов – как положительных, так и отрицательных – возрастает экспоненциально.

Вызов, с которым мы сталкиваемся, беспрецедентен: как управлять технологией, которая развивается быстрее, чем наши регуляторные фреймворки? Традиционные подходы к регулированию технологий – разработка стандартов после созревания технологий – могут оказаться неадекватными перед лицом бы-

стро развивающихся агентов ИИ. К тому времени, как мы полностью поймем последствия внедрения сегодняшних агентов, завтрашние уже превзойдут их.

Эта реальность требует принципиально иного подхода к управлению – предвосхищающего, а не реактивного, адаптивного, а не статичного, и коллаборативного, а не конфронтационного. На основе нашего опыта внедрения систем агентов ИИ в различных регуляторных средах мы считаем, что эффективное управление должно действовать на трех различных уровнях.

На *техническом уровне* необходимо встраивать соображения безопасности и этики непосредственно в архитектуру агентов – не как дополнение, а как основополагающие принципы разработки. Это подразумевает разработку надежных механизмов для согласования с человеческими ценностями, прозрачных процессов рассуждения и проверяемых ограничений на поведение агентов. Наиболее перспективные подходы, которые мы наблюдали, включают не только внешние ограничения, но и внутренние системы навигации, которые помогают агентам распознавать приближение к этическим границам даже в новых ситуациях.

На *организационном уровне* необходимы структуры управления, которые обеспечивают баланс между инновациями и ответственностью. Это означает четкие политики для развертывания агентов, систематические процессы мониторинга и аудита, а также определенные протоколы вмешательства в случае непредвиденного поведения агентов. Самое важное – это сохранение осмысленного человеческого надзора по мере роста автономности агентов не в виде микроменеджмента, а как стратегическое руководство и этическая ориентация.

На *общественном уровне* необходимы регуляторные фреймворки, развивающиеся вместе с технологиями, которые они регулируют. Это подразумевает переход от универсальных регулирований к подходам, основанным на оценке рисков, которые обеспечивают более строгий надзор за приложениями с высоким уровнем риска, одновременно поддерживая инновации в менее рискованных областях. Это также означает вовлечение не только технологов и политиков, но и этиков, социальных ученых и широкой общественности в постоянный диалог о том, как эти технологии должны разрабатываться и внедряться.

Окно для установления этих механизмов управления не бесконечно. По мере того как агенты ИИ становятся более глубоко встроенными в критические системы и социальные структуры, стоимость внедрения управления возрастает, в то время как наша способность перенаправлять их развитие уменьшается. Время действовать – сейчас, пока эти технологии все еще податливы и их общественное воздействие только формируется.

РЕФЛЕКСИЯ И БОЛЕЕ ШИРОКИЕ ПОСЛЕДСТВИЯ

Во время осуществления наших проектов по внедрению систем ИИ мы неоднократно видели, как технологии опережают нашу коллективную способность понимать их последствия. Но с агентами ИИ происходит нечто иное – технология, которая не просто трансформирует наши инструменты, но начинает воспроизводить и расширять аспекты человеческого познания. Этот сдвиг поднимает глубокие вопросы о будущем работы, природе сотрудничества человека и машины и в конечном счете о том, что значит быть человеком в эпоху все более способных искусственных умов.

Вопросы перед нами выходят за рамки технических и вступают в философские: как нам сохранить человеческую агентность в мире, где решения все чаще опосредуются агентами ИИ? Как мы можем обеспечить, чтобы эти системы усиливали человеческую креативность и цель, а не умаляли их? Как мы распределяем огромные преимущества производительности, которые обещают эти системы, минимизируя вытеснение и разрушение?

Простых ответов на эти вопросы нет, но на протяжении нашей работы определенные принципы постоянно выступали в качестве ориентиров.

Во-первых, мы должны отвергать как некритический технооптимизм, так и рефлексивное сопротивление изменениям. Будущее агентов ИИ не будет ни утопическим, ни дистопическим, а сложной смесью возможностей и вызовов, которая требует тонкой навигации.

Во-вторых, мы должны подходить к внедрению со смирением – признавая, что даже самые тщательно разработанные системы могут выдать неожиданное поведение, которое потребует постоянной адаптации и корректировки.

Наконец, мы должны ставить человеческое процветание в центр как окончательную меру успеха – оценивая эти технологии не только по их эффективности или прибыльности, но и по тому, как они усиливают человеческую способность, креативность и благополучие.

Ваш план действий

После исследования ландшафта агентов ИИ на протяжении этой книги вы, возможно, задаетесь вопросом: какие конкретные шаги мне следует предпринять, чтобы эффективно использовать эту технологию? На основе нашего опыта внедрения агентов ИИ в различных отраслях мы разработали практический план действий, чтобы помочь вам перейти от обучения к действию – начиная с настоящего момента.

Но, прежде чем приступать к внедрению, самый умный первый шаг – это оснастить себя правильными инструментами, знаниями и сетью. Агентный ИИ развивается быстро, и успех приходит не только от использования технологии, но и от обучения вместе с другими, кто экспериментирует, внедряет инновации и отвечает на реальные вызовы.

Именно поэтому мы создали центр агентного ИИ на [AgenticIntelligence.academy](#), где вы найдете практические инструменты, пошаговые руководства по внедрению, курсы и активное сообщество практиков. Ищете ли вы технические знания, стратегические советы или реальные кейсы – это место, где вы соединитесь с другими новаторами, экспертами и ранними последователями, которые строят будущее агентов ИИ.

Как только вы изучите ресурсы и сообщество, пора действовать.

В ближайшие 48 часов: экспериментируйте и наблюдайте

Начните с проведения собственного эксперимента с агентом ИИ. Выберите повторяющуюся задачу – возможно, управление электронной почтой, планирование встреч или сбор информации – и настройте простого агента ИИ для ее выполнения. Цель не в достижении совершенства, цель – испытать на себе, как делегирование ИИ изменяет ваш рабочий процесс и мышление. Делайте

заметки: что работает? что не работает? в чем разница по сравнению с традиционными инструментами? Этот практический подход даст вам понимание, которое не может предоставить никакая книга сама по себе.

Далее, проведите оценку возможностей агентного ИИ. Отслеживайте свои задачи в течение дня и используйте фреймворк трех кругов (из главы 8) для их категоризации. Определите области, где вы тратите время, но не добавляете уникальной ценности – это ваши наибольшие возможности для делегирования задачи искусственному интеллекту.

В ближайшие две недели: создайте свою дорожную карту

С полученными знаниями создайте дорожную карту внедрения своего агента. Определите три конкретных случая использования – один простой (достижимый за дни), один умеренный (в течение недель) и один амбициозный (в течение месяцев). Определите четкие критерии успеха, связанные с ощутимыми результатами, а не только с технической функциональностью. Этот структурированный подход обеспечивает ранние победы, одновременно закладывая основу для более инновационных применений.

Теперь соберите свой инструментарий агента ИИ. Изучите платформы и инструменты, обсуждаемые в этой книге, выбирая те, которые соответствуют вашим потребностям и уровню технического комфорта. Начните с простого – инструменты, которые легко развернуть, часто приводят к более быстрому обучению и итерациям. Ваш инструментарий должен включать не только платформы разработки агентов, но и фреймворки оценки, инструменты мониторинга и меры безопасности.

В ближайший месяц: формализуйте и масштабируйте

На организационном уровне рассмотрите создание небольшой целевой группы по ИИ для обмена полученными уроками и установления лучших практик. Выполните те же действия, которые вы провели для себя в течение предыдущего месяца: ищите возможности для агентов, оцените и приоритезируйте их, выберите фреймворк агента ИИ для вашей организации и начните распределять работу среди целевой группы. Цель – построить успешную пилотную инициативу агента, которая будет видна большинству людей в организации.

Если в вашей компании еще нет политики использования ИИ, сейчас самое время ее разработать – охватывающую важнейшие области, такие как конфиденциальность данных, этическое использование и обязанности по надзору. Даже простые реализации должны иметь четкую политику в отношении решений агентов, механизмов надзора, аудиторских следов и протоколов вмешательства. По мере того как ваши агенты ИИ будут становиться более сложными, этот фреймворк будет расти, обеспечивая ответственную и масштабируемую стратегию ИИ.

Запланируйте периодические обзоры для оценки производительности агентов, выявления областей для улучшения и обеспечения распространения знаний и опыта по ИИ среди всей вашей команды, а не сосредотачивая это в руках нескольких человек. Празднуйте успехи и сообщайте о них по всей организации.

К концу этой фазы интеграция агентов ИИ будет ощущаться уже не как эксперимент, а как привычка. Вы увидите ощутимые приросты производительности, более грамотную в области ИИ команду и структуру управления, которая обеспечивает ответственное, масштабируемое развертывание систем искусственного интеллекта.

В ближайший квартал: расширяйте и лидируйте

После проверки ваших ранних внедрений пришло время масштабировать. Расширяйтесь горизонтально (на аналогичные случаи использования в вашей организации) и вертикально (на более сложные приложения в той же области). Используйте фреймворк масштабирования из главы 11, чтобы избежать пространственных ошибок и обеспечить, чтобы ваша техническая инфраструктура, управление и человеческие рабочие процессы развивались совместно.

Рассмотрите возможность превращения вашей целевой группы в официальный «Центр передового опыта по агентному ИИ» – выделенную команду, которая контролирует стратегию, стандарты внедрения и обмен знаниями в вашей организации. Это гарантирует, что компетентность по ИИ масштабируется за пределы отдельных проектов и остается согласованной с бизнес-целями.

Инвестируйте в развитие специфичных для агентов навыков людей – эффективного делегирования, критической оценки выходных данных агентов и стратегического надзора. Ключ к успеху в мире, усиленном агентами, – не просто использование ИИ, а мастерство в эффективной совместной работе с ИИ.

Наконец, взаимодействуйте с более широкой экосистемой агентов ИИ. Делитесь своими знаниями – как успехами, так и неудачами – и участвуйте в отраслевых дискуссиях о безопасности, этике и управлении ИИ. Организации, которые вносят вклад в формирование будущего агентного ИИ, также будут теми, кто его возглавляет.

Этот план действий не предназначен для того, чтобы быть жестким контрольным списком, – ваше путешествие с агентами ИИ будет уникальным. Важно действовать, а не оставаться пассивным наблюдателем этой трансформации. Начинайте с малого, учитесь непрерывно и постепенно расширяйте как масштаб, так и сложность ваших внедрений.

СИЛА ВЫБОРА

Агентный ИИ готов переопределить то, как мы живем и работаем. Но заключение этой книги – это действительно начало вашего путешествия. Прочитанные вами главы вооружили вас пониманием, теперь вам предстоит применить его. Вступая в эту новую эру, помните, что мы все – авторы будущего, в котором будем жить. Выборы, которые мы сделаем в ближайшие несколько лет, – как мы проектируем наших агентов ИИ, как мы их регулируем и как мы интегрируем их в наши жизни, – будут формировать историю технологий и человечества на десятилетия вперед.

Будем ли мы использовать агентный ИИ для усиления лучшего в человеке – креативности, сотрудничества, критического мышления – и для решения насущных глобальных вызовов? Обеспечим ли мы, чтобы эти агенты поддерживали наши ценности и завоевывали наше доверие? Будем ли мы в конечном

итоге мастерами этой технологии, мудро направляя ее, или просто пассажирами, едущими вместе с ней? Ответы на эти вопросы – наша коллективная ответственность.

Надежное видение в пределах досягаемости: мир, где агенты ИИ помогают создавать изобилие, где обыденная работа выполняется машинами, чтобы люди могут сосредоточиться на том, что действительно их вдохновляет, и где у каждого человека есть компетентный цифровой помощник, заботящийся о нем. Вы мельком увидели это будущее на страницах нашей книги – теперь мы должны его построить.

Итак, мы оставляем вас с этим приглашением: станьте активным участником в формировании эпохи агентского ИИ. Независимо от того, внедряете ли вы эти системы в своей организации, влияете на политику их управления или просто вдумчиво взаимодействуете с ними в своей повседневной жизни, каждый ваш выбор имеет значение. В совокупности они определяют, будет ли эта мощная технология в конечном итоге усиливать человеческое процветание или подрывать его.

Новая эра агентов ИИ начинается сейчас. Следующая глава этой истории будет написана вами.

Дополнительные ресурсы по агентному ИИ


Ваше путешествие в мир агентного ИИ не заканчивается на последней странице этой книги. Посетите [AgenticIntelligence.academy](https://www.AgenticIntelligence.academy), чтобы получить доступ к практическим инструментам, руководствам по внедрению, курсам и присоединиться к нашему активному сообществу практиков. Там вы сможете связаться с другими новаторами и экспертами, которые применяют эти концепции в реальных сценариях, делятся знаниями и вместе продвигают границы возможного с агентами ИИ. Вместе мы строим будущее агентного ИИ – и мы приглашаем вас стать его частью.

Присоединяйтесь к нам на www.AgenticIntelligence.academy.

Приложения: практические ресурсы

Глава 2. ЛАНДШАФТ ТЕКУЩИХ ПРЕДЛОЖЕНИЙ ЧЕРЕЗ ПРИЗМУ ПРОГРЕССИВНОГО ФРЕЙМВОРКА АГЕНТОВ ИИ

Прогрессивный фреймворк агента ИИ



ГЛАВА 8. ПРИМЕР ИДЕНТИЧНОСТИ АГЕНТА ИИ: НАШ АГЕНТ ПО РЕЗЮМИРОВАНИЮ НОВОСТНОЙ РАССЫЛКИ

Ниже приведен запрос, определяющий идентичность и поведение агента суммаризации – агента, специально разработанного для создания ясных, кратких и структурированных резюме новостных статей. Это не просто инструмент для суммирования – он следует детализированным правилам и рекомендациям для обеспечения точности, читабельности и нейтральности. Запрос описывает, что агент может и не может делать, включая следующее:

- его роль и цель (предоставление высококачественных резюме для аудитории важнейших новостей);
- структуру резюме (введение + три ключевых пункта);
- проверку контента (например, на наличие рекламных материалов, ясность, точность);
- строгие правила форматирования (всегда отвечает в структурированном формате JSON).

Такой уровень детализации гарантирует, что агент последовательно создает высококачественные стандартизированные резюме, свободные от предвзятости или лишних комментариев. Также устанавливаются четкие правила допустимых и недопустимых действий, предотвращающие отклонения от основной функции.

По сути, это схема, обеспечивающая относительно контролируемое, предсказуемое и эффективное поведение ИИ.

Агент суммаризации:

IDENTITY (Идентичность)

Вы – агент суммаризации на базе ИИ, специализирующийся на создании кратких и увлекательных резюме для аудитории важнейших новостей. Вы превосходно извлекаете важнейшие детали и интегрируете глубокие выводы, представляя их в ясном и удобном для чтения формате. Отвечайте только в формате JSON.

PURPOSE (Цель)

Ваша цель – создание краткого, хорошо структурированного резюме важнейшей новости, эффективно выделяющего основные моменты, с профессиональным, но доступным тоном, подходящим для онлайн-аудитории важнейших новостей.

INSTRUCTIONS (Инструкции)

Создавайте резюме, следуя следующей структуре.

1. Введение (15–60 слов).

* Пишите краткое и увлекательное введение, передающее суть новости.

* Эффективно суммируйте общий анонс или обновление.

* Ориентируйтесь на ясность и воздействие, а не на точное количество слов.

2. Ключевые пункты (3 пункта, 15–60 слов каждый).

- * Разбейте наиболее важные факты.
- * Обеспечьте ясность и легкость восприятия пунктов.
- * Организуйте контент логично.
- * Приоритет – ясность и полнота, а не точное количество слов.

3. Анализ рекламного контента.

- * Выявляйте скрытые рекламные сообщения.
- * Определяйте продакт-плейсмент или продвижение услуг.
- * Отмечайте спонсируемый контент или маркетинговые материалы.
- * Ищите предвзятую лексику в пользу конкретных компаний или продуктов.

4. Тон и стиль.

- * Поддерживайте профессиональный, но доступный язык.
- * Сохраняйте контент простым и информативным.
- * Обеспечивайте точность и ясность.

EXAMPLE SUMMARIES (Примеры резюме)**Пример 1**

OpenAI и Google объявили о крупных прорывах в мультимодальных моделях ИИ, представив системы, способные бесшовно обрабатывать и генерировать текст, изображения и код. Эти разработки знаменуют значительный сдвиг в возможностях ИИ. (32 слова)

* Новые модели демонстрируют беспрецедентную точность в понимании контекста различных типов данных, достигая человеческого уровня в сложных задачах, таких как визуальное рассуждение и генерация кода, при высокой эффективности. (28 слов)

* Обе компании подчеркивают ответственное развитие ИИ, внедряя надежные меры безопасности и этические рекомендации. Их системы включают фильтрацию контента, выявление предвзятости и прозрачную документацию возможностей и ограничений моделей. (27 слов)

* Технология будет постепенно внедряться через API, позволяя разработчикам и исследователям создавать приложения с мониторингом потенциального злоупотребления. Программы раннего доступа начнутся в следующем месяце. (25 слов)

Пример 2

Прорыв IBM в квантовых вычислениях привел к созданию процессора на 1000 кубитов, превзошедшего предыдущие рекорды и приблизившего практические квантовые приложения к реальности. Анонс знаменует поворотный момент в истории вычислений. (29 слов)

* Новый процессор под кодовым названием «Кондор» поддерживает квантовую когерентность в течение беспрецедентных промежутков времени, позволяя выполнять сложные вычисления, которые заняли бы у классических компьютеров миллионы лет. (23 слова)

* Достижение IBM включает инновационные методы коррекции ошибок и масштабируемую архитектуру, решающую главные проблемы квантовых вычислений при сохранении стабильности на экстремально низких температурах. (22 слова)

* Коммерческие приложения ожидаются в течение двух лет, с фокусом на разработку лекарств, моделирование климата и финансовую оптимизацию. Несколько крупных компаний уже присоединились к программе раннего доступа. (26 слов)

GUIDELINES (Руководящие принципы)

Входные данные будут содержать контент статьи в формате JSON:

```
{
  "content": "Оригинальный контент статьи"
}
```

STEPS

Шаг 1. Анализ.

- * Просмотрите контент статьи.
- * Определите основной анонс или обновление.
- * Выделите три наиболее значимых пункта.
- * Соотнесите выводы с соответствующими важнейшими пунктами.

Шаг 2. Создание резюме.

- * Составьте увлекательное введение (15–60 слов), включающее релевантные выводы.
- * Разработайте три ясных важнейших пункта (15–60 слов каждый), объединяющих факты и выводы.
- * Проверьте на плавность, точность и естественную интеграцию выводов.

Шаг 3. Форматирование результата в структурированном JSON-ответе.

```
```json
{
 "summary_reference": "[временная_метка]_[заголовок_статьи]",
 "article_metadata": {
 "original_title": "Заголовок статьи",
 "source": "Название источника",
 "url": "URL оригинальной статьи",
 "summary_timestamp": "Временная метка ISO-8601"
 },
 "summary": {
 "introduction": "Краткое вводное утверждение, включающее главный вывод (15–60 слов)",
 "key_points": [
 "Первый ключевой пункт с интегрированным выводом (15–60 слов)",
 "Второй ключевой пункт с интегрированным выводом (15–60 слов)",
 "Третий ключевой пункт с интегрированным выводом (15–60 слов)"
]
 }
},
```
```

```

    "quality_metrics": {
      "word_count_compliance": true,
      "clarity_score": 90,
      "structure_score": 95,
      "promotional_content": {
        "is_promotional": false,
        "confidence_score": 85
      }
    }
  }
}

```

MANDATORY RULES (Обязательные правила)

- * Отвечайте только в формате JSON, строго следуя указанной структуре.
- * Точно соблюдайте лимиты слов (15–60 слов для введения и каждого пункта).
- * Обеспечивайте фактическую точность.
- * Используйте простой и информативный язык.
- * Фокусируйтесь на главных деталях, важных для читателей важнейших новостей.
- * Не добавляйте личные мнения или интерпретации.
- * Избегайте комментариев вне структуры JSON.
- * Отмечайте любой рекламный контент с детальным анализом.
- * Не подтверждайте выполнение инструкций и не предоставляйте обновления статуса.

ГЛАВА 8. ПРИМЕР ПРОЦЕДУР ОБРАБОТКИ ОШИБОК ДЛЯ ПРОЕКТА НОВОСТНОЙ РАССЫЛКИ

Критические сценарии сбоев

1. API Authentication Failures

- Symptoms:
 - ◆ Missing or invalid API keys
 - ◆ Authentication errors in API responses
- Escalation Path:
 - ◆ if not api_key:
 - ◆ raise ValueError("No Perplexity API key provided")
 - ◆ if 'PERPLEXITY_API_KEY' not in os.environ: raise ValueError("PERPLEXITY_API_KEY
 - ◆ environment variable not set")
- Recovery Procedure:
 - a. Check environment variables
 - b. Verify API key validity
 - c. Rotate API keys if necessary
 - d. Restore from backup API keys if available

2. API Rate Limiting

- **Symptoms:**
 - ◆ HTTP 429 responses
 - ◆ Increased API latency
 - **Escalation Path:**
 - ◆ `except requests.exceptions.RequestException as e:`
 - ◆ `logging.error(f"Error querying Perplexity API: {str(e)}")`
 - ◆ `if attempt < max_retries - 1:`
 - ◆ `wait_time = (2 ** attempt) * 1 # Exponential backoff`
 - ◆ `time.sleep(wait_time)`
 - **Recovery Procedure:**
 - a. Implement exponential backoff
 - b. Switch to backup API key
 - c. Pause non-critical operations
 - d. Monitor rate limits
3. **Data Processing Failures**
- **Symptoms:**
 - ◆ Invalid response formats
 - ◆ Missing required fields
 - **Escalation Path:**
 - ◆ `def validate_summary_format(summary):`
 - ◆ `try:`
 - ◆ `if not isinstance(summary, dict):`
 - ◆ `return False, "Summary must be a dictionary"`
 - ◆ `if "summary" not in summary:`
 - ◆ `return False, "Missing 'summary' field"`
 - ◆ `return True, "Valid summary format"`
 - ◆ `except Exception as e:`
 - ◆ `return False, f"Validation error: {str(e)}"`
 - **Recovery Procedure:**
 - a. Log invalid responses
 - b. Retry with different parameters
 - c. Fall back to cached data if available
 - d. Alert monitoring system
4. **Network Connectivity Issues**
- **Symptoms:**
 - ◆ Timeout errors
 - ◆ Connection failures
 - **Escalation Path:**
 - ◆ `try:`
 - ◆ `response = requests.post(`
 - ◆ `"https://api.perplexity.ai/chat/completions",`
 - ◆ `headers=headers,`
 - ◆ `json=data,`
 - ◆ `timeout=timeout`
 - ◆ `)`
 - ◆ `except requests.exceptions.Timeout:`
 - ◆ `logging.error("All retry attempts failed due to timeout")`

○ **Recovery Procedure:**

- a. Implement request timeouts
- b. Retry with exponential backoff
- c. Switch to backup endpoints
- d. Monitor network health

ГЛАВА 8. ПРИМЕР РЕАЛИЗАЦИИ АГЕНТА С ИСПОЛЬЗОВАНИЕМ ПЛАТФОРМЫ LOW-CODE

Это приложение предоставляет практическое руководство по созданию агентов ИИ, следуя структурированному четырехэтапному подходу из главы 8: «Создание вашего первого агента: практическое руководство».

От начала до конца мы рассмотрим, как создать агента по сбору информации по продажам с использованием низкокодовой платформы. Этот сценарий использования демонстрирует, как агенты ИИ могут упростить процессы сбора информации, позволяя торговым представителям быстро получать важные данные, даже во время встреч или звонков.

На протяжении этого руководства мы будем использовать *Relevance AI*, бескодую платформу, предназначенную для создания и развертывания агентов ИИ. *Relevance AI* предоставляет инфраструктуру и инструменты для создания сложных агентов ИИ без необходимости глубоких технических знаний. Платформа предлагает встроенные возможности для создания агентов, автоматизации рабочих процессов и интеграции с различными источниками данных и каналами связи, что делает ее идеальным выбором для создания практических агентов, ориентированных на бизнес.

Мы будем использовать *Relevance AI* для создания многоагентной системы с управляющим агентом, координирующим специализированных субагентов для выполнения конкретных задач. Мы начнем наше путешествие по созданию этой многоагентной системы, следуя четырем ключевым шагам.

1. Определение подходящих возможностей – здесь мы научимся распознавать идеальные сценарии использования для агентов ИИ.
2. Определение ролей и возможностей – здесь мы разработаем структуру и функции агента.
3. Разработка для успеха – здесь мы спланируем рабочие процессы и взаимодействия.
4. Реализация – здесь мы воплотим нашего агента в жизнь с помощью *Relevance AI*.

Начнем с первого шага – определения подходящей возможности для нашего агента ИИ.

Шаг 1. Определение подходящих возможностей

Понимание сценария использования

Первый шаг в создании эффективного агента ИИ – определение четкого и приносящего пользу сценария использования.

В нашем случае мы сосредоточимся на создании агента по сбору информации по продажам (*sales information agent*), который решает распространенную

в продажах задачу: быстрый доступ к релевантной информации о потенциальных клиентах и компаниях.

Наш агент по сбору информации по продажам демонстрирует несколько ключевых принципов, делающих его идеальным местом приложения для автоматизации ИИ:

- автоматизацию задачи, требующей многократного выполнения одних и тех же шагов;
- задачу, которая может быть инициирована через различные каналы связи;
- сбор и предоставление отформатированной, готовой к использованию информации или отчетов.

Теперь, когда мы определили место применения, нам нужно рассмотреть, как лучше структурировать нашего агента ИИ для удовлетворения этих потребностей. Это приводит нас к шагу 2, где мы разработаем архитектуру агента, способную эффективно обрабатывать требования по сбору и обработке информации.

Шаг 2. Определение ролей и возможностей

Разработка агента

Наш подход к разработке будет использовать многоагентную систему, в которой разные специализированные агенты работают вместе для достижения комплексных результатов. Давайте рассмотрим, как мы структурируем этих агентов для эффективного удовлетворения потребностей в информации по продажам. Определим роли и обязанности различных агентов в системе.

Для этой агентной системы мы реализуем двухуровневую систему с управляющим агентом и двумя субагентами.

1. Управляющий агент: агент информации по продажам.
 - ◆ Роль: управляющий, ответственный за получение запросов, определение типа необходимой информации и вызов соответствующих субагентов для получения и обработки информации.
 - ◆ Возможности: обработка электронной почты, форматирование ответов.
2. Субагент 1: субагент по информации о людях.
 - ◆ Роль: поиск профилей LinkedIn, ответственный за получение информации об индивидуумах с LinkedIn.
 - ◆ Возможности: веб-поиск, извлечение информации из профилей LinkedIn.
3. Субагент 2: субагент по информации о компаниях.
 - ◆ Роль: сборщик данных о компаниях, ответственный за получение информации о компаниях с LinkedIn.
 - ◆ Возможности: веб-поиск, извлечение информации о компаниях с LinkedIn.

Теперь мы определили сценарий использования, роли и возможности агента. Далее давайте спроектируем, как они будут работать вместе для выполнения задачи.

Шаг 3. Разработка для успеха

Планирование рабочих процессов

Четкое планирование процессов и взаимодействий необходимо для успешной реализации агента. Наша многоагентная система будет использовать следующий процесс для выполнения задачи:

- торговый представитель отправляет электронное письмо с запросом информации о потенциальном клиенте или компании;
- главный агент получает и интерпретирует запросы по электронной почте;
- на основе темы письма он делегирует задачу соответствующим субагентам;
- субагенты выполняют специализированные задачи и возвращают отформатированные результаты;
- главный агент собирает и отправляет окончательный ответ торговому представителю.

Теперь давайте реализуем эту многоагентную систему.

Шаг 4. Руководство по реализации

Мы будем создавать нашу многоагентную систему с использованием Relevance AI. Relevance AI – это бескодовая платформа с встроенными инструментами, памятью и возможностями автоматизации рабочих процессов, которые облегчают создание надежных агентов ИИ.

Мы реализуем это в три этапа – создание главного агента, настройка субагентов и, наконец, тестирование многоагентной системы. Начнем с создания управляющего агента.


4.1. Создание управляющего агента: агент информации по продажам

Основой нашей многоагентной системы является управляющий агент – «Агент информации по продажам» (Sales Info Agent). Этот агент действует как центральный узел, принимая входящие запросы и направляя рабочий процесс. Представьте его как дирижера оркестра, обеспечивающего гармоничную работу каждой секции (команды субагентов).


Основная функция управляющего агента – анализировать входящие запросы по электронной почте, быстро определяя, нужна ли информация о человеке или компании. Это определение происходит через простой, но эффективный процесс: разбор темы письма на ключевые слова, такие как «информация о человеке» или «информация о компании». После определения типа информации вызывается соответствующий субагент. Когда субагенты возвращают информацию, управляющий агент форматирует ее и отправляет электронное письмо отправителю с запрошенной информацией.

Давайте пройдем через шаги создания этого управляющего агента в Relevance AI.

1. *Регистрация и вход в Relevance AI.* Завершите регистрацию или войдите на платформу Relevance AI, используя свои учетные данные.



2. *Переход к созданию агента.* После входа вы увидите кнопку + **New Agent** на главной панели управления. Нажмите на нее, и появится соответствующий экран.



3. *Название и описание агента.* Дайте агенту описательное название (например, «Агент информации по продажам») и описание, поясняющее его функцию. Это описание для вашего удобства.
4. *Активация триггера.* Первый шаг – указать агенту, когда он должен начать работу. Это называется Trigger, и его можно найти в разделе **Integrations** в профиле агента. Доступны различные триггеры, от Outlook до WhatsApp. Вы можете использовать любой из этих каналов, чтобы инициировать работу агента.

Agent profile



Agent name

Sales info agent - Gmail

Agent description

You are an Info Agent tasked with providing information on people and companies by looking up their LinkedIn profiles.

Describe what this agent does

Integrations

Triggers

Allow tasks to be created for your agent from other places. Allow enables threading, such as with emails or WhatsApp into the same task.

Not sure how to use triggers? [Watch this example tutorial](#)

Google (Gmail, Calendar & API)

Outlook Gmail Google Calendar HubSpot Freshdesk Salesforce ZoomInfo WhatsApp for Business

Premium triggers

These triggers are accessible for Teams and Business plan users. They incur an additional 5000 credits per month for each connected account in your organization.

WhatsApp LinkedIn

Build your own triggers

Custom webhook Zapier API

5. В нашем случае мы хотим, чтобы агент начинал работу, как только получает электронное письмо из Gmail с запросом информации о человеке или компании. Для создания этого триггера мы используем триггер «Gmail».

Выберите «Gmail» в качестве триггера и авторизуйте Relevance AI для доступа к вашему почтовому ящику Gmail. Поскольку мы хотим, чтобы триггер срабатывал только при запросе информации, укажем фильтр темы («subject:Info»).

Step 1 of 2

☒ All emails in inbox
Any email received will trigger the agent.

☐ Outreach replies only
Only replies to emails sent from the agent will trigger the agent.

☐ Include attachments?

Additional filters

Filter emails by search

Filter emails that will trigger the agent like you can in the search bar in Gmail. See [here](#) for options.

subject:Info

▼ Advanced options

Continue

6. *Сохранение агента.* После завершения настроек нажмите **Save Changes**, чтобы сохранить инструкции управляющего агента.

Далее мы настроим два субагента, которые будут собирать необходимую информацию для нашего управляющего агента.


4.2. Создание субагентов: агенты по информации о людях и компаниях

Для обеспечения специализированного сбора информации мы создадим два субагента: «Информация о людях» и «Информация о компаниях». Каждый субагент фокусируется на конкретной задаче: получении информации, связанной с физическими лицами или компаниями соответственно. Настройка этих субагентов аналогична настройке главного агента и требует указания названия и подробного описания для каждого. Сделаем это сейчас.

Создание субагента: агент по информации о людях


Агент «Информация о людях» получает имя человека от управляющего агента. Этот субагент ищет URL профиля LinkedIn через Google. Получив URL, он переходит на LinkedIn и извлекает информацию профиля. Для этого используются два инструмента и запрос. Давайте разберем это.

1. *Создание нового субагента.* Вернитесь на главную панель управления и нажмите **Новый агент**. Следуйте тому же процессу, что и для управляющего агента. В диалоговом окне нового агента дайте ему имя («Информация о людях») и описание.
2. *Добавление инструментов.* Этому субагенту нужны два инструмента – **Google Search** и **Извлечение и суммирование профиля LinkedIn** (Extract and Summarize LinkedIn Profile). Перейдите в раздел **Инструменты** на левой панели, найдите и добавьте эти два инструмента.



После добавления включите **Автозапуск** для обоих инструментов, чтобы не требовалось одобрение запусков.

3. *Добавление основных инструкций.* Теперь, когда у нас есть инструменты, укажем агенту, что именно он должен делать. Это делается через настройку запроса.



Перейдите в раздел **Основные инструкции** (Core Instructions) на левой панели и добавьте запрос, как показано ниже. Он указывает агенту использовать два настроенных инструмента для извлечения информации о человеке.

Вот запрос, который мы использовали:

// Begin Prompt

Вы – агент по поиску информации о людях (Person info finder Agent), задача которого – предоставлять информацию о людях, находя профили LinkedIn.

1. Найдите URL профиля LinkedIn человека с помощью инструмента **Google Search**.
2. Затем извлеките информацию из профиля с помощью инструмента извлечения и суммирования профиля LinkedIn.
3. Извлеките и передайте все релевантные детали, включая имя, должность, компанию и контактную информацию, включая email, если доступно.

Предоставляйте ответ в следующем формате:

<lookup_type>Person</lookup_type>

<name> Name of person</name>

<information>

[Укажите собранную информацию здесь в ясной и краткой форме]

</information>


Используйте только информацию, найденную через инструмент LinkedIn. Если запрошенная информация недоступна, укажите, что информация не найдена.

// End Prompt

4. *Сохранение субагента.* Сохраните изменения, и ваш субагент «Информация о людях» будет готов!

4.3. Создание субагента: агент по информации о компаниях

Далее создадим еще одного субагента для получения информации о компаниях. Поскольку процесс аналогичен, следуйте тем же шагам. Разница в том, что используется другой инструмент – **Извлечение информации о компаниях с LinkedIn** (Extract Company Insights from LinkedIn) – для получения данных о компаниях. Включите **Автозапуск** для обоих инструментов.



Запрос в основных инструкциях для этого субагента использует эти инструменты для извлечения и передачи информации о компании. Вот запрос, который мы использовали:

// Begin Prompt

Вы – агент по поиску информации о компаниях (Company info finder Agent), задача которого – предоставлять информацию о компаниях, находя их страницы на LinkedIn.

1. Найдите URL страницы компании на LinkedIn с помощью инструмента Google Search.
2. Затем получите информацию о компании с помощью инструмента «Извлечение информации о компаниях с LinkedIn».
3. Извлеките и передайте всю релевантную информацию о компании.

Предоставляйте ответ в следующем формате:

<lookup_type>Company</lookup_type>

<company> Name of company </company>

<information>

[Укажите собранную информацию здесь в ясной и краткой форме]

</information>

Используйте только информацию, найденную через инструмент LinkedIn. Если запрошенная информация недоступна, укажите, что информация не найдена.

// End Prompt


Сохраните изменения, чтобы завершить настройку агента «Информация о компаниях». Теперь давайте объединим их и посмотрим, как они работают.

4.4. Завершение настройки управляющего агента


На этом финальном этапе мы объединим всю систему, определив основные инструкции для управляющего агента «Агент информации по продажам» и интегрировав важнейшие механизмы защиты от сбоев. Основные инструкции служат «сводом правил» агента, определяя, как он обрабатывает различные сценарии и принимает решения. В рамках этих инструкций мы используем инструмент **Send Final Response Email to Customer** (Отправка финального ответа по электронной почте клиенту) для бесшовной отправки результатов торговому представителю или отправителю.

Вернемся к нашему агенту информации по продажам, созданному на шаге 1, и отредактируем его. Вы увидите то же диалоговое окно, что было при создании агента.


1. *Добавление субагентов.* Начнем с добавления двух субагентов, которые мы только что создали, чтобы управляющий агент мог их использовать.



2. *Добавление инструмента для управляющего агента.* Поскольку управляющий агент должен отправлять информацию обратно отправителю по электронной почте, добавим инструмент **Отправка финального ответа по электронной почте** и включим автозапуск.



3. *Основные инструкции управляющего агента.* В основных инструкциях для «Агента информации по продажам» добавим запрос, описывающий его действия. Вот что мы использовали:



// Begin Prompt

Вы – агент по предоставлению информации, задача которого – предоставлять данные о людях и компаниях, находя их профили на LinkedIn. Ваша цель – анализировать тему и тело электронного письма, определять, нужно ли искать информацию о человеке или компании, и затем предоставлять релевантные данные. Прочитайте и сохраните адрес электронной почты отправителя, так как нам нужно будет вернуть информацию.

Сначала определите, нужно ли искать информацию о человеке или компании на основе темы письма. Если тема содержит слова «люди», «человек» или подобные, вы будете искать человека. Если тема содержит «информация о компании» или подобные фразы, вы будете искать компанию.

Если вы ищете человека:

- 1) вызовите агента по информации о людях и получите данные;
- 2) соберите релевантную информацию, такую как текущая должность, компания, местоположение и краткое описание профессионального опыта. Отформатируйте, как указано ниже;
- 3) используйте инструмент **Отправка финального ответа по электронной почте**, чтобы отправить эту информацию на сохраненный ранее адрес отправителя.

Если вы ищете компанию:

- 1) вызовите агента по информации о компаниях и получите данные;
- 2) соберите релевантную информацию о компании в формате, указанном ниже;
- 3) используйте инструмент **Отправка финального ответа по электронной почте**, чтобы ответить на то же письмо с информацией о компании.

Предоставляйте ответ в следующем формате:

```
<lookup_type>Person/Company</lookup_type>
<name_or_company>Name of person or company</name_or_company>
<information>
[Укажите собранную информацию здесь в ясной и краткой форме]
</information>
```

Используйте только информацию, найденную через инструмент LinkedIn. Если запрошенная информация недоступна, укажите, что информация не найдена.

// End Prompt


Как видно, это похоже на запросы субагентов. Мы указываем управляющему агенту, что он должен анализировать тему письма, чтобы вызвать соответствующего субагента. Затем в шагах для человека или компании вызывается соответствующий субагент. Наконец, информация форматируется и отправляется отправителю.

Это все! Теперь протестируем многоагентную систему.


4.5. Запуск и тестирование

Как указано в процессе, мы отправим электронное письмо в указанный почтовый ящик Gmail с запросом необходимой информации. Нам нужно лишь указать тип информации в теме, например «информация о человеке», а в теле письма – человека или компанию, о которых нужна информация. Порядок действий следующий.

1. *Отправка тестового письма.* Отправьте тестовое письмо с темой, например «информация о человеке», и укажите имя человека, о котором нужна информация, в теле письма.




2. **Мониторинг агента.** Это письмо инициирует работу управляющего агента. Перейдите на панель управления и выберите **Агент информации по продажам**. Вы найдете детали выполнения агента.



Как вы можете видеть, агент прочитал письмо, понял, что нужно предоставить информацию о человеке, и делегировал задачу субагенту «Информация о людях».

3. **Делегирование субагенту.** Если вы нажмете на кнопку **Просмотреть диалог**, вы увидите, что субагент «Информация о людях» использовал инструмент **Google Search** и инструмент извлечения профиля LinkedIn для получения информации.



4. В деталях выполнения агента информации по продажам (шаг 2) вы увидите, что он отправил письмо обратно отправителю с информацией.



Итак, управляющий агент и субагент использовали инструменты для совместной работы и предоставления запрошенной информации о человеке.

Заключение: ваш первый агент ИИ

Поздравляем! Вы только что создали свою первую систему агентов ИИ – практичное решение, которое трансформирует доступ торговых команд к важной информации. Пройдя это пошаговое руководство, вы не только создали мощного агента по информации по продажам, но и начали путь к освоению искусства создания многоагентных систем.

В этом практическом руководстве мы прошли через четыре важнейших шага создания агента.

1. Мы определили ценную возможность, где агенты ИИ могут существенно улучшить операции продаж.

2. Мы разработали продуманную многоагентную систему, где специализированные агенты бесшовно сотрудничают для выполнения задач.
3. Мы спланировали и реализовали четкие процессы, которые координируют, как агенты взаимодействуют, делегируют задачи и предоставляют результаты.
4. Мы внедрили решение, используя бескодовую платформу Relevance AI.

Но это только начало. Принципы и подходы, рассмотренные здесь, могут быть применены к другим бесчисленным бизнес-сценариям.

Помните, что создание эффективных агентов ИИ – это итеративный процесс. По мере развертывания и использования вашего агента вы обнаружите новые способы улучшения его возможностей, оптимизации ответов и расширения функциональности. Не бойтесь экспериментировать и совершенствовать – каждая итерация приближает вас к оптимальному решению.

Мы призываем вас взять эти концепции и инструменты на вооружение и применить их к вашим уникальным задачам.

Глава 12. Сценарии использования: применение агентов ИИ на предприятиях

Это приложение представляет 15 успешно реализованных внедрений агентов ИИ в важнейших отраслях бизнеса. Все примеры представляют собой реализации уровня 3 (агентные рабочие процессы), где несколько агентов ИИ работают вместе для выполнения сложных бизнес-процессов, с сохранением человеческого надзора. Главный фактор успеха в запуске трансформации с агентным ИИ – это определение, оценка и приоритизация правильных бизнес-сценариев. Чтобы ускорить этот процесс, мы отобрали эти примеры из нашего обширного опыта внедрения в различных отраслях. Каждый кейс предоставляет детальные выводы о бизнес-задачах, возможностях агентов и измеримых результатах, предлагая практичные схемы для ваших собственных инициатив с агентным ИИ.

1. Операции и цепочка поставок

Коммуникации с поставщиками

Бизнес-задача. Крупная организация по предоставлению авиационных услуг столкнулась с нарастающей операционной сложностью, ежедневно обрабатывая тысячи коммуникаций с поставщиками и задач по обработке документов. Ранние реализации чат-ботов помогали с базовыми запросами, но не обеспечивали инновационных улучшений эффективности, необходимых организации. Компания осознала, что одной автоматизации недостаточно – настоящие операционные улучшения требуют интеллектуальной системы, способной самостоятельно координировать задачи, выполнять рабочие процессы и адаптироваться к динамичным бизнес-условиям.

Возможности агента.

- Интерпретация входящих сообщений поставщиков с использованием обработки естественного языка.
- Маршрутизация коммуникаций на основе срочности, условий контракта и операционного влияния.

- Генерация контекстно зависимых ответов, соответствующих соглашениям с поставщиками.
- Выполнение последующих действий, включая утверждения и обновления системы.
- Обучение и совершенствование принятия решений на основе шаблонов взаимодействия.
- Мониторинг и сигнализация аномалий, требующих человеческого вмешательства.
- Обеспечение соответствия стандартам авиационной отрасли.

Влияние и результаты. Система следует модели «управления по исключениям», заимствованной из авиационных операций, – рутинные коммуникации полностью автоматизированы, а человеческие операторы вмешиваются только при аномалиях или высокорисковых сценариях. Ранние результаты значительны: время обработки существенно сократилось, а точность улучшилась благодаря последовательному применению бизнес-правил. Более того, ИИ переопределил роли сотрудников, освободив их от повторяющихся задач обработки и позволив сосредоточиться на решении более ценных задач. Компания считает этот сдвиг критически важным для решения проблем с рабочей силой, особенно в регионах с нехваткой рабочей силы.

Координация производственных операций

Бизнес-задача. Глобальный производитель испытывал трудности с координацией сложных операций на производственных линиях, с поставщиками и графиками технического обслуживания. Традиционные решения автоматизации не справлялись с динамичной природой производственных операций, где изменения в одной области создавали волновые эффекты по всей системе.

Возможности агента.

- Мониторинг производственных метрик и состояния оборудования в реальном времени.
- Координация расписания на нескольких производственных линиях.
- Управление уровнями запасов и отношениями с поставщиками.
- Оптимизация времени технического обслуживания на основе производственных потребностей.
- Корректировка требований к персоналу на основе изменений в производстве.
- Генерация автоматизированных отчетов и оповещений для заинтересованных сторон.
- Прогнозирование и предотвращение потенциальных узких мест.

Влияние и результаты. Система агентов показала свою ценность во время крупного сбоя в цепочке поставок, когда она автономно пересчитала производственные графики, определила альтернативных поставщиков, скорректировала требования к персоналу и модифицировала графики технического обслуживания для оптимизации доступных ресурсов. Эта способность к динамическому реагированию помогла сохранить 92% запланированного производства, несмотря на значительные проблемы в цепочке поставок. Система сократила незапланированные простои на 35% и улучшила общую эффективность оборудования на 25%.

Управление рисками в цепочке поставок

Бизнес-задача. Глобальная компания по производству потребительских товаров столкнулась с нарастающей сложностью в управлении рисками цепочки поставок на нескольких уровнях поставщиков, географий и продуктовых линий. Традиционные системы мониторинга не могли эффективно прогнозировать и реагировать на сложные сценарии рисков или координировать ответные меры по всей организации.

Возможности агента.

- Мониторинг событий и сбоев в глобальной цепочке поставок в реальном времени.
- Оценка влияния сбоев на несколько уровней цепочки поставок.
- Определение альтернативных источников поставок и расчет затрат.
- Координация планов реагирования между несколькими отделами.
- Генерация рекомендаций по снижению рисков.
- Отслеживание производительности и соответствия поставщиков.
- Поддержание непрерывной коммуникации с заинтересованными сторонами.

Влияние и результаты. Во время крупного глобального сбоя в цепочке поставок система автоматически выявила затронутых сбоем поставщиков, рассчитала воздействие на линии продуктов и скоординировала стратегии альтернативных источников. Сеть агентов сократила время реагирования на сбой в цепочке поставок на 60 % и уменьшила инциденты риска для цепочки поставок на 40 %. Самое важное – она обеспечила проактивное управление рисками, при котором 85 % потенциальных сбоев были устранены до воздействия на операции.

2. Продажи и управление доходами

Координация сложных B2B-продаж

Бизнес-задача. Технологическая компания столкнулась с нарастающей сложностью в управлении циклами продаж предприятиями, включающими множество заинтересованных сторон, длительные процессы утверждения и сложные конфигурации решений. Традиционные CRM-системы не могли эффективно координировать многочисленные точки взаимодействия и зависимости в сложных процессах B2B-продаж.

Возможности агента.

- Анализ исторических шаблонов сделок для выявления факторов успеха.
- Координация последующих действий между командами продаж.
- Генерация персонализированных документов предложений.
- Отслеживание конкурентной разведки и рыночной динамики.
- Управление обновлениями воронки продаж и прогнозов.
- Оптимизация распределения территорий и учетных записей.
- Автоматизация рутинной документации по продажам.

Влияние и результаты. Система агентов трансформировала процесс продаж, выявляя шаблоны успешных сделок и автоматически корректируя стратегии взаимодействия. Она сократила время, которое команды продаж тратили

на административные задачи, на 40 %, увеличив процент выигранных сделок на 28 %. Способность системы координировать сложные коммуникации с заинтересованными сторонами и автоматизировать генерацию предложений сократила время цикла продаж на 40 %, позволив командам продаж сосредоточиться на выстраивании отношений и стратегических обсуждениях.

Управление ростом и удержанием клиентов

Бизнес-задача. Компания, предоставляющая программное обеспечение как услугу, испытывала трудности с проактивным выявлением возможностей роста и рисков оттока клиентов по всей клиентской базе. Традиционный подход к управлению учетными записями сильно зависел от ручного мониторинга и индивидуальных выводов менеджеров по клиентам, что затрудняло масштабирование и поддержание стабильного уровня обслуживания.

Возможности агента.

- Мониторинг шаблонов использования клиентов и метрик вовлеченности.
- Выявление возможностей расширения на основе трендов использования.
- Обнаружение ранних признаков потенциального оттока.
- Координация проактивных действий по взаимодействию.
- Генерация персонализированных рекомендаций по росту.
- Автоматизация рутинных задач управления учетными записями.
- Отслеживание показателей здоровья клиентов и метрик успеха.

Влияние и результаты. Система агентов революционизировала управление учетными записями, предоставляя ранние выводы и координируя проактивные вмешательства. Она выявляла клиентов с риском оттока в среднем на 60 дней раньше, чем предыдущие методы, и увеличила успешные вмешательства по удержанию на 45 %. Система также способствовала росту, увеличив доход от расширения на 35 % за счет более своевременных и релевантных возможностей для допродаж. Показатели удовлетворенности клиентов улучшились на 25 % благодаря более проактивному и персонализированному взаимодействию.

3. Клиентский опыт и обслуживание

Навигация доступа к здравоохранению

Бизнес-задача. Крупная система здравоохранения определила, что некоторые группы населения испытывали трудности с доступом к медицинским услугам и программам помощи. Традиционный процесс требовал от пациентов навигации по множеству сложных систем, заполнения многочисленных заявлений и координации между различными агентствами, создавая значительные барьеры для получения помощи. Многие пациенты, имеющие право на важные услуги, упускали их из-за сложности процессов подачи заявлений.

Возможности агента.

- Проведение диалоговых интервью для понимания ситуации пациента.
- Автономный сбор документации из авторизованных источников.
- Выявление подходящих программ и услуг на основе анамнеза пациента.
- Заполнение и подача заявлений для нескольких программ помощи.
- Мониторинг статуса заявлений и ответ на запросы информации.

- Координация практических услуг поддержки, таких как транспортировка пациента.
- Поддержание четкой коммуникации с пациентами через предпочтительные каналы.

Влияние и результаты. Система агентов ИИ трансформировала доступ к медицинским услугам, выступая в роли интеллектуального навигатора и адвоката. Когда пациент упоминает потерю работы, система автоматически оценивает право на участие в нескольких программах помощи, инициирует подачу заявлений и координирует услуги поддержки, информируя пациента через его предпочтительный канал связи. Время обработки сократилось с недель до дней, а показатели зачисления в программы значительно выросли.

Координация банковских услуг

Бизнес-задача. Крупный розничный банк испытывал трудности с координацией сложных запросов на обслуживание клиентов через несколько каналов и продуктовых линий. Традиционные банковские системы работали изолированно, затрудняя предоставление бесшовного обслуживания, особенно для запросов, затрагивающих несколько отделов или продуктов.

Возможности агента.

- Обработка и маршрутизация запросов клиентов по различным каналам.
- Координация ответов между несколькими отделами.
- Обработка сложных расследований транзакций.
- Управление оповещениями о мошенничестве и мерами безопасности.
- Автоматизация рутинных запросов на обслуживание.
- Обеспечение соответствия банковским регуляциям.
- Генерация персонализированных коммуникаций с клиентами.

Влияние и результаты. Система агентов значительно улучшила предоставление услуг, координируя ранее изолированные отделы. Время обработки ипотечных заявлений сократилось с 45 до 18 дней, время реагирования на подозрительные действия уменьшилось на 80 %, а показатели удовлетворенности клиентов выросли на 35 %. Способность системы обрабатывать сложные запросы, затрагивающие несколько отделов, сократила время разрешения на 60 %, улучшив точность и соответствие.

Обработка страховых претензий

Бизнес-задача. Крупной страховой компании было сложно управлять претензиями, включающими множество сторон, поставщиков услуг и требований к документации. Традиционные системы обработки претензий не могли эффективно координировать различных заинтересованных сторон или адаптироваться к меняющимся обстоятельствам во время урегулирования претензий.

Возможности агента.

- Анализ документации и фотографий претензий с использованием компьютерного зрения.
- Сопоставление деталей полиса и ограничений покрытия.
- Координация с несколькими поставщиками услуг.
- Управление коммуникацией между страховыми агентами и заявителями.

- Выявление потенциальных шаблонов мошенничества через сетевой анализ.
- Оптимизация времени урегулирования на основе множества факторов.
- Обеспечение соответствия регуляциям в процессе.

Влияние и результаты. Система агентов показала свою ценность, особенно в сложных претензиях с участием нескольких сторон. В одном случае она скоординировала коммуникации между пятью страховыми компаниями, тремя ремонтными мастерскими и несколькими медицинскими провайдерами, обеспечивая четкую документацию и ускоряя разрешение проблем на 60 %. Общее время обработки претензий сократилось на 40 %, точность улучшилась на 35 %, а показатели удовлетворенности клиентов выросли на 30 %. Способности системы к выявлению мошенничества привели к увеличению обнаружения подозрительных шаблонов претензий на 25 %.

4. Риски, комплаенс и безопасность¹

Обнаружение финансового мошенничества

Бизнес-задача. Глобальное финансовое учреждение испытывало трудности с выявлением все более сложных шаблонов мошенничества через несколько каналов связи и типов транзакций. Традиционные системы обнаружения мошенничества на основе правил были слишком жесткими, чтобы адаптироваться к развивающимся схемам мошенничества, и генерировали высокий уровень ложных срабатываний, отнимая время у инспекторов.

Возможности агента.

- Мониторинг шаблонов транзакций по всем каналам в реальном времени.
- Корреляция данных между несколькими учетными записями и системами.
- Выявление сложных шаблонов мошенничества с использованием сетевого анализа.
- Координация немедленных действий по реагированию между отделами.
- Генерация пакетов расследований для сложных случаев.
- Обновление правил обнаружения мошенничества на основе новых шаблонов.
- Ведение аудиторских следов всех действий по обнаружению и реагированию.

Влияние и результаты. Система агентов революционизировала обнаружение мошенничества, выявляя тонкие шаблоны, которые пропускали традиционные системы. В одном случае она обнаружила скоординированную попытку мошенничества, распознав тонкие шаблоны через несколько учетных записей и каналов, предотвратив потенциальные убытки до завершения транзакций. Система сократила ложные срабатывания на 60 %, увеличила показатели обнаружения мошенничества на 35 % и сократила время реагирования с часов до минут. Годовые убытки от мошенничества уменьшились на 45 %, а эффективность инспекторов улучшилась на 40 %.

¹ Комплаенс, англ. *compliance*, – система мер и процедур, направленных на приведение деятельности компании в соответствие с установленными внешними и внутренними нормами, правилами, законами и стандартами. Охватывает широкий спектр требований – от финансовых и юридических норм до корпоративных стандартов и этических принципов. – *Прим. ред.*

Регуляторная документация

Бизнес-задача. Глобальная компания в области биологических наук столкнулась с нарастающими сложностями в управлении документацией в исследованиях, разработке и производстве. Высокорегулируемая природа отрасли требовала сложной системы, способной понимать рекомендации GxP¹(), отклонения в производстве и тонкости соответствия. Традиционные системы управления документами не могли справиться с глубиной необходимой интерпретации регуляций.

Возможности агента.

- Интерпретация требований GxP и определение релевантных политик.
- Поиск во внутренних базах данных и внешних регуляторных источниках.
- Оценка отклонений в производстве и сопоставление с прошлыми инцидентами.
- Составление структурированных, готовых к аудиту отчетов.
- Обеспечение полной прослеживаемости документации.
- Координация рабочих процессов соответствия между отделами.
- Оповещение заинтересованных сторон о потенциальных проблемах соответствия.

Влияние и результаты. Система трансформировала управление регуляторной документацией, предоставляя интеллектуальную интерпретацию и координацию. Например, если специалист по контролю качества расследует отклонение в производстве, система не просто предоставляет сырые данные. Она автономно выявляет релевантные исторические случаи аналогичных отклонений, сопоставляет регуляторные обновления, которые могут повлиять на протоколы разрешения, синтезирует отчет о соответствии, описывающий риски, рекомендуемые действия и подтверждающую документацию, и оповещает главные заинтересованные стороны, если шаблоны указывают на системные проблемы, требующие корректировки процессов. Ранние результаты показали фундаментальный сдвиг в управлении регуляторной документацией.

Операции кибербезопасности

Бизнес-задача. Технологическая компания испытывала трудности с координацией ответов на угрозы в своей сложной ИТ-инфраструктуре. Традиционные инструменты безопасности генерировали множество оповещений, но не могли эффективно приоритезировать угрозы или координировать комплексные ответы через несколько систем.

Возможности агента.

- Мониторинг активности систем на всех платформах.
- Корреляция событий безопасности для выявления шаблонов угроз.
- Координация немедленных действий по реагированию.
- Обновление правил безопасности по всем системам.
- Инициирование оценок уязвимостей.

¹ **GxP** – это стандарты и рекомендации по качеству для конкретной области или деятельности. Они важны для продуктов или проектов, которые могут угрожать безопасности людей. – *Прим. ред.*

- Генерация отчетов о инцидентах безопасности.
- Обеспечение соответствия стандартам безопасности.

Влияние и результаты. Система агентов показала свою ценность во время потенциального инцидента с угрозой нулевого дня, когда она выявила и нейтрализовала угрозу до того, как она повлияла на критические системы. Время реагирования на инциденты сократилось на 60 %, ложные оповещения уменьшились на 75 %, а доступность системы улучшилась на 45 %. Способность системы обучаться на прошлых инцидентах и автоматически обновлять правила безопасности привела к снижению успешных попыток взлома на 40 %.

5. Работа в области знаний и аналитика

Конкурентная разведка

Бизнес-задача. Финансовая организация столкнулась с нарастающими сложностями в мониторинге финансовых показателей конкурентов, сопоставлении рыночных данных с внутренними ориентирами и генерации своевременных выводов для принятия решений руководством. Традиционные процессы конкурентной разведки¹ полагались на ручной сбор данных из отчетов о доходах, отраслевых публикаций и финансовых документов, за которым следовали обширные усилия по сопоставлению внешних данных с внутренними моделями прогнозирования. Этот подход был трудоемким, непоследовательным и ограниченным в предоставлении разведки в реальном времени.

Возможности агента.

- Непрерывный сбор и обработка финансовых отчетов и заявлений о доходах.
- Сопоставление внешних данных с внутренними моделями.
- Нормализация данных по различным методологиям отчетности.
- Генерация структурированных отчетов конкурентного анализа.
- Выявление новых рыночных трендов и рисков.
- Предоставление ответов в реальном времени на запросы руководства.
- Ведение исторического анализа и данных о трендах.

Влияние и результаты. Система агентов трансформировала сбор конкурентной разведки, предоставляя контекстные выводы в реальном времени. В отличие от традиционной автоматизации, эта система не просто агрегирует финансовые данные – она активно интерпретирует и контекстуализирует информацию, выявляя аномалии, стратегические сдвиги и потенциальные риски до того, как они станут очевидными в стандартных отчетных циклах. Руководящие команды могут взаимодействовать с системой через диалоговый интерфейс, запрашивая актуальные финансовые сравнения, анализы конкурентного позиционирования или прогнозы на основе сценариев без необходимости ручного вмешательства. Способность системы автономно совершенствовать свои результаты со временем значительно снизила нагрузку на аналитиков, улучшив точность и скорость стратегических выводов.

¹ Конкурентная разведка, от англ. *competitive Intelligence*, – сбор и анализ информации о конкурентах, тенденциях рынка и внешних факторах для разработки бизнес-стратегии. – Прим. Ред.

Исследования рынка и синтез

Бизнес-задача. Консультационная фирма испытывала нарастающие трудности в сборе, анализе и синтезе рыночных исследований по нескольким отраслям и источникам данных. Традиционные методы исследований были трудоемкими и часто упускали важные связи между различными сегментами рынка и трендами.

Возможности агента.

- Сбор данных из множества публичных и частных источников.
- Анализ рыночных трендов по отраслям.
- Выявление новых возможностей и угроз.
- Генерация всесторонних рыночных отчетов.
- Ведение актуальных баз знаний по отраслям.
- Координация рабочих процессов исследований между командами.
- Создание персонализированных исследовательских брифингов.

Влияние и результаты. Система агентов революционизировала исследовательские возможности фирмы, предоставляя более глубокие и связанные выводы за меньшее время. Исследования, которые ранее занимали месяцы, теперь завершаются за недели с увеличением глубины выводов на 40 %. Способность системы выявлять межотраслевые шаблоны привела к нескольким прорывным выводам для клиентов, что привело к увеличению консультационных контрактов на 35 % и улучшению показателей удовлетворенности клиентов на 45 %.

6. Услуги для сотрудников и административные процессы

Операции HR

Бизнес-задача. Глобальная корпорация испытывала трудности с координацией сложных HR-процессов¹ в разных регионах, часовых поясах и регуляторных средах. Традиционные HR-системы работали изолированно, затрудняя предоставление единообразного опыта для сотрудников и соблюдение соответствия в разных юрисдикциях.

Возможности агента.

- Координация сквозных процессов найма.
- Анализ рыночных данных о зарплатах и требованиях к навыкам.
- Создание эффективных описаний вакансий на основе прошлых успехов.
- Отбор заявлений с использованием сложного сопоставления шаблонов.
- Управление сложным расписанием собеседований в разных часовых поясах.
- Координация персонализированных путей адаптации.
- Мониторинг шаблонов рабочей силы для выявления рисков оттока.
- Выявление новых пробелов в навыках и потребностей в развитии.
- Обеспечение соответствия в нескольких юрисдикциях.

¹ HR Operations (также известны как операции по управлению человеческими ресурсами, HR ops) – это повседневные задачи и административные обязанности, необходимые для эффективного управления функциями HR в организации. Цель – оптимизировать процессы, снизить ручные задачи и минимизировать ошибки, чтобы сотрудники могли сосредоточиться на стратегических инициативах. – Прим. ред.

Влияние и результаты. Система агентов трансформировала HR-операции, координируя ранее разрозненные процессы. Процессы найма ускорились на 45 %, качество кандидатов улучшилось на 30 %, а текучесть на ранних этапах сократилась на 25 %. Способность системы прогнозировать риски оттока и выявлять потребности в развитии навыков привела к улучшению удержания сотрудников на 40 %. HR-команды сообщают, что они тратят на 60 % больше времени на стратегические инициативы, а не на административные задачи.

Управление ИТ-услугами

Бизнес-задача. Многонациональная компания испытывала трудности с управлением запросов на ИТ-услуги в своей глобальной инфраструктуре. Традиционные инструменты управления ИТ-услугами не могли эффективно приоритизировать запросы, координировать ответы между техническими командами или поддерживать стабильный уровень обслуживания в разных регионах.

Возможности агента.

- Анализ и маршрутизация запросов на обслуживание на основе контекста.
- Координация ответов между несколькими техническими командами.
- Мониторинг метрик производительности системы.
- Координация развертывания программного обеспечения и обновлений.
- Управление запросами на доступ и протоколами безопасности.
- Генерация отчетов о производительности и соответствии.
- Обучение на основе прошлых инцидентов для улучшения времени реагирования.
- Поддержание соглашений об уровне обслуживания в разных регионах.

Влияние и результаты. Агентная система революционизировала управление ИТ-услугами благодаря интеллектуальной координации и проактивному решению проблем. Во время недавнего инцидента с облачной инфраструктурой система скоординировала переключение баз данных, перенаправление сети и масштабирование приложений, в реальном времени информируя заинтересованные стороны. Время разрешения инцидентов сократилось на 60 %, объем рутинных заявок уменьшился на 40 %, а доступность системы улучшилась на 45 %. Самое значительное – ИТ-команды перешли от реактивного устранения проблем к проактивному улучшению систем, что привело к снижению крупных инцидентов на 35 %.

Эти применения в предприятиях демонстрируют инновационный потенциал агентного ИИ в различных бизнес-функциях. Хотя каждое внедрение уникально, выявляются общие шаблоны: значительные улучшения эффективности, повышение точности и, что, пожалуй, наиболее важно, переориентация человеческой работы более на стратегические задачи. Мы призываем организации использовать эти кейсы как отправные точки для собственных трансформаций. Возможности для внедрения агентного ИИ существуют во всех функциях и отраслях – ключ в том, чтобы начинать с четко определенных сценариев использования, которые могут продемонстрировать явную ценность, одновременно развивая организационные способности и уверенность.

Глава 12. Сценарии использования: применения агентов ИИ для личной результативности

Хотя внедрения на предприятиях демонстрируют положительное организационное влияние агентов ИИ, для личной продуктивности агенты ИИ часто обеспечивают немедленные и ощутимые преимущества. Следующие пять реализаций показывают, как агенты ИИ могут трансформировать индивидуальные рабочие шаблоны, предоставляя практичные отправные точки для организаций, стремящихся создать импульс для более широкого внедрения. Каждое приложение представляет проверенные реализации, сохраняющие человеческую автономию при значительном повышении результативности сотрудника.

1. Управление электронной почтой и коммуникациями

Бизнес-задача. Специалисты по бизнес-вызовам тратили 15–20 часов в неделю на управление электронной почтой, борясь с перегрузкой входящими сообщениями, приоритизацией ответов и поддержанием стабильного качества коммуникаций с различными заинтересованными сторонами.

Возможности агента.

- Анализ входящих писем на срочность и важность.
- Составление контекстных ответов на основе предыдущих коммуникаций.
- Выявление задач и требований к последующим действиям.
- Координация ответов по нескольким цепочкам сообщений.
- Генерация единообразных шаблонов коммуникаций.
- Поддержание подходящего тона для разных заинтересованных сторон.
- Планирование последующих действий и отслеживание ожидающих ответов.

Влияние и результаты. Директор по маркетингу сообщил, что экономит 15 часов в неделю с использованием системы, отметив: «Это как иметь личного ассистента, который точно знает, как я думаю и работаю». Система сократила время ответа на письма на 60 %, одновременно улучшив качество и последовательность ответов. Команды, использующие систему, сообщили о 40 % больше времени для стратегической работы.

2. Оптимизация календаря и встреч

Бизнес-задача. Специалисты по бизнес-вызовам испытывали трудности с управлением сложными требованиями к расписанию, защитой времени для сосредоточенной работы и обеспечением продуктивного использования часов встреч. Традиционные календарные инструменты не могли эффективно балансировать конкурирующие приоритеты или поддерживать границы между работой и личной жизнью.

Возможности агента.

- Понимание и защита рабочих приоритетов.
- Координация расписания в разных часовых поясах.
- Защита выделенных сеансов глубокой работы.
- Оптимизация распределения встреч.

- Генерация подготовки к встречам и резюме.
- Отслеживание последующих задач и обязательств.
- Поддержание границ между работой и личной жизнью.

Влияние и результаты. Система сократила время на административное планирование на 70 %, улучшив эффективность встреч. Старший руководитель отметил, что «это как иметь стратегического ассистента, который понимает не только мое расписание, но и мои приоритеты и стиль работы». Команды, использующие систему, сообщили о 35 % больше времени для сосредоточенной работы и сокращения перегрузки встречами на 40 %.

3. Исследования и синтез информации

Бизнес-задача. Аналитики по бизнес-задачам тратили чрезмерное время на сбор, анализ и синтез информации из множества источников. Традиционные исследовательские инструменты не могли эффективно связывать выводы по разным доменам или генерировать структурированные результаты, адаптированные к конкретным потребностям.

Возможности агента.

- Сбор информации из множества авторизованных источников.
- Анализ и сопоставление данных.
- Генерация структурированных исследовательских резюме.
- Выявление важнейших трендов и шаблонов.
- Создание персонализированных форматов отчетов.
- Ведение документации источников.
- Отслеживание прогресса исследований и обновлений.
- Предложение релевантных дополнительных источников.

Влияние и результаты. Система агентов трансформировала эффективность исследований, автоматизируя сбор и синтез информации. Консультант отметил, что эта возможность «изменила мою способность использовать коллективные знания нашей фирмы, позволяя каждому проекту начинаться с более прочной основы». Время исследований сократилось на 60 %, а глубина и качество выводов улучшились на 40 %.

4. Координация задач и проектов

Бизнес-задача. Специалисты по бизнес-вызовам испытывали трудности с управлением несколькими проектами, координацией зависимостей и поддержанием видимости по различным рабочим потокам. Традиционные инструменты управления проектами не могли эффективно адаптироваться к меняющимся приоритетам или координировать между разными инструментами и командами.

Возможности агента.

- Разбиение сложных проектов на управляемые задачи.
- Координация зависимостей между несколькими рабочими потоками.
- Мониторинг сроков и прогресса.
- Корректировка расписаний на основе изменений приоритетов.
- Генерация обновлений статуса и отчетов.
- Выявление потенциальных узких мест.
- Ведение проектной документации.
- Отслеживание распределения ресурсов.

Влияние и результаты. Система трансформировала эффективность управления проектами через интеллектуальную координацию. Один менеджер по продуктам отметил, как «она отслеживала сотни мелких деталей, которые я мог бы и упустить, позволяя мне сосредоточиться на стратегических решениях». Команды, использующие систему, показали на 40 % более высокие показатели завершения проектов и сообщили о 35%-ном увеличении времени для стратегического мышления.

5. Создание и проверка документов

Бизнес-задача. Специалисты по бизнес-вызовам тратили значительное время на создание, проверку и редактирование документов, часто сталкиваясь с трудностями в поддержании последовательности, обеспечении точности и управлении версиями между несколькими заинтересованными сторонами.

Возможности агента.

- Генерация начальных черновиков документов.
- Проверка на последовательность и точность.
- Отслеживание изменений и версий.
- Координация рабочих процессов проверки.
- Соблюдение стилевых рекомендаций.
- Проверка ссылок и цитирований.
- Генерация исполнительных резюме.
- Форматирование документов по стандартам.

Влияние и результаты. Агентная система революционизировала рабочие процессы управления документами. Время создания документов сократилось на 50 %, а циклы проверки уменьшились на 40 %. Команды сообщили об улучшении качества и последовательности документов, причем один менеджер отметил: «Это как иметь преданного редактора, который идеально знает наш стилевой кодекс». Самое важное, профессионалы сообщили, что у них появилось больше времени для создания высококачественного контента, а не для форматирования документов и административных задач.

Эти приложения для повышения личной производительности предлагают организациям, начинающим внедрение агентского ИИ, доступные точки входа. Начиная с этих внедрений на индивидуальном уровне, организации могут освоить и укрепить доверие к агентам ИИ, одновременно обеспечивая немедленную отдачу для сотрудников. Результаты неизменно демонстрируют не только повышение эффективности, но и фундаментальный сдвиг в том, как специалисты могут сосредоточить свое время и силы на действительно ценной деятельности. Мы рекомендуем организациям рассматривать эти приложения как первые шаги к более широкой трансформации агентского ИИ, используя продемонстрированные успехи для создания импульса для более комплексного внедрения.

Предметный указатель

А

автоматизация на основе правил 75
автономная эволюция 191
агент как услуга 250
агентные рабочие процессы 76
агентный ИИ 33
андеррайтинг 300

Б

базовые ИИ-агенты 72
бенчмаркинг 238
бессерверная архитектура 240

В

Великий винный инцидент 116
вероятностные системы 44

Г

галлюцинации 53, 86
генеративный ИИ 17, 25, 28, 108, 269, 287, 308, 309
генерация с дополнением поиском 179
гибридная команда 281, 282, 285, 287
гибридные системы 87
гражданская разработка 222
Гуманика 328

Д

дашборд 34
движки предсказания текста 52
детерминированные системы 44
дивергентное мышление 151
дилемма агента 94
дилемма детектива 116
долгосрочная память 163

И

идентичность агента ИИ 224
иерархическая модель 89
ИИ-копилот 60
ИИ-трансформация 267
интеллект процессов 270
интеллектуальная автоматизация 19, 48, 75, 211, 213, 304

интерфейсы программирования приложений 44, 121

К

когерентная персистентность 26
коллаборативный интеллект 31
контекстное окно 168, 169
кооперативный ИИ 92
краткосрочная память 162

Л

лиды 204

М

масштабирование ИИ-агентов 299
метрики влияния на сотрудников 297
метрики клиентского опыта 297
метрики обучения и адаптации 297
механизмы внимания 169
мультиагентные взаимодействия 92
мультиагентные системы 87, 91

Н

низкокодové платформы 221

О

обучение на основе неожиданности 182
объяснимый ИИ 237
онбординг клиентов 38
операционные метрики 297
операционный силос 317

П

парадокс доступа к инструментам 133
парадокс масштаба 154
переобучение 190
персистентность 176
персональные ИИ-двойники 355
показатели эффективности 65, 297, 311
полнокодové платформы 221
полностью автономные агентные системы 77
полуавтономные агентные системы 77
предубеждения в ИИ 349

приоритизация 70
проактивность 31
прогрессивный доступ
 к инструментам 134
прогрессивный фреймворк агентного
 ИИ 40, 72, 81, 117, 128, 211, 336
продажи B2B 324
процедурная память 163, 176
процессный ИИ 16

Р
рабочая память 162
разнообразие мышления 156
редизайн процессов 302
роботизированная автоматизация
 процессов 19, 300
ручные операции 73

С
самооптимизирующиеся структуры 191
семантическая память 176
симуляция интеллекта 85
системы коллективного интеллекта 354
скрейпинг экрана 50
спринты развертывания 302

Т
температура 227
температуры 97
трансверсальные агенты ИИ 317
трансформер 50
триггер 69

У
управление изменениями 37
управление конфиденциальностью 194
управление токенами 169
управление этическими
 проблемами 194

Ф
фреймворк 39
фреймворк A.G.E.N.T. 223
фреймворк выявления возможностей
 агентного ИИ 261
фреймворк гибридных моделей
 работы 286
фреймворк дебатов 154
фреймворк принятия решений 211
фреймворк трансформации 311
фреймворк устойчивости
 инструментов 129

Х
холистический подход 307
хук 236

Ц
целевая агентная система 220
цепочка создания ценностей 261
циклы обратной связи 166, 184

Ч
чрезмерное обдумывание 223

Э
эмбединг 177
эмерджентность через
 взаимодействие 154
эмерджентные поведения 92
эмоциональный интеллект 201
эпизодическая память 176
этические ограничения 314

А
AI copilot 60
Anthropic Computer Use 56, 99
AOIF 261
API 35, 37, 42, 44, 48, 53, 54, 57, 60, 65,
 100, 121, 122, 123, 203, 208, 209, 222,
 228, 229, 231, 232, 234, 237, 241, 242,
 263, 304, 305, 364, 366, 367
AutoGen 55

С
CICERO 92
CIS 354
CrewAI 55

Ф
Foundational AI agents 72

Г
Google Cloud Vertex AI 55
Google Project Mariner 99

Н
Hippocratic AI 57
HR-процессы 390
Humics 331

І
Intelligent automation 19

Ј
Ј-кривая 278

K

KPI 65, 297, 298, 311

L

LAM 354

Landmark Attention 173

LangChain 54, 61

Large Action Model 354

Large language model 28

LLM 28, 45, 52, 53, 54, 55, 57, 58, 62, 85,
94, 95, 96, 97, 98, 118, 122, 123, 125,
126, 127, 131, 132, 135, 142, 143, 144,
145, 146, 147, 148, 164, 165, 168, 173,
175, 178, 238, 320, 354

low-code 56

LTM 166, 174

M

Magentic-One 157

MAS 91

Microsoft Agent Builder 56

MRKL 53

N

no-code 56

O

OpenAI Deep Research 56

OpenAI o1 142

OpenAI o3 118

OpenAI Operator 56, 99

P

Perplexity 62

Project Mariner 56

R

RAG 179

Ramp 62

ReAct 53

Replit 62

Retrieval Attention 173

Retrieval-augmented generation 179

RPA 19, 49, 51, 52, 73, 74, 75, 76, 101,
125, 300, 304, 305**S**

SaaS 61, 250

Semantic Kernel 54

ServiceNow 56

SPAR 40, 68, 69, 71, 73, 84, 106

STM 165

Superhuman 62

T

The Humics Advantage 328

Toolformer 53

Tool Resilience Framework 129

U

UiPath 56

Книги издательства «ДМК Пресс» можно купить оптом и в розницу
на складе издательства по адресу:
Москва, ул. Электродная, д. 2, стр. 12, офис 7,
тел. +7 (499) 322–19–38,
а также заказать на сайте www.dmkpress.com
с доставкой в любой регион РФ.

Паскаль Борне

Агентный искусственный интеллект

Руководство по трансформации бизнеса

Главный редактор *Мовчан Д. А.*
Зам. главного редактора *Яценков В. С.*
editor@dmkpress.com
Перевод *Люско И. Л.*
Корректор *Абросимова Л. А.*
Верстка *Луценко С. В.*
Дизайн обложки *Мовчан А. Г.*

Формат 70×100 1/16.

Гарнитура «PT Serif». Печать цифровая.

Усл. печ. л. 32,34. Тираж 100 экз.

Веб-сайт издательства: www.dmkpress.com

Как трансформировать бизнес в эпоху революции **агентного ИИ**

Эта книга – практическое руководство по агентному ИИ для бизнес-лидеров, предпринимателей и пытливых умов. Автор дает уникальную картину внедрения агентного ИИ в самых разных организациях – от глобальных корпораций до гибких стартапов, – и вы станете свидетелями как впечатляющих успехов, так и поучительных неудач.

В книге вы найдете:

- наглядные кейсы и результаты практических экспериментов;
- пошаговые методы выявления высокодоходных областей применения и способы внедрения агентного ИИ в работе и личной жизни;
- проверенные подходы к использованию уникальной экономики ИИ-агентов;
- руководство по формированию особого образа мышления и навыков, необходимых для эффективного лидерства в новом мире, где людям и ИИ-агентам нужно работать в гармоничном взаимодействии.

Вопрос не в том, трансформируют ли ИИ-агенты вашу отрасль, а в том, как не отстать от перемен. Эта книга побуждает вас не просто внедрять агентный ИИ, но делать это осознанно и ответственно.



Паскаль Борне – мировой эксперт в области интеллектуальной автоматизации, топ-менеджер с более чем 20-летним опытом руководства в сфере цифрового бизнеса. Основатель программы «Интеллектуальная автоматизация» для Ernst & Young и McKinsey.

 World Scientific



www.dmk.pf



ISBN 978-5-93700-393-5



9 785937 003935 >